



Giới thiệu R cho Nghiên cứu Lâm sàng

Phân tích Dữ liệu Lâm sàng bằng R

Bernard Isekah Osang'ir
Vương Mỹ Lượng

Giới thiệu R cho Nghiên cứu Lâm sàng

Phân tích Dữ liệu Lâm sàng bằng R

Bernard Isekah Osang'ir

Vương Mỹ Lượng



Giới thiệu R cho Nghiên cứu Lâm sàng

Phân tích Dữ liệu Lâm sàng bằng R

Ấn bản thứ nhất, 2026

Bản tiếng Việt của *Introduction to R for Clinical Research: Clinical Data Analysis in R*.

Dữ liệu dùng trong cuốn sách này là dữ liệu mô phỏng phục vụ giảng dạy: chúng giống một nghiên cứu đa trung tâm thực tế về chăm sóc tăng huyết áp, nhưng các kết quả chỉ minh họa phương pháp, không phải phát hiện lâm sàng.

Mọi kết quả, bảng và hình trong sách đều được tạo ra từ mã R in kèm, sử dụng R, knitr và tidyverse; sách được dàn trang bằng XeLaTeX.

Copyright © Neudata, 2026

All property rights and copyright are reserved. This book contains proprietary information and materials developed by Neudata and may not be copied, reproduced, distributed, published or cited, in whole or in part, without the prior written consent of Neudata. Where explicit written permission has been granted, appropriate attribution must be included, followed by “by courtesy of Neudata”.

Neudata Consulting Ltd · www.neu-data.com · contact@neu-data.com

Mục lục

Lời nói đầu	vi
1 Bắt đầu với R và RStudio	1
1.1 R và RStudio là gì	2
1.2 R như một máy tính	4
1.3 Đối tượng và phép gán	8
1.4 Các kiểu dữ liệu	11
1.5 Vectơ	16
1.6 Hàm, đối số và trợ giúp	22
1.7 Gói	24
1.8 Dự án, thư mục làm việc và đường dẫn tệp	26
1.9 Nghiên cứu tình huống và nhập dữ liệu.	27
1.10 Kiểm tra dữ liệu lần đầu.	30
1.11 Toán tử pipe và làm quen với dplyr.	38
1.12 Viết một script có thể tái lập	41
1.13 Tóm tắt.	43
1.14 Đọc thêm	44
1.15 Bài tập	45
2 Tìm hiểu và làm sạch dữ liệu lâm sàng	47
2.1 Vì sao làm sạch dữ liệu lại quan trọng	48
2.2 Dữ liệu gọn gàng và các loại biến	50
2.3 Nhập dữ liệu với các mã giá trị khuyết tường minh	52
2.4 Dữ liệu khuyết: khái niệm và kiểm kê	55
2.5 Bản ghi trùng lặp	59
2.6 Danh mục không nhất quán và khoảng trống.	61
2.7 Kiểm định các giá trị không thể xảy ra	66
2.8 Mã hóa lại và tạo biến dẫn xuất.	70

2.9	Ngày tháng	75
2.10	Factor, thứ tự mức và nhóm tham chiếu	77
2.11	Kiểm định cuối cùng, lưu dữ liệu và nhật ký làm sạch	82
2.12	Tóm tắt	86
2.13	Đọc thêm	87
2.14	Bài tập	87
3	Thống kê mô tả, bảng và hình	90
3.1	Vì sao phải mô tả trước khi kiểm định?	91
3.2	Các loại biến và cách tóm tắt phù hợp	92
3.3	Các số đo xu hướng trung tâm	94
3.4	Các số đo độ phân tán	96
3.5	Hình dạng của một phân phối	100
3.6	Giá trị khuyết và cái bẫy na.rm	104
3.7	Tóm tắt theo nhóm	105
3.8	Từ mô tả đến suy luận: sai số chuẩn và khoảng tin cậy	108
3.9	Mô tả biến phân loại	112
3.10	Xây dựng Bảng 1 với gtsummary	116
3.11	Vẽ hình với ggplot2	120
3.12	Xuất bảng và hình	127
3.13	Tóm tắt	128
3.14	Đọc thêm	129
3.15	Bài tập	129
4	Các kiểm định thống kê thường dùng trong nghiên cứu y học	131
4.1	Từ mô tả đến suy luận	132
4.2	Xác định quần thể phân tích	139
4.3	Kiểm tra giả định phân phối chuẩn	140
4.4	So sánh hai nhóm: biến kết cục liên tục	144
4.5	So sánh nhiều hơn hai nhóm	150
4.6	Hai biến phân loại	155
4.7	Tương quan giữa hai biến liên tục	162
4.8	Chọn kiểm định phù hợp với câu hỏi	165
4.9	Cầu nối sang hồi quy: vì sao xem xét từng biến một là chưa đủ	166
4.10	Báo cáo kết quả đúng cách	167

4.11 Tóm tắt	168
4.12 Đọc thêm	169
4.13 Bài tập	169
5 Mô hình hồi quy và báo cáo kết quả	173
5.1 Vì sao cần hồi quy?	174
5.2 Chuẩn bị phân tích	175
5.3 Hồi quy tuyến tính cho biến kết cục liên tục	177
5.4 Biến kết cục nhị phân: xác suất, odds và log-odds	181
5.5 Mô hình hồi quy logistic	184
5.6 Xây dựng mô hình logistic trong R	187
5.7 Nhiễu: ước lượng thô so với ước lượng hiệu chỉnh	194
5.8 Xây dựng mô hình	199
5.9 Kiểm tra mô hình	201
5.10 Trình bày kết quả	208
5.11 Viết phần kết quả	210
5.12 Báo cáo có thể tái lập	213
5.13 Tóm tắt	216
5.14 Đọc thêm	217
5.15 Bài tập	218
A Lời giải bài tập	221
A.1 Chương 1: Bắt đầu với R và RStudio	221
A.2 Chương 2: Tìm hiểu và làm sạch dữ liệu lâm sàng	227
A.3 Chương 3: Thống kê mô tả, bảng và hình	238
A.4 Chương 4: Các kiểm định thống kê thường dùng trong nghiên cứu y học	247
A.5 Chương 5: Mô hình hồi quy và báo cáo kết quả	259
Tài liệu tham khảo	269

Lời nói đầu

Mọi dự án nghiên cứu lâm sàng đều kết thúc bằng những con số: tỷ lệ bệnh nhân được điều trị, hiệu số huyết áp trung bình, một tỷ số chênh kèm khoảng tin cậy. Những con số ấy định hình các hướng dẫn chuyên môn, các quyết định cấp kinh phí và, rốt cuộc, chất lượng chăm sóc mà người bệnh nhận được. Thế nhưng con đường đi từ một bảng tính chứa các số đo thô đến một câu văn trong bản thảo bài báo lại thường bị che khuất. Nó có thể nằm trong một chuỗi thao tác nhấp chuột mà không ai ghi lại, trong một bảng tính đã bị sửa bằng tay, hoặc trong trí nhớ của một người phân tích duy nhất nay đã chuyển đi nơi khác. Cuốn sách này hướng tới việc làm cho con đường đó trở nên minh bạch, cần trọng và có thể lặp lại.

Introduction to R for Clinical Research (Giới thiệu R cho Nghiên cứu Lâm sàng) hướng dẫn bạn phân tích dữ liệu lâm sàng bằng R, một ngôn ngữ lập trình miễn phí dành cho tính toán thống kê (R Core Team 2026). Sách được viết cho những người làm trong ngành y tế muốn hiểu và tự thực hiện các phân tích của mình, chứ không phải cho các lập trình viên tình cờ làm việc trong lĩnh vực y tế. Chúng tôi bắt đầu từ con số không, không đòi hỏi bất kỳ kinh nghiệm lập trình nào, và kết thúc bằng một phân tích hoàn chỉnh, có thể tái lập, cho một nghiên cứu lâm sàng thực tế: từ việc nhập một tệp dữ liệu thô lộn xộn cho đến việc viết phần Kết quả của một bản thảo bài báo.

Vì sao dùng R cho nghiên cứu lâm sàng?

Trên thị trường có rất nhiều phần mềm thống kê, và hầu hết đều có thể thực hiện một kiểm định t hay một mô hình hồi quy logistic. Lý do để chọn R không nằm ở một phương pháp thống kê cụ thể nào. Nó nằm ở một cách làm việc.

Phân tích dưới dạng mã lệnh

Khi phân tích dữ liệu bằng R, bạn viết các chỉ dẫn vào một script: nhập tệp này, mã hóa lại biến kia, loại bỏ những giá trị không thể xảy ra này, ước lượng mô hình kia. Script *chính là* bản phân tích. Bất kỳ ai có script và dữ liệu thô đều có thể chạy nó và thu được đúng những bảng và hình như vậy. Nếu người phản biện hỏi một biến được tạo ra như thế nào, câu trả lời đã được ghi lại sẵn. Nếu sáu tháng sau bạn phát hiện ra một lỗi trong dữ liệu thô, bạn sửa lỗi đó rồi chạy lại script, và mọi con số phía sau đều được cập nhật một cách nhất quán.

Đây chính là cốt lõi của **nghiên cứu có thể tái lập** (reproducible research): ý tưởng rằng một kết quả được công bố cần đi kèm với dữ liệu và mã lệnh cần thiết để tạo lại nó (Peng 2011). Peng lập luận rằng trong khoa học tính toán, nơi kết quả phụ thuộc vào những chuỗi xử lý dữ liệu dài, khả năng tái lập là tiêu chuẩn tối thiểu để kiểm tra các phát hiện, ngay cả trước khi có ai đó cố gắng lặp lại nghiên cứu một cách độc lập. Nghiên cứu lâm sàng ngày nay đã mang tính tính toán một cách toàn diện. Ngay cả một khảo sát cắt ngang khiếm tốn cũng bao gồm hàng chục quyết định về giá trị khuyết, giá trị ngoại lai, cách phân nhóm và cách xác định mô hình, và

mỗi quyết định đều có thể làm thay đổi câu trả lời.

Phần mềm kiểu "trở và nhấp" khiến chúng ta đưa ra những quyết định đó một cách thâm lặng. Một script buộc chúng phải được thể hiện rõ ràng. Đó là lý do tại sao xuyên suốt cuốn sách này, chúng tôi sẽ yêu cầu bạn viết công việc của mình vào script thay vì gõ lệnh vào console rồi quên chúng đi.

Minh bạch và đáng tin cậy

Nghiên cứu lâm sàng ngày càng được kỳ vọng phải công khai. Các tạp chí yêu cầu tuyên bố chia sẻ dữ liệu, các nhà tài trợ yêu cầu kế hoạch quản lý dữ liệu, và các hướng dẫn báo cáo yêu cầu tác giả mô tả phương pháp thống kê đủ chi tiết để người khác có thể đánh giá. Một script R là phần phương pháp đầy đủ nhất mà bạn có thể viết. Nó không chỉ ghi lại kiểm định *nào* đã được dùng mà còn ghi lại dữ liệu đã được chuẩn bị *như thế nào* cho kiểm định đó, và đây chính là nơi phần lớn các lỗi thực tế xảy ra.

Sự minh bạch cũng bảo vệ chính bạn. Viết mã phân tích buộc bạn phải suy nghĩ về từng bước, và đọc lại mã sau đó giúp bạn, đồng nghiệp hoặc người hướng dẫn phát hiện sai sót trước khi chúng được in ra. Wilson et al. (2017) mô tả một tập hợp các thực hành "đủ tốt" cho tính toán khoa học: giữ nguyên dữ liệu thô, viết mã trong script, đặt tên tệp và tên biến có ý nghĩa, tổ chức mỗi dự án trong một thư mục riêng, và ghi lại các bước biến dữ liệu thô thành kết quả. Không thực hành nào trong số này đòi hỏi kỹ năng nâng cao, và tất cả đều dễ áp dụng trong R. Chúng tôi áp dụng chúng ngay từ chương đầu tiên.

Miễn phí, mở và được sử dụng rộng rãi

R là phần mềm miễn phí và mã nguồn mở. Bạn có thể cài đặt nó trên máy tính xách tay của mình, trên máy tính của bệnh viện hay trên máy chủ của trường đại học mà không phải trả phí bản quyền, và bạn có thể tiếp tục sử dụng khi chuyển cơ quan hay chuyển sang quốc gia khác. Đối với các nhà nghiên cứu ở những nước có thu nhập thấp và trung bình, cũng như bất kỳ ai làm việc với ngân sách hạn hẹp, điều này vô cùng quan trọng. Nó cũng có nghĩa là các cộng sự của bạn có thể chạy mã của bạn mà không cần mua bất cứ thứ gì.

Vì R là phần mềm mở, hàng nghìn nhà thống kê và nhà nghiên cứu đã đóng góp các *gói* (packages): những tập hợp hàm mở rộng khả năng của R. Nhiều phương pháp dùng trong thống kê y học được triển khai đầu tiên trong R, và các phương pháp mới thường xuất hiện ở đó trước bất kỳ nơi nào khác. Trong cuốn sách này, chúng tôi dựa nhiều vào **tidyverse**, một bộ sưu tập nhất quán các gói dùng để nhập, sắp xếp, biến đổi và trực quan hóa dữ liệu, có chung một thiết kế và một "ngữ pháp" (Wickham et al. 2019). Tidyverse giúp mã R đọc lên gần giống như một đoạn mô tả điều bạn muốn làm, điều này hỗ trợ rất nhiều cho người mới bắt đầu và cho bất kỳ ai phải đọc mã của bạn sau này.

Đôi lời thẳng thắn về quá trình học

So với một phần mềm dùng menu, R đòi hỏi ở bạn nhiều hơn trong giai đoạn đầu. Bạn sẽ gõ nhầm, sẽ gặp các thông báo lỗi và đôi khi sẽ tự hỏi tại sao một dấu phẩy lại quan trọng đến thế. Điều này hoàn toàn bình thường, và giai đoạn ấy qua đi nhanh hơn hầu hết mọi người nghĩ. Công sức bỏ ra sẽ được đền đáp nhanh chóng: một khi bạn đã viết được một script làm sạch và mô tả một bộ dữ liệu, việc điều chỉnh nó cho nghiên cứu tiếp theo chỉ mất vài phút thay vì vài ngày, và bạn không bao giờ phải nhớ mình đã chọn những tùy chọn menu nào.

Thực hành tốt

Hãy coi script R như một phần của hồ sơ nghiên cứu, giống như đề cương và kế hoạch quản lý dữ liệu. Lưu nó cùng với dự án, đặt cho nó một cái tên rõ ràng như `02_clean_data.R`, và thêm những chú thích ngắn giải thích *tại sao* mỗi bước được thực hiện, chứ không chỉ *làm gì*.

Cuốn sách này dành cho ai

Cuốn sách này được viết cho những người làm việc trong hoặc liên quan đến lĩnh vực chăm sóc sức khỏe và muốn tự mình phân tích dữ liệu:

- **bác sĩ lâm sàng** thực hiện đánh giá lâm sàng (audit), dự án cải tiến chất lượng hoặc nghiên cứu song song với công việc lâm sàng;
- **dược sĩ** quan tâm đến sử dụng thuốc, tuân thủ điều trị và dược dịch tễ học;
- **điều dưỡng và hộ sinh** thu thập và sử dụng dữ liệu bệnh nhân trong thực hành và nghiên cứu;
- **người làm y tế công cộng, nhà dịch tễ học và cán bộ chương trình** theo dõi dịch vụ và đánh giá các can thiệp;
- **học viên sau đại học và sinh viên đại học** ngành y, điều dưỡng, dược, y tế công cộng và các ngành liên quan cần phân tích dữ liệu cho khóa luận hoặc luận văn;
- **điều phối viên nghiên cứu và cán bộ quản lý dữ liệu** chuẩn bị bộ dữ liệu và muốn hiểu điều gì xảy ra với chúng ở bước tiếp theo.

Bạn **không** cần có nền tảng lập trình. Chúng tôi giải thích từng đoạn mã khi nó xuất hiện lần đầu, và xây dựng dần dần từ việc gõ một phép tính đến việc ước lượng một mô hình đa biến. Bạn cũng không cần toán học nâng cao. Khi một công thức giúp ích cho việc hiểu, chúng tôi trình bày nó và giải thích từng thành phần bằng lời, nhưng trọng tâm luôn là biết *khi nào* một phương pháp là phù hợp, *cách* thực hiện nó đúng, và kết quả *có ý nghĩa gì* đối với người bệnh.

Điều bạn thực sự cần là sự tò mò, khả năng suy luận lâm sàng và sẵn sàng học hỏi từ sai lầm. Kiến thức lâm sàng là một lợi thế thực sự ở đây: bạn đã biết rằng huyết áp tâm thu 700 mmHg là không thể có và một bệnh nhân 200 tuổi là lỗi nhập liệu. Phần lớn công việc phân tích dữ liệu tốt chính là áp dụng một cách có hệ thống đúng loại phán đoán đó.

Những bạn đọc đã sử dụng một phần mềm thống kê khác như SPSS hay Stata sẽ thấy nội dung thống kê quen thuộc và có thể tập trung vào cách triển khai trong R và vào quy trình làm việc có thể tái lập. Những bạn đọc mới làm quen với thống kê sẽ thấy các khái niệm chính được giải thích từ những nguyên lý cơ bản, kèm theo tài liệu tham khảo là các giáo trình thống kê y học kinh điển dành cho những ai muốn tìm hiểu sâu hơn (Altman 1991; Kirkwood and Sterne 2003; Bland 2015).

Những gì bạn sẽ làm được

Khi học xong cuốn sách, bạn sẽ có thể:

1. sử dụng R và RStudio một cách tự tin, làm việc với script trong một RStudio Project;

2. tạo và sử dụng đối tượng, vectơ và khung dữ liệu (data frame), cài đặt và nạp gói;
3. nhập dữ liệu lâm sàng từ tệp CSV và Excel và kiểm tra chúng một cách có hệ thống;
4. nhận biết các vấn đề thường gặp về chất lượng dữ liệu và xác định kiểu biến (số, ký tự, factor, ngày tháng);
5. làm sạch dữ liệu theo cách có thể tái lập: xử lý các mã giá trị khuyết, loại bỏ bản ghi trùng lặp, thống nhất các nhóm phân loại không nhất quán và kiểm tra các giá trị không thể xảy ra;
6. tạo các biến lâm sàng mới, chẳng hạn chỉ số khối cơ thể và phân loại huyết áp, và đặt nhóm tham chiếu hợp lý cho các factor;
7. tính toán đúng các thống kê mô tả, bao gồm cả việc xử lý đúng dữ liệu khuyết;
8. xây dựng "Bảng 1" sẵn sàng cho bản thảo và các hình đạt chất lượng xuất bản, rồi xuất chúng ra tệp;
9. chọn kiểm định giả thuyết phù hợp cho một câu hỏi lâm sàng cụ thể, thực hiện nó, kiểm tra các giả định và diễn giải giá trị p và khoảng tin cậy một cách trung thực;
10. ước lượng các mô hình hồi quy logistic đơn biến và đa biến, diễn giải tỷ số chênh với khoảng tin cậy 95% và kiểm tra mô hình;
11. báo cáo kết quả theo phong cách các tạp chí lâm sàng mong đợi, kèm một script hoàn chỉnh có thể tạo lại mọi con số.

Các kỹ năng này mang tính tích lũy. Mỗi chương lấy kết quả của chương trước làm điểm xuất phát, để đến chương cuối cùng bạn đã thực hiện xong một phân tích hoàn chỉnh cho một nghiên cứu duy nhất.

Cấu trúc của cuốn sách

Cuốn sách gồm năm chương, một phụ lục lời giải và một danh mục tài liệu tham khảo. Tất cả các chương đều dùng chung một nghiên cứu tình huống, được mô tả ở phần sau của lời nói đầu này, để các kỹ năng bạn học được nối tiếp trực tiếp với nhau.

Chương 1: Bắt đầu với R và RStudio. Chúng ta cài đặt R và RStudio, làm quen với giao diện RStudio và tìm hiểu vì sao script và Project là nền tảng của công việc có thể tái lập. Chúng ta dùng R như một máy tính, tạo đối tượng và vectơ, làm quen với các kiểu dữ liệu chính, và học cách cài đặt và nạp gói. Chương này kết thúc bằng việc nhập dữ liệu thô của nghiên cứu tình huống từ cả tệp CSV lẫn bảng tính Excel và xem xét lần đầu, một cách có cấu trúc, nội dung của chúng. Cuối Chương 1, bạn sẽ có dữ liệu thô trong R và cảm nhận được rằng có điều gì đó chưa ổn với nó.

Chương 2: Hiểu và làm sạch dữ liệu lâm sàng. Dữ liệu lâm sàng thực tế hiếm khi sạch, và phân tích dữ liệu "bẩn" sẽ cho ra những câu trả lời tự tin nhưng sai. Chương này lần lượt xử lý các vấn đề được cố ý cài vào tệp dữ liệu thô: các mã giá trị khuyết như 999 và -99, bản ghi bệnh nhân bị trùng lặp, cách viết không nhất quán của các nhóm phân loại, khoảng trống thừa, các số đo không thể có về mặt sinh lý và ngày tháng được ghi theo nhiều định dạng. Chúng ta tạo các biến mới, chuyển các biến phân loại thành factor với nhóm tham chiếu hợp lý về mặt lâm sàng, rà soát dữ liệu khuyết còn lại và lưu một tệp sạch, sẵn sàng cho phân tích. Mọi chương sau đều bắt đầu từ tệp này.

Chương 3: Thống kê mô tả, bảng và hình. Trước khi kiểm định bất cứ điều gì, chúng ta phải mô tả tốt quần thể nghiên cứu. Chương này trình bày các số đo xu hướng trung tâm và độ phân tán, bảng tần số và bảng chéo, cùng cái bẫy thường gặp của giá trị khuyết trong các hàm tóm tắt. Chúng ta xây dựng một "Bảng 1" đạt chất lượng bản thảo với gói **gtsummary** (Sjoberg et al. 2021) và vẽ biểu đồ tần suất (histogram), biểu đồ cột, biểu đồ hộp và biểu đồ phân tán với **ggplot2** (Wickham 2016), chú ý đến các nguyên tắc trình bày đồ họa rõ ràng.

Chương 4: Các kiểm định thống kê thường dùng trong nghiên cứu y học. Ở đây chúng ta chuyển từ mô tả sang suy luận. Chúng tôi giải thích giá trị p là gì và không phải là gì (Wasserstein and Lazar 2016; Greenland et al. 2016), cách kiểm tra các giả định về phân phối, và cách lựa chọn giữa kiểm định tham số và phi tham số. Chúng ta so sánh các nhóm bằng kiểm định t , kiểm định Wilcoxon và phân tích phương sai (ANOVA), xem xét mối liên quan giữa các biến phân loại bằng kiểm định khi bình phương và kiểm định chính xác Fisher, và đo lường tương quan. Mỗi kiểm định được áp dụng cho một câu hỏi thực sự từ nghiên cứu tình huống, với sự chú ý cẩn thận đến độ lớn ảnh hưởng (effect size) và khoảng tin cậy chứ không chỉ riêng giá trị p .

Chương 5: Mô hình hồi quy và báo cáo kết quả. Chương cuối cùng kết nối mọi thứ lại với nhau. Chúng tôi giới thiệu hồi quy logistic cho biến kết cục nhị phân, diễn giải tỷ số chênh, và đi từ mô hình thô đến mô hình hiệu chỉnh, đồng thời thảo luận về nhiễu và các nguyên tắc xây dựng mô hình (Hosmer et al. 2013; Heinze et al. 2018). Chúng ta kiểm tra hiện tượng đa cộng tuyến của mô hình và đánh giá khả năng phân biệt bằng diện tích dưới đường cong ROC, sau đó trình bày kết quả trong một bảng hồi quy sẵn sàng xuất bản và viết một đoạn Kết quả ngắn theo văn phong bản thảo lâm sàng.

Phụ lục: Lời giải bài tập. Mỗi chương kết thúc bằng một loạt bài tập, xếp từ dễ đến khó. Phụ lục đưa ra lời giải chi tiết cho từng bài tập, kèm mã R, kết quả và một đoạn diễn giải ngắn. Hãy dùng phụ lục để kiểm tra bài làm sau khi bạn đã thực sự cố gắng tự giải.

Tài liệu tham khảo. Tất cả các nguồn được trích dẫn trong sách được liệt kê ở cuối sách. Chúng bao gồm các giáo trình thống kê y học kinh điển, các bài báo gốc giới thiệu những phương pháp chúng ta sử dụng và tài liệu tham khảo cho các gói phần mềm. Mỗi chương cũng kết thúc bằng một mục "Đọc thêm" ngắn, chỉ ra những nguồn hữu ích nhất trong số này và giải thích lý do.

Cách đọc và sử dụng cuốn sách

Các chương được thiết kế để đọc theo thứ tự, vì mỗi chương xây dựng trên dữ liệu và kỹ năng do chương trước tạo ra. Nếu đã biết chút ít về R, bạn có thể đọc lướt Chương 1, nhưng xin hãy đọc kỹ Chương 2: tệp dữ liệu sạch được tạo ra ở đó được dùng ở mọi nơi khác, và các quyết định đưa ra khi làm sạch dữ liệu ảnh hưởng đến mọi kết quả về sau.

Mã R và kết quả

Mã R xuất hiện trong các khối có nền tô màu. Kết quả mà R in ra khi chạy mã xuất hiện ngay bên dưới, mỗi dòng bắt đầu bằng `#>`. Ví dụ:

```
# Trung bình của bốn lần đo huyết áp tâm thu (mmHg)
sbp <- c(120, 130, 140, 150)
mean(sbp)
```

R

#> [1] 135

Dòng đầu tiên của khối, bắt đầu bằng #, là một *chú thích* (comment): R bỏ qua mọi thứ đứng sau dấu # trên một dòng, vì vậy chú thích là những ghi chú dành cho người đọc. Dòng thứ hai tạo một đối tượng tên là `sbp` chứa bốn giá trị, và dòng thứ ba tính trung bình của chúng. Dòng `#> [1] 135` là câu trả lời của R. Tiền tố `#>` được thêm vào để bạn có thể phân biệt mã lệnh và kết quả ngay khi nhìn; khi bạn tự chạy mã, kết quả sẽ xuất hiện trong console của RStudio mà không có tiền tố này. (Ký hiệu `[1]` chỉ đơn giản cho biết câu trả lời là phần tử thứ nhất của kết quả; điều này sẽ được giải thích trong Chương 1.)

Toàn bộ kết quả trong sách này đều được tạo ra bằng cách thực sự chạy mã trên dữ liệu của nghiên cứu tình huống trong quá trình biên soạn sách. Nếu chạy cùng mã trên cùng dữ liệu, bạn sẽ thấy cùng kết quả, ngoại trừ những khác biệt nhỏ về định dạng giữa các phiên bản R và các gói.

Trong phần văn bản, tên hàm, tên biến, tên gói và tên tệp được viết bằng phông chữ có độ rộng cố định, ví dụ `mean()`, `treatment_uptake` và `analysis_data.rds`. Tên hàm có kèm cặp ngoặc đơn phía sau để phân biệt với các đối tượng khác.

Các hộp chú ý

Bốn loại hộp được làm nổi bật xuất hiện xuyên suốt cuốn sách. Mỗi loại có một mục đích riêng, và việc nhận ra chúng sẽ giúp bạn định hướng khi đọc.

Hộp **Diễn giải lâm sàng** giải thích một kết quả thống kê có ý nghĩa gì đối với người bệnh hoặc đối với thực hành lâm sàng:

Diễn giải lâm sàng

Một tỷ số chênh bằng 2,0 đối với đái tháo đường có nghĩa là, trong số những bệnh nhân đã được chẩn đoán tăng huyết áp, odds đang được điều trị ở người đồng thời mắc đái tháo đường cao gấp đôi so với người không mắc, sau khi đã tính đến các biến khác trong mô hình. Điều đó không có nghĩa là đái tháo đường làm tăng gấp đôi *xác suất* được điều trị, và trong một nghiên cứu cắt ngang, tự bản thân nó không chứng minh được quan hệ nhân quả.

Hộp **Thực hành tốt** đưa ra một thói quen hoặc kỹ thuật giúp công việc của bạn đáng tin cậy hơn, hiệu quả hơn hoặc dễ đọc hơn:

Thực hành tốt

Không bao giờ sửa tệp dữ liệu thô bằng tay. Hãy giữ nguyên nó đúng như khi bạn nhận được, và thực hiện mọi chỉnh sửa trong script R, để mỗi thay đổi đều được ghi lại và có thể được xem xét lại hoặc hoàn tác.

Hộp **Lỗi thường gặp** cảnh báo về một sai sót mà người mới bắt đầu, và đôi khi cả những người phân tích có kinh nghiệm, thường mắc phải:

Lỗi thường gặp

Chạy `mean(x)` trên một biến có chứa giá trị khuyết sẽ trả về NA thay vì một con số. Thêm `na.rm = TRUE` sẽ loại bỏ các giá trị khuyết trước khi tính toán, nhưng bạn luôn cần báo cáo có bao nhiêu giá trị bị khuyết, thay vì lặng lẽ bỏ chúng đi.

Cuối cùng, mỗi chương khép lại bằng một hộp **Điểm chính** tóm tắt những thông điệp cốt yếu:

Điểm chính

- Script R giúp một phân tích trở nên minh bạch và có thể tái lập.
- Mọi chương đều dùng chung một nghiên cứu tình huống, vì vậy các kỹ năng được xây dựng nối tiếp nhau.
- Hãy tự gõ mã, chạy nó và đọc kết quả thật cẩn thận.

Bài tập và lời giải

Mỗi chương kết thúc bằng năm đến tám bài tập, tất cả đều có thể giải bằng dữ liệu của nghiên cứu tình huống. Các bài tập bắt đầu bằng những nhiệm vụ ngắn nhằm củng cố các kỹ thuật chính, rồi tiến dần đến những câu hỏi mở hơn, yêu cầu bạn lựa chọn cách tiếp cận và diễn giải kết quả về mặt lâm sàng. Lời giải chi tiết được tập hợp trong phụ lục. Bạn sẽ học được nhiều hơn rất nhiều nếu tự làm từng bài trước khi xem lời giải, và sau đó so sánh mã của mình với mã của chúng tôi: thường có nhiều hơn một cách viết đúng.

Hãy gõ, đừng sao chép

Việc sao chép và dán mã từ sách vào R rất hấp dẫn. Thay vào đó, chúng tôi khuyến khích bạn **tự gõ mã**. Việc gõ làm bạn chậm lại vừa đủ để để ý đến từng tên hàm, từng đối số và từng dấu ngoặc. Bạn sẽ mắc những lỗi nhỏ, thấy các thông báo lỗi tương ứng và học cách sửa chúng, và đó chính xác là kỹ năng bạn sẽ cần khi phân tích dữ liệu của riêng mình. Sau vài chương, phần lớn cú pháp sẽ trở thành phản xạ tự nhiên.

Khi gặp lỗi, hãy đọc kỹ thông báo. Nó thường cho bạn biết hàm nào bị lỗi và thường cả lý do. Hãy kiểm tra các dấu ngoặc đơn hoặc dấu nháy chưa được đóng, tên đối tượng viết sai chính tả (R phân biệt chữ hoa và chữ thường, vì vậy `Age` và `age` là khác nhau), và các dấu phẩy bị thiếu giữa các đối số. Sau đó hãy thử nghiệm: mỗi lần chỉ thay đổi một điều rồi chạy lại mã.

Phần mềm và thiết lập

Cài đặt R và RStudio

Bạn cần hai phần mềm miễn phí. **R** là ngôn ngữ và là "động cơ" thực hiện các phép tính. **RStudio** là một môi trường phát triển tích hợp (integrated development environment, IDE): một không gian làm việc thuận tiện đặt bên trên R, với trình soạn thảo script, console, khung hiển thị các đối tượng trong bộ nhớ, và các khung dành cho tệp, đồ thị, gói và trợ giúp. Bạn cài R trước, sau đó cài RStudio.

1. Tải và cài đặt R từ Mạng lưu trữ R toàn diện (Comprehensive R Archive Network, CRAN)

tại <https://cran.r-project.org>. Chọn phiên bản dành cho hệ điều hành của bạn (Windows, macOS hoặc Linux) và chấp nhận các tùy chọn cài đặt mặc định.

2. Tải và cài đặt RStudio Desktop (phiên bản miễn phí) từ <https://posit.co/download/rstudio-desktop/>.
3. Mở RStudio. Phần mềm sẽ tự động tìm thấy R, và bạn sẽ hiếm khi cần mở riêng R.

Cả hai chương trình đều được cập nhật thường xuyên. Bất kỳ phiên bản R nào gần đây đều dùng được với cuốn sách này; nếu bạn đã cài một phiên bản cũ hơn, nên cập nhật trước khi bắt đầu, vì một số gói đòi hỏi phiên bản R tương đối mới.

Các gói được sử dụng trong sách

Bản cài đặt lõi của R đã cung cấp rất nhiều chức năng thống kê, nhưng chúng ta cũng sử dụng một số gói do cộng đồng đóng góp:

- **tidyverse**: bộ sưu tập các gói dùng để nhập, xử lý và trực quan hóa dữ liệu, bao gồm **dplyr**, **tidyr**, **readr**, **forcats** và **stringr** (Wickham et al. 2019);
- **readxl**: nhập dữ liệu từ bảng tính Excel;
- **janitor**: chuẩn hóa tên cột, hỗ trợ tìm bản ghi trùng lặp và lập bảng dữ liệu;
- **lubridate**: đọc và xử lý ngày tháng;
- **gtsummary**: tạo các bảng tóm tắt và bảng hồi quy sẵn sàng xuất bản (Sjoberg et al. 2021);
- **broom**: chuyển kết quả của mô hình thành các khung dữ liệu gọn gàng;
- **ggplot2**: tạo đồ họa dựa trên ngữ pháp đồ họa (grammar of graphics; gói này được cài cùng tidyverse) (Wickham 2016);
- **car**: cung cấp các công cụ chẩn đoán hồi quy, bao gồm hệ số phóng đại phương sai (variance inflation factor, VIF);
- **pROC**: tính toán và vẽ đường cong ROC cùng diện tích dưới đường cong.

Mỗi gói chỉ cần được cài đặt một lần trên mỗi máy tính, tức là tải nó về từ CRAN. Đoạn mã sau cài đặt tất cả các gói dùng trong sách. Việc này cần kết nối internet và có thể mất vài phút trong lần đầu:

```
# Chạy MỘT LẦN trên mỗi máy tính: tải và cài đặt các gói dùng trong sách
install.packages(c(
  "tidyverse", "readxl", "janitor", "lubridate",
  "gtsummary", "broom", "ggplot2", "car", "pROC"
))
```

Sau khi cài đặt, một gói phải được *nạp* bằng `library()` trong mỗi phiên làm việc R mới trước khi có thể dùng các hàm của nó, ví dụ `library(tidyverse)`. Nhầm lẫn giữa hai bước này là một trong những nguyên nhân phổ biến nhất gây bức bối trong giai đoạn đầu: bạn cài đặt một lần, nhưng nạp mỗi lần sử dụng.

Lỗi thường gặp

Đừng để `install.packages()` ở đầu các script phân tích. Cài đặt lại gói mỗi lần chạy script vừa chậm, vừa cần kết nối internet và có thể âm thầm làm thay đổi phiên bản gói

giữa chừng dự án. Hãy cài đặt một lần từ console; nạp gói bằng `library()` trong script.

Làm việc trong RStudio Project

R luôn làm việc tương đối với một thư mục gọi là *thư mục làm việc* (working directory). Nếu mã của bạn đọc `"Data/analysis_data.rds"`, R sẽ tìm thư mục `Data` bên trong thư mục làm việc. Cách đáng tin cậy nhất để quản lý điều này là dùng một **RStudio Project**: một thư mục chứa một tệp `.Rproj` nhỏ báo cho RStudio biết "đây là thư mục gốc của bản phân tích".

Để tạo một Project, chọn *File > New Project*, sau đó chọn *New Directory* hoặc *Existing Directory*, rồi chọn thư mục đang chứa (hoặc sẽ chứa) dữ liệu và script của bạn. Mỗi khi bạn mở dự án, RStudio tự động đặt thư mục làm việc là thư mục đó, nhờ vậy mọi đường dẫn trong mã có thể viết *tương đối* so với nó. Khi đó, bản phân tích của bạn sẽ chạy mà không cần sửa đổi trên máy tính của đồng nghiệp, trên máy chủ hay trên chính máy tính xách tay của bạn một năm sau.

Một cấu trúc thư mục đơn giản và hiệu quả cho một dự án phân tích lâm sàng là:

- `Data/` cho các tệp dữ liệu thô và dữ liệu đã làm sạch (tệp thô không bao giờ bị sửa);
- `Scripts/` cho các script R, được đánh số theo thứ tự cần chạy;
- `Outputs/` cho các bảng và hình do script tạo ra;
- một tệp `README` ngắn mô tả dự án và cách chạy nó.

Thực hành tốt

Tránh dùng `setwd("C:/Users/yourname/Documents/...")` trong script. Một đường dẫn tuyệt đối được viết cứng chỉ hoạt động trên một máy tính. Trong một RStudio Project, hãy dùng đường dẫn tương đối như `"Data/hypertension_phc_raw.csv"`.

Các phiên bản phần mềm dùng trong sách

R và các gói của nó thay đổi theo thời gian, và đôi khi một phiên bản mới làm thay đổi cách một hàm hoạt động hoặc cách kết quả được in ra. Mã trong sách này được chạy với các phiên bản liệt kê dưới đây. Nếu kết quả của bạn trông hơi khác so với của chúng tôi, hãy so sánh phiên bản của bạn với các phiên bản này.

```
# Phiên bản R dùng để tạo ra cuốn sách này
R.version.string
```

```
#> [1] "R version 4.6.1 (2026-06-24 ucrt)"
```

```
# Phiên bản của các gói chính dùng trong sách
pkgs <- c("tidyverse", "readxl", "janitor", "lubridate",
          "gtsummary", "broom", "ggplot2", "car", "pROC")
data.frame(
  package = pkgs,
  version = vapply(pkgs, function(p) as.character(packageVersion(p)),
                   character(1)),
```

```
row.names = NULL
)
```

```
#>      package version
#> 1 tidyverse   2.0.0
#> 2 readxl      1.5.0
#> 3 janitor     2.2.1
#> 4 lubridate   1.9.5
#> 5 gtsummary   2.5.1
#> 6 broom       1.0.13
#> 7 ggplot2     4.0.3
#> 8 car         3.1.5
#> 9 pROC        1.19.0.1
```

Bạn có thể chạy cùng đoạn mã này trên máy tính của mình. Những khác biệt nhỏ ở chữ số cuối cùng của số phiên bản hiếm khi quan trọng; một phiên bản chính (major version, con số đầu tiên) khác đôi khi lại có ảnh hưởng.

Nghiên cứu tình huống

Xuyên suốt cuốn sách, chúng ta phân tích một nghiên cứu duy nhất. Làm việc với một bộ dữ liệu duy nhất, nhất quán từ đầu đến cuối có một ưu điểm lớn: bạn thấy được các quyết định đưa ra khi làm sạch dữ liệu ảnh hưởng thế nào đến các bảng mô tả, các bảng mô tả định hướng việc lựa chọn kiểm định ra sao, và tất cả những điều này dẫn tới mô hình hồi quy cuối cùng và bản báo cáo như thế nào. Điều này phản ánh đúng cách nghiên cứu lâm sàng được thực hiện trong thực tế.

Bối cảnh lâm sàng: tăng huyết áp và khoảng trống điều trị

Huyết áp tăng cao là yếu tố nguy cơ có thể thay đổi hàng đầu gây bệnh tim mạch và tử vong sớm trên toàn thế giới. Đây là nguyên nhân chính gây đột quỵ, bệnh tim thiếu máu cục bộ, suy tim và bệnh thận mạn. Gánh nặng toàn cầu của tăng huyết áp tăng đều đặn, và mức tăng đặc biệt mạnh ở các nước có thu nhập thấp và trung bình, nơi hệ thống y tế thường được tổ chức xoay quanh chăm sóc cấp tính hơn là chăm sóc bệnh mạn tính (Mills et al. 2020).

Một phân tích gộp các nghiên cứu dựa trên quần thể từ khắp nơi trên thế giới cho thấy số người trưởng thành từ 30 đến 79 tuổi bị tăng huyết áp đã tăng gần gấp đôi trong giai đoạn 1990 đến 2019, lên tới hơn một tỷ người (NCD Risk Factor Collaboration (NCD-RisC) 2021). Cũng phân tích này ghi nhận một *khoảng trống điều trị* lớn và dai dẳng: một tỷ lệ đáng kể người bị tăng huyết áp không biết mình mắc bệnh, chưa đến một nửa đang được điều trị, và chỉ một số ít kiểm soát được huyết áp. Khoảng trống lớn nhất ở một số khu vực của châu Phi cận Sahara, Nam Á và châu Đại Dương.

Các loại thuốc hiệu quả và rẻ tiền đã có sẵn. Hướng dẫn của Tổ chức Y tế Thế giới về điều trị tăng huyết áp bằng thuốc khuyến cáo bắt đầu điều trị thuốc ở người trưởng thành đã được chẩn đoán xác định và có huyết áp tâm thu từ 140 mmHg trở lên hoặc huyết áp tâm trương từ 90 mmHg trở lên, còn với những người có nguy cơ tim mạch cao thì bắt đầu điều trị ở ngưỡng thấp hơn (World Health Organization 2021). Do đó, vấn đề ở nhiều nơi không phải là thiếu liệu pháp hiệu quả mà là việc bệnh nhân đã được chẩn đoán không bắt đầu hoặc không duy trì điều trị. Có nhiều nguyên nhân: chi phí và việc không có bảo hiểm y tế, khoảng cách đến cơ sở y tế,

hiểu biết hạn chế về tăng huyết áp, những ưu tiên cạnh tranh khác và việc bệnh không có triệu chứng, cũng như những đặc điểm của chính các dịch vụ y tế.

Các cơ sở chăm sóc sức khỏe ban đầu là nơi phần lớn người trưởng thành bị tăng huyết áp được chẩn đoán và quản lý. Hiểu được bệnh nhân nào đến khám tại các cơ sở này đang được điều trị và bệnh nhân nào không có thể giúp các dịch vụ y tế định hướng hoạt động giáo dục, tiếp cận cộng đồng và bảo vệ tài chính tới những người cần nhất. Đó chính là câu hỏi mà nghiên cứu tình huống của chúng ta giải quyết.

Nghiên cứu

Tên đề tài. *Các yếu tố quyết định việc sử dụng điều trị tăng huyết áp ở người trưởng thành đến khám tại các cơ sở chăm sóc sức khỏe ban đầu (Determinants of hypertension treatment uptake among adults attending primary healthcare facilities).*

Thiết kế. Nghiên cứu cắt ngang đa trung tâm trên 1.500 người trưởng thành đến khám tại sáu cơ sở chăm sóc sức khỏe ban đầu. Với mỗi người tham gia, nghiên cứu ghi nhận các đặc điểm nhân khẩu học - xã hội, hành vi sức khỏe, số đo nhân trắc, huyết áp, các dấu ấn sinh học xét nghiệm, hiểu biết về tăng huyết áp, khả năng tiếp cận chăm sóc, tình trạng chẩn đoán và điều trị tăng huyết áp.

Câu hỏi nghiên cứu. Trong số những người trưởng thành đã được chẩn đoán tăng huyết áp, những yếu tố nào có liên quan đến việc đang điều trị bằng thuốc hạ huyết áp?

Biến kết cục chính. `treatment_uptake`: người tham gia hiện có đang dùng thuốc hạ huyết áp hay không (Yes/No, với "No" là nhóm tham chiếu). Biến này chỉ được phân tích trong số những người tham gia đã được chẩn đoán tăng huyết áp, tức là những người có `htn_diagnosed` = "Yes". Việc giới hạn này xuất phát từ logic lâm sàng không kém gì từ thống kê: một người không thể bắt đầu điều trị cho một bệnh chưa được chẩn đoán.

Biến kết cục phụ. Hai biến kết cục khác chỉ được xác định ở những người tham gia đang được điều trị:

- `adherence`: mức độ tuân thủ điều trị, được ghi nhận là Good (tốt) hoặc Poor (kém);
- `bp_controlled`: huyết áp có được kiểm soát hay không, được định nghĩa là huyết áp tâm thu dưới 140 mmHg và huyết áp tâm trương dưới 90 mmHg.

Các yếu tố quyết định tiềm năng. Nghiên cứu ghi nhận một loạt yếu tố có thể ảnh hưởng một cách hợp lý đến việc một bệnh nhân đã được chẩn đoán có đang điều trị hay không:

- *nhân khẩu học - xã hội*: tuổi, giới tính, nơi cư trú (thành thị hoặc nông thôn), trình độ học vấn, nghề nghiệp, tình trạng hôn nhân và bảo hiểm y tế;
- *hành vi*: hút thuốc, uống rượu bia và hoạt động thể lực;
- *lâm sàng*: chỉ số khối cơ thể, tiền sử gia đình bị tăng huyết áp, đái tháo đường, số bệnh đồng mắc, huyết áp tâm thu và tâm trương và thời gian kể từ khi được chẩn đoán;
- *hiểu biết và khả năng tiếp cận*: điểm hiểu biết về tăng huyết áp (0 đến 20) và khoảng cách đến cơ sở y tế.

Ngoài ra, tám dấu ấn sinh học xét nghiệm (lipid máu, glucose lúc đói, creatinine, natri và kali) có sẵn cho phân tích mô tả và các bài tập.

Lỗi thường gặp

Vì thiết kế là cắt ngang, phơi nhiễm và biến kết cục được đo cùng một thời điểm. Một mối liên quan giữa, chẳng hạn, bảo hiểm y tế và việc sử dụng điều trị không chứng minh được rằng bảo hiểm *gây ra* việc sử dụng điều trị. Xuyên suốt cuốn sách, chúng tôi nói về *mối liên quan* và *yếu tố quyết định* theo nghĩa thận trọng này, và chúng tôi thảo luận rõ ràng về nhiều trong Chương 5.

Dữ liệu là dữ liệu mô phỏng

Bộ dữ liệu dùng trong sách này được **mô phỏng cho mục đích giảng dạy**. Nó được tạo ra bằng máy tính để giống với loại dữ liệu thu thập trong một khảo sát thực tế về tăng huyết áp tại tuyến chăm sóc ban đầu, với các phân phối thực tế, các mối quan hệ hợp lý giữa các biến và những loại vấn đề chất lượng dữ liệu thường gặp trong thực tế. Dữ liệu không mô tả bệnh nhân thật, và tên các cơ sở y tế chỉ được dùng để minh họa.

Điều này dẫn đến hai hệ quả. Thứ nhất, không có vấn đề gì về bảo mật, và bạn được tự do khám phá, chỉnh sửa và chia sẻ dữ liệu trong quá trình học. Thứ hai, và quan trọng hơn, **các kết quả trong sách này minh họa phương pháp, không phải là phát hiện lâm sàng thực sự**. Khi chúng tôi báo cáo rằng một yếu tố nào đó có liên quan đến việc sử dụng điều trị, nhận định đó là về dữ liệu mô phỏng và không được trích dẫn như bằng chứng về chăm sóc tăng huyết áp ở bất kỳ đâu. Chúng tôi sẽ nhắc bạn điều này mỗi khi diễn giải kết quả.

Các biến

Từ điển dữ liệu (data dictionary) mô tả từng biến trong số 36 biến được ghi nhận trong nghiên cứu. Nó được cung cấp dưới dạng tệp CSV để R có thể đọc như bất kỳ bộ dữ liệu nào khác. Đoạn mã dưới đây đọc từ điển và in ra các cột chính:

```
# Đọc từ điển dữ liệu đi kèm dữ liệu của nghiên cứu tình huống
dictionary <- read.csv("Data/data_dictionary.csv")

# Giữ lại các cột mô tả từng biến và trình bày dưới dạng bảng
knitr::kable(
  dictionary[, c("variable", "label", "type", "units_coding", "role")],
  col.names = c("Biến", "Nhãn", "Kiểu", "Đơn vị / mã hóa", "Vai trò"),
  caption = "Các biến được ghi nhận trong nghiên cứu về việc sử dụng điều trị tăng huyết áp."
)
```

Bảng 1: Các biến được ghi nhận trong nghiên cứu về việc sử dụng điều trị tăng huyết áp.

Biến	Nhãn	Kiểu	Đơn vị / mã hóa	Vai trò
patient_id	Patient identifier	Character	PHC-0001 ... PHC-1500	ID
facility	Healthcare facility	Categorical	6 PHC facilities	Cluster/covariate
enroll_date	Date of enrolment	Date	Mixed: YYYY-MM-DD, DD/MM/YYYY, DD-Mon-YYYY	Metadata
age	Age	Numeric	Years	Predictor
sex	Sex	Categorical	Female / Male	Predictor
residence	Place of residence	Categorical	Urban / Rural	Predictor

Biến	Nhãn	Kiểu	Đơn vị / mã hóa	Vai trò
education	Highest education	Ordinal	None < Primary < Secondary < Tertiary	Predictor
occupation	Occupation	Categorical	Unemployed/Farmer/Trader/Professional	Predictor
marital_status	Marital status	Categorical	Single/Married/Divorced/Widowed	Predictor
health_insurance	Has health insurance	Binary	Yes / No	Predictor
height_cm	Height	Numeric	centimetres	Derived input
weight_kg	Weight	Numeric	kilograms	Derived input
bmi	Body mass index	Numeric	kg/m ²	Predictor
smoking	Smoking status	Categorical	Never / Former / Current	Predictor
alcohol	Alcohol intake	Categorical	None / Moderate / Heavy	Predictor
physical_activity	Physical activity level	Ordinal	Low / Moderate / High	Predictor
family_history_htn	Family history of hypertension	Binary	Yes / No	Predictor
diabetes	Diabetes mellitus	Binary	Yes / No	Predictor
sbp_mmHg	Systolic blood pressure	Numeric	mmHg	Clinical
dbp_mmHg	Diastolic blood pressure	Numeric	mmHg	Clinical
total_chol_mmol_L	Total cholesterol	Numeric	mmol/L	Lab biomarker
hdl_mmol_L	HDL cholesterol	Numeric	mmol/L	Lab biomarker
ldl_mmol_L	LDL cholesterol	Numeric	mmol/L	Lab biomarker
triglycerides_mmol_L	Triglycerides	Numeric	mmol/L	Lab biomarker
fasting_glucose_mmol_L	Fasting glucose	Numeric	mmol/L	Lab biomarker
creatinine_umol_L	Serum creatinine	Numeric	umol/L	Lab biomarker
sodium_mmol_L	Serum sodium	Numeric	mmol/L	Lab biomarker
potassium_mmol_L	Serum potassium	Numeric	mmol/L	Lab biomarker
knowledge_score	Hypertension knowledge score	Numeric	0-20	Predictor
distance_to_facility	Distance to facility	Numeric	kilometres	Predictor
comorbidity_count	Number of comorbidities	Count	0+	Predictor
htn_diagnosed	Diagnosed hypertensive	Binary	Yes / No	Filter
months_since_diagnosis	Months since HTN diagnosis	Numeric	Months	Predictor
treatment_uptake	On antihypertensive treatment	Binary	Yes / No	PRIMARY OUTCOME
adherence	Treatment adherence	Categorical	Good / Poor (blank if untreated)	Secondary outcome
bp_controlled	Blood pressure controlled	Binary	Yes / No (blank if untreated)	Secondary outcome

Cột **Vai trò** cho biết mỗi biến được sử dụng như thế nào (các giá trị trong bảng giữ nguyên tiếng Anh như trong tệp từ điển). patient_id định danh người tham gia và facility ghi nhận cụm (cơ sở y tế) mà mỗi người tham gia đến khám. Phần lớn các biến là biến dự báo tiềm năng. htn_diagnosed đóng vai trò *bộ lọc* xác định quần thể phân tích, treatment_uptake là biến kết cục chính, còn adherence và bp_controlled là các biến kết cục phụ. Tệp từ điển dữ liệu còn có

một cột ghi chú mô tả các vấn đề đã biết trong dữ liệu thô, mà chúng ta sẽ dùng trong Chương 2. Hãy luôn để từ điển trong tầm tay: biết chính xác mỗi biến có nghĩa là gì và được mã hóa như thế nào đã là một nửa của một phân tích tốt.

Trong tệp phân tích đã làm sạch, hai biến dẫn xuất được thêm vào 36 biến này: `bmi_cat`, phân loại chỉ số khối cơ thể theo Tổ chức Y tế Thế giới, và `bp_category`, phân loại huyết áp đo được. Cả hai đều được tạo ra trong Chương 2.

Tổng quan quần thể nghiên cứu

Tệp phân tích đã làm sạch, được tạo ra trong Chương 2, có mỗi dòng ứng với một người tham gia. Đoạn mã sau nạp tệp này và đếm số người tham gia, số cơ sở y tế và số người tham gia đã được chẩn đoán tăng huyết áp, tức là quần thể cho phân tích chính:

```
# Nạp dữ liệu sạch, sẵn sàng cho phân tích, được tạo ra trong Chương 2
analysis_data <- readRDS("Data/analysis_data.rds")
```

```
# Số dòng (người tham gia) và số cột (biến)
dim(analysis_data)
```

```
#> [1] 1500 38
```

```
# Các con số chính mô tả quần thể nghiên cứu
diagnosed <- analysis_data[analysis_data$htn_diagnosed == "Yes", ]
study_size <- data.frame(
  quantity = c("Người tham gia", "Cơ sở y tế",
               "Được chẩn đoán tăng huyết áp",
               "Được chẩn đoán và đang điều trị"),
  n = c(nrow(analysis_data),
        length(unique(analysis_data$facility)),
        nrow(diagnosed),
        sum(diagnosed$treatment_uptake == "Yes", na.rm = TRUE))
)
knitr::kable(study_size, col.names = c("Chỉ số", "n"),
              caption = "Quần thể của nghiên cứu tình huống.")
```

Bảng 2: Quần thể của nghiên cứu tình huống.

Chỉ số	n
Người tham gia	1500
Cơ sở y tế	6
Được chẩn đoán tăng huyết áp	1089
Được chẩn đoán và đang điều trị	508

Dữ liệu gồm 1.500 người tham gia và 38 biến (36 biến được ghi nhận cộng với hai biến phân loại dẫn xuất) từ sáu cơ sở y tế. Trong số những người tham gia, 1089 người đã được chẩn đoán tăng huyết áp, và họ tạo thành mẫu số cho biến kết cục chính. Trong số này, 508 người (47%) đang điều trị bằng thuốc hạ huyết áp. Trong các chương tiếp theo, chúng ta sẽ tìm hiểu những bệnh nhân này là ai, họ khác với những người không điều trị như thế nào, và những yếu tố nào vẫn còn liên quan đến việc điều trị sau khi đã tính đến các yếu tố khác.

Diễn giải lâm sàng

Trong dữ liệu mô phỏng này, chưa đến một nửa số bệnh nhân đã biết bị tăng huyết áp đang được điều trị. Trong một nghiên cứu thực tế, một phát hiện như vậy sẽ chỉ ra một khoảng trống đáng kể giữa chẩn đoán và chăm sóc ở tuyến ban đầu, và sẽ thúc đẩy việc tìm kiếm các yếu tố quyết định mà phần còn lại của cuốn sách thực hiện.

Các tệp dữ liệu và quy trình phân tích

Các tệp dữ liệu

Dữ liệu của nghiên cứu tình huống gồm nhiều tệp, mỗi tệp có một mục đích riêng. Tất cả được lưu trong một thư mục tên là `Data/`, và toàn bộ mã trong sách đọc chúng bằng đường dẫn tương đối như `"Data/analysis_data.rds"`.

- `hypertension_phc_raw.csv` và `hypertension_phc_raw.xlsx`: **dữ liệu thô**, giống như khi được nhóm thu thập dữ liệu gửi đến, ở hai định dạng phổ biến. Hai tệp chứa cùng các bản ghi. Chúng đã được cố ý gán những vấn đề mà dữ liệu lâm sàng thực tế rất hay gặp: 1.503 dòng cho 1.500 bệnh nhân do có ba bản ghi trùng lặp; các nhóm phân loại được viết theo nhiều cách (ví dụ F, f, female và Female); các biến có/không được mã hóa lúc là Yes/No, lúc là Y/N và lúc là 1/0; giá trị khuyết được ghi là ô trống, NA, 999 hoặc -99; các giá trị không thể có như tuổi 200 hoặc huyết áp tâm thu 700 mmHg; khoảng trống thừa trước và sau văn bản; và ngày tháng được nhập theo ba định dạng khác nhau. Các tệp này được dùng trong Chương 1 và Chương 2.
- `analysis_data.rds`: **dữ liệu sạch, sẵn sàng cho phân tích**, được lưu ở định dạng tệp riêng của R. Các vấn đề đã được sửa, các biến có kiểu đúng, các biến phân loại là factor với nhóm tham chiếu hợp lý về mặt lâm sàng, và các biến dẫn xuất đã được thêm vào. Định dạng `.rds` lưu giữ chính xác tất cả những điều này, điều mà tệp CSV không làm được. Các chương từ 3 đến 5 bắt đầu từ tệp này.
- `data_dictionary.csv` và `data_dictionary.md`: **từ điển dữ liệu**, mô tả từng biến, cách mã hóa, vai trò của biến trong phân tích và các vấn đề đã biết của biến.

Chương 2 hướng dẫn bạn tự tạo ra `analysis_data.rds` từ tệp dữ liệu thô. Một bản dựng sẵn được cung cấp để bạn có thể làm việc với bất kỳ chương nào một cách độc lập, và để bạn so sánh dữ liệu đã làm sạch của mình với dữ liệu của chúng tôi.

Thực hành tốt

Hãy giữ dữ liệu thô và dữ liệu sẵn sàng cho phân tích trong các tệp riêng biệt, và tạo tệp thứ hai từ tệp thứ nhất bằng một script. Nếu sau này phát hiện vấn đề trong dữ liệu thô, bạn sửa script và tạo lại tệp sạch, thay vì vá tệp sạch bằng tay.

Quy trình phân tích

Các chương đi theo các giai đoạn của một phân tích dữ liệu lâm sàng điển hình. Nên ghi nhớ trình tự này, vì nó áp dụng cho hầu như mọi nghiên cứu bạn sẽ phân tích:

1. **Nhập** dữ liệu thô vào R và kiểm tra chúng: có bao nhiêu dòng và cột, có những kiểu biến nào, điều gì có vẻ không ổn (Chương 1).
2. **Làm sạch** dữ liệu: xử lý các mã giá trị khuyết, loại bỏ bản ghi trùng lặp, thống nhất các nhóm phân loại, kiểm tra các giá trị không thể có, đọc ngày tháng, tạo biến mới và đặt các mức của factor, sau đó lưu một tệp phân tích sạch (Chương 2).
3. **Mô tả** quần thể nghiên cứu bằng các thống kê tóm tắt, một "Bảng 1" và các hình được thiết kế tốt, cho toàn bộ mẫu và theo nhóm biến kết cục (Chương 3).
4. **Kiểm định** các giả thuyết cụ thể về sự khác biệt và mối liên quan, chọn từng kiểm định phù hợp với kiểu dữ liệu và kiểm tra các giả định của nó (Chương 4).
5. **Mô hình hóa** biến kết cục bằng hồi quy, đi từ ước lượng thô đến ước lượng hiệu chỉnh và kiểm tra mức độ phù hợp của mô hình (Chương 5).
6. **Báo cáo** các phát hiện một cách rõ ràng và trung thực, bằng bảng, hình và văn bản đáp ứng kỳ vọng của các tạp chí lâm sàng và các hướng dẫn báo cáo như STROBE cho nghiên cứu quan sát (Elm et al. 2007) (Chương 3 và Chương 5).

Mỗi giai đoạn đều được viết dưới dạng mã lệnh, vì vậy toàn bộ con đường từ tệp thô đến báo cáo cuối cùng có thể được chạy lại bất cứ lúc nào. Tóm lại trong một câu, đó chính là điều cuốn sách này muốn truyền đạt.

Về các tác giả

Bernard Isekah Osang'ir là Chuyên gia Thống kê Sinh học cao cấp tại Neudata Consulting Ltd.

Vương Mỹ Lượng là Chuyên gia Thống kê Sinh học cao cấp tại Neudata Consulting Ltd.

Cả hai tác giả đều làm việc trong lĩnh vực thiết kế và phân tích các nghiên cứu lâm sàng và y tế công cộng, và đào tạo các cán bộ y tế tự phân tích dữ liệu của mình một cách có thể tái lập bằng R.

Lời cảm ơn

Cuốn sách này được phát triển từ các tài liệu giảng dạy dành cho những người làm trong ngành y tế học cách phân tích dữ liệu lâm sàng bằng R. Chúng tôi xin cảm ơn những học viên đã học qua các phiên bản trước của tài liệu: những câu hỏi, những lỗi sai và những nhận xét sâu sắc của họ đã cho thấy chỗ nào cần giải thích rõ hơn, chỗ nào ví dụ cần gắn với lâm sàng hơn và chỗ nào cần đi chậm lại. Chúng tôi cũng cảm ơn các đồng nghiệp và người phản biện đã đọc bản thảo các chương và đã có những góp ý cẩn thận giúp cải thiện cả phần thống kê lẫn phần văn phong.

Cuối cùng, chúng tôi xin cảm ơn cộng đồng R: Nhóm R Core, những người phát triển và duy trì chính R, cùng nhiều tác giả của các gói được dùng trong sách này, những người đã chia sẻ công trình của mình một cách miễn phí để người khác có thể tiếp tục xây dựng trên đó. Mọi sai sót còn lại thuộc về chúng tôi.

Bắt đầu với R và RStudio

Mọi nghiên cứu lâm sàng tốt cuộc đều trở thành một bảng gồm các con số và chữ: mỗi dòng là một bệnh nhân, mỗi cột là một phép đo. Huyết áp, tuổi, kết quả xét nghiệm, chẩn đoán và quyết định điều trị đều kết thúc trong một bảng tính hoặc cơ sở dữ liệu, và cần có người biến bảng đó thành bằng chứng. Cách làm việc này có ý nghĩa quan trọng. Một phân tích thực hiện bằng cách trở và nhấp chuột không để lại dấu vết về những gì đã làm, đồng nghiệp khó kiểm tra lại, và khó lặp lại khi dữ liệu được chỉnh sửa hoặc khi người phản biện yêu cầu một phân tích độ nhạy. Ngược lại, một phân tích được viết dưới dạng mã lệnh trong R là một bản ghi đầy đủ, dễ đọc và có thể chạy lại cho từng bước, từ dữ liệu thô đến bảng kết quả cuối cùng. Chương này đưa bạn đi từ lần đầu mở R đến việc nhập một bộ dữ liệu lâm sàng thực tế (mô phỏng) gồm 1.500 người trưởng thành đến khám tại các cơ sở chăm sóc sức khỏe ban đầu và xem xét nó lần đầu một cách cẩn thận. Trên đường đi, bạn sẽ học một nhóm nhỏ các ý tưởng làm nền tảng cho mọi nội dung khác của cuốn sách: đối tượng, kiểu dữ liệu, vectơ, hàm, gói, dự án và khung dữ liệu (data frame).

Mục tiêu học tập

- Mô tả R và RStudio là gì, gọi tên bốn khung (pane) của RStudio và giải thích vì sao mã phân tích cần được viết trong script thay vì trong console.
- Dùng R như một máy tính, bao gồm thứ tự ưu tiên của toán tử và các hàm toán học có sẵn, và tính các đại lượng lâm sàng đơn giản như chỉ số khối cơ thể và huyết áp động mạch trung bình.
- Tạo, đặt tên, ghi đè và xóa đối tượng bằng mũi tên gán `<-`.
- Phân biệt các kiểu dữ liệu chính (numeric, integer, character, logical, factor và Date), kiểm tra chúng bằng `class()` và chuyển đổi giữa các kiểu, nhận biết các bất chuyển kiểu thường gặp.
- Tạo và truy xuất phần tử của vectơ, thực hiện phép tính số học và phép so sánh logic theo vectơ, và tóm tắt các vectơ có chứa giá trị khuyết.
- Gọi hàm với đối số theo vị trí và đối số có tên, tìm và đọc trang trợ giúp, và hiểu các thông báo lỗi thường gặp.
- Cài đặt và nạp gói, tổ chức công việc trong một RStudio Project và dùng đường dẫn tệp tương đối.
- Nhập một tệp CSV và một tệp Excel vào khung dữ liệu, kiểm tra nó bằng `dim()`, `names()`, `glimpse()`, `summary()` và `table()`, và phát hiện các vấn đề về chất lượng dữ liệu.

- Dùng toán tử pipe `|>` với các "động từ" của dplyr: `select()`, `filter()`, `arrange()`, `mutate()` và `count()`.
- Viết một script phân tích có cấu trúc tốt, có chú thích và có thể tái lập.

1.1 R và RStudio là gì

1.1.1 R: một ngôn ngữ dành cho phân tích dữ liệu

R là một ngôn ngữ lập trình và môi trường phần mềm miễn phí, mã nguồn mở, được thiết kế cho tính toán thống kê và đồ họa (R Core Team 2026). R ra đời vào những năm 1990 như một phiên bản mở của ngôn ngữ S được phát triển tại Phòng thí nghiệm Bell, và hiện được duy trì bởi Nhóm R Core cùng một cộng đồng người đóng góp rất lớn. Có ba đặc điểm giải thích vì sao R đã trở thành một trong những công cụ tiêu chuẩn của nghiên cứu lâm sàng và dịch tễ học.

Thứ nhất, R là phần mềm **miễn phí và mở**. Bất kỳ ai cũng có thể tải về, bất kỳ ai cũng có thể xem mã nguồn thực hiện một phép tính, và không có khoản phí bản quyền nào ngăn cách một bệnh viện huyện, một bộ môn đại học hay một bộ y tế với một phân tích thống kê hiện đại. Thứ hai, R có tính **mở rộng**. Hàng nghìn *gói* bổ sung do các nhà thống kê và nhà khoa học dữ liệu đóng góp cung cấp các phương pháp từ bảng tần số đơn giản đến phân tích sống còn, quy gán đa bội (multiple imputation), phân tích gộp và học máy. Khi một phương pháp mới được công bố, phiên bản triển khai bằng R thường xuất hiện cùng lúc. Thứ ba, và quan trọng nhất đối với nghiên cứu, R là một **ngôn ngữ**. Bạn không ra lệnh cho R bằng cách nhấp vào menu; bạn viết các chỉ dẫn. Những chỉ dẫn đó có thể được lưu lại, đọc, chia sẻ, kiểm tra và chạy lại, và đó là nền tảng của nghiên cứu có thể tái lập.

1.1.2 RStudio: một nơi làm việc thuận tiện với R

Bản thân R là "động cơ" thực hiện các phép tính. Nếu dùng riêng, R chỉ cung cấp một cửa sổ khá đơn sơ để bạn gõ lệnh. **RStudio** (do công ty Posit phát triển) là một *môi trường phát triển tích hợp* (integrated development environment, IDE): một chương trình đặt bên trên R, cung cấp cho bạn trình soạn thảo script, console, trình xem dữ liệu và đồ thị, trình duyệt tệp, trình duyệt trợ giúp và nhiều tiện ích như tự động hoàn thành mã và phím tắt. Một phép so sánh hữu ích là chiếc ô tô: R là động cơ, còn RStudio là bảng đồng hồ, vô lăng và ghế ngồi. Bạn cần cả hai, bạn cài R trước, và khi cả hai đã được cài đặt, bạn chỉ cần mở RStudio, phần mềm này sẽ tự khởi động R ở phía sau.

Việc cài đặt phần mềm khá đơn giản. R được tải về từ Mạng lưu trữ R toàn diện (Comprehensive R Archive Network, CRAN) tại <https://cran.r-project.org>, chọn bộ cài đặt phù hợp với hệ điều hành của bạn. RStudio Desktop (miễn phí) được tải về từ <https://posit.co/download/rstudio-desktop>. Hãy chấp nhận các tùy chọn mặc định trong cả hai bộ cài đặt.

1.1.3 Bốn khung của RStudio

Khi mở RStudio, bạn sẽ thấy một cửa sổ được chia thành (tối đa) bốn khung. Biết mỗi khung dùng để làm gì sẽ xóa bỏ phần lớn sự bối rối trong giờ đầu tiên.

Nếu bạn chỉ thấy ba khung, nghĩa là chưa có script nào được mở: hãy chọn *File > New File > R Script* (hoặc nhấn `Ctrl+Shift+N` trên Windows, `Cmd+Shift+N` trên macOS) và khung soạn thảo

Bảng 1.1: Bốn khung của RStudio ở vị trí mặc định.

Khung	Vị trí mặc định	Công dụng
Source (trình soạn thảo script)	Trên bên trái	Viết, sửa và lưu mã. Đây là bản ghi lâu dài của bản phân tích.
Console	Dưới bên trái	Nơi R thực sự chạy mã và in kết quả. Có thể gõ lệnh ở đây nhưng không có gì được lưu lại.
Environment / History	Trên bên phải	Liệt kê các đối tượng (bộ dữ liệu, giá trị, kết quả) đang có trong bộ nhớ, và các lệnh đã chạy.
Files / Plots / Packages / Help / Viewer	Dưới bên phải	Duyệt thư mục dự án, xem hình, quản lý gói và đọc trang trợ giúp.

sẽ xuất hiện. Các khung có thể được thay đổi kích thước và sắp xếp lại trong *Tools > Global Options > Pane Layout*, nhưng bố cục mặc định đã hợp lý và cuốn sách này giả định bạn dùng bố cục đó.

1.1.4 Console và script

Console (cửa sổ lệnh) là một cuộc đối thoại với R. Bạn gõ một lệnh sau dấu nhắc `>`, nhấn Enter, và R trả lời ngay lập tức. Điều này rất phù hợp cho những câu hỏi nhanh ("trung bình của cột này là bao nhiêu?", "hàm này làm gì?"), nhưng cuộc đối thoại chỉ là tạm thời. Khi bạn đóng RStudio, hoặc sau vài trăm dòng kết quả, sẽ không còn bản ghi gọn gàng nào về những gì bạn đã hỏi và theo thứ tự nào.

Một **script** là một tệp văn bản thuần, có phần mở rộng `.R`, chứa các lệnh R được viết lần lượt, kèm theo các chú thích giải thích chúng. Bạn viết mã trong script, đặt con trỏ trên một dòng và nhấn `Ctrl+Enter` (Windows) hoặc `Cmd+Enter` (macOS); RStudio gửi dòng đó sang console, R chạy nó, và kết quả xuất hiện trong console y như thể bạn đã gõ trực tiếp ở đó. Bôi đen nhiều dòng rồi nhấn `Ctrl+Enter` sẽ chạy tất cả các dòng đó; `Ctrl+Shift+Enter` chạy toàn bộ script từ đầu đến cuối.

Trong cuốn sách này, mã R được trình bày trong các ô màu xám. Những dòng mà R in ra để phản hồi bắt đầu bằng `#>`, để bạn phân biệt được đầu vào và đầu ra. Ví dụ:

```
2 + 2
```

#> [1] 4

Ký hiệu `[1]` ở đầu kết quả là một chỉ số: nó cho biết giá trị đầu tiên hiển thị trên dòng này là phần tử số 1 của kết quả. Chỉ số này trở nên hữu ích khi R in những kết quả dài trải trên nhiều dòng.

1.1.5 Vì sao script giúp phân tích có thể tái lập

Một phân tích là **có thể tái lập** (reproducible) khi một người khác (hoặc chính bạn, sáu tháng sau) có thể lấy cùng dữ liệu và cùng mã lệnh và thu được chính xác cùng kết quả. Peng (2011) lập luận rằng khả năng tái lập là tiêu chuẩn tối thiểu để đánh giá khoa học tính toán: ngay cả khi một nghiên cứu không thể được *lặp lại* (replicated) một cách độc lập với các bệnh nhân mới, người đọc ít nhất phải có khả năng kiểm chứng rằng các con số được báo cáo thực sự xuất phát từ dữ liệu. Trong nghiên cứu lâm sàng, điều này quan trọng vì những lý do rất thực tế. Bộ dữ

liệu được chỉnh sửa sau khi các thắc mắc về dữ liệu được giải quyết; người phản biện yêu cầu hiệu chỉnh thêm một biến; hội đồng giám sát an toàn dữ liệu yêu cầu cùng các bảng đó ở lần phân tích giữa kỳ tiếp theo; một học viên tiếp nhận dự án từ người hướng dẫn. Có script, mỗi yêu cầu này chỉ có nghĩa là chạy lại mã. Không có script, nó có nghĩa là cố gắng nhớ lại mình đã nhấp vào những gì.

Wilson et al. (2017) mô tả một tập hợp các thực hành tính toán "đủ tốt" mà bất kỳ nhà nghiên cứu nào cũng có thể áp dụng mà không cần trở thành kỹ sư phần mềm. Một số thực hành trong đó được giới thiệu ngay trong chương này: giữ nguyên dữ liệu thô và thực hiện mọi chỉnh sửa bằng mã lệnh, viết mã trong script có chú thích, đặt tên tệp và đối tượng có ý nghĩa, tổ chức mỗi công việc trong một thư mục dự án riêng, và dùng đường dẫn tệp tương đối thay vì tuyệt đối. Không thực hành nào trong số này khó, và kết hợp lại, chúng bảo vệ bạn khỏi phần lớn các lỗi len lỏi vào những phân tích thủ công.

Thực hành tốt

Hãy viết mọi lệnh quan trọng vào script, ngay cả khi bạn thử nó trước trong console. Một quy tắc hữu ích: nếu một dòng lệnh tạo ra con số sẽ xuất hiện trong báo cáo, dòng đó phải tồn tại trong một script đã được lưu. Console dùng để khám phá; script mới là bản phân tích.

1.2 R như một máy tính

Cách đơn giản nhất để bắt đầu với R là coi nó như một chiếc máy tính rất mạnh.

1.2.1 Các toán tử số học

R hiểu các toán tử số học quen thuộc.

```
140 + 90      # phép cộng
```

R

```
#> [1] 230
```

```
140 - 90      # phép trừ
```

R

```
#> [1] 50
```

```
140 * 2       # phép nhân
```

R

```
#> [1] 280
```

```
140 / 90      # phép chia
```

R

```
#> [1] 1.556
```

```
2^10      # lũy thừa (2 mũ 10)
```

R

```
#> [1] 1024
```

```
17 %/% 5   # chia lấy phần nguyên: 17 chứa được bao nhiêu số 5 trọn vẹn
```

R

```
#> [1] 3
```

```
17 %% 5    # chia lấy dư (modulo): phần còn lại
```

R

```
#> [1] 2
```

Mọi thứ đứng sau dấu # trên một dòng là một **chú thích** (comment). R bỏ qua nó, nhưng người đọc thì không, và chú thích là một trong những phần quan trọng nhất của bất kỳ script nào. Cũng hãy để ý rằng R in ra 1.556 cho $140 / 90$: theo mặc định R hiển thị khoảng bảy chữ số có nghĩa (cuốn sách này dùng bốn chữ số để kết quả gọn hơn), nhưng bên trong R lưu số với độ chính xác khoảng mười lăm đến mười sáu chữ số. (Lưu ý rằng R luôn dùng dấu chấm làm dấu thập phân, khác với cách viết dấu phẩy thập phân trong tiếng Việt.)

1.2.2 Thứ tự ưu tiên của toán tử

Khi một biểu thức chứa nhiều toán tử, R tuân theo thứ tự thực hiện phép tính quen thuộc trong toán học: ngoặc đơn trước, sau đó đến lũy thừa, rồi nhân và chia (từ trái sang phải), và cuối cùng là cộng và trừ (từ trái sang phải).

Bảng 1.2: Thứ tự R thực hiện các toán tử số học (ưu tiên cao nhất trước).

Mức ưu tiên	Toán tử	Ý nghĩa
1	()	Ngoặc đơn
2	^	Lũy thừa
3	-x	Dấu trừ một ngôi (dấu âm)
4	%%, %/%	Chia lấy dư, chia lấy phần nguyên
5	*, /	Nhân, chia
6	+, -	Cộng, trừ

Hệ quả rất dễ thấy:

```
2 + 3 * 4   # nhân trước: 2 + 12
```

R

```
#> [1] 14
```

```
(2 + 3) * 4  # ngoặc trước: 5 * 4
```

R

```
#> [1] 20
```

```
-2^2          # lũy thừa trước dấu trừ: -(2^2)
```

R

```
#> [1] -4
```

```
(-2)^2        # bình phương của âm hai
```

R

```
#> [1] 4
```

Khi còn phân vân, hãy thêm ngoặc đơn. Chúng không tốn gì, chúng thể hiện rõ ý định của bạn với người đọc, và chúng ngăn chặn cả một loại lỗi âm thầm. Một công thức sai do thứ tự ưu tiên không tạo ra thông báo lỗi nào; nó tạo ra một con số trông có vẻ hợp lý nhưng sai, và điều đó nguy hiểm hơn nhiều.

1.2.3 Các hàm toán học

R có một thư viện lớn các hàm toán học có sẵn. Một **hàm** (function) là một đoạn mã có tên, nhận một hoặc nhiều đầu vào (gọi là *đối số*, arguments) đặt trong ngoặc đơn và trả về một kết quả. Chúng ta sẽ xem xét hàm một cách chi tiết trong Mục 1.6; trước mắt, chỉ cần vài hàm phổ biến là đủ.

```
sqrt(16)      # căn bậc hai
```

R

```
#> [1] 4
```

```
abs(-7)       # giá trị tuyệt đối
```

R

```
#> [1] 7
```

```
exp(1)        # số e, cơ số của logarit tự nhiên
```

R

```
#> [1] 2.718
```

```
log(100)      # logarit tự nhiên (cơ số e)
```

R

```
#> [1] 4.605
```

```
log10(100)    # logarit cơ số 10
```

R

```
#> [1] 2
```

```
log(8, base = 2) # logarit với cơ số tự chọn
```

R

```
#> [1] 3
```

```
round(3.14159, 2) # làm tròn đến 2 chữ số thập phân
```

R

```
#> [1] 3.14
```

```
signif(123456, 2) # làm tròn đến 2 chữ số có nghĩa
```

R

```
#> [1] 120000
```

Lưu ý rằng `log()` trong R là logarit **tự nhiên**, được viết là *ln* trong nhiều sách giáo khoa. Điều này làm nhiều người ngạc nhiên vì họ đã quen với máy tính cầm tay, nơi "log" có nghĩa là cơ số 10. Logarit tự nhiên xuất hiện khắp nơi trong thống kê sinh học (ví dụ trong hồi quy logistic ở Chương 5, nơi tỷ số chênh được tính bằng cách lấy lũy thừa cơ số *e* của các hệ số bằng `exp()`), vì vậy nên ghi nhớ điều này ngay từ bây giờ.

1.2.4 Một ví dụ lâm sàng: chỉ số khối cơ thể và huyết áp động mạch trung bình

Hãy dùng R cho hai phép tính mà các bác sĩ lâm sàng thực hiện hằng ngày. Chỉ số khối cơ thể (body mass index, BMI) bằng cân nặng tính theo kilôgam chia cho bình phương chiều cao tính theo mét:

$$\text{BMI} = \frac{\text{weight (kg)}}{\text{height (m)}^2}$$

Với một bệnh nhân nặng 78,5 kg và cao 166,2 cm, trước tiên ta phải đổi chiều cao sang mét bằng cách chia cho 100:

```
78.5 / (166.2 / 100)^2
```

R

```
#> [1] 28.42
```

Cặp ngoặc quanh `166.2 / 100` rất quan trọng. Nếu không có chúng, R sẽ tính `100^2` trước (vì lũy thừa có mức ưu tiên cao nhất) và chia 166,2 cho 10.000, cho ra một BMI vô nghĩa trên 470.000.

Huyết áp động mạch trung bình (mean arterial pressure, MAP) ước tính áp lực trung bình trong động mạch trong một chu chuyển tim. Vì tim dành khoảng hai phần ba mỗi chu chuyển ở thì tâm trương, một công thức xấp xỉ thông dụng gán trọng số cho huyết áp tâm trương (DBP) lớn hơn huyết áp tâm thu (SBP):

$$\text{MAP} \approx \text{DBP} + \frac{\text{SBP} - \text{DBP}}{3}$$

Với một lần đo 152/95 mmHg:

```
95 + (152 - 95) / 3
```

R

```
#> [1] 114
```

```
round(95 + (152 - 95) / 3, 1)
```

R

```
#> [1] 114
```

MAP vào khoảng 114 mmHg. Một lần nữa, cặp ngoặc quanh $152 - 95$ là thiết yếu; biểu thức $95 + 152 - 95 / 3$ sẽ chỉ trừ đi một phần ba huyết áp tâm trương và cho ra 215,3 mmHg, một giá trị sai nhưng không hiển nhiên vô lý trước một đôi mắt mệt mỏi.

Diễn giải lâm sàng

MAP khoảng 114 mmHg cao hơn hẳn khoảng giá trị thường gặp ở người trưởng thành có huyết áp bình thường (khoảng 70 đến 100 mmHg), phù hợp với lần đo tăng 152/95 mmHg. Điểm cần nhấn mạnh ở đây không phải là quyết định lâm sàng mà là phép tính: một khi công thức đã được viết đúng trong R, nó có thể được áp dụng y hệt cho một bệnh nhân hoặc cho cả 1.500 bệnh nhân trong một nghiên cứu, không có lỗi sao chép nào.

1.3 Đối tượng và phép gán

Tính một giá trị rồi để nó trôi khỏi màn hình thì không mấy hữu ích. Để dùng lại một giá trị, ta lưu nó vào một **đối tượng** (object, đôi khi gọi là biến): một cái tên trỏ tới một giá trị được giữ trong bộ nhớ máy tính.

1.3.1 Mũi tên gán

Đối tượng được tạo bằng **toán tử gán** `<-`, gõ bằng dấu "nhỏ hơn" theo sau là dấu gạch nối. Trong tiếng Anh nó được đọc là "gets": `sbp <- 152` đọc là "sbp nhận giá trị 152". Trong RStudio, phím tắt `Alt + -` (Windows) hoặc `Option + -` (macOS) sẽ gõ mũi tên kèm khoảng trắng hai bên.

```
sbp <- 152    # huyết áp tâm thu của một bệnh nhân
dbp <- 95     # huyết áp tâm trương của cùng bệnh nhân đó
```

R

Phép gán diễn ra một cách im lặng: R lưu các giá trị nhưng không in gì ra. Để xem một đối tượng chứa gì, hãy gõ tên của nó (thao tác này ngầm gọi hàm `print()`):

```
sbp
```

R

```
#> [1] 152
```

```
print(dbp)
```

R

```
#> [1] 95
```

Đối tượng hoạt động y hệt như giá trị mà nó chứa, vì vậy có thể dùng trong các phép tính, và kết quả lại có thể được lưu thành đối tượng:

```
sbp + 10
```

R

```
#> [1] 162
```

```
map <- dbp + (sbp - dbp) / 3 # huyết áp động mạch trung bình
map
```

```
#> [1] 114
```

```
pulse_pressure <- sbp - dbp
pulse_pressure
```

```
#> [1] 57
```

Đây là cái nhìn đầu tiên về sức mạnh của lập trình. Công thức tính MAP giờ được viết một lần duy nhất, bằng các đại lượng có tên, và bất kỳ ai đọc mã cũng có thể hiểu ý nghĩa của nó.

Lỗi thường gặp

R cũng chấp nhận = để gán ở cấp cao nhất (`sbp = 152` vẫn chạy), và `->` gán sang phải (`152 -> sbp`). Quy ước của cộng đồng R, được áp dụng xuyên suốt cuốn sách này, là dùng `<-` để gán và dành = cho việc đặt tên đối số bên trong lời gọi hàm, ví dụ `round(x, digits = 1)`. Trộn lẫn hai cách làm mã khó đọc hơn. Một lỗi liên quan là gõ `<` và `-` có khoảng trắng ở giữa: `sbp < - 152` hoàn toàn không phải là phép gán mà là câu hỏi "sbp có nhỏ hơn âm 152 không?", trả về `FALSE` và giữ nguyên `sbp`.

1.3.2 Đặt tên đối tượng

Tên đối tượng phải tuân theo một vài quy tắc:

- Tên có thể chứa chữ cái, chữ số, dấu chấm (.) và dấu gạch dưới (_).
- Tên phải bắt đầu bằng một chữ cái (hoặc một dấu chấm không đứng trước chữ số).
- Tên không được chứa khoảng trắng hay các ký hiệu khác như -, / hoặc %.
- Tên không được là các từ khóa dành riêng như `if`, `else`, `TRUE`, `FALSE`, `NA`, `function`, `for` hoặc `NULL`.

Trong phạm vi các quy tắc này, bạn được tự do lựa chọn, và đáng để suy nghĩ về việc đặt tên tốt. Tên nên cho biết đối tượng chứa gì, đủ ngắn để gõ và theo một phong cách nhất quán. Cuốn sách này dùng kiểu **snake case**: các từ viết thường nối với nhau bằng dấu gạch dưới, cũng là phong cách của bộ dữ liệu nghiên cứu tình huống (`sbp_mmhg`, `treatment_uptake`). Đưa đơn vị đo vào tên của một phép đo, như `weight_kg` hay `creatinine_umol_l`, giúp phòng tránh một lỗi lâm sàng thường gặp: nhầm lẫn giữa các đơn vị như `mmol/L` và `mg/dL`. Nên đặt tên đối tượng bằng tiếng Anh không dấu (hoặc tiếng Việt không dấu), vì chữ có dấu trong tên đối tượng dễ gây lỗi mã hóa ký tự khi chia sẻ mã.

R phân biệt chữ hoa và chữ thường. Các đối tượng `sbp`, `SBP` và `Sbp` là ba đối tượng khác nhau, và yêu cầu một đối tượng không tồn tại sẽ gây ra lỗi:

Bảng 1.3: Ví dụ về tên đối tượng.

Tên	Hợp lệ?	Nhận xét
sbp_mmhg	Có	Rõ ràng, có đơn vị, kiểu snake case
mean_age_diagnosed	Có	Mang tính mô tả; dài nhưng dễ đọc
x2	Có	Hợp lệ nhưng không nói gì về nội dung
SBP	Có	Hợp lệ, nhưng là một đối tượng khác với sbp
2nd_visit	Không	Bắt đầu bằng chữ số; hãy dùng visit_2
systolic bp	Không	Chứa khoảng trắng
bp-control	Không	R hiểu đây là bp trừ control

SBP

R

```
#> Error:
#> ! object 'SBP' not found
```

Thông báo "object 'SBP' not found" (không tìm thấy đối tượng 'SBP') có lẽ là thông báo lỗi phổ biến nhất trong R. Nó hầu như luôn có nghĩa là gõ nhầm (một chữ hoa, thiếu dấu gạch dưới) hoặc dòng lệnh tạo đối tượng đó chưa bao giờ được chạy.

1.3.3 Ghi đè đối tượng và môi trường làm việc

Gán một giá trị mới cho một tên đã tồn tại sẽ **thay thế** giá trị cũ mà không có cảnh báo nào:

```
age <- 60
age
```

R

```
#> [1] 60
```

```
age <- 61      # giá trị cũ 60 đã mất
age
```

R

```
#> [1] 61
```

```
age <- age + 1 # dùng giá trị cũ để tính giá trị mới
age
```

R

```
#> [1] 62
```

Dòng `age <- age + 1` trông kỳ lạ với những ai có nền tảng toán học, nhưng lại hoàn toàn tự nhiên trong R: về phải được tính trước bằng giá trị hiện tại của `age`, rồi kết quả được lưu ngược lại dưới cùng tên đó.

Mọi đối tượng bạn tạo ra đều nằm trong **môi trường toàn cục** (global environment), chính là nội dung mà khung Environment trong RStudio hiển thị. Bạn cũng có thể liệt kê chúng bằng mã, và xóa những đối tượng không còn cần:

```
ls() # liệt kê các đối tượng trong môi trường
```

R

```
#> [1] "age"          "dbp"          "map"          "pulse_pressure"
#> [5] "sbp"
```

```
rm(pulse_pressure) # xóa một đối tượng
ls()
```

R

```
#> [1] "age" "dbp" "map" "sbp"
```

Thực hành tốt

Đừng dựa vào nội dung của môi trường làm việc. Những đối tượng được tạo bởi các dòng lệnh bạn đã xóa khỏi script có thể vẫn đang ẩn trong bộ nhớ, và script của bạn có thể chỉ có vẻ chạy được là nhờ chúng. Hãy khởi động lại R thường xuyên (*Session > Restart R*, hoặc **Ctrl+Shift+F10**) và chạy script từ đầu. Trong *Tools > Global Options > General*, bỏ chọn "Restore .RData into workspace at startup" và đặt "Save workspace to .RData on exit" thành "Never", để mỗi phiên làm việc đều bắt đầu sạch sẽ (Wickham et al. 2023).

1.4 Các kiểu dữ liệu

Mọi giá trị trong R đều có một **kiểu** (type), và kiểu quyết định R có thể làm gì với giá trị đó. Bạn có thể cộng hai con số nhưng không thể cộng hai cái tên; bạn có thể sắp xếp ngày tháng theo thứ tự thời gian, nhưng sắp xếp chúng như văn bản sẽ cho thứ tự sai. Phần lớn công việc làm sạch dữ liệu trong Chương 2, về bản chất, là đảm bảo mỗi biến có đúng kiểu.

1.4.1 Các kiểu cơ bản

Bảng 1.4: Các kiểu dữ liệu chính dùng trong phân tích dữ liệu lâm sàng.

Kiểu (class)	Ví dụ	Ứng dụng lâm sàng điển hình
numeric (double)	152, 23.4, -0.5	Huyết áp, BMI, giá trị xét nghiệm
integer	3L, 0L	Số đếm như số bệnh đồng mắc
character	"Female", "PHC-0142"	Mã định danh, văn bản tự do, nhãn phân loại thô
logical	TRUE, FALSE	Điều kiện có/không như "SBP từ 140 trở lên"
factor	Female, Male (có các mức)	Biến phân loại: giới tính, cơ sở y tế, học vấn
Date	2024-03-15	Ngày tuyển chọn, ngày chẩn đoán

Giá trị **numeric** (số) là các số thực được lưu ở dạng "độ chính xác kép" (double precision). Đây là kiểu mặc định cho mọi thứ trông giống một con số. **Integer** (số nguyên) là các số nguyên; bạn hiếm khi cần tạo chúng một cách tường minh (hậu tố L, như trong 3L, làm việc đó), và với mục đích phân tích, integer và double hoạt động gần như giống hệt nhau. Giá trị **character** (ký tự), còn gọi là *chuỗi* (strings), là văn bản và luôn phải được viết trong dấu nháy, đơn hoặc kép. Giá trị **logical** (logic) là TRUE và FALSE (luôn viết hoa) và được tạo ra từ các phép so sánh. **Factor** là cách R lưu trữ dữ liệu phân loại: một tập giá trị bị giới hạn trong một danh sách nhóm cố định, gọi là các *mức* (levels). **Date** (ngày tháng) lưu ngày theo lịch ở dạng cho phép tính toán

(có bao nhiêu ngày giữa lần tuyển chọn và lần theo dõi?) và sắp xếp đúng theo thứ tự thời gian.

1.4.2 Kiểm tra kiểu: `class()` và các hàm `is.*()`

Hàm `class()` cho biết kiểu của bất kỳ đối tượng nào.

```
class(152)
```

R

```
#> [1] "numeric"
```

```
class(3L)
```

R

```
#> [1] "integer"
```

```
class("Female")
```

R

```
#> [1] "character"
```

```
class(TRUE)
```

R

```
#> [1] "logical"
```

```
class(sbp > 140)
```

R

```
#> [1] "logical"
```

Một nhóm hàm bắt đầu bằng `is.` đặt một câu hỏi có/không về kiểu:

```
is.numeric(152)
```

R

```
#> [1] TRUE
```

```
is.character(152)
```

R

```
#> [1] FALSE
```

```
is.character("152")
```

R

```
#> [1] TRUE
```

```
is.logical(FALSE)
```

R

```
#> [1] TRUE
```

Cặp ví dụ cuối cùng đáng được chú ý. 152 và "152" trông giống nhau trên màn hình, nhưng cái đầu là một con số, còn cái sau là một đoạn văn bản tình cờ được tạo thành từ các chữ số. Bạn không thể làm phép tính với cái sau:

```
"152" + 10
```

```
#> Error in `"152" + 10`:  
#> ! non-numeric argument to binary operator
```

"Non-numeric argument to binary operator" (đối số không phải số cho toán tử hai ngôi) có nghĩa là một vế của phép + không phải là số. Khi gặp thông báo này trên dữ liệu thực tế, nguyên nhân thường gặp là một cột *đáng lẽ* là số nhưng lại được nhập ở dạng ký tự vì có vài ô chứa văn bản, như "missing", "<0.5" hoặc "n/a".

1.4.3 Chuyển đổi kiểu: các hàm as.*()

Mỗi hàm is. có một hàm as. tương ứng, cố gắng chuyển một giá trị sang kiểu tương ứng. Việc này được gọi là **ép kiểu** (coercion).

```
as.numeric("152")      # văn bản thành số
```

```
#> [1] 152
```

```
as.character(152)      # số thành văn bản
```

```
#> [1] "152"
```

```
as.numeric(TRUE)      # TRUE trở thành 1
```

```
#> [1] 1
```

```
as.numeric(FALSE)     # FALSE trở thành 0
```

```
#> [1] 0
```

```
as.logical("TRUE")     # văn bản thành giá trị logic
```

```
#> [1] TRUE
```

```
as.integer(3.9)        # cắt bỏ phần thập phân về phía 0; KHÔNG làm tròn
```

```
#> [1] 3
```

1.4.4 Những cái bẫy khi ép kiểu

Không phải lúc nào cũng chuyển đổi được. Khi R không thể chuyển một giá trị, nó không dừng lại với một lỗi; nó tạo ra NA (mã của R cho giá trị khuyết) và đưa ra một cảnh báo:

```
as.numeric(c("120", "135", "missing", "<90"))
```

```
#> [1] 120 135 NA NA
```

(Cảnh báo "NAs introduced by coercion" (NA được tạo ra do ép kiểu) được ẩn đi trong kết quả của cuốn sách này nhưng sẽ xuất hiện trên màn hình của bạn.) Hành vi này tiện lợi nhưng nguy hiểm: một phép chuyển đổi bất cẩn có thể âm thầm biến thông tin thật, chẳng hạn "dưới ngưỡng phát hiện", thành dữ liệu khuyết. Hãy luôn đếm số giá trị khuyết trước và sau khi chuyển đổi, và tìm hiểu bất kỳ giá trị khuyết nào mới xuất hiện.

Cái bẫy thứ hai nảy sinh khi kết hợp các giá trị có kiểu khác nhau. Một vectơ (xem Mục 1.5) chỉ có thể chứa một kiểu, vì vậy R âm thầm chuyển mọi thứ sang kiểu linh hoạt nhất hiện có, theo thứ bậc logical < integer < numeric < character:

```
c(152, 138, "145") # một giá trị văn bản biến tất cả thành văn bản
```

```
#> [1] "152" "138" "145"
```

```
c(TRUE, FALSE, 3) # giá trị logic trở thành số 0/1
```

```
#> [1] 1 0 3
```

Vì vậy, chỉ cần một ô ký tự lạc lõng trong một cột huyết áp là đủ để biến cả cột thành văn bản. Đây chính xác là điều đã xảy ra với một số cột trong dữ liệu thô của nghiên cứu tình huống, như chúng ta sẽ thấy ở Mục 1.10.

Cái bẫy thứ ba là việc chuyển factor thành số. Bên trong, một factor được lưu dưới dạng các mã số nguyên (1, 2, 3, ...) có gắn nhãn, và `as.numeric()` trả về các mã, chứ không phải các nhãn:

```
dose <- factor(c("10", "5", "20", "5"))
dose
```

```
#> [1] 10 5 20 5
#> Levels: 10 20 5
```

```
as.numeric(dose) # các mã nội bộ: sai!
```

```
#> [1] 1 3 2 3
```

```
as.numeric(as.character(dose)) # chuyển sang văn bản trước: đúng
```

R

```
#> [1] 10 5 20 5
```

1.4.5 Factor

Các biến lâm sàng dạng phân loại, như giới tính, cơ sở y tế, trình độ học vấn hay tình trạng hút thuốc, tốt nhất nên được lưu dưới dạng factor. Một factor biết các nhóm được phép của nó (các mức) và thứ tự của chúng, điều quan trọng đối với bảng, đồ thị và, đặc biệt, đối với các mô hình hồi quy, nơi mức đầu tiên trở thành *nhóm tham chiếu* (reference category) (Chương 5).

```
smoking <- factor(c("Never", "Current", "Former", "Never", "Never"),
                  levels = c("Never", "Former", "Current"))
smoking
```

R

```
#> [1] Never Current Former Never Never
#> Levels: Never Former Current
```

```
levels(smoking)
```

R

```
#> [1] "Never" "Former" "Current"
```

```
table(smoking)
```

R

```
#> smoking
#>   Never Former Current
#>      3      1      1
```

Nếu không có đối số `levels`, R sẽ sắp xếp các mức theo thứ tự bảng chữ cái (Current, Former, Never), hiếm khi là thứ tự mà bác sĩ lâm sàng muốn đọc (ở đây "Never" là chưa bao giờ hút, "Former" là đã bỏ, "Current" là đang hút). Một giá trị không nằm trong các mức sẽ trở thành NA, đây là một cơ chế bảo vệ hữu ích chống lại lỗi chính tả: `factor("Curent", levels = c("Never", "Former", "Current"))` cho ra NA thay vì tạo ra một nhóm thứ tư giả tạo.

1.4.6 Ngày tháng

Ngày tháng được lưu dưới dạng số ngày tính từ 1 tháng 1 năm 1970, điều này cho phép tính toán, nhưng chúng được in ra ở định dạng năm-tháng-ngày quen thuộc. Hàm `as.Date()` chuyển văn bản ở định dạng tiêu chuẩn quốc tế (ISO 8601, YYYY-MM-DD) thành ngày tháng:

```
enrol <- as.Date("2024-03-15")
followup <- as.Date("2024-09-11")
class(enrol)
```

R

```
#> [1] "Date"
```

```
followup - enrol # hiệu số tính bằng ngày
```

R

```
#> Time difference of 180 days
```

```
as.numeric(followup - enrol) / 7 # tính bằng tuần
```

R

```
#> [1] 25.71
```

```
format(enrol, "%d %B %Y") # in ra theo định dạng dễ đọc hơn
```

R

```
#> [1] "15 March 2024"
```

Ngày tháng được nhập theo các định dạng khác, như 15/03/2024 hoặc 15-Mar-2024, cần được cho biết định dạng của chúng, và các bộ dữ liệu trộn lẫn nhiều định dạng là chuyện thường gặp. Gói **lubridate** (Grolemund and Wickham 2011) giúp việc đọc những ngày tháng như vậy dễ dàng hơn nhiều, và chúng ta sẽ dùng nó trong Chương 2.

Diễn giải lâm sàng

Kiểu dữ liệu không phải là một chi tiết kỹ thuật vụn vặt. Nếu việc sử dụng điều trị được lưu dưới dạng văn bản "1" và "0" ở một số dòng và "Yes" và "No" ở các dòng khác, bảng tần số sẽ hiện bốn nhóm thay vì hai và mọi tỷ lệ đều sai. Nếu ngày tuyển chọn được lưu dưới dạng văn bản, "01/02/2024" sẽ được xếp trước "2024-01-12" bất kể ngày nào thực sự đến trước. Xác định đúng kiểu dữ liệu là bước đầu tiên của một phân tích hợp lệ.

1.5 Vectơ

Cho đến giờ, mỗi đối tượng chỉ chứa một giá trị. Dĩ nhiên, dữ liệu lâm sàng gồm rất nhiều giá trị: huyết áp tâm thu của tất cả bệnh nhân trong một phòng khám, giới tính của tất cả người tham gia. Cấu trúc cơ bản của R cho một tập hợp giá trị là **vectơ** (vector): một dãy giá trị có thứ tự, tất cả cùng một kiểu. Thực ra, một con số đơn lẻ như 152 chỉ đơn giản là một vectơ có độ dài bằng một, và đó là lý do R in [1] phía trước nó.

1.5.1 Tạo vectơ

Hàm `c()`, viết tắt của "combine" (kết hợp), tạo một vectơ từ các đối số của nó.

```
sbp_readings <- c(152, 138, 145, 160, 129, 142) # số
sex <- c("Female", "Male", "Female", "Female", "Male", "Female") # ký tự
on_treatment <- c(TRUE, FALSE, TRUE, TRUE, FALSE, FALSE) # logic
sbp_readings
```

R

```
#> [1] 152 138 145 160 129 142
```

```
length(sbp_readings)
```

R

```
#> [1] 6
```

Sáu giá trị này có thể là huyết áp tâm thu của sáu bệnh nhân khám trong một buổi sáng tại phòng khám, với giới tính và tình trạng điều trị của họ ở các vị trí tương ứng.

1.5.2 Dãy số đều: `seq()`, `:` và `rep()`

Các dãy số thường xuyên được cần đến, ví dụ để xác định các nhóm tuổi hay các thời điểm theo dõi. Toán tử dấu hai chấm tạo dãy số nguyên, `seq()` tạo dãy với bước nhảy bất kỳ, và `rep()` lặp lại các giá trị.

```
1:10 # các số nguyên từ 1 đến 10
```

```
#> [1] 1 2 3 4 5 6 7 8 9 10
```

```
seq(from = 18, to = 88, by = 10) # ranh giới các nhóm tuổi
```

```
#> [1] 18 28 38 48 58 68 78 88
```

```
seq(0, 1, length.out = 5) # năm giá trị cách đều nhau
```

```
#> [1] 0.00 0.25 0.50 0.75 1.00
```

```
rep("Control", times = 3) # lặp lại một giá trị
```

```
#> [1] "Control" "Control" "Control"
```

```
rep(c("A", "B"), times = 3) # lặp lại một mẫu
```

```
#> [1] "A" "B" "A" "B" "A" "B"
```

```
rep(c("A", "B"), each = 3) # lặp lại từng phần tử
```

```
#> [1] "A" "A" "A" "B" "B" "B"
```

Hai dòng cuối cho thấy sự khác biệt giữa đối số `times` và `each`, điều hữu ích khi xây dựng, chẳng hạn, một danh sách phân bổ điều trị theo thiết kế khối.

1.5.3 Truy xuất phần tử: lấy ra các phần tử

Từng phần tử của một vectơ được lấy ra bằng dấu ngoặc vuông `[ ]`. Vị trí trong R bắt đầu từ 1 (không phải 0 như trong một số ngôn ngữ khác).

```
sbp_readings[1] # lần đo thứ nhất
```

```
#> [1] 152
```

```
sbp_readings[c(1, 3)]      # lần đo thứ nhất và thứ ba
```

```
#> [1] 152 145
```

```
sbp_readings[2:4]          # từ lần đo thứ hai đến thứ tư
```

```
#> [1] 138 145 160
```

```
sbp_readings[-1]           # tất cả trừ lần đo thứ nhất
```

```
#> [1] 138 145 160 129 142
```

```
sbp_readings[length(sbp_readings)] # lần đo cuối cùng
```

```
#> [1] 142
```

Một chỉ số âm sẽ loại bỏ phần tử thay vì chọn chúng. Truy xuất vượt quá cuối vectơ sẽ trả về NA thay vì báo lỗi, đây là một tình huống khác mà R lặng lẽ trả cho bạn một giá trị khuyết.

Cách truy xuất hữu ích nhất dùng một **vector logic**: R giữ lại những phần tử ở các vị trí mà chỉ số là TRUE.

```
sbp_readings[on_treatment]      # SBP của các bệnh nhân đang điều trị
```

```
#> [1] 152 145 160
```

```
sbp_readings[sex == "Male"]      # SBP của các bệnh nhân nam
```

```
#> [1] 138 129
```

Đây là ý tưởng làm nền tảng cho mọi thao tác lọc dữ liệu, từ việc chọn ra các bệnh nhân tăng huyết áp trong một nghiên cứu đến việc loại bỏ các giá trị không hợp lý.

1.5.4 Phép tính theo vector

Phép tính số học trong R được **vector hóa** (vectorised): một phép toán áp dụng cho một vectơ sẽ được áp dụng cho mọi phần tử cùng lúc, không cần viết vòng lặp.

```
sbp_readings - 10           # trừ 10 khỏi mỗi lần đo
```

```
#> [1] 142 128 135 150 119 132
```

```
sbp_readings / 7.5 # đổi mmHg sang kPa (1 kPa = 7,5 mmHg)
```

R

```
#> [1] 20.27 18.40 19.33 21.33 17.20 18.93
```

```
dbp_readings <- c(95, 88, 90, 101, 79, 85)
map_readings <- dbp_readings + (sbp_readings - dbp_readings) / 3
round(map_readings, 1)
```

R

```
#> [1] 114.0 104.7 108.3 120.7 95.7 104.0
```

Khi hai vectơ có cùng độ dài được kết hợp, R ghép cặp chúng theo từng phần tử: SBP thứ nhất với DBP thứ nhất, thứ hai với thứ hai, và cứ thế. Đây chính xác là điều ta muốn khi mỗi vị trí đại diện cho một bệnh nhân. (Nếu độ dài khác nhau, R sẽ *tái sử dụng* (recycle) vectơ ngắn hơn, kèm cảnh báo nếu độ dài này không phải là bội số của độ dài kia. Việc tái sử dụng thỉnh thoảng hữu ích nhưng thường là dấu hiệu của một sai sót.)

1.5.5 Phép so sánh logic

Các toán tử so sánh tạo ra vectơ logic.

Bảng 1.5: Các toán tử so sánh và toán tử logic trong R.

Toán tử	Ý nghĩa	Ví dụ
==	bằng	sex == "Female"
!=	khác	sex != "Female"
<, <=	nhỏ hơn (hoặc bằng)	sbp < 140
>, >=	lớn hơn (hoặc bằng)	dbp >= 90
&	và (cả hai đều đúng)	sbp >= 140 & dbp >= 90
!	phủ định (không)	!on_treatment
%in%	thuộc một tập hợp	sex %in% c("F", "f")

Bảng trên bỏ qua một toán tử vì ký hiệu của nó xung đột với cách trình bày bảng: dấu gạch đứng | có nghĩa là *hoặc*, vì vậy `sbp >= 140 | dbp >= 90` là TRUE khi ít nhất một trong hai điều kiện đúng. Cũng hãy lưu ý dấu bằng kép == dùng để so sánh; một dấu = đơn là phép gán hoặc tên đối số, không bao giờ là phép kiểm tra bằng nhau.

```
high_sbp <- sbp_readings >= 140
high_sbp
```

R

```
#> [1] TRUE FALSE TRUE TRUE FALSE TRUE
```

```
high_bp <- sbp_readings >= 140 | dbp_readings >= 90 # một trong hai tăng
high_bp
```

R

```
#> [1] TRUE FALSE TRUE TRUE FALSE TRUE
```

Vì trong phép tính số học TRUE được coi là 1 và FALSE là 0, hàm `sum()` của một vectơ logic sẽ

đếm số giá trị TRUE và `mean()` cho ra tỷ lệ của chúng. Mẹo nhỏ này được dùng liên tục trong phân tích dữ liệu.

```
sum(high_bp)      # bao nhiêu bệnh nhân có chỉ số huyết áp tăng
```

R

```
#> [1] 4
```

```
mean(high_bp)     # tỷ lệ
```

R

```
#> [1] 0.6667
```

Bốn trong sáu bệnh nhân (67%) có huyết áp tâm thu từ 140 mmHg trở lên hoặc huyết áp tâm trương từ 90 mmHg trở lên, là các ngưỡng quy ước cho huyết áp tăng khi đo tại phòng khám (World Health Organization 2021). Trong ví dụ nhỏ này, những bệnh nhân có huyết áp tâm trương tăng tình cờ cũng có huyết áp tâm thu tăng, nên `high_bp` và `high_sbp` trùng nhau; trong một mẫu lớn hơn thì điều này sẽ không xảy ra.

1.5.6 Các hàm tóm tắt

R có nhiều hàm thu gọn một vectơ thành một giá trị tóm tắt duy nhất. Chúng ta sẽ tìm hiểu chúng một cách đầy đủ, cùng với ý nghĩa thống kê, trong Chương 3; dưới đây là phần giới thiệu trước.

```
mean(sbp_readings)
```

R

```
#> [1] 144.3
```

```
median(sbp_readings)
```

R

```
#> [1] 143.5
```

```
sd(sbp_readings)      # độ lệch chuẩn
```

R

```
#> [1] 10.82
```

```
min(sbp_readings)
```

R

```
#> [1] 129
```

```
max(sbp_readings)
```

R

```
#> [1] 160
```

```
range(sbp_readings)
```

R

```
#> [1] 129 160
```

```
summary(sbp_readings) # tóm tắt sáu con số
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#>      129     139     144     144     150     160
```

Kết quả của `summary()` cho biết, từ trái sang phải, giá trị nhỏ nhất, tứ phân vị thứ nhất (25% số giá trị nằm dưới nó), trung vị, trung bình, tứ phân vị thứ ba và giá trị lớn nhất. Với sáu lần đo này, trung bình (144,3) và trung vị (143,5) gần nhau, cho thấy các giá trị phân bố khá đối xứng quanh trung tâm.

Với một vectơ ký tự, cách tóm tắt tự nhiên là bảng tần số:

```
table(sex)
```

```
#> sex
#> Female  Male
#>      4      2
```

1.5.7 Giá trị khuyết: NA

Dữ liệu thực tế luôn có những chỗ trống. Một mẫu máu bị vỡ hồng cầu, một bệnh nhân từ chối cân, một phiếu bị bỏ trống. R biểu diễn một giá trị khuyết bằng ký hiệu đặc biệt NA ("not available", không có sẵn), có thể xuất hiện trong vectơ thuộc bất kỳ kiểu nào. Giá trị khuyết có tính "lây lan": bất kỳ phép tính nào có một giá trị chưa biết thì kết quả cũng chưa biết.

```
weights <- c(61.3, 68.3, NA, 78.5, 71.6)
weights + 1
```

```
#> [1] 62.3 69.3  NA 79.5 72.6
```

```
mean(weights)
```

```
#> [1] NA
```

Trung bình của năm số trong đó có một số chưa biết thì không thể biết được, vì vậy R trả lời NA. Đây là mặc định đúng đắn, vì nó buộc bạn phải để ý đến giá trị khuyết. Để tính trung bình của các giá trị *quan sát được*, hãy đặt đối số `na.rm = TRUE` ("NA remove", loại bỏ NA):

```
mean(weights, na.rm = TRUE)
```

```
#> [1] 69.92
```

```
sum(is.na(weights)) # có bao nhiêu giá trị bị khuyết?
```

```
#> [1] 1
```

Hàm `is.na()` trả về TRUE cho mỗi phần tử bị khuyết, vì vậy `sum(is.na(x))` đếm số giá trị khuyết. Bạn không thể kiểm tra giá trị khuyết bằng `x == NA`, vì so sánh bất kỳ thứ gì với một giá trị chưa biết cũng cho kết quả chưa biết: `NA == NA` là NA.

Lỗi thường gặp

Đừng tự động dùng ngay `na.rm = TRUE`. Rất dễ tính ra một giá trị trung bình "của tất cả bệnh nhân" mà thực chất chỉ là trung bình của 60% số người đã làm xét nghiệm. Hãy luôn báo cáo số giá trị bị khuyết kèm theo mọi giá trị tóm tắt, và suy nghĩ xem vì sao chúng bị khuyết: những giá trị bị khuyết vì một lý do liên quan đến biến kết cục có thể làm sai lệch kết quả (Little and Rubin 2019). Dữ liệu khuyết được thảo luận thêm trong Chương 2 và Chương 3.

1.6 Hàm, đối số và trợ giúp

1.6.1 Cấu trúc của một lời gọi hàm

Bạn đã dùng nhiều hàm: `sqrt()`, `round()`, `mean()`, `c()`, `seq()`. Mọi lời gọi hàm đều có cùng một hình dạng: tên hàm, theo sau là cặp ngoặc đơn chứa các **đối số** của nó, phân cách nhau bằng dấu phẩy. Đối số là các đầu vào cho hàm biết cần xử lý cái gì và xử lý như thế nào.

```
round(144.33333, digits = 1)
```

R

```
#> [1] 144.3
```

Ở đây `round` là hàm, `144.33333` là đối số thứ nhất (con số cần làm tròn) và `digits = 1` là đối số thứ hai điều khiển cách hàm hoạt động. Hàm trả về một giá trị, mà R sẽ in ra hoặc bạn có thể lưu vào một đối tượng.

1.6.2 Đối số theo vị trí và đối số có tên

Đối số có thể được cung cấp theo hai cách. Đối số **theo vị trí** (positional) được ghép theo thứ tự của chúng trong định nghĩa hàm; đối số **có tên** (named) được ghép theo tên, với thứ tự bất kỳ. Định nghĩa của `seq()` bắt đầu bằng `seq(from, to, by, ...)`, vì vậy các lời gọi sau là tương đương:

```
seq(18, 88, 10) # theo vị trí
```

R

```
#> [1] 18 28 38 48 58 68 78 88
```

```
seq(from = 18, to = 88, by = 10) # có tên
```

R

```
#> [1] 18 28 38 48 58 68 78 88
```

```
seq(by = 10, to = 88, from = 18) # có tên, thứ tự bất kỳ
```

R

```
#> [1] 18 28 38 48 58 68 78 88
```

Nhiều đối số có **giá trị mặc định**, được dùng khi bạn không cung cấp chúng. Giá trị mặc định của `digits` trong `round()` là 0, và giá trị mặc định của `na.rm` trong `mean()` là `FALSE`, đó là lý do `mean()` trả về `NA` ở ví dụ trên.

Thực hành tốt

Một thói quen tốt là cung cấp một hoặc hai đối số đầu tiên theo vị trí (chúng thường là dữ liệu, và ý nghĩa của chúng là hiển nhiên) và tất cả các đối số khác theo tên, như trong `mean(weights, na.rm = TRUE)` hoặc `round(map, digits = 1)`. Đối số có tên khiến mã tự giải thích được và bảo vệ bạn nếu thứ tự đối số của hàm có lúc thay đổi.

Các hàm có thể được **lồng nhau**, khi đầu ra của hàm này trở thành đầu vào của hàm khác. R tính chúng từ trong ra ngoài:

```
round(mean(weights, na.rm = TRUE), 1)
```

R

```
#> [1] 69.9
```

Ở đây `mean()` được tính trước và kết quả của nó (69,925) được chuyển cho `round()`. Lồng hàm quá sâu sẽ nhanh chóng trở nên khó đọc, và đó là vấn đề mà toán tử pipe giải quyết (Mục 1.11).

1.6.3 Tìm trợ giúp

Không ai nhớ hết mọi hàm và mọi đối số. Biết cách tra cứu là một kỹ năng cốt lõi. Mỗi hàm trong R đều có một trang trợ giúp, mà bạn mở bằng `?` hoặc `help()`:

```
?mean          # trang trợ giúp của mean()
help("read_csv") # tương tự, dưới dạng lời gọi hàm
??"standard deviation" # tìm một cụm từ trong tất cả các trang trợ giúp
example(mean)    # chạy các ví dụ ở cuối trang trợ giúp
vignette("dplyr") # một bài hướng dẫn dài hơn đi kèm với gói
```

R

Các trang trợ giúp hiện ra trong khung Help và luôn có cùng một cấu trúc: *Description* (hàm làm gì), *Usage* (các đối số và giá trị mặc định), *Arguments* (ý nghĩa của từng đối số), *Value* (giá trị trả về), *Details*, *See Also* và, hữu ích nhất, *Examples* ở cuối trang, mà bạn có thể sao chép vào console để chạy. Trang trợ giúp được viết ngắn gọn và lúc đầu có thể cảm thấy khô khan; đọc phần *Usage* và *Examples* trước là một chiến lược tốt. Ngoài trợ giúp của chính R, cuốn sách trực tuyến miễn phí *R for Data Science* (Wickham et al. 2023) và trang web của các gói là những tài liệu tham khảo tuyệt vời. Khi tìm kiếm trên internet, hãy thêm "R" và tên gói cùng với thông báo lỗi hoặc tác vụ cần làm (tìm bằng tiếng Anh thường cho nhiều kết quả hơn).

1.6.4 Đọc thông báo lỗi

Lỗi là một phần bình thường của lập trình, không phải dấu hiệu thất bại. R dừng lại và in ra một thông báo bắt đầu bằng `Error`; thông báo mô tả điều gì đã sai, và học cách đọc nó sẽ tiết kiệm cho bạn hàng giờ. Cảnh báo (warnings), bắt đầu bằng `warning`, có nghĩa là R đã hoàn thành

lệnh nhưng có thể có điều gì đó không ổn; không bao giờ được bỏ qua chúng. Dưới đây là một số lỗi thường gặp và nguyên nhân thường thấy:

Bảng 1.6: Các thông báo lỗi R thường gặp và nguyên nhân thường thấy.

Thông báo	Nguyên nhân thường thấy
object 'x' not found	Gõ nhầm, sai chữ hoa/thường, hoặc dòng tạo ra x chưa được chạy
could not find function "x"	Viết sai tên hàm, hoặc gói chứa hàm chưa được nạp bằng <code>library()</code>
non-numeric argument to binary operator	Tính toán trên văn bản, thường là một con số được lưu dưới dạng ký tự
unexpected symbol / unexpected ') '	Lỗi cú pháp: thiếu dấu phẩy, dấu ngoặc hoặc dấu nháy
'file.csv' does not exist in current working directory	Sai đường dẫn tệp hoặc sai thư mục làm việc
there is no package called 'x'	Gói chưa được cài đặt

Dưới đây là một trong số đó trong thực tế. Ta thử dùng một hàm từ một gói chưa được nạp trong phiên làm việc hiện tại:

```
clean_names(data.frame(Patient.ID = 1))
```

R

```
#> Error in `clean_names()`:  
#> ! could not find function "clean_names"
```

Cách khắc phục là nạp gói cung cấp `clean_names()` (ở đây là **janitor**) hoặc gọi hàm kèm tiền tố tên gói, như `janitor::clean_names()`.

Một nguồn gây bối rối thường gặp là lệnh *chưa hoàn chỉnh*. Nếu bạn quên một dấu ngoặc đóng hoặc dấu nháy, dấu nhắc của console chuyển từ `>` thành `+`, nghĩa là R đang chờ bạn hoàn thành lệnh. Hãy hoàn thành nó hoặc nhấn `Esc` để hủy và bắt đầu lại.

Lỗi thường gặp

Quên dấu nháy quanh văn bản là một lỗi kinh điển. `sex == Female` yêu cầu R so sánh `sex` với một *đối tượng* có tên `Female`, vốn không tồn tại ("object 'Female' not found"). Giá trị văn bản luôn cần dấu nháy: `sex == "Female"`. Ngược lại, tên đối tượng và tên cột không cần dấu nháy trong hầu hết các hàm: `mean(sbp)`, chứ không phải `mean("sbp")`.

1.7 Gói

1.7.1 Cài đặt một lần, nạp mỗi phiên làm việc

Các hàm đi kèm R ("base R") bao quát rất nhiều thứ, nhưng phần lớn sức mạnh của R đến từ các **gói** (packages): những tập hợp hàm, dữ liệu và tài liệu do cộng đồng viết và phân phối qua CRAN. Năm 2026, CRAN lưu trữ hơn hai mươi nghìn gói. Sử dụng một gói gồm hai bước riêng biệt:

- 1. Cài đặt** gói, tức là tải gói về từ internet và lưu trên máy tính của bạn. Bạn làm việc này *một*

lần trên mỗi máy tính (và chỉ làm lại khi nâng cấp R hoặc muốn có phiên bản mới hơn của gói).

2. **Nạp** gói bằng `library()`, giúp các hàm của gói có sẵn trong phiên làm việc R hiện tại. Bạn làm việc này *mỗi lần* khởi động R, ở đầu mỗi script.

Một phép so sánh hữu ích: cài đặt một gói giống như mua một cuốn sách và đặt nó lên giá; nạp gói giống như lấy sách từ giá xuống để đọc. Bạn mua sách một lần, nhưng lấy nó xuống bất cứ khi nào cần.

```
install.packages("tidyverse") # một lần trên mỗi máy tính: tải về từ CRAN
install.packages("readxl")
```

```
library(tidyverse) # mỗi phiên: nhập, xử lý dữ liệu, ggplot2
library(readxl)    # mỗi phiên: đọc tệp Excel
```

Khi được nạp, tidyverse in ra một thông báo ngắn liệt kê các gói nó đã gắn vào và một vài "xung đột" (conflicts), tức là các hàm trong những gói khác nhau có cùng tên. Ví dụ, cả gói **stats** của base R và **dplyr** đều có một hàm tên là `filter()`; sau `library(tidyverse)`, tên `filter` chỉ phiên bản của dplyr. Nếu cần nói rõ, toán tử hai dấu hai chấm `package::function()` gọi một hàm từ một gói cụ thể, dù gói đó đã được nạp hay chưa, như `dplyr::filter()` hoặc `stats::filter()`.

Lỗi thường gặp

Đừng đặt `install.packages()` trong một script phân tích được chạy mỗi lần. Làm vậy vừa chậm, cần kết nối internet, có thể âm thầm cập nhật một gói lên phiên bản hoạt động khác đi, và sẽ thất bại trên những máy tính mà bạn không có quyền cài đặt phần mềm. Hãy cài đặt gói một lần từ console (hoặc bằng một dòng đã được biến thành chú thích, như ở trên); nạp chúng bằng `library()` ở đầu mỗi script.

1.7.2 Tidyverse

Tidyverse là một bộ sưu tập các gói có chung triết lý thiết kế, ngữ pháp và cấu trúc dữ liệu (Wickham et al. 2019). Nạp nó bằng `library(tidyverse)` sẽ gắn các thành viên cốt lõi cùng một lúc:

- **readr** để đọc các tệp dữ liệu dạng bảng như CSV;
- **dplyr** để xử lý khung dữ liệu (chọn, lọc, tóm tắt);
- **tidyr** để thay đổi hình dạng dữ liệu;
- **ggplot2** để vẽ đồ thị (Wickham 2016);
- **stringr** để làm việc với văn bản, **forcats** cho factor và **lubridate** cho ngày tháng;
- **tibble**, một phiên bản hiện đại của khung dữ liệu, và **purrr** cho các thao tác lặp lại.

Tidyverse được xây dựng quanh ý tưởng **dữ liệu gọn gàng** (tidy data), trong đó mỗi biến là một cột, mỗi quan sát là một dòng và mỗi giá trị là một ô (Wickham 2014). Một bộ dữ liệu lâm sàng ở cấp độ bệnh nhân với mỗi dòng là một bệnh nhân vốn đã gọn gàng một cách tự nhiên, và đó là một lý do khiến tidyverse rất phù hợp với nghiên cứu lâm sàng. Cuốn sách này dùng các hàm của tidyverse cho phần lớn việc xử lý dữ liệu và vẽ đồ thị, và dùng base R khi cách đó đơn giản

hơn. Các gói khác, như **readxl** cho tệp Excel, **janitor** cho làm sạch dữ liệu, **gtsummary** cho các bảng sẵn sàng xuất bản (Sjoberg et al. 2021) và **broom** cho kết quả mô hình gọn gàng, sẽ được giới thiệu khi cần đến.

1.8 Dự án, thư mục làm việc và đường dẫn tệp

1.8.1 Thư mục làm việc

Khi bạn yêu cầu R đọc một tệp, R phải biết cần tìm ở đâu. **Thư mục làm việc** (working directory) là thư mục mà R coi là vị trí hiện tại của nó; một tên tệp không có đường dẫn đầy đủ sẽ được tìm ở đó.

```
getwd() # in ra thư mục làm việc hiện tại
```

R

Trên máy tính dùng để biên soạn cuốn sách này, `getwd()` trả về một đường dẫn kết thúc bằng `.../Course`, thư mục chứa thư mục `Data/` của nghiên cứu tình huống. Trên máy tính của bạn, đường dẫn sẽ khác.

1.8.2 Đường dẫn tuyệt đối và tương đối

Một **đường dẫn tuyệt đối** (absolute path) cho biết vị trí đầy đủ của một tệp tính từ gốc của ổ đĩa, ví dụ `C:/Users/amina/Documents/htn_study/Data/hypertension_phc_raw.csv`. Một **đường dẫn tương đối** (relative path) cho biết vị trí so với thư mục làm việc, ví dụ `Data/hypertension_phc_raw.csv`. Đường dẫn tuyệt đối chỉ hoạt động trên chiếc máy tính nơi nó được viết ra, và chỉ cho đến khi một thư mục bị đổi tên; đường dẫn tương đối vẫn hoạt động khi toàn bộ thư mục dự án được sao chép sang máy tính xách tay của đồng nghiệp, một máy chủ hay một chiếc USB.

Lưu ý rằng R dùng dấu gạch chéo xuôi `/` trong đường dẫn, ngay cả trên Windows. Nếu bạn sao chép một đường dẫn từ Windows Explorer, vốn dùng dấu gạch chéo ngược, hãy thay chúng bằng `/` hoặc gấp đôi chúng (`\\`), vì một dấu gạch chéo ngược đơn có ý nghĩa đặc biệt bên trong chuỗi ký tự của R.

1.8.3 RStudio Project

Cách đáng tin cậy để quản lý thư mục làm việc là dùng một **RStudio Project**. Một project đơn giản là một thư mục chứa một tệp nhỏ có phần mở rộng `.Rproj`. Khi bạn mở project (bằng cách nhấp đúp vào tệp `.Rproj`, hoặc qua *File > Open Project*), RStudio khởi động một phiên R mới với thư mục làm việc là thư mục của project. Khi đó, mọi đường dẫn tương đối trong script của bạn đều được hiểu đúng, bất kể project nằm trên máy tính nào.

Để tạo một project, chọn *File > New Project*, sau đó chọn *New Directory* (để bắt đầu từ đầu) hoặc *Existing Directory* (để biến một thư mục sẵn có thành project). Một bố cục đơn giản phù hợp với hầu hết các phân tích lâm sàng, theo tinh thần của Wilson et al. (2017), như sau:

```
htn_study/  
  htn_study.Rproj  
  Data/      # dữ liệu thô (không bao giờ sửa bằng tay) và dữ liệu đã làm sạch  
  Scripts/   # các script R, đánh số theo thứ tự chạy  
  Outputs/   # bảng và hình do các script tạo ra  
  Reports/   # bản thảo bài báo và báo cáo
```

R

Lỗi thường gặp

Tránh bắt đầu script bằng `setwd("C:/Users/yourname/Desktop/analysis")`. Dòng lệnh này chỉ hoạt động trên đúng một máy tính, và script sẽ thất bại với thông báo "cannot change working directory" (không thể thay đổi thư mục làm việc) đối với bất kỳ ai khác, kể cả chính bạn trên một máy tính mới. Thay vào đó, hãy dùng RStudio Project và đường dẫn tương đối. Tương tự, tránh lưu dữ liệu ở một thư mục khác với các script phân tích chúng; hãy giữ mọi thứ thuộc về một nghiên cứu trong cùng một project.

1.9 Nghiên cứu tình huống và nhập dữ liệu

1.9.1 Nghiên cứu tình huống

Mọi ví dụ trong cuốn sách này đều dùng một bộ dữ liệu duy nhất, để bạn có thể theo dõi một phân tích từ dữ liệu thô đến mô hình cuối cùng. Bộ dữ liệu đến từ một nghiên cứu cắt ngang đa trung tâm, *Các yếu tố quyết định việc sử dụng điều trị tăng huyết áp ở người trưởng thành đến khám tại các cơ sở chăm sóc sức khỏe ban đầu*, trong đó 1.500 người trưởng thành đến khám tại sáu cơ sở chăm sóc sức khỏe ban đầu (primary healthcare, PHC) được đưa vào nghiên cứu. Câu hỏi nghiên cứu là: trong số những người trưởng thành đã được chẩn đoán tăng huyết áp, những yếu tố nào quyết định việc họ hiện có đang dùng thuốc hạ huyết áp hay không? Tăng huyết áp ảnh hưởng tới hơn một tỷ người trưởng thành trên toàn thế giới, và một phần lớn những người đã được chẩn đoán không được điều trị (NCD Risk Factor Collaboration (NCD-RisC) 2021; Mills et al. 2020), vì vậy hiểu được các rào cản đối với việc sử dụng điều trị là một ưu tiên y tế công cộng thực sự.

Bộ dữ liệu ghi nhận các đặc điểm nhân khẩu học (tuổi, giới tính, nơi cư trú, học vấn, nghề nghiệp, tình trạng hôn nhân, bảo hiểm y tế), hành vi (hút thuốc, uống rượu bia, hoạt động thể lực), các số đo lâm sàng (chiều cao, cân nặng, BMI, huyết áp, bệnh đồng mắc, tiền sử gia đình, đái tháo đường), các dấu ấn sinh học xét nghiệm (lipid máu, glucose, creatinine, điện giải), điểm hiểu biết về tăng huyết áp, khoảng cách đến cơ sở y tế, và các biến kết cục: bệnh nhân có được chẩn đoán tăng huyết áp hay không (`htn_diagnosed`), có đang điều trị hay không (`treatment_uptake`, biến kết cục chính), mức độ tuân thủ điều trị và huyết áp có được kiểm soát hay không. Định nghĩa đầy đủ có trong từ điển dữ liệu, `Data/data_dictionary.md`.

Dữ liệu được **mô phỏng cho mục đích giảng dạy**. Chúng được tạo ra để giống với dữ liệu thực tế từ tuyến chăm sóc ban đầu, bao gồm các mối quan hệ thực tế giữa các biến và, một cách có chủ ý, những loại lỗi thường thấy trong các tệp thu thập dữ liệu thực tế. Các kết quả thu được từ dữ liệu này minh họa phương pháp; chúng không phải là phát hiện lâm sàng.

1.9.2 Khung dữ liệu và tibble

Một vectơ chứa một biến. Một nghiên cứu cần nhiều biến được đo trên cùng các bệnh nhân, và R lưu chúng trong một **khung dữ liệu** (data frame): một bảng hình chữ nhật trong đó mỗi cột là một vectơ (tất cả cùng một kiểu) và mọi cột đều có cùng độ dài. Mỗi dòng là một quan sát, ở đây là một bệnh nhân. Các cột khác nhau có thể có kiểu khác nhau: một mã định danh dạng ký tự, tuổi dạng số, một factor cho giới tính. Một khung dữ liệu nhỏ có thể được tạo bằng tay:

```
clinic <- data.frame(
  patient_id = c("P01", "P02", "P03", "P04"),
  age        = c(54, 61, 47, 70),
  sex        = c("Female", "Male", "Female", "Male"),
  sbp_mmhg   = c(152, 138, 145, 160)
)
clinic
```

```
#>   patient_id age    sex sbp_mmhg
#> 1      P01   54 Female     152
#> 2      P02   61  Male     138
#> 3      P03   47 Female     145
#> 4      P04   70  Male     160
```

Một **tibble** là phiên bản hiện đại của khung dữ liệu trong tidyverse. Tibble hoạt động giống khung dữ liệu ở gần như mọi khía cạnh, nhưng được in ra hữu ích hơn (hiển thị kiểu của từng cột và chỉ in số dòng, số cột vừa với màn hình) và chặt chẽ hơn trong một số tình huống mà khung dữ liệu âm thầm làm những điều gây bất ngờ. Các hàm nhập dữ liệu của tidyverse trả về tibble; trong cuốn sách này, "khung dữ liệu" được dùng để chỉ cả hai.

```
as_tibble(clinic)
```

```
#> # A tibble: 4 × 4
#>   patient_id age sex    sbp_mmhg
#>   <chr>      <dbl> <chr>    <dbl>
#> 1 P01         54 Female      152
#> 2 P02         61 Male        138
#> 3 P03         47 Female      145
#> 4 P04         70 Male        160
```

Dòng <chr> <dbl> <chr> <dbl> bên dưới tên cột cho biết kiểu của từng cột: chr là ký tự (character) và dbl là số thực (double, numeric).

Một cột đơn lẻ được lấy ra từ khung dữ liệu dưới dạng vector bằng dấu đô la \$, và có thể thêm một cột theo cùng cách:

```
clinic$sbp_mmhg
```

```
#> [1] 152 138 145 160
```

```
mean(clinic$age)
```

```
#> [1] 58
```

```
clinic$high_sbp <- clinic$sbp_mmhg >= 140
clinic
```

```
#>   patient_id age    sex sbp_mmhg high_sbp
#> 1      P01   54 Female     152     TRUE
#> 2      P02   61  Male     138    FALSE
```

```
#> 3      P03  47 Female    145    TRUE
#> 4      P04  70   Male    160    TRUE
```

1.9.3 Nhập tệp CSV bằng `read_csv()`

Dữ liệu lâm sàng thường được gửi đến dưới dạng tệp **CSV** (comma-separated values, giá trị phân cách bằng dấu phẩy): một tệp văn bản thuần trong đó mỗi dòng là một hàng và các giá trị được phân cách bằng dấu phẩy. Tệp CSV có thể được mở bằng bất kỳ phần mềm nào và là định dạng có tính di động cao nhất để chia sẻ dữ liệu. Gói **readr** (thuộc tidyverse) cung cấp hàm `read_csv()`:

```
htn <- read_csv("Data/hypertension_phc_raw.csv")
```

Không có gì được in ra ở đây vì thiết lập của cuốn sách này đã tắt báo cáo cột của `readr`. Trên màn hình của bạn, `read_csv()` sẽ in ra một thông báo như `Rows: 1503 Columns: 36` kèm theo bản tóm tắt các kiểu cột mà nó đã đoán. `readr` xem xét 1.000 dòng đầu tiên của mỗi cột và chọn kiểu cụ thể nhất phù hợp với tất cả các dòng đó: logic, rồi số, rồi ngày tháng, và quay về kiểu ký tự nếu không có kiểu nào khác phù hợp. Theo mặc định, hàm coi ô trống và văn bản NA là giá trị khuyết, và loại bỏ khoảng trắng ở đầu và cuối các giá trị (`trim_ws = TRUE`).

Điều đầu tiên cần lưu ý là tệp thô có **1.503 dòng**, chứ không phải 1.500 bệnh nhân đã được đưa vào nghiên cứu. Đã có điều gì đó không ổn: như từ điển dữ liệu cảnh báo, ba bệnh nhân đã bị nhập hai lần. Chúng ta sẽ loại bỏ các bản ghi trùng lặp này trong Chương 2.

1.9.4 Nhập tệp Excel bằng `read_excel()`

Nhiều bộ dữ liệu lâm sàng được thu thập hoặc chia sẻ dưới dạng bảng tính Excel. Gói **readxl** (Wickham et al. 2023) đọc các tệp `.xls` và `.xlsx` mà không cần cài đặt Excel. Một bảng tính có thể chứa nhiều trang tính (sheet), vì vậy nên kiểm tra tên các trang tính và chỉ rõ tên trang tính bạn muốn đọc:

```
excel_sheets("Data/hypertension_phc_raw.xlsx")
```

```
#> [1] "data"
```

```
htn_xl <- read_excel("Data/hypertension_phc_raw.xlsx", sheet = "data")
dim(htn_xl)
```

```
#> [1] 1503  36
```

```
dim(htn_xl)
```

```
#> [1] 1503  36
```

```
identical(names(htn), names(htn_xl))
```

```
#> [1] TRUE
```

Cả hai tệp đều chứa cùng 1.503 dòng và 36 cột với tên cột giống hệt nhau. Hàm `identical()` chỉ trả về một giá trị `TRUE` duy nhất nếu hai đối số của nó giống hệt nhau, đây là một cách tiện lợi để kiểm tra rằng hai phiên bản của một bộ dữ liệu khớp nhau. Các định dạng khác cũng dễ đọc như vậy: gói **haven** đọc các tệp SPSS (`read_sav()`), Stata (`read_dta()`) và SAS (`read_sas()`), vốn phổ biến trong nghiên cứu lâm sàng.

Thực hành tốt

Hãy coi tệp dữ liệu thô là tệp chỉ đọc. Không bao giờ sửa nó bằng tay trong Excel để "sửa" một lỗi, vì khi đó việc chỉnh sửa không để lại dấu vết gì. Thay vào đó, hãy thực hiện mọi thay đổi trong script R, để con đường từ dữ liệu thô đến bộ dữ liệu phân tích được ghi lại đầy đủ và có thể được xem xét lại. Nếu dữ liệu được gửi đến dưới dạng bảng tính, các khuyến nghị của Broman and Woo (2018) (mỗi cột một biến, mỗi ô một giá trị, không dùng màu sắc để mã hóa dữ liệu, ngày tháng và mã thống nhất) giúp việc phân tích dễ dàng hơn nhiều.

1.10 Kiểm tra dữ liệu lần đầu

Trước khi tính bất kỳ thống kê nào, hãy nhìn vào dữ liệu. Vài phút kiểm tra sẽ cho thấy cấu trúc của bộ dữ liệu, các kiểu mà R đã gán và rất thường xuyên là những vấn đề dữ liệu đầu tiên. Các hàm trong mục này tạo thành một quy trình thường quy mà bạn nên chạy trên mọi bộ dữ liệu mới.

1.10.1 Kích thước và tên biến

```
dim(htn)      # số dòng và số cột
```

R

```
#> [1] 1503  36
```

```
nrow(htn)
```

R

```
#> [1] 1503
```

```
ncol(htn)
```

R

```
#> [1] 36
```

```
names(htn)
```

R

```
#> [1] "patient_id"      "facility"
#> [3] "enroll_date"     "age"
#> [5] "sex"             "residence"
#> [7] "education"       "occupation"
```

```
#> [9] "marital_status"      "health_insurance"
#> [11] "height_cm"           "weight_kg"
#> [13] "bmi"                 "smoking"
#> [15] "alcohol"             "physical_activity"
#> [17] "family_history_htn"  "diabetes"
#> [19] "sbp_mmhg"            "dbp_mmhg"
#> [21] "total_chol_mmol_l"   "hdl_mmol_l"
#> [23] "ldl_mmol_l"          "triglycerides_mmol_l"
#> [25] "fasting_glucose_mmol_l" "creatinine_umol_l"
#> [27] "sodium_mmol_l"       "potassium_mmol_l"
#> [29] "knowledge_score"     "distance_to_facility_km"
#> [31] "comorbidity_count"   "htn_diagnosed"
#> [33] "months_since_diagnosis" "treatment_uptake"
#> [35] "adherence"           "bp_controlled"
```

`dim()` trả về số dòng và số cột, theo đúng thứ tự đó. `names()` liệt kê 36 tên biến. Các tên này đã theo phong cách snake case nhất quán và có chứa đơn vị khi cần, nhờ đó dễ làm việc.

1.10.2 In ra và xem các dòng đầu tiên

Gõ tên của một tibble sẽ in ra mười dòng đầu tiên và số cột vừa với màn hình:

htn

R

```
#> # A tibble: 1,503 × 36
#>   patient_id facility enroll_date age sex residence education occupation
#>   <chr>      <chr>    <chr>      <dbl> <chr> <chr>      <chr>      <chr>
#> 1 PHC-1224 Igoma HC 01/02/2024 74 Fema... Urban Primary Trader
#> 2 PHC-1169 Kisesa ... 2024-09-03 56 Fema... Urban Primary
Professio...
#> 3 PHC-1391 Bugando... 2024-11-26 54 Fema... Urban None Farmer
#> 4 PHC-0142 Ilemela... 2024-10-23 33 Fema... Urban Primary Farmer
#> 5 PHC-0112 Kisesa ... 2024-06-03 86 Male Urban Primary Unemployed
#> 6 PHC-0102 Igoma HC 2024-04-22 70 Male Urban Primary Trader
#> 7 PHC-1019 Nyamaga... 08/08/2024 45 Fema... Urban None Unemployed
#> 8 PHC-1431 Bugando... 18/02/2024 59 f Urban Primary Professio...
#> 9 PHC-0119 Bugando... 2024-01-12 46 Male Urban Primary Trader
#> 10 PHC-0397 Bugando... 2024-10-19 61 Fema... Rural None Trader
#> # i 1,493 more rows
#> # i 28 more variables: marital_status <chr>, health_insurance <chr>,
#> # height_cm <dbl>, weight_kg <dbl>, bmi <dbl>, smoking <chr>,
#> # alcohol <chr>, physical_activity <chr>, family_history_htn <chr>,
#> # diabetes <chr>, sbp_mmhg <dbl>, dbp_mmhg <dbl>, total_chol_mmol_l <dbl>,
#> # hdl_mmol_l <dbl>, ldl_mmol_l <dbl>, triglycerides_mmol_l <dbl>,
#> # fasting_glucose_mmol_l <dbl>, creatinine_umol_l <dbl>, ...
```

Dòng tiêu đề cho biết tibble có 1.503 dòng và 36 cột. Bên dưới mỗi tên cột là kiểu của cột đó, và phần chân liệt kê các cột không vừa màn hình. `head()` hiển thị một số dòng tùy chọn; để xem một vài cột cụ thể, ta có thể kết hợp nó với `select()`, hàm mà chúng ta sẽ tìm hiểu đầy đủ ở Mục 1.11:

```
head(select(htn, patient_id, facility, age, sex, sbp_mmhg, dbp_mmhg), 5)
```

R

```
#> # A tibble: 5 × 6
#>   patient_id facility age sex sbp_mmhg dbp_mmhg
#>   <chr>      <chr>   <dbl> <chr>   <dbl>   <dbl>
#> 1 PHC-1224 Igoma HC    74 Female    140     92
#> 2 PHC-1169 Kisesa HC    56 Female    185     91
#> 3 PHC-1391 Bugando PHC    54 Female    147     85
#> 4 PHC-0142 Ilemela HC    33 Female    124    102
#> 5 PHC-0112 Kisesa HC    86 Male      131     95
```

Trong RStudio, `view(htn)` mở dữ liệu trong một trình xem giống bảng tính, nơi bạn có thể cuộn, sắp xếp và lọc (mà không thay đổi dữ liệu). Nó hữu ích để duyệt dữ liệu nhưng, vì mang tính tương tác, nó không để lại bản ghi nào, vì vậy đừng dựa vào nó cho bất cứ việc gì bạn cần lặp lại.

1.10.3 Cấu trúc: `glimpse()` và `str()`

`glimpse()` (của `dplyr`) là cái nhìn tổng quan đơn lẻ giàu thông tin nhất. Nó liệt kê mỗi cột trên một dòng riêng, kèm kiểu và vài giá trị đầu tiên:

`glimpse(htn)`

R

```
#> Rows: 1,503
#> Columns: 36
#> $ patient_id      <chr> "PHC-1224", "PHC-1169", "PHC-1391", "PHC-01...
#> $ facility        <chr> "Igoma HC", "Kisesa HC", "Bugando PHC", "Il...
#> $ enroll_date     <chr> "01/02/2024", "2024-09-03", "2024-11-26", "...
#> $ age             <dbl> 74, 56, 54, 33, 86, 70, 45, 59, 46, 61, 70,...
#> $ sex            <chr> "Female", "Female", "Female", "Female", "Ma...
#> $ residence       <chr> "Urban", "Urban", "Urban", "Urban", "Urban"...
#> $ education       <chr> "Primary", "Primary", "None", "Primary", "P...
#> $ occupation      <chr> "Trader", "Professional", "Farmer", "Farmer...
#> $ marital_status  <chr> "Married", "Married", "Single", "Single", "...
#> $ health_insurance <chr> "Yes", "No", "No", "Yes", "0", "No", "No", ...
#> $ height_cm       <dbl> 164.6, 160.0, 152.8, 166.2, 182.0, 175.6, 1...
#> $ weight_kg       <dbl> 61.3, 68.3, 49.9, 78.5, 71.6, 97.4, 106.7, ...
#> $ bmi             <dbl> 22.6, 26.7, 21.4, 28.4, 21.6, 31.6, NA, 25....
#> $ smoking        <chr> "Former", "Current", "Never", "Never", "For...
#> $ alcohol         <chr> "None", "Moderate", "Moderate", "None", "He...
#> $ physical_activity <chr> "Low", "Low", "Moderate", "Low", "High", "M...
#> $ family_history_htn <chr> "Yes", "1", "1", "1", "0", "No", "No", "No"...
#> $ diabetes        <chr> "No", "No", "No", "No", "0", "No", "0", "No...
#> $ sbp_mmhg        <dbl> 140, 185, 147, 124, 131, 153, 162, 108, 152...
#> $ dbp_mmhg        <dbl> 92, 91, 85, 102, 95, 95, 100, 100, 87, 69, ...
#> $ total_chol_mmol_l <dbl> -99.0, 5.4, 5.4, 5.9, 4.8, 3.6, 5.3, 2.9, 6...
#> $ hdl_mmol_l      <dbl> 1.93, 0.70, 1.67, 0.65, 1.69, 1.20, 1.83, 1...
#> $ ldl_mmol_l      <dbl> 3.5, NA, 2.3, 4.1, 2.4, 1.4, 2.2, NA, 3.4, ...
#> $ triglycerides_mmol_l <dbl> 1.0, 2.1, 2.7, 1.7, 2.0, 1.3, 1.0, 1.5, 2.5...
#> $ fasting_glucose_mmol_l <dbl> 6.6, 5.5, 6.0, 5.2, 5.1, 5.8, 5.5, 4.1, 6.2...
#> $ creatinine_umol_l <dbl> 61, 66, 75, 86, 87, 72, 103, 57, 98, 76, 99...
#> $ sodium_mmol_l   <dbl> 134, 134, 139, 140, 142, 138, 141, 141, 140...
#> $ potassium_mmol_l <dbl> 4.1, 3.6, 4.4, 4.4, 4.2, 4.0, 4.5, 5.0, 4.7...
#> $ knowledge_score <dbl> 14, 7, 9, 12, NA, 12, 17, 8, 13, NA, 11, 6,...
#> $ distance_to_facility_km <dbl> 2.9, 10.5, 2.4, 2.2, 5.4, 6.7, 0.2, 0.4, 5....
#> $ comorbidity_count <dbl> 1, 0, 0, 0, 0, 1, 1, 0, 1, 1, 1, 1, 1, 0...
#> $ htn_diagnosed    <chr> "1", "Y", "Yes", "Yes", "Yes", "Yes", "Yes"...
```

```
#> $ months_since_diagnosis <dbl> 95, 87, 116, 31, 80, 28, 6, 96, 114, 53, 39...
#> $ treatment_uptake      <chr> "Yes", "No", "N", "Yes", "No", "No", "1", "...
#> $ adherence             <chr> "Poor", NA, NA, "Good", NA, NA, "Good", NA,...
#> $ bp_controlled         <chr> "No", NA, NA, "No", NA, NA, "No", NA, NA, "...
```

Hãy đọc kết quả này thật cẩn thận, từng cột một, với từ điển dữ liệu bên cạnh. Nó kể một câu chuyện:

- `patient_id`, `facility`, `sex`, `residence` và các biến nhân khẩu học khác có kiểu ký tự (`<chr>`), đúng như mong đợi đối với văn bản.
- `enroll_date` có kiểu ký tự, **không phải** ngày tháng. Các giá trị đầu tiên, "01/02/2024" và "2024-09-03", dùng các định dạng khác nhau, vì vậy `readr` không thể nhận ra một định dạng ngày duy nhất và giữ nguyên văn bản.
- Các số đo (`age`, `height_cm`, `weight_kg`, `bmi`, `sbp_mmhg`, các giá trị xét nghiệm) có kiểu số (`<dbl>`), điều này là đúng.
- `total_chol_mmol_l` bắt đầu bằng giá trị -99.0. Cholesterol âm là điều không thể: đây là một **mã giá trị khuyết** (một giá trị "canh gác", sentinel) được dùng trong quá trình nhập liệu, mà R đã coi là một con số thật.
- `health_insurance`, `family_history_htn`, `diabetes`, `htn_diagnosed` và `treatment_uptake` đáng lẽ là các biến Yes/No (có/không), nhưng ta thấy các giá trị như "1", "0" và "Y" lẫn với "Yes" và "No". Do sự pha trộn này, chúng được lưu ở kiểu ký tự.
- `adherence` và `bp_controlled` chứa NA ở những bệnh nhân không điều trị, vì với họ các biến kết cục này không được xác định.

Hàm `str()` ("structure", cấu trúc) của base R cho thông tin tương tự với cách trình bày hơi khác. Áp dụng cho toàn bộ một tibble thì kết quả rất dài dòng, vì vậy ở đây chúng tôi chỉ trình bày cho vài cột:

```
str(select(htn, age, sex, sbp_mmhg, treatment_uptake))
```

R

```
#> tibble [1,503 × 4] (S3: tbl_df/tbl/data.frame)
#> $ age          : num [1:1503] 74 56 54 33 86 70 45 59 46 61 ...
#> $ sex          : chr [1:1503] "Female" "Female" "Female" "Female" ...
#> $ sbp_mmhg     : num [1:1503] 140 185 147 124 131 153 162 108 152 127 ...
#> $ treatment_uptake: chr [1:1503] "Yes" "No" "N" "Yes" ...
```

1.10.4 Tóm tắt các biến số

`summary()` áp dụng cho một vectơ số cho ra bản tóm tắt sáu con số, kèm theo số giá trị khuyết nếu có. Đây là cách nhanh nhất để phát hiện các giá trị không thể có.

```
summary(htn$age)
```

R

```
#>   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#>   0.0   43.0   52.0   52.3   62.0   200.0
```

Tuổi trung vị là 52 tuổi và một nửa số bệnh nhân ở giữa có tuổi từ 43 đến 62, điều này hợp lý đối với người trưởng thành đến khám ở tuyến ban đầu. Nhưng giá trị nhỏ nhất là 0 và giá trị lớn nhất là 200. Không giá trị nào có thể có ở một người tham gia trưởng thành: đây là lỗi nhập liệu. Áp dụng `summary()` cho nhiều cột cùng lúc cho thấy thêm nhiều vấn đề:

```
summary(select(htn, sbp_mmhg, dbp_mmhg, weight_kg, height_cm))
```

```
#>      sbp_mmhg      dbp_mmhg      weight_kg      height_cm
#> Min.   : 0      Min.   : 5.0      Min.   : 7.0      Min.   : 17
#> 1st Qu.:126      1st Qu.: 79.0      1st Qu.: 60.9      1st Qu.:158
#> Median :139      Median : 86.0      Median : 70.1      Median :164
#> Mean   :140      Mean   : 85.9      Mean   : 70.9      Mean   :164
#> 3rd Qu.:153      3rd Qu.: 93.0      3rd Qu.: 80.3      3rd Qu.:169
#> Max.   :700      Max.   :121.0      Max.   :132.8      Max.   :193
#>                                     NAs      :45
```

Huyết áp tâm thu dao động từ 0 đến 700 mmHg, huyết áp tâm trương xuống tới 5 mmHg, cân nặng thấp nhất là 7 kg và chiều cao thấp nhất là 17 cm (có lẽ là 170 cm bị đặt sai dấu thập phân). `weight_kg` còn có 45 giá trị khuyết (NA's). Không giá trị nào trong số này qua được ánh mắt của một bác sĩ lâm sàng khi xem phiếu thu thập thông tin ca bệnh, thế nhưng chúng sẽ âm thầm làm sai lệch giá trị trung bình, độ lệch chuẩn và hệ số hồi quy nếu được phân tích nguyên trạng. Các mã "canh gác" cũng hiện rõ trong các biến xét nghiệm:

```
summary(htn$total_chol_mmol_l)
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
#> -99.00   4.30    5.10    2.59   5.80    8.30    55
```

```
summary(htn$fasting_glucose_mmol_l)
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
#>      3.0   4.8    5.4    32.5   6.1    999.0    35
```

Cholesterol toàn phần có giá trị nhỏ nhất là -99 và glucose lúc đói có giá trị lớn nhất là 999 mmol/L: đây là các mã cho "khuyết", không phải số đo.

1.10.5 Bảng tần số của các biến phân loại

Với các biến ký tự và factor, `table()` đếm từng giá trị khác nhau.

```
table(htn$sex)
```

```
#>
#>      f      F female Female      m      M      male      Male
#>     74     73     68    672     40     39     42     495
```

Đáng lẽ phải có hai nhóm; thực tế có tám. Cùng hai giới tính đã được gõ thành Female, female, F và f (nữ), và Male, male, M và m (nam). Vì R phân biệt chữ hoa, chữ thường và so sánh văn bản một cách chính xác, nó coi mỗi cách viết là một nhóm riêng biệt. Một bảng giới tính theo

việc sử dụng điều trị, hay một mô hình hồi quy hiệu chỉnh theo giới tính, sẽ vô nghĩa cho đến khi các cách viết này được chuẩn hóa.

```
table(htn$treatment_uptake, useNA = "ifany")
```

R

```
#>
#>    0    1    N No    Y Yes
#> 134   79   95 766   52 377
```

Biến kết cục chính được mã hóa theo sáu cách khác nhau: Yes, Y và 1 cho nhóm được điều trị, và No, N và 0 cho nhóm không được điều trị. Đối số `useNA = "ifany"` yêu cầu `table()` hiển thị số giá trị khuyết nếu có; theo mặc định `table()` lặng lẽ bỏ qua chúng, một cái bẫy mà chúng ta sẽ quay lại trong Chương 3. Ở đây không có giá trị khuyết nào, nên không có cột NA nào xuất hiện.

```
table(htn$facility)
```

R

```
#>
#>   Bugando PHC   Buzuruga PHC      Igoma HC      Ilemela HC      Kisesa HC
#>         337         175         175         283         228
#> Nyamagana PHC
#>         305
```

Sáu cơ sở y tế hiện ra gọn gàng, và Bugando PHC đóng góp nhiều bệnh nhân nhất. Tuy nhiên, từ điển dữ liệu cảnh báo rằng một số tên cơ sở có chứa khoảng trắng thừa ở đầu hoặc cuối. Chúng ta không thấy chúng vì `read_csv()` mặc định cắt bỏ khoảng trắng. Đọc lại tệp với `trim_ws = FALSE` sẽ làm lộ ra vấn đề:

```
htn_untrimmed <- read_csv("Data/hypertension_phc_raw.csv", trim_ws = FALSE)
table(htn_untrimmed$facility)
```

R

```
#>
#>   Bugando PHC   Buzuruga PHC      Igoma HC      Ilemela HC
#>         25         16         11         16
#>   Kisesa HC   Nyamagana PHC      Bugando PHC      Buzuruga PHC
#>         16         24         312         159
#>   Igoma HC      Ilemela HC      Kisesa HC      Nyamagana PHC
#>        164         267         212         281
```

```
# có bao nhiêu giá trị khác với phiên bản đã cắt khoảng trắng của chúng?
sum(htn_untrimmed$facility != str_trim(htn_untrimmed$facility))
```

R

```
#> [1] 108
```


Giờ đây mỗi cơ sở xuất hiện hai lần. Sáu số đếm đầu tiên thuộc về các phiên bản tên có khoảng trắng ở đầu và cuối (như " Igoma HC "), mà R xếp trước các chữ cái; sáu số đếm cuối là các phiên bản sạch. Tổng cộng có 108 giá trị mang khoảng trắng vô hình. Nếu không cắt khoảng trắng, mọi bảng theo cơ sở y tế sẽ hiện mười hai cơ sở thay vì sáu. Các phần mềm khác, và một số hàm nhập dữ liệu của R, không tự động cắt khoảng trắng, vì vậy thật yên tâm khi biết `readr` đang làm gì thay cho bạn, và điều quan trọng là phải kiểm tra thay vì giả định.

1.10.6 Hình đầu tiên

Các con số trong một bản tóm tắt dễ nắm bắt hơn khi được vẽ thành đồ thị. Biểu đồ tần suất (histogram) của tuổi cho thấy toàn bộ phân phối cùng một lúc. Chúng ta dùng **ggplot2**, gói sẽ được giới thiệu đầy đủ trong Chương 3; tạm thời, hãy đọc đoạn mã như sau: "lấy dữ liệu htn, đặt age lên trục x, và vẽ một biểu đồ tần suất".

```
ggplot(htn, aes(x = age)) +  
  geom_histogram(binwidth = 5, fill = "#1F6F8B", colour = "white") +  
  labs(title = "Tuổi của người tham gia, dữ liệu thô",  
        x = "Tuổi (năm)", y = "Số bệnh nhân")
```

Tuổi của người tham gia, dữ liệu thô



Hình 1.1: Biểu đồ tần suất của tuổi được ghi nhận trong dữ liệu thô của nghiên cứu tình huống (n = 1.503). Hầu hết bệnh nhân có tuổi từ 18 đến 95, nhưng hai giá trị không thể có, ở mức 0 và 200 tuổi, nổi bật tách riêng.


Phần lớn phân phối là một "bướu" duy nhất nằm giữa 18 và 95 tuổi, có tâm ở khoảng đầu tuổi năm mươi và tương đối đối xứng. Những cột nhỏ xíu tách biệt ở mức 0 và 200 là các giá trị không thể có đã được `summary()` phát hiện; mỗi cột chỉ là một bệnh nhân, vì vậy chúng hầu như không nhô lên khỏi trục. Biểu đồ tần suất khiến những giá trị ngoại lai như vậy không thể bị bỏ sót, và đó là lý do vẽ đồ thị dữ liệu là một bước thiết yếu của mọi lần kiểm tra chất lượng dữ liệu.

Biểu đồ cột làm cùng nhiệm vụ đó cho một biến phân loại. Ở đây chúng ta hiển thị số bệnh nhân được tuyển chọn tại mỗi cơ sở y tế, sắp xếp từ lớn nhất đến nhỏ nhất:

```
htn |>  
  count(facility) |>  
  ggplot(aes(x = n, y = fct_reorder(facility, n))) +  
  geom_col(fill = "#1F6F8B") +  
  geom_text(aes(label = n), hjust = -0.2, size = 3.5) +  
  labs(title = "Số bản ghi theo cơ sở y tế",  
        x = "Số bản ghi", y = NULL) +  
  expand_limits(x = 380)
```

Quy mô các cơ sở chênh lệch nhau gần gấp đôi, từ 175 bản ghi tại Buzuruga PHC và Igoma HC

Số bản ghi theo cơ sở y tế



Hình 1.2: Số bản ghi theo từng cơ sở chăm sóc sức khỏe ban đầu trong dữ liệu thô của nghiên cứu tình huống. Bugando PHC và Nyamagana PHC đóng góp nhiều người tham gia nhất; Buzuruga PHC và Igoma HC ít nhất.

đến 337 bản ghi tại Bugando PHC. Trong một nghiên cứu đa trung tâm, điều này đáng được lưu ý: các cơ sở lớn hơn sẽ chi phối các ước lượng gộp, và bệnh nhân đến khám tại cùng một cơ sở có thể giống nhau hơn so với bệnh nhân từ các cơ sở khác nhau.

1.10.7 Tổng kết: những vấn đề đã lộ rõ

Không cần tính một thống kê nào, lần kiểm tra đầu tiên đã phát hiện phần lớn các vấn đề chất lượng dữ liệu được ghi trong từ điển dữ liệu. Bảng dưới đây tập hợp chúng lại. Quyết định cách xử lý từng vấn đề là chủ đề của Chương 2.

```
problems <- tibble(
  Problem = c("Bản ghi trùng lặp", "Giá trị không hợp lý",
    "Mã giá trị khuyết", "Cách viết không nhất quán",
    "Mã nhị phân pha trộn", "Định dạng ngày pha trộn",
    "Khoảng trắng thừa"),
  Evidence = c("1.503 dòng cho 1.500 bệnh nhân",
    "tuổi 0 và 200; SBP 0 và 700; cân nặng 7 kg",
    "cholesterol -99; glucose 999",
    "sex: Female/female/F/f, Male/male/M/m",
    "treatment_uptake: Yes/Y/1, No/N/0",
    "enroll_date: 01/02/2024 và 2024-09-03",
    "tên cơ sở có khoảng trắng ở đầu/cuối")
)
knitr::kable(problems, col.names = c("Vấn đề", "Bảng chứng"),
  caption = "Các vấn đề dữ liệu phát hiện qua lần kiểm tra đầu tiên.")
```

Bảng 1.7: Các vấn đề dữ liệu phát hiện qua lần kiểm tra đầu tiên.

Vấn đề	Bằng chứng
Bản ghi trùng lặp	1.503 dòng cho 1.500 bệnh nhân
Giá trị không hợp lý	tuổi 0 và 200; SBP 0 và 700; cân nặng 7 kg
Mã giá trị khuyết	cholesterol -99; glucose 999
Cách viết không nhất quán	sex: Female/female/F/f, Male/male/M/m
Mã nhị phân pha trộn	treatment_uptake: Yes/Y/1, No/N/0
Định dạng ngày pha trộn	enroll_date: 01/02/2024 và 2024-09-03
Khoảng trắng thừa	tên cơ sở có khoảng trắng ở đầu/cuối

Diễn giải lâm sàng

Mỗi vấn đề trong số này đều sẽ làm thay đổi một kết luận lâm sàng nếu bị bỏ mặc. Một SBP 700 mmHg làm tăng giả tạo huyết áp trung bình; một giá trị cholesterol -99 mmol/L kéo trung bình cholesterol xuống; ba bệnh nhân bị trùng lặp được đếm hai lần; và tám cách viết giới tính khiến "tỷ lệ phụ nữ đang điều trị" thậm chí không thể tính được. Vì vậy, lần kiểm tra đầu tiên không phải là việc dọn dẹp tùy chọn: nó là một phần của phương pháp khoa học, và những phát hiện của nó cần được ghi lại trong script phân tích.

1.11 Toán tử pipe và làm quen với dplyr

1.11.1 Toán tử pipe |>

Phân tích dữ liệu là một chuỗi các bước: lấy dữ liệu, giữ lại một số dòng, giữ lại một số cột, tính toán điều gì đó, sắp xếp kết quả. Khi được viết dưới dạng các lời gọi hàm lồng nhau, các bước phải được đọc từ trong ra ngoài, ngược với thứ tự chúng diễn ra:

```
head(arrange(select(htn, patient_id, age), desc(age)), 3)
```

R

```
#> # A tibble: 3 × 2
#>   patient_id age
#>   <chr>     <dbl>
#> 1 PHC-0174   200
#> 2 PHC-0144    95
#> 3 PHC-1062    92
```

Toán tử **pipe** |> (có sẵn trong R từ phiên bản 4.1) chuyển kết quả ở bên trái nó thành đối số thứ nhất của hàm ở bên phải. Cùng phép tính đó trở thành một "công thức nấu ăn" dễ đọc, đọc từ trên xuống dưới, với |> được hiểu là "rồi thì":

```
htn |>
  select(patient_id, age) |>
  arrange(desc(age)) |>
  head(3)
```

R

```
#> # A tibble: 3 × 2
#>   patient_id age
```

```
#>   <chr>      <dbl>
#> 1 PHC-0174    200
#> 2 PHC-0144     95
#> 3 PHC-1062     92
```

"Lấy htn, rồi chọn mã bệnh nhân và tuổi, rồi sắp xếp theo tuổi giảm dần, rồi hiển thị ba dòng đầu tiên." Kết quả xác định được bệnh nhân duy nhất được ghi nhận 200 tuổi (PHC-0174), tiếp theo là hai bệnh nhân thực sự cao tuổi nhưng hợp lý, 95 và 92 tuổi: đây là cách bạn tìm ra chính xác những bản ghi nào cần được gửi thắc mắc về điểm nghiên cứu. Trong RStudio, phím tắt `Ctrl+Shift+M` (`Cmd+Shift+M` trên macOS) sẽ gỡ toán tử pipe. Bạn cũng sẽ thấy toán tử pipe cũ hơn `%>%` của gói **magrittr** trong nhiều sách và câu trả lời trực tuyến; trong sử dụng hằng ngày, hai toán tử này có thể thay thế cho nhau.

1.11.2 Năm "động từ" thiết yếu của dplyr

Gói **dplyr** cung cấp một nhóm nhỏ các hàm, thường được gọi là *động từ* (verbs), mỗi hàm làm một việc với một khung dữ liệu. Mọi động từ đều nhận một khung dữ liệu làm đối số thứ nhất và trả về một khung dữ liệu mới, điều này giúp chúng dễ dàng được nối với nhau bằng pipe (Wickham et al. 2023). Tên cột được viết không có dấu nháy.

Bảng 1.8: Năm động từ của dplyr được giới thiệu trong chương này.

Động từ	Công dụng	Ví dụ
<code>select()</code>	Giữ lại (hoặc bỏ đi) các cột	<code>select(htn, age, sex)</code>
<code>filter()</code>	Giữ lại các dòng thỏa mãn một điều kiện	<code>filter(htn, age >= 60)</code>
<code>arrange()</code>	Sắp xếp các dòng	<code>arrange(htn, desc(sbp_mmhg))</code>
<code>mutate()</code>	Tạo mới hoặc sửa đổi cột	<code>mutate(htn, pp = sbp_mmhg - dbp_mmhg)</code>
<code>count()</code>	Đếm số dòng theo từng nhóm	<code>count(htn, facility)</code>

`select()` giữ lại các cột được nêu tên. Một dấu trừ sẽ bỏ một cột, và các hàm hỗ trợ chọn cột theo mẫu tên:

```
htn |>
  select(patient_id, ends_with("_mmhg")) |>
  head(3)
```

```
#> # A tibble: 3 × 3
#>   patient_id sbp_mmhg dbp_mmhg
#>   <chr>      <dbl>    <dbl>
#> 1 PHC-1224    140      92
#> 2 PHC-1169    185      91
#> 3 PHC-1391    147      85
```

`filter()` giữ lại các dòng mà điều kiện là TRUE. Điều kiện dùng các toán tử so sánh và toán tử logic ở Mục 1.5; nhiều điều kiện phân cách bằng dấu phẩy thì tất cả đều phải đúng.

```
htn |>
  filter(facility == "Kisesa HC", age >= 70) |>
  select(patient_id, facility, age, sbp_mmhg) |>
  head(4)
```

```
#> # A tibble: 4 × 4
#>   patient_id facility age sbp_mmhg
#>   <chr>      <chr>   <dbl>   <dbl>
#> 1 PHC-0112   Kisesa HC      86     131
#> 2 PHC-0035   Kisesa HC      81     174
#> 3 PHC-0379   Kisesa HC      72     135
#> 4 PHC-0737   Kisesa HC      80     154
```

Cùng ý tưởng đó giúp tìm ra các giá trị huyết áp không hợp lý mà ta đã thấy trong bản tóm tắt:

```
htn |>
  filter(sbp_mmhg < 60 | sbp_mmhg > 260) |>
  select(patient_id, facility, sbp_mmhg, dbp_mmhg)
```

```
#> # A tibble: 2 × 4
#>   patient_id facility sbp_mmhg dbp_mmhg
#>   <chr>      <chr>   <dbl>   <dbl>
#> 1 PHC-0768   Bugando PHC      0      73
#> 2 PHC-0360   Bugando PHC     700     81
```

Hai bản ghi, đều từ Bugando PHC, có huyết áp tâm thu là 0 và 700 mmHg, những giá trị không tương thích với sự sống; huyết áp tâm trương của họ (73 và 81 mmHg) trông bình thường, gợi ý rằng lỗi gõ phím chỉ xảy ra ở trường huyết áp tâm thu. Lưu ý rằng `filter()` loại bỏ cả những dòng có điều kiện là NA lẫn những dòng có điều kiện là FALSE.

`arrange()` sắp xếp các dòng, theo thứ tự tăng dần theo mặc định hoặc giảm dần với `desc()`. Chúng ta đã dùng nó ở trên để tìm những tuổi cao nhất được ghi nhận.

`mutate()` thêm các cột mới được tính từ các cột hiện có. Ở đây chúng ta tính huyết áp động mạch trung bình cho mọi bệnh nhân cùng một lúc, dùng cùng công thức như ở Mục 1.2:

```
htn |>
  mutate(map_mmhg = dbp_mmhg + (sbp_mmhg - dbp_mmhg) / 3,
         map_mmhg = round(map_mmhg, 1)) |>
  select(patient_id, sbp_mmhg, dbp_mmhg, map_mmhg) |>
  head(5)
```

```
#> # A tibble: 5 × 4
#>   patient_id sbp_mmhg dbp_mmhg map_mmhg
#>   <chr>      <dbl>   <dbl>   <dbl>
#> 1 PHC-1224    140     92    108
#> 2 PHC-1169    185     91   122.3
#> 3 PHC-1391    147     85   105.7
#> 4 PHC-0142    124    102   109.3
#> 5 PHC-0112    131     95    107
```

Công thức từng được viết cho một bệnh nhân giờ chạy trên cả 1.503 dòng. Lưu ý rằng `mutate()` không thay đổi chính `htn`: cột mới chỉ tồn tại trong kết quả được in ra. Để giữ nó, hãy gán kết quả cho một đối tượng (ví dụ, `htn <- htn |> mutate(...)`). Đây là một nguyên tắc chung: các động từ của `dplyr` không bao giờ sửa đổi trực tiếp đầu vào của chúng.

`count()` lập bảng các giá trị của một hoặc nhiều biến và trả về một tibble, khác với kết quả của `table()`, có thể tiếp tục được chuyển qua pipe:

```
htn |>
  count(residence, sort = TRUE)
```

```
#> # A tibble: 2 × 2
#>   residence      n
#>   <chr>      <int>
#> 1 Urban        799
#> 2 Rural        704
```

Số bệnh nhân sống ở thành thị (799) nhỉnh hơn một chút so với nông thôn (704) (các giá trị "Urban" và "Rural"); `sort = TRUE` liệt kê nhóm có tần số cao nhất trước. Đếm theo hai biến cho ra một bảng chéo ở dạng dài:

```
htn |>
  count(facility, residence) |>
  head(6)
```

```
#> # A tibble: 6 × 3
#>   facility      residence      n
#>   <chr>      <chr>      <int>
#> 1 Bugando PHC Rural        147
#> 2 Bugando PHC Urban        190
#> 3 Buzuruga PHC Rural         75
#> 4 Buzuruga PHC Urban        100
#> 5 Igoma HC    Rural         92
#> 6 Igoma HC    Urban         83
```

Chúng ta sẽ dùng các động từ này, cùng với `summarise()` và `group_by()`, xuyên suốt phần còn lại của cuốn sách.

Mẹo

Hãy xây dựng một chuỗi pipe từng bước một. Chạy dòng đầu tiên, kiểm tra kết quả, thêm động từ tiếp theo, chạy lại. Khi một chuỗi pipe dài cho ra câu trả lời bất ngờ, hãy xóa dần các bước từ cuối lên cho đến khi kết quả trở lại hợp lý; vấn đề nằm ở bước bạn vừa xóa.

1.12 Viết một script có thể tái lập

1.12.1 Lưu và tổ chức script

Lưu script bằng *File > Save* (Ctrl+S hoặc Cmd+S) vào thư mục *Scripts/* của dự án, với một cái tên cho biết script làm gì, như `01_import_and_inspect.R`. Đánh số các script theo thứ tự cần chạy giúp một phân tích nhiều bước dễ theo dõi. Hãy lưu thường xuyên; RStudio hiển thị tên tệp màu đỏ kèm dấu hoa thị khi còn những thay đổi chưa được lưu.

1.12.2 Chú thích

Chú thích giải thích *tại sao* mã làm điều nó làm; bản thân mã cho thấy nó làm *gì*. Chú thích tốt ghi lại các quyết định ("loại SBP > 260 mmHg vì không hợp lý về sinh lý, theo mục 8.2 của đề cương"), nguồn gốc của một công thức, và bất cứ điều gì mà người đọc nếu không có chú thích

sẽ phải đoán. Các tiêu đề mục được tạo từ các dòng chú thích, như # 2. Import data ----, được RStudio nhận diện và xuất hiện trong mục lục tài liệu (nút ở góc trên bên phải của trình soạn thảo script), giúp dễ dàng di chuyển trong những script dài.

1.12.3 Mẫu cho một script phân tích

Mọi script phân tích trong cuốn sách này đều theo cùng một bộ khung: phần đầu cho biết script dùng để làm gì, ai viết và viết khi nào; các gói; dữ liệu; phân tích; và, khi cần, lưu kết quả đầu ra. Dưới đây là một script hoàn chỉnh cho công việc của chương này. Vì script không ghi gì ra ổ đĩa, bạn có thể chạy nó bao nhiêu lần tùy thích một cách an toàn.

```
# =====
# Dự án:      Các yếu tố quyết định việc sử dụng điều trị tăng huyết áp
# Script:     01_import_and_inspect.R
# Mục đích:   Nhập dữ liệu thô và kiểm tra dữ liệu lần đầu
# Tác giả:    <tên của bạn>          Ngày: <ngày>
# Đầu vào:    Data/hypertension_phc_raw.csv
# Đầu ra:     không có (chỉ kiểm tra)
# =====
```

```
# 1. Các gói ----
library(tidyverse)
```

```
# 2. Nhập dữ liệu ----
htn <- read_csv("Data/hypertension_phc_raw.csv")
```

```
# 3. Kiểm tra ----
dim(htn)                                # kỳ vọng 1.500 bệnh nhân
```

```
#> [1] 1503   36
```

```
n_distinct(htn$patient_id)              # số bệnh nhân duy nhất
```

```
#> [1] 1500
```

```
summary(htn$age)                        # kiểm tra khoảng giá trị
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#>      0.0   43.0   52.0   52.3   62.0   200.0
```

```
sum(htn$sbp_mmhg > 260 | htn$sbp_mmhg < 60, na.rm = TRUE) # SBP không hợp lý
```

```
#> [1] 2
```

```
# 4. Ghi chú cho bước làm sạch (Chương 2) ----
# - 1.503 dòng nhưng 1.500 mã duy nhất: loại bỏ 3 bản ghi trùng lặp
# - tuổi 0 và 200; SBP 0 và 700: đặt thành giá trị khuyết
```

Kết quả xác nhận các phát hiện của chương này chỉ trong bốn dòng: 1.503 dòng nhưng chỉ có

1.500 mã bệnh nhân khác nhau (hàm `n_distinct()` đếm số giá trị duy nhất), tuổi trải từ 0 đến 200, và hai giá trị huyết áp tâm thu nằm ngoài khoảng hợp lý.

Khi một phân tích có ghi tệp, chẳng hạn một bộ dữ liệu đã làm sạch hoặc một hình, đoạn mã lưu chúng nên đặt ở cuối script. Ví dụ (được trình bày nhưng không chạy ở đây, để không có gì bị ghi vào dự án):

```
write_csv(htn, "Outputs/htn_inspected.csv") # lưu một khung dữ liệu thành CSV
ggsave("Outputs/age_histogram.png", width = 7, height = 4.3) # lưu hình vừa vẽ
```

R

Thực hành tốt

Một phép thử nhanh về khả năng tái lập: khởi động lại R (`Ctrl+Shift+F10`), rồi chạy toàn bộ script từ đầu (`Ctrl+Shift+Enter`). Nếu script chạy không lỗi và cho cùng kết quả, nó là một script độc lập, tự đủ. Nếu thất bại, nó đã phụ thuộc vào điều gì đó bạn làm bằng tay hoặc vào một đối tượng còn sót lại trong bộ nhớ. Hãy biến phép thử này thành thói quen trước khi chia sẻ bất kỳ kết quả nào. Với các báo cáo kết hợp văn bản, mã và kết quả trong một tài liệu, R Markdown và phiên bản kế nhiệm của nó là Quarto đưa khả năng tái lập tiến thêm một bước (Xie 2015).

1.13 Tóm tắt

Chương này đã giới thiệu các công cụ và thói quen mà phần còn lại của cuốn sách dựa vào. R là một ngôn ngữ miễn phí dành cho tính toán thống kê, và RStudio là môi trường mà chúng ta dùng để làm việc với nó. Viết phân tích dưới dạng script, thay vì gõ trong console hay nhấp chuột vào menu, giúp mọi kết quả đều có thể truy ngược về dữ liệu và mã lệnh đã tạo ra nó, và đó là cốt lõi của nghiên cứu có thể tái lập.

Đầu tiên chúng ta dùng R như một máy tính, chú ý đến thứ tự ưu tiên của toán tử, và tính BMI cùng huyết áp động mạch trung bình. Chúng ta lưu giá trị vào đối tượng bằng `<-`, làm quen với các kiểu dữ liệu chính và thấy rằng lỗi về kiểu, đặc biệt là số được lưu dưới dạng văn bản và việc âm thầm ép kiểu thành NA, là nguồn gốc phổ biến của những sai sót ẩn. Vector chứa nhiều giá trị cùng một kiểu; có thể truy xuất phần tử của chúng theo vị trí hoặc theo điều kiện logic, và phép tính số học trên vector được vector hóa. Giá trị khuyết (NA) lan truyền qua các phép tính trừ khi được loại bỏ có chủ ý bằng `na.rm = TRUE`. Hàm nhận đối số theo vị trí hoặc theo tên, và các trang trợ giúp cùng thông báo lỗi của chúng tồn tại để được đọc. Gợi mở rộng khả năng của R; chúng được cài đặt một lần và nạp trong mỗi phiên làm việc, và tidyverse cung cấp một bộ công cụ nhất quán cho phần lớn công việc của chúng ta. RStudio Project và đường dẫn tương đối giúp bản phân tích có tính di động.

Cuối cùng, chúng ta đã nhập dữ liệu thô của nghiên cứu tình huống từ cả tệp CSV lẫn tệp Excel và kiểm tra nó bằng `dim()`, `glimpse()`, `summary()`, `table()` và hai hình nhanh. Ngay cả cái nhìn đầu tiên này cũng đã phát hiện các bản ghi trùng lặp, giá trị không thể có, mã giá trị khuyết, cách viết không nhất quán, mã hóa pha trộn, định dạng ngày pha trộn và khoảng trắng thừa. Chương 2 sẽ hướng dẫn cách khắc phục tất cả những vấn đề này theo cách được ghi chép đầy đủ và có thể tái lập.

Điểm chính

- Viết mã phân tích trong một script đã lưu, có chú thích, nằm trong một RStudio Project; chỉ dùng console để khám phá.
- Dùng `<-` để gán và `==` để so sánh; nhớ rằng R phân biệt chữ hoa với chữ thường và văn bản cần có dấu nháy.
- Mọi giá trị đều có một kiểu. Kiểm tra kiểu bằng `class()` hoặc `glimpse()`; số được lưu dưới dạng văn bản và việc âm thầm ép kiểu thành NA là những lỗi ẩn thường gặp.
- Vectơ chứa các giá trị cùng một kiểu; phép toán trên vectơ được vectơ hóa; `sum()` và `mean()` của một vectơ logic cho ra số đếm và tỷ lệ.
- NA đánh dấu một giá trị khuyết và lan truyền qua các phép tính; hãy dùng `na.rm = TRUE` một cách có chủ ý và luôn báo cáo số giá trị bị khuyết.
- Cài đặt gói một lần bằng `install.packages()`; nạp gói bằng `library()` ở đầu mỗi script.
- Dùng đường dẫn tương đối trong một Project; không bao giờ dùng `setwd()` với một đường dẫn tuyệt đối.
- Nhập dữ liệu bằng `read_csv()` hoặc `read_excel()`, sau đó luôn kiểm tra bằng `dim()`, `glimpse()`, `summary()` và `table()` trước khi phân tích.
- Toán tử pipe `|>` nối các bước thành một công thức dễ đọc; `select()`, `filter()`, `arrange()`, `mutate()` và `count()` đáp ứng phần lớn công việc xử lý dữ liệu hằng ngày.

1.14 Đọc thêm

- Wickham et al. (2023), *R for Data Science* (ấn bản thứ 2, miễn phí trực tuyến): tài liệu nhập môn tiêu chuẩn về tidyverse; các chương về quy trình làm việc, nhập dữ liệu và biến đổi dữ liệu mở rộng mọi nội dung trong chương này.
- Wilson et al. (2017), "Good enough practices in scientific computing": những lời khuyên ngắn gọn, thiết thực về cách tổ chức dự án, dữ liệu và mã lệnh mà mọi nhà nghiên cứu có thể áp dụng ngay.
- Broman and Woo (2018), "Data organization in spreadsheets": cách thiết lập bảng tính thu thập dữ liệu để có thể nhập và phân tích mà không gặp những vấn đề đã thấy trong chương này.
- Peng (2011), "Reproducible research in computational science": một lập luận dài hai trang về lý do mã lệnh và dữ liệu cần đi kèm các kết quả được công bố.
- Wickham et al. (2019), "Welcome to the tidyverse": tổng quan ngắn gọn về thiết kế và các thành phần của tidyverse.

1.15 Bài tập

Bài tập 1.1

R như một máy tính. Một bệnh nhân nặng 82 kg, cao 168 cm và có huyết áp 148/96 mmHg.

1. Lưu bốn số đo này vào các đối tượng có tên hợp lý.
2. Dùng chúng để tính BMI và huyết áp động mạch trung bình của bệnh nhân, mỗi giá trị làm tròn đến một chữ số thập phân.
3. Điều gì xảy ra nếu bạn quên dấu ngoặc khi đổi chiều cao sang mét? Giải thích kết quả dựa trên thứ tự ưu tiên của toán tử.

Bài tập 1.2

Vectơ và phép so sánh logic. Huyết áp tâm trương của tám bệnh nhân khám trong một buổi sáng tại phòng khám là 88, 92, 79, 101, 95, NA, 84 và 90 mmHg.

1. Lưu chúng vào một vectơ `dbp` và tìm độ dài của vectơ.
2. Tính trung bình khi có và không có `na.rm = TRUE`, và giải thích sự khác biệt.
3. Có bao nhiêu lần đo đạt ít nhất 90 mmHg, và con số đó chiếm tỷ lệ bao nhiêu trong số các lần đo *quan sát được*?
4. Lấy ra các lần đo từ thứ ba đến thứ năm, sau đó lấy tất cả các lần đo trừ giá trị bị khuyết.

Bài tập 1.3

Kiểu dữ liệu và ép kiểu. Xét vectơ `glucose <- c("5.4", "6.1", "<2.0", "7.3", "999", "4.8")`, giống như khi nó được xuất ra từ một hệ thống phòng xét nghiệm.

1. Class của nó là gì, và tại sao?
2. Chuyển nó sang kiểu số bằng `as.numeric()`. Những giá trị nào trở thành NA, và tại sao?
3. Giá trị nào còn lại gần như chắc chắn không phải là một số đo thật? Điều gì sẽ xảy ra với giá trị trung bình nếu để nguyên giá trị đó?

Bài tập 1.4

Nhập dữ liệu. Nạp tidyverse và readxl. Nhập `Data/hypertension_phc_raw.csv` vào một đối tượng `htn` và trang tính data của `Data/hypertension_phc_raw.xlsx` vào `htn_xl`.

1. Mỗi đối tượng có bao nhiêu dòng và cột? Bạn kỳ vọng có bao nhiêu dòng, và vì sao chúng khác nhau?
2. Xác nhận rằng hai đối tượng có cùng tên cột.
3. Dùng `n_distinct()` để đếm số giá trị duy nhất của `patient_id`.

Bài tập 1.5

Kiểm tra cấu trúc. Dùng `glimpse(htn)` để trả lời các câu hỏi sau.

1. Liệt kê ba biến được lưu ở kiểu số và ba biến được lưu ở kiểu ký tự.
2. Kể tên hai biến được lưu ở kiểu ký tự nhưng sau khi làm sạch nên là factor Yes/No. Những giá trị nào trong đó khiến R không thể xử lý chúng đơn giản hơn?
3. Tại sao `enroll_date` không được lưu ở kiểu ngày tháng?

Bài tập 1.6

Phát hiện vấn đề dữ liệu. Dùng `summary()` và `table()` trên dữ liệu thô.

1. Báo cáo giá trị nhỏ nhất và lớn nhất của `sbp_mmhg`, `dbp_mmhg` và `height_cm`. Những giá trị nào không hợp lý?
2. Lập bảng tần số của `diabetes` và của `htn_diagnosed`. Mỗi biến dùng bao nhiêu mã khác nhau?
3. Có bao nhiêu giá trị của `weight_kg` bị khuyết?

Bài tập 1.7

Sử dụng pipe và dplyr. Bắt đầu từ `htn`, hãy viết một chuỗi pipe giữ lại các bệnh nhân ở Nyamagana PHC, tạo một cột `map_mmhg` chứa huyết áp động mạch trung bình làm tròn đến một chữ số thập phân, giữ lại `patient_id`, `age`, `sbp_mmhg`, `dbp_mmhg` và `map_mmhg`, và sắp xếp kết quả từ MAP cao nhất đến thấp nhất. Hiển thị năm dòng đầu tiên. Các giá trị cao nhất có hợp lý không? Sau đó dùng `count()` để cho biết tại mỗi cơ sở có bao nhiêu bệnh nhân được ghi nhận mắc đái tháo đường với mã chính xác là "Yes".

Bài tập 1.8

Thử thách: hình đầu tiên. Vẽ biểu đồ tần suất của huyết áp tâm thu cho dữ liệu thô, dùng `ggplot()` và `geom_histogram()` như ở Mục 1.10. Sau đó vẽ biểu đồ tần suất thứ hai sau khi chỉ giữ lại các giá trị từ 60 đến 260 mmHg bằng `filter()`. Có bao nhiêu bản ghi bị loại bỏ, và hình dạng phân phối thay đổi như thế nào? Viết hai câu mô tả phân phối của các giá trị hợp lý.

CHƯƠNG 2

Tìm hiểu và làm sạch dữ liệu lâm sàng

Một bộ dữ liệu lâm sàng vừa được chuyển đến bàn làm việc của bạn. Số cột đúng như mong đợi, tên biến trông hợp lý và vài dòng đầu tiên có vẻ ổn. Bạn rất dễ bị cám dỗ đi thẳng vào phần thú vị: bảng đặc điểm ban đầu của đối tượng nghiên cứu, so sánh bệnh nhân có điều trị và không điều trị, mô hình hồi quy. Hãy cưỡng lại cám dỗ đó. Đầu đó trong 1.500 dòng kia có một giá trị huyết áp tâm thu 700 mmHg, một bệnh nhân 200 tuổi, một người trưởng thành có cân nặng được ghi là 7 kg, tình trạng đái tháo đường được mã hóa theo sáu cách khác nhau và ba bệnh nhân xuất hiện hai lần. Không vấn đề nào trong số này ngăn được R tính ra một giá trị trung bình, một giá trị p hay một tỷ số chênh. Nhưng tất cả chúng đều sẽ làm cho những con số đó sai. Chương này nói về việc tìm ra những vấn đề như vậy một cách có hệ thống, quyết định cách xử lý từng vấn đề, và ghi lại các quyết định đó dưới dạng mã R, để hành trình từ tệp thô đến dữ liệu sẵn sàng phân tích được minh bạch và có thể được bất kỳ ai lặp lại, vào bất kỳ lúc nào, với đúng cùng một kết quả. Bộ dữ liệu sạch được tạo ra ở đây, `analysis_data`, là điểm xuất phát cho mọi chương còn lại của cuốn sách.

Mục tiêu học tập

- Giải thích vì sao làm sạch dữ liệu (data cleaning) là một bước khoa học phải được viết thành script, được ghi chép và có thể tái lập, đồng thời mô tả "hợp đồng làm sạch" giữa dữ liệu thô và dữ liệu sẵn sàng phân tích.
- Áp dụng các nguyên tắc của dữ liệu gọn gàng (tidy data) và phân loại các biến lâm sàng thành liên tục, rời rạc, danh định, thứ bậc, nhị phân hoặc ngày tháng, chọn cách biểu diễn phù hợp trong R cho từng loại.
- Nhập một tệp thô đồng thời khai báo tường minh các mã giá trị khuyết, và chứng minh các mã không được khai báo như -99 và 999 làm sai lệch thống kê tóm tắt như thế nào.
- Phân biệt dữ liệu khuyết hoàn toàn ngẫu nhiên, khuyết ngẫu nhiên và khuyết không ngẫu nhiên, giải thích vì sao phân tích trên các trường hợp đầy đủ có thể bị sai lệch, và tạo một bảng cùng một hình kiểm kê dữ liệu khuyết.
- Phát hiện, kiểm tra, loại bỏ và báo cáo các bản ghi trùng lặp.
- Chuẩn hóa các danh mục không nhất quán và khoảng trắng thừa bằng `str_trim()`, `str_to_lower()` và `case_when()`, đồng thời viết một hàm trợ giúp có thể dùng lại cho các biến Yes/No (có/không).
- Kiểm định các phép đo liên tục theo khoảng giá trị sinh lý hợp lý, chuyển các giá trị

không thể xảy ra thành giá trị khuyết và đếm những gì đã thay đổi.

- Tạo biến chỉ số khối cơ thể và các phân loại lâm sàng của BMI và huyết áp, rồi đối chiếu các biến dẫn xuất với định nghĩa của chúng.
- Phân tích cú pháp (parse) các ngày tháng được ghi theo nhiều định dạng khác nhau bằng `lubridate`.
- Chuyển các biến phân loại thành factor với thứ tự mức và nhóm tham chiếu được chọn có chủ đích, lưu dữ liệu sạch và kiểm tra rằng quy trình làm sạch có thể tái lập.

2.1 Vì sao làm sạch dữ liệu lại quan trọng

2.1.1 Rác vào, rác ra

Các phương pháp thống kê nhận các con số như chúng vốn có. Một kiểm định t không biết rằng huyết áp tâm thu 700 mmHg là điều không thể về mặt sinh lý; một mô hình hồi quy logistic không biết rằng "Y", "yes" và "1" có cùng một nghĩa; một bảng tần số không biết rằng hai dòng mô tả cùng một bệnh nhân. Mọi phương pháp trong cuốn sách này đều giả định rằng dữ liệu trước mặt nó là bản ghi trung thực của những gì đã được đo. Khi giả định đó không đúng, phân tích thất bại một cách âm thầm: phần mềm vẫn cho ra kết quả trông có vẻ đáng tin cậy y như kết quả từ dữ liệu sạch. Đây là nguyên tắc lâu đời của ngành tin học, *rác vào, rác ra* (garbage in, garbage out), và trong nghiên cứu lâm sàng hậu quả của nó không chỉ dừng lại ở sự ngưng ngừng. Một giá trị huyết áp trung bình bị đội lên do lỗi nhập liệu có thể làm thay đổi tỷ lệ hiện mắc biểu kiến của tăng huyết áp không được kiểm soát; một phơi nhiễm bị phân loại sai có thể che giấu một mối liên quan có thật hoặc tạo ra một mối liên quan giả; một bệnh nhân bị nhân đôi có thể làm cho một biến cố bất lợi hiếm gặp trông phổ biến gấp đôi.

Người ta thường nói rằng việc chuẩn bị dữ liệu chiếm phần lớn thời gian trong một phân tích thực tế, với các con số thường được nhắc đến từ 50 đến 80 phần trăm. Dù tỷ lệ chính xác là bao nhiêu, kinh nghiệm của phần lớn các nhà thống kê ứng dụng và nhà dịch tễ học là việc làm sạch, mã hóa lại và kiểm tra tốn nhiều thời gian hơn hẳn so với việc xây dựng mô hình. Đó không phải là thời gian lãng phí. Làm sạch là giai đoạn bạn hiểu ra các biến thực sự có nghĩa là gì, chúng được thu thập như thế nào, giá trị nào đáng ngờ và dữ liệu có thể hay không thể trả lời những câu hỏi nào. Một nhà phân tích cẩn thận bước ra khỏi giai đoạn làm sạch với hiểu biết tường tận về bộ dữ liệu, và hiểu biết đó sẽ được đền đáp ở mọi bước tiếp theo.

2.1.2 Hợp đồng làm sạch

Ý tưởng trung tâm của chương này là điều mà chúng ta sẽ gọi là **hợp đồng làm sạch** (cleaning contract). Hợp đồng gồm ba điều khoản.

1. **Dữ liệu thô không bao giờ được chỉnh sửa bằng tay.** Tệp lấy từ hệ thống thu thập dữ liệu (ở đây là `hypertension_phc_raw.csv`) được coi là chỉ đọc. Bạn không mở nó trong một bảng tính rồi ghi đè 700 thành 170, xóa các dòng trùng lặp hay gõ lại "F" thành "Female". Những chỉnh sửa thủ công không để lại dấu vết, không thể được rà soát và không thể được lặp lại khi một phiên bản đã sửa của tệp thô được gửi đến.
2. **Mọi thay đổi đều được thực hiện bằng mã.** Một script làm sạch đọc tệp thô và áp dụng từng chỉnh sửa dưới dạng một dòng lệnh R tường minh, có chú thích. Bất kỳ ai đọc script

đều thấy chính xác những gì đã được thay đổi và vì sao; bất kỳ ai chạy nó đều nhận được đúng cùng một kết quả.

- 3. Đầu ra là một tệp duy nhất, được ghi chép đầy đủ và sẵn sàng phân tích.** Script kết thúc bằng việc lưu dữ liệu sạch (ở đây là `analysis_data.rds`). Mọi phân tích, trong mọi chương sau, đều bắt đầu bằng việc đọc tệp này, và không bao giờ bằng việc lặp lại hay sửa đổi các bước làm sạch.

Việc tách biệt dữ liệu thô, mã làm sạch và dữ liệu sạch là một nền tảng của nghiên cứu có thể tái lập (reproducible research) (Peng 2011). Đó cũng là khuyến nghị đầu tiên trong phần lớn các hướng dẫn thực hành tốt về quản lý dữ liệu. Broman and Woo (2018) đưa ra các quy tắc thực tế để tổ chức dữ liệu trong bảng tính sao cho phần mềm có thể đọc chúng một cách đáng tin cậy (mỗi ô một giá trị, mã hóa nhất quán, không dùng màu sắc để mang thông tin, có một từ điển dữ liệu riêng), và Wilson et al. (2017) khuyến nghị lưu dữ liệu thô ở dạng nguyên gốc, thực hiện việc làm sạch bằng script, và lưu dữ liệu đã làm sạch riêng biệt kèm theo ghi chép về cách chúng được tạo ra. Tuân theo các nguyên tắc này đòi hỏi một chút kỷ luật lúc ban đầu nhưng giúp tránh được rất nhiều rắc rối về sau.

Thực hành tốt

Hãy giữ một cấu trúc thư mục làm cho hợp đồng trở nên hiển hiện: các tệp thô ở một nơi (không bao giờ bị sửa đổi), các script ở một nơi khác, và dữ liệu dẫn xuất cùng các kết quả ở nơi thứ ba. Nếu có lúc bạn muốn "chỉ sửa một giá trị thôi" trong tệp thô, hãy viết một dòng mã thay vào đó, kèm theo chú thích giải thích nguồn gốc của chỉnh sửa (ví dụ: "giá trị đã được xác nhận với sổ đăng ký của cơ sở ngày 12 tháng 3").

2.1.3 Dữ liệu nghiên cứu tình huống và những vấn đề đã biết

Trong suốt chương, chúng ta làm việc với tệp thô của nghiên cứu tình huống đã giới thiệu trong Lời nói đầu: một nghiên cứu cắt ngang đa trung tâm trên người trưởng thành đến khám tại sáu cơ sở chăm sóc sức khỏe ban đầu. Dữ liệu được mô phỏng cho mục đích giảng dạy, và một số vấn đề đã được cài cắm có chủ ý để chúng ta có thể thực hành tìm và sửa chúng. Từ điển dữ liệu (`Data/data_dictionary.md`) liệt kê các vấn đề đã biết: các mã giá trị khuyết (ô trống, NA, 999, -99), ba bản ghi trùng lặp, cách viết giới tính không nhất quán, các biến Yes/No được mã hóa lẫn lộn, khoảng trắng thừa trong một số biến văn bản, các giá trị không thể xảy ra của tuổi, huyết áp, chiều cao và cân nặng, một biến BMI có sẵn nhưng chứa lỗi, và ngày tuyển chọn được ghi theo ba định dạng khác nhau. Trong các dự án thực tế, bạn sẽ không được báo trước các vấn đề; một phần của kỹ năng là phải tự đi tìm chúng. Vì vậy, chúng ta sẽ dùng từ điển như một công cụ kiểm tra lại công việc "thám tử" của chính mình chứ không phải như một danh sách để làm theo một cách máy móc.

Các bước làm sạch trong chương này được áp dụng theo một thứ tự cố định, và thứ tự đó có ý nghĩa. Chúng ta nhập dữ liệu với các mã giá trị khuyết được khai báo, loại bỏ bản ghi trùng lặp, chuẩn hóa văn bản, kiểm định các giá trị không thể xảy ra, tạo các biến mới từ những phép đo đã được kiểm định, phân tích cú pháp ngày tháng và cuối cùng thiết lập các mức của factor. Ở cuối chương, chúng ta kiểm tra rằng kết quả của mình giống hệt tệp `Data/analysis_data.rds` mà các chương còn lại sử dụng.

2.2 Dữ liệu gọn gàng và các loại biến

2.2.1 Dữ liệu gọn gàng

Trước khi làm sạch các giá trị, cần kiểm tra xem *hình dạng* của dữ liệu đã đúng hay chưa. Wickham (2014) đã hệ thống hóa một tập nguyên tắc đơn giản, gọi là **dữ liệu gọn gàng** (tidy data), mô tả cách bố trí mà phần lớn phần mềm thống kê mong đợi:

1. mỗi biến tạo thành một cột;
2. mỗi quan sát tạo thành một dòng;
3. mỗi loại đơn vị quan sát tạo thành một bảng.

Trong một nghiên cứu cắt ngang như nghiên cứu của chúng ta, đơn vị quan sát là bệnh nhân, vì vậy một bộ dữ liệu gọn gàng có một dòng cho mỗi bệnh nhân và một cột cho mỗi đặc điểm hoặc phép đo. Nhiều bộ dữ liệu lâm sàng thực tế vi phạm các nguyên tắc này theo những cách dễ nhận ra một khi bạn đã biết các quy tắc. Một bảng tính có một cột cho mỗi lần khám (sbp_visit1, sbp_visit2, sbp_visit3) đang lưu một biến (lần khám) trong tên cột; một cột như bp chứa "148/96" đang lưu hai biến trong một ô; một trang tính trong đó các dòng tiêu đề của từng cơ sở xen kẽ với các dòng bệnh nhân đang trộn lẫn hai đơn vị quan sát. Mỗi trường hợp như vậy cần được định dạng lại trước khi phân tích, bằng các công cụ như `pivot_longer()` và `separate()` được mô tả trong Wickham et al. (2023).

Tập thô của chúng ta đã gọn gàng về hình dạng: 36 cột, mỗi cột là một biến, và (sau khi loại bỏ các bản ghi trùng lặp) mỗi dòng là một bệnh nhân. Những vấn đề chúng ta gặp phải là vấn đề về *giá trị* và *kiểu dữ liệu*, không phải về cách bố trí. Đây là tình huống điển hình của dữ liệu được xuất ra từ một phiếu thu thập dữ liệu điện tử (electronic case report form), và nó cho phép chúng ta tập trung vào nội dung.

2.2.2 Các loại biến lâm sàng

Các phương pháp thống kê phụ thuộc vào loại biến được phân tích, vì vậy câu hỏi đầu tiên cần đặt ra với mỗi cột là nó ghi nhận loại đại lượng nào. Cách phân loại thông thường như sau (Kirkwood and Sterne 2003; Altman 1991).

- Biến **liên tục** (continuous), về nguyên tắc, có thể nhận bất kỳ giá trị nào trong một khoảng: tuổi, huyết áp, chiều cao, cân nặng, cholesterol. Chúng được tóm tắt bằng trung bình và độ lệch chuẩn hoặc trung vị và khoảng tứ phân vị, và được so sánh bằng kiểm định *t*, kiểm định dựa trên hạng hoặc hồi quy tuyến tính.
- Biến **rời rạc** (discrete, biến đếm) nhận các giá trị nguyên: số bệnh đồng mắc, số lần đến khám trong một năm. Chúng là biến số, nhưng các phép tính trên chúng phải lưu ý rằng "1,6 bệnh đồng mắc" là một giá trị trung bình, không phải là một bệnh nhân có thể tồn tại.
- Biến phân loại **danh định** (nominal) có các danh mục không có thứ tự tự nhiên: cơ sở y tế, nghề nghiệp, tình trạng hôn nhân. Chúng được tóm tắt bằng số lượng và tỷ lệ phần trăm.
- Biến phân loại **thứ bậc** (ordinal) có các danh mục với thứ tự tự nhiên nhưng không có khoảng cách cố định giữa chúng: trình độ học vấn (không đi học, tiểu học, trung học, sau trung học), mức độ hoạt động thể lực (thấp, trung bình, cao). Thứ tự này mang thông tin và không nên bị bỏ đi.

- Biến **nhị phân** (binary) là trường hợp đặc biệt có hai danh mục: có hay không có đài tháo đường, có hay không sử dụng điều trị. Biến kết cục nhị phân là lĩnh vực của hồi quy logistic (Chương 5).
- Biến **ngày và giờ** ghi nhận thời điểm một sự việc xảy ra: tuyển chọn, chẩn đoán, tử vong. Chúng chỉ hỗ trợ các phép tính (thời gian kể từ khi chẩn đoán, thời gian theo dõi) nếu được lưu dưới dạng ngày tháng chứ không phải dưới dạng văn bản.

R biểu diễn mỗi loại biến bằng một kiểu dữ liệu nhất định, và một phần của việc làm sạch là đảm bảo mỗi cột cuối cùng có đúng kiểu. Sự tương ứng cho nghiên cứu tình huống được tóm tắt trong bảng dưới đây.

Bảng 2.1: Các loại biến lâm sàng, ví dụ từ nghiên cứu tình huống và cách biểu diễn trong R sau khi làm sạch.

Loại biến	Ví dụ trong nghiên cứu tình huống	Kiểu R sau khi làm sạch
Liên tục	age, sbp_mmhg, height_cm, total_cholesterol_mmol_l	số (double)
Biến đếm rời rạc	comorbidity_count, knowledge_score	số (double)
Danh định	facility, occupation, marital_status	factor
Thứ bậc	education, physical_activity, bmi_cat	factor (có thứ tự hoặc có các mức được sắp xếp)
Nhị phân	diabetes, treatment_uptake, sex	factor có hai mức
Ngày tháng	enroll_date	Date
Mã định danh	patient_id	character (văn bản)

Có hai đặc điểm của bảng này cần bàn thêm. Thứ nhất, mã định danh `patient_id` được lưu dưới dạng văn bản mặc dù nó chứa chữ số. Mã định danh là nhãn, không phải đại lượng: tính trung bình của chúng không có ý nghĩa gì, và lưu chúng dưới dạng số sẽ làm mất các số 0 ở đầu (PHC-0011 không giống 11). Thứ hai, các biến nhị phân và phân loại trở thành **factor**. Một factor lưu tập hợp các danh mục được phép (các *mức*, levels) cùng với thứ tự của chúng. Thứ tự đó quyết định cách trình bày các bảng và, quan trọng hơn, danh mục nào đóng vai trò *nhóm tham chiếu* (reference level) trong các mô hình hồi quy, một vấn đề mà chúng ta sẽ quay lại ở Mục 2.10.

2.2.3 R đoán gì khi nhập dữ liệu

Khi `read_csv()` nhập một tệp, nó xem xét các dòng đầu tiên của mỗi cột và đoán một kiểu dữ liệu. Các con số trở thành kiểu `double`, mọi thứ khác trở thành kiểu `character` (văn bản). Hãy xem nó đoán gì với tệp thô khi chúng ta nhập một cách ngây thơ, tức là không cho R biết bất cứ điều gì về dữ liệu.

```
library(tidyverse)
library(lubridate)

# Nhập ngây thơ: để read_csv() tự đoán mọi thứ
raw_naive <- read_csv("Data/hypertension_phc_raw.csv")
dim(raw_naive)
```

```
#> [1] 1503 36
```

```
# read_csv() đã chọn bao nhiêu cột cho mỗi kiểu?
map_chr(raw_naive, \(x) class(x)[1]) |> table()
```

R

```
#>
#> character    numeric
#>          18         18
```

Tập có 1.503 dòng và 36 cột. Mười tám cột được đọc dưới dạng số và mười tám cột dưới dạng văn bản. Đó là một phỏng đoán ban đầu hợp lý, nhưng chưa phải câu trả lời cuối cùng. `enroll_date` được đọc dưới dạng văn bản vì các giá trị của nó được viết theo nhiều định dạng. Các biến Yes/No được đọc dưới dạng văn bản vì chúng trộn lẫn chữ và số. Các biến phân loại là văn bản chứ không phải factor; đây là mặc định của tidyverse và là mặc định đúng: chúng ta sẽ tự quyết định các mức thay vì để R sắp xếp chúng theo thứ tự bảng chữ cái. Và số dòng cho chúng ta biết có điều gì đó không ổn trước khi ta nhìn vào bất kỳ giá trị nào: nghiên cứu đã tuyển chọn 1.500 bệnh nhân, không phải 1.503.

2.3 Nhập dữ liệu với các mã giá trị khuyết tường minh

2.3.1 Giá trị canh gác

Các hệ thống thu thập dữ liệu và những người sử dụng chúng có nhiều cách để nói "không có giá trị nào được ghi nhận". Một ô có thể được để trống, được điền chữ NA, hoặc được điền một **giá trị canh gác** (sentinel value): một con số không thể là phép đo thật và được dùng làm cờ đánh dấu, thường là 999, -99, -9 hoặc 9999. Giá trị canh gác phổ biến trong các phần mềm cũ không thể lưu một ô số bị trống, và ngày nay chúng vẫn tồn tại trong nhiều hệ thống xét nghiệm và hệ thống sổ đăng ký.

Giá trị canh gác nguy hiểm vì chúng trông giống những con số. R sẽ sẵn lòng đưa một giá trị cholesterol -99 mmol/L vào phép tính trung bình. Hãy xem cholesterol toàn phần trong lần nhập ngẫu thơ.

```
# Cholesterol toàn phần khi nhập ngẫu thơ
summary(raw_naive$total_chol_mmol_l)
```

R

```
#>   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.    NAs
#> -99.00   4.30   5.10   2.59   5.80   8.30   55
```

```
# Có bao nhiêu giá trị là giá trị canh gác -99?
sum(raw_naive$total_chol_mmol_l == -99, na.rm = TRUE)
```

R

```
#> [1] 35
```

Giá trị nhỏ nhất -99 là không thể xảy ra: một nồng độ không thể âm. Bản tóm tắt ngẫu thơ báo cáo 55 giá trị khuyết (các ô trống và chuỗi NA mà `read_csv()` mặc định nhận ra), nhưng còn có thêm 35 giá trị được mã hóa là -99, và chúng kéo giá trị trung bình xuống thấp hơn nhiều so với trung vị. Một bản tóm tắt như thế này phải khiến bạn dừng lại ngay lập tức.

Trước khi quyết định mã nào cần coi là giá trị khuyết, nên rà soát toàn bộ các cột số để tìm các

giá trị đáng ngờ, thay vì chỉ xem từng cột một. Đoạn mã tiếp theo đếm, với mỗi cột số, có bao nhiêu giá trị bằng từng giá trị cạnh góc thường gặp.

```
# Đếm các mã có khả năng là giá trị cạnh góc trong mọi cột số
sentinel_scan <- raw_naive |>
  select(where(is.numeric)) |>
  pivot_longer(everything(), names_to = "variable") |>
  filter(value %in% c(-99, -9, 999, 9999)) |>
  count(variable, value, name = "n")

knitr::kable(sentinel_scan,
  col.names = c("Biến", "Giá trị", "n"),
  caption = "Các mã cạnh góc trong các cột số của tệp thô.")
```

Bảng 2.2: Các mã cạnh góc trong các cột số của tệp thô.

Biến	Giá trị	n
bmi	999	22
fasting_glucose_mmol_l	999	40
total_chol_mmol_l	-99	35

Ba biến chứa giá trị cạnh góc: biến BMI có sẵn và glucose lúc đói dùng 999, còn cholesterol toàn phần dùng -99. Không cột nào dùng -9 hoặc 9999. Kết quả rà soát cũng cho chúng ta một điều yên tâm: không có biến nào mà 999 có thể là một giá trị thật một cách hợp lý (ví dụ, một giá trị creatinine 999 $\mu\text{mol/L}$ là có thể xảy ra trong suy thận nặng, và sẽ cần được xử lý cẩn thận hơn nhiều).

Lỗi thường gặp

Việc khai báo một giá trị cạnh góc là giá trị khuyết được áp dụng cho *mọi* cột của tệp. Trước khi thêm "999" vào danh sách mã giá trị khuyết, hãy kiểm tra rằng không có biến nào thực sự có thể nhận giá trị đó. Creatinine, triglyceride tính bằng $\mu\text{mol/L}$, khoảng cách tính bằng mét và nhiều chỉ số đếm xét nghiệm có thể vượt quá 999 một cách hoàn toàn hợp lệ. Nếu một mã là giá trị cạnh góc ở một cột nhưng là giá trị thật ở cột khác, hãy chỉ chuyển nó thành NA ở những cột mà nó là giá trị cạnh góc, ví dụ bằng `na_if()` bên trong `mutate()`.

2.3.2 Khai báo mã giá trị khuyết khi nhập dữ liệu

Cách gọn gàng nhất để xử lý giá trị cạnh góc là khai báo chúng ngay khi đọc tệp, bằng đối số `na` của `read_csv()`. Bất kỳ ô nào có nội dung văn bản trùng khớp chính xác với một trong các chuỗi này sẽ trở thành NA.

```
# Nhập dữ liệu, khai báo mọi mã có nghĩa là "khuyết"
raw <- read_csv(
  "Data/hypertension_phc_raw.csv",
  na = c("", "NA", "999", "-99") # ô trống, "NA" và hai giá trị cạnh góc
)
dim(raw)
```

```
#> [1] 1503 36
```

```
summary(raw$total_chol_mmol_l)
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
#>      2.8    4.4    5.1    5.1    5.8    8.3    90
```

Cholesterol giờ đây nằm trong khoảng từ 2,8 đến 8,3 mmol/L, một khoảng hợp lý về mặt lâm sàng, trung bình (5,1) bằng trung vị (5,1), và 90 giá trị khuyết được đếm một cách trung thực là giá trị khuyết. Bảng so sánh dưới đây cho thấy tác động của đối số `na` lên mọi cột có giá trị khuyết.

```
# Số giá trị khuyết trong mỗi cột: nhập ngay thơ so với khai báo mã
na_compare <- tibble(
  variable = names(raw),
  na_naive = colSums(is.na(raw_naive)),
  na_declared = colSums(is.na(raw))
) |>
  filter(na_declared > 0) |>
  mutate(gained = na_declared - na_naive)

knitr::kable(na_compare,
  caption = "Số giá trị khuyết trước và sau khi khai báo mã.")
```

Bảng 2.3: Số giá trị khuyết trước và sau khi khai báo mã.

variable	na_naive	na_declared	gained
education	30	30	0
weight_kg	45	45	0
bmi	38	60	22
smoking	45	45	0
total_chol_mmol_l	55	90	35
ldl_mmol_l	105	105	0
fasting_glucose_mmol_l	35	75	40
knowledge_score	45	45	0
distance_to_facility_km	60	60	0
adherence	995	995	0
bp_controlled	995	995	0

Hãy đọc bảng theo từng cột. `na_naive` đếm các giá trị mà `read_csv()` đã nhận ra là khuyết (ô trống và chuỗi NA); `na_declared` đếm số giá trị khuyết sau khi thêm các giá trị canh gác; và `gained` là hiệu số giữa hai cột. Cholesterol toàn phần có thêm 35 giá trị khuyết, glucose lúc đói thêm 40 và BMI có sẵn thêm 22: đúng bằng số giá trị canh gác tìm thấy khi rà soát. Mọi cột khác không thay đổi. Số lượng rất lớn ở `adherence` và `bp_controlled` hoàn toàn không phải giá trị canh gác; chúng ta sẽ quay lại vấn đề này ở mục tiếp theo.

Thực hành tốt

Đối số `na` so khớp với *văn bản* trong tệp. Một giá trị canh góc được viết là `-99.0` hoặc `999.00` sẽ không khớp với `"-99"` hay `"999"`. Sau khi nhập, hãy luôn chạy `summary()` trên các cột số và xem giá trị nhỏ nhất và lớn nhất: một giá trị cực trị không thể xảy ra thường là một mã chưa được khai báo.

2.4 Dữ liệu khuyết: khái niệm và kiểm kê

Khai báo đúng các giá trị khuyết mới chỉ là bước khởi đầu. Câu hỏi khó hơn là các giá trị khuyết *có ý nghĩa gì* đối với phân tích. Hầu như bộ dữ liệu lâm sàng nào cũng có dữ liệu khuyết (missing data), và cách xử lý chúng có thể quan trọng không kém việc lựa chọn kiểm định thống kê.

2.4.1 Vì sao giá trị bị khuyết: ba cơ chế

Rubin (1976) đã đưa ra cách phân loại các quá trình, hay **cơ chế** (mechanisms), gây ra dữ liệu khuyết. Đây là nền tảng của tư duy hiện đại về dữ liệu khuyết (Little and Rubin 2019), và mọi nhà nghiên cứu lâm sàng đều nên biết.

- **Khuyết hoàn toàn ngẫu nhiên (missing completely at random, MCAR).** Xác suất một giá trị bị khuyết không liên quan đến bất kỳ đặc điểm nào của bệnh nhân, dù quan sát được hay không. Một mẫu máu bị đánh rơi trong phòng xét nghiệm, một trang phiếu bị thất lạc trong quá trình vận chuyển, một nhóm bệnh nhân được chọn ngẫu nhiên không được làm xét nghiệm vì thiếu hóa chất: trong mỗi trường hợp, những bệnh nhân có giá trị khuyết là một mẫu con ngẫu nhiên của toàn bộ bệnh nhân. Theo cơ chế MCAR, chỉ phân tích các bản ghi đầy đủ sẽ làm giảm độ chính xác nhưng không gây ra sai lệch.
- **Khuyết ngẫu nhiên (missing at random, MAR).** Xác suất một giá trị bị khuyết phụ thuộc vào các đặc điểm *đã được quan sát*, nhưng không phụ thuộc vào chính giá trị bị khuyết sau khi đã tính đến các đặc điểm đó. Giả sử cholesterol được đo ít hơn ở một cơ sở vì phòng xét nghiệm ở xa hơn, hoặc ít hơn ở bệnh nhân trẻ tuổi vì bác sĩ cho rằng họ có nguy cơ thấp. Khi đó, việc bị khuyết phụ thuộc vào cơ sở hoặc tuổi, cả hai đều được ghi nhận. Trong mỗi cơ sở, hay mỗi nhóm tuổi, những bệnh nhân bị khuyết cholesterol giống với những bệnh nhân có cholesterol được quan sát. Cái tên này dễ gây hiểu nhầm: MAR không có nghĩa là "ngẫu nhiên" theo nghĩa thông thường, mà có nghĩa là "ngẫu nhiên sau khi đã tính đến những gì chúng ta biết".
- **Khuyết không ngẫu nhiên (missing not at random, MNAR).** Xác suất một giá trị bị khuyết phụ thuộc vào chính giá trị đó, ngay cả sau khi đã tính đến dữ liệu quan sát được. Bệnh nhân có huyết áp rất cao có thể dễ bỏ lỡ lần tái khám hơn vì họ cảm thấy không khỏe; người uống rượu nhiều có thể dễ bỏ trống câu hỏi về rượu hơn; một máy xét nghiệm có thể không trả kết quả glucose khi giá trị vượt quá ngưỡng đo của máy. MNAR là cơ chế khó xử lý nhất, vì riêng dữ liệu quan sát được không thể cho chúng ta biết các giá trị khuyết khác biệt như thế nào.

Thông thường không thể chứng minh cơ chế khuyết từ dữ liệu. Chúng ta có thể cho thấy việc bị khuyết phụ thuộc vào các biến quan sát được (bằng chứng chống lại MCAR), nhưng không bao giờ có thể chỉ ra, chỉ từ dữ liệu quan sát được, rằng nó không đồng thời phụ thuộc vào các giá trị

không quan sát được. Các nhận định về MNAR phải đến từ hiểu biết lâm sàng về cách dữ liệu đã được thu thập.

2.4.2 Vì sao phân tích trên các trường hợp đầy đủ có thể gây hiểu nhầm

Phần lớn các hàm R, và phần lớn các phân tích đã công bố, xử lý dữ liệu khuyết bằng **phân tích trên các trường hợp đầy đủ** (complete-case analysis, còn gọi là loại bỏ theo danh sách hay listwise deletion): bất kỳ bệnh nhân nào có giá trị khuyết ở bất kỳ biến nào được dùng trong mô hình đều bị loại bỏ. Đây là điều mà `lm()` và `glm()` làm theo mặc định, và chúng báo cáo "observations deleted due to missingness" (số quan sát bị loại do khuyết) trong kết quả.

Phân tích trên các trường hợp đầy đủ có hai cái giá. Cái giá thứ nhất là mất độ chính xác. Nếu năm hiệp biến, mỗi biến có 5 phần trăm giá trị khuyết một cách độc lập, thì khoảng 23 phần trăm bệnh nhân có thể bị loại khỏi một mô hình sử dụng cả năm biến, và khoảng tin cậy sẽ rộng ra tương ứng. Cái giá thứ hai là nguy cơ **sai lệch** (bias). Trừ khi dữ liệu là MCAR, các trường hợp đầy đủ không phải là một mẫu ngẫu nhiên của quần thể nghiên cứu. Nếu cholesterol bị khuyết thường xuyên hơn ở bệnh nhân nông thôn, và bệnh nhân nông thôn ít có khả năng sử dụng điều trị hơn, thì một phân tích giới hạn ở những bệnh nhân có kết quả cholesterol sẽ có quá nhiều bệnh nhân thành thị và có thể cho một bức tranh sai lệch về việc sử dụng điều trị. Chiều hướng và độ lớn của sai lệch phụ thuộc vào cơ chế khuyết và vào phân tích, và trong một số tình huống phân tích trên các trường hợp đầy đủ vẫn không bị sai lệch ngay cả khi dữ liệu không phải MCAR (ví dụ, trong hồi quy khi việc bị khuyết chỉ phụ thuộc vào các hiệp biến) (Little and Rubin 2019). Điểm quan trọng là đây là một giả định, chứ không phải một lựa chọn mặc định trung lập.

2.4.3 Quy nạp đa trị: nhìn trước một bước

Khi dữ liệu khuyết nhiều và có khả năng là MAR, cách tiếp cận được khuyến nghị thường là **quy nạp đa trị** (multiple imputation) (Rubin 1976; Little and Rubin 2019). Thay vì xóa các bản ghi không đầy đủ, mỗi giá trị khuyết được thay bằng một giá trị rút ra từ một mô hình dự đoán nó dựa trên các biến khác. Việc này được thực hiện nhiều lần (chẳng hạn 20 lần), tạo ra nhiều bộ dữ liệu đầy đủ chỉ khác nhau ở các giá trị được quy nạp. Phân tích được thực hiện trên từng bộ dữ liệu và các kết quả được kết hợp lại bằng những quy tắc phản ánh cả độ bất định bên trong mỗi bộ dữ liệu lẫn độ bất định tăng thêm do không biết các giá trị khuyết. Trong R, gói `mice` thực hiện quy nạp đa trị bằng các phương trình nối tiếp (multiple imputation by chained equations) (Buuren and Groothuis-Oudshoorn 2011). Quy nạp đa trị rất mạnh nhưng không phải phép màu: nó phụ thuộc vào một mô hình quy nạp tốt, vào giả định MAR, và vào việc báo cáo cẩn thận. Sterne et al. (2009) mô tả những sai lầm thường gặp nhất và đưa ra hướng dẫn về cách báo cáo. Phương pháp này nằm ngoài phạm vi của cuốn sách nhập môn này, nhưng bạn nên biết nó tồn tại và nhận ra khi nào phân tích của mình có thể cần đến nó.

Lỗi thường gặp

Đừng thay thế các giá trị khuyết bằng giá trị trung bình, bằng số 0 hay bằng các giá trị "bình thường" trước khi phân tích. Quy nạp đơn bằng trung bình làm cho dữ liệu trông đầy đủ hơn và ít biến thiên hơn thực tế, làm sai số chuẩn bị ước lượng thấp và có thể làm sai lệch các mối liên quan. Hãy để giá trị khuyết là NA trong quá trình làm sạch, và đưa ra một quyết định có chủ đích, được ghi chép rõ ràng về cách xử lý chúng ở giai đoạn phân tích.

2.4.4 Kiểm kê dữ liệu khuyết

Bước thực hành đầu tiên là một cuộc **kiểm kê** (audit): một bảng cho thấy, với mỗi biến, có bao nhiêu giá trị bị khuyết và chiếm bao nhiêu phần trăm. Chúng ta viết nó một lần dưới dạng một hàm nhỏ để có thể dùng lại ở cuối chương trên dữ liệu sạch.

```
# Số lượng và tỷ lệ phần trăm giá trị khuyết trong mọi cột
missing_audit <- function(data) {
  tibble(
    variable = names(data),
    n_missing = colSums(is.na(data)),
    pct      = round(100 * n_missing / nrow(data), 1)
  ) |>
  arrange(desc(n_missing))
}

audit_raw <- missing_audit(raw)
audit_raw |>
  filter(n_missing > 0) |>
  knitr::kable(col.names = c("Biến", "Số khuyết", "%"),
               caption = "Giá trị khuyết trong dữ liệu thô (đã khai báo mã).")
```

Bảng 2.4: Giá trị khuyết trong dữ liệu thô (đã khai báo mã).


Biến	Số khuyết	%
adherence	995	66.2
bp_controlled	995	66.2
ldl_mmol_l	105	7.0
total_chol_mmol_l	90	6.0
fasting_glucose_mmol_l	75	5.0
bmi	60	4.0
distance_to_facility_km	60	4.0
weight_kg	45	3.0
smoking	45	3.0
knowledge_score	45	3.0
education	30	2.0

Mười một trong 36 cột có giá trị khuyết. Hai cột nổi bật: adherence (tuân thủ điều trị) và bp_controlled (huyết áp được kiểm soát) bị khuyết ở 995 trong số 1.503 bản ghi (66 phần trăm). Trước khi hoảng hốt, hãy xem từ điển dữ liệu: tuân thủ điều trị và kiểm soát huyết áp chỉ được định nghĩa cho những bệnh nhân *đang điều trị*. Một bệnh nhân không dùng thuốc hạ huyết áp thì không thể tuân thủ hay không tuân thủ thuốc đó. Những giá trị này là **khuyết do cấu trúc** (structurally missing), hay "không áp dụng", và hoàn toàn không phải là vấn đề về chất lượng dữ liệu. Chúng ta sẽ kiểm chứng điều này một cách chính thức ở cuối chương.

Các biến còn lại có từ 2 đến 7 phần trăm giá trị khuyết. Các giá trị xét nghiệm (LDL, cholesterol toàn phần, glucose lúc đói) bị khuyết nhiều nhất, điều này là điển hình: xét nghiệm máu cần có mẫu bệnh phẩm, một phòng xét nghiệm hoạt động và một kết quả được chuyển trở lại vào hồ sơ. Một hình vẽ giúp nhìn thấy quy luật này dễ dàng hơn.

```
audit_raw |>
  filter(n_missing > 0) |>
  mutate(
    type = if_else(variable %in% c("adherence", "bp_controlled"),
                  "Không áp dụng (chưa điều trị)", "Dữ liệu khuyết"),
    variable = fct_reorder(variable, pct)
  ) |>
  ggplot(aes(x = pct, y = variable, fill = type)) +
  geom_col() +
  geom_text(aes(label = paste0(pct, "%")), hjust = -0.15, size = 3) +
  scale_fill_manual(values = c("#04242F", "#8FB8C4")) +
  scale_x_continuous(limits = c(0, 75), expand = c(0, 0)) +
  labs(x = "Khuyết (%)", y = NULL, fill = NULL,
       title = "Giá trị khuyết theo biến") +
  theme(legend.position = "bottom",
        legend.key.spacing.x = unit(12, "pt")) # tách các mục chú giải
```

Giá trị khuyết theo biến



Hình 2.1: Tỷ lệ phần trăm giá trị khuyết theo từng biến trong dữ liệu thô, sau khi khai báo các mã giá trị khuyết. Các biến khuyết do cấu trúc (chỉ được định nghĩa cho bệnh nhân đang điều trị) được thể hiện bằng màu nhạt hơn.

2.4.5 Tìm hiểu cơ chế khuyết

Chúng ta không thể chứng minh một cơ chế khuyết, nhưng có thể tìm bằng chứng chống lại MCAR bằng cách xem việc bị khuyết có liên quan đến các đặc điểm quan sát được hay không. Đoạn mã tiếp theo so sánh tỷ lệ phần trăm giá trị xét nghiệm bị khuyết giữa các cơ sở.

```
# Tỷ lệ phần trăm khuyết của ba giá trị xét nghiệm, theo cơ sở
raw |>
  mutate(facility = str_trim(facility)) |>
  group_by(facility) |>
  summarise(
    n = n(),
    chol_pct = round(100 * mean(is.na(total_chol_mmol_l)), 1),
    ldl_pct = round(100 * mean(is.na(ldl_mmol_l)), 1),
```

```

gluc_pct = round(100 * mean(is.na(fasting_glucose_mmol_l)), 1)
) |>
knitr::kable(col.names = c("Cơ sở", "n", "Chol (%)", "LDL (%)",
                           "Glucose (%)"),
              caption = "Tỷ lệ giá trị xét nghiệm bị khuyết theo cơ sở.")

```

Bảng 2.5: Tỷ lệ giá trị xét nghiệm bị khuyết theo cơ sở.

Cơ sở	n	Chol (%)	LDL (%)	Glucose (%)
Bugando PHC	337	5.6	5.6	5.3
Buzuruga PHC	175	4.6	7.4	7.4
Igoma HC	175	6.3	6.9	6.3
Ilemela HC	283	5.3	7.8	3.2
Kisesa HC	228	9.2	7.0	3.9
Nyamagana PHC	305	5.2	7.5	4.9

Tỷ lệ phần trăm có khác nhau đôi chút giữa các cơ sở, nhưng với 175 đến 337 bệnh nhân mỗi cơ sở, những chênh lệch vài điểm phần trăm là điều mà riêng yếu tố ngẫu nhiên cũng có thể tạo ra. Không có cơ sở nào mà kết quả xét nghiệm vắng mặt một cách có hệ thống. Trong một nghiên cứu thực tế, một cơ sở có, chẳng hạn, 30 phần trăm cholesterol bị khuyết sẽ là lý do để trao đổi với nhóm thực địa: phòng xét nghiệm có đóng cửa một tháng không, hay các phiếu được điền theo cách khác? Một quy luật như vậy gợi ý rằng việc khuyết là MAR (phụ thuộc vào cơ sở) và cơ sở nên được đưa vào bất kỳ mô hình phân tích hay mô hình quy nạp nào sử dụng cholesterol.

Diễn giải lâm sàng

Hãy hỏi vì sao mỗi giá trị bị khuyết trước khi quyết định phải làm gì. Một kết quả glucose bị khuyết vì máy xét nghiệm hỏng (MCAR), vì chỉ những bệnh nhân có triệu chứng mới được xét nghiệm (MAR, nếu triệu chứng được ghi nhận) và vì các giá trị rất cao không được báo cáo (MNAR) đòi hỏi những cách xử lý rất khác nhau. Những người thu thập dữ liệu thường biết câu trả lời; hãy hỏi họ. Vì dữ liệu này là dữ liệu mô phỏng, các quy luật ở đây minh họa cho phương pháp chứ không phải là phát hiện lâm sàng thực tế.

2.5 Bản ghi trùng lặp

2.5.1 Bản ghi trùng lặp đến từ đâu

Một **bản ghi trùng lặp** (duplicate) là một bản ghi xuất hiện nhiều hơn một lần cho cái lẽ ra chỉ là một đơn vị quan sát. Trong dữ liệu lâm sàng, bản ghi trùng lặp phát sinh khi một phiếu được nhập hai lần (mỗi lần bởi một trong hai nhân viên nhập liệu, hoặc một lần trước và một lần sau khi chỉnh sửa), khi các tệp từ hai nguồn được gộp lại và có phần chồng lấn, hoặc khi một lần xuất dữ liệu được chạy hai lần và nối vào nhau. Bản ghi trùng lặp làm tăng cỡ mẫu một cách giả tạo, khiến một số bệnh nhân được tính hai lần, và làm sai số chuẩn nhỏ hơn thực tế. Nếu những bệnh nhân bị trùng lặp khác biệt một cách có hệ thống so với phần còn lại (ví dụ, nếu các phiếu có vấn đề dễ bị nhập lại hơn), chúng còn có thể gây ra sai lệch.

Có hai loại bản ghi trùng lặp cần tìm. **Trùng lặp hoàn toàn** (exact duplicates) là các dòng giống hệt nhau ở mọi cột; gần như chắc chắn chúng là cùng một bản ghi được nhập hai lần và có thể

loại bỏ một cách an toàn. **Trùng lặp theo khóa** (key duplicates) có cùng mã định danh nhưng khác nhau ở một số cột; chúng có thể là một bản ghi được nhập lại có chỉnh sửa, hai lần khám của cùng một bệnh nhân, hoặc hai bệnh nhân khác nhau bị gán nhầm cùng một mã. Trùng lặp theo khóa cần được điều tra, chứ không được xóa tự động.

2.5.2 Phát hiện bản ghi trùng lặp

Chúng ta bắt đầu bằng cách so sánh số dòng với số mã bệnh nhân khác nhau, rồi liệt kê các mã xuất hiện nhiều hơn một lần.

```
nrow(raw) # số dòng R
```

```
#> [1] 1503
```

```
n_distinct(raw$patient_id) # số bệnh nhân khác nhau R
```

```
#> [1] 1500
```

```
# Những mã nào xuất hiện nhiều hơn một lần? R
raw |>
  count(patient_id) |>
  filter(n > 1)
```

```
#> # A tibble: 3 × 2
#>   patient_id     n
#>   <chr>      <int>
#> 1 PHC-0011      2
#> 2 PHC-0251      2
#> 3 PHC-0881      2
```

Có 1.503 dòng nhưng chỉ có 1.500 mã bệnh nhân khác nhau, và ba mã (PHC-0011, PHC-0251 và PHC-0881) mỗi mã xuất hiện hai lần. Tiếp theo, chúng ta hỏi liệu đây có phải là trùng lặp hoàn toàn hay không.

```
# Số dòng giống hệt một dòng xuất hiện trước đó ở mọi cột R
sum(duplicated(raw))
```

```
#> [1] 3
```

`duplicated()` đánh dấu mỗi dòng giống hệt một dòng đã xuất hiện trước đó, vì vậy tổng bằng 3 là số bản sao thừa. Vì số trùng lặp hoàn toàn bằng số mã thừa, mọi mã bị lặp lại đều là bản sao chính xác của một dòng khác: không có trùng lặp theo khóa mâu thuẫn nào cần điều tra. Dù vậy, vẫn nên xem các bản ghi trùng lặp trước khi loại bỏ chúng.

```
# Hiển thị các bản ghi trùng lặp cạnh nhau (vài cột đầu tiên) R
raw |>
  filter(patient_id %in% c("PHC-0011", "PHC-0251", "PHC-0881")) |>
  arrange(patient_id) |>
  select(patient_id, facility, enroll_date, age, sex, sbp_mmhg)
```

```
#> # A tibble: 6 × 6
#>   patient_id facility enroll_date age sex sbp_mmhg
#>   <chr>      <chr>      <chr>    <dbl> <chr>    <dbl>
#> 1 PHC-0011  Ilemela HC    2024-12-01    51 Male     128
#> 2 PHC-0011  Ilemela HC    2024-12-01    51 Male     128
#> 3 PHC-0251  Bugando PHC    2024-01-28    51 Female    131
#> 4 PHC-0251  Bugando PHC    2024-01-28    51 Female    131
#> 5 PHC-0881  Kisesa HC     2024-02-25    45 Female    140
#> 6 PHC-0881  Kisesa HC     2024-02-25    45 Female    140
```

Mỗi cặp đều giống hệt nhau, đúng như dự kiến. Gói `janitor` cung cấp hàm `get_dupes()`, cho ra cùng danh sách này chỉ với một lệnh và có thêm một cột đếm; đây là một lựa chọn thay thế tiện lợi với các tệp lớn hơn.

2.5.3 Loại bỏ bản ghi trùng lặp và kiểm tra kết quả

`distinct()` giữ lại lần xuất hiện đầu tiên của mỗi dòng duy nhất và bỏ đi phần còn lại.

```
n_before <- nrow(raw)
raw <- distinct(raw) # bỏ các dòng trùng lặp hoàn toàn
n_after <- nrow(raw)

c(before = n_before, after = n_after, removed = n_before - n_after)
```

```
#>   before  after removed
#>    1503   1500      3
```

```
# Giờ đây mỗi dòng phải là một bệnh nhân khác nhau
n_distinct(raw$patient_id) == nrow(raw)
```

```
#> [1] TRUE
```

Ba dòng đã bị loại bỏ và còn lại 1.500 dòng, mỗi dòng một bệnh nhân. Dòng cuối cùng là một phép kiểm tra đơn giản nhưng mạnh mẽ: nó chỉ trả về `TRUE` nếu mã bệnh nhân giờ đây là một khóa duy nhất.

Thực hành tốt

Luôn báo cáo các bản ghi trùng lặp. Một câu như "Ba bản ghi là bản sao hoàn toàn của các bản ghi khác và đã được loại bỏ, còn lại 1.500 người tham gia" nên được đưa vào phần phương pháp hoặc vào một sơ đồ luồng, như khuyến nghị của hướng dẫn STROBE cho các nghiên cứu quan sát (Elm et al. 2007). Nếu bạn phát hiện trùng lặp theo khóa với các giá trị mâu thuẫn, đừng chọn ngẫu nhiên một bản: hãy quay lại tài liệu gốc, và ghi lại phiên bản nào được giữ lại và vì sao.

2.6 Danh mục không nhất quán và khoảng trống

Các biến phân loại là nơi dấu ấn của việc nhập liệu thủ công thể hiện rõ nhất. Những nhân viên nhập liệu khác nhau, các mẫu phiếu khác nhau và các phiên bản phần mềm khác nhau tạo ra

những cách viết khác nhau cho cùng một danh mục: "Female", "female", "F" và "f"; "Yes", "Y" và "1". Với người đọc, chúng hiển nhiên là tương đương. Với R, chúng là những chuỗi khác nhau, và một bảng tần số hay một mô hình hồi quy sẽ coi chúng là các danh mục khác nhau.

2.6.1 Khoảng trắng

Vấn đề khó thấy nhất là **khoảng trắng** (whitespace): các dấu cách trước hoặc sau một giá trị, như trong " Rural ". Chúng vô hình trong hầu hết các bản in, nhưng " Rural " không bằng "Rural". Từ điển dữ liệu cảnh báo rằng một số giá trị của facility, residence, education và occupation có khoảng trắng thừa. Thế nhưng bảng tần số của facility trong dữ liệu đã nhập lại trông rất sạch.

```
table(raw$facility)
```

```
#>
#>   Bugando PHC   Buzuruga PHC      Igoma HC      Ilemela HC      Kisesa HC
#>         336         175         175         282         227
#> Nyamagana PHC
#>         305
```

Lý do là read_csv() mặc định cắt bỏ khoảng trắng ở đầu và cuối (đối số trim_ws = TRUE). Chúng ta có thể làm lộ ra vấn đề bằng cách nhập dữ liệu với chức năng cắt khoảng trắng bị tắt.

```
# Nhập lại KHÔNG cắt khoảng trắng, chỉ để thấy các dấu cách bị ẩn
raw_untrimmed <- read_csv("Data/hypertension_phc_raw.csv",
  na = c("", "NA", "999", "-99"),
  trim_ws = FALSE)

# Số giá trị có dấu cách ở đầu hoặc cuối, trong mỗi cột văn bản
raw_untrimmed |>
  select(facility, residence, education, occupation) |>
  summarise(across(everything(), \(x) sum(x != str_trim(x), na.rm = TRUE)))
```

```
#> # A tibble: 1 × 4
#>   facility residence education occupation
#>   <int>      <int>      <int>      <int>
#> 1     108       143       117       109
```

```
# Những gì R thấy khi không cắt khoảng trắng
table(raw_untrimmed$residence)
```

```
#>
#>   Rural   Urban   Rural   Urban
#>    68     75    636    724
```

Khi không cắt khoảng trắng, residence (nơi cư trú) có bốn danh mục thay vì hai, và từ 108 đến 143 giá trị trong mỗi biến của bốn biến này mang dấu cách ẩn. Nhiều cách nhập dữ liệu, bao gồm sao chép dữ liệu từ một đối tượng R khác, đọc từ cơ sở dữ liệu hoặc đọc một số định dạng văn bản, không tự động cắt khoảng trắng. Vì vậy, chúng ta áp dụng str_trim() cho mọi cột văn bản một cách tường minh. Việc này không tốn gì khi dữ liệu đã sạch và bảo vệ quy trình nếu

cách nhập dữ liệu thay đổi về sau.

```
# Xóa dấu cách ở đầu/cuối trong mọi cột kiểu character
raw <- raw |>
  mutate(across(where(is.character), str_trim))
```

`across(where(is.character), str_trim)` được đọc là "với mọi cột kiểu character, thay nó bằng phiên bản đã được cắt khoảng trắng". Đây là lần đầu tiên trong nhiều lần dùng `across()` trong chương này: nó cho phép một dòng mã thực hiện cùng một công việc trên nhiều cột.

2.6.2 Cách viết không nhất quán: giới tính

Bây giờ chúng ta lập bảng tần số cho sex, yêu cầu `table()` hiển thị cả giá trị khuyết.

```
table(raw$sex, useNA = "ifany")
```

```
#>
#>      f      F female Female      m      M      male      Male
#>    74     73     68     670    40     39     42     494
```

Có tám cách viết cho hai danh mục: từ đầy đủ viết hoa chữ cái đầu và viết thường, và chữ cái đơn viết hoa và viết thường. Cách sửa gồm hai phần. Đầu tiên, chúng ta chuyển văn bản sang chữ thường bằng `str_to_lower()`, gộp "Female", "female" thành "female" và "F", "f" thành "f". Sau đó `case_when()` ánh xạ mỗi nhóm cách viết thành một nhãn sạch duy nhất. `case_when()` đánh giá các điều kiện từ trên xuống dưới và trả về giá trị của điều kiện đúng đầu tiên; dòng `TRUE ~ cuối cùng` là lưới hứng cho mọi giá trị không được nhận ra.

```
sex_before <- raw$sex # giữ một bản sao để kiểm tra việc mã hóa lại

raw <- raw |>
  mutate(sex = case_when(
    str_to_lower(sex) %in% c("female", "f") ~ "Female",
    str_to_lower(sex) %in% c("male", "m") ~ "Male",
    TRUE ~ NA_character_ # mọi giá trị không nhận ra đều thành khuyết
  ))

table(raw$sex, useNA = "ifany")
```

```
#>
#> Female      Male
#>    885     615
```

Giờ đây có 885 phụ nữ ("Female") và 615 nam giới ("Male"), không có giá trị khuyết nào. Lưới hứng không tạo ra NA nào, cho thấy mọi giá trị ban đầu đều đã được nhận ra. Một phép mã hóa lại luôn cần được kiểm tra bằng cách lập bảng chéo giữa giá trị cũ và giá trị mới.

```
table(before = sex_before, after = raw$sex, useNA = "ifany")
```

```
#>      after
#> before Female Male
#>      f      74    0
#>      F      73    0
```

```
#> female      68      0
#> Female     670      0
#> m           0      40
#> M           0      39
#> male        0      42
#> Male        0     494
```

Mỗi cách viết ban đầu được ánh xạ đến đúng một danh mục sạch, và không có gì bị mất. Bảng chéo này là sự bảo vệ tốt nhất chống lại lỗi gõ trong một quy tắc mã hóa lại (ví dụ, viết "femle"), lỗi mà nếu không thì sẽ âm thầm biến các giá trị hợp lệ thành giá trị khuyết.

Lỗi thường gặp

Kết thúc `case_when()` bằng `TRUE ~ sex` (giữ nguyên giá trị gốc) thay vì `TRUE ~ NA_character_` sẽ che giấu vấn đề: một cách viết bất ngờ như "FM" sẽ đi qua mà không thay đổi và xuất hiện như một danh mục thứ ba trong các bảng sau này. Ánh xạ các giá trị không nhận ra thành NA rồi kiểm tra rằng không có NA mới nào xuất hiện sẽ làm cho những điều bất ngờ trở nên hiển hiện.

2.6.3 Một hàm trợ giúp dùng lại được cho các biến Yes/No

Năm biến (`diabetes`, `family_history_htn`, `health_insurance`, `htn_diagnosed` và `treatment_uptake`) trộn lẫn ba cách mã hóa cho cùng một thông tin nhị phân.

```
table(raw$diabetes, useNA = "ifany")
```

```
#>
#>    0    1    N   No    Y   Yes
#> 229    7  143 1093    4    24
```

```
table(raw$treatment_uptake, useNA = "ifany")
```

```
#>
#>    0    1    N   No    Y   Yes
#> 134   79   95  763   52  377
```

Đái tháo đường được ghi là 0/1, N/Y và No/Yes. Lưu ý rằng `read_csv()` đọc các cột này dưới dạng văn bản vì chữ và số bị trộn lẫn; nếu một cột chỉ chứa 0 và 1 thì nó sẽ được đọc dưới dạng số, và đó là một lý do nữa để chuyển các giá trị bằng `as.character()` trước khi so sánh chúng với văn bản.

Thay vì viết cùng một `case_when()` năm lần, chúng ta viết một **hàm** (function) nhỏ. Hàm là cách tự nhiên để áp dụng cùng một logic một cách nhất quán: nếu quy tắc cần thay đổi (chẳng hạn xuất hiện một mã mới "U" cho "không rõ"), nó chỉ cần được sửa ở một chỗ.

```
# Chuẩn hóa mọi cách mã hóa Yes/No thành "Yes", "No" hoặc NA
to_yesno <- function(x) {
  x <- str_to_lower(str_trim(as.character(x))) # văn bản, bỏ cách, viết thường
  case_when(
```

```
x %in% c("yes", "y", "1", "true") ~ "Yes",
x %in% c("no", "n", "0", "false") ~ "No",
TRUE ~ NA_character_ # mọi giá trị khác -> khuyết
)
}

# Thử hàm trợ giúp trên một vector nhỏ trước khi dùng cho dữ liệu
to_ynsno(c("Yes", " y", "1", "No", "N", "0", "TRUE", "maybe", NA))

#> [1] "Yes" "Yes" "Yes" "No" "No" "No" "Yes" NA NA
```

Thử một hàm trợ giúp trên một vector nhỏ tự tạo có chứa các trường hợp khó (một dấu cách ở đầu, một giá trị trông giống giá trị logic, một từ bất ngờ, một giá trị khuyết) là một thói quen đáng rèn luyện. Kết quả đúng như mong muốn: bốn dạng của "có" ("Yes"), ba dạng của "không" ("No"), và NA cho từ không nhận ra và cho giá trị khuyết. Giờ chúng ta áp dụng hàm cho cả năm cột cùng lúc bằng `across()`.

```
binary_vars <- c("diabetes", "family_history_htn", "health_insurance",
                "htn_diagnosed", "treatment_uptake")
binary_before <- raw |> select(all_of(binary_vars)) # bản sao để kiểm tra

raw <- raw |>
  mutate(across(all_of(binary_vars), to_ynsno))

# Số lượng mỗi giá trị sạch trong từng biến nhị phân
raw |>
  select(all_of(binary_vars)) |>
  pivot_longer(everything(), names_to = "variable") |>
  count(variable, value) |>
  pivot_wider(names_from = value, values_from = n, values_fill = 0) |>
  knitr::kable(caption = "Các biến nhị phân sau khi chuẩn hóa.")
```

Bảng 2.6: Các biến nhị phân sau khi chuẩn hóa.

variable	No	Yes
diabetes	1465	35
family_history_htn	940	560
health_insurance	988	512
htn_diagnosed	411	1089
treatment_uptake	992	508

Giờ đây mọi biến nhị phân chỉ có các giá trị "No" và "Yes", và bảng không có cột NA, nghĩa là mọi mã ban đầu đều đã được nhận ra. Trong số 1.500 bệnh nhân, 1.089 người đã được chẩn đoán tăng huyết áp và 508 người đang sử dụng điều trị hạ huyết áp. Để kiểm tra phép ánh xạ, bảng chéo cho biến sử dụng điều trị xác nhận rằng mỗi mã ban đầu đã đi đến đúng chỗ.

```
table(before = binary_before$treatment_uptake,
      after = raw$treatment_uptake)
```

```
#>      after
#> before No Yes
```

```
#>    0    134    0
#>    1     0    79
#>    N     95    0
#>   No    763    0
#>    Y     0    52
#>   Yes     0   377
```

Thực hành tốt

Gói `forcats` (một phần của `tidyverse`) cung cấp `fct_recode()` và `fct_collapse()` để mã hóa lại các mức của `factor`, ví dụ `fct_collapse(sex, Female = c("F", "f", "female", "Female"))`. Chúng tiện lợi khi đã biết trước danh sách đầy đủ các cách viết. `case_when()` kết hợp với `str_to_lower()` vững vàng hơn trước những cách viết bạn không lường trước, vì nó chuẩn hóa văn bản trước khi so sánh.

2.7 Kiểm định các giá trị không thể xảy ra

2.7.1 Khoảng giá trị hợp lý

Sau các mã giá trị khuyết và cách viết, loại vấn đề tiếp theo là những giá trị được ghi dưới dạng số nhưng không thể đúng. Một số là lỗi gõ hiển nhiên: huyết áp tâm thu 700 có lẽ là 170 bị lệch một chữ số, chiều cao 17 cm có lẽ là 170 cm bị rơi mất số 0. Số khác là giá trị giữ chỗ (tuổi 0 cho "không rõ") hoặc nhầm lẫn đơn vị (cân nặng tính bằng pound trong một cột dành cho kilogram).

Cách tiếp cận chuẩn là xác định, cho mỗi biến liên tục, một **khoảng giá trị hợp lý** (plausible range) dựa trên sinh lý học và tiêu chuẩn chọn vào của nghiên cứu, rồi đánh dấu mọi giá trị nằm ngoài khoảng đó. Khoảng này cần đủ rộng để giữ lại các giá trị cực trị có thật (tăng huyết áp nặng, bệnh nhân rất cao hoặc rất gầy là có thật và quan trọng về mặt lâm sàng) và đủ hẹp để loại bỏ những giá trị không thể đúng. Lý tưởng nhất là chúng được ghi vào kế hoạch quản lý dữ liệu của nghiên cứu trước khi xem dữ liệu. Các khoảng được dùng cho nghiên cứu tình huống được trình bày dưới đây.

Bảng 2.7: Các khoảng giá trị hợp lý dùng để kiểm định các phép đo liên tục ở bệnh nhân trưởng thành tại tuyến chăm sóc ban đầu.

Biến	Giới hạn dưới	Giới hạn trên	Lý do
age (năm)	18	110	Chỉ người trưởng thành (tiêu chuẩn chọn vào); tuổi cao nhất hợp lý
sbp_mmhg (mmHg)	70	260	Dưới 70 là sốc; trên 260 hầu như không bao giờ được ghi nhận
dbp_mmhg (mmHg)	40	150	Giới hạn sinh lý ở người trưởng thành ngồi
height_cm (cm)	120	210	Khoảng chiều cao của người trưởng thành
weight_kg (kg)	30	200	Khoảng cân nặng của người trưởng thành trong quần thể này

Những giới hạn này là các nhận định, và những người hợp lý có thể chọn các giới hạn hơi khác. Điều quan trọng là chúng phải tường minh, có lý do và được áp dụng bằng mã, để người đọc có thể thấy chúng và người phản biện có thể yêu cầu một phân tích độ nhạy với các giới hạn khác.

2.7.2 Tìm các giá trị vi phạm

Trước khi thay đổi bất cứ điều gì, chúng ta đếm có bao nhiêu giá trị nằm ngoài mỗi khoảng và xem xét chúng.

```
# Đếm các giá trị nằm ngoài mỗi khoảng hợp lý (không đếm giá trị NA)
raw |>
  summarise(
    age      = sum(age < 18 | age > 110, na.rm = TRUE),
    sbp      = sum(sbp_mmhg < 70 | sbp_mmhg > 260, na.rm = TRUE),
    dbp      = sum(dbp_mmhg < 40 | dbp_mmhg > 150, na.rm = TRUE),
    height   = sum(height_cm < 120 | height_cm > 210, na.rm = TRUE),
    weight   = sum(weight_kg < 30 | weight_kg > 200, na.rm = TRUE)
  )
```

```
#> # A tibble: 1 × 5
#>   age    sbp    dbp height weight
#>   <int> <int> <int>   <int>   <int>
#> 1     2     2     1     1     1
```

```
# Các bản ghi liên quan
raw |>
  filter(age < 18 | age > 110 | sbp_mmhg < 70 | sbp_mmhg > 260 |
         dbp_mmhg < 40 | dbp_mmhg > 150 | height_cm < 120 |
         height_cm > 210 | weight_kg < 30 | weight_kg > 200) |>
  select(patient_id, age, sbp_mmhg, dbp_mmhg, height_cm, weight_kg)
```

```
#> # A tibble: 7 × 6
#>   patient_id age sbp_mmhg dbp_mmhg height_cm weight_kg
#>   <chr>      <dbl>   <dbl>   <dbl>   <dbl>   <dbl>
#> 1 PHC-0174   200     130     83     154.4   77.9
#> 2 PHC-0689    34     130     87     170.7    7
#> 3 PHC-0768    32      0     73     158.3   81.4
#> 4 PHC-0664    52    102     61      17     63.9
#> 5 PHC-0360    34    700     81     169.2   64.9
#> 6 PHC-0806     0    157     91     166.3   85.8
#> 7 PHC-1342    54    106      5     150.2   40.1
```

Bảy giá trị ở bảy bệnh nhân khác nhau nằm ngoài khoảng: hai giá trị tuổi (0 và 200), hai giá trị huyết áp tâm thu (0 và 700), một giá trị huyết áp tâm trương (5), một chiều cao (17 cm) và một cân nặng (7 kg). Đây chính xác là những vấn đề được liệt kê trong từ điển dữ liệu. Hãy nhìn từng dòng: ngoài giá trị không thể xảy ra duy nhất, mọi phép đo khác của những bệnh nhân này đều hợp lý. Đây là đặc điểm điển hình của lỗi nhập liệu và ứng hộ quyết định chỉ loại bỏ giá trị không thể xảy ra, chứ không loại bỏ cả bệnh nhân.

2.7.3 Chuyển các giá trị không thể xảy ra thành giá trị khuyết

Nên thay một giá trị không thể xảy ra bằng gì? Bạn dễ bị cám dỗ "sửa" 700 thành 170, hay 17 thành

1. Hãy củng lại: bạn không biết giá trị dự định là 170 chứ không phải 107 hay 160, và một giá

trị bị ra còn tệ hơn một ô trống trung thực. Trừ khi giá trị đúng có thể được xác nhận từ tài liệu gốc (phiếu giấy, sổ đăng ký của phòng khám), lựa chọn an toàn là chuyển giá trị đó thành giá trị khuyết. `if_else()` giữ nguyên giá trị khi điều kiện đúng và thay bằng NA trong trường hợp ngược lại.

```
raw_before_validation <- raw      # giữ một bản sao cho các hình trước/sau

raw <- raw |>
  mutate(
    age      = if_else(age >= 18 & age <= 110, age, NA_real_),
    sbp_mmhg = if_else(sbp_mmhg >= 70 & sbp_mmhg <= 260, sbp_mmhg, NA_real_),
    dbp_mmhg = if_else(dbp_mmhg >= 40 & dbp_mmhg <= 150, dbp_mmhg, NA_real_),
    height_cm = if_else(height_cm >= 120 & height_cm <= 210,
                        height_cm, NA_real_),
    weight_kg = if_else(weight_kg >= 30 & weight_kg <= 200, weight_kg, NA_real_)
  )

summary(select(raw, age, sbp_mmhg, dbp_mmhg, height_cm, weight_kg))
```

```
#>      age      sbp_mmhg      dbp_mmhg      height_cm      weight_kg
#> Min.   :18.0   Min.    : 90   Min.    : 56   Min.    :141   Min.    : 34.6
#> 1st Qu.:43.0   1st Qu.:126   1st Qu.: 79   1st Qu.:158   1st Qu.: 60.9
#> Median :52.0   Median :139   Median : 86   Median :164   Median : 70.1
#> Mean   :52.3   Mean    :139   Mean    : 86   Mean    :164   Mean    : 70.9
#> 3rd Qu.:62.0   3rd Qu.:153   3rd Qu.: 93   3rd Qu.:169   3rd Qu.: 80.4
#> Max.   :95.0   Max.    :201   Max.    :121   Max.    :193   Max.    :132.8
#> NAs    :2      NAs     :2      NAs     :1      NAs     :1      NAs     :46
```

```
# Số giá trị bị chuyển thành khuyết do kiểm định
vars_checked <- c("age", "sbp_mmhg", "dbp_mmhg", "height_cm", "weight_kg")
n_invalid <- sum(is.na(raw[vars_checked])) -
  sum(is.na(raw_before_validation[vars_checked]))
n_invalid

#> [1] 7
```

Hãy đọc bản tóm tắt theo từng cột. Tuổi giờ đây nằm trong khoảng từ 18 đến 95, huyết áp tâm thu từ 90 đến 201 mmHg, huyết áp tâm trương từ 56 đến 121 mmHg, chiều cao từ khoảng 141 đến 193 cm (`summary()` làm tròn theo số chữ số có nghĩa mà nó hiển thị) và cân nặng từ 34,6 đến 132,8 kg. Mọi giá trị nhỏ nhất và lớn nhất đều đáng tin về mặt lâm sàng. Dòng NA's cho thấy cái giá phải trả: tuổi và huyết áp tâm thu mỗi biến có hai giá trị khuyết (hai giá trị không thể xảy ra), huyết áp tâm trương và chiều cao mỗi biến một, và cân nặng 46 (45 giá trị vốn đã khuyết cộng với giá trị 7 kg). Các giá trị trung bình hầu như không thay đổi, ngoại trừ huyết áp tâm thu, nơi giá trị 700 duy nhất đã kéo trung bình lên thêm một phần đáng kể của một milimét thủy ngân.

Có hai chi tiết của đoạn mã đáng lưu ý. `NA_real_` là giá trị khuyết của kiểu số; `if_else()` đòi hỏi cả hai kết quả của nó phải cùng kiểu, vì vậy một NA thông thường (vốn có kiểu logic) sẽ gây lỗi. Và điều kiện được viết sao cho một giá trị vốn đã khuyết vẫn tiếp tục khuyết: `NA >= 18` là NA, và `if_else()` trả về NA khi điều kiện của nó là NA.


Lỗi thường gặp

Đừng xóa cả bệnh nhân (cả dòng) chỉ vì một phép đo không thể xảy ra. Loại bỏ bệnh nhân có cân nặng 7 kg đồng nghĩa với việc loại bỏ cả tuổi, huyết áp, chẩn đoán và tình trạng điều trị hợp lệ của người đó, và mỗi lần xóa như vậy lại đẩy mẫu xa thêm khỏi quần thể. Hãy chuyển giá trị không thể xảy ra duy nhất đó thành NA và giữ lại phần còn lại của bản ghi.

2.7.4 Nhìn thấy tác động

Các hình vẽ làm cho tác động của việc kiểm định trở nên rõ ràng. Hình đầu tiên so sánh phân phối của huyết áp tâm thu trước và sau khi kiểm định.

```
bind_rows(  
  tibble(stage = "Trước kiểm định", sbp = raw_before_validation$sbp_mmhg),  
  tibble(stage = "Sau kiểm định", sbp = raw$sbp_mmhg)  
) |>  
  mutate(stage = fct_inorder(stage)) |>  
  ggplot(aes(x = sbp, y = stage)) +  
  geom_boxplot(fill = "#8FB8C4", outlier.colour = "#B03A2E", na.rm = TRUE) +  
  labs(x = "Huyết áp tâm thu (mmHg)", y = NULL,  
       title = "Huyết áp tâm thu trước và sau khi kiểm định")
```




Hình 2.2: Huyết áp tâm thu trước và sau khi kiểm định. Trước khi kiểm định, các giá trị 0 và 700 mmHg kéo giãn trực vượt xa phạm vi của dữ liệu hợp lý; sau khi kiểm định, phân phối hợp lý về mặt lâm sàng.

Trước khi kiểm định, một giá trị duy nhất 700 mmHg kéo giãn trực ra hơn ba lần phạm vi của dữ liệu thật, khiến cái hộp chứa một nửa số bệnh nhân ở giữa chỉ chiếm một phần nhỏ của hình, và giá trị 0 nằm trợt ở bên trái. Trong một biểu đồ tần suất hay một hình để công bố, chính hai giá trị đó còn làm méo thang đo nhiều hơn nữa. Sau khi kiểm định, cái hộp trải từ khoảng 126 đến 153 mmHg và các giá trị ngoại lai còn lại là những số đo cao có thật, là những bệnh nhân tăng huyết áp nặng mà một nghiên cứu về tăng huyết áp cần giữ lại hơn ai hết. Hình thứ hai thể hiện cùng ý tưởng đó cho tuổi, bằng biểu đồ tần suất (histogram).

```
bind_rows(
  tibble(stage = "Trước kiểm định", age = raw_before_validation$age),
  tibble(stage = "Sau kiểm định", age = raw$age)
) |>
mutate(stage = fct_inorder(stage)) |>
ggplot(aes(x = age)) +
  geom_histogram(binwidth = 5, fill = "#04242F", colour = "white",
    na.rm = TRUE) +
  facet_wrap(~ stage, ncol = 1, scales = "free_x") +
  labs(x = "Tuổi (năm)", y = "Số bệnh nhân",
    title = "Tuổi trước và sau khi kiểm định")
```

Tuổi trước và sau khi kiểm định



Hình 2.3: Phân phối tuổi trước và sau khi kiểm định. Các giá trị tuổi không thể xảy ra là 0 và 200 xuất hiện như những cột đơn độc trước khi kiểm định và không còn sau đó.

Diễn giải lâm sàng

Một khoảng giá trị hợp lý phát hiện được các giá trị không thể xảy ra, nhưng không phát hiện được các tổ hợp bất hợp lý. Một huyết áp tâm trương cao hơn huyết áp tâm thu, một người 20 tuổi có 110 tháng kể từ khi được chẩn đoán, hay một người nam được ghi là đang mang thai đều nằm trong khoảng hợp lý của từng biến riêng lẻ nhưng không thể cùng xảy ra. Sau khi kiểm tra khoảng giá trị, hãy nghĩ đến các **kiểm tra tính nhất quán giữa các biến** (cross-variable consistency checks) gợi ra từ ý nghĩa lâm sàng của dữ liệu (Bài tập 2.4 yêu cầu bạn thử một kiểm tra như vậy).

2.8 Mã hóa lại và tạo biến dẫn xuất

Nhiều biến dùng trong phân tích không được đo trực tiếp mà được **dẫn xuất** (derived) từ các biến khác: chỉ số khối cơ thể từ chiều cao và cân nặng, huyết áp động mạch trung bình từ huyết áp tâm thu và tâm trương, phân loại tăng huyết áp từ các số đo huyết áp, nhóm tuổi từ tuổi. Một biến dẫn xuất thừa hưởng mọi lỗi trong các biến đầu vào của nó, vì vậy nó phải được tính *sau khi* các biến đầu vào đã được kiểm định, và phải được đối chiếu với định nghĩa của nó.

2.8.1 Chỉ số khối cơ thể

Chỉ số khối cơ thể (body mass index, BMI) là cân nặng tính bằng kilogam chia cho bình phương chiều cao tính bằng mét:

$$\text{BMI} = \frac{\text{cân nặng (kg)}}{\text{chiều cao (m)}^2} = \frac{\text{cân nặng (kg)}}{(\text{chiều cao (cm)}/100)^2}$$

Tập thô đã có sẵn một cột bmi. Chúng ta có nên tin nó không? Hãy so sánh nó với BMI được tính lại từ chiều cao và cân nặng đã kiểm định.

```
bmi_check <- raw |>
  mutate(bmi_recalc = round(weight_kg / (height_cm / 100)^2, 1),
         diff = bmi - bmi_recalc)

# Giá trị BMI nào có sẵn trong mỗi phiên bản?
bmi_check |>
  count(supplied_missing = is.na(bmi), recalc_missing = is.na(bmi_recalc))
```

```
#> # A tibble: 4 × 3
#>   supplied_missing recalc_missing     n
#>   <lg1>           <lg1>         <int>
#> 1 FALSE          FALSE        1397
#> 2 FALSE          TRUE          43
#> 3 TRUE           FALSE          56
#> 4 TRUE           TRUE           4
```

```
# Khi cả hai cùng có, chúng có chênh nhau nhiều hơn mức làm tròn không?
bmi_check |>
  filter(abs(diff) > 0.1) |>
  select(patient_id, height_cm, weight_kg, bmi, bmi_recalc)
```

```
#> # A tibble: 1 × 5
#>   patient_id height_cm weight_kg   bmi bmi_recalc
#>   <chr>         <dbl>     <dbl> <dbl>     <dbl>
#> 1 PHC-0286     167.6       69.7  120      24.8
```

Bảng thứ nhất phân loại chéo các bệnh nhân theo việc mỗi phiên bản BMI có sẵn hay không. Với 1.397 bệnh nhân, cả hai đều có. Với 56 bệnh nhân, BMI có sẵn bị khuyết (ô trống hoặc giá trị canh gác 999) mặc dù chiều cao và cân nặng đã được ghi nhận, nên có thể khôi phục BMI bằng cách tính lại. Với 43 bệnh nhân thì ngược lại: BMI đã được cung cấp, nhưng cân nặng hoặc chiều cao đứng sau nó bị khuyết hoặc đã bị chuyển thành khuyết trong quá trình kiểm định (bao gồm cả những bệnh nhân có cân nặng 7 kg và chiều cao 17 cm). Một giá trị BMI không thể truy ngược về các phép đo của nó thì không thể kiểm tra, nên chúng ta không giữ lại. Bảng thứ hai cho thấy, trong số 1.397 bệnh nhân có cả hai phiên bản, chỉ một người có chênh lệch lớn hơn mức làm tròn: một BMI có sẵn là 120 kg/m², một giá trị không thể xảy ra, ở một bệnh nhân có chiều cao và cân nặng cho ra BMI 24,8. Bài học này mang tính tổng quát: **đừng bao giờ tin một biến dẫn xuất có sẵn; hãy tính lại nó từ các biến đầu vào đã được kiểm định.**

```
raw <- raw |>
  mutate(bmi = round(weight_kg / (height_cm / 100)^2, 1))

summary(raw$bmi)
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
#>      15.0   23.2   26.3   26.4   29.5   42.5     47
```

BMI được tính lại nằm trong khoảng từ 15,0 đến 42,5 kg/m², với trung vị 26,3 và 47 giá trị khuyết: 46 bệnh nhân không có cân nặng hợp lệ cộng với một bệnh nhân không có chiều cao hợp lệ.

2.8.2 Phân loại BMI

Để mô tả và cho một số phân tích, BMI được chia thành các nhóm theo định nghĩa của Tổ chức Y tế Thế giới (WHO).

Bảng 2.8: Phân loại BMI cho người trưởng thành của Tổ chức Y tế Thế giới.

Phân loại	BMI (kg/m ²)
Thiếu cân	dưới 18,5
Cân nặng bình thường	18,5 đến 24,9
Thừa cân	25,0 đến 29,9
Béo phì	từ 30,0 trở lên

Hàm `cut()` chia một biến liên tục thành các khoảng được xác định bởi các **điểm cắt** (break points). Với `breaks = c(-Inf, 18.5, 25, 30, Inf)` có bốn khoảng, và `labels` đặt tên cho chúng. Các nhãn được giữ bằng tiếng Anh vì chúng là giá trị lưu trong bộ dữ liệu dùng ở các chương sau: "Underweight" (thiếu cân), "Normal" (bình thường), "Overweight" (thừa cân) và "Obese" (béo phì).

```
raw <- raw |>
  mutate(bmi_cat = cut(bmi,
    breaks = c(-Inf, 18.5, 25, 30, Inf),
    labels = c("Underweight", "Normal",
      "Overweight", "Obese")))

table(raw$bmi_cat, useNA = "ifany")

#>
#> Underweight      Normal  Overweight      Obese      <NA>
#>           84         476         577         316         47
```

Một phân loại dẫn xuất luôn cần được đối chiếu với biến mà nó được tạo ra. Cách kiểm tra đơn giản nhất là xem khoảng BMI trong mỗi nhóm.

```
raw |>
  group_by(bmi_cat) |>
  summarise(n = n(), min_bmi = min(bmi), max_bmi = max(bmi)) |>
  knitr::kable(col.names = c("Phân loại BMI", "n", "BMI nhỏ nhất",
    "BMI lớn nhất"),
```

```
caption = "Khoảng BMI trong mỗi nhóm phân loại BMI dẫn xuất.")
```

Bảng 2.9: Khoảng BMI trong mỗi nhóm phân loại BMI dẫn xuất.

Phân loại BMI	n	BMI nhỏ nhất	BMI lớn nhất
Underweight	84	15.0	18.5
Normal	476	18.6	25.0
Overweight	577	25.1	30.0
Obese	316	30.1	42.5
NA	47	NA	NA

Mỗi nhóm bao phủ đúng phần mong đợi của thang BMI và các nhóm không chồng lấn nhau. Những bệnh nhân bị khuyết BMI rơi vào nhóm NA, đúng như phải thế: một biến đầu vào bị khuyết phải cho ra một phân loại bị khuyết, không bao giờ là một phân loại mặc định.

Lỗi thường gặp

Theo mặc định, `cut()` tạo ra các khoảng *đóng bên phải*: $(18.5, 25]$ bao gồm 25 nhưng không bao gồm 18,5. Vì vậy một BMI đúng bằng 25,0 được gán nhãn "Normal" và một BMI đúng bằng 18,5 được gán nhãn "Underweight", trong khi định nghĩa của WHO xếp 25,0 vào nhóm "Overweight" và 18,5 vào nhóm "Normal". Khi BMI được làm tròn đến một chữ số thập phân, sẽ có một vài bệnh nhân nằm đúng trên điểm cắt (trong dữ liệu của chúng ta là 21 bệnh nhân). Bộ dữ liệu sạch dùng trong cuốn sách này giữ cách mặc định để khớp với tệp được dùng ở các chương sau, nhưng trong công việc của riêng bạn, hãy thêm `right = FALSE` vào `cut()` để mỗi khoảng bao gồm giới hạn dưới của nó và các nhóm khớp chính xác với định nghĩa đã công bố. Bài tập 2.5 tìm hiểu sự khác biệt này.

2.8.3 Phân loại huyết áp

Huyết áp là phép đo trung tâm của nghiên cứu tình huống. Chúng ta tạo một biến phân loại ba mức từ huyết áp tâm thu và tâm trương đã đo. Theo ngưỡng quy ước 140/90 mmHg cho tăng huyết áp (World Health Organization 2021), một bệnh nhân được phân loại là "Hypertension" (tăng huyết áp) nếu huyết áp tâm thu ít nhất 140 mmHg *hoặc* huyết áp tâm trương ít nhất 90 mmHg; là "Elevated" (huyết áp tăng nhẹ) nếu không thỏa điều kiện trên nhưng huyết áp tâm thu ít nhất 130 hoặc tâm trương ít nhất 80; và là "Normal" (bình thường) trong các trường hợp còn lại. Vì `case_when()` dừng lại ở điều kiện đúng đầu tiên, thứ tự của các quy tắc tự động thực hiện logic "nếu không thỏa điều kiện trên" cho chúng ta.

```
raw <- raw |>
  mutate(bp_category = case_when(
    is.na(sbp_mmhg) | is.na(dbp_mmhg) ~ NA_character_, # cần cả hai số đo
    sbp_mmhg >= 140 | dbp_mmhg >= 90 ~ "Hypertension",
    sbp_mmhg >= 130 | dbp_mmhg >= 80 ~ "Elevated",
    TRUE ~ "Normal"
  ))

table(raw$bp_category, useNA = "ifany")
```

```
#>
#>      Elevated Hypertension      Normal      <NA>
#>          357          996          144          3
```

Quy tắc đầu tiên dễ bị quên nhưng lại thiết yếu. Nếu thiếu nó, một bệnh nhân bị huyết áp tâm thu và có huyết áp tâm trương 70 sẽ không thỏa hai quy tắc đầu (vì NA >= 140 là NA, mà case_when() coi là không đúng) và rơi xuống nhóm "Normal", một sự phân loại chỉ dựa trên một nửa thông tin. Có quy tắc này, ba bệnh nhân bị huyết áp một số đo được gán đúng một phân loại huyết.

Gần hai phần ba số bệnh nhân (996 trong 1.500) có huyết áp đo được nằm trong ngưỡng tăng huyết áp. Điều này không đáng ngạc nhiên: nghiên cứu tuyển chọn người trưởng thành đến khám tại tuyến chăm sóc ban đầu, nhiều người trong số họ đang được theo dõi vì tăng huyết áp đã biết. Hãy đối chiếu biến dẫn xuất với định nghĩa của nó, cả bằng con số lẫn bằng hình vẽ.

```
raw |>
  group_by(bp_category) |>
  summarise(n = n(),
            sbp_min = min(sbp_mmhg), sbp_max = max(sbp_mmhg),
            dbp_min = min(dbp_mmhg), dbp_max = max(dbp_mmhg)) |>
  knitr::kable(col.names = c("Phân loại", "n", "HATT min", "HATT max",
                             "HATTr min", "HATTr max"),
               caption = paste("Khoảng huyết áp trong mỗi nhóm dẫn xuất",
                              "(HATT: tâm thu; HATTr: tâm trương)."))
```


Bảng 2.10: Khoảng huyết áp trong mỗi nhóm dẫn xuất (HATT: tâm thu; HATTr: tâm trương).

Phân loại	n	HATT min	HATT max	HATTr min	HATTr max
Elevated	357	90	139	56	89
Hypertension	996	90	201	59	121
Normal	144	90	129	57	79
NA	3	NA	NA	NA	NA

Trong nhóm "Normal", mọi huyết áp tâm thu đều dưới 130 và mọi huyết áp tâm trương đều dưới 80, đúng như định nghĩa yêu cầu. Trong nhóm "Elevated", huyết áp tâm thu lớn nhất là 139 và tâm trương lớn nhất là 89, nên không có số đo tăng huyết áp nào lọt vào nhóm này. Nhóm "Hypertension" cần được đọc cẩn thận hơn: huyết áp tâm thu nhỏ nhất là 90 và huyết áp tâm trương nhỏ nhất là 59, điều có thể trông như một lỗi. Thực ra không phải, vì hai giá trị nhỏ nhất này đến từ những bệnh nhân khác nhau. Người có huyết áp tâm thu 90 thuộc nhóm này vì có huyết áp tâm trương ít nhất 90, và người có huyết áp tâm trương 59 thuộc nhóm này vì có huyết áp tâm thu ít nhất 140. Giá trị nhỏ nhất theo từng cột không thể kiểm tra một quy tắc "hoặc"; một hình vẽ thì có thể. (Cũng lưu ý rằng các nhóm được liệt kê theo thứ tự bảng chữ cái, vì bp_category vẫn đang là văn bản; chúng ta sẽ sửa thứ tự này ở Mục 2.10.)

```
raw |>
  filter(!is.na(bp_category)) |>
  mutate(bp_category = fct_relevel(bp_category, "Normal", "Elevated")) |>
  ggplot(aes(x = dbp_mmhg, y = sbp_mmhg, colour = bp_category)) +
  geom_point(alpha = 0.5, size = 1) +
  geom_hline(yintercept = c(130, 140), linetype = "dashed", colour = "grey40") +
```

```
geom_vline(xintercept = c(80, 90), linetype = "dashed", colour = "grey40") +
scale_colour_manual(values = c("#2E8B57", "#E0A800", "#B03A2E")) +
labs(x = "Huyết áp tâm trương (mmHg)",
y = "Huyết áp tâm thu (mmHg)", colour = "Phân loại",
title = "Các nhóm phân loại huyết áp dẫn xuất")
```



Hình 2.4: Huyết áp tâm thu theo huyết áp tâm trương, tô màu theo phân loại huyết áp dẫn xuất. Các đường nét đứt đánh dấu ngưỡng 130/80 và 140/90 mmHg; các nhóm tạo thành những vùng hình chữ L như mong đợi.

Các điểm tạo thành ba vùng rõ ràng được phân tách dọc theo các đường ngưỡng: màu xanh lá ở góc dưới bên trái (dưới 130 và dưới 80), màu hổ phách trong một dải hình chữ L và màu đỏ ở mọi nơi phía trên hoặc bên phải các đường 140/90. Không có điểm nào của một màu nằm trong vùng của màu khác. Loại hình này là một trong những cách nhanh nhất để phát hiện lỗi trong một phép dẫn xuất, chẳng hạn viết & ở chỗ lẽ ra phải là |.

Diễn giải lâm sàng

bp_category mô tả một lần đo huyết áp duy nhất vào ngày khảo sát, không phải một chẩn đoán. Một bệnh nhân đang điều trị hiệu quả có thể có số đo "Normal" mà vẫn mắc tăng huyết áp; một bệnh nhân bị tăng huyết áp "áo choàng trắng" có thể có một số đo cao đơn lẻ mà không mắc bệnh. Biến chẩn đoán của nghiên cứu là htn_diagnosed, và phân tích chính về việc sử dụng điều trị được giới hạn ở những bệnh nhân có htn_diagnosed == "Yes". Hãy giữ hai khái niệm này tách biệt khi mô tả kết quả.

2.9 Ngày tháng

2.9.1 Vì sao ngày tháng cần được phân tích cú pháp

Ngày tháng khó hơn về bề ngoài của chúng. Cùng một ngày có thể được viết là 2024-02-01, 01/02/2024, 02/01/2024, 1-Feb-2024 hoặc 1 February 2024, và một số cách viết trong đó

là mơ hồ: 01/02/2024 là ngày 1 tháng 2 ở phần lớn thế giới (kể cả Việt Nam) nhưng là ngày 2 tháng 1 ở Hoa Kỳ. Văn bản trông giống ngày tháng chưa phải là ngày tháng đối với R cho đến khi nó được **phân tích cú pháp** (parse) thành kiểu Date của R, kiểu lưu số ngày tính từ ngày 1 tháng 1 năm

1. Chỉ khi đó các ngày mới có thể được sắp xếp theo thứ tự thời gian, trừ nhau để ra khoảng thời

gian, hay được nhóm theo tháng.

Hãy xem các định dạng trong `enroll_date` (ngày tuyển chọn). Một cách nhanh để thấy các mẫu định dạng, thay vì các giá trị, là thay mọi chữ số bằng 9.

```
head(raw$enroll_date, 8)
```

```
#> [1] "01/02/2024" "2024-09-03" "2024-11-26" "2024-10-23" "2024-06-03"
#> [6] "2024-04-22" "08/08/2024" "18/02/2024"
```

```
# Thay chữ số bằng 9 để làm lộ ra các định dạng được sử dụng
raw |>
  mutate(pattern = str_replace_all(enroll_date, "[0-9]", "9"),
         pattern = str_replace(pattern, "[A-Za-z]{3}", "Mon")) |>
  count(pattern)
```

```
#> # A tibble: 3 × 2
#>   pattern      n
#>   <chr>    <int>
#> 1 99-Mon-9999  103
#> 2 99/99/9999  347
#> 3 9999-99-99 1050
```

Có ba định dạng: định dạng chuẩn quốc tế YYYY-MM-DD (1.050 bản ghi), định dạng ngày trước DD/MM/YYYY (347 bản ghi) và một định dạng có tên tháng viết tắt, DD-Mon-YYYY (103 bản ghi). Vì nghiên cứu được thực hiện ở một quốc gia viết ngày trước tháng, chúng ta hiểu 01/02/2024 là ngày 1 tháng 2 năm 2024.

2.9.2 Phân tích cú pháp bằng lubridate

Gói lubridate giúp việc phân tích cú pháp ngày tháng trở nên đơn giản (Grolemund and Wickham 2011). Các hàm của nó được đặt tên theo thứ tự các thành phần: `ymd()` phân tích năm-tháng-ngày, `dmy()` phân tích ngày-tháng-năm, v.v. Với một cột trộn lẫn nhiều định dạng, `parse_date_time()` chấp nhận nhiều **thứ tự** (orders) và lần lượt thử từng thứ tự cho mỗi giá trị. Hàm này trả về một giá trị ngày-giờ, và `as_date()` chuyển nó thành một ngày đơn thuần.

```
raw <- raw |>
  mutate(enroll_date = parse_date_time(
    enroll_date,
    orders = c("ymd", "dmy", "d-b-Y") # năm trước, ngày trước, ngày-Mon-năm
  ) |> as_date())

class(raw$enroll_date)
```

```
#> [1] "Date"
```

```
sum(is.na(raw$enroll_date)) # các giá trị không phân tích được
```

```
#> [1] 0
```

```
range(raw$enroll_date)
```

```
#> [1] "2024-01-08" "2024-12-02"
```

Cả 1.500 ngày đều được phân tích, không có giá trị nào thất bại, và cột này giờ có lớp Date. Khoảng thời gian, từ ngày 8 tháng 1 đến ngày 2 tháng 12 năm 2024, phù hợp với một nghiên cứu được tiến hành trong một năm dương lịch. Một ngày nằm ngoài thời gian nghiên cứu (ví dụ, năm 2042 do lỗi gõ, hoặc năm 1924 do năm được viết bằng hai chữ số) sẽ lộ ra ngay trong khoảng này và cần được điều tra.

Lỗi thường gặp

Luôn kiểm tra cách các ngày mơ hồ đã được diễn giải. Nếu `orders` liệt kê "mdy" trước "dmy", thì 01/02/2024 sẽ được đọc là ngày 2 tháng 1, trong khi các ngày như 15/03/2024 (không thể là tháng trước) vẫn được đọc đúng, nên lỗi sẽ diễn ra âm thầm với phần lớn các giá trị. Hãy quyết định quy ước dựa trên hiểu biết về nơi và cách dữ liệu được ghi nhận, liệt kê thứ tự đó một cách tường minh, và kiểm tra khoảng thời gian cùng một vài giá trị riêng lẻ sau đó.

2.9.3 Sử dụng ngày tháng


Sau khi được phân tích cú pháp, ngày tháng hoạt động như những con số trên một thang thời gian. Hình dưới đây đếm số lượt tuyển chọn theo tháng, dùng `floor_date()` để làm tròn mỗi ngày xuống ngày đầu tiên của tháng đó.

```
raw |>
  mutate(month = floor_date(enroll_date, "month")) |>
  count(month) |>
  ggplot(aes(x = month, y = n)) +
  geom_col(fill = "#04242F") +
  scale_x_date(date_labels = "%m", date_breaks = "1 month") +
  labs(x = "Tháng tuyển chọn (2024)", y = "Số bệnh nhân được tuyển chọn",
       title = "Tiến độ tuyển chọn theo thời gian")
```

Việc tuyển chọn diễn ra đều đặn từ tháng 1 đến tháng 11, và số ít lượt tuyển chọn trong tháng 12 phản ánh việc kết thúc tuyển chọn vào ngày 2 tháng 12 chứ không phải một vấn đề. Một hình như thế này tự nó đã là một phép kiểm tra chất lượng dữ liệu hữu ích: một tháng không có lượt tuyển chọn nào, hay một đỉnh tăng đột ngột, có thể phản ánh một sự kiện có thật (một cơ sở đóng cửa, một đợt tăng cường tuyển chọn) hoặc một vấn đề với ngày tháng.

2.10 Factor, thứ tự mức và nhóm tham chiếu

Tiến độ tuyển chọn theo thời gian



Hình 2.5: Số bệnh nhân được tuyển chọn mỗi tháng trong năm 2024. Từ tháng 1 đến tháng 11, mỗi tháng có từ 118 đến 152 bệnh nhân được tuyển chọn; việc tuyển chọn kết thúc vào những ngày đầu tháng 12.

2.10.1 Vì sao cần factor

Bước cấu trúc cuối cùng là chuyển các biến phân loại từ văn bản thành **factor**. Một factor lưu một tập hợp các danh mục được phép, gọi là các **mức** (levels), theo một thứ tự xác định. Có ba điều phụ thuộc vào thứ tự đó:

- 1. Bảng và hình.** Bảng tần số và biểu đồ cột liệt kê các danh mục theo thứ tự mức. Nếu để tự nhiên, R sắp xếp các mức theo thứ tự bảng chữ cái, cho ra "Heavy", "Moderate", "None" với rượu bia và "Current", "Former", "Never" với hút thuốc: những thứ tự làm cho bảng khó đọc hơn.
- 2. Thông tin thứ bậc.** Với trình độ học vấn và hoạt động thể lực, thứ tự là một phần của ý nghĩa. Một **factor có thứ tự** (ordered factor) ghi nhận rằng None < Primary < Secondary < Tertiary (không đi học < tiểu học < trung học < sau trung học), để R có thể sắp xếp và so sánh các danh mục một cách chính xác.
- 3. Nhóm tham chiếu trong hồi quy.** Khi một factor được dùng làm biến dự báo trong mô hình hồi quy, mức đầu tiên trở thành **nhóm tham chiếu** (reference category), và mỗi hệ số so sánh một mức khác với nhóm này. Khi một factor nhị phân là biến kết cục của hồi quy logistic, R mô hình hóa xác suất của mức *thứ hai*. Đặt sai thứ tự sẽ cho ra các tỷ số chênh là nghịch đảo của các tỷ số chênh mong muốn.

2.10.2 Thiết lập các mức của factor

Bây giờ chúng ta tạo bộ dữ liệu phân tích cuối cùng. Với các biến danh định không có thứ tự tự nhiên và không có nhóm tham chiếu hiển nhiên (facility, occupation, marital_status), thứ tự bảng chữ cái là chấp nhận được. Với mọi biến phân loại khác, chúng ta khai báo các mức một cách tường minh. Với các biến nhị phân, "No" đứng đầu để nó là nhóm tham chiếu và các mô hình ước lượng odds của "Yes". Với hút thuốc và rượu bia, nhóm "không phơi nhiễm" (Never, None) đứng đầu, và với huyết áp, nhóm "Normal" đứng đầu.

```
analysis_data <- raw |>
  mutate(
    facility      = factor(facility),
    sex           = factor(sex, levels = c("Female", "Male")),
    residence     = factor(residence, levels = c("Rural", "Urban")),
    education     = factor(education,
                          levels = c("None", "Primary",
                                     "Secondary", "Tertiary"),
                          ordered = TRUE),
    occupation    = factor(occupation),
    marital_status = factor(marital_status),
    physical_activity = factor(physical_activity,
                              levels = c("Low", "Moderate", "High"),
                              ordered = TRUE),
    smoking       = factor(smoking,
                          levels = c("Never", "Former", "Current")),
    alcohol       = factor(alcohol,
                          levels = c("None", "Moderate", "Heavy")),
    bp_category   = factor(bp_category,
                          levels = c("Normal", "Elevated",
                                     "Hypertension")),
    # Biến dự báo và biến kết cục nhị phân: nhóm tham chiếu "No" đứng đầu
    health_insurance = factor(health_insurance, levels = c("No", "Yes")),
    family_history_htn = factor(family_history_htn, levels = c("No", "Yes")),
    diabetes         = factor(diabetes, levels = c("No", "Yes")),
    htn_diagnosed    = factor(htn_diagnosed, levels = c("No", "Yes")),
    treatment_uptake = factor(treatment_uptake, levels = c("No", "Yes")),
    adherence        = factor(na_if(adherence, ""),
                              levels = c("Poor", "Good")),
    bp_controlled    = factor(na_if(bp_controlled, ""),
                              levels = c("No", "Yes"))
  )

glimpse(analysis_data)
```

```
#> Rows: 1,500
#> Columns: 38
#> $ patient_id      <chr> "PHC-1224", "PHC-1169", "PHC-1391", "PHC-011...
#> $ facility        <fct> Igoma HC, Kisesa HC, Bugando PHC, Ilemela H...
#> $ enroll_date     <date> 2024-02-01, 2024-09-03, 2024-11-26, 2024-1...
#> $ age             <dbl> 74, 56, 54, 33, 86, 70, 45, 59, 46, 61, 70,...
#> $ sex             <fct> Female, Female, Female, Female, Male, Male,...
#> $ residence       <fct> Urban, Urban, Urban, Urban, Urban, Urban, U...
#> $ education       <ord> Primary, Primary, None, Primary, Primary, P...
#> $ occupation      <fct> Trader, Professional, Farmer, Farmer, Unemp...
#> $ marital_status  <fct> Married, Married, Single, Single, Married, ...
#> $ health_insurance <fct> Yes, No, No, Yes, No, No, No, No, No, No, Y...
#> $ height_cm       <dbl> 164.6, 160.0, 152.8, 166.2, 182.0, 175.6, 1...
#> $ weight_kg       <dbl> 61.3, 68.3, 49.9, 78.5, 71.6, 97.4, 106.7, ...
#> $ bmi             <dbl> 22.6, 26.7, 21.4, 28.4, 21.6, 31.6, 38.9, 2...
#> $ smoking        <fct> Former, Current, Never, Never, Former, Neve...
#> $ alcohol         <fct> None, Moderate, Moderate, None, Heavy, Heav...
#> $ physical_activity <ord> Low, Low, Moderate, Low, High, Moderate, Mo...
#> $ family_history_htn <fct> Yes, Yes, Yes, Yes, No, No, No, No, Yes, No...
#> $ diabetes        <fct> No, No, No, No, No, No, No, No, No, No, No,...
#> $ sbp_mmhg        <dbl> 140, 185, 147, 124, 131, 153, 162, 108, 152...
```

```
#> $ dbp_mmhg <dbl> 92, 91, 85, 102, 95, 95, 100, 100, 87, 69, ...
#> $ total_chol_mmol_l <dbl> NA, 5.4, 5.4, 5.9, 4.8, 3.6, 5.3, 2.9, 6.0,...
#> $ hdl_mmol_l <dbl> 1.93, 0.70, 1.67, 0.65, 1.69, 1.20, 1.83, 1...
#> $ ldl_mmol_l <dbl> 3.5, NA, 2.3, 4.1, 2.4, 1.4, 2.2, NA, 3.4, ...
#> $ triglycerides_mmol_l <dbl> 1.0, 2.1, 2.7, 1.7, 2.0, 1.3, 1.0, 1.5, 2.5...
#> $ fasting_glucose_mmol_l <dbl> 6.6, 5.5, 6.0, 5.2, 5.1, 5.8, 5.5, 4.1, 6.2...
#> $ creatinine_umol_l <dbl> 61, 66, 75, 86, 87, 72, 103, 57, 98, 76, 99...
#> $ sodium_mmol_l <dbl> 134, 134, 139, 140, 142, 138, 141, 141, 140...
#> $ potassium_mmol_l <dbl> 4.1, 3.6, 4.4, 4.4, 4.2, 4.0, 4.5, 5.0, 4.7...
#> $ knowledge_score <dbl> 14, 7, 9, 12, NA, 12, 17, 8, 13, NA, 11, 6,...
#> $ distance_to_facility_km <dbl> 2.9, 10.5, 2.4, 2.2, 5.4, 6.7, 0.2, 0.4, 5....
#> $ comorbidity_count <dbl> 1, 0, 0, 0, 0, 1, 1, 0, 1, 1, 1, 1, 1, 0...
#> $ htn_diagnosed <fct> Yes, Yes, Yes, Yes, Yes, Yes, Yes, Yes, Yes...
#> $ months_since_diagnosis <dbl> 95, 87, 116, 31, 80, 28, 6, 96, 114, 53, 39...
#> $ treatment_uptake <fct> Yes, No, No, Yes, No, No, Yes, No, No, Yes,...
#> $ adherence <fct> Poor, NA, NA, Good, NA, NA, Good, NA, NA, P...
#> $ bp_controlled <fct> No, NA, NA, No, NA, NA, No, NA, NA, Yes, Ye...
#> $ bmi_cat <fct> Normal, Overweight, Normal, Overweight, Nor...
#> $ bp_category <fct> Hypertension, Hypertension, Hypertension, H...
```

`glimpse()` giờ cho thấy cấu trúc cuối cùng: 1.500 dòng và 38 cột (36 cột ban đầu cộng với `bmi_cat` và `bp_category`). Mã định danh là kiểu `character`, các phép đo là kiểu `double`, `enroll_date` là kiểu ngày tháng, và mọi biến phân loại đều là `factor`, hiển thị là `<fct>` hoặc, với hai `factor` có thứ tự, là `<ord>`.

Lỗi thường gặp

Khi bạn truyền đối số `levels` cho `factor()`, mọi giá trị không khớp *chính xác* với một trong các mức sẽ trở thành `NA`, mà không có cảnh báo nào. Nếu `residence` vẫn còn chứa `"Urban"` với một dấu cách ở đầu, hoặc `"urban"` viết thường, những bệnh nhân đó sẽ âm thầm mất thông tin nơi cư trú. Đây là lý do việc cắt khoảng trắng và mã hóa lại phải đi trước việc chuyển thành `factor`, và vì sao lần kiểm kê cuối cùng so sánh số giá trị khuyết trước và sau.

2.10.3 Kiểm tra các mức

Nên in ra các mức của các biến quan trọng để xác nhận thứ tự.

```
levels(analysis_data$treatment_uptake)
```

```
#> [1] "No" "Yes"
```

```
levels(analysis_data$education)
```

```
#> [1] "None" "Primary" "Secondary" "Tertiary"
```

```
levels(analysis_data$bp_category)
```

```
#> [1] "Normal" "Elevated" "Hypertension"
```

```
is.ordered(analysis_data$education)
```

R

```
#> [1] TRUE
```

Biến kết cục có "No" là mức đầu tiên, nên "Yes" là biến cố được mô hình hóa; trình độ học vấn là một factor có thứ tự đi từ "None" đến "Tertiary"; và các nhóm huyết áp đi từ "Normal" đến "Hypertension".

2.10.4 Vì sao nhóm tham chiếu quan trọng

Một minh họa ngắn cho thấy hệ quả của nhóm tham chiếu đối với một mô hình hồi quy. Chương 5 trình bày đầy đủ về hồi quy logistic; ở đây chúng ta chỉ xem tên và giá trị của các hệ số. Chúng ta mô hình hóa việc sử dụng điều trị theo giới tính ở những bệnh nhân đã được chẩn đoán, lần đầu với "Female" làm nhóm tham chiếu và sau đó với "Male".

```
diagnosed <- filter(analysis_data, htn_diagnosed == "Yes")
```

R

```
# Nhóm tham chiếu = Female (mức đầu tiên)
fit_f <- glm(treatment_uptake ~ sex, family = binomial, data = diagnosed)
round(exp(coef(fit_f)), 2)
```

```
#> (Intercept)      sexMale
#>          1.00          0.73
```

```
# Nhóm tham chiếu = Male, dùng relevel()
fit_m <- glm(treatment_uptake ~ relevel(sex, ref = "Male"),
             family = binomial, data = diagnosed)
round(exp(coef(fit_m)), 2)
```

R

```
#> (Intercept) relevel(sex, ref = "Male")Female
#>          0.73          1.37
```

Trong mô hình thứ nhất, hệ số được đặt tên là `sexMale`: đó là tỷ số chênh của nam giới so với nữ giới. Trong mô hình thứ hai, hệ số so sánh nữ giới với nam giới, và giá trị của nó là nghịch đảo của giá trị thứ nhất (một chia cho giá trị kia). Cả hai mô hình mô tả chính xác cùng một dữ liệu; chúng trả lời phép so sánh theo hai chiều ngược nhau. Trong một bài báo, một tỷ số chênh được báo cáo mà không kèm nhóm tham chiếu là không thể diễn giải, và một tỷ số chênh được tính với nhóm tham chiếu ngoài ý muốn có thể bị báo cáo ngược chiều. Thiết lập nhóm tham chiếu một cách có chủ đích trong quá trình làm sạch, và nêu rõ chúng trong mọi bảng, sẽ ngăn chặn cả hai lỗi này.

Thực hành tốt

Hãy chọn làm nhóm tham chiếu danh mục giúp phép so sánh trở nên tự nhiên nhất với người đọc: nhóm không phơi nhiễm (chưa bao giờ hút thuốc, không mắc đái tháo đường), nhóm phổ biến nhất, hoặc nhóm có mức thấp nhất của một biến thứ bậc. Tránh chọn một nhóm tham chiếu rất nhỏ, vì mọi phép so sánh với nhóm đó sẽ thiếu chính xác.

2.11 Kiểm định cuối cùng, lưu dữ liệu và nhật ký làm sạch

2.11.1 Kiểm kê dữ liệu khuyết lần cuối

Sau khi hoàn tất việc làm sạch, chúng ta lặp lại việc kiểm kê dữ liệu khuyết trên bộ dữ liệu phân tích.

```

missing_audit(analysis_data) |>
  filter(n_missing > 0) |>
  knitr::kable(col.names = c("Biến", "Số khuyết", "%"),
    caption = "Giá trị khuyết trong dữ liệu phân tích đã làm sạch.")
    
```

Bảng 2.11: Giá trị khuyết trong dữ liệu phân tích đã làm sạch.

Biến	Số khuyết	%
adherence	992	66.1
bp_controlled	992	66.1
ldl_mmol_l	105	7.0
total_chol_mmol_l	90	6.0
fasting_glucose_mmol_l	75	5.0
distance_to_facility_km	60	4.0
bmi	47	3.1
bmi_cat	47	3.1
weight_kg	46	3.1
smoking	45	3.0
knowledge_score	45	3.0
education	30	2.0
bp_category	3	0.2
age	2	0.1
sbp_mmhg	2	0.1
height_cm	1	0.1
dbp_mmhg	1	0.1

Hãy so sánh bảng này với bảng kiểm kê dữ liệu thô. Các biến khuyết do cấu trúc adherence và bp_controlled giờ có 992 giá trị khuyết thay vì 995, vì ba bản ghi trùng lặp đã bị loại bỏ. BMI có 47 giá trị khuyết thay vì 60, vì việc tính lại đã khôi phục những giá trị chỉ bị khuyết trong cột có sẵn. Cân nặng có thêm một giá trị khuyết (bản ghi 7 kg), và tuổi, huyết áp tâm thu, huyết áp tâm trương và chiều cao có thêm các giá trị bị chuyển thành khuyết trong quá trình kiểm định. Các biến dẫn xuất bmi_cat và bp_category có số giá trị khuyết đúng như các biến đầu vào của chúng cho phép suy ra. Không có biến nào có thêm giá trị khuyết một cách bất ngờ, điều này xác nhận rằng việc chuyển thành factor không làm mất dữ liệu nào.

2.11.2 Kiểm tra dữ liệu khuyết do cấu trúc

Chúng ta đã khẳng định rằng adherence và bp_controlled bị khuyết chính xác ở những bệnh nhân không điều trị. Đó là một khẳng định có thể kiểm tra được.

```

analysis_data |>
  count(treatment_uptake,
    adherence_missing = is.na(adherence),
    )
    
```

```
control_missing = is.na(bp_controlled))
```

```
#> # A tibble: 2 × 4
#>   treatment_uptake adherence_missing control_missing     n
#>   <fct>           <lgl>             <lgl>         <int>
#> 1 No             TRUE              TRUE           992
#> 2 Yes            FALSE             FALSE          508
```

Tất cả 992 bệnh nhân không điều trị đều bị khuyết cả hai biến, và tất cả 508 bệnh nhân đang điều trị đều có cả hai biến được ghi nhận. Việc khuyết hoàn toàn mang tính cấu trúc, và các phân tích về tuân thủ điều trị và kiểm soát huyết áp sẽ được giới hạn ở những bệnh nhân đang điều trị, nơi các biến này đầy đủ.

2.11.3 Kiểm tra tự động

Những phép kiểm tra mà chúng ta đã làm bằng mắt cũng có thể được viết thành các **khẳng định** (assertions): những mệnh đề phải đúng với dữ liệu sạch. `stopifnot()` không làm gì nếu mọi điều kiện của nó đều đúng và dừng lại với một thông báo lỗi nếu có điều kiện nào sai. Đặt các khẳng định ở cuối script làm sạch có nghĩa là nếu một phiên bản tương lai của tệp thô xuất hiện một vấn đề mới, script sẽ thất bại một cách rõ ràng thay vì âm thầm tạo ra dữ liệu sai.

```
ad <- analysis_data                                # tên ngắn để kiểm tra
stopifnot(
  nrow(ad) == 1500,                                # mỗi bệnh nhân một dòng
  n_distinct(ad$patient_id) == nrow(ad),            # mã định danh là duy nhất
  all(between(ad$age, 18, 110), na.rm = TRUE),      # tuổi trong khoảng hợp lý
  all(between(ad$sbp_mmhg, 70, 260), na.rm = TRUE), # HA tâm thu trong khoảng
  all(levels(ad$treatment_uptake) == c("No", "Yes")), # tham chiếu là "No"
  !anyNA(ad$sex),                                   # giới tính đã mã hóa đủ
  !anyNA(ad$enroll_date),                           # mọi ngày đều đã phân tích
  inherits(ad$enroll_date, "Date")
)
"Tất cả các phép kiểm tra đều đạt"
```

```
#> [1] "Tất cả các phép kiểm tra đều đạt"
```

2.11.4 Lưu dữ liệu sạch

Dữ liệu sạch được lưu ở hai định dạng. Định dạng `.rds` là định dạng riêng của R: nó lưu chính xác một đối tượng R, bao gồm các mức của factor, thứ tự của chúng, các factor có thứ tự và ngày tháng. Đọc lại bằng `readRDS()` sẽ cho ra đúng đối tượng ban đầu. Một bản sao `.csv` tiện lợi cho các đồng nghiệp dùng phần mềm khác, nhưng nó chỉ lưu văn bản, nên các mức của factor và kiểu ngày tháng phải được khai báo lại khi đọc vào. Trong cuốn sách này, bản sao dữ liệu sạch của dự án đã có sẵn trong `Data/analysis_data.rds`, vì vậy chúng ta minh họa việc lưu vào thư mục tạm của R. Trong script làm sạch của riêng bạn, bạn sẽ lưu vào thư mục dữ liệu của dự án, như trong các dòng được chú thích dưới đây.

```
# Trong một dự án thực tế:
#   saveRDS(analysis_data, "Data/analysis_data.rds")
```

```
# write_csv(analysis_data, "Data/analysis_data.csv")

# Ở đây ta lưu vào một thư mục tạm để không động chạm đến các tệp của dự án
out_rds <- file.path(tempdir(), "analysis_data.rds")
out_csv <- file.path(tempdir(), "analysis_data.csv")
saveRDS(analysis_data, out_rds)
write_csv(analysis_data, out_csv)

# Đọc lại và xác nhận không có gì bị mất sau vòng lưu - đọc
reloaded <- readRDS(out_rds)
identical(reloaded, analysis_data)

#> [1] TRUE
```

`identical()` trả về TRUE: đối tượng được lưu và đọc lại giống nhau ở mọi chi tiết. Điều này sẽ không đúng với tệp CSV, vì các factor của nó sẽ trở lại dưới dạng văn bản.

Thực hành tốt

Mọi script phân tích sau này đều nên bắt đầu bằng `analysis_data <- readRDS("Data/analysis_data.rds")` và không lấy thêm gì khác từ chương này. Nếu bạn phát hiện một vấn đề dữ liệu mới trong lúc phân tích, hãy sửa nó trong script làm sạch, chạy lại script để tạo lại tệp sạch, rồi chạy lại các phân tích. Không bao giờ vá dữ liệu sạch bên trong một script phân tích.

2.11.5 Quy trình có tái lập được không?

Phép thử cuối cùng của hợp đồng làm sạch là khả năng tái lập: chạy mã của chúng ta trên tệp thô có cho ra chính xác bộ dữ liệu mà phần còn lại của cuốn sách sử dụng hay không?

```
reference <- readRDS("Data/analysis_data.rds")

dim(analysis_data)
```

```
#> [1] 1500 38
```

```
dim(reference)
```

```
#> [1] 1500 38
```

```
all.equal(analysis_data, reference)
```

```
#> [1] TRUE
```

Cả hai bộ dữ liệu đều có 1.500 dòng và 38 cột, và `all.equal()` báo TRUE: mọi giá trị, mọi kiểu dữ liệu và mọi mức của factor đều giống nhau. Bắt đầu từ một tệp thô lộn xộn và làm theo các bước của chương này, bất kỳ ai có R đều có thể tạo lại chính xác bộ dữ liệu phân tích. Đó là ý nghĩa của khả năng tái lập trong thực tế.

2.11.6 Nhật ký làm sạch

Cuối cùng, một **nhật ký làm sạch** (cleaning log) ghi lại những gì đã làm và mỗi bước đã thay đổi bao nhiêu giá trị. Đó là bản tóm tắt mà người phản biện, đồng tác giả hay chính bạn trong tương lai sẽ đọc đầu tiên, và nó cung cấp những con số cần thiết cho phần phương pháp của một bài báo.

```

cleaning_log <- tribble(
  ~step, ~action, ~records_affected,
  "1. Nhập dữ liệu", "Khai báo ' ', 'NA', '999', '-99' là khuyết",
    sum(na_compare$gained),
  "2. Trùng lặp", "Loại bỏ các dòng trùng lặp hoàn toàn",
    n_before - n_after,
  "3. Khoảng trắng", "Cắt dấu cách trong cột văn bản (ẩn khi nhập)",
    sum(raw_untrimmed$facility != str_trim(raw_untrimmed$facility),
      na.rm = TRUE),
  "4. Giới tính", "Mã hóa lại 8 cách viết thành Female/Male",
    sum(sex_before != as.character(analysis_data$sex)),
  "5. Kiểm định", "Chuyển tuổi, HA, chiều cao, cân nặng ngoài khoảng thành NA",
    n_invalid,
  "6. BMI", "Tính lại từ chiều cao và cân nặng đã kiểm định",
    sum(is.na(bmi_check$bmi) & !is.na(bmi_check$bmi_recalc)),
  "7. Ngày tháng", "Phân tích 3 định dạng ngày; số lỗi",
    sum(is.na(analysis_data$enroll_date))
)

knitr::kable(cleaning_log,
  col.names = c("Bước", "Thao tác", "Số bản ghi bị ảnh hưởng"),
  caption = "Nhật ký làm sạch dữ liệu nghiên cứu tình huống.")
    
```

Bảng 2.12: Nhật ký làm sạch dữ liệu nghiên cứu tình huống.

Bước	Thao tác	Số bản ghi bị ảnh hưởng
1. Nhập dữ liệu	Khai báo " ", 'NA', '999', '-99' là khuyết	97
2. Trùng lặp	Loại bỏ các dòng trùng lặp hoàn toàn	3
3. Khoảng trắng	Cắt dấu cách trong cột văn bản (ẩn khi nhập)	108
4. Giới tính	Mã hóa lại 8 cách viết thành Female/Male	336
5. Kiểm định	Chuyển tuổi, HA, chiều cao, cân nặng ngoài khoảng thành NA	7
6. BMI	Tính lại từ chiều cao và cân nặng đã kiểm định	56
7. Ngày tháng	Phân tích 3 định dạng ngày; số lỗi	0

Mỗi dòng của nhật ký tương ứng với một mục của chương này. Bước 3 đếm các giá trị của biến cơ sở có mang dấu cách ẩn (các cột văn bản khác có số lượng tương tự). Bước 4 đếm 336 giá trị của sex có cách viết đã thay đổi. Bước 6 đếm những bệnh nhân có BMI bị khuyết trong cột có sẵn nhưng có thể khôi phục được từ chiều cao và cân nặng. Mọi con số trong nhật ký đều được tính bằng mã chứ không gõ bằng tay, vì vậy nhật ký tự cập nhật nếu dữ liệu thô thay đổi và script được chạy lại.

2.12 Tóm tắt

Làm sạch dữ liệu biến một tệp thô, với mọi khiếm khuyết của quá trình thu thập dữ liệu thực tế, thành một bộ dữ liệu sẵn sàng phân tích. Đó là một phần của khoa học, chứ không phải một việc vặt cần làm vội vàng, và nó phải được thực hiện bằng mã để mọi quyết định đều hiển hiện và có thể lặp lại. Trong chương này, chúng ta đã nhập tệp thô của nghiên cứu tình huống đồng thời khai báo các mã giá trị khuyết, qua đó khôi phục 97 giá trị khuyết bị ẩn và loại bỏ các giá trị cholesterol âm không thể xảy ra khỏi phép tính trung bình. Chúng ta đã tìm hiểu ba cơ chế của dữ liệu khuyết, MCAR, MAR và MNAR, thấy vì sao phân tích trên các trường hợp đầy đủ là một giả định chứ không phải một mặc định trung lập, và tạo một bảng kiểm kê dữ liệu khuyết tách biệt các giá trị thực sự bị khuyết với các giá trị khuyết do cấu trúc. Chúng ta đã loại bỏ ba bản ghi trùng lặp, cắt các dấu cách ẩn, gộp tám cách viết của giới tính và ba cách mã hóa của năm biến Yes/No, và chuyển bảy phép đo không thể xảy ra thành giá trị khuyết bằng các khoảng giá trị hợp lý tường minh. Chúng ta đã tính lại BMI từ các biến đầu vào đã kiểm định, tạo các biến phân loại BMI và huyết áp rồi đối chiếu chúng với định nghĩa, phân tích ba định dạng ngày tháng, và thiết lập các mức của factor cùng các nhóm tham chiếu một cách có chủ đích. Cuối cùng, chúng ta đã kiểm kê kết quả, viết các khẳng định, lưu dữ liệu và cho thấy quy trình của mình tái tạo chính xác bộ dữ liệu phân tích của cuốn sách.

Điểm chính

- Không bao giờ chỉnh sửa dữ liệu thô bằng tay. Một script làm sạch đọc tệp thô và lưu một tệp sạch là bản ghi có thể tái lập của mọi quyết định.
- Khai báo các mã giá trị khuyết như 999 và -99 ngay khi nhập bằng `na = c(...)`, sau khi đã kiểm tra rằng không có biến nào thực sự có thể nhận các giá trị đó.
- Dữ liệu khuyết có thể là MCAR, MAR hoặc MNAR. Phân tích trên các trường hợp đầy đủ không bị sai lệch khi dữ liệu là MCAR nhưng có thể bị sai lệch trong các trường hợp khác; quy nạp đa trị là phương pháp chuẩn khi dữ liệu là MAR. Hãy phân biệt các giá trị khuyết do cấu trúc ("không áp dụng") với các giá trị thực sự bị khuyết.
- Phát hiện bản ghi trùng lặp bằng cách so sánh số dòng với số mã khác nhau; loại bỏ trùng lặp hoàn toàn bằng `distinct()`, điều tra các trùng lặp mâu thuẫn, và báo cáo những gì đã bị loại bỏ.
- Chuẩn hóa văn bản bằng `str_trim()` và `str_to_lower()`, mã hóa lại bằng `case_when()` (ánh xạ các giá trị không nhận ra thành NA), và dùng các hàm trợ giúp cùng `across()` cho các công việc lặp lại. Luôn lập bảng chéo giữa giá trị cũ và giá trị mới.
- Kiểm định các biến liên tục theo các khoảng giá trị hợp lý tường minh và chuyển các giá trị không thể xảy ra, chứ không phải cả bệnh nhân, thành NA.
- Tính lại các biến dẫn xuất từ các biến đầu vào đã kiểm định và đối chiếu mọi phân loại dẫn xuất với định nghĩa của nó.
- Phân tích cú pháp ngày tháng bằng `lubridate`, quyết định thứ tự cho các ngày mơ hồ dựa trên hiểu biết về dữ liệu, và kiểm tra khoảng thời gian thu được.
- Thiết lập các mức của factor và nhóm tham chiếu một cách có chủ đích: chúng quyết định cách trình bày bảng và chiều của mọi phép so sánh trong hồi quy.
- Kết thúc bằng một lần kiểm kê, các khẳng định, một tệp `.rds` đã lưu và một nhật ký làm sạch.

2.13 Đọc thêm

- Wickham (2014): bài báo định nghĩa dữ liệu gọn gàng; ngắn gọn, rõ ràng và là nền tảng của cách tiếp cận tidyverse trong tổ chức dữ liệu được dùng xuyên suốt cuốn sách này.
- Broman and Woo (2018): các quy tắc thực tế, được trích dẫn rộng rãi, về tổ chức dữ liệu trong bảng tính; vô cùng hữu ích nếu bạn tham gia thiết kế việc thu thập dữ liệu chứ không chỉ phân tích kết quả.
- Wilson et al. (2017): một bộ thực hành "đủ tốt" ngắn gọn về quản lý dữ liệu, mã nguồn và tổ chức dự án mà bất kỳ nhóm nghiên cứu nào cũng có thể áp dụng.
- Sterne et al. (2009): một hướng dẫn dễ tiếp cận dành cho các nhà nghiên cứu lâm sàng về tiềm năng và những cạm bẫy của quy nạp đa trị, kèm theo khuyến nghị về cách báo cáo dữ liệu khuyết.
- Little and Rubin (2019): tài liệu tham khảo chuẩn về lý thuyết dữ liệu khuyết, dành cho người đọc muốn đi xa hơn phần giới thiệu ở đây.

2.14 Bài tập

Bài tập 2.1

Mã giá trị khuyết. Nhập `Data/hypertension_phc_raw.csv` hai lần: một lần với các thiết lập mặc định của `read_csv()` và một lần với `na = c("", "NA", "999", "-99")`.

1. Với glucose lúc đói, hãy báo cáo trung bình, trung vị và giá trị lớn nhất trong mỗi lần nhập. Thống kê tóm tắt nào bị ảnh hưởng nhiều nhất bởi giá trị cạnh góc, và vì sao?
2. `fasting_glucose_mmol_l` có bao nhiêu giá trị khuyết trong mỗi lần nhập?
3. Giả sử một phòng xét nghiệm gửi các giá trị creatinine trong đó 999 là một kết quả đo thật. Bạn sẽ xử lý 999 như giá trị khuyết trong glucose nhưng không phải trong creatinine như thế nào?

Bài tập 2.2

Bản ghi trùng lặp. Sử dụng dữ liệu thô đã nhập (với các mã giá trị khuyết đã khai báo):

1. Dùng `count()` để tìm các mã bệnh nhân xuất hiện nhiều hơn một lần, và `janitor::get_dupes(patient_id)` để liệt kê các bản ghi của họ.
2. Xác nhận rằng các bản ghi trùng lặp là bản sao chính xác bằng cách so sánh `sum(duplicated(raw))` với số mã thừa.
3. Viết một câu, phù hợp cho phần phương pháp của một bài báo, báo cáo cách xử lý các bản ghi trùng lặp.

Bài tập 2.3

Chuẩn hóa danh mục. Bắt đầu lại từ dữ liệu thô đã nhập:

1. Lập bảng tần số cho `health_insurance` và `htn_diagnosed` với `useNA = "ifany"`.

Mỗi biến dùng bao nhiêu mã khác nhau?

2. Áp dụng hàm trợ giúp `to_yesno()` cho cả hai biến và lập bảng chéo giữa giá trị cũ và mới để kiểm tra phép ánh xạ.
3. Trong dữ liệu sạch, tỷ lệ bệnh nhân có bảo hiểm y tế là bao nhiêu, và tỷ lệ đã được chẩn đoán tăng huyết áp là bao nhiêu?

Bài tập 2.4

Tính nhất quán giữa các biến. Đọc dữ liệu sạch bằng `analysis_data <- readRDS("Data/analysis_data.rds")`.

1. Đếm số bệnh nhân có huyết áp tâm trương lớn hơn hoặc bằng huyết áp tâm thu. Điều đó có khả thi về mặt sinh lý không?
2. Hiệu áp (pulse pressure) là huyết áp tâm thu trừ huyết áp tâm trương. Hãy tóm tắt biến này, và đếm số bệnh nhân có hiệu áp dưới 20 mmHg.
3. Kiểm tra một quy tắc nhất quán khác từ từ điển dữ liệu: những bệnh nhân không được chẩn đoán tăng huyết áp phải có `months_since_diagnosis` bằng 0, và tuân thủ điều trị chỉ được ghi nhận cho những bệnh nhân đang điều trị. Dữ liệu có thỏa mãn cả hai quy tắc không?

Bài tập 2.5

BMI và điểm cắt. Sử dụng `analysis_data`:

1. Tạo lại `bmi_cat` bằng `cut()` với `right = FALSE`, để mỗi khoảng bao gồm giới hạn dưới của nó như trong định nghĩa của WHO.
2. Lập bảng chéo giữa hai phiên bản. Có bao nhiêu bệnh nhân thay đổi nhóm, và những giá trị BMI nào là nguyên nhân?
3. Tạo một biến nhóm tuổi với các nhóm 18–39, 40–59 và từ 60 trở lên, và kiểm tra nó bằng cách tóm tắt tuổi nhỏ nhất và lớn nhất trong mỗi nhóm.

Bài tập 2.6

Ngày tháng. Bắt đầu từ tệp thô:

1. Dùng `str_detect()` để đếm có bao nhiêu giá trị `enroll_date` thuộc mỗi định dạng trong ba định dạng.
2. Phân tích cú pháp các ngày bằng các thứ tự `c("ymd", "mdy", "d-b-Y")`, tức là đặt tháng trước thay vì ngày trước cho định dạng có dấu gạch chéo. Có bao nhiêu ngày không phân tích được, và bao nhiêu ngày được phân tích khác với các ngày trong `analysis_data`?
3. Sử dụng `analysis_data`, thêm một cột `enroll_quarter` bằng `quarter(enroll_date)` và đếm số bệnh nhân được tuyển chọn trong mỗi quý.

Bài tập 2.7

Tìm hiểu cơ chế khuyết. Sử dụng `analysis_data`:

1. Tạo một biến chỉ thị `chol_missing` nhận giá trị `TRUE` khi `total_chol_mmol_l` bị khuyết. So sánh tỷ lệ phần trăm bị khuyết cholesterol giữa những bệnh nhân đã và chưa được chẩn đoán tăng huyết áp, và giữa người sống ở nông thôn và thành thị.
2. So sánh tuổi trung bình của những bệnh nhân có và không bị khuyết cholesterol.
3. Dựa trên các kết quả này, giả định MCAR có hợp lý đối với cholesterol không? Dữ liệu này có thể cho bạn biết cholesterol có phải là MNAR hay không? Hãy giải thích.

Bài tập 2.8

Thử thách: một hàm làm sạch. Viết một hàm `clean_htn(path)` nhận đường dẫn của tệp CSV thô, thực hiện tất cả các bước làm sạch của chương này theo cùng thứ tự, và trả về dữ liệu sạch.

1. Chạy `clean_htn("Data/hypertension_phc_raw.csv")` và dùng `all.equal()` để so sánh kết quả với `readRDS("Data/analysis_data.rds")`.
2. Thêm ít nhất ba khẳng định `stopifnot()` bên trong hàm, ngay trước khi nó trả về kết quả, để hàm thất bại nếu dữ liệu thô có thêm một vấn đề mới.
3. Vì sao một hàm như thế này hữu ích hơn một script dài khi nhận được một tệp thô đã được sửa?

CHƯƠNG 3

Thống kê mô tả, bảng và hình

Mọi bài báo lâm sàng, dù các phân tích phía sau có phức tạp đến đâu, đều bắt đầu bằng cùng một đoạn văn khiêm tốn: *bệnh nhân là những ai?* Trước khi người đọc có thể đánh giá một mô hình hồi quy, một tỷ số chênh hay một giá trị p có ý nghĩa gì hay không, họ cần biết người tham gia bao nhiêu tuổi, bao nhiêu người là phụ nữ, huyết áp của họ cao đến mức nào, bao nhiêu người mắc đái tháo đường và bao nhiêu thông tin bị khuyết. Đoạn văn đó, cùng với "Bảng 1" đi kèm, là nền móng cho mọi kết luận suy luận. Nếu phần mô tả sai, cấu tả hoặc che giấu hình dạng của dữ liệu, thì không có gì phía sau đáng tin cậy.

Chương này hướng dẫn bạn mô tả một bộ dữ liệu lâm sàng một cách đúng đắn, bằng cả con số lẫn hình ảnh. Chúng ta bắt đầu từ tệp phân tích đã làm sạch ở Chương 2 và lần lượt tìm hiểu lý thuyết về các thống kê tóm tắt (trung bình, độ lệch chuẩn hay khoảng tứ phân vị thực sự đo cái gì, và khi nào nên chọn từng loại), sau đó trình bày cách tính chúng trong R, cách xây dựng Bảng 1 sẵn sàng cho bản thảo bằng **gtsummary**, và cách vẽ các hình trung thực, đạt chất lượng xuất bản bằng **ggplot2**. Trên đường đi, chúng ta sẽ gặp sai số chuẩn (standard error) và khoảng tin cậy (confidence interval), cây cầu nối từ việc mô tả một mẫu sang việc đưa ra nhận định về một quần thể, vốn là chủ đề của Chương 4.

Mục tiêu học tập

- Giải thích vì sao mô tả cẩn thận phải đi trước mọi kiểm định thống kê, và một "Bảng 1" cần chứa những gì.
- Ghép mỗi loại biến (liên tục, rời rạc, nhị phân, danh định, thứ bậc) với các cách tóm tắt bằng số và bằng hình phù hợp.
- Định nghĩa và tính trung bình, trung vị, yếu vị, khoảng biến thiên, phương sai, độ lệch chuẩn, phân vị, khoảng tứ phân vị và hệ số biến thiên, đồng thời giải thích các tính chất của chúng.
- Đánh giá hình dạng của một phân phối (tính đối xứng, độ lệch, tính chuẩn) và quyết định dùng trung bình (SD) hay trung vị (IQR).
- Tránh cái bẫy `na.rm` và báo cáo số quan sát đứng sau mọi thống kê tóm tắt.
- Tạo các bảng tóm tắt theo nhóm bằng `dplyr::group_by()` và `summarise()`.
- Tính và diễn giải sai số chuẩn và khoảng tin cậy 95% cho một trung bình và cho một tỷ lệ.
- Xây dựng bảng tần số và bảng chéo, và chọn đúng giữa tỷ lệ phần trăm theo hàng và theo cột.

- Xây dựng Bảng 1 cho bản thảo bằng `gtsummary::tbl_summary()`.
- Vẽ biểu đồ tần suất (histogram), biểu đồ mật độ, biểu đồ cột, biểu đồ hộp và biểu đồ violin, biểu đồ phân tán và biểu đồ chia ô (facet) bằng `ggplot2`, theo các nguyên tắc của đồ họa khoa học tốt.
- Xuất bảng và hình cho bản thảo.

3.1 Vì sao phải mô tả trước khi kiểm định?

Thống kê mô tả tóm tắt dữ liệu mà bạn thực sự có. Chúng không đưa ra nhận định nào về một quần thể rộng hơn và không liên quan đến giả thuyết nào; nhiệm vụ của chúng là *cho thấy*. Thống kê suy luận (khoảng tin cậy, kiểm định giả thuyết, mô hình hồi quy) tiến thêm một bước và dùng mẫu để nói điều gì đó về quần thể mà mẫu được rút ra. Người ta dễ bị cám dỗ lao ngay sang bước suy luận, vì đó dường như là nơi chứa "kết quả". Những nhà phân tích giàu kinh nghiệm làm điều ngược lại: họ dành một phần lớn thời gian cho việc mô tả, vì ít nhất bốn lý do.

- 1. Mô tả là kết quả đầu tiên.** Các hướng dẫn báo cáo cho nghiên cứu quan sát đòi hỏi điều này. Mục 13 của tuyên bố STROBE yêu cầu tác giả báo cáo số người ở mỗi giai đoạn của nghiên cứu, và mục 14 yêu cầu trình bày đặc điểm của người tham gia (nhân khẩu học, lâm sàng, xã hội) cùng với số người tham gia bị khuyết dữ liệu ở từng biến quan tâm (Elm et al. 2007). Trong thực tế, điều này trở thành đoạn đầu tiên của phần Kết quả và Bảng 1 của bài báo.
- 2. Mô tả phát hiện vấn đề.** Tuổi tối đa là 200, huyết áp tâm thu bằng 0, một giá trị xét nghiệm 999 thực ra là mã cho giá trị khuyết: những điều này được phát hiện nhờ tóm tắt, chứ không phải nhờ kiểm định. Chương 2 đã làm sạch các lỗi hiển nhiên, nhưng việc mô tả dữ liệu đã làm sạch là bước kiểm tra cuối cùng để chắc chắn rằng việc làm sạch đã thành công.
- 3. Mô tả định hướng việc chọn phân tích.** Một biến đối xứng hay lệch, một nhóm hiếm đến mức phải gộp với nhóm khác, một biến dự báo có 30% giá trị khuyết: những sự thật này quyết định kiểm định và mô hình nào sẽ phù hợp về sau (Altman 1991; Kirkwood and Sterne 2003).
- 4. Mô tả giúp người đọc đánh giá khả năng khái quát hóa.** Tỷ lệ sử dụng điều trị ở những bệnh nhân chăm sóc ban đầu có tuổi trung bình 50, phần lớn là phụ nữ và phần lớn không có bảo hiểm, có thể không áp dụng được cho một phòng khám bệnh viện gồm những nam giới trẻ hơn và có bảo hiểm. Người đọc chỉ có thể đánh giá điều này nếu bạn cho họ biết ai đã được nghiên cứu.

Diễn giải lâm sàng

Hãy coi Bảng 1 như danh sách bệnh nhân mà một bác sĩ lâm sàng muốn xem trước khi đọc kết luận của bạn. Nó trả lời câu hỏi "những bệnh nhân này có giống bệnh nhân của tôi không?". Một thử nghiệm hay một cuộc điều tra mà người tham gia được mô tả sơ sài thì không thể áp dụng an toàn vào thực hành, dù giá trị p của nó nhỏ đến đâu.

3.1.1 Chuẩn bị

Như ở mọi chương, chúng ta nạp các gói và đọc tệp phân tích đã làm sạch được lưu ở cuối Chương 2. Vì biến kết cục chính, `treatment_uptake`, chỉ có ý nghĩa đối với những bệnh nhân đã được chẩn đoán tăng huyết áp, chúng ta cũng tạo ngay quần thể phân tích `diagnosed` và dùng nó mỗi khi có liên quan đến biến kết cục.

```
library(tidyverse) # dplyr, ggplot2, tidyr, readr, ...
library(gtsummary) # Bảng 1 và các bảng tóm tắt khác
library(janitor) # tabyl() và adorn_*() cho bảng tần số
library(knitr) # kable() cho các bảng đơn giản
library(scales) # định dạng phần trăm cho trục và nhãn
library(patchwork) # ghép nhiều ggplot thành một hình

# Đọc dữ liệu sẵn sàng phân tích đã tạo ở Chương 2
analysis_data <- readRDS("Data/analysis_data.rds")

# Quần thể phân tích cho biến kết cục chính: người đã chẩn đoán tăng huyết áp
diagnosed <- analysis_data |>
  filter(htn_diagnosed == "Yes")

# Một màu được định nghĩa một lần và dùng lại trong mọi hình
teal <- "#0D7377"

c(all_patients = nrow(analysis_data), diagnosed = nrow(diagnosed))

#> all_patients      diagnosed
#>           1500           1089
```

Toàn bộ dữ liệu gồm 1500 người trưởng thành đến khám tại sáu cơ sở chăm sóc sức khỏe ban đầu, trong đó 1089 người đã được chẩn đoán tăng huyết áp. Hãy ghi nhớ cả hai con số: con số thứ nhất mô tả tất cả những người được tuyển vào, con số thứ hai là mẫu số cho các nhận định về việc sử dụng điều trị. Một nguồn gây nhầm lẫn phổ biến trong bản thảo là một tỷ lệ phần trăm không bao giờ nêu rõ mẫu số; trong suốt chương này chúng ta sẽ luôn nêu rõ.

Lỗi thường gặp

Dữ liệu là dữ liệu mô phỏng phục vụ giảng dạy. Mọi con số trong chương này chỉ minh họa một phương pháp; không con số nào là phát hiện lâm sàng thực tế về chăm sóc tăng huyết áp ở bất kỳ quốc gia hay cơ sở nào.

3.2 Các loại biến và cách tóm tắt phù hợp

Cách tóm tắt đúng phụ thuộc vào loại biến. Chương 2 đã giới thiệu các loại biến từ góc độ cách lưu trữ trong R (numeric, character, factor). Ở đây chúng ta xem xét chúng từ góc độ *đo lường*, vốn là yếu tố quyết định thống kê nào được dùng (Altman 1991; Kirkwood and Sterne 2003, ch. 2).

- **Biến số (định lượng)** nhận các giá trị số mà hiệu số giữa chúng có ý nghĩa.
 - Biến *liên tục* về nguyên tắc có thể nhận bất kỳ giá trị nào trong một khoảng: tuổi, huyết

áp tâm thu (systolic blood pressure, SBP), chỉ số khối cơ thể (body mass index, BMI), cholesterol, glucose, khoảng cách đến cơ sở y tế.

- Biến *rời rạc* là các số đếm: số bệnh đồng mắc, số lần khám. Chúng thường được tóm tắt như biến liên tục khi nhận nhiều giá trị, và như biến phân loại khi chỉ nhận vài giá trị.

• **Biến phân loại (định tính)** xếp mỗi người vào một trong một tập hợp các nhóm.

- Biến *nhị phân* (dichotomous) có hai nhóm: đái tháo đường có/không, sử dụng điều trị có/không.
- Biến *danh định* (nominal) có nhiều hơn hai nhóm và không có thứ tự tự nhiên: cơ sở y tế, nghề nghiệp, tình trạng hôn nhân.
- Biến *thứ bậc* (ordinal) có các nhóm được sắp thứ tự: học vấn (không đi học < tiểu học < trung học < sau trung học), hoạt động thể lực (thấp < trung bình < cao), phân loại huyết áp.

Bảng 3.1: Các loại biến trong nghiên cứu tình huống và các cách tóm tắt, biểu đồ phù hợp.

Loại biến	Ví dụ trong nghiên cứu tình huống	Tóm tắt bằng số	Biểu đồ
Liên tục, đối xứng	age, sbp_mmhg, bmi	trung bình (SD)	histogram, mật độ, biểu đồ hộp
Liên tục, lệch	distance_to_facility_km	trung vị (IQR)	histogram, biểu đồ hộp
Số đếm rời rạc	comorbidity_count	trung vị (IQR) hoặc n (%)	biểu đồ cột
Nhị phân	diabetes, treatment_uptake	n (%)	biểu đồ cột
Danh định	facility, occupation	n (%)	biểu đồ cột (đã sắp xếp)
Thứ bậc	education, bp_category	n (%), đôi khi trung vị	biểu đồ cột (theo thứ tự)

Từ bảng này rút ra hai lời cảnh báo. Thứ nhất, một con số không phải lúc nào cũng là biến số: mã định danh bệnh nhân hay mã cơ sở y tế được lưu dưới dạng 1, 2, 3 là biến phân loại, và trung bình của chúng vô nghĩa. Thứ hai, các biến liên tục đôi khi được *nhóm* lại thành các nhóm, như BMI được nhóm thành `bmi_cat` và huyết áp thành `bp_category`. Việc nhóm giúp ích cho giao tiếp lâm sàng, vì bác sĩ lâm sàng suy nghĩ theo các khái niệm như "béo phì" hay "tăng huyết áp", nhưng nó làm mất thông tin, vì vậy một Bảng 1 tốt thường trình bày cả giá trị đo liên tục lẫn phân loại lâm sàng.

```
# Cách R lưu mỗi biến: số thực (dbl), factor (fct), factor có thứ tự (ord)
analysis_data |>
  select(age, sbp_mmhg, comorbidity_count, diabetes, facility, education) |>
  glimpse()
```

```
#> Rows: 1,500
#> Columns: 6
#> $ age          <dbl> 74, 56, 54, 33, 86, 70, 45, 59, 46, 61, 70, 56, 4...
#> $ sbp_mmhg     <dbl> 140, 185, 147, 124, 131, 153, 162, 108, 152, 127,...
#> $ comorbidity_count <dbl> 1, 0, 0, 0, 0, 1, 1, 0, 1, 1, 1, 1, 1, 0, 0, 0...
#> $ diabetes     <fct> No, No, No, No, No, No, No, No, No, No, No, No, N...
#> $ facility     <fct> Igoma HC, Kisesa HC, Bugando PHC, Ilemela HC, Kis...
#> $ education    <ord> Primary, Primary, None, Primary, Primary, Primary...
```

`glimpse()` xác nhận rằng các biến liên tục được lưu dưới dạng số (`<dbl>`), các biến danh định và nhị phân dưới dạng `factor` (`<fct>`) và học vấn dưới dạng `factor` có thứ tự (`<ord>`), đúng như đã thiết lập ở Chương 2. Cách lưu trữ khớp với thang đo chính là điều cho phép R, và đặc biệt là `gtsummary`, tự động chọn các thống kê tóm tắt hợp lý.

3.3 Các số đo xu hướng trung tâm

Một số đo xu hướng trung tâm (central tendency, còn gọi là số đo *vị trí*) trả lời câu hỏi "giá trị điển hình là bao nhiêu?". Có ba số đo thường được sử dụng.

3.3.1 Trung bình

Trung bình cộng (mean) của n quan sát $x_1, x_2, \dots, x_n$ là tổng của chúng chia cho n :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Trung bình có những tính chất toán học hấp dẫn. Nó sử dụng mọi quan sát; nó là điểm cân bằng của dữ liệu, theo nghĩa là tổng các độ lệch $x_i - \bar{x}$ bằng không; và nó là giá trị làm cực tiểu tổng bình phương các độ lệch $\sum (x_i - c)^2$. Hành vi lấy mẫu của nó đã được hiểu rõ, đó là lý do phần lớn thống kê cổ điển (kiểm định t, phân tích phương sai, hồi quy tuyến tính) được xây dựng trên trung bình. Điểm yếu của nó là mặt kia của cùng một đồng xu: vì mỗi quan sát đóng góp tương ứng với độ lớn của nó, chỉ một giá trị cực đoan cũng có thể kéo trung bình đi rất xa.

3.3.2 Trung vị

Trung vị (median) là giá trị nằm ở giữa khi các quan sát được sắp xếp từ nhỏ nhất đến lớn nhất. Nếu $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ ký hiệu các giá trị đã sắp xếp, thì

$$\text{median} = \begin{cases} x_{((n+1)/2)} & \text{if } n \text{ is odd,} \\ \frac{1}{2} (x_{(n/2)} + x_{(n/2+1)}) & \text{if } n \text{ is even.} \end{cases}$$

(trong đó *odd* là lẻ và *even* là chẵn). Một nửa số quan sát nằm dưới trung vị và một nửa nằm trên. Vì chỉ *thứ hạng* của các quan sát là quan trọng, chứ không phải độ lớn chính xác của chúng, trung vị có tính **vững** (robust): làm cho giá trị lớn nhất lớn gấp mười lần cũng không làm trung vị thay đổi. Trung vị làm cực tiểu tổng các độ lệch tuyệt đối $\sum |x_i - c|$, và nó là bách phân vị thứ 50, một mối liên hệ mà chúng ta sẽ khai thác khi bàn về phân vị bên dưới.

3.3.3 Yếu vị

Yếu vị (mode) là giá trị xuất hiện nhiều nhất. Nó hiếm khi hữu ích cho các phép đo liên tục (với đủ số chữ số thập phân thì mọi giá trị đều là duy nhất) nhưng lại là "giá trị điển hình" tự nhiên cho một biến danh định: nghề nghiệp phổ biến nhất, cơ sở y tế phổ biến nhất. Một phân phối có hai đỉnh rõ rệt được gọi là *hai đỉnh* (bimodal), điều này thường báo hiệu rằng hai nhóm bệnh nhân khác nhau đã bị trộn lẫn với nhau. R cơ bản không có hàm tính yếu vị thống kê (hàm `mode()`) trả về kiểu lưu trữ của một đối tượng, một nguồn gây nhầm lẫn kinh điển), vì vậy chúng ta tự viết một hàm nhỏ.

```
# Yếu vị thống kê: (các) giá trị xuất hiện nhiều nhất của một vector
stat_mode <- function(x) {
  counts <- table(x) # tần số của mỗi giá trị (bỏ NA)
  names(counts)[counts == max(counts)] # (các) giá trị có tần số cao nhất
}
```

```
stat_mode(analysis_data$education) # trình độ học vấn phổ biến nhất
```

```
#> [1] "Primary"
```

```
stat_mode(analysis_data$occupation) # nghề nghiệp phổ biến nhất
```

```
#> [1] "Farmer"
```

```
stat_mode(analysis_data$sbp_mmhg) # (các) giá trị SBP ghi nhận nhiều nhất
```

```
#> [1] "143"
```

Tiểu học (Primary) và làm nông (Farmer) là các nhóm phổ biến nhất, và đây là những thông tin hữu ích về quần thể. Yếu vị SBP 143 mmHg thì ít hữu ích hơn nhiều: với hàng trăm giá trị có thể có, việc giá trị nào tình cờ xuất hiện nhiều nhất phần lớn là do ngẫu nhiên, và nó sẽ thay đổi với một mẫu khác. Với các phép đo liên tục, yếu vị chủ yếu là công cụ để phát hiện điều bất thường. Chẳng hạn, trong dữ liệu lâm sàng thực tế, yếu vị SBP là 120 hoặc 140 mmHg và sự dư thừa các số đo tận cùng bằng 0 hoặc 5 sẽ cho thấy *ưu tiên chữ số* (digit preference), tức xu hướng của người đo làm tròn các số đo huyết áp thủ công, một nguồn sai số đo lường đã được ghi nhận.

3.3.4 Tính vững: một giá trị sai gây ra điều gì

Sự khác biệt giữa trung bình và trung vị dễ thấy nhất qua một ví dụ nhỏ. Bảy số đo SBP dưới đây đều hợp lý. Sau đó chúng ta thay số đo cuối cùng bằng 700 mmHg, đúng loại lỗi nhập liệu mà chúng ta đã loại bỏ ở Chương 2.

```
sbp_small <- c(128, 132, 135, 140, 141, 145, 150)
sbp_error <- c(128, 132, 135, 140, 141, 145, 700) # một lỗi đánh máy
```

```
c(mean = mean(sbp_small), median = median(sbp_small))
```

```
#> mean median
#> 138.7 140.0
```

```
c(mean = mean(sbp_error), median = median(sbp_error))
```

```
#> mean median
#> 217.3 140.0
```

Chỉ một giá trị sai đã đẩy trung bình từ khoảng 139 mmHg lên khoảng 217 mmHg, một giá trị

không mô tả bất kỳ ai trong bảy bệnh nhân, trong khi trung vị vẫn giữ ở 140 mmHg. Đây là ý nghĩa thực tiễn của tính vững, và cũng là lý do các thống kê tóm tắt của dữ liệu *chưa làm sạch* có thể gây hiểu lầm nghiêm trọng. Với dữ liệu đã làm sạch, cùng một logic áp dụng cho các giá trị cực đoan có thật: một vài bệnh nhân sống cách phòng khám 40 km kéo khoảng cách trung bình lên cao, dù phần lớn bệnh nhân sống gần hơn nhiều.

3.3.5 Xu hướng trung tâm trong dữ liệu nghiên cứu tình huống

```
# Trung bình và trung vị của bốn phép đo lâm sàng (đã loại giá trị khuyết)
analysis_data |>
  summarise(
    across(c(age, sbp_mmhg, bmi, distance_to_facility_km),
      list(mean = ~ mean(.x, na.rm = TRUE),
           median = ~ median(.x, na.rm = TRUE)))
  ) |>
  pivot_longer(everything(),
    names_to = c("variable", ".value"),
    names_pattern = "(.*)_(mean|median)") |>
  kable(digits = 2, caption = "Trung bình và trung vị của bốn biến liên tục.")
```

Bảng 3.2: Trung bình và trung vị của bốn biến liên tục.

variable	mean	median
age	52.28	52.00
sbp_mmhg	139.29	139.00
bmi	26.35	26.30
distance_to_facility_km	7.82	6.45

Với tuổi, SBP và BMI, trung bình và trung vị gần như bằng nhau (52,3 so với 52 tuổi, 139,3 so với 139 mmHg, 26,35 so với 26,3 kg/m²). Sự trùng khớp đó là gợi ý đầu tiên rằng các phân phối này gần như đối xứng. Khoảng cách đến cơ sở y tế thì khác: trung bình 7,8 km cao hơn hẳn trung vị 6,45 km, dấu hiệu đặc trưng của một phân phối *lệch phải* với một cái đuôi dài gồm những bệnh nhân sống ở xa. Chúng ta sẽ trở lại vấn đề này ở Mục 3.5.

3.4 Các số đo độ phân tán

Hai nhóm bệnh nhân có thể có cùng SBP trung bình 140 mmHg, trong khi một nhóm dao động từ 130 đến 150 mmHg và nhóm kia từ 100 đến 200 mmHg. Về mặt lâm sàng, đây là hai quần thể rất khác nhau. Các số đo *độ phân tán* (dispersion, độ biến thiên) định lượng mức độ các quan sát thường nằm cách xa trung tâm bao nhiêu.

3.4.1 Khoảng biến thiên

Khoảng biến thiên (range) là hiệu số giữa giá trị lớn nhất và nhỏ nhất, $x_{(n)} - x_{(1)}$. Trong thực tế, việc báo cáo chính hai giá trị cực trị ("tuổi dao động từ 18 đến 95") cung cấp nhiều thông tin hơn, đồng thời cũng là một bước kiểm tra dữ liệu. Khoảng biến thiên chỉ phụ thuộc vào hai quan sát, nên nó cực kỳ nhạy với giá trị ngoại lai và có xu hướng tăng theo cỡ mẫu: bạn tuyển càng nhiều bệnh nhân, càng dễ gặp một trường hợp cực đoan. Vì vậy đây là một số đo kém về độ

biến thiên, nhưng lại là một cách tốt để kiểm tra tính hợp lý.

3.4.2 Phương sai và độ lệch chuẩn

Phương sai (variance) là trung bình của bình phương các độ lệch so với trung bình. Với một mẫu, nó được tính như sau

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2,$$

và **độ lệch chuẩn** (standard deviation, SD) là căn bậc hai của nó:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Việc bình phương các độ lệch có hai tác dụng: nó ngăn các độ lệch dương và âm triệt tiêu lẫn nhau, và nó cho các độ lệch lớn trọng số lớn hơn các độ lệch nhỏ. Việc lấy căn bậc hai đưa kết quả trở về đơn vị ban đầu, nên SD của SBP có đơn vị mmHg; đó là lý do người ta báo cáo SD chứ không phải phương sai. Số chia $n - 1$ thay vì n là *bậc tự do* (degrees of freedom): một khi trung bình đã được ước lượng từ dữ liệu, chỉ còn $n - 1$ độ lệch được tự do thay đổi (độ lệch cuối cùng bị cố định vì tổng các độ lệch bằng không). Việc chia cho $n - 1$ làm cho s^2 là một ước lượng không chệch của phương sai quần thể σ^2 (Kirkwood and Sterne 2003, ch. 4). Các hàm `var()` và `sd()` của R dùng $n - 1$.

Một cách hữu ích để hình dung SD: nó xấp xỉ khoảng cách điển hình giữa giá trị của một bệnh nhân và trung bình. Với dữ liệu có phân phối xấp xỉ chuẩn, SD có một cách diễn giải chính xác, được trình bày ở Mục 3.5.

3.4.3 Phân vị, tứ phân vị và khoảng tứ phân vị

Một **phân vị** (quantile) chia dữ liệu đã sắp xếp theo những tỷ lệ cho trước. Phân vị thứ p , $Q(p)$, là giá trị mà dưới nó có một tỷ lệ p các quan sát. Phân vị biểu diễn theo phần trăm được gọi là *bách phân vị* (centile hay percentile), theo phần tư là *tứ phân vị* (quartile), theo phần năm là *ngũ phân vị* (quintile) (Altman and Bland 1994). Ba tứ phân vị là

- $Q_1 = Q(0.25)$, tứ phân vị dưới (bách phân vị thứ 25);
- $Q_2 = Q(0.50)$, trung vị;
- $Q_3 = Q(0.75)$, tứ phân vị trên (bách phân vị thứ 75).

Khoảng tứ phân vị (interquartile range) là $IQR = Q_3 - Q_1$, độ rộng của khoảng chứa một nửa ở giữa của dữ liệu. Giống trung vị, nó chỉ phụ thuộc vào thứ hạng nên có tính vững trước các giá trị cực đoan. Trong bài báo, thường nên báo cáo hai tứ phân vị hơn là hiệu số của chúng, ví dụ "trung vị 6,5 km (IQR 4,0 đến 10,3)", vì cặp giá trị này cũng cho thấy tính bất đối xứng: nếu trung vị gần Q_1 hơn nhiều so với Q_3 , phân phối bị lệch phải.

Có nhiều quy ước để tính một phân vị khi $p(n - 1)$ không phải là số nguyên. R cung cấp chín quy ước (type = 1 đến 9 trong `quantile()`); quy ước mặc định, type 7, đặt $Q(p)$ tại vị trí $h = (n - 1)p + 1$ trong dữ liệu đã sắp xếp và nội suy tuyến tính giữa hai quan sát lân cận. Với hàng

trăm quan sát, các quy ước cho kết quả giống nhau trong phạm vi làm tròn, nhưng với một vài giá trị thì chúng khác nhau; điều này giải thích vì sao SPSS, Stata và R có thể cho các tử phân vị hơi khác nhau với cùng một mẫu nhỏ.

Gộp lại, giá trị nhỏ nhất, Q_1 , trung vị, Q_3 và giá trị lớn nhất tạo thành **bản tóm tắt năm số** (five-number summary), đúng là những gì một biểu đồ hộp thể hiện.

3.4.4 Hệ số biến thiên

SD được biểu diễn theo đơn vị của biến, vì vậy SD của SBP (mmHg) không thể so sánh trực tiếp với SD của cholesterol (mmol/L). **Hệ số biến thiên** (coefficient of variation, CV) loại bỏ đơn vị bằng cách biểu diễn SD dưới dạng phần trăm của trung bình:

$$CV = 100 \times \frac{S}{\bar{X}} \%$$

CV được dùng rộng rãi trong y học xét nghiệm để mô tả độ chính xác của một xét nghiệm (một xét nghiệm có CV 3% có độ lặp lại tốt hơn một xét nghiệm có CV 10%) và để so sánh độ biến thiên tương đối của các phép đo khác nhau. Nó chỉ có ý nghĩa với các biến đo trên thang tỷ số có điểm không thực sự và giá trị dương; nó vô nghĩa với nhiệt độ tính bằng độ C hay với một điểm số có thể âm.

3.4.5 Độ phân tán trong R

```
age <- analysis_data$age
```

R

```
range(age, na.rm = TRUE)      # giá trị nhỏ nhất và lớn nhất
```

```
#> [1] 18 95
```

```
var(age, na.rm = TRUE)        # phương sai (năm bình phương)
```

R

```
#> [1] 198.7
```

```
sd(age, na.rm = TRUE)         # độ lệch chuẩn (năm)
```

R

```
#> [1] 14.1
```

```
IQR(age, na.rm = TRUE)        # Q3 - Q1
```

R

```
#> [1] 19
```

```
quantile(age, probs = c(0, 0.25, 0.5, 0.75, 1), na.rm = TRUE)
```

R

```
#>    0%   25%   50%   75%  100%
#>   18   43   52   62   95
```

```
fivenum(age) # bản tóm tắt năm số của Tukey
```

R

```
#> [1] 18 43 52 62 95
```

Đọc kết quả từng dòng: tuổi dao động từ 18 đến 95, hợp lý với một quần thể người trưởng thành khám chăm sóc ban đầu và xác nhận việc làm sạch ở Chương 2. Phương sai khoảng 199 *năm bình phương*, một đơn vị không ai có thể diễn giải, vì thế chúng ta báo cáo căn bậc hai của nó, tức SD khoảng 14,1 năm. Một nửa ở giữa số bệnh nhân có tuổi từ 43 đến 62, tức IQR là 19 năm. `quantile()` với năm xác suất và `fivenum()` cho cùng các con số ở đây; `fivenum()` dùng một quy tắc hơi khác (bản lề Tukey, Tukey's hinges) có thể khác `quantile()` ở các mẫu nhỏ, và nó tự động loại bỏ giá trị khuyết.

Một cách gọn để xem nhiều biến cùng lúc là một bảng tóm tắt dạng dài. Chúng ta định dạng lại dữ liệu sao cho mỗi hàng là một phép đo của một bệnh nhân, sau đó tóm tắt theo biến.

```
continuous_vars <- c("age", "sbp_mmhg", "dbp_mmhg", "bmi",
                     "total_chol_mmol_l", "fasting_glucose_mmol_l",
                     "distance_to_facility_km")

spread_table <- analysis_data |>
  select(all_of(continuous_vars)) |>
  pivot_longer(everything(), names_to = "variable", values_to = "value") |>
  group_by(variable) |>
  summarise(
    n      = sum(!is.na(value)),          # số quan sát thực sự được dùng
    mean   = mean(value, na.rm = TRUE),
    sd     = sd(value, na.rm = TRUE),
    median = median(value, na.rm = TRUE),
    iqr    = IQR(value, na.rm = TRUE),
    cv_pct = 100 * sd / mean              # hệ số biến thiên
  )

spread_table |>
  kable(digits = 2,
        caption = "Vị trí trung tâm và độ phân tán của bảy biến liên tục.")
```

R

Bảng 3.3: Vị trí trung tâm và độ phân tán của bảy biến liên tục.

variable	n	mean	sd	median	iqr	cv_pct
age	1498	52.28	14.10	52.00	19.0	26.96
bmi	1453	26.35	4.87	26.30	6.3	18.48
dbp_mmhg	1499	86.00	10.67	86.00	14.0	12.40
distance_to_facility_km	1440	7.82	6.09	6.45	6.3	77.82
fasting_glucose_mmol_l	1425	5.45	0.99	5.40	1.2	18.16
sbp_mmhg	1498	139.29	19.74	139.00	27.0	14.17
total_chol_mmol_l	1410	5.11	0.98	5.10	1.4	19.16

Bảng này cho thấy nhiều bài học. Cột n khác nhau giữa các biến: cholesterol toàn phần có ở 1.410 bệnh nhân nhưng tuổi có ở 1.498 bệnh nhân, vì vậy mỗi thống kê tóm tắt dựa trên một mẫu số khác nhau, điều mà bản thảo phải báo cáo. SD của SBP khoảng 20 mmHg và của huyết áp tâm trương (diastolic blood pressure, DBP) khoảng 11 mmHg; so với trung bình của chúng,

các giá trị này cho CV tương tự nhau (14% và 12%). Khoảng cách đến cơ sở y tế có CV gần 78%: bệnh nhân khác nhau rất nhiều về quãng đường phải đi, một thực tế có hàm ý rõ ràng đối với khả năng tiếp cận chăm sóc.

Thực hành tốt

Luôn báo cáo số quan sát không khuyết bên cạnh một thống kê tóm tắt. "Cholesterol toàn phần trung bình 5,1 mmol/L (SD 1,0; n = 1.410)" cho người đọc biết rằng 90 bệnh nhân không được đại diện, và gợi ra câu hỏi liệu những người này có khác với phần còn lại hay không.

3.5 Hình dạng của một phân phối

Trung bình và SD chỉ là bản mô tả đầy đủ của một phân phối khi đã biết hình dạng của nó. Với một phân phối đối xứng, hình chuông, chúng nói lên gần như mọi điều; với một phân phối lệch, chúng có thể gây hiểu lầm. Trước khi chọn cách tóm tắt, hãy nhìn vào hình dạng.

3.5.1 Độ lệch

Một phân phối là **đối xứng** nếu nửa trái và nửa phải của nó là ảnh qua gương của nhau, như phân phối chuẩn, trong đó trung bình, trung vị và yếu vị trùng nhau. Nó **lệch phải** (lệch dương, right-skewed) nếu có một cái đuôi dài về bên phải, như thu nhập, thời gian nằm viện, các giá trị xét nghiệm như triglyceride hay protein phản ứng C, và khoảng cách đến cơ sở y tế. Trong một phân phối lệch phải, một vài giá trị lớn kéo trung bình lên cao hơn trung vị. Các phân phối **lệch trái**, với đuôi dài về bên trái, hiếm gặp hơn trong y học; tuổi thai lúc sinh là một ví dụ kinh điển.

Độ lệch (skewness) có thể được định lượng bằng hệ số độ lệch mẫu,

$$g_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^3}{\left[\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \right]^{3/2}},$$

hệ số này bằng không với một phân phối đối xứng, dương khi lệch phải và âm khi lệch trái. Việc lập phương các độ lệch giữ nguyên dấu của chúng, nên một đuôi dài bên phải tạo ra một tổng dương lớn. Theo hướng dẫn sơ bộ, các giá trị nằm giữa -0.5 và 0.5 cho thấy phân phối xấp xỉ đối xứng và các giá trị vượt quá ± 1 cho thấy lệch rõ rệt, mặc dù một hình vẽ luôn cung cấp nhiều thông tin hơn một hệ số đơn lẻ.

```
# Hệ số độ lệch mẫu g1 (không cần thêm gói nào)
skewness <- function(x) {
  x <- x[!is.na(x)]
  m <- mean(x)
  mean((x - m)^3) / mean((x - m)^2)^1.5
}

analysis_data |>
  summarise(across(all_of(continuous_vars), skewness)) |>
  pivot_longer(everything(), names_to = "variable", values_to = "skewness") |>
  arrange(desc(skewness)) |>
  kable(digits = 2, caption = "Độ lệch mẫu của bảy biến liên tục.")
```

Bảng 3.4: Độ lệch mẫu của bảy biến liên tục.

variable	skewness
distance_to_facility_km	1.51
fasting_glucose_mmol_l	0.57
total_chol_mmol_l	0.10
age	0.07
dbp_mmhg	0.05
bmi	0.04
sbp_mmhg	0.03

Khoảng cách đến cơ sở y tế có độ lệch khoảng 1,5, lệch phải rõ ràng. Glucose lúc đói cho thấy lệch phải nhẹ (khoảng 0,6), như glucose thường vẫn vậy: một thiểu số bệnh nhân mắc đái tháo đường chưa được chẩn đoán hoặc kiểm soát kém tạo ra một cái đuôi gồm các giá trị cao. Các biến còn lại có độ lệch gần bằng không và có thể được coi là đối xứng một cách hợp lý.

3.5.2 Phân phối chuẩn

Phân phối **chuẩn** (normal distribution, hay phân phối Gauss) là đường cong hình chuông đối xứng quen thuộc. Nó được xác định hoàn toàn bởi hai tham số, trung bình μ và độ lệch chuẩn σ , và hàm mật độ xác suất của nó là

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

Nhiều phép đo sinh học ở các quần thể khỏe mạnh, như chiều cao hay huyết áp, có phân phối xấp xỉ chuẩn, và phân phối chuẩn đóng vai trò trung tâm trong thống kê vì trung bình mẫu có phân phối xấp xỉ chuẩn ngay cả khi các quan sát riêng lẻ không như vậy (định lý giới hạn trung tâm, được dùng ở Mục 3.8). Với phân phối chuẩn, một tỷ lệ cố định các giá trị nằm trong một số SD bất kỳ cho trước tính từ trung bình (Altman and Bland 1995b):

- khoảng 68% giá trị nằm trong $\mu \pm 1\sigma$;
- khoảng 95% nằm trong $\mu \pm 2\sigma$ (chính xác hơn là $\mu \pm 1.96\sigma$);
- khoảng 99,7% nằm trong $\mu \pm 3\sigma$.

Đây là **quy tắc 68–95–99,7**. Nó giải thích vì sao trung bình và SD là cách tóm tắt hiệu quả đến vậy cho dữ liệu có phân phối chuẩn: "SBP trung bình 139 mmHg (SD 20)" lập tức cho người đọc biết rằng khoảng 95% bệnh nhân có SBP trong khoảng từ xấp xỉ 100 đến 179 mmHg. Khoảng $\bar{x} \pm 1.96s$ được gọi là *khoảng tham chiếu 95%* (reference range) và là cơ sở của nhiều "khoảng bình thường" trong xét nghiệm (Altman 1991, ch. 14).

Chúng ta có thể kiểm tra quy tắc này bằng thực nghiệm cho SBP bằng cách đếm tỷ lệ bệnh nhân nằm trong một, hai và ba SD tính từ trung bình.

```
sbp <- na.omit(analysis_data$sbp_mmhg) # bỏ 2 giá trị khuyết
m_sbp <- mean(sbp)
s_sbp <- sd(sbp)
```

R

```
tibble(k = 1:3) |>
  mutate(
    lower = m_sbp - k * s_sbp,
    upper = m_sbp + k * s_sbp,
    observed = map_dbl(k, ~ mean(abs(sbp - m_sbp) <= .x * s_sbp)),
    expected = c(0.683, 0.954, 0.997) # giá trị lý thuyết (phân phối chuẩn)
  ) |>
  kable(digits = 3,
    caption = "Tỷ lệ giá trị SBP nằm trong k SD tính từ trung bình.")
```

Bảng 3.5: Tỷ lệ giá trị SBP nằm trong k SD tính từ trung bình.

k	lower	upper	observed	expected
1	119.56	159.0	0.674	0.683
2	99.82	178.8	0.961	0.954
3	80.09	198.5	0.999	0.997

Các tỷ lệ quan sát được (khoảng 0,67, 0,96 và 0,999) rất gần với các giá trị kỳ vọng của phân phối chuẩn, nên trung bình và SD tóm tắt tốt SBP. Hình dưới đây cho thấy cùng điều đó bằng hình ảnh: histogram của SBP, được chia theo thang mật độ, được phủ lên bởi một đường cong chuẩn có cùng trung bình và SD với dữ liệu.

```
ggplot(analysis_data, aes(x = sbp_mmhg)) +
  # histogram trên thang mật độ để có thể phủ một đường cong lên trên
  geom_histogram(aes(y = after_stat(density)), binwidth = 5,
    fill = teal, colour = "white", alpha = 0.7, na.rm = TRUE) +
  # ước lượng mật độ kernel: một phiên bản làm trơn của histogram
  geom_density(linewidth = 0.9, colour = "grey20", na.rm = TRUE) +
  # đường cong chuẩn lý thuyết với trung bình và SD của mẫu
  stat_function(fun = dnorm, args = list(mean = m_sbp, sd = s_sbp),
    linetype = "dashed", linewidth = 0.9, colour = "#C0392B") +
  geom_vline(xintercept = 140, linetype = "dotted") +
  labs(title = "Huyết áp tâm thu có phân phối gần chuẩn",
    x = "Huyết áp tâm thu (mmHg)", y = "Mật độ")
```


Ba lớp được vẽ trên cùng một hệ trục. Các cột là histogram; đường liền là ước lượng mật độ kernel (kernel density estimate), mà bạn có thể hình dung như một histogram được làm trơn để không phụ thuộc vào vị trí các mép cột; đường nét đứt là đường cong chuẩn lý tưởng. Sự gần gũi giữa đường liền và đường nét đứt là một cách kiểm tra tính chuẩn bằng mắt. Đường thẳng đứng chấm chấm tại 140 mmHg, ngưỡng quy ước cho tăng huyết áp (World Health Organization 2021), cho thấy hơn một nửa số bệnh nhân có số đo tăng vào ngày khảo sát. Các kiểm định chính thức và biểu đồ phân vị-phân vị chuẩn (normal Q-Q plot) được giới thiệu ở Chương 4.

3.5.3 Khi nào nên báo cáo trung vị (IQR) thay vì trung bình (SD)

Khoảng cách đến cơ sở y tế lại là một câu chuyện khác. Hình tiếp theo trình bày histogram của biến này với trung bình và trung vị được đánh dấu.

```
dist_summary <- analysis_data |>
  summarise(mean = mean(distance_to_facility_km, na.rm = TRUE),
    median = median(distance_to_facility_km, na.rm = TRUE))
```

Huyết áp tâm thu có phân phối gần chuẩn



Hình 3.1: Phân phối huyết áp tâm thu ở 1.498 bệnh nhân: histogram (mỗi cột rộng 5 mmHg) với ước lượng mật độ đã làm trơn (đường đậm) và đường cong chuẩn có cùng trung bình và SD (nét đứt); đường chấm chấm đánh dấu ngưỡng chẩn đoán 140 mmHg.


```
ggplot(analysis_data, aes(x = distance_to_facility_km)) +
  geom_histogram(binwidth = 1, boundary = 0, fill = teal,
    colour = "white", na.rm = TRUE) +
  geom_vline(xintercept = dist_summary$mean, linewidth = 0.9) +
  geom_vline(xintercept = dist_summary$median, linewidth = 0.9,
    linetype = "dashed") +
  # nhãn chữ đặt bên phải hai đường thẳng
  annotate("text", x = dist_summary$mean + 0.8, y = c(150, 135), hjust = 0,
    label = c(sprintf("trung vị = %.2f km (nét đứt)",
      dist_summary$median),
      sprintf("trung bình = %.2f km (nét liền)",
        dist_summary$mean))) +
  labs(title = "Khoảng cách đến cơ sở y tế có đuôi dài bên phải",
    x = "Khoảng cách đến cơ sở y tế (km)", y = "Số bệnh nhân")
```

Phần lớn bệnh nhân sống trong phạm vi khoảng 10 km, nhưng một số ít phải đi từ 30 km trở lên. Số ít đó kéo trung bình lên 7,8 km, cao hơn trung vị 6,45 km. Hơn nữa, SD (6,1 km) gần lớn bằng trung bình, nên "trung bình 7,8 km (SD 6,1)", nếu được hiểu như một phân phối chuẩn, sẽ ngụ ý rằng khoảng một trong mười bệnh nhân sống ở khoảng cách *âm* (giá trị 0 nằm dưới trung bình 1,3 SD), điều không thể xảy ra. Trung bình và SD đơn giản là ngôn ngữ sai cho hình dạng này. Một quy tắc thực hành tốt là: **nếu SD lớn hơn khoảng một nửa trung bình đối với một biến không thể nhận giá trị âm, thì phân phối bị lệch** (Altman 1991). Với những biến như vậy, hãy báo cáo trung vị kèm khoảng tứ phân vị: "khoảng cách trung vị 6,5 km (IQR 4,0 đến 10,3)".

Tóm lại, lựa chọn được định hướng bởi hình dạng, không phải bởi thói quen:

- **Trung bình (SD)** cho các phân phối xấp xỉ đối xứng (tuổi, SBP, DBP, BMI và cholesterol trong bộ dữ liệu này).

Khoảng cách đến cơ sở y tế có đuôi dài bên phải



Hình 3.2: Khoảng cách từ nhà đến cơ sở y tế ($n = 1.440$) bị lệch phải: phần lớn bệnh nhân sống trong phạm vi 10 km nhưng có một cái đuôi dài gồm những người phải đi xa hơn nhiều, vì vậy trung bình (đường liền) nằm bên phải trung vị (đường nét đứt).

- **Trung vị (IQR)** cho các phân phối lệch, các phân phối có giá trị ngoại lai, các biến rời rạc có ít giá trị, và các điểm số thứ bậc.
- Khi còn phân vân, hãy báo cáo cả hai, hoặc trình bày phân phối bằng một hình.

Lỗi thường gặp

Đừng nhầm SD với sai số chuẩn (SE). SD mô tả mức độ *bệnh nhân* khác nhau; SE (Mục 3.8) mô tả mức độ chính xác của việc ước lượng một *trung bình*. Báo cáo "trung bình $\pm$ SE" trong một bảng mô tả làm cho dữ liệu trông ít biến thiên hơn nhiều so với thực tế, vì SE giảm đi khi mẫu tăng lên trong khi SD thì không (Altman and Bland 1994).

3.6 Giá trị khuyết và cái bẫy `na.rm`

Dữ liệu lâm sàng thực tế luôn không đầy đủ, và R được thiết kế để thận trọng với giá trị khuyết. Trong R, một giá trị khuyết là NA ("not available", không có sẵn), và quy tắc rất đơn giản: *mọi phép tính có liên quan đến một giá trị chưa biết đều cho kết quả chưa biết*. Nếu SBP của một bệnh nhân bị khuyết, R không thể biết tổng của tất cả các SBP, và do đó không thể biết trung bình.

```
sum(is.na(analysis_data$sbp_mmhg)) # có bao nhiêu giá trị SBP bị khuyết?
```

```
#> [1] 2
```

```
mean(analysis_data$sbp_mmhg) # cái bẫy: một NA làm kết quả thành NA
```

```
#> [1] NA
```

```
mean(analysis_data$sbp_mmhg, na.rm = TRUE) # cách khắc phục: loại NA trước
```

```
#> [1] 139.3
```

Hai bệnh nhân không được ghi SBP, nên `mean()` trả về NA. Thêm `na.rm = TRUE` ("NA remove", loại bỏ NA) yêu cầu R bỏ các giá trị khuyết và tính trung bình của 1.498 giá trị còn lại. Đối số này cũng có ở `median()`, `sd()`, `var()`, `quantile()`, `IQR()`, `min()`, `max()`, `range()` và `sum()`.

Cái bẫy này quan trọng nhất với các biến có nhiều giá trị khuyết. Cholesterol toàn phần có 90 giá trị khuyết.

```
chol <- analysis_data$total_chol_mmol_l

c(n_total = length(chol),
  n_missing = sum(is.na(chol)),
  pct_miss = round(100 * mean(is.na(chol)), 1),
  mean = round(mean(chol, na.rm = TRUE), 2))
```

```
#>   n_total n_missing pct_miss   mean
#>   1500.00     90.00     6.00    5.11
```

Hãy lưu ý cách viết quen thuộc `mean(is.na(x))`: `is.na()` trả về TRUE/FALSE, R coi TRUE là 1 và FALSE là 0, nên trung bình của một vector logic chính là tỷ lệ các giá trị TRUE. Ở đây 6% giá trị cholesterol bị khuyết. Trung bình 5,1 mmol/L mô tả 1.410 bệnh nhân đã được xét nghiệm, chứ không phải toàn bộ 1.500 người.

Lỗi thường gặp

`na.rm = TRUE` làm thông báo lỗi biến mất; nó không làm vấn đề dữ liệu khuyết biến mất. Việc loại bỏ giá trị khuyết âm thầm thay đổi mẫu số, và nếu những bệnh nhân không có kết quả cholesterol khác với những người có kết quả (có thể những bệnh nhân nặng nhất đã được chuyển thẳng đến bệnh viện trước khi lấy máu), thì trung bình bị chệch. Hãy luôn đếm các giá trị khuyết, báo cáo chúng, và suy nghĩ về lý do chúng bị khuyết (Rubin 1976; Little and Rubin 2019).

Mẹo

Bên trong `summarise()`, nên tính `n = sum(!is.na(x))` bên cạnh mỗi trung bình, như trong bảng độ phân tán ở Mục 3.4. Khi đó mẫu số luôn đi kèm thống kê và không thể bị quên khi bảng được chép vào bản thảo.

3.7 Tóm tắt theo nhóm

Thống kê mô tả trở nên giàu thông tin nhất khi chúng ta so sánh các nhóm: bệnh nhân được điều trị so với không được điều trị, phụ nữ so với nam giới, cơ sở này so với cơ sở khác. Các động từ của **dplyr** là `group_by()` và `summarise()` làm việc này trong hai bước: `group_by()` chia

dữ liệu thành các nhóm và `summarise()` tính một hàng thống kê cho mỗi nhóm (Wickham et al. 2023).

3.7.1 Theo việc sử dụng điều trị

Trước tiên chúng ta viết một hàm trợ giúp nhỏ định dạng trung bình và SD thành một chuỗi ký tự duy nhất, đúng định dạng dùng trong các bảng đã xuất bản. Sau đó chúng ta tóm tắt năm biến theo việc sử dụng điều trị ở những bệnh nhân đã được chẩn đoán.

```
# Định dạng "trung bình (SD)" với một chữ số thập phân
mean_sd <- function(x) {
  sprintf("%.1f (%.1f)", mean(x, na.rm = TRUE), sd(x, na.rm = TRUE))
}

diagnosed |>
  group_by(treatment_uptake) |>
  summarise(
    n          = n(),                                # số bệnh nhân trong mỗi nhóm
    Age        = mean_sd(age),
    SBP        = mean_sd(sbp_mmhg),
    DBP        = mean_sd(dbp_mmhg),
    BMI        = mean_sd(bmi),
    Knowledge  = mean_sd(knowledge_score)
  ) |>
  kable(col.names = c("Điều trị", "n", "Tuổi", "SBP", "DBP", "BMI",
    "Kiến thức"),
    caption = paste("Trung bình (SD) của năm biến theo việc sử dụng",
    "điều trị ở bệnh nhân đã được chẩn đoán."))
```

Bảng 3.6: Trung bình (SD) của năm biến theo việc sử dụng điều trị ở bệnh nhân đã được chẩn đoán.

Điều trị	n	Tuổi	SBP	DBP	BMI	Kiến thức
No	581	51.1 (13.4)	142.2 (19.8)	88.8 (10.6)	26.8 (4.9)	9.9 (3.4)
Yes	508	56.3 (14.1)	148.1 (18.3)	88.2 (10.7)	26.9 (4.7)	10.9 (3.4)

Trong 1.089 bệnh nhân đã được chẩn đoán, 581 người không điều trị và 508 người có điều trị. Bệnh nhân được điều trị trung bình lớn hơn khoảng năm tuổi và có điểm kiến thức trung bình cao hơn một chút (khoảng một điểm trên thang 0–20). SBP trung bình của họ cũng *cao hơn*, điều có vẻ đáng ngạc nhiên nếu điều trị làm giảm huyết áp. Tuy nhiên, trong một nghiên cứu cắt ngang, chúng ta chỉ quan sát mỗi bệnh nhân một lần: những bệnh nhân có huyết áp cao nhất là những người dễ được bắt đầu điều trị nhất, và điều trị không đưa mọi bệnh nhân đạt mục tiêu. Các so sánh mô tả không thể tách bạch nhân và quả; chúng đặt ra các câu hỏi cho những phân tích ở Chương 4 và 5.

3.7.2 Theo cơ sở y tế

```
diagnosed |>
  group_by(facility) |>
  summarise(
    n          = n(),
    treated    = sum(treatment_uptake == "Yes"),
```

```
pct_treated = 100 * mean(treatment_uptake == "Yes"),
median_dist = median(distance_to_facility_km, na.rm = TRUE),
pct_insured = 100 * mean(health_insurance == "Yes")
) |>
arrange(desc(pct_treated)) |>
kable(digits = 1,
caption = paste("Sử dụng điều trị, khoảng cách và bảo hiểm theo",
"cơ sở y tế (bệnh nhân đã được chẩn đoán)."))
```

Bảng 3.7: Sử dụng điều trị, khoảng cách và bảo hiểm theo cơ sở y tế (bệnh nhân đã được chẩn đoán).

facility	n	treated	pct_treated	median_dist	pct_insured
Nyamagana PHC	220	118	53.6	6.4	36.8
Bugando PHC	259	123	47.5	6.5	34.0
Kisesa HC	154	71	46.1	6.2	33.1
Ilemela HC	192	87	45.3	7.2	35.9
Buzuruga PHC	134	59	44.0	5.5	26.1
Igoma HC	130	50	38.5	5.8	30.8

Tỷ lệ sử dụng điều trị dao động từ khoảng 54% ở Nyamagana PHC đến khoảng 39% ở Igoma HC. Việc sắp xếp theo thống kê quan tâm (`arrange(desc(...))`) làm cho thứ hạng hiện rõ chỉ trong nháy mắt. Liệu mức chênh lệch này có lớn hơn mức mà riêng yếu tố ngẫu nhiên có thể tạo ra hay không là câu hỏi dành cho khoảng tin cậy (Mục 3.8) và các kiểm định chính thức (Chương 4). Một lần nữa hãy lưu ý cách viết `mean(treatment_uptake == "Yes")`: phép so sánh trả về TRUE/FALSE, và trung bình của nó là một tỷ lệ.

3.7.3 Theo hai biến phân nhóm

`group_by()` chấp nhận nhiều biến. Ở đây chúng ta xem SBP trung bình theo giới tính và việc sử dụng điều trị ở những bệnh nhân đã được chẩn đoán.

```
diagnosed |>
group_by(sex, treatment_uptake) |>
summarise(n = n(),
mean_sbp = mean(sbp_mmhg, na.rm = TRUE),
sd_sbp = sd(sbp_mmhg, na.rm = TRUE),
.groups = "drop") |> # bỏ phân nhóm sau khi tóm tắt
kable(digits = 1,
caption = "SBP (mmHg) theo giới tính và việc sử dụng điều trị.")
```

Bảng 3.8: SBP (mmHg) theo giới tính và việc sử dụng điều trị.

sex	treatment_uptake	n	mean_sbp	sd_sbp
Female	No	315	141.1	19.8
Female	Yes	314	149.1	17.9
Male	No	266	143.4	19.8
Male	Yes	194	146.6	18.9

Xu hướng quan sát được ở toàn bộ mẫu (SBP cao hơn ở bệnh nhân được điều trị) vẫn đúng ở cả phụ nữ và nam giới, mặc dù khoảng chênh lệch lớn hơn ở phụ nữ (khoảng 8 mmHg) so với nam giới

(khoảng 3 mmHg). Như vậy, khác biệt chung không đơn thuần do tỷ lệ nam và nữ khác nhau giữa hai nhóm, nhưng độ lớn của nó có thể phụ thuộc vào giới tính, một gợi ý về điều mà các nhà dịch tễ học gọi là *biến đổi tác động* (effect modification). Đối số `.groups = "drop"` trả về một kết quả không còn phân nhóm, giúp tránh những bất ngờ nếu bảng được xử lý tiếp.

Thực hành tốt

Hãy dùng `across()` để áp dụng cùng một thống kê tóm tắt cho nhiều cột, như ở Mục 3.3 và 3.4, thay vì sao chép và dán một dòng cho mỗi biến. Ít dòng hơn nghĩa là ít lỗi đánh máy hơn, và việc thêm một biến chỉ còn là thay đổi một từ.

3.8 Từ mô tả đến suy luận: sai số chuẩn và khoảng tin cậy

Cho đến giờ chúng ta đã mô tả mẫu. Nhưng mục đích của phần lớn các nghiên cứu lâm sàng là tìm hiểu về một *quần thể*: tất cả người trưởng thành đến khám chăm sóc ban đầu trong khu vực, chứ không chỉ 1.500 người đã được tuyển vào. Nếu chúng ta rút một mẫu 1.500 người khác, chúng ta sẽ có một SBP trung bình hơi khác. Nó sẽ dao động bao nhiêu? Câu trả lời là **sai số chuẩn** (standard error), và nó dẫn thẳng đến **khoảng tin cậy** (confidence interval), công cụ đơn lẻ hữu ích nhất của suy luận thống kê (Altman 1991; Kirkwood and Sterne 2003).

3.8.1 Sai số chuẩn của trung bình

Hãy tưởng tượng lặp lại nghiên cứu nhiều lần, mỗi lần tính trung bình mẫu $\bar{x}$. Các trung bình này sẽ tạo thành một phân phối riêng, gọi là *phân phối lấy mẫu của trung bình* (sampling distribution of the mean). Định lý giới hạn trung tâm cho biết rằng, với các mẫu đủ lớn, phân phối này xấp xỉ chuẩn, có tâm tại trung bình quần thể μ , với độ lệch chuẩn

$$SE(\bar{x}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}}.$$

Độ lệch chuẩn này của phân phối lấy mẫu là **sai số chuẩn của trung bình**. Nó giảm theo căn bậc hai của cỡ mẫu: số bệnh nhân tăng gấp bốn lần thì SE giảm một nửa. Ngược lại, SD không giảm theo cỡ mẫu, vì bệnh nhân không trở nên giống nhau hơn khi tuyển thêm nhiều người.

3.8.2 Khoảng tin cậy cho một trung bình

Vì $\bar{x}$ có phân phối xấp xỉ chuẩn với SD bằng SE, khoảng 95% các mẫu cho một trung bình nằm trong phạm vi 1,96 SE tính từ μ . Đảo ngược nhận định này ta có **khoảng tin cậy** (CI) 95%

$$\bar{x} \pm t_{n-1, 0.975} \times \frac{s}{\sqrt{n}},$$

trong đó $t_{n-1, 0.975}$ là bách phân vị thứ 97,5 của phân phối t Student với $n - 1$ bậc tự do (Student 1908). Với n lớn, giá trị này rất gần 1,96; với các mẫu nhỏ, nó lớn hơn, làm khoảng rộng ra để tính đến sự bất định trong s .

```
n_sbp <- length(sbp) # 1.498 giá trị không khuyết
se_sbp <- s_sbp / sqrt(n_sbp) # sai số chuẩn của trung bình
t_crit <- qt(0.975, df = n_sbp - 1) # khoảng 1,96 khi n lớn
```

R

```
c(mean = m_sbp, sd = s_sbp, se = se_sbp, t = t_crit,
  lower = m_sbp - t_crit * se_sbp, upper = m_sbp + t_crit * se_sbp)
```

```
#>      mean      sd      se      t    lower    upper
#> 139.2924 19.7355  0.5099  1.9615 138.2922 140.2926
```

```
# Cùng khoảng tin cậy đó từ t.test(), hàm sẽ được trình bày đầy đủ ở Chương 4
t.test(sbp)$conf.int
```

```
#> [1] 138.3 140.3
#> attr(,"conf.level")
#> [1] 0.95
```

SBP trung bình là 139,3 mmHg. SD 19,7 mmHg mô tả mức độ khác nhau giữa từng bệnh nhân; SE chỉ 0,51 mmHg mô tả mức độ chính xác của việc ước lượng trung bình quần thể từ 1.498 bệnh nhân. CI 95% trải từ khoảng 138,3 đến 140,3 mmHg. `t.test()` cho cùng khoảng này mà không cần tính toán thủ công.

Diễn giải lâm sàng

CI 95% cho biết dữ liệu phù hợp với một SBP trung bình của quần thể nằm ở bất kỳ đâu trong khoảng từ xấp xỉ 138 đến 140 mmHg. Nói một cách chặt chẽ, "95%" là nói về phương pháp: nếu nghiên cứu được lặp lại nhiều lần, 95% các khoảng được tính theo cách này sẽ chứa trung bình thật. CI là về *trung bình*; nó không nói rằng 95% bệnh nhân có SBP trong khoảng này. Để nói điều đó, chúng ta cần khoảng tham chiếu, trung bình $\pm 1,96$ SD, tức khoảng 101 đến 178 mmHg.

3.8.3 Khoảng tin cậy cho một tỷ lệ

Cùng một logic áp dụng cho một tỷ lệ. Nếu x trong số n bệnh nhân có một đặc điểm, tỷ lệ mẫu là $\hat{p} = x/n$, sai số chuẩn của nó là

$$SE(\hat{p}) = \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}},$$

và CI 95% đơn giản (Wald) là

$$\hat{p} \pm 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}.$$

Khoảng Wald hoạt động tốt khi cả $n\hat{p}$ và $n(1 - \hat{p})$ đều ít nhất khoảng 10. Với các mẫu nhỏ hoặc tỷ lệ gần 0 hay 1, nó có thể quá hẹp hoặc thậm chí kéo dài xuống dưới 0; **khoảng điểm Wilson** (Wilson score interval) hoạt động tốt hơn nhiều và là khoảng mà `prop.test()` báo cáo (Agresti 2013, ch. 1). Với các mẫu lớn, hai khoảng này rất gần nhau.

```
x_treated <- sum(diagnosed$treatment_uptake == "Yes") # số được điều trị
n_diag    <- nrow(diagnosed)                        # tất cả người đã chẩn đoán
```

```
p_hat <- x_treated / n_diag
se_p <- sqrt(p_hat * (1 - p_hat) / n_diag)

# Khoảng Wald, tính thủ công
round(100 * c(p = p_hat, lower = p_hat - 1.96 * se_p,
              upper = p_hat + 1.96 * se_p), 1)

#>      p lower upper
#> 46.6 43.7 49.6
```

```
# Khoảng điểm Wilson (correct = FALSE tắt hiệu chỉnh liên tục)
round(100 * prop.test(x_treated, n_diag, correct = FALSE)$conf.int, 1)

#> [1] 43.7 49.6
#> attr(,"conf.level")
#> [1] 0.95
```

Trong 1.089 bệnh nhân đã được chẩn đoán, 508 người (46,6%) đang dùng thuốc điều trị tăng huyết áp. CI 95% khoảng từ 43,7% đến 49,6% theo cả hai phương pháp. Nói cách khác: dữ liệu phù hợp với một tỷ lệ sử dụng điều trị trong quần thể ở mức khoảng giữa 40%, và rõ ràng dưới một nửa. Việc ít hơn một nửa số bệnh nhân đã được chẩn đoán đang điều trị chính là loại "khoảng trống điều trị" (treatment gap) được báo cáo trong nhiều cuộc điều tra thực tế về chăm sóc tăng huyết áp (NCD Risk Factor Collaboration (NCD-RisC) 2021; Mills et al. 2020), mặc dù, xin nhắc lại, đây là dữ liệu mô phỏng.

3.8.4 Khoảng tin cậy theo nhóm

Khoảng tin cậy trở nên đặc biệt giàu thông tin khi so sánh các nhóm. Đoạn mã dưới đây tính tỷ lệ sử dụng điều trị và CI 95% Wald của nó cho từng cơ sở y tế, và hình tiếp theo biểu diễn các kết quả đó.

```
facility_ci <- diagnosed |>
  group_by(facility) |>
  summarise(n = n(), treated = sum(treatment_uptake == "Yes")) |>
  mutate(p = treated / n,
         se = sqrt(p * (1 - p) / n),
         lower = p - 1.96 * se,
         upper = p + 1.96 * se)

facility_ci |>
  mutate(across(c(p, lower, upper), ~ 100 * .x)) |>
  select(facility, n, treated, pct = p, lower, upper) |>
  kable(digits = 1,
        caption = "Tỷ lệ sử dụng điều trị (%) kèm CI 95% theo cơ sở y tế.")


ggplot(facility_ci,
       aes(x = p, y = fct_reorder(facility, p))) + # sắp xếp cơ sở theo p
  geom_vline(xintercept = p_hat, linetype = "dashed", colour = "grey40") +
  geom_pointrange(aes(xmin = lower, xmax = upper),
                 colour = teal, linewidth = 0.8) +
```

Bảng 3.9: Tỷ lệ sử dụng điều trị (%) kèm CI 95% theo cơ sở y tế.

facility	n	treated	pct	lower	upper
Bugando PHC	259	123	47.5	41.4	53.6
Buzuruga PHC	134	59	44.0	35.6	52.4
Igoma HC	130	50	38.5	30.1	46.8
Ilemela HC	192	87	45.3	38.3	52.4
Kisesa HC	154	71	46.1	38.2	54.0
Nyamagana PHC	220	118	53.6	47.0	60.2

```
scale_x_continuous(labels = label_percent(), limits = c(0.25, 0.70)) +
labs(title = "Tỷ lệ sử dụng điều trị khác nhau giữa các cơ sở y tế",
x = "Bệnh nhân đã chẩn đoán đang điều trị (CI 95%)", y = NULL)
```

Tỷ lệ sử dụng điều trị khác nhau giữa các cơ sở y tế



Hình 3.3: Tỷ lệ bệnh nhân tăng huyết áp đã được chẩn đoán đang điều trị tại mỗi cơ sở y tế, kèm khoảng tin cậy 95%; đường nét đứt đánh dấu tỷ lệ chung (46,6%). Các cơ sở được sắp xếp theo tỷ lệ sử dụng điều trị.

Mỗi điểm là tỷ lệ sử dụng điều trị của một cơ sở và thanh ngang là CI 95% của nó. Các khoảng này rộng, khoảng ± 6 đến ± 8 điểm phần trăm, vì mỗi cơ sở chỉ đóng góp 130 đến 260 bệnh nhân đã được chẩn đoán, so với ± 3 điểm khi gộp cả 1.089 người. Igoma HC thấp nhất và Nyamagana PHC cao nhất, và các khoảng của chúng (30,1% đến 46,8% và 47,0% đến 60,2%) chỉ vừa đủ để không chồng lên nhau; bốn cơ sở còn lại phù hợp với tỷ lệ chung. Sự chồng lấp giữa các khoảng *không phải* là một kiểm định chính thức (hai khoảng có thể chồng lên nhau một chút ngay cả khi các nhóm khác nhau có ý nghĩa thống kê), và việc chọn ra hai cơ sở cực trị trong sáu cơ sở sẽ phóng đại sự tương phản, vì vậy chúng ta để việc so sánh này cho kiểm định khi bình phương ở Chương 4. Một biểu đồ các ước lượng kèm khoảng tin cậy, được sắp xếp theo độ lớn, cung cấp nhiều thông tin hơn hẳn một biểu đồ cột tỷ lệ phần trăm, vì nó cho thấy cả sự bất định lẫn ước lượng.

3.9 Mô tả biến phân loại

Với các biến phân loại, cách tóm tắt tự nhiên là **tần số** (số đếm) và **tần số tương đối** (tỷ lệ hoặc tỷ lệ phần trăm). Những quyết định thực sự duy nhất là dùng mẫu số nào và xử lý giá trị khuyết ra sao.

3.9.1 Bảng tần số với R cơ bản

`table()` đếm từng nhóm và `prop.table()` chuyển số đếm thành tỷ lệ.

```
table(analysis_data$sex)
```

số đếm

R

```
#>
#> Female   Male
#>    885    615
```

```
round(100 * prop.table(table(analysis_data$sex)), 1) # tỷ lệ phần trăm
```

R

```
#>
#> Female   Male
#>    59    41
```

Mẫu gồm 885 phụ nữ (59,0%) và 615 nam giới (41,0%). Tỷ lệ phụ nữ chiếm ưu thế là điều thường gặp ở những người đến khám chăm sóc ban đầu tại nhiều nơi, và đó chính là loại thông tin mà Bảng 1 phải báo cáo, vì nó ảnh hưởng đến mức độ khái quát hóa của kết quả.

3.9.2 Làm cho giá trị khuyết hiện ra

Theo mặc định, `table()` âm thầm bỏ qua NA. Với một biến có giá trị khuyết, điều này làm thay đổi mẫu số mà không báo cho bạn biết.

```
table(analysis_data$education)
```

NA bị bỏ qua âm thầm

R

```
#>
#>      None   Primary Secondary  Tertiary
#>      270     608     424      168
```

```
table(analysis_data$education, useNA = "ifany")
```

hiện NA nếu có

R

```
#>
#>      None   Primary Secondary  Tertiary  <NA>
#>      270     608     424      168     30
```

Ba mươi bệnh nhân không được ghi trình độ học vấn. Bảng thứ nhất che giấu họ, vì vậy các tỷ lệ phần trăm tính từ bảng đó sẽ dựa trên 1.470 bệnh nhân trong khi trông như đang mô tả cả 1.500 người. Đối số `useNA = "ifany"` thêm một cột <NA> bất cứ khi nào có giá trị khuyết (dùng "always" để hiện cột này ngay cả khi số đếm bằng không).

Thực hành tốt

Trong bản thảo, tỷ lệ phần trăm của một biến phân loại thường được tính trong số những bệnh nhân có giá trị đã biết, còn số bị khuyết được báo cáo riêng ("học vấn bị khuyết ở 30 bệnh nhân (2,0%)"). Dù dùng quy ước nào, hãy nêu rõ trong chú thích của bảng, và đừng bao giờ để giá trị khuyết biến mất mà không thông báo.

3.9.3 Bảng tần số gọn gàng với `count()`

`dplyr::count()` trả về một khung dữ liệu (data frame) thay vì một đối tượng bảng, nên kết quả có thể được chuyển tiếp bằng pipe sang các bước khác, ví dụ để thêm một cột tỷ lệ phần trăm.

```
analysis_data |>
  count(bp_category) |> # NA được giữ thành một hàng riêng
  mutate(percent = round(100 * n / sum(n), 1))
```

```
#> # A tibble: 4 × 3
#>   bp_category     n percent
#>   <fct>         <int>   <dbl>
#> 1 Normal         144     9.6
#> 2 Elevated       357    23.8
#> 3 Hypertension   996    66.4
#> 4 <NA>           3      0.2
```

Theo mặc định, `count()` giữ NA thành một hàng riêng. Trong 1.500 bệnh nhân, 996 người (66,4%) có số đo trong ngưỡng tăng huyết áp, 357 người (23,8%) ở mức tăng (Elevated) và 144 người (9,6%) ở mức bình thường; ba người không thể phân loại vì thiếu một giá trị huyết áp.

3.9.4 Bảng tần số trau chuốt với `janitor`

Gói **janitor** cung cấp `tabyl()`, hàm tạo bảng tần số với số đếm, tỷ lệ phần trăm và (khi có giá trị khuyết) một cột "tỷ lệ hợp lệ" (valid percent) riêng không tính giá trị khuyết, cùng một họ hàm `adorn_*()` để định dạng chúng cho việc trình bày.

```
analysis_data |>
  tabyl(education) |>
  adorn_totals("row") |> # thêm hàng Total (tổng)
  adorn_pct_formatting(digits = 1) # định dạng tỷ lệ thành phần trăm
```

```
#>   education     n percent valid_percent
#>   None       270   18.0%      18.4%
#>   Primary    608   40.5%      41.4%
#>   Secondary  424   28.3%      28.8%
#>   Tertiary   168   11.2%      11.4%
#>   <NA>        30    2.0%         -
#>   Total   1500  100.0%     100.0%
```

Cột percent dùng toàn bộ 1.500 bệnh nhân làm mẫu số; `valid_percent` loại 30 giá trị khuyết. Trình độ tiểu học phổ biến nhất (40,5% trên tổng số bệnh nhân, 41,4% trong số những người biết trình độ học vấn). Vì `education` là một factor có thứ tự, các nhóm xuất hiện theo thứ tự tự nhiên thay vì theo bảng chữ cái, một trong những lợi ích của việc thiết lập các mức factor ở Chương

2.

3.9.5 Bảng chéo

Một **bảng chéo** (cross-tabulation, hay bảng tiếp liên, contingency table) đếm bệnh nhân theo hai biến phân loại cùng lúc. Ở những bệnh nhân đã được chẩn đoán, hãy lập bảng chéo giữa đái tháo đường và việc sử dụng điều trị.

```
xtab <- table(Diabetes = diagnosed$diabetes,
              Treated  = diagnosed$treatment_uptake)
xtab
```

```
#>      Treated
#> Diabetes No Yes
#>      No  574 487
#>      Yes   7  21
```

```
addmargins(xtab)
```

thêm tổng hàng và tổng cột

```
#>      Treated
#> Diabetes No Yes Sum
#>      No  574 487 1061
#>      Yes   7  21  28
#>      Sum 581 508 1089
```

Mỗi ô đếm số bệnh nhân có một tổ hợp nhất định: ví dụ, 21 bệnh nhân đã được chẩn đoán vừa mắc đái tháo đường vừa đang điều trị. `addmargins()` thêm các tổng (Sum): 28 bệnh nhân đã được chẩn đoán mắc đái tháo đường, 508 người được điều trị, và tổng chung là 1.089.

3.9.6 Tỷ lệ phần trăm theo hàng hay theo cột?

Một bảng hai chiều có thể được chuyển thành tỷ lệ phần trăm theo ba cách, được điều khiển bởi đối số `margin` của `prop.table()`:

- `margin = 1`: **tỷ lệ phần trăm theo hàng**, mỗi hàng cộng lại bằng 100%;
- `margin = 2`: **tỷ lệ phần trăm theo cột**, mỗi cột cộng lại bằng 100%;
- không có `margin`: tỷ lệ phần trăm so với tổng chung.

```
round(100 * prop.table(xtab, margin = 1), 1) # % hàng: trong nhóm đái tháo đường
```

```
#>      Treated
#> Diabetes No Yes
#>      No  54.1 45.9
#>      Yes  25.0 75.0
```

```
round(100 * prop.table(xtab, margin = 2), 1) # % cột: trong nhóm điều trị
```

```
#>           Treated
#> Diabetes    No   Yes
#>         No  98.8 95.9
#>         Yes   1.2  4.1
```

Hai bảng trả lời những câu hỏi khác nhau. Với đái tháo đường ở các hàng, **tỷ lệ phần trăm theo hàng** cho biết 75,0% bệnh nhân đã được chẩn đoán có đái tháo đường đang điều trị, so với 45,9% ở những người không mắc đái tháo đường. **Tỷ lệ phần trăm theo cột** cho biết 4,1% bệnh nhân được điều trị mắc đái tháo đường, so với 1,2% ở bệnh nhân không được điều trị.

Báo cáo tỷ lệ nào phụ thuộc vào câu hỏi. Nếu việc sử dụng điều trị là biến kết cục và đái tháo đường là một yếu tố quyết định có thể có, như trong nghiên cứu của chúng ta, phép so sánh tự nhiên là tỷ lệ được điều trị trong mỗi nhóm đái tháo đường, ở đây là tỷ lệ phần trăm theo hàng. Quy tắc là tính tỷ lệ phần trăm **trong các nhóm của biến giải thích**, để mỗi tỷ lệ trả lời câu hỏi "trong số những bệnh nhân có đặc điểm này, bao nhiêu phần trăm có biến kết cục?" (Altman 1991; Kirkwood and Sterne 2003). Trong một Bảng 1 được trình bày theo nhóm biến kết cục (các cột = được điều trị và không được điều trị), quy ước thì ngược lại: tỷ lệ phần trăm theo cột, mô tả thành phần của mỗi nhóm. Cả hai đều đúng với mục đích của chúng; sai lầm là tính một loại rồi mô tả nó bằng lời lẽ dành cho loại kia.

Lỗi thường gặp

"4,1% bệnh nhân đái tháo đường được điều trị" là cách đọc sai tỷ lệ phần trăm theo cột ở trên, vốn thực ra nói rằng 4,1% bệnh nhân được điều trị mắc đái tháo đường. Trước khi viết một câu về một tỷ lệ phần trăm, hãy nói to mẫu số là gì: "trong số __, bao nhiêu phần trăm __?"

Cũng hãy lưu ý các con số nhỏ: chỉ 28 bệnh nhân đã được chẩn đoán mắc đái tháo đường, nên con số 75,0% dựa trên 21 trong 28 bệnh nhân và có khoảng tin cậy rộng. Các ô có số đếm nhỏ là dấu hiệu cảnh báo cho các phân tích về sau (Chương 4 giải thích vì sao trong tình huống này kiểm định khi bình phương có thể được thay bằng kiểm định chính xác Fisher).

3.9.7 Bảng chéo với janitor

`tabyl()` cũng tạo được bảng hai chiều, và các hàm `adorn` thêm tổng, tỷ lệ phần trăm và số đếm gốc trong một cách hiển thị dễ đọc.

```
diagnosed |>
  tabyl(diabetes, treatment_uptake) |>
  adorn_totals(c("row", "col")) |>
  adorn_percentages("row") |>           # tỷ lệ phần trăm theo hàng
  adorn_pct_formatting(digits = 1) |>
  adorn_ns() |>                         # thêm số đếm trong ngoặc
  adorn_title("combined")               # ghi nhãn chung cho hàng và cột
```

```
#> diabetes/treatment_uptake           No           Yes           Total
#>         No  54.1% (574)  45.9% (487) 100.0% (1,061)
#>         Yes  25.0% (7)   75.0% (21) 100.0% (28)
#>         Total 53.4% (581) 46.6% (508) 100.0% (1,089)
```

Giờ đây mỗi ô hiển thị tỷ lệ phần trăm theo hàng, theo sau là số đếm, ví dụ "75.0% (21)", đây là định dạng mà nhiều tạp chí ưa chuộng: tỷ lệ phần trăm để so sánh, số đếm để người đọc thấy nó đại diện cho bao nhiêu bệnh nhân.

3.10 Xây dựng Bảng 1 với gtsummary

3.10.1 Bảng 1 cần có những gì

Bảng 1 của một bài báo lâm sàng mô tả đặc điểm của những người tham gia nghiên cứu. Theo STROBE, bảng này nên trình bày các đặc điểm nhân khẩu học, lâm sàng và xã hội, thông tin về các phơi nhiễm và các yếu tố gây nhiễu tiềm tàng, và số người tham gia bị khuyết dữ liệu ở từng biến (Elm et al. 2007). Trong nghiên cứu cắt ngang về việc sử dụng điều trị của chúng ta, một Bảng 1 điển hình sẽ trình bày:

- các biến **nhân khẩu học**: tuổi, giới tính, nơi cư trú, học vấn, bảo hiểm y tế;
- các biến **hành vi**: hút thuốc, rượu bia, hoạt động thể lực;
- các biến **lâm sàng**: BMI, huyết áp, đái tháo đường, tiền sử gia đình;
- **khả năng tiếp cận và kiến thức**: khoảng cách đến cơ sở y tế, điểm kiến thức;

thường cho toàn bộ mẫu và theo biến phân nhóm chính, ở đây là việc sử dụng điều trị ở những bệnh nhân đã được chẩn đoán. Mỗi biến liên tục được tóm tắt bằng trung bình (SD) hoặc trung vị (IQR) tùy theo phân phối của nó, và mỗi biến phân loại bằng n (%).

Xây dựng một bảng như vậy bằng tay, từng ô một, vừa chậm vừa dễ sai: chỉ một lần sao chép-dán nhầm là một tỷ lệ phần trăm đã xuất bản sẽ sai. Gói **gtsummary** tự động hóa toàn bộ quy trình (Sjoberg et al. 2021). Nó xem xét từng biến, chọn một thống kê tóm tắt hợp lý, định dạng các con số, và tạo ra một bảng có thể xuất sang Word, HTML hoặc PDF.

3.10.2 Bảng 1 đầu tiên

```
diagnosed |>
  select(age, sex, residence, health_insurance, diabetes,
         treatment_uptake) |>
  tbl_summary(by = treatment_uptake) |> # mỗi nhóm sử dụng điều trị một cột
  as_kable(caption = "Bảng 1 đầu tiên: kết quả mặc định của gtsummary.")
```

Chỉ với một dòng mã thực sự, `tbl_summary()` đã tạo ra một bảng dùng được. Cách đọc bảng:

- Tiêu đề cột cho biết cỡ của mỗi nhóm: 581 bệnh nhân đã được chẩn đoán không điều trị (No) và 508 bệnh nhân có điều trị (Yes).
- Tuổi, một biến liên tục, được tóm tắt bằng *trung vị (Q1, Q3)*, mặc định của gtsummary cho biến liên tục, vì trung vị và IQR an toàn bất kể hình dạng phân phối.
- Giới tính và nơi cư trú có hai mức, nên cả hai mức đều được liệt kê kèm n (%).
- Bảo hiểm y tế và đái tháo đường là các biến Yes/No, nên gtsummary chỉ hiển thị hàng "Yes" (có), tức một cách tóm tắt *nhị phân* (dichotomous), đây là cách trình bày theo quy ước và gọn hơn.

Bảng 3.10: Bảng 1 đầu tiên: kết quả mặc định của gtsummary.

Characteristic	No N = 581	Yes N = 508
age	51 (41, 60)	56 (47, 66)
Unknown	1	0
sex		
Female	315 (54%)	314 (62%)
Male	266 (46%)	194 (38%)
residence		
Rural	306 (53%)	195 (38%)
Urban	275 (47%)	313 (62%)
health_insurance	162 (28%)	202 (40%)
diabetes	7 (1.2%)	21 (4.1%)

- Nhãn hàng là tên biến gốc (age, health_insurance), và một bệnh nhân bị khuyết tuổi xuất hiện ở hàng có nhãn Unknown (không rõ). Cả hai cần được chỉnh sửa trước khi xuất bản.
- Tỷ lệ phần trăm được làm tròn thành số nguyên, trừ khi dưới 10% thì hiển thị một chữ số thập phân.
- Các tỷ lệ phần trăm là **tỷ lệ phần trăm theo cột**: chúng mô tả thành phần của mỗi nhóm. Con số cho bảo hiểm y tế trong cột No là tỷ lệ người có bảo hiểm trong số 581 bệnh nhân *không được điều trị*, chứ không phải tỷ lệ người không được điều trị trong số những người có bảo hiểm.

Điểm cuối cùng cần được lưu ý cẩn thận, và chúng ta sẽ quay lại sau khi tùy chỉnh bảng.

3.10.3 Tùy chỉnh thống kê, nhãn và giá trị khuyết

Một bảng cho bản thảo cần nhãn dễ đọc, thống kê phù hợp với từng biến, số chữ số thập phân nhất quán và cách xử lý dữ liệu khuyết rõ ràng.

```
table1 <- diagnosed |>
  select(age, sex, residence, education, health_insurance,
         bmi, sbp_mmhg, diabetes, knowledge_score,
         distance_to_facility_km, treatment_uptake) |>
  tbl_summary(
    by = treatment_uptake,
    # các biến đối xứng: trung bình (SD); khoảng cách bị lệch: trung vị (IQR)
    statistic = list(
      all_continuous() ~ "{mean} ({sd})",
      distance_to_facility_km ~ "{median} ({p25}, {p75})",
      all_categorical() ~ "{n} ({p}%"
    ),
    digits = list(all_continuous() ~ 1, all_categorical() ~ c(0, 1)),
    label = list(
      age ~ "Tuổi, năm",
      sex ~ "Giới tính",
      residence ~ "Nơi cư trú",
      education ~ "Học vấn",
      health_insurance ~ "Bảo hiểm y tế",
```

```

bmi ~ "BMI, kg/m^2",
sbp_mmhg ~ "Huyết áp tâm thu, mmHg",
diabetes ~ "Đái tháo đường",
knowledge_score ~ "Điểm kiến thức (0-20)",
distance_to_facility_km ~ "Khoảng cách đến cơ sở y tế, km"
),
missing = "ifany",          # chỉ hiện hàng Khuyết khi cần
missing_text = "Khuyết"
) |>
# cột Chung (overall) đặt đầu tiên
add_overall(last = FALSE, col_label = "**Chung** \nN = {N}") |>
modify_header(label = "**Đặc điểm**")

table1 |>
as_kable(caption = paste("Đặc điểm của bệnh nhân tăng huyết áp đã được",
                          "chẩn đoán theo việc sử dụng điều trị."))

```

Bảng 3.11: Đặc điểm của bệnh nhân tăng huyết áp đã được chẩn đoán theo việc sử dụng điều trị.

Đặc điểm	Chung N = 1089	No N = 581	Yes N = 508
Tuổi, năm	53.5 (14.0)	51.1 (13.4)	56.3 (14.1)
Khuyết	1	1	0
Giới tính			
Female	629 (57.8%)	315 (54.2%)	314 (61.8%)
Male	460 (42.2%)	266 (45.8%)	194 (38.2%)
Nơi cư trú			
Rural	501 (46.0%)	306 (52.7%)	195 (38.4%)
Urban	588 (54.0%)	275 (47.3%)	313 (61.6%)
Học vấn			
None	201 (18.9%)	126 (22.1%)	75 (15.2%)
Primary	444 (41.7%)	252 (44.2%)	192 (38.8%)
Secondary	292 (27.4%)	137 (24.0%)	155 (31.3%)
Tertiary	128 (12.0%)	55 (9.6%)	73 (14.7%)
Khuyết	24	11	13
Bảo hiểm y tế	364 (33.4%)	162 (27.9%)	202 (39.8%)
BMI, kg/m^2	26.8 (4.8)	26.8 (4.9)	26.9 (4.7)
Khuyết	33	19	14
Huyết áp tâm thu, mmHg	144.9 (19.4)	142.2 (19.8)	148.1 (18.3)
Khuyết	1	0	1
Đái tháo đường	28 (2.6%)	7 (1.2%)	21 (4.1%)
Điểm kiến thức (0-20)	10.4 (3.5)	9.9 (3.4)	10.9 (3.4)
Khuyết	29	16	13
Khoảng cách đến cơ sở y tế, km	6.3 (3.8, 10.2)	6.8 (4.3, 10.7)	5.8 (3.1, 9.6)
Khuyết	47	20	27

Đây là một bảng có thể đưa vào bản thảo mà không cần chỉnh sửa thêm nhiều. Những điểm cần lưu ý trong mã và kết quả:

- `statistic` nhận một danh sách các *công thức* (formula): về trái chọn biến (bằng các hàm trợ

giúp như `all_continuous()` và `all_categorical()`, hoặc bằng tên), về phải là một khuôn mẫu trong đó `{mean}`, `{sd}`, `{median}`, `{p25}`, `{p75}`, `{n}` và `{p}` được thay bằng các giá trị đã tính. Quy tắc riêng cho khoảng cách ghi đề quy tắc chung cho các biến liên tục.

- `digits` đặt một chữ số thập phân cho các thống kê của biến liên tục, và số đếm nguyên với một chữ số thập phân cho tỷ lệ phần trăm.
- `label` thay tên biến bằng các nhãn dễ đọc có kèm đơn vị.
- `missing = "ifany"` thêm một hàng "Khuyết" dưới mỗi biến có giá trị khuyết, như STROBE yêu cầu. Giá trị khuyết *không* được tính vào mẫu số của các tỷ lệ phần trăm.
- `add_overall()` thêm một cột cho tất cả bệnh nhân đã được chẩn đoán, ở đây được đặt đầu tiên (đối số `col_label` đặt tiêu đề tiếng Việt cho cột này).

Đọc nội dung bảng, bệnh nhân được điều trị trung bình lớn tuổi hơn (56,3 so với 51,1 tuổi), là phụ nữ nhiều hơn (61,8% so với 54,2%), sống ở thành thị nhiều hơn (61,6% so với 47,3%), có học vấn cao hơn, có bảo hiểm nhiều hơn (39,8% so với 27,9%) và mắc đái tháo đường nhiều hơn, có điểm kiến thức cao hơn khoảng một điểm, và sống gần cơ sở y tế hơn một chút (trung vị 5,8 so với 6,8 km). SBP trung bình của họ cao hơn, vì những lý do đã thảo luận ở Mục 3.7, trong khi BMI gần như giống hệt nhau ở hai nhóm. Đây là những khác biệt *mô tả*; liệu chúng có lớn hơn mức do ngẫu nhiên hay không, và liệu chúng có còn tồn tại sau khi hiệu chỉnh lẫn nhau hay không, là những câu hỏi dành cho Chương 4 và 5.

Diễn giải lâm sàng

Các tỷ lệ phần trăm trong mỗi cột mô tả nhóm đó. "Đái tháo đường: 21 (4,1%)" trong cột được điều trị có nghĩa là 4,1% bệnh nhân được điều trị mắc đái tháo đường. Nó *không* có nghĩa là 4,1% bệnh nhân đái tháo đường được điều trị (con số đó là 75%, từ tỷ lệ phần trăm theo hàng ở Mục 3.9). Nếu câu hỏi của bạn là "việc sử dụng điều trị khác nhau thế nào theo tình trạng đái tháo đường?", hãy báo cáo tỷ lệ phần trăm theo hàng trong phần văn bản, hoặc dùng `tbl_summary(by = diabetes, percent = "row")`.

3.10.4 Bảng 1 có nên chứa giá trị p?

`gtsummary` có thể thêm một cột giá trị p bằng `add_p()`, hàm này chọn một kiểm định cho mỗi biến (kiểm định tổng hạng Wilcoxon hoặc kiểm định t cho biến liên tục, kiểm định khi bình phương hoặc kiểm định chính xác Fisher cho biến phân loại). Việc có *nên* làm vậy hay không vẫn còn tranh luận.

Trong một **thử nghiệm ngẫu nhiên**, Bảng 1 so sánh các nhóm được hình thành do ngẫu nhiên. Theo định nghĩa, mọi khác biệt ban đầu đều do ngẫu nhiên, nên một kiểm định ý nghĩa thống kê đặt ra một câu hỏi mà câu trả lời đã được biết trước; do đó hướng dẫn CONSORT và nhiều nhà thống kê khuyên không nên đưa giá trị p vào bảng đặc điểm ban đầu của một thử nghiệm (Altman 1991). Điều quan trọng là liệu sự mất cân bằng ban đầu có đủ lớn để có ý nghĩa *lâm sàng* hay không, điều mà giá trị p không thể cho bạn biết.

Trong một **nghiên cứu quan sát** như nghiên cứu của chúng ta, việc so sánh các nhóm được xác định theo biến kết cục là một phân tích thực sự (chưa hiệu chỉnh) về mối liên quan, và giá trị p dễ được biện minh hơn. Dù vậy, một cột giá trị p trong Bảng 1 khiến người đọc coi " $p < 0,05$ " như một phán quyết cho từng biến, khuyến khích việc kiểm định nhiều lần, và làm lẫn lộn ý nghĩa thống kê với ý nghĩa lâm sàng (Wasserstein and Lazar 2016; Greenland et al. 2016). Một

giải pháp dung hòa hợp lý, được áp dụng trong cuốn sách này, là giữ Bảng 1 ở dạng mô tả và trình bày các kiểm định cùng các ước lượng hiệu ứng kèm khoảng tin cậy trong một bảng phân tích riêng (Chương 4 và 5). Nếu một tạp chí yêu cầu giá trị p, gtsummary thêm chúng chỉ bằng một dòng, và các kiểm định được giải thích ở Chương 4:

```
diagnosed |>
  select(age, sex, diabetes, treatment_uptake) |>
  tbl_summary(by = treatment_uptake,
    statistic = all_continuous() ~ "{mean} ({sd})",
    label = list(age ~ "Tuổi, năm", sex ~ "Giới tính",
      diabetes ~ "Đái tháo đường"),
    missing_text = "Khuyết") |>
  add_p(test = list(age ~ "t.test")) |> # kiểm định t Welch cho tuổi
  modify_header(label = "***Đặc điểm***", p.value = "***Giá trị p***") |>
  as_kable(caption = "Bảng 1 có cột giá trị p (dùng thận trọng).")
```

Bảng 3.12: Bảng 1 có cột giá trị p (dùng thận trọng).

Đặc điểm	No N = 581	Yes N = 508	Giá trị p
Tuổi, năm	51 (13)	56 (14)	<0.001
Khuyết	1	0	
Giới tính			0.011
Female	315 (54%)	314 (62%)	
Male	266 (46%)	194 (38%)	
Đái tháo đường	7 (1.2%)	21 (4.1%)	0.002

Lỗi thường gặp

Một giá trị p không có ý nghĩa thống kê trong Bảng 1 không chứng tỏ rằng các nhóm "có thể so sánh được", và một giá trị p có ý nghĩa không chứng tỏ rằng một biến là yếu tố gây nhiễu. Không có bằng chứng không phải là bằng chứng của sự không có (Altman and Bland 1995a). Hãy đánh giá sự mất cân bằng qua độ lớn của khác biệt, và xử lý nhiễu bằng hiệu chỉnh (Chương 5).

3.11 Vẽ hình với ggplot2

Bảng cho các con số chính xác; hình cho thấy các xu hướng, hình dạng và giá trị ngoại lai mà bảng che giấu. Một hình tốt thường là phần được đọc nhiều nhất của một bài báo. Trong R, công cụ tiêu chuẩn là **ggplot2** (Wickham 2016), gói mà chúng ta đã dùng cho các histogram ở trên.

3.11.1 Ngữ pháp đồ họa

ggplot2 hiện thực hóa một *ngữ pháp đồ họa* (grammar of graphics): thay vì chọn từ một danh sách các loại biểu đồ, bạn mô tả một biểu đồ như sự kết hợp của các thành phần độc lập (Wickham 2016):

- **dữ liệu** (data): khung dữ liệu cần vẽ;

- **ánh xạ thẩm mỹ** (aesthetic mappings, `aes()`): biến nào được ánh xạ vào thuộc tính thị giác nào, như vị trí trên trục x và y, màu đường viền, màu tô, kích thước hay hình dạng;
- **đối tượng hình học** (`geom_*()`): những gì được vẽ, như điểm, cột, đường, hộp;
- **phép biến đổi thống kê** (`stat_*()`): các phép tính được áp dụng trước khi vẽ, như việc chia khoảng trong histogram hay đường khớp trong một phép làm trơn;
- **thang đo** (`scale_*()`): cách các giá trị dữ liệu được chuyển thành giá trị thị giác, bao gồm các mốc và nhãn trên trục và bảng màu;
- **chia ô** (facets, `facet_wrap()`, `facet_grid()`): các biểu đồ nhỏ lặp lại, mỗi phân nhóm một ô;
- **hệ tọa độ và chủ đề** (theme): hệ tọa độ và phần trình bày không thuộc dữ liệu.

Một biểu đồ được xây dựng bằng cách cộng thêm các lớp bằng dấu `+`. Mọi biểu đồ trong chương này đều theo cùng một khuôn mẫu:

```
ggplot(data = <DATA>, aes(x = <X>, y = <Y>, fill = <GROUP>)) +  
  geom_<TYPE>(<thiết lập cố định như colour hoặc alpha>) +  
  labs(title = "...", x = "... (đơn vị)", y = "...") +  
  theme_minimal()
```

R

Một điểm phân biệt thường làm người mới bắt đầu bối rối: một thuộc tính được *ánh xạ* vào một biến thì đặt bên trong `aes()` (`aes(fill = treatment_uptake)` tô màu các cột theo nhóm), còn một thuộc tính được *đặt* bằng một hằng số thì đặt bên ngoài (`fill = teal` tô mọi cột màu xanh mòng két).

3.11.2 Các nguyên tắc của biểu đồ khoa học tốt

Một vài nguyên tắc, rút ra từ Weissgerber et al. (2015) và Wickham (2016), sẽ cải thiện gần như mọi hình:


1. **Hãy cho thấy dữ liệu.** Bất cứ khi nào cỡ mẫu cho phép, hãy trình bày từng quan sát hoặc toàn bộ phân phối của chúng, chứ không chỉ một thống kê tóm tắt.
2. **Chọn hình phù hợp với loại biến:** histogram hoặc biểu đồ mật độ cho một biến liên tục, biểu đồ cột cho một biến phân loại, biểu đồ hộp, violin hoặc biểu đồ điểm cho một biến liên tục theo nhóm, biểu đồ phân tán cho hai biến liên tục.
3. **Ghi nhãn trục kèm đơn vị** và viết chú thích hình sao cho có thể hiểu được mà không cần đọc phần văn bản.
4. **Sắp xếp các nhóm một cách có ý nghĩa:** biến thứ bậc theo thứ tự tự nhiên của chúng, biến danh định theo tần số hoặc theo thống kê quan tâm.
5. **Dùng màu có mục đích**, để mã hóa một biến, không phải để trang trí; ưu tiên các bảng màu vẫn phân biệt được khi in đen trắng và với người đọc mù màu.
6. **Tránh "rác biểu đồ"** (chart junk): hiệu ứng ba chiều, lưới đậm và trục kép thêm mực mà không thêm thông tin.

3.11.3 Biểu đồ cột cho biến phân loại

`geom_bar()` tự đếm số hàng trong mỗi nhóm, nên nó nhận dữ liệu gốc chứ không phải một bảng đã tính sẵn. Để hiển thị tỷ lệ phần trăm, chúng ta tính chúng trước và dùng `geom_col()`, hàm vẽ các cột có chiều cao cho trước.

```
edu_pct <- analysis_data |>
  filter(!is.na(education)) |>
  count(education) |>
  mutate(pct = n / sum(n))

ggplot(edu_pct, aes(x = education, y = pct)) +
  geom_col(fill = teal, width = 0.7) +
  geom_text(aes(label = percent(pct, accuracy = 0.1)), # ghi nhãn cho mỗi cột
    vjust = -0.4, size = 3.5) +
  scale_y_continuous(labels = label_percent(),
    expand = expansion(mult = c(0, 0.08))) +
  labs(title = "Phần lớn người tham gia có học vấn tiểu học hoặc trung học",
    x = "Trình độ học vấn cao nhất", y = "Bệnh nhân (%)")
```



Hình 3.4: Trình độ học vấn cao nhất của toàn bộ 1.500 người tham gia; các cột được sắp theo thứ tự tự nhiên của các nhóm và ghi nhãn bằng tỷ lệ phần trăm trong số bệnh nhân biết trình độ học vấn (không hiển thị 30 giá trị khuyết).


Vì `education` là một factor có thứ tự, các cột xuất hiện theo thứ tự tự nhiên, từ không đi học (`None`) đến sau trung học (`Tertiary`). Ghi nhãn tỷ lệ phần trăm cho mỗi cột giúp người đọc không phải ước lượng giá trị từ trục. Chú thích hình nêu rõ mẫu số và những gì đã bị loại ra.

Để so sánh phân phối của một biến phân loại *giữa các nhóm*, biểu đồ cột chồng 100% là một lựa chọn gọn. Hình tiếp theo trình bày phân loại BMI theo việc sử dụng điều trị ở những bệnh nhân đã được chẩn đoán.

```
diagnosed |>
  filter(!is.na(bmi_cat)) |>
  ggplot(aes(x = treatment_uptake, fill = bmi_cat)) +
```

```
geom_bar(position = "fill", width = 0.6) +      # "fill" = chồng 100%
scale_y_continuous(labels = label_percent()) +
scale_fill_brewer(palette = "BuGn") +          # bảng màu tuần tự, biến có thứ tự
labs(title = "Phân loại BMI theo việc sử dụng điều trị",
     x = "Đang dùng thuốc điều trị tăng huyết áp", y = "Bệnh nhân (%)",
     fill = "Phân loại BMI")
```

Phân loại BMI theo việc sử dụng điều trị



Hình 3.5: Phân phối phân loại BMI ở những bệnh nhân đã được chẩn đoán không điều trị và có điều trị; mỗi cột cộng lại bằng 100% số bệnh nhân có giá trị BMI.

`position = "fill"` điều chỉnh mỗi cột về 100%, nên các cột so sánh *tỷ lệ* chứ không phải số đếm. Một bảng màu tuần tự (từ nhạt đến đậm) phản ánh thứ tự của các nhóm BMI. Hai cột trông rất giống nhau: đặc điểm BMI của bệnh nhân được điều trị và không được điều trị gần như như nhau.

3.11.4 Biểu đồ hộp, biểu đồ violin và vì sao biểu đồ cột của trung bình che giấu dữ liệu

Một hình rất phổ biến trong các bài báo lâm sàng là biểu đồ cột của trung bình các nhóm kèm thanh sai số (cái gọi là "biểu đồ thuốc nổ", dynamite plot). Weissgerber et al. (2015) đã chỉ ra rằng những biểu đồ như vậy rất phổ biến và gây hiểu lầm: nhiều phân phối khác nhau (đối xứng, lệch, hai đỉnh, có giá trị ngoại lai, hoặc có cỡ mẫu rất chênh lệch) có thể tạo ra cùng một cột. Cột cũng gợi ý rằng các giá trị nằm giữa số không và trung bình, điều vô nghĩa với một phép đo như huyết áp. Hình dưới đây đặt hai cách tiếp cận cạnh nhau cho cùng một dữ liệu.


```
# Ô A: cột trung bình +/- SE (biểu đồ nên tránh)
sbp_means <- diagnosed |>
  group_by(treatment_uptake) |>
  summarise(mean = mean(sbp_mmhg, na.rm = TRUE),
            se = sd(sbp_mmhg, na.rm = TRUE) / sqrt(sum(!is.na(sbp_mmhg))))

p_bar <- ggplot(sbp_means, aes(x = treatment_uptake, y = mean)) +
  geom_col(fill = "grey70", width = 0.6) +
```

```
geom_errorbar(aes(ymin = mean - se, ymax = mean + se), width = 0.2) +
labs(title = "A. Cột trung bình ( $\pm$  SE)",
x = "Đang điều trị", y = "Huyết áp tâm thu (mmHg)")

# Ô B: violin + hộp + các điểm rải ngẫu nhiên (cho thấy dữ liệu)
p_violin <- ggplot(diagnosed, aes(x = treatment_uptake, y = sbp_mmhg)) +
  geom_violin(fill = teal, alpha = 0.25, colour = NA, na.rm = TRUE) +
  geom_jitter(width = 0.15, alpha = 0.25, size = 0.8, na.rm = TRUE) +
  geom_boxplot(width = 0.18, outlier.shape = NA, fill = "white",
alpha = 0.8, na.rm = TRUE) +
labs(title = "B. Violin, hộp và điểm",
x = "Đang điều trị", y = "Huyết áp tâm thu (mmHg)")

p_bar + p_violin # patchwork đặt hai biểu đồ cạnh nhau
```



Hình 3.6: Cùng một dữ liệu SBP của bệnh nhân đã được chẩn đoán được trình bày theo hai cách: (A) biểu đồ cột của trung bình kèm thanh sai số chuẩn che giấu phân phối; (B) biểu đồ violin kèm biểu đồ hộp và từng bệnh nhân (các điểm được rải ngẫu nhiên) cho thấy toàn bộ độ phân tán, sự chồng lấp giữa các nhóm và mọi giá trị ngoại lai.

Ô A gợi ý hai nhóm tách biệt gọn gàng. Ô B cho thấy sự thật: hai phân phối chồng lên nhau gần như hoàn toàn, với SBP ở cả hai nhóm dao động từ khoảng 100 đến 200 mmHg; khác biệt trung bình khoảng 6 mmHg là nhỏ so với độ phân tán giữa các bệnh nhân. Mỗi thành phần của ô B đều mang thông tin:

- **violin** là một ước lượng mật độ được phản chiếu đối xứng, cho thấy hình dạng của phân phối;
- **biểu đồ hộp** cho thấy trung vị (đường đậm), các tứ phân vị (hai cạnh hộp, nên chiều cao hộp là IQR) và các râu (whiskers), kéo dài đến các giá trị cực trị nhất nằm trong phạm vi $1,5 \times$ IQR tính từ hộp; theo quy ước, các điểm nằm ngoài râu được đánh dấu là giá trị ngoại lai tiềm tàng (chúng ta ẩn chúng bằng `outlier.shape = NA` vì các điểm rải ngẫu nhiên đã hiển thị mọi bệnh nhân);
- **các điểm rải ngẫu nhiên** (jittered points) là từng bệnh nhân, được dịch ngang một cách ngẫu nhiên để không chồng lên nhau.

Dấu + giữa hai biểu đồ đã lưu được cung cấp bởi **patchwork**, gói ghép nhiều ggplot thành một hình.

Thực hành tốt


Với một biến kết cục liên tục được so sánh giữa các nhóm, hãy ưu tiên biểu đồ hộp, biểu đồ violin hoặc biểu đồ điểm, và thêm các điểm riêng lẻ khi mỗi nhóm có ít hơn vài trăm quan sát (Weissgerber et al. 2015). Hãy dành biểu đồ cột cho số đếm và tỷ lệ phần trăm, nơi chiều dài của cột tính từ số không thực sự biểu diễn đại lượng đó.

3.11.5 Biểu đồ phân tán cho hai biến liên tục

Mối quan hệ giữa hai biến liên tục được thể hiện bằng biểu đồ phân tán (scatter plot). Ở đây chúng ta vẽ SBP theo BMI cho tất cả bệnh nhân và thêm một đường thẳng khớp với dữ liệu.

```
ggplot(analysis_data, aes(x = bmi, y = sbp_mmhg)) +  
  # độ trong suốt (alpha) làm các vùng dày đặc, chồng lấp hiện đậm hơn  
  geom_point(alpha = 0.25, colour = teal, na.rm = TRUE) +  
  # xu hướng đường thẳng (tuyến tính) kèm dải tin cậy 95%  
  geom_smooth(method = "lm", formula = y ~ x, colour = "grey15",  
             na.rm = TRUE) +  
  labs(title = "BMI cao hơn đi kèm huyết áp tâm thu cao hơn",  
       x = expression("Chỉ số khối cơ thể (kg/m^2)"),  
       y = "Huyết áp tâm thu (mmHg)")
```

BMI cao hơn đi kèm huyết áp tâm thu cao hơn



Hình 3.7: Huyết áp tâm thu theo chỉ số khối cơ thể ở 1.451 bệnh nhân có cả hai số đo; mỗi điểm là một bệnh nhân, và đường thẳng là đường khớp tuyến tính theo bình phương tối thiểu kèm dải tin cậy 95%.

Mỗi điểm là một bệnh nhân. Độ trong suốt ($\alpha = 0.25$) làm các vùng dày đặc đậm hơn, để việc các điểm vẽ chồng lên nhau không che giấu nơi tập trung phần lớn bệnh nhân. Đường thẳng, được khớp theo phương pháp bình phương tối thiểu với $\text{method} = "lm"$, đi lên từ trái sang phải: trung bình, bệnh nhân có BMI cao hơn có SBP cao hơn. Dải màu xám là khoảng tin cậy 95% cho SBP trung bình tại mỗi giá trị BMI, hẹp vì có nhiều bệnh nhân. Đám mây điểm

quanh đường thẳng rộng, nên BMI chỉ giải thích một phần khiêm tốn sự biến thiên SBP giữa các cá nhân. Việc đo lường và kiểm định mối liên quan này (tương quan) được trình bày ở Chương 4, và bản thân đường hồi quy ở Chương 5.

Diễn giải lâm sàng


Độ dốc dương phù hợp với mối liên hệ đã được xác lập rõ giữa thừa cân và tăng huyết áp (Mills et al. 2020). Trong một nghiên cứu cắt ngang, nó chỉ cho thấy mối liên quan: nó không thể chứng minh rằng giảm BMI sẽ làm giảm SBP ở những bệnh nhân này, và các yếu tố khác như tuổi có thể góp phần vào cả hai.

3.11.6 Chia ô: các biểu đồ nhỏ lặp lại

Khi một phép so sánh cần được lặp lại qua các phân nhóm, **chia ô** (facets) vẽ cùng một biểu đồ một lần cho mỗi phân nhóm, trên các trục chung, để các ô có thể được so sánh trực tiếp. Hình dưới đây trình bày phân phối tuổi của bệnh nhân đã được chẩn đoán có điều trị và không điều trị, riêng cho từng cơ sở y tế.

```
ggplot(diagnosed, aes(x = age, fill = treatment_uptake,
                      colour = treatment_uptake)) +
  geom_density(alpha = 0.35, na.rm = TRUE) +
  facet_wrap(~ facility, ncol = 3) + # mỗi cơ sở một ô
  scale_fill_manual(values = c(No = "grey60", Yes = teal)) +
  scale_colour_manual(values = c(No = "grey40", Yes = teal)) +
  labs(title = "Bệnh nhân được điều trị có xu hướng lớn tuổi hơn ở mọi cơ sở",
       x = "Tuổi (năm)", y = "Mật độ",
       fill = "Đang điều trị", colour = "Đang điều trị") +
  theme(legend.position = "bottom")
```

Bệnh nhân được điều trị có xu hướng lớn tuổi hơn ở mọi cơ sở



Hình 3.8: Phân phối tuổi của bệnh nhân đã được chẩn đoán theo việc sử dụng điều trị, trình bày riêng cho từng cơ sở trong sáu cơ sở y tế (đường cong mật độ trên các trục chung); bệnh nhân được điều trị có xu hướng lớn tuổi hơn ở mọi cơ sở.

Trong mọi ô, đường cong màu xanh mỏng kết (được điều trị) dịch sang phải so với đường màu xám (không được điều trị); chênh lệch tuổi trung bình dao động từ khoảng 3 năm ở Kisesa HC, nơi hai đường cong gần như trùng nhau, đến khoảng 7 năm ở Igoma HC. Do đó, khác biệt về tuổi quan sát được ở toàn bộ mẫu không phải do một cơ sở bất thường tạo ra mà nhất quán về chiều hướng ở các cơ sở. Chia ô là một cách đơn giản và mạnh mẽ để kiểm tra xem một xu hướng là chung hay do một phân nhóm chi phối, và nó báo trước ý tưởng về phân tích phân tầng và biến đổi tác động.

3.12 Xuất bảng và hình

Một bản thảo, một báo cáo gửi bộ ngành hay một trang chiếu cho cuộc họp cần các tệp, không phải kết quả hiển thị của R. Nguyên tắc cũng giống như với làm sạch dữ liệu: tệp nên được tạo ra bằng mã, để có thể tái tạo giống hệt bất cứ khi nào dữ liệu hoặc phân tích thay đổi.

3.12.1 Hình

`ggsave()` lưu một biểu đồ vào tệp có định dạng được chọn theo phần mở rộng (.png, .pdf, .tiff, .svg). Các tạp chí thường yêu cầu ít nhất 300 điểm mỗi inch (dpi) cho ảnh raster, hoặc một định dạng vector như PDF. Ở đây chúng ta lưu vào thư mục tạm của R; trong dự án của riêng bạn, bạn sẽ dùng một thư mục như `outputs/`.

```
p_scatter <- ggplot(analysis_data, aes(x = bmi, y = sbp_mmhg)) +
  geom_point(alpha = 0.25, colour = teal, na.rm = TRUE) +
  labs(x = "BMI (kg/m^2)", y = "Huyết áp tâm thu (mmHg)")

out_png <- file.path(tempdir(), "fig_sbp_bmi.png")
ggsave(out_png, plot = p_scatter, width = 7, height = 5, dpi = 300)
file.exists(out_png)
```

```
#> [1] TRUE
```

Luôn truyền đối tượng biểu đồ bằng `plot =` thay vì dựa vào "biểu đồ được hiển thị gần nhất", và đặt `width` và `height` một cách tường minh (mặc định tính bằng inch) để cỡ chữ nhất quán giữa các hình.

3.12.2 Bảng

Một bảng `gtsummary` có thể được chuyển thành **flextable**, gói ghi bảng Word gốc mà các đồng tác giả có thể chỉnh sửa, hoặc thành bảng **gt** cho HTML. Các khung dữ liệu đơn giản có thể được ghi ra CSV cho đồng nghiệp dùng phần mềm khác.

```
out_docx <- file.path(tempdir(), "table1.docx")
table1 |>
  as_flex_table() |>
  flextable::save_as_docx(path = out_docx) # gtsummary -> flextable
                                           # ghi ra tài liệu Word

out_csv <- file.path(tempdir(), "spread_table.csv")
write_csv(spread_table, out_csv)           # CSV thuần cho mọi phần mềm
```

```
file.exists(c(out_docx, out_csv))
```

```
#> [1] TRUE TRUE
```

Trong một dự án thực tế, cùng đoạn mã đó sẽ ghi vào thư mục kết quả của bạn, ví dụ:

```
# Bên trong dự án phân tích của riêng bạn (không chạy ở đây)
ggsave("outputs/figure2_sbp_bmi.pdf", plot = p_scatter, width = 7, height = 5)
table1 |>
  as_flex_table() |>
  flextable::save_as_docx(path = "outputs/table1.docx")
table1 |> as_gt() |> gt::gtsave("outputs/table1.html")
```

Thực hành tốt

Đừng bao giờ gõ lại bằng tay các con số từ kết quả R vào bản thảo. Hãy xuất bảng trực tiếp, và với các con số trong văn bản hãy dùng mã R nội dòng (inline R code) trong R Markdown (như cuốn sách này làm), để mọi con số tự động cập nhật khi dữ liệu thay đổi (Xie 2015; Peng 2011).

3.13 Tóm tắt

Mô tả là bước đầu tiên và cơ bản nhất của mọi phân tích lâm sàng. Trong chương này, chúng ta đã mô tả quần thể của nghiên cứu tình huống bằng số và bằng hình. Chúng ta đã ghép các thống kê tóm tắt với các loại biến; định nghĩa trung bình, trung vị và yếu vị, và thấy một lỗi duy nhất làm dịch chuyển trung bình nhưng không làm dịch chuyển trung vị ra sao; đo độ phân tán bằng khoảng biến thiên, phương sai, SD, phân vị, IQR và CV; xem xét hình dạng qua độ lệch và quy tắc 68–95–99,7 của phân phối chuẩn, và dùng nó để chọn giữa trung bình (SD) và trung vị (IQR). Chúng ta đã gặp cái bẫy `na.rm` và vấn đề quan trọng hơn mà nó che giấu, đó là mẫu số âm thầm thay đổi. Chúng ta đã tạo các bảng tóm tắt theo nhóm, tính sai số chuẩn và khoảng tin cậy cho một trung bình và một tỷ lệ, xây dựng bảng tần số và bảng chéo với tỷ lệ phần trăm đúng, lập Bảng 1 cho bản thảo bằng `gtsummary`, và vẽ các hình trung thực bằng `ggplot2` trước khi xuất chúng ra tệp.

Điểm chính

- Mô tả trước khi kiểm định: phần mô tả người tham gia là kết quả đầu tiên của mọi nghiên cứu và là Bảng 1 của mọi bài báo (các mục 13 và 14 của STROBE).
- Dùng trung bình (SD) cho các biến liên tục đối xứng và trung vị (IQR) cho các biến lệch; kiểm tra hình dạng bằng histogram, không theo thói quen.
- SD mô tả sự biến thiên giữa các bệnh nhân; SE mô tả độ chính xác của một trung bình. Đừng bao giờ dùng SE để mô tả một mẫu.
- `na.rm = TRUE` loại giá trị khuyết khỏi phép tính; hãy luôn đếm và báo cáo chúng.
- CI 95% ($\bar{x} \pm 1.96 \text{ SE}$, hoặc $\hat{p} \pm 1.96 \text{ SE}$) thể hiện độ chính xác của một ước lượng và cung cấp nhiều thông tin hơn chỉ riêng ước lượng.
- Làm cho giá trị khuyết hiện ra trong bảng tần số (`useNA = "ifany"`, `tabyl()`).

- Tính tỷ lệ phần trăm trong các nhóm của biến giải thích, và luôn nêu rõ mẫu số; cần biết mình đang đọc tỷ lệ phần trăm theo hàng hay theo cột.
- `gtsummary::tbl_summary()` xây dựng một Bảng 1 có thể tái lập; hãy giữ nó ở dạng mô tả và trình bày các kiểm định và ước lượng hiệu ứng riêng.
- Hãy cho thấy dữ liệu: ưu tiên biểu đồ hộp, violin và biểu đồ điểm thay vì biểu đồ cột của trung bình, và ghi nhãn trục kèm đơn vị.
- Xuất bảng và hình bằng mã (`ggsave()`, `as_flex_table()`), không bao giờ bằng cách gõ lại.

3.14 Đọc thêm

- Altman (1991), chương 2–4: một trình bày kinh điển, rõ ràng về các loại dữ liệu, thống kê tóm tắt và cách trình bày chúng, được viết cho các nhà nghiên cứu y học.
- Kirkwood and Sterne (2003), chương 2–6: trình bày súc tích về tóm tắt dữ liệu định lượng và phân loại, phân phối chuẩn, sai số chuẩn và khoảng tin cậy.
- Weissgerber et al. (2015): một bài báo ngắn, thuyết phục về lý do biểu đồ cột của trung bình gây hiểu lầm, kèm các phương án thay thế thực tế.
- Sjöberg et al. (2021): bài báo mô tả `gtsummary`, với các ví dụ về những bảng mà gói này có thể tạo ra.
- Wickham (2016): cuốn sách về `ggplot2` của chính tác giả gói, giải thích sâu về ngữ pháp đồ họa.

3.15 Bài tập

Bài tập 3.1

Dùng `analysis_data`, tính trung bình, SD, trung vị và IQR của `age` và của `distance_to_facility_km`, nhớ dùng `na.rm = TRUE`. Mỗi biến có bao nhiêu giá trị khuyết? Với mỗi biến, hãy quyết định trung bình (SD) hay trung vị (IQR) là cách tóm tắt tốt hơn, và lý giải lựa chọn của bạn bằng các con số.

Bài tập 3.2

Với `ldl_mmol_l` (cholesterol LDL), hãy cho thấy `mean()` trả về gì khi không có `na.rm = TRUE`. Sau đó báo cáo số lượng và tỷ lệ phần trăm giá trị khuyết, trung bình và SD ở những bệnh nhân có kết quả, và hệ số biến thiên. Viết một câu báo cáo kết quả như cách nó sẽ xuất hiện trong một bài báo.

Bài tập 3.3

Lập bảng tần số (số đếm và tỷ lệ phần trăm) của `smoking` và `bp_category` cho tất cả bệnh nhân, sao cho giá trị khuyết hiện ra. Dùng cả `table(..., useNA = "ifany")` và `janitor::tabyl()`. Bao nhiêu phần trăm bệnh nhân hiện đang hút thuốc (a) trong tổng số

bệnh nhân và (b) trong số những người biết tình trạng hút thuốc?

Bài tập 3.4

Ở những bệnh nhân đã được chẩn đoán (`htn_diagnosed == "Yes"`), lập bảng chéo `health_insurance` theo `treatment_uptake`. Tính cả tỷ lệ phần trăm theo hàng và theo cột. Bao nhiêu phần trăm bệnh nhân đã được chẩn đoán *có bảo hiểm* đang điều trị, và bao nhiêu phần trăm ở nhóm *không có bảo hiểm*? Tỷ lệ phần trăm nào trả lời câu hỏi "bảo hiểm có liên quan đến việc sử dụng điều trị không?", và vì sao?

Bài tập 3.5

Ở những bệnh nhân đã được chẩn đoán, tính SBP trung bình kèm sai số chuẩn và khoảng tin cậy 95% riêng cho bệnh nhân được điều trị và không được điều trị, dùng `group_by()` và `summarise()`. Sau đó tính tỷ lệ đang điều trị ở bệnh nhân đã được chẩn đoán sống ở nông thôn và ở thành thị, mỗi tỷ lệ kèm CI 95%. Giải thích bằng lời sự khác biệt giữa SD và SE trong kết quả của bạn.

Bài tập 3.6

Xây dựng một Bảng 1 cho bệnh nhân đã được chẩn đoán, phân tầng theo `treatment_uptake`, bằng `gtsummary::tbl_summary()`, gồm `age`, `sex`, `residence`, `education`, `health_insurance`, `family_history_htn`, `knowledge_score` và `comorbidity_count`. Dùng trung bình (SD) cho tuổi và điểm kiến thức, trung vị (IQR) cho số bệnh đồng mắc, nhãn dễ đọc, một cột chung và một hàng dữ liệu khuyết khi cần. Nêu tên hai đặc điểm khác nhau giữa các nhóm và cho biết những khác biệt đó có hợp lý về mặt lâm sàng hay không.

Bài tập 3.7

Vẽ (a) một biểu đồ hộp kèm các điểm rải ngẫu nhiên của `knowledge_score` theo `treatment_uptake` ở những bệnh nhân đã được chẩn đoán, và (b) một biểu đồ cột tỷ lệ phần trăm bệnh nhân đã được chẩn đoán đang điều trị theo `education`, theo thứ tự tự nhiên của các trình độ học vấn. Đặt cho cả hai hình tiêu đề giàu thông tin, nhãn trục và một câu theo kiểu chú thích hình mô tả những gì chúng cho thấy.

Bài tập 3.8

(Thử thách.) Với mỗi cơ sở y tế, ở những bệnh nhân đã được chẩn đoán, hãy tính số bệnh nhân, tỷ lệ phần trăm đang điều trị kèm CI 95% Wilson (`prop.test()`), khoảng cách trung vị đến cơ sở và tỷ lệ phần trăm có bảo hiểm. Trình bày kết quả dưới dạng một bảng được sắp xếp theo tỷ lệ sử dụng điều trị, và vẽ biểu đồ phân tán tỷ lệ sử dụng điều trị của cơ sở (trục y) theo khoảng cách trung vị (trục x), với các điểm được ghi nhãn bằng tên cơ sở. Tỷ lệ sử dụng điều trị ở cấp cơ sở có vẻ liên quan đến khoảng cách không? Vì sao các kết luận rút ra từ sáu cơ sở cần được đưa ra hết sức thận trọng?

CHƯƠNG 4

Các kiểm định thống kê thường dùng trong nghiên cứu y học

Ở Chương 3, chúng ta đã mô tả 1.500 bệnh nhân của mình: tuổi, huyết áp, số người có bảo hiểm y tế và số người đã tiếp nhận điều trị thuốc hạ áp. Mô tả là cần thiết, nhưng hiếm khi trả lời được câu hỏi mà người thầy thuốc hay nhà hoạch định y tế thực sự đặt ra. Họ muốn biết liệu những bệnh nhân tiếp nhận điều trị có *khác* những người không tiếp nhận hay không: lớn tuổi hơn, hiểu biết tốt hơn, sống gần cơ sở y tế hơn, hay có bảo hiểm y tế nhiều hơn. Trong mẫu của chúng ta, những bệnh nhân được điều trị trung bình lớn hơn khoảng năm tuổi so với những người không được điều trị. Đó có phải là một đặc điểm thực sự của bệnh nhân tăng huyết áp đến khám tại tuyến chăm sóc ban đầu, hay một chênh lệch cỡ đó hoàn toàn có thể xuất hiện do ngẫu nhiên, chỉ vì chúng ta tình cờ tuyển chọn đúng 1.089 bệnh nhân đã được chẩn đoán này mà không phải những người khác? Các kiểm định thống kê, cùng với "người họ hàng gần" của chúng là khoảng tin cậy, là những công cụ giúp chúng ta đi từ *mô tả một mẫu* đến *đưa ra những nhận định thận trọng về quần thể mà mẫu đó được rút ra*. Chương này giải thích logic đằng sau các kiểm định, trình bày một số ít kiểm định bao quát phần lớn các câu hỏi trong nghiên cứu y học, và — điều cũng quan trọng không kém — hướng dẫn cách đọc và báo cáo kết quả mà không rơi vào những cái bẫy đã khiến giá trị p trở thành một trong những con số bị hiểu sai nhiều nhất trong khoa học.

Mục tiêu học tập

- Giải thích sự khác biệt giữa quần thể và mẫu, và vì sao các ước lượng thay đổi từ mẫu này sang mẫu khác (sai số chuẩn).
- Mô tả logic của một kiểm định giả thuyết: giả thuyết không và giả thuyết đối, thống kê kiểm định, phân phối dưới giả thuyết không và giá trị p .
- Phát biểu đúng giá trị p là gì và không phải là gì; giải thích sai lầm loại I, sai lầm loại II, lực thống kê và khoảng tin cậy.
- Xác định quần thể phân tích một cách tường minh và lý giải lựa chọn đó.
- Đánh giá tính chuẩn của một biến liên tục bằng biểu đồ tần suất (histogram), biểu đồ Q-Q và kiểm định Shapiro–Wilk, và giải thích vì sao các kiểm định chuẩn hình thức dễ gây hiểu lầm khi cỡ mẫu lớn.
- So sánh một biến liên tục giữa hai nhóm (kiểm định t Student và Welch, kiểm định tổng hạng Wilcoxon) và giữa nhiều hơn hai nhóm (ANOVA một yếu tố, kiểm định Kruskal–Wallis), kèm các so sánh hậu kiểm (post-hoc) phù hợp.

- Kiểm định mối liên quan giữa hai biến phân loại (kiểm định khi bình phương và kiểm định chính xác Fisher) và ước lượng hiệu số nguy cơ, nguy cơ tương đối và tỷ số chênh kèm khoảng tin cậy.
- Đo lường mối liên quan giữa hai biến liên tục bằng hệ số tương quan Pearson và Spearman.
- Chọn kiểm định phù hợp cho một câu hỏi nghiên cứu, nhận ra khi nào các kiểm định đơn biến là chưa đủ, và báo cáo kết quả bằng lời với một ước lượng, một khoảng tin cậy và một giá trị p.

Chúng ta dùng các gói giống như ở những chương trước và nạp lại bộ dữ liệu sạch đã lưu ở cuối Chương 2. Mọi chương đều bắt đầu từ tệp đã lưu đó; không có gì phải làm sạch lại bằng tay.

```
library(tidyverse) # dplyr để xử lý dữ liệu, ggplot2 để vẽ hình
library(broom)    # tidy() đưa kết quả kiểm định, mô hình về data frame
library(patchwork) # đặt nhiều khung ggplot2 cạnh nhau
library(gtsummary) # bảng tóm tắt kèm giá trị p

course_teal <- "#0D7377" # màu nhấn dùng cho các hình trong sách
course_amber <- "#E8A33D" # màu thứ hai cho các hình so sánh hai nhóm

analysis_data <- readRDS("Data/analysis_data.rds")
dim(analysis_data)
```

```
#> [1] 1500 38
```

4.1 Từ mô tả đến suy luận

4.1.1 Quần thể, mẫu, tham số và thống kê

Hầu như mọi nghiên cứu lâm sàng đều quan sát một **mẫu** (sample) người để tìm hiểu về một **quần thể** (population) lớn hơn. Nghiên cứu của chúng ta tuyển chọn người trưởng thành đến khám tại sáu cơ sở chăm sóc sức khỏe ban đầu; quần thể quan tâm, nói rộng ra, là người trưởng thành đến khám tại các cơ sở chăm sóc ban đầu tương tự. Những đại lượng mô tả quần thể, chẳng hạn tỷ lệ thực sự bệnh nhân tăng huyết áp đã được chẩn đoán đang điều trị, hay tuổi trung bình thực sự của những người đang điều trị, được gọi là **tham số** (parameter). Chúng cố định nhưng chưa biết. Các đại lượng tương ứng tính từ dữ liệu của chúng ta, chẳng hạn tỷ lệ đang điều trị quan sát được, được gọi là **thống kê** (statistic) hay **ước lượng** (estimate). Chúng ta dùng chữ cái Hy Lạp cho tham số và chữ cái La-tinh cho ước lượng: μ là trung bình quần thể và $\bar{x}$ là trung bình mẫu dùng để ước lượng nó; π là tỷ lệ quần thể và p là tỷ lệ mẫu (Kirkwood and Sterne 2003; Altman 1991).

Suy luận thống kê (statistical inference) là công việc dùng các ước lượng để nói điều gì đó về các tham số, kèm theo một nhận định trung thực về mức độ không chắc chắn của chúng ta. Nó dựa trên một giả định then chốt: mẫu có thể được coi (gần đúng) là một mẫu ngẫu nhiên từ quần thể. Không kiểm định thống kê nào cứu được một mẫu thiếu tính đại diện nghiêm trọng. Ví dụ, nếu chỉ những bệnh nhân có động lực nhất đồng ý tham gia, tỷ lệ đang điều trị trong mẫu sẽ ước lượng quá cao tỷ lệ trong quần thể, và giá trị p sẽ hoàn toàn không cảnh báo chúng ta điều

đó. Các kiểm định trong chương này xử lý **sai số ngẫu nhiên** (random error, tức tác động của may rủi); chúng không xử lý **sai số hệ thống** (systematic error — sai lệch trong chọn mẫu, đo lường hoặc nhiễu), vốn phải được giải quyết bằng thiết kế nghiên cứu và, như Chương 5 sẽ trình bày, một phần bằng hiệu chỉnh thống kê (Rothman et al. 2008).

4.1.2 Biến thiên do chọn mẫu và sai số chuẩn

Hãy tưởng tượng lặp lại nghiên cứu nhiều lần, mỗi lần tuyển chọn một tập bệnh nhân ngẫu nhiên khác nhau. Mỗi lần lặp sẽ cho một giá trị huyết áp tâm thu trung bình hơi khác nhau. **Biến thiên do chọn mẫu** (sampling variation) này là không thể tránh khỏi, và độ lớn của nó phụ thuộc vào hai yếu tố: phép đo biến thiên nhiều đến đâu giữa các cá nhân, và chúng ta đo bao nhiêu người. Phân phối của một ước lượng qua các lần lặp lại giả định của nghiên cứu được gọi là **phân phối mẫu** (sampling distribution) của nó, và độ lệch chuẩn của phân phối mẫu đó được gọi là **sai số chuẩn** (standard error, SE). Với trung bình mẫu, sai số chuẩn là

$$SE(\bar{x}) = \frac{\sigma}{\sqrt{n}} \approx \frac{s}{\sqrt{n}},$$

trong đó σ là độ lệch chuẩn của phép đo trong quần thể, được ước lượng bằng độ lệch chuẩn mẫu s , và n là cỡ mẫu. Với một tỷ lệ p , sai số chuẩn là $\sqrt{p(1-p)/n}$. Sự phân biệt giữa hai đại lượng "chuẩn" này rất quan trọng và thường bị nhầm lẫn trong các bài báo đã công bố: **độ lệch chuẩn** mô tả mức độ biến thiên giữa các cá nhân, còn **sai số chuẩn** mô tả mức độ chính xác khi ta ước lượng một đại lượng tóm tắt như trung bình (Altman 1991; Bland 2015). Độ lệch chuẩn không nhỏ đi khi ta tuyển thêm bệnh nhân; sai số chuẩn thì có, theo tỷ lệ $1/\sqrt{n}$. Muốn giảm sai số chuẩn đi một nửa, chúng ta cần số bệnh nhân gấp bốn lần.

Chúng ta có thể quan sát trực tiếp biến thiên do chọn mẫu bằng một mô phỏng nhỏ. Ta coi 1.088 bệnh nhân đã được chẩn đoán có ghi nhận huyết áp tâm thu như thể đó là toàn bộ quần thể, rút 2.000 mẫu ngẫu nhiên gồm 25 bệnh nhân và 2.000 mẫu gồm 100 bệnh nhân, rồi tính huyết áp tâm thu trung bình của từng mẫu.

```

dx_all <- filter(analysis_data, htn_diagnosed == "Yes")
sbp_pop <- na.omit(dx_all$sbp_mmhg) # "quần thể" giả định của chúng ta

set.seed(2026) # giúp mô phỏng có thể tái lập
sim_means <- tibble(
  n = rep(c(25, 100), each = 2000),
  sample_mean = c(replicate(2000, mean(sample(sbp_pop, 25))),
    replicate(2000, mean(sample(sbp_pop, 100))))
)

# Độ phân tán của 2.000 trung bình mẫu so với công thức sigma / sqrt(n)
sim_means |>
  group_by(n) |>
  summarise(mean_of_means = mean(sample_mean),
    sd_of_means = sd(sample_mean),
    formula_se = sd(sbp_pop) / sqrt(first(n)))


#> # A tibble: 2 × 4
#>       n mean_of_means sd_of_means formula_se
#>   <dbl>         <dbl>         <dbl>         <dbl>
#> 1    25           145.           3.80           3.87

```

```
#> 2    100      145.      1.80      1.94
```

Huyết áp tâm thu trung bình của quần thể là 144.9 mmHg và độ lệch chuẩn là 19.4 mmHg. Kết quả cho thấy ba điều. Thứ nhất, trung bình của 2.000 trung bình mẫu (mean_of_means) về cơ bản bằng trung bình quần thể dù cỡ mẫu là bao nhiêu: trung bình mẫu là một ước lượng **không chệch** (unbiased). Thứ hai, các trung bình mẫu dao động ít hơn nhiều với mẫu 100 người so với mẫu 25 người: độ lệch chuẩn của các trung bình mô phỏng (sd_of_means) giảm khoảng một nửa khi n tăng gấp bốn. Thứ ba, độ phân tán thực nghiệm đó rất khớp với công thức $\sigma/\sqrt{n}$ (formula_se); nó nhỏ hơn một chút với $n = 100$ chỉ vì chúng ta lấy mẫu không hoàn lại từ một "quần thể" hữu hạn gồm 1.088 bệnh nhân. Trong một nghiên cứu thực tế, chúng ta chỉ có một mẫu duy nhất, nhưng công thức cho phép ước lượng sai số chuẩn từ chính mẫu đó. Hình 4.1 trình bày hai phân phối mẫu.

```
ggplot(sim_means, aes(x = sample_mean)) +  
  geom_histogram(binwidth = 1, fill = "teal", colour = "white") +  
  geom_vline(xintercept = mean(sbp_pop), linetype = "dashed") +  
  facet_wrap(~ n, labeller = label_both) +  
  labs(x = "Huyết áp tâm thu trung bình trong mẫu (mmHg)",  
       y = "Số mẫu")
```



Hình 4.1: Phân phối mẫu của huyết áp tâm thu trung bình trong 2.000 mẫu ngẫu nhiên gồm 25 và gồm 100 bệnh nhân đã được chẩn đoán. Mẫu lớn hơn cho các trung bình tập trung sát hơn quanh trung bình quần thể (đường nét đứt).

Cũng cần lưu ý rằng cả hai biểu đồ tần suất đều có dạng đường cong chuẩn hình chuông quen thuộc, mặc dù huyết áp tâm thu ở từng cá nhân hơi lệch. Đây chính là **định lý giới hạn trung tâm** (central limit theorem) đang phát huy tác dụng: dù phân phối của các giá trị cá nhân có hình dạng thế nào, phân phối mẫu của một trung bình (hoặc một tỷ lệ) sẽ xấp xỉ phân phối chuẩn khi cỡ mẫu tăng lên (Kirkwood and Sterne 2003; Lumley et al. 2002). Định lý này là lý do vì sao rất nhiều kiểm định dựa trên phân phối chuẩn hoạt động tốt với cỡ mẫu vừa và lớn, và chúng ta sẽ quay lại với nó khi bàn về tính chuẩn ở Mục 4.3.

4.1.3 Logic của một kiểm định giả thuyết

Một kiểm định giả thuyết (hypothesis test) đặt ra một câu hỏi hẹp: *nếu thực sự không có khác biệt (hay không có mối liên quan) trong quần thể, thì dữ liệu của chúng ta đáng ngạc nhiên đến mức nào?* Quy trình gồm năm bước (Kirkwood and Sterne 2003; Altman 1991).

1. Phát biểu **giả thuyết không** (null hypothesis), H_0 , thường là "không có tác động": ví dụ, khoảng cách trung bình đến cơ sở y tế là như nhau ở bệnh nhân tiếp nhận điều trị và ở bệnh nhân không tiếp nhận, $H_0 : \mu_{\text{Yes}} = \mu_{\text{No}}$.
2. Phát biểu **giả thuyết đối** (alternative hypothesis), H_1 , thường là có một khác biệt nào đó theo bất kỳ hướng nào, $H_1 : \mu_{\text{Yes}} \neq \mu_{\text{No}}$ (giả thuyết đối *hai phía*).
3. Tính một **thống kê kiểm định** (test statistic) từ dữ liệu: một con số duy nhất đo mức độ dữ liệu khác với điều mà H_0 dự đoán, thường tính theo đơn vị sai số chuẩn,

$$\text{thống kê kiểm định} = \frac{\text{ước lượng quan sát} - \text{giá trị theo } H_0}{\text{sai số chuẩn của ước lượng}}.$$

4. Xác định **phân phối dưới giả thuyết không** (null distribution): phân phối mà thống kê kiểm định sẽ có nếu H_0 đúng. Với nhiều kiểm định, đây là một phân phối lý thuyết đã biết (chuẩn, t , χ^2 hoặc F).
5. So sánh thống kê quan sát được với phân phối dưới giả thuyết không để thu được **giá trị p** (p-value).

Phân phối dưới giả thuyết không là trái tim khái niệm của kiểm định, và có thể xây dựng nó mà không cần đến bất kỳ lý thuyết nào. Giả sử việc tiếp nhận điều trị hoàn toàn không liên quan đến khoảng cách tới cơ sở y tế. Khi đó các nhãn "Yes" (có) và "No" (không) gắn với bệnh nhân là tùy ý, và việc xáo trộn chúng một cách ngẫu nhiên sẽ tạo ra những chênh lệch khoảng cách trung bình tương tự chênh lệch mà ta đã quan sát. Đây là một **kiểm định hoán vị** (permutation test). Chúng ta xáo trộn các nhãn 5.000 lần và ghi lại chênh lệch khoảng cách trung bình mỗi lần.

```
perm_data <- filter(dx_all, !is.na(distance_to_facility_km))
# Chênh lệch khoảng cách trung bình quan sát được, No trừ Yes (km)
obs_diff <- with(perm_data,
  mean(distance_to_facility_km[treatment_uptake == "No"]) -
  mean(distance_to_facility_km[treatment_uptake == "Yes"]))
obs_diff

#> [1] 1.0777
```

```
set.seed(2026)
perm_diffs <- replicate(5000, {
  shuffled <- sample(perm_data$treatment_uptake) # phá vỡ mọi liên kết thực
  mean(perm_data$distance_to_facility_km[shuffled == "No"]) -
  mean(perm_data$distance_to_facility_km[shuffled == "Yes"])
})


# Giá trị p hai phía: tỷ lệ các lần xáo trộn cực đoan ít nhất bằng quan sát
```

```
mean(abs(perm_diffs) >= abs(obs_diff))
```

```
#> [1] 0.0034
```

Bệnh nhân không được điều trị sống xa cơ sở y tế hơn trung bình khoảng 1,08 km so với bệnh nhân được điều trị. Trong 5.000 lần xáo trộn ngẫu nhiên, một chênh lệch ít nhất lớn như vậy theo bất kỳ hướng nào chỉ xảy ra vài lần, nên giá trị p hoán vị vào khoảng 0,003. Hình 4.2 trình bày phân phối dưới giả thuyết không và vị trí của chênh lệch quan sát được.

```
tibble(diff = perm_diffs) |>
  mutate(extreme = abs(diff) >= abs(obs_diff)) |>
  ggplot(aes(x = diff, fill = extreme)) +
  geom_histogram(binwidth = 0.05, colour = "white", linewidth = 0.1) +
  geom_vline(xintercept = obs_diff, linewidth = 0.8) +
  geom_vline(xintercept = -obs_diff, linetype = "dashed") +
  scale_fill_manual(values = c(`FALSE` = "grey70", `TRUE` = "darkred"),
    guide = "none") +
  labs(x = "Chênh lệch khoảng cách trung bình theo H0 (km)",
    y = "Số lần xáo trộn")
```



Hình 4.2: Phân phối hoán vị dưới giả thuyết không của chênh lệch khoảng cách trung bình đến cơ sở y tế (không điều trị trừ có điều trị) khi các nhãn điều trị được xáo trộn ngẫu nhiên. Đường liền đánh dấu chênh lệch quan sát được và đường nét đứt là ảnh đối xứng của nó; các phần đuôi được tô màu chứa những lần xáo trộn cực đoan ít nhất bằng dữ liệu.

Biểu đồ tần suất màu xám là những gì may rủi đơn thuần tạo ra: các chênh lệch tập trung quanh không, phần lớn nằm trong khoảng ± 0.7 km. Chênh lệch quan sát được 1,08 km của chúng ta nằm rất xa ở đuôi phải. Hoặc chúng ta vừa chứng kiến một sự kiện hiếm gặp, hoặc giả thuyết không là sai. Kiểm định t ở Mục 4.4 đi đến cùng kết luận bằng cách dùng phân phối t lý thuyết thay cho việc xáo trộn, và cho giá trị p gần như y hệt (0,003).

4.1.4 Giá trị p là gì và không phải là gì

Giá trị p là xác suất — được tính với giả định rằng giả thuyết không (và mọi giả định khác của kiểm định) là đúng — thu được một thống kê kiểm định ít nhất cực đoan bằng thống kê đã quan

sát. Giá trị p nhỏ nghĩa là dữ liệu sẽ bất thường nếu H_0 đúng; đó là bằng chứng chống lại H_0 . Giá trị p càng nhỏ, bằng chứng càng mạnh (Kirkwood and Sterne 2003).

Năm 2016, Hiệp hội Thống kê Hoa Kỳ (American Statistical Association) đã đưa ra một tuyên bố công khai hiếm có về giá trị p vì tình trạng sử dụng sai đã trở nên quá phổ biến (Wasserstein and Lazar 2016). Sáu nguyên tắc của tuyên bố này, cùng với danh mục dài hơn về các cách hiểu sai do Greenland et al. (2016) tổng hợp, có thể tóm tắt như sau.

- Giá trị p cho biết dữ liệu không tương thích đến mức nào với một mô hình thống kê xác định (giả thuyết không cộng với các giả định của kiểm định).
- Giá trị p **không** phải là xác suất để giả thuyết không đúng, cũng không phải là xác suất để kết quả xuất hiện "chỉ do ngẫu nhiên". Giá trị $p = 0,003$ không có nghĩa là có 0,3% khả năng khoảng cách không liên quan đến việc tiếp nhận điều trị.
- Các kết luận khoa học và quyết định lâm sàng không nên chỉ dựa vào việc giá trị p có vượt qua một ngưỡng như 0,05 hay không.
- Suy luận đúng đắn đòi hỏi báo cáo đầy đủ và minh bạch: thực hiện nhiều kiểm định rồi chỉ báo cáo những kiểm định "có ý nghĩa" sẽ làm mất hiệu lực của các giá trị p .
- Giá trị p **không** đo độ lớn của một tác động hay tầm quan trọng của một kết quả. Một khác biệt rất nhỏ, không có ý nghĩa lâm sàng vẫn có thể có giá trị p rất nhỏ trong một nghiên cứu lớn.
- Tự thân giá trị p không phải là một thước đo tốt về bằng chứng cho một giả thuyết; nó cần được đi kèm với một ước lượng tác động và khoảng tin cậy của ước lượng đó.

Lỗi thường gặp

Viết " $p = 0,003$, vậy có 99,7% khả năng khác biệt là có thật" là sai. Giá trị p được tính với *giả định* giả thuyết không là đúng, nên nó không thể là xác suất để giả thuyết không đúng. Sai không kém là câu " $p = 0,40$, vậy không có khác biệt": một giá trị p lớn chỉ nói rằng dữ liệu tương thích với việc không có khác biệt; dữ liệu cũng có thể tương thích với một khác biệt lớn.

4.1.5 Mức ý nghĩa, sai lầm loại I, sai lầm loại II và lực thống kê

Nhiều nghiên cứu biến giá trị p thành một quyết định bằng cách so sánh nó với một **mức ý nghĩa** (significance level) α được chọn trước, theo quy ước là 0,05: nếu $p < \alpha$ thì kết quả được gọi là "có ý nghĩa thống kê" và H_0 bị "bác bỏ". Ngưỡng này là một quy ước, không phải một quy luật tự nhiên, và về bản chất không có gì khác biệt giữa $p = 0.049$ và $p = 0.051$ (Wasserstein and Lazar 2016). Tuy nhiên, suy nghĩ theo hướng ra quyết định giúp làm rõ hai loại sai lầm mà một kiểm định có thể mắc phải (Bảng 4.1).

Sai lầm loại I (Type I error) là kết luận có khác biệt khi thực tế không có; theo cách xây dựng, xác suất của nó là α đối với một kiểm định đơn lẻ. **Sai lầm loại II** (Type II error) là không phát hiện được một khác biệt có thật; xác suất của nó được ký hiệu là β . **Lực thống kê** (power) của một nghiên cứu, $1 - \beta$, là xác suất nghiên cứu phát hiện được một tác động thực có độ lớn xác định. Lực thống kê tăng theo độ lớn của tác động thực, theo cỡ mẫu và theo mức ý nghĩa, và giảm khi độ biến thiên của biến kết cục tăng (Altman 1991; Kirkwood and Sterne 2003). Các nghiên cứu lâm sàng thường được thiết kế để có lực thống kê 80% hoặc 90% đối với tác động

Bảng 4.1: Bốn kết cục có thể xảy ra của một kiểm định giả thuyết.

Quyết định từ kiểm định	H_0 thực sự đúng	H_0 thực sự sai
Bác bỏ H_0 ("có ý nghĩa")	Sai lầm loại I (dương tính giả); xác suất α	Đúng; xác suất $1 - \beta =$ lực thống kê
Không bác bỏ H_0	Đúng; xác suất $1 - \alpha$	Sai lầm loại II (âm tính giả); xác suất β

nhỏ nhất có ý nghĩa lâm sàng. Hàm `power.t.test()` của R thực hiện phép tính chuẩn cho việc so sánh hai trung bình.

```
# Số bệnh nhân cần cho mỗi nhóm để phát hiện chênh lệch 5 mmHg
# về SBP trung bình,
# với SD 19 mmHg (như trong dữ liệu), alpha hai phía = 0,05,
# lực thống kê 80%
power.t.test(delta = 5, sd = 19, sig.level = 0.05, power = 0.80)
```

R

```
#>
#> Two-sample t test power calculation
#>
#>          n = 227.64
#>        delta = 5
#>          sd = 19
#>    sig.level = 0.05
#>        power = 0.8
#> alternative = two.sided
#>
#> NOTE: n is number in *each* group
```

Để phát hiện chênh lệch 5 mmHg về huyết áp tâm thu trung bình, với độ lệch chuẩn 19 mmHg, lực thống kê 80% ở mức ý nghĩa 5%, cần khoảng 228 bệnh nhân cho mỗi nhóm (R báo cáo n dưới dạng số thập phân, ta làm tròn lên). Nghiên cứu của chúng ta có hơn 500 bệnh nhân mỗi nhóm, nên có lực thống kê cao đối với những khác biệt cỡ đó; điều này cũng có nghĩa là nó sẽ đánh dấu cả những khác biệt khá nhỏ là có ý nghĩa thống kê.

4.1.6 Khoảng tin cậy và giá trị p

Khoảng tin cậy (confidence interval, CI; viết tắt tiếng Việt là KTC) cho một khoảng các giá trị của tham số quần thể tương thích với dữ liệu. Với một ước lượng có phân phối mẫu xấp xỉ chuẩn, khoảng tin cậy 95% là

$$\text{ước lượng} \pm 1.96 \times \text{SE}(\text{ước lượng}).$$

Cách diễn giải liên quan đến quy trình: nếu chúng ta lặp lại nghiên cứu nhiều lần và mỗi lần tính một khoảng tin cậy 95%, thì khoảng 95% trong số các khoảng đó sẽ chứa tham số thực (Altman 1991; Kirkwood and Sterne 2003). Nói một cách không chính thức, khoảng tin cậy cho thấy dải các giá trị quần thể mà dữ liệu của chúng ta tương đối phù hợp.

Khoảng tin cậy và giá trị p hai phía là hai góc nhìn của cùng một phép tính. Nếu khoảng tin cậy 95% của một hiệu số không chứa 0 (hoặc khoảng tin cậy 95% của một tỷ số không chứa 1), thì $p < 0.05$, và ngược lại. Nhưng khoảng tin cậy mang nhiều thông tin hơn hẳn giá trị p: nó cho

thấy **độ lớn** của tác động, **hướng** của tác động và **độ chính xác** của ước lượng. Một khoảng rộng cảnh báo rằng nghiên cứu không xác định được rõ tác động; một khoảng hẹp nằm hoàn toàn trong vùng các giá trị không quan trọng về mặt lâm sàng cho biết mọi tác động đều quá nhỏ để có ý nghĩa. Vì lý do này, các tạp chí y học và hướng dẫn báo cáo yêu cầu tác giả báo cáo ước lượng tác động kèm khoảng tin cậy, và coi giá trị p là thông tin thứ yếu (Altman 1991; Elm et al. 2007).

4.1.7 Ý nghĩa thống kê và ý nghĩa lâm sàng

"Có ý nghĩa thống kê" chỉ có nghĩa là dữ liệu khó dung hòa với giả thuyết không. Nó không có nghĩa là tác động lớn, quan trọng hay hữu ích. Trong một nghiên cứu lớn, chênh lệch 1 mmHg về huyết áp tâm thu trung bình có thể có ý nghĩa thống kê nhưng không có hệ quả lâm sàng nào với từng bệnh nhân. Ngược lại, trong một nghiên cứu nhỏ, mức giảm 10 mmHg có ý nghĩa lâm sàng quan trọng vẫn có thể không đạt ý nghĩa thống kê vì khoảng tin cậy rộng. Câu hỏi "có ý nghĩa không?" luôn cần được theo sau bởi câu hỏi "lớn đến đâu, và độ lớn đó có quan trọng với bệnh nhân không?" Trả lời câu hỏi thứ hai đòi hỏi kiến thức lâm sàng chứ không phải thống kê: ví dụ, biết rằng việc giảm bền vững 10 mmHg huyết áp tâm thu làm giảm đáng kể nguy cơ tim mạch (World Health Organization 2021).

4.1.8 Không có bằng chứng không phải là bằng chứng của sự không có

Một kết quả không có ý nghĩa thống kê thường bị báo cáo sai thành "không có khác biệt" hoặc "điều trị không có tác dụng". Altman and Bland (1995a) gọi đây là một trong những lỗi phổ biến nhất trong nghiên cứu y học. Một giá trị p lớn chỉ có nghĩa là nghiên cứu không tìm thấy bằng chứng thuyết phục về một khác biệt; có thể đơn giản là nghiên cứu quá nhỏ, hoặc biến kết cục biến thiên quá nhiều, để phát hiện được khác biệt. Khoảng tin cậy cho biết chúng ta đang ở tình huống nào. Nếu khoảng tin cậy hẹp và tập trung gần 0, ta có thể kết luận một cách hợp lý rằng mọi khác biệt đều nhỏ. Nếu khoảng rộng và bao gồm cả những giá trị quan trọng về mặt lâm sàng, nghiên cứu là chưa có kết luận và cách tóm tắt trung thực là "chúng ta không thể biết".

Thực hành tốt

Hãy báo cáo mỗi phép so sánh bằng một **ước lượng**, **khoảng tin cậy 95%** của nó và **giá trị p chính xác** (ví dụ $p = 0.003$, không phải " $p < 0.05$ " hay "NS"), và diễn giải ước lượng theo ngôn ngữ lâm sàng. Các giá trị p rất nhỏ có thể được ghi là $p < 0.001$.

4.2 Xác định quần thể phân tích

Trước mọi kiểm định, chúng ta phải quyết định chính xác dữ liệu của *những ai* trả lời câu hỏi. Biến kết cục chính của nghiên cứu là **việc sử dụng điều trị** (tiếp nhận điều trị, treatment uptake): bệnh nhân hiện có đang dùng thuốc hạ áp hay không. Biến kết cục này chỉ có ý nghĩa với những bệnh nhân đã được chẩn đoán tăng huyết áp. Một bệnh nhân chưa bao giờ được thông báo rằng huyết áp của mình cao thì không thể "không tiếp nhận" điều trị; kết cục của họ không phải là "No" mà là không xác định. Đưa họ vào sẽ trộn lẫn hai câu hỏi khác nhau (ai được chẩn đoán, và ai được điều trị sau khi đã được chẩn đoán) và sẽ làm sai lệch mọi phép so sánh. Vì vậy, **quần thể phân tích** (analytic population) cho biến tiếp nhận điều trị là những bệnh nhân có `htn_diagnosed == "Yes"`, và chúng ta định nghĩa nó một lần, tường minh, rồi dùng cùng một đối tượng xuyên suốt chương.

```
# Quần thể phân tích: bệnh nhân đã được chẩn đoán tăng huyết áp
dx <- analysis_data |>
  filter(htn_diagnosed == "Yes")

nrow(dx) # số bệnh nhân được phân tích
```

```
#> [1] 1089
```

```
dx |> count(treatment_uptake) |>
  mutate(percent = round(100 * n / sum(n), 1))
```

```
#> # A tibble: 2 × 3
#>   treatment_uptake     n percent
#>   <fct>           <int>   <dbl>
#> 1 No              581     53.4
#> 2 Yes             508     46.6
```

Trong 1.500 bệnh nhân, 1.089 người đã được chẩn đoán tăng huyết áp, và 508 người trong số đó (46,6%) đang điều trị. Mọi kết quả trong phần còn lại của chương này đều đề cập đến 1.089 bệnh nhân này. Lưu ý rằng một số biến có giá trị khuyết trong nhóm này (ví dụ 47 bệnh nhân không có ghi nhận khoảng cách đến cơ sở y tế); các hàm kiểm định của R loại bỏ giá trị khuyết một cách âm thầm, nên số bệnh nhân đóng góp vào mỗi kiểm định có thể ít hơn 1.089 một chút. Một báo cáo tốt nên rõ số người được phân tích cho từng kết quả.

Lỗi thường gặp

Thực hiện phân tích tiếp nhận điều trị trên toàn bộ 1.500 bệnh nhân. Khi đó 411 bệnh nhân chưa được chẩn đoán đều sẽ có giá trị "No" cho biến điều trị, làm tỷ lệ tiếp nhận thấp đi một cách giả tạo và làm sai lệch mọi phép so sánh (chẳng hạn, bất kỳ đặc điểm nào liên quan đến việc *được chẩn đoán* cũng sẽ có vẻ liên quan đến việc *được điều trị*). Hãy xác định quần thể phân tích trước tiên, ghi rõ trong phần phương pháp và sử dụng nó một cách nhất quán.

Dữ liệu được mô phỏng cho mục đích giảng dạy. Các mối liên quan trong dữ liệu được cài sẵn để minh họa phương pháp; không nên đọc các con số trong chương này như những phát hiện lâm sàng thực tế về chăm sóc tăng huyết áp.

4.3 Kiểm tra giả định phân phối chuẩn


Một số kiểm định kinh điển, gọi là kiểm định **tham số** (parametric), được xây dựng dựa trên giả định rằng dữ liệu (hay chính xác hơn là phần dư, hoặc các giá trị trong từng nhóm) tuân theo **phân phối chuẩn** (normal distribution): kiểm định t, phân tích phương sai và hệ số tương quan Pearson. Các kiểm định **phi tham số** (non-parametric) tương ứng (kiểm định tổng hạng Wilcoxon, kiểm định Kruskal–Wallis và tương quan Spearman) thay các giá trị quan sát bằng thứ hạng của chúng và không cần giả định đó (Altman 1991; Bland 2015). Để chọn giữa hai loại, chúng ta cần xem xét hình dạng của dữ liệu.

Phân phối chuẩn đối xứng, có hình chuông, và được mô tả đầy đủ bởi trung bình μ và độ lệch chuẩn σ : khoảng 68% giá trị nằm trong phạm vi một độ lệch chuẩn quanh trung bình và 95%

nằm trong phạm vi 1,96 độ lệch chuẩn (Altman and Bland 1995b). Chúng ta xem xét ba biến liên tục trong quần thể phân tích: tuổi, huyết áp tâm thu và khoảng cách đến cơ sở y tế.

4.3.1 Hãy nhìn trước: biểu đồ tần suất

```
p_age <- ggplot(dx, aes(x = age)) +  
  geom_histogram(binwidth = 4, fill = course_teal, colour = "white") +  
  labs(x = "Tuổi (năm)", y = "Số bệnh nhân")  
p_sbp <- ggplot(dx, aes(x = sbp_mmhg)) +  
  geom_histogram(binwidth = 6, fill = course_teal, colour = "white") +  
  labs(x = "HA tâm thu (mmHg)", y = NULL)  
p_dist <- ggplot(dx, aes(x = distance_to_facility_km)) +  
  geom_histogram(binwidth = 1.5, fill = course_teal, colour = "white") +  
  labs(x = "Khoảng cách (km)", y = NULL)  
  
p_age + p_sbp + p_dist      # patchwork đặt ba khung cạnh nhau
```



Hình 4.3: Biểu đồ tần suất của tuổi, huyết áp tâm thu và khoảng cách đến cơ sở y tế ở bệnh nhân đã được chẩn đoán. Tuổi và huyết áp tâm thu gần đối xứng; khoảng cách lệch phải rõ rệt.


Biểu đồ tần suất cho thấy hình dạng tổng thể. Tuổi và huyết áp tâm thu gần đối xứng và có một đỉnh; huyết áp tâm thu có đuôi phải dài hơn một chút. Khoảng cách đến cơ sở y tế rõ ràng **lệch phải** (right-skewed): phần lớn bệnh nhân sống trong phạm vi khoảng 10 km nhưng một số ít sống xa hơn 25 km. Với một biến lệch, trung bình bị kéo về phía đuôi dài (ở đây khoảng cách trung bình là 7,7 km nhưng trung vị chỉ là 6,3 km), và trung vị cùng khoảng tứ phân vị là những đại lượng tóm tắt tốt hơn (Chương 3).

4.3.2 Biểu đồ Q-Q

Biểu đồ phân vị–phân vị (quantile–quantile plot, Q–Q plot) là một công cụ sắc bén hơn. Nó biểu diễn các giá trị dữ liệu đã sắp xếp theo các giá trị mà ta kỳ vọng nếu dữ liệu đến từ một phân phối chuẩn có cùng trung bình và độ lệch chuẩn. Nếu dữ liệu có phân phối chuẩn, các điểm nằm gần một đường thẳng. Độ cong có hệ thống cho thấy độ lệch; các điểm tách khỏi đường ở cả hai đầu theo hai hướng ngược nhau cho thấy đuôi dày hơn (hoặc mỏng hơn) so với phân phối chuẩn (Altman and Bland 1995b; Bland 2015).

```
qq_panel <- function(var, label) {
  ggplot(dx, aes(sample = .data[[var]])) +
    stat_qq(size = 0.6, alpha = 0.5, colour = course_teal) +
    stat_qq_line(colour = "black") +
    labs(title = label, x = "Phân vị lý thuyết", y = "Phân vị mẫu")
}

qq_panel("age", "Tuổi") +
  qq_panel("sbp_mmhg", "HA tâm thu") +
  qq_panel("distance_to_facility_km", "Khoảng cách")
```



Hình 4.4: Biểu đồ Q–Q chuẩn cho tuổi, huyết áp tâm thu và khoảng cách đến cơ sở y tế. Các điểm nằm gần đường tham chiếu cho thấy phân phối xấp xỉ chuẩn; đường cong của biến khoảng cách cho thấy lệch phải rõ rệt.

Các điểm của biến tuổi bám theo đường thẳng gần như hoàn hảo, ngoại trừ một đoạn nằm ngang ngắn ở đầu dưới: nghiên cứu chỉ tuyển người trưởng thành, nên đuôi trái bị cắt ở 18 tuổi. Huyết áp tâm thu bám theo đường thẳng khá tốt ở phần giữa của phân phối, với một đoạn nằm ngang ở đầu dưới (một "sàn" các giá trị đo rất thấp) và một hình chữ S nhẹ; đây là những sai lệch khiêm tốn, chỉ ảnh hưởng đến vài phần trăm bệnh nhân ở hai cực. Khoảng cách cong lên thành hình quả chuối: các khoảng cách lớn nhất lớn hơn nhiều so với những gì một phân phối chuẩn tạo ra — dấu hiệu đặc trưng của lệch phải.

4.3.3 Kiểm định chuẩn hình thức: Shapiro–Wilk

Kiểm định Shapiro–Wilk (Shapiro and Wilk 1965) kiểm định giả thuyết không rằng dữ liệu đến từ một phân phối chuẩn. Thống kê W của nó so sánh một tổ hợp có trọng số tối ưu của các quan sát đã sắp xếp với phương sai mẫu; W gần bằng 1 với dữ liệu chuẩn và nhỏ hơn với dữ liệu không chuẩn. Trong R, `shapiro.test()` chấp nhận từ 3 đến 5.000 quan sát.

```
shapiro.test(dx$age)
```

```
#>
#>      Shapiro-Wilk normality test
#>
#> data:  dx$age
#> W = 0.997, p-value = 0.056
```

```
shapiro.test(dx$sbp_mmhg)
```

R

```
#>
#>      Shapiro-Wilk normality test
#>
#> data:  dx$sbp_mmhg
#> W = 0.988, p-value = 7.5e-08
```

```
shapiro.test(dx$distance_to_facility_km)
```

R

```
#>
#>      Shapiro-Wilk normality test
#>
#> data:  dx$distance_to_facility_km
#> W = 0.888, p-value <2e-16
```

Đọc kết quả: mỗi khối nêu tên kiểm định và dữ liệu, sau đó cho W và giá trị p . Với tuổi, $W = 0.997$ và $p = 0.056$, nên không có bằng chứng mạnh chống lại tính chuẩn. Với khoảng cách, $W = 0.888$ và $p < 2.2 \times 10^{-16}$ (cách R nói "nhỏ hơn con số nhỏ nhất mà nó báo cáo"), xác nhận độ lệch hiển nhiên. Trường hợp đáng chú ý là huyết áp tâm thu: $W = 0.988$, rất gần 1, nhưng $p = 7.5 \times 10^{-8}$. Kiểm định "bác bỏ tính chuẩn" một cách dứt khoát đối với một biến có biểu đồ tần suất và biểu đồ Q-Q trông gần như chuẩn.

4.3.4 Vì sao kiểm định chuẩn gây hiểu lầm khi cỡ mẫu lớn

Đây là vấn đề chung của các kiểm định chuẩn. Như mọi kiểm định khác, kiểm định Shapiro–Wilk có lực thống kê tăng lên khi cỡ mẫu tăng. Với hơn một nghìn quan sát, nó phát hiện những sai lệch so với phân phối chuẩn quá nhỏ để có ý nghĩa cho bất kỳ mục đích thực tiễn nào. Với mẫu nhỏ thì ngược lại: kiểm định có lực thống kê thấp và có thể không phát hiện được độ lệch nghiêm trọng. Như vậy, kiểm định có khả năng bác bỏ tính chuẩn cao nhất chính khi tính chuẩn ít quan trọng nhất (mẫu lớn) và bỏ sót sự không chuẩn khi nó quan trọng nhất (mẫu nhỏ).

Lý do tính chuẩn ít quan trọng nhất khi mẫu lớn là định lý giới hạn trung tâm. Kiểm định t và ANOVA so sánh các *trung bình*, và phân phối mẫu của một trung bình gần với phân phối chuẩn khi mẫu lớn, bất kể phân phối của các giá trị cá nhân ra sao, như Hình 4.1 đã cho thấy. Lumley et al. (2002) đã tổng quan các bằng chứng và cho thấy rằng với các bộ dữ liệu y tế công cộng có cỡ thông thường, kiểm định t và hồi quy tuyến tính cho kết quả hợp lệ ngay cả với những biến kết cục lệch rõ rệt; điều quan trọng hơn là trung bình phải là một đại lượng tóm tắt hợp lý cho câu hỏi nghiên cứu. Do đó, giả định phân phối chuẩn đáng được chú ý nhất khi mẫu nhỏ (chẳng hạn dưới 30 người mỗi nhóm) hoặc khi dữ liệu lệch cực độ hay chứa các giá trị ngoại lai lớn.

```
# Cùng kiểm định trên mẫu ngẫu nhiên chỉ 50 giá trị tuổi:
# lực thống kê thấp hơn nhiều
set.seed(1)
shapiro.test(sample(dx$age, 50))
```

R

```
#>
#>      Shapiro-Wilk normality test
#>
#> data:  sample(dx$age, 50)
```

```
#> W = 0.97, p-value = 0.23
```

Thực hành tốt

Hãy quyết định giữa phương pháp tham số và phi tham số bằng cách **quan sát** (biểu đồ tần suất, biểu đồ Q-Q), bằng cách cân nhắc **cỡ mẫu** và bằng cách tự hỏi liệu **trung bình** có phải là đại lượng tóm tắt có ý nghĩa cho câu hỏi hay không. Đừng để một giá trị p của kiểm định Shapiro–Wilk tự mình đưa ra quyết định. Với mẫu lớn, dữ liệu gần đối xứng có thể được phân tích bằng kiểm định t và ANOVA; dữ liệu lệch mạnh, điểm số thứ bậc và mẫu nhỏ gợi ý dùng các phương pháp dựa trên thứ hạng (hoặc một phép biến đổi, chẳng hạn logarit, trước khi phân tích tham số).

4.4 So sánh hai nhóm: biến kết cục liên tục

Câu hỏi thực chất đầu tiên của chúng ta là liệu bệnh nhân tiếp nhận điều trị có khác về tuổi so với những người không tiếp nhận hay không. Biến được so sánh là một biến liên tục (tuổi) và biến phân nhóm có hai loại (tiếp nhận điều trị "Yes" hoặc "No").

4.4.1 Mẫu độc lập và mẫu bắt cặp

Kiểm định phù hợp phụ thuộc vào cách thu được hai tập số đo.

- **Mẫu độc lập** (independent samples): hai nhóm gồm những cá nhân khác nhau, không liên quan với nhau, chẳng hạn bệnh nhân được điều trị và không được điều trị. Mỗi bệnh nhân đóng góp một số đo.
- **Mẫu bắt cặp** (paired samples): mỗi quan sát trong nhóm này được liên kết với một quan sát cụ thể trong nhóm kia, chẳng hạn huyết áp đo trên cùng những bệnh nhân trước và sau khi bắt đầu điều trị, hoặc trong các cặp bệnh–chứng được ghép cặp. Các cặp được phân tích thông qua *hiệu số* của chúng, giúp loại bỏ biến thiên giữa các cá nhân và thường cho độ chính xác cao hơn nhiều.

Với dữ liệu bắt cặp, **kiểm định t bắt cặp** (paired t-test) đơn giản là một kiểm định t một mẫu trên các hiệu số trong cặp d_i , với thống kê $t = \bar{d} / (s_d / \sqrt{n})$ có $n - 1$ bậc tự do, trong đó n là số cặp; kiểm định tương ứng dựa trên thứ hạng là **kiểm định hạng có dấu Wilcoxon** (Wilcoxon signed-rank test) (Altman 1991; Kirkwood and Sterne 2003). Trong R, đó là `t.test(x, y, paired = TRUE)` và `wilcox.test(x, y, paired = TRUE)`. Nghiên cứu cắt ngang của chúng ta đo mỗi bệnh nhân một lần, nên mọi phép so sánh trong chương này đều là giữa các nhóm độc lập. Phân tích dữ liệu bắt cặp như thể chúng độc lập (hoặc ngược lại) là một lỗi nghiêm trọng, dẫn đến sai số chuẩn sai.

4.4.2 Kiểm định t Student

Kiểm định t hai mẫu (two-sample t-test) được W. S. Gosset xây dựng; ông viết dưới bút danh "Student" khi làm việc cho nhà máy bia Guinness (Student 1908). Với hai nhóm độc lập có trung bình $\bar{x}_1, \bar{x}_2$, độ lệch chuẩn s_1, s_2 và cỡ mẫu n_1, n_2 , kiểm định giả định rằng biến kết cục có

phân phối chuẩn trong mỗi nhóm với cùng một phương sai. Phương sai chung được ước lượng bằng cách gộp hai nhóm,

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2},$$

và thống kê kiểm định là

$$t = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}},$$

dưới $H_0 : \mu_1 = \mu_2$, thống kê này tuân theo phân phối t với $n_1 + n_2 - 2$ bậc tự do. Phân phối t trông giống phân phối chuẩn nhưng có đuôi dày hơn, để tính đến độ không chắc chắn bổ sung do phải ước lượng độ lệch chuẩn; với hơn vài chục bậc tự do, nó thực tế giống hệt phân phối chuẩn. Khoảng tin cậy 95% cho hiệu số trung bình là $(\bar{x}_1 - \bar{x}_2) \pm t_{0.975, n_1+n_2-2} \times s_p \sqrt{1/n_1 + 1/n_2}$.

4.4.3 Kiểm định t Welch

Nếu hai nhóm có phương sai khác nhau, sai số chuẩn gộp sẽ không đúng, đặc biệt khi hai nhóm còn khác nhau về cỡ mẫu. Welch (1947) đề xuất dùng các phương sai riêng,

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}},$$

và so sánh với một phân phối t có số bậc tự do được cho bởi xấp xỉ Welch–Satterthwaite,

$$\nu \approx \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}},$$

con số này thường không phải là số nguyên. Kiểm định Welch mất rất ít khi các phương sai thực ra bằng nhau và bảo vệ khỏi sai lầm khi chúng không bằng nhau, vì vậy R dùng nó làm mặc định và đây là lựa chọn thường quy hợp lý.

4.4.4 Kiểm định t trong R

Trước hết, một bảng tóm tắt số liệu của tuổi theo nhóm, để biết kiểm định đang so sánh điều gì.

```
dx |>
  group_by(treatment_uptake) |>
  summarise(n      = sum(!is.na(age)),
            mean    = mean(age, na.rm = TRUE),
            sd      = sd(age, na.rm = TRUE))
```

R

```
#> # A tibble: 2 × 4
#>   treatment_uptake     n mean   sd
#>   <fct>          <int> <dbl> <dbl>
#> 1 No              580  51.1  13.4
#> 2 Yes              508  56.3  14.1
```

Bệnh nhân được điều trị trung bình lớn hơn khoảng 5 tuổi (56,3 so với 51,1 tuổi), và độ lệch chuẩn tương tự nhau (13,4 và 14,1 năm). Bây giờ là kiểm định. Công thức `age ~ treatment_uptake` được đọc là "tuổi theo việc tiếp nhận điều trị".

```
t.test(age ~ treatment_uptake, data = dx)
```

R

```
#>
#>      Welch Two Sample t-test
#>
#> data:  age by treatment_uptake
#> t = -6.18, df = 1050, p-value = 8.9e-10
#> alternative hypothesis: true difference in means between group No and group
#>   Yes is not equal to 0
#> 95 percent confidence interval:
#>  -6.8184 -3.5338
#> sample estimates:
#> mean in group No mean in group Yes
#>      51.103      56.280
```

Đọc kết quả từng dòng:

- **Welch Two Sample t-test:** R dùng phiên bản Welch (cho phép phương sai không bằng nhau).
- **data: age by treatment_uptake:** biến kết cục và biến phân nhóm.
- **t = -6.18:** thống kê kiểm định. Hiệu số trung bình cách 0 khoảng 6,2 sai số chuẩn. Giá trị âm vì R trừ theo thứ tự các mức của factor, "No" trừ "Yes", và nhóm "No" trẻ hơn.
- **df = 1050:** số bậc tự do Welch–Satterthwaite, được làm tròn khi in (giá trị chính xác là 1049,6; số bậc tự do Welch thường không phải là số nguyên).
- **p-value = 8.9e-10:** 8.9×10^{-10} , tức là $p < 0.001$. Nếu tuổi trung bình thực sự giống hệt nhau ở hai quần thể, một chênh lệch lớn như vậy gần như không bao giờ xảy ra do ngẫu nhiên.
- **alternative hypothesis:** xác nhận đây là kiểm định hai phía về việc hiệu số (No trừ Yes) có khác 0 hay không.
- **95 percent confidence interval: -6.82 -3.53:** hiệu số tuổi trung bình (No trừ Yes) được ước lượng nằm trong khoảng từ -6.8 đến -3.5 tuổi. Nói cách khác, bệnh nhân được điều trị trung bình lớn hơn từ 3,5 đến 6,8 tuổi.
- **sample estimates:** trung bình của hai nhóm, 51,1 và 56,3 tuổi.

Để so sánh, phiên bản Student với phương sai gộp được yêu cầu bằng `var.equal = TRUE`.

```
t.test(age ~ treatment_uptake, data = dx, var.equal = TRUE)
```

R

```
#>
#>      Two Sample t-test
#>
#> data:  age by treatment_uptake
#> t = -6.21, df = 1086, p-value = 7.7e-10
#> alternative hypothesis: true difference in means between group No and group
#>   Yes is not equal to 0
#> 95 percent confidence interval:
#>  -6.8125 -3.5397
#> sample estimates:
#> mean in group No mean in group Yes
#>      51.103      56.280
```

Với các nhóm lớn và độ lệch chuẩn tương tự, hai phiên bản cho kết quả giống nhau đến chữ số thập phân đầu tiên: $t = -6.21$ với 1.086 bậc tự do, cùng khoảng tin cậy và cùng kết luận. Chúng chỉ khác nhau khi phương sai và cỡ nhóm khác nhau đáng kể, và trong tình huống đó kiểm định Welch là kiểm định đáng tin cậy.

Hàm `broom::tidy()` chuyển kết quả kiểm định thành một data frame một dòng, rất tiện cho việc xây dựng bảng kết quả.

```
t.test(age ~ treatment_uptake, data = dx) |>
  tidy() |>
  select(estimate, estimate1, estimate2, statistic, p.value,
         conf.low, conf.high)
```

```
#> # A tibble: 1 × 7
#>   estimate estimate1 estimate2 statistic  p.value conf.low conf.high
#>   <dbl>      <dbl>      <dbl>      <dbl>    <dbl>    <dbl>    <dbl>
#> 1    -5.18      51.1      56.3      -6.18  8.92e-10    -6.82    -3.53
```

4.4.5 Độ lớn tác động: hiệu số trung bình

Độ lớn tác động (effect size) hữu ích nhất cho một biến kết cục liên tục được đo bằng đơn vị có ý nghĩa lâm sàng đơn giản là **hiệu số trung bình kèm khoảng tin cậy 95%**: bệnh nhân được điều trị trung bình lớn hơn 5,2 tuổi (KTC 95% từ 3,5 đến 6,8 tuổi). Con số này có thể diễn giải trực tiếp. Các độ lớn tác động chuẩn hóa, chẳng hạn d của Cohen (hiệu số trung bình chia cho độ lệch chuẩn gộp, ở đây khoảng $5.2/13.7 \approx 0.38$), hữu ích khi so sánh các biến kết cục đo trên những thang đo khác nhau hoặc khi lập kế hoạch cỡ mẫu, nhưng chúng kém minh bạch hơn với người đọc lâm sàng và nên bổ sung chứ không thay thế hiệu số thô (Kirkwood and Sterne 2003).

Diễn giải lâm sàng

Trong số bệnh nhân tăng huyết áp đã được chẩn đoán, những người đang điều trị trung bình lớn hơn 5,2 tuổi so với những người không điều trị (KTC 95% từ 3,5 đến 6,8 tuổi; $p < 0.001$). Bệnh nhân lớn tuổi hơn có nhiều khả năng tiếp xúc thường xuyên với dịch vụ y tế và đã tích lũy nguy cơ tim mạch, nên khuôn mẫu này là hợp lý. Đây là một mối liên quan trong một mẫu cắt ngang, không phải bằng chứng cho thấy tuổi tác *gây ra* việc tiếp nhận điều trị, và các yếu tố khác thay đổi theo tuổi có thể giải thích một phần mối liên quan

này (Mục 4.9).

4.4.6 Kiểm định tổng hạng Wilcoxon (Mann–Whitney)

Khi biến kết cục bị lệch, có tính thứ bậc, hoặc khi mẫu nhỏ, một kiểm định dựa trên thứ hạng là lựa chọn tốt hơn. **Kiểm định tổng hạng Wilcoxon** (Wilcoxon rank-sum test), tương đương với **kiểm định U Mann–Whitney** (Mann and Whitney 1947), gộp hai nhóm lại, xếp hạng tất cả các quan sát từ nhỏ nhất đến lớn nhất (các giá trị bằng nhau nhận hạng trung bình), rồi so sánh thứ hạng giữa các nhóm. Nếu R_1 là tổng hạng trong nhóm 1, thống kê kiểm định là

$$W = R_1 - \frac{n_1(n_1 + 1)}{2},$$

đại lượng này đếm số cặp (mỗi nhóm một bệnh nhân) trong đó giá trị của nhóm 1 lớn hơn giá trị của nhóm 2. Dưới H_0 rằng hai phân phối giống hệt nhau, W có một phân phối đã biết với trung bình $n_1 n_2 / 2$; với mẫu lớn, người ta dùng xấp xỉ chuẩn. Vì chỉ dùng thứ hạng, kiểm định không bị ảnh hưởng bởi độ lớn của các giá trị cực đoan. Nó kiểm định xem các giá trị trong một nhóm có xu hướng lớn hơn nhóm kia hay không; nó chỉ là kiểm định về trung vị nếu hai phân phối có cùng hình dạng (Altman 1991; Bland 2015).

Khoảng cách đến cơ sở y tế lệch mạnh, nên chúng ta so sánh biến này giữa hai nhóm tiếp nhận điều trị bằng kiểm định tổng hạng. Trước hết là trung vị và các tứ phân vị:

```
dx |>
  group_by(treatment_uptake) |>
  summarise(n      = sum(!is.na(distance_to_facility_km)),
            median = median(distance_to_facility_km, na.rm = TRUE),
            q1     = quantile(distance_to_facility_km, 0.25, na.rm = TRUE),
            q3     = quantile(distance_to_facility_km, 0.75, na.rm = TRUE))
```

```
#> # A tibble: 2 × 5
#>   treatment_uptake     n median    q1    q3
#>   <fct>           <int> <dbl> <dbl> <dbl>
#> 1 No              561    6.8   4.3  10.7
#> 2 Yes              481    5.8   3.1   9.6
```

```
wilcox.test(distance_to_facility_km ~ treatment_uptake, data = dx,
            conf.int = TRUE)
```

```
#>
#>      Wilcoxon rank sum test with continuity correction
#>
#> data:  distance_to_facility_km by treatment_uptake
#> W = 151283, p-value = 0.00073
#> alternative hypothesis: true location shift is not equal to 0
#> 95 percent confidence interval:
#>  0.39997 1.50000
#> sample estimates:
#> difference in location
#>               0.99998
```

Đọc kết quả:

- **Wilcoxon rank sum test with continuity correction:** R dùng xấp xỉ chuẩn (kèm một hiệu chỉnh liên tục nhỏ) vì mẫu lớn và có các giá trị bằng nhau.
- **W = 151283:** thống kê tổng hạng cho nhóm thứ nhất ("No"). Độ lớn tuyệt đối của nó tự thân không có ý nghĩa diễn giải.
- **p-value = 0.00073:** bằng chứng mạnh cho thấy khoảng cách có xu hướng khác nhau giữa hai nhóm.
- **95 percent confidence interval: 0.40 1.50** và **difference in location 1.00** (in ra là 0.39997, 1.50000 và 0.99998, vì ước lượng được tìm bằng phương pháp số): do chúng ta yêu cầu `conf.int = TRUE`, R còn báo cáo **ước lượng Hodges–Lehmann**, tức trung vị của mọi hiệu số từng cặp giữa một bệnh nhân "No" và một bệnh nhân "Yes". Bệnh nhân không được điều trị thường sống xa hơn khoảng 1,0 km (KTC 95% từ 0,4 đến 1,5 km).

Các trung vị cho thấy cùng một câu chuyện: 6,8 km (IQR 4,3 đến 10,7) ở nhóm không điều trị và 5,8 km (IQR 3,1 đến 9,6) ở nhóm được điều trị. Ước lượng Hodges–Lehmann dựa trên thứ hạng là độ lớn tác động tự nhiên để báo cáo cùng với kiểm định này. Để so sánh, đây là kiểm định t Welch trên cùng biến lệch đó:

```
t.test(distance_to_facility_km ~ treatment_uptake, data = dx) |>
  tidy() |>
  select(estimate, statistic, p.value, conf.low, conf.high)
```

```
#> # A tibble: 1 × 5
#>   estimate statistic p.value conf.low conf.high
#>   <dbl>      <dbl>   <dbl>   <dbl>   <dbl>
#> 1     1.08       2.95 0.00326    0.361    1.79
```

Kiểm định t ước lượng hiệu số *trung bình* là 1,08 km (KTC 95% từ 0,36 đến 1,79 km, $p = 0.003$), cùng giá trị p với kiểm định hoán vị ở Mục 4.1. Với hơn 500 bệnh nhân mỗi nhóm, định lý giới hạn trung tâm bảo vệ kiểm định t ngay cả với một biến lệch, và cả hai kiểm định đi đến cùng một kết luận. Vì vậy, việc lựa chọn giữa chúng phần nào phụ thuộc vào điều chúng ta muốn mô tả: một hiệu số *trung bình* (chẳng hạn liên quan đến gánh nặng đi lại trung bình) hay một *sự dịch chuyển* điển hình của phân phối.

```
# Kiểm định tổng hạng cho tuổi, để so sánh với kiểm định t
wilcox.test(age ~ treatment_uptake, data = dx)
```

```
#>
#>      Wilcoxon rank sum test with continuity correction
#>
#> data:  age by treatment_uptake
#> W = 117011, p-value = 4.5e-09
#> alternative hypothesis: true location shift is not equal to 0
```

Với tuổi, vốn gần chuẩn, kiểm định tổng hạng ($p = 4.5 \times 10^{-9}$) thống nhất với kiểm định t. Khi kiểm định tham số và phi tham số thống nhất, hãy báo cáo kiểm định phù hợp với thống kê tóm tắt của bạn (trung bình với kiểm định t, trung vị với kiểm định tổng hạng). Khi chúng không thống nhất, hãy xem lại dữ liệu: thường là độ lệch hoặc giá trị ngoại lai đang chi phối kiểm định t.

Lỗi thường gặp

Chỉ báo cáo "Mann–Whitney $p < 0.001$ " mà không có độ lớn tác động nào. Một kiểm định thứ hạng trả lời câu hỏi "có khác biệt không?", chứ không phải "khác biệt lớn đến đâu?". Hãy báo cáo trung vị (và IQR) của cả hai nhóm và, lý tưởng nhất, hiệu số Hodges–Lehmann kèm khoảng tin cậy của nó.

4.5 So sánh nhiều hơn hai nhóm

Kiến thức về tăng huyết áp, được đo bằng một điểm số từ 0 đến 20, có thể khác nhau theo trình độ học vấn. Với bốn mức học vấn (None — không đi học, Primary — tiểu học, Secondary — trung học, Tertiary — cao đẳng/đại học) có sáu cặp nhóm có thể so sánh. Thực hiện sáu kiểm định t sẽ làm tăng khả năng có ít nhất một kết quả dương tính giả (Mục 4.5.5). Thay vào đó, **phân tích phương sai một yếu tố** (one-way analysis of variance, ANOVA) đặt ra một câu hỏi duy nhất: tất cả các trung bình nhóm có bằng nhau không?

4.5.1 Ý tưởng của phân tích phương sai

ANOVA, do R. A. Fisher phát triển, so sánh hai ước lượng về độ biến thiên (Altman 1991; Kirkwood and Sterne 2003). Giả sử có k nhóm, nhóm j có n_j quan sát với trung bình $\bar{x}_j$, trung bình chung là $\bar{x}$ và tổng số quan sát là N . Tổng biến thiên của các quan sát quanh trung bình chung được chia thành hai phần:

$$\underbrace{\sum_j \sum_i (x_{ij} - \bar{x})^2}_{\text{SS toàn phần}} = \underbrace{\sum_j n_j (\bar{x}_j - \bar{x})^2}_{\text{SS giữa các nhóm}} + \underbrace{\sum_j \sum_i (x_{ij} - \bar{x}_j)^2}_{\text{SS trong nhóm}}.$$

Mỗi **tổng bình phương** (sum of squares, SS) được chia cho số bậc tự do của nó để cho ra một **bình phương trung bình** (mean square, MS): $MS_{\text{between}} = SS_{\text{between}} / (k - 1)$ và $MS_{\text{within}} = SS_{\text{within}} / (N - k)$ (between: giữa các nhóm; within: trong nhóm). Bình phương trung bình trong nhóm ước lượng phương sai của các cá nhân quanh trung bình nhóm của họ, bất kể sự thật về các trung bình nhóm là gì. Bình phương trung bình giữa các nhóm ước lượng cùng phương sai đó nếu H_0 đúng, nhưng sẽ lớn lên nếu các trung bình nhóm khác nhau. Tỷ số của chúng là **thống kê F**,

$$F = \frac{MS_{\text{between}}}{MS_{\text{within}}},$$


thống kê này gần bằng 1 dưới H_0 và được so sánh với phân phối F có $k - 1$ và $N - k$ bậc tự do. Với hai nhóm, ANOVA một yếu tố giống hệt kiểm định t Student ($F = t^2$). Các giả định là những giả định của kiểm định t Student mở rộng cho k nhóm: các quan sát độc lập, giá trị trong mỗi nhóm có phân phối xấp xỉ chuẩn (ít quan trọng hơn khi mẫu lớn), và phương sai tương tự nhau giữa các nhóm.

4.5.2 Hãy xem xét các nhóm trước

```
dx |>
  filter(!is.na(education), !is.na(knowledge_score)) |>
  group_by(education) |>
  summarise(n = n(), mean = mean(knowledge_score),
            sd = sd(knowledge_score), median = median(knowledge_score))
```

```
#> # A tibble: 4 × 5
#>   education      n mean    sd median
#>   <ord>      <int> <dbl> <dbl> <dbl>
#> 1 None         197 10.4   3.15    11
#> 2 Primary      432  9.85   3.37    10
#> 3 Secondary    285 10.8   3.64    11
#> 4 Tertiary     122 11.3   3.41    11
```

```
dx |>
  filter(!is.na(education), !is.na(knowledge_score)) |>
  ggplot(aes(x = education, y = knowledge_score)) +
  geom_jitter(width = 0.2, height = 0.2, alpha = 0.15, size = 0.8,
             colour = course_teal) +
  geom_boxplot(fill = NA, outlier.shape = NA, width = 0.5) +
  stat_summary(fun = mean, geom = "point", shape = 23, size = 3,
             fill = course_amber) +
  labs(x = "Trình độ học vấn cao nhất", y = "Điểm kiến thức (0-20)")
```



Hình 4.5: Điểm kiến thức về tăng huyết áp theo trình độ học vấn cao nhất ở bệnh nhân đã được chẩn đoán. Hộp thể hiện trung vị và khoảng tứ phân vị; các điểm là từng bệnh nhân (được làm nhỏ nhẹ vị trí); hình thoi đánh dấu trung bình nhóm.

Việc thể hiện từng điểm dữ liệu bên cạnh các hộp, như Weissgerber et al. (2015) khuyến nghị, giúp người đọc thấy được cỡ mẫu và độ phân tán trong từng nhóm. Điểm kiến thức trung bình dao động từ 9,9 (Primary) đến 11,3 (Tertiary), với độ lệch chuẩn từ 3,2 đến 3,6 ở mọi nhóm: chênh lệch giữa các nhóm là nhỏ so với biến thiên trong từng nhóm, nhưng các nhóm có cỡ lớn.

4.5.3 ANOVA một yếu tố trong R

`aov()` ước lượng mô hình phân tích phương sai; `summary()` in ra bảng ANOVA.

```
aov_know <- aov(knowledge_score ~ education, data = dx)
summary(aov_know)
```

```
#>               Df Sum Sq Mean Sq F value    Pr(>F)
#> education       3      274      91.2     7.84 3.5e-05 ***
#> Residuals    1032    12008      11.6
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#> 53 observations deleted due to missingness
```

Đọc bảng ANOVA:

- Dòng **education**: dòng giữa các nhóm. **Df = 3** ($k - 1 = 4 - 1$), **Sum Sq = 274** (SS giữa các nhóm), **Mean Sq = 91.2** ($274/3$).
- Dòng **Residuals**: dòng trong nhóm (phần dư). **Df = 1032** ($N - k = 1036 - 4$), **Sum Sq = 12008**, **Mean Sq = 11.6**, tức phương sai gộp trong nhóm (căn bậc hai của nó, 3,4, là độ lệch chuẩn gộp).
- **F value = 7.84**: $91.2/11.6$. Biến thiên giữa các nhóm học vấn lớn gần gấp tám lần mức ta kỳ vọng nếu chỉ có biến thiên trong nhóm.
- **Pr(>F) = 3.5e-05**: giá trị p, $p < 0.001$. Có bằng chứng mạnh cho thấy kiến thức trung bình khác nhau giữa ít nhất một số mức học vấn.
- Các dấu sao và dòng "Signif. codes" là chú giải cho giá trị p; chúng không bổ sung thông tin gì và tốt nhất nên bỏ qua.
- **53 observations deleted due to missingness**: các bệnh nhân thiếu thông tin học vấn hoặc điểm kiến thức đã bị loại, nên $N = 1,036$. Luôn ghi nhận dòng này.

4.5.4 Kiểm tra các giả định

Giả định phương sai bằng nhau có thể được xem xét một cách không chính thức bằng cách so sánh các độ lệch chuẩn (ở đây từ 3,2 đến 3,6, rất tương tự) hoặc bằng **kiểm định Levene** (Levene's test), có trong gói `car`. Nếu các phương sai khác nhau rõ rệt, **ANOVA Welch** (`oneway.test()`) mở rộng kiểm định t Welch cho nhiều nhóm.

```
# Kiểm định Levene: H0 = phương sai bằng nhau ở mọi nhóm.
# education là factor có thứ tự; ở đây car cần một factor thông thường.
car::leveneTest(knowledge_score ~ factor(education, ordered = FALSE),
                data = dx)
```

```
#> Levene's Test for Homogeneity of Variance (center = median)
#>      Df F value Pr(>F)
#> group   3    1.88  0.13
#>      1032
```

```
# ANOVA Welch không giả định phương sai bằng nhau
oneway.test(knowledge_score ~ education, data = dx)
```

R

```
#>
#>      One-way analysis of means (not assuming equal variances)
#>
#> data:  knowledge_score and education
#> F = 7.74, num df = 3, denom df = 405, p-value = 4.9e-05
```

Kiểm định Levene cho $p = 0.13$: không có bằng chứng cho thấy các phương sai khác nhau. ANOVA Welch cho $F = 7.74$ với 3 và 404,5 bậc tự do, $p < 0.001$, về cơ bản cùng câu trả lời với ANOVA kinh điển. Điểm kiến thức là một số đếm bị chặn từ 0 đến 20 và không hoàn toàn chuẩn, nhưng với hơn 100 bệnh nhân mỗi nhóm, định lý giới hạn trung tâm khiến điều này không quan trọng; chúng ta sẽ xác nhận bằng kiểm định Kruskal–Wallis ở phần dưới.

4.5.5 So sánh hậu kiểm và vấn đề kiểm định bội

Một kiểm định F có ý nghĩa cho biết các trung bình nhóm không bằng nhau hết, nhưng không cho biết những nhóm nào khác nhau. Để tìm ra, chúng ta so sánh từng cặp nhóm, và lúc này xuất hiện vấn đề **kiểm định bội** (multiple testing). Nếu mỗi kiểm định có 5% khả năng cho kết quả dương tính giả, thì với m kiểm định độc lập, khả năng có ít nhất một kết quả dương tính giả khi mọi giả thuyết không đều đúng là $1 - 0.95^m$: 26% với sáu kiểm định và 64% với hai mươi kiểm định. Lọc lợi qua nhiều phép so sánh rồi báo cáo những phép so sánh có ý nghĩa là một cách chắc chắn để tạo ra những phát hiện sai.

Biện pháp đơn giản nhất là **hiệu chỉnh Bonferroni** (Bonferroni correction) (Bland and Altman 1995): để giữ tỷ lệ sai lầm chung (family-wise error rate) ở mức α , hãy kiểm định mỗi phép so sánh trong m phép so sánh ở mức α/m , hoặc tương đương, nhân mỗi giá trị p với m (tối đa bằng 1). Phương pháp này đơn giản và luôn hợp lệ nhưng bảo thủ, đặc biệt khi m lớn hoặc các kiểm định có tương quan với nhau. Phương pháp **khác biệt có ý nghĩa thực sự của Tukey** (Tukey's honestly significant difference, HSD) được thiết kế riêng cho mọi phép so sánh từng cặp sau ANOVA và cho các khoảng tin cậy đồng thời cho mọi hiệu số từng cặp (Altman 1991).

```
TukeyHSD(aov_know)
```

R

```
#> Tukey multiple comparisons of means
#> 95% family-wise confidence level
#>
#> Fit: aov(formula = knowledge_score ~ education, data = dx)
#>
#> $education
#>
#>      diff      lwr      upr    p adj
#> Primary-None -0.54685 -1.301448 0.20775 0.24398
#> Secondary-None 0.37442 -0.438846 1.18769 0.63668
#> Tertiary-None 0.92685 -0.084373 1.93808 0.08591
#> Secondary-Primary 0.92127 0.251447 1.59110 0.00237
#> Tertiary-Primary 1.47370 0.573791 2.37361 0.00016
#> Tertiary-Secondary 0.55243 -0.397215 1.50208 0.43971
```

Mỗi dòng trong kết quả Tukey là một phép so sánh từng cặp. **diff** là hiệu số điểm kiến thức trung bình (nhóm được nêu trước trừ nhóm được nêu sau); **lwr** và **upr** là các giới hạn của khoảng

tin cậy 95% đã được hiệu chỉnh cho việc thực hiện sáu phép so sánh; **p adj** là giá trị p đã hiệu chỉnh. Có hai phép so sánh nổi bật: Secondary so với Primary (hiệu số 0,92 điểm, KTC 95% từ 0,25 đến 1,59, p hiệu chỉnh = 0.002) và Tertiary so với Primary (1,47 điểm, từ 0,57 đến 2,37, $p < 0.001$). Các khoảng tin cậy còn lại đều chứa 0. Điều thú vị là nhóm None có điểm cao hơn một chút so với nhóm Primary, nên khuôn mẫu không phải là một gradient đều đặn; với dữ liệu mô phỏng, chúng ta không nên diễn giải quá mức điều này.

Các kiểm định t từng cặp được hiệu chỉnh Bonferroni cho cùng một bức tranh:

```
pairwise.t.test(dx$knowledge_score, dx$education,
               p.adjust.method = "bonferroni")

#>
#>      Pairwise comparisons using t tests with pooled SD
#>
#> data:  dx$knowledge_score and dx$education
#>
#>      None  Primary Secondary
#> Primary  0.375 -      -
#> Secondary 1.000 0.003 -
#> Tertiary  0.111 2e-04 0.808
#>
#> P value adjustment method: bonferroni
```

Kết quả này là một tam giác các giá trị p đã hiệu chỉnh, mỗi giá trị cho một cặp. Một lần nữa, chỉ có Secondary–Primary ($p = 0.003$) và Tertiary–Primary ($p < 0.001$) nhỏ hơn 0,05.

Thực hành tốt

Hãy quyết định những phép so sánh bạn quan tâm *trước khi* xem dữ liệu, giữ cho số lượng của chúng ít, và nêu rõ trong phần phương pháp cách xử lý vấn đề so sánh bội. Một vài phép so sánh được xác định trước cần ít hoặc không cần hiệu chỉnh; một cuộc "rà lưới" thăm dò qua hàng chục biến thì cần hiệu chỉnh và nên được mô tả là mang tính thăm dò. Đừng chạy các kiểm định hậu kiểm sau một kiểm định F không có ý nghĩa để cố tìm ra điều gì đó có ý nghĩa.

4.5.6 Kiểm định Kruskal–Wallis

Kiểm định tương ứng dựa trên thứ hạng của ANOVA một yếu tố là **kiểm định Kruskal–Wallis** (Kruskal and Wallis 1952). Tất cả N quan sát được xếp hạng chung; nếu $\bar{R}_j$ là hạng trung bình trong nhóm j , thống kê

$$H = \frac{12}{N(N+1)} \sum_{j=1}^k n_j \left(\bar{R}_j - \frac{N+1}{2} \right)^2$$

đo mức độ các hạng trung bình của các nhóm cách xa hạng trung bình chung $(N+1)/2$. Dưới H_0 rằng mọi nhóm đến từ cùng một phân phối, H tuân theo xấp xỉ phân phối χ^2 với $k-1$ bậc tự do. Với hai nhóm, kiểm định này tương đương với kiểm định tổng hạng Wilcoxon.

```
kruskal.test(knowledge_score ~ education, data = dx)
```

```
#>
#>      Kruskal-Wallis rank sum test
#>
#> data:  knowledge_score by education
#> Kruskal-Wallis chi-squared = 24.4, df = 3, p-value = 2e-05
```

Kết quả cho thống kê kiểm định (**Kruskal-Wallis chi-squared = 24.4**), số bậc tự do (**df = 3**) và giá trị p (2.0×10^{-5}). Phân tích dựa trên thứ hạng thống nhất với ANOVA. Nếu cần so sánh từng cặp sau kiểm định Kruskal-Wallis, hãy dùng các kiểm định Wilcoxon từng cặp có hiệu chỉnh, ví dụ `pairwise.wilcox.test(x, g, p.adjust.method = "bonferroni")`.

Diễn giải lâm sàng

Kiến thức về tăng huyết áp khác nhau theo trình độ học vấn ($F = 7.8$ với 3 và 1.032 bậc tự do, $p < 0.001$), chủ yếu vì bệnh nhân có trình độ trung học hoặc cao đẳng/đại học đạt điểm cao hơn khoảng 1 đến 1,5 điểm (trên thang 20) so với những người có trình độ tiểu học. Các khác biệt này là có thật theo nghĩa thống kê nhưng có độ lớn khiêm tốn so với độ phân tán của điểm số (SD khoảng 3,4): học vấn chỉ giải thích một phần nhỏ lý do vì sao bệnh nhân khác nhau về kiến thức. Giáo dục sức khỏe cần tiếp cận bệnh nhân ở mọi trình độ học vấn.

4.6 Hai biến phân loại

Các câu hỏi trọng tâm của nghiên cứu liên quan đến một biến kết cục nhị phân, việc tiếp nhận điều trị, và các yếu tố quyết định dạng phân loại như bảo hiểm y tế, nơi cư trú và đài tháo đường. Việc tiếp nhận điều trị có liên quan đến việc có bảo hiểm y tế hay không?

4.6.1 Bảng tiếp liên và tỷ lệ phần trăm phù hợp

Dữ liệu về hai biến phân loại được tóm tắt trong một **bảng tiếp liên** (contingency table, hay bảng chéo — cross-tabulation) gồm các số đếm. Khi đặt yếu tố quyết định tiềm năng ở các dòng và biến kết cục ở các cột, **tỷ lệ phần trăm theo dòng** trả lời câu hỏi tự nhiên về mặt lâm sàng: bao nhiêu phần trăm bệnh nhân có bảo hiểm, và bao nhiêu phần trăm bệnh nhân không có bảo hiểm, tiếp nhận điều trị?

```
tab_ins <- table(Insurance = dx$health_insurance,
                 Uptake    = dx$treatment_uptake)
addmargins(tab_ins) # số đếm kèm tổng
```

```
#>      Uptake
#> Insurance No  Yes  Sum
#>      No   419  306  725
#>      Yes  162  202  364
#>      Sum  581  508 1089
```


```
# Tỷ lệ phần trăm theo dòng: tiếp nhận điều trị trong từng nhóm bảo hiểm
round(100 * prop.table(tab_ins, margin = 1), 1)
```

```
#>           Uptake
#> Insurance  No  Yes
#>           No 57.8 42.2
#>           Yes 44.5 55.5
```

Trong số 364 bệnh nhân có bảo hiểm, 55,5% đang điều trị, so với 42,2% trong số 725 bệnh nhân không có bảo hiểm. Hình 4.6 trình bày cùng phép so sánh này dưới dạng đồ thị, cùng với trình độ học vấn.

```
bar_data <- bind_rows(
  dx |> count(group = health_insurance, treatment_uptake) |>
    mutate(variable = "Bảo hiểm y tế"),
  dx |> filter(!is.na(education)) |>
    count(group = as.character(education), treatment_uptake) |>
    mutate(variable = "Học vấn")
) |>
  mutate(group = factor(group, levels = c("No", "Yes", "None", "Primary",
                                          "Secondary", "Tertiary")),
         variable = factor(variable, levels = c("Bảo hiểm y tế",
                                                "Học vấn"))

ggplot(bar_data, aes(x = group, y = n, fill = treatment_uptake)) +
  geom_col(position = "fill", width = 0.7) +
  geom_text(aes(label = n, position = position_fill(vjust = 0.5),
              colour = "white", size = 3) +
  facet_grid(~ variable, scales = "free_x", space = "free_x") +
  scale_y_continuous(labels = scales::percent) +
  scale_fill_manual(values = c(No = "grey60", Yes = "teal"),
                    name = "Tiếp nhận điều trị") +
  labs(x = NULL, y = "Tỷ lệ bệnh nhân")
```



Hình 4.6: Tỷ lệ phần trăm bệnh nhân đã được chẩn đoán đang dùng thuốc hạ áp theo tình trạng bảo hiểm y tế và theo trình độ học vấn. Mỗi cột có tổng bằng 100%; các con số bên trong cột là số bệnh nhân.

4.6.2 Kiểm định khi bình phương Pearson

Nếu bảo hiểm và việc tiếp nhận điều trị **độc lập** với nhau, tỷ lệ tiếp nhận điều trị sẽ như nhau ở bệnh nhân có và không có bảo hiểm, và bằng tỷ lệ chung. Khi đó **số đếm kỳ vọng** (expected count) trong ô ở dòng i và cột j sẽ là

$$E_{ij} = \frac{(\text{tổng dòng } i) \times (\text{tổng cột } j)}{\text{tổng chung}}.$$

Thống kê khi bình phương Pearson (Pearson's chi-square statistic) (Pearson 1900) cộng các bình phương chênh lệch giữa số đếm quan sát O_{ij} và số đếm kỳ vọng, chia cho số đếm kỳ vọng:

$$X^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}.$$

Dưới H_0 về tính độc lập, X^2 tuân theo xấp xỉ phân phối χ^2 với $(r - 1)(c - 1)$ bậc tự do, trong đó r và c là số dòng và số cột; một bảng 2x2 có một bậc tự do. Giá trị X^2 lớn cho thấy bảng quan sát được khác xa so với điều mà giả thuyết độc lập dự đoán (Kirkwood and Sterne 2003; Agresti 2013). Phép tính đủ đơn giản để làm bằng tay, giúp logic của nó trở nên minh bạch.

```
observed <- tab_ins
expected <- outer(rowSums(observed), colSums(observed)) / sum(observed)
round(expected, 1)
```

```
#>      No   Yes
#> No  386.8 338.2
#> Yes 194.2 169.8
```

```
x2 <- sum((observed - expected)^2 / expected) # thống kê Pearson
x2
```

```
#> [1] 17.192
```

```
pchisq(x2, df = 1, lower.tail = FALSE) # giá trị p từ chi-square(1)
```

```
#> [1] 3.3789e-05
```

Nếu độc lập, chúng ta kỳ vọng có 169,8 bệnh nhân có bảo hiểm đang điều trị; chúng ta quan sát được 202. Thống kê kiểm định là 17,2 với một bậc tự do, $p = 3.4 \times 10^{-5}$. Hàm có sẵn của R cho kết quả tương tự, với một điểm tinh chỉnh:

```
chisq.test(tab_ins)
```

```
#>
#>      Pearson's Chi-squared test with Yates' continuity correction
#>
#> data:  tab_ins
```

```
#> X-squared = 16.7, df = 1, p-value = 4.5e-05
```

- **Pearson's Chi-squared test with Yates' continuity correction:** với bảng 2x2, R mặc định áp dụng **hiệu chỉnh Yates** (Yates' correction), trừ 0,5 khỏi mỗi $|O - E|$ trước khi bình phương. Hiệu chỉnh này làm kiểm định hơi bảo thủ.
- **X-squared = 16.7, df = 1:** thống kê đã hiệu chỉnh, nhỏ hơn một chút so với giá trị 17,2 của chúng ta.
- **p-value = 4.5e-05:** bằng chứng mạnh cho thấy tiếp nhận điều trị và bảo hiểm không độc lập với nhau.

Với mẫu lớn, kiểm định có hiệu chỉnh và không hiệu chỉnh cho kết quả rất gần nhau; `chisq.test(tab_ins, correct = FALSE)` tái tạo đúng phép tính bằng tay của chúng ta. Cả thống kê kiểm định lẫn giá trị p đều không cho biết *hướng* hay *độ lớn* của mối liên quan: để biết điều đó, chúng ta cần tỷ lệ phần trăm theo dòng và các thước đo tác động ở Mục 4.6.4.

4.6.3 Giả định về số đếm kỳ vọng và kiểm định chính xác Fisher

Phân phối khi bình phương là một xấp xỉ cho mẫu lớn. Một quy tắc được dùng rộng rãi, do Cochran đề xuất, là xấp xỉ này phù hợp khi không có số đếm kỳ vọng nào nhỏ hơn 1 và không quá 20% số đếm kỳ vọng nhỏ hơn 5; với bảng 2x2, mọi số đếm kỳ vọng nên ít nhất bằng 5 (Kirkwood and Sterne 2003; Agresti 2013). Lưu ý rằng quy tắc này áp dụng cho số đếm kỳ vọng, không phải số đếm quan sát. Khi quy tắc không được thỏa mãn, **kiểm định chính xác Fisher** (Fisher's exact test) tính xác suất chính xác của bảng quan sát được, và của mọi bảng cực đoan hơn, với điều kiện các tổng dòng và tổng cột cố định, dựa trên phân phối siêu bội (hypergeometric). Kiểm định này không dùng xấp xỉ cho mẫu lớn và hợp lệ với mọi cỡ mẫu (Agresti 2013).

Đái tháo đường là một ví dụ hữu ích, vì chỉ có 28 bệnh nhân đã được chẩn đoán tăng huyết áp mắc đái tháo đường.

```
tab_diab <- table(Diabetes = dx$diabetes, Uptake = dx$treatment_uptake)
addmargins(tab_diab)
```

```
#>      Uptake
#> Diabetes No  Yes  Sum
#>      No   574  487 1061
#>      Yes    7   21   28
#>      Sum   581  508 1089
```

```
chisq.test(tab_diab)$expected      # kiểm tra các số đếm kỳ vọng
```

```
#>      Uptake
#> Diabetes      No      Yes
#>      No  566.062  494.938
#>      Yes   14.938   13.062
```

Số đếm kỳ vọng nhỏ nhất là 13,1, nên thực ra kiểm định khi bình phương vẫn chấp nhận được ở đây, nhưng có hai ô quan sát nhỏ (7 và 21), và kiểm định Fisher là một phép kiểm tra tự nhiên.

```
fisher.test(tab_diab)
```

R

```
#>
#>      Fisher's Exact Test for Count Data
#>
#> data:  tab_diab
#> p-value = 0.0033
#> alternative hypothesis: true odds ratio is not equal to 1
#> 95 percent confidence interval:
#>  1.4313 9.9226
#> sample estimates:
#> odds ratio
#>      3.5321
```

- **p-value = 0.0033**: bằng chứng mạnh về mối liên quan giữa đái tháo đường và việc tiếp nhận điều trị.
- **odds ratio 3.53** với **95 percent confidence interval 1.43 to 9.92**: kiểm định Fisher báo cáo một ước lượng *hợp lý cực đại có điều kiện* (conditional maximum likelihood) của tỷ số chênh, có thể hơi khác so với tỷ số tích chéo đơn giản được mô tả dưới đây. Khoảng tin cậy rộng vì chỉ có 28 bệnh nhân mắc đái tháo đường.

Trong R, `fisher.test()` cũng áp dụng được cho các bảng lớn hơn 2×2 , dù có thể chạy chậm với bảng lớn; `simulate.p.value = TRUE` cho một xấp xỉ Monte Carlo.

Lỗi thường gặp

Áp dụng quy tắc "ít nhất 5 trong mỗi ô" cho số đếm *quan sát*. Một ô có số đếm quan sát bằng 2 vẫn ổn nếu số đếm kỳ vọng của nó, chẳng hạn, là 8. Hãy kiểm tra `chisq.test(tab)$expected`, và chuyển sang kiểm định chính xác Fisher khi số đếm kỳ vọng nhỏ.

4.6.4 Các thước đo tác động từ bảng 2×2

Một kiểm định trả lời câu hỏi "có mối liên quan không?" Người đọc lâm sàng muốn biết "mạnh đến đâu?". Hãy viết bảng 2×2 như sau

	Kết cục Có	Kết cục Không	Tổng
Có phơi nhiễm	a	b	$n_1 = a + b$
Không phơi nhiễm	c	d	$n_0 = c + d$

với nguy cơ (tỷ lệ có biến kết cục) $p_1 = a/n_1$ ở nhóm có phơi nhiễm và $p_0 = c/n_0$ ở nhóm không phơi nhiễm. Có ba thước đo được dùng phổ biến (Kirkwood and Sterne 2003; Agresti 2013; Bland and Altman 2000).

- **Hiệu số nguy cơ** (risk difference) $RD = p_1 - p_0$, với sai số chuẩn $\sqrt{p_1(1 - p_1)/n_1 + p_0(1 - p_0)/n_0}$. Đây là thước đo trên thang tuyệt đối và hữu ích nhất cho việc lập kế hoạch dịch vụ (thêm bao nhiêu bệnh nhân trên 100 người sẽ được điều trị).
- **Nguy cơ tương đối** (relative risk, hay tỷ số nguy cơ — risk ratio) $RR = p_1/p_0$. Khoảng tin cậy của nó được tính trên thang logarit, $SE(\ln RR) = \sqrt{1/a - 1/n_1 + 1/c - 1/n_0}$.

- **Tỷ số chênh** (odds ratio, OR) $OR = \frac{a/b}{c/d} = \frac{ad}{bc}$, tức tỷ số giữa odds của biến kết cục ở hai nhóm, với $SE(\ln OR) = \sqrt{1/a + 1/b + 1/c + 1/d}$.

Với các thước đo dạng tỷ số, KTC 95% là $\exp\{\ln(\text{tỷ số}) \pm 1.96 \times SE\}$, khoảng này không đối xứng quanh ước lượng trên thang đo gốc. "Không có mối liên quan" tương ứng với RD = 0, RR = 1 và OR = 1. Chúng ta tính cả ba thước đo cho bảo hiểm y tế (có phơi nhiễm = có bảo hiểm) và việc tiếp nhận điều trị.

```
# Các ô được đặt tên như trong bảng trên (tránh đặt tên một ô là "c",  
# vì sẽ che khuất hàm c() của R)  
a <- tab_ins["Yes", "Yes"]; b <- tab_ins["Yes", "No"] # có bảo hiểm  
cc <- tab_ins["No", "Yes"]; dd <- tab_ins["No", "No"] # không có bảo hiểm  
n1 <- a + b; n0 <- cc + dd  
p1 <- a / n1; p0 <- cc / n0  
  
rd <- p1 - p0  
se_rd <- sqrt(p1 * (1 - p1) / n1 + p0 * (1 - p0) / n0)  
  
rr <- p1 / p0  
se_log_rr <- sqrt(1 / a - 1 / n1 + 1 / cc - 1 / n0)  
  
or <- (a * dd) / (b * cc)  
se_log_or <- sqrt(1 / a + 1 / b + 1 / cc + 1 / dd)  
  
effects <- tibble(  
  measure = c("Hiệu số nguy cơ", "Nguy cơ tương đối", "Tỷ số chênh"),  
  estimate = c(rd, rr, or),  
  lower = c(rd - 1.96 * se_rd, exp(log(rr) - 1.96 * se_log_rr),  
            exp(log(or) - 1.96 * se_log_or)),  
  upper = c(rd + 1.96 * se_rd, exp(log(rr) + 1.96 * se_log_rr),  
            exp(log(or) + 1.96 * se_log_or))  
)  
knitr::kable(effects, digits = 3,  
  col.names = c("Thước đo", "Ước lượng", "Cận dưới", "Cận trên"),  
  caption = "Mối liên quan giữa bảo hiểm y tế và việc tiếp nhận điều trị:  
ba thước đo tác động kèm khoảng tin cậy 95%.")
```

Bảng 4.2: Mối liên quan giữa bảo hiểm y tế và việc tiếp nhận điều trị: ba thước đo tác động kèm khoảng tin cậy 95%.

Thước đo	Ước lượng	Cận dưới	Cận trên
Hiệu số nguy cơ	0.133	0.070	0.195
Nguy cơ tương đối	1.315	1.160	1.490
Tỷ số chênh	1.707	1.325	2.201

Đọc bảng: bệnh nhân có bảo hiểm có khả năng đang điều trị cao hơn 13,3 điểm phần trăm (KTC 95% từ 7,0 đến 19,5); xác suất tiếp nhận điều trị của họ bằng 1,31 lần so với bệnh nhân không có bảo hiểm (KTC 95% từ 1,16 đến 1,49); và odds tiếp nhận điều trị của họ cao gấp 1,71 lần (KTC 95% từ 1,32 đến 2,20). Cả ba khoảng tin cậy đều không chứa giá trị "không tác động", phù hợp với giá trị p của kiểm định khi bình phương.

Vì sao lại có ba thước đo, và vì sao tỷ số chênh (1,71) cách xa 1 hơn nhiều so với nguy cơ tương đối (1,31)? Odds và nguy cơ chỉ gần nhau khi biến kết cục hiếm gặp (chẳng hạn dưới 10%).

Việc tiếp nhận điều trị là phổ biến (47%), nên ở đây tỷ số chênh phóng đại đáng kể nguy cơ tương đối nếu bị đọc nhầm thành nguy cơ tương đối (Zhang and Yu 1998; Bland and Altman 2000). Dù vậy, tỷ số chênh vẫn quan trọng: đó là thước đo có thể ước lượng từ các nghiên cứu bệnh–chứng, nó có tính đối xứng (tỷ số chênh cho “không tiếp nhận điều trị” đơn giản là $1/1.71$), và đó là đại lượng mà **hồi quy logistic** ước lượng, vì vậy nó chiếm ưu thế trong phân tích các biến kết cục nhị phân (Mục 4.9 và Chương 5).

Diễn giải lâm sàng

Trong mẫu (mô phỏng) này, 55,5% bệnh nhân đã được chẩn đoán có bảo hiểm và 42,2% bệnh nhân không có bảo hiểm đang điều trị, chênh lệch 13 điểm phần trăm (KTC 95% từ 7 đến 20; $p < 0.001$). Nếu mối liên quan này là nhân quả, cứ mỗi 100 bệnh nhân sẽ có thêm khoảng 13 người được điều trị nếu bệnh nhân không có bảo hiểm đạt được tỷ lệ tiếp nhận của bệnh nhân có bảo hiểm. Đó là một khác biệt lớn xét về mặt y tế công cộng, nhưng tình trạng bảo hiểm có liên quan đến các đặc điểm khác (thu nhập, học vấn, nơi cư trú), nên phép so sánh thô này có thể phản ánh một phần các yếu tố đó.

4.6.5 Các bảng lớn hơn

Kiểm định khi bình phương áp dụng tương tự cho các bảng lớn hơn. Với học vấn (bốn mức) theo việc tiếp nhận điều trị:

```
tab_edu <- table(Education = dx$education, Uptake = dx$treatment_uptake)
round(100 * prop.table(tab_edu, margin = 1), 1)
```

```
#>           Uptake
#> Education    No  Yes
#>   None       62.7 37.3
#>  Primary    56.8 43.2
#> Secondary   46.9 53.1
#> Tertiary    43.0 57.0
```

```
chisq.test(tab_edu)
```

```
#>
#>      Pearson's Chi-squared test
#>
#> data:  tab_edu
#> X-squared = 19.5, df = 3, p-value = 0.00022
```

Tỷ lệ tiếp nhận điều trị tăng từ 37,3% ở bệnh nhân không đi học lên 57,0% ở những người có trình độ cao đẳng/đại học (Hình 4.6). Thống kê khi bình phương là 19,5 với $(4 - 1)(2 - 1) = 3$ bậc tự do, $p < 0.001$. Hiệu chỉnh Yates không được dùng cho các bảng lớn hơn 2×2 . Lưu ý rằng kiểm định này bỏ qua *thứ tự* của học vấn: nó sẽ cho cùng một kết quả nếu các dòng bị xáo trộn. Khi các nhóm có thứ tự, một kiểm định xu hướng (ví dụ kiểm định khi bình phương cho xu hướng, hoặc hồi quy logistic với học vấn được mã hóa thành điểm số; xem Chương 5) có lực thống kê cao hơn và trả lời câu hỏi cụ thể hơn về một gradient (Altman 1991; Agresti 2013).

4.6.6 Thực hiện kiểm định cho cả một bảng

Trong một bản thảo, việc so sánh các đặc điểm giữa các nhóm kết cục thường được trình bày trong một bảng. Gói `gtsummary` (Sjoberg et al. 2021) bổ sung giá trị p bằng `add_p()`, tự chọn một kiểm định cho từng biến. Điều quan trọng là phải biết gói dùng những kiểm định nào: theo mặc định là kiểm định tổng hạng Wilcoxon cho các biến liên tục, và kiểm định khi bình phương (hoặc kiểm định chính xác Fisher khi số đếm kỳ vọng nhỏ) cho các biến phân loại.

```
dx |>
  select(treatment_uptake, age, distance_to_facility_km,
         health_insurance, residence, diabetes) |>
  tbl_summary(by = treatment_uptake, missing = "no",
             label = list(age ~ "Tuổi (năm)",
                          distance_to_facility_km ~ "Khoảng cách (km)",
                          health_insurance ~ "Bảo hiểm y tế",
                          residence ~ "Nơi cư trú",
                          diabetes ~ "Đái tháo đường")) |>
  add_p() |>
  modify_header(label = "***Đặc điểm***", p.value = "***Giá trị p***") |>
  as_kable(caption = "Đặc điểm của bệnh nhân đã được chẩn đoán theo việc tiếp nhận
điều trị, với giá trị p từ các kiểm định mặc định của gtsummary.")
```

Bảng 4.3: Đặc điểm của bệnh nhân đã được chẩn đoán theo việc tiếp nhận điều trị, với giá trị p từ các kiểm định mặc định của `gtsummary`.

Đặc điểm	No N = 581	Yes N = 508	Giá trị p
Tuổi (năm)	51 (41, 60)	56 (47, 66)	<0.001
Khoảng cách (km)	6.8 (4.3, 10.7)	5.8 (3.1, 9.6)	<0.001
Bảo hiểm y tế	162 (28%)	202 (40%)	<0.001
Nơi cư trú			<0.001
Rural	306 (53%)	195 (38%)	
Urban	275 (47%)	313 (62%)	
Đái tháo đường	7 (1.2%)	21 (4.1%)	0.002

Lỗi thường gặp

Đưa giá trị p vào bảng đặc điểm ban đầu của một thử nghiệm ngẫu nhiên có đối chứng. Trong thử nghiệm, mọi khác biệt ban đầu đều do ngẫu nhiên theo thiết kế, nên việc kiểm định chúng là vô nghĩa; giá trị p trong một bảng như bảng này chỉ phù hợp trong các nghiên cứu quan sát, nơi chúng mô tả các mối liên quan, và ngay cả khi đó, các ước lượng vẫn quan trọng hơn giá trị p.

4.7 Tương quan giữa hai biến liên tục

Huyết áp tâm thu có liên quan đến chỉ số khối cơ thể (BMI) không? Khi cả hai biến đều liên tục và không biến nào rõ ràng là "biến kết cục", chúng ta có thể đo mức độ mạnh của mối liên quan giữa chúng bằng một **hệ số tương quan** (correlation coefficient).

4.7.1 Hệ số tương quan Pearson

Hệ số tương quan tích-mômen Pearson (Pearson's product-moment correlation coefficient) cho n cặp (x_i, y_i) là

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2 \sum_i (y_i - \bar{y})^2}}.$$

Hệ số này nằm trong khoảng từ -1 (quan hệ đường thẳng nghịch biến hoàn hảo), qua 0 (không có quan hệ *tuyến tính*), đến $+1$ (quan hệ đường thẳng đồng biến hoàn hảo). Kiểm định $H_0 : \rho = 0$ dùng $t = r\sqrt{(n-2)/(1-r^2)}$ với $n-2$ bậc tự do, và khoảng tin cậy được tính thông qua phép biến đổi z của Fisher. Hệ số r Pearson chỉ đo mối liên quan *tuyến tính*, nhạy cảm với giá trị ngoại lai, và kiểm định của nó giả định rằng ít nhất một trong hai biến có phân phối xấp xỉ chuẩn (Altman 1991; Bland 2015).

4.7.2 Hệ số tương quan hạng Spearman

Hệ số tương quan hạng Spearman (Spearman's rank correlation coefficient) r_s (thường được viết là ρ) là hệ số Pearson được tính trên thứ hạng của x và y thay vì giá trị của chúng (Spearman 1904). Khi không có giá trị bằng nhau, công thức rút gọn thành

$$r_s = 1 - \frac{6 \sum_i d_i^2}{n(n^2 - 1)},$$

trong đó d_i là hiệu số giữa thứ hạng của x_i và của y_i . Hệ số này đo mối liên quan **đơn điệu** (monotonic — biến này có xu hướng tăng khi biến kia tăng, không nhất thiết theo một đường thẳng), vững trước giá trị ngoại lai và phù hợp với dữ liệu thứ bậc hoặc dữ liệu lệch.

4.7.3 Hãy xem biểu đồ phân tán

Luôn vẽ dữ liệu trước khi tính một hệ số tương quan. Một con số duy nhất không thể phân biệt một quan hệ tuyến tính thực sự với một đường cong, một cụm giá trị ngoại lai hay hai phân nhóm tách biệt.

```
ggplot(dx, aes(x = bmi, y = sbp_mmhg)) +  
  geom_point(alpha = 0.3, size = 1, colour = course_teal) +  
  geom_smooth(method = "lm", formula = y ~ x, colour = "black") +  
  labs(x = "Chỉ số khối cơ thể (kg/m²)", y = "HA tâm thu (mmHg)")
```

R


Đám mây điểm dốc lên: bệnh nhân có BMI cao hơn có xu hướng có huyết áp tâm thu cao hơn, nhưng các điểm phân tán rất nhiều quanh đường thẳng.

4.7.4 Tương quan trong R

```
cor.test(dx$bmi, dx$sbp_mmhg, method = "pearson")
```

R

```
#>  
#>      Pearson's product-moment correlation  
#>
```



Hình 4.7: Huyết áp tâm thu theo chỉ số khối cơ thể ở bệnh nhân đã được chẩn đoán, với đường thẳng bình phương tối thiểu và dải tin cậy 95% của nó.

```
#> data: dx$bmi and dx$sbp_mmhg
#> t = 11.8, df = 1053, p-value <2e-16
#> alternative hypothesis: true correlation is not equal to 0
#> 95 percent confidence interval:
#> 0.28742 0.39407
#> sample estimates:
#> cor
#> 0.34185
```

Đọc kết quả:

- **t = 11.8, df = 1053:** thống kê kiểm định cho $H_0 : \rho = 0$; có 1.055 bệnh nhân có cả hai số đo ($n - 2 = 1053$).
- **p-value < 2.2e-16:** bằng chứng áp đảo rằng hệ số tương quan khác 0.
- **95 percent confidence interval: 0.29 0.39:** khoảng giá trị hợp lý cho hệ số tương quan trong quần thể.
- **cor 0.34185:** $r = 0.34$ của Pearson, một mối liên quan tuyến tính đồng biến ở mức trung bình.

```
cor.test(dx$bmi, dx$sbp_mmhg, method = "spearman", exact = FALSE)
```

R

```
#>
#> Spearman's rank correlation rho
#>
#> data: dx$bmi and dx$sbp_mmhg
#> S = 1.35e+08, p-value <2e-16
#> alternative hypothesis: true rho is not equal to 0
#> sample estimates:
#> rho
#> 0.31132
```

Hệ số Spearman $r_s = 0.31$ là tương tự, như dự kiến khi mối quan hệ gần tuyến tính và không có giá trị ngoại lai cực đoan. Thống kê s là tổng bình phương các hiệu số thứ hạng; `exact = FALSE` yêu cầu giá trị p thông thường cho mẫu lớn (giá trị p chính xác không tính được khi có các giá trị bằng nhau). R không đưa ra khoảng tin cậy cho hệ số Spearman.

Bình phương của hệ số Pearson, $r^2 = 0.34^2 \approx 0.12$, là tỷ lệ phương sai của một biến được "giải thích" bởi quan hệ đường thẳng với biến kia: BMI giải thích khoảng 12% biến thiên của huyết áp tâm thu trong mẫu này. Đôi khi người ta dùng các nhãn mô tả ước lệ (dưới 0,3 là yếu, từ 0,3 đến 0,7 là trung bình, trên 0,7 là mạnh), nhưng bối cảnh lâm sàng quan trọng hơn nhãn.

Hãy xem xét thêm tương quan giữa tuổi và huyết áp tâm thu.

```
cor.test(dx$age, dx$sbp_mmhg) |> tidy() |>
  select(estimate, statistic, p.value, conf.low, conf.high)
```

```
#> # A tibble: 1 × 5
#>   estimate statistic    p.value conf.low conf.high
#>   <dbl>     <dbl>    <dbl>    <dbl>    <dbl>
#> 1    0.142      4.72 0.00000263    0.0832    0.200
```

Ở đây $r = 0.14$ với $p < 0.001$: rất "có ý nghĩa", nhưng tuổi chỉ giải thích khoảng 2% biến thiên của huyết áp tâm thu (0.14^2). Với một nghìn bệnh nhân, hầu như mọi hệ số tương quan khác 0 đều có ý nghĩa thống kê; điều quan trọng là độ lớn của r và khoảng tin cậy của nó.

Lỗi thường gặp

Diễn giải một hệ số tương quan như bằng chứng của quan hệ nhân quả, hoặc một giá trị p có ý nghĩa như bằng chứng của một mối quan hệ mạnh. Tương quan chỉ đo lường mối liên quan: BMI và huyết áp có thể tương quan với nhau vì cả hai cùng chịu ảnh hưởng của chế độ ăn, hoạt động thể lực và tuổi. Tương quan cũng không nói gì về sự phù hợp (agreement): hai máy đo huyết áp có thể tương quan rất cao nhưng lại lệch nhau một cách hệ thống 10 mmHg (Altman 1991; Bland 2015).

4.8 Chọn kiểm định phù hợp với câu hỏi

Việc chọn phương pháp xuất phát từ câu hỏi nghiên cứu và từ loại của các biến liên quan, chứ không phải từ việc kiểm định nào cho giá trị p nhỏ nhất. Bảng dưới đây tóm tắt các phương pháp trong chương này.

Ba câu hỏi thực tiễn định hướng lựa chọn:

- 1. Biến kết cục thuộc loại nào?** Liên tục, nhị phân hoặc phân loại, thứ bậc, thời gian đến sự kiện.
- 2. Có bao nhiêu nhóm, và các nhóm độc lập hay bắt cặp?**
- 3. Các giả định của kiểm định tham số có hợp lý không?** Hãy cân nhắc hình dạng phân phối, cỡ mẫu và liệu trung bình có phải là đại lượng tóm tắt hợp lý hay không.

4.9 Cầu nối sang hồi quy: vì sao xem xét từng biến một là chưa đủ

Bảng 4.4: Chọn kiểm định thống kê cho một phép so sánh hoặc một mối liên quan giữa hai biến.

Câu hỏi	Loại biến kết cục	Phương pháp tham số	Phi tham số / chính xác	Thước đo tác động
Hai nhóm độc lập có khác nhau?	Liên tục	Kiểm định t Welch, <code>t.test()</code>	Tổng hạng Wilcoxon, <code>wilcox.test()</code>	Hiệu số trung bình (hoặc độ dịch chuyển Hodges–Lehmann) kèm KTC
Hai số đo bắt cặp có khác nhau?	Liên tục	Kiểm định t bắt cặp, <code>t.test(paired = TRUE)</code>	Hạng có dấu Wilcoxon	Hiệu số trung bình kèm KTC
Nhiều hơn hai nhóm có khác nhau?	Liên tục	ANOVA một yếu tố, <code>aov()</code> ; ANOVA Welch, <code>oneway.test()</code>	Kruskal–Wallis, <code>kruskal.test()</code>	Hiệu số từng cặp (Tukey, Bonferroni)
Hai biến phân loại có liên quan?	Phân loại	Khi bình phương, <code>chisq.test()</code>	Chính xác Fisher, <code>fisher.test()</code>	RD, RR, OR kèm KTC
Hai biến liên tục có liên quan?	Liên tục	Pearson, <code>cor.test()</code>	Spearman, <code>cor.test(method = "spearman")</code>	Hệ số tương quan kèm KTC
Biến kết cục nhị phân và một hay nhiều biến dự báo	Nhị phân	Hồi quy logistic, <code>glm(family = binomial)</code>	—	Tỷ số chênh kèm KTC

Mọi kiểm định trong chương này đều xem xét **hai biến cùng một lúc**. Trong nghiên cứu quan sát, đây là một hạn chế nghiêm trọng, vì các nhóm được so sánh thường khác nhau về nhiều mặt cùng lúc. Bệnh nhân đái tháo đường trong dữ liệu của chúng ta lớn tuổi hơn bệnh nhân không mắc đái tháo đường (tuổi trung bình 59,7 so với 53,4), và bệnh nhân lớn tuổi hơn có nhiều khả năng đang điều trị hơn. Vậy khi thấy tỷ lệ tiếp nhận điều trị cao hơn ở bệnh nhân đái tháo đường, bao nhiêu phần là do đái tháo đường và bao nhiêu phần là do tuổi? Một biến như tuổi, vừa liên quan đến phơi nhiễm vừa liên quan đến biến kết cục và không nằm trên con đường nhân quả giữa chúng, là một **yếu tố gây nhiễu** (confounder) (Rothman et al. 2008; Greenland et al. 1999). Các kiểm định hai biến không thể tách tác động của nó khỏi tác động của phơi nhiễm. Phân tầng (lặp lại kiểm định trong từng nhóm tuổi) nhanh chóng cạn dữ liệu khi số yếu tố gây nhiễu tăng lên. **Các mô hình hồi quy** giải quyết vấn đề này bằng cách ước lượng tác động của từng biến trong khi giữ các biến khác không đổi.

Với một biến kết cục nhị phân, mô hình chuẩn là **hồi quy logistic** (logistic regression), được trình bày đầy đủ ở Chương 5 (Hosmer et al. 2013). Mô hình này mô tả log-odds của biến kết cục như một hàm tuyến tính của các biến dự báo,

$$\ln\left(\frac{\pi}{1-\pi}\right) = \beta_0 + \beta_1 x_1 + \dots + \beta_k x_k,$$

trong đó π là xác suất tiếp nhận điều trị. Với một biến dự báo nhị phân duy nhất, e^{β_1} chính xác bằng tỷ số chênh của bảng 2x2. Chúng ta có thể xác nhận điều này với biến bảo hiểm y tế.

```
m_ins <- glm(treatment_uptake ~ health_insurance, data = dx,
             family = binomial)
tidy(m_ins, exponentiate = TRUE, conf.int = TRUE) |>
  select(term, estimate, p.value, conf.low, conf.high)
```

R

```
#> # A tibble: 2 × 5
#>   term                estimate p.value conf.low conf.high
#>   <chr>                <dbl>    <dbl>    <dbl>    <dbl>
#> 1 (Intercept)          0.730 0.0000292    0.630    0.846
#> 2 health_insuranceYes  1.71 0.0000363    1.33    2.20
```

```
# Tỷ số chênh tích chéo từ bảng 2x2, để so sánh
or
```

```
#> [1] 1.7074
```

Đổi số `family = binomial` cho `glm()` biết biến kết cục là nhị phân; vì nhóm tham chiếu của `treatment_uptake` là "No", mô hình mô tả odds của "Yes". `exponentiate = TRUE` chuyển các hệ số từ log-odds sang tỷ số chênh. Dòng `health_insuranceYes` cho tỷ số chênh 1,707, giống hệt giá trị ad/bc mà chúng ta đã tính bằng tay. KTC 95% của nó (1,33 đến 2,20) là một khoảng *hợp lý hồ sơ* (profile-likelihood), loại khoảng mà `glm()` dùng theo mặc định; nó gần như giống hệt khoảng tin cậy trên thang logarit (Wald) của chúng ta, từ 1,32 đến 2,20. Giá trị p (3.6×10^{-5}) rất gần với giá trị p của kiểm định khi bình phương. Dòng (Intercept) là odds tiếp nhận điều trị ở nhóm không có bảo hiểm ($306/419 = 0.73$). Như vậy, hồi quy logistic với một biến dự báo chỉ là một cách khác để phân tích bảng 2x2; sức mạnh của nó nằm ở chỗ có thể thêm các biến dự báo khác. Hãy xem qua điều này đạt được gì đối với đái tháo đường:

```
crude <- glm(treatment_uptake ~ diabetes, data = dx, family = binomial)
adjusted <- glm(treatment_uptake ~ diabetes + age, data = dx,
               family = binomial)
```

```
# Tỷ số chênh của đái tháo đường trước và sau khi tính đến tuổi
exp(c(crude = coef(crude)[["diabetesYes"]],
      age_adjusted = coef(adjusted)[["diabetesYes"]]))
```

```
#>      crude age_adjusted
#>      3.5359      3.0995
```

Tỷ số chênh thô của đái tháo đường là 3,54; sau khi tính đến tuổi, nó giảm xuống còn 3,10. Một phần tác động biểu kiến của đái tháo đường thực ra là tác động của việc lớn tuổi hơn. Chương 5 sẽ phát triển nội dung này một cách đầy đủ: chọn yếu tố gây nhiễu, xây dựng và kiểm tra các mô hình đa biến, và báo cáo tỷ số chênh hiệu chỉnh.

4.10 Báo cáo kết quả đúng cách

Một kết quả thống kê chỉ hữu ích nếu người đọc hiểu được nó. Hướng dẫn của tuyên bố STROBE cho các nghiên cứu quan sát (Elm et al. 2007), và của các sách thống kê được trích dẫn xuyên suốt chương này, quy về một vài nguyên tắc.

- **Mô tả trước khi kiểm định.** Đưa ra các thống kê tóm tắt cho từng nhóm (trung bình và độ lệch chuẩn, trung vị và IQR, hoặc số lượng và tỷ lệ phần trăm), kèm số bệnh nhân được phân tích.
- **Đặt ước lượng và khoảng tin cậy của nó lên đầu**, theo đơn vị của biến kết cục, và đưa giá

trị p chính xác như thông tin bổ trợ.

- **Nêu tên kiểm định** trong phần phương pháp, và cho biết các giả định đã được kiểm tra như thế nào và vấn đề so sánh bội đã được xử lý ra sao.
- **Diễn giải độ lớn** của tác động theo ngôn ngữ lâm sàng, và không diễn giải một kết quả không có ý nghĩa thống kê như bằng chứng của việc không có tác động.
- **Đường phóng đại.** Các mối liên quan cắt ngang không phải là tác động nhân quả, và các mối liên quan thô có thể bị nhiễu.

Dưới đây là cách các kết quả chính của chương này có thể được trình bày trong phần kết quả của một bài báo.

Trong số 1.089 bệnh nhân đã được chẩn đoán tăng huyết áp, 508 người (46,6%) đang dùng thuốc hạ áp. Bệnh nhân đang điều trị lớn tuổi hơn những người không điều trị (trung bình 56,3 so với 51,1 tuổi; chênh lệch 5,2 tuổi, KTC 95% từ 3,5 đến 6,8; kiểm định t Welch $p < 0.001$) và sống gần cơ sở y tế hơn (trung vị 5,8 so với 6,8 km; hiệu số Hodges–Lehmann 1,0 km, KTC 95% từ 0,4 đến 1,5; kiểm định tổng hạng Wilcoxon $p < 0.001$). Tỷ lệ tiếp nhận điều trị cao hơn ở bệnh nhân có bảo hiểm so với bệnh nhân không có bảo hiểm (55,5% so với 42,2%; hiệu số nguy cơ 13,3 điểm phần trăm, KTC 95% từ 7,0 đến 19,5; tỷ số chênh 1,71, KTC 95% từ 1,32 đến 2,20; $\chi^2 = 16.7$, 1 bậc tự do, $p < 0.001$).

Thực hành tốt

Tránh viết "có khác biệt có ý nghĩa thống kê ($p < 0,05$)" mà không có con số nào. Thay vào đó, hãy viết khác biệt là bao nhiêu, được ước lượng chính xác đến đâu và bằng chứng mạnh đến mức nào: "bệnh nhân được điều trị trung bình lớn hơn 5,2 tuổi (KTC 95% từ 3,5 đến 6,8; $p < 0,001$)".

4.11 Tóm tắt

Chương này đã đi từ việc mô tả dữ liệu đến việc rút ra suy luận về quần thể mà dữ liệu được lấy từ đó. Mọi ước lượng đều chịu biến thiên do chọn mẫu, được định lượng bằng sai số chuẩn của nó. Một kiểm định giả thuyết đo mức độ tương thích của dữ liệu với một giả thuyết không về việc không có tác động, được tóm tắt bằng giá trị p; một khoảng tin cậy cho thấy dải các độ lớn tác động tương thích với dữ liệu và thường cung cấp nhiều thông tin hơn. Với biến kết cục liên tục ở hai nhóm độc lập, chúng ta dùng kiểm định t Welch hoặc kiểm định tổng hạng Wilcoxon; với nhiều nhóm, dùng ANOVA một yếu tố hoặc kiểm định Kruskal–Wallis, theo sau (nếu cần) là các phép so sánh từng cặp có tính đến vấn đề kiểm định bội. Với hai biến phân loại, chúng ta dùng kiểm định khi bình phương hoặc kiểm định chính xác Fisher và ước lượng hiệu số nguy cơ, nguy cơ tương đối hoặc tỷ số chênh. Với hai biến liên tục, chúng ta dùng tương quan Pearson hoặc Spearman, sau khi đã vẽ dữ liệu. Tất cả các phương pháp này đều xem xét hai biến cùng một lúc và không thể xử lý nhiễu — đó là nhiệm vụ của các mô hình hồi quy ở Chương 5.

Điểm chính

- Xác định quần thể phân tích một cách tường minh; với việc tiếp nhận điều trị, chỉ phân tích những bệnh nhân đã được chẩn đoán (`htn_diagnosed == "Yes"`, $n = 1,089$).
- Sai số chuẩn đo độ chính xác của một ước lượng và giảm theo $\sqrt{n}$; độ lệch chuẩn đo

biến thiên giữa các cá nhân.

- Giá trị p là xác suất thu được dữ liệu ít nhất cực đoan bằng dữ liệu quan sát *nếu giả thuyết không là đúng*. Nó không phải là xác suất để giả thuyết không đúng và không phải là thước đo độ lớn tác động.
- Báo cáo ước lượng kèm khoảng tin cậy 95% và giá trị p chính xác; phân biệt ý nghĩa thống kê với ý nghĩa lâm sàng; không có bằng chứng không phải là bằng chứng của sự không có.
- Đánh giá tính chuẩn bằng biểu đồ tần suất và biểu đồ Q–Q, cỡ mẫu và câu hỏi nghiên cứu, chứ không chỉ bằng giá trị p của kiểm định Shapiro–Wilk; định lý giới hạn trung tâm bảo vệ các kiểm định về trung bình khi mẫu lớn.
- Hai nhóm: `t.test()` (Welch) hoặc `wilcox.test()`. Nhiều hơn hai nhóm: `aov()` hoặc `kruskal.test()`, kèm so sánh hậu kiểm Tukey hoặc Bonferroni.
- Hai biến phân loại: `chisq.test()` (kiểm tra số đếm kỳ vọng) hoặc `fisher.test()`; báo cáo RD, RR hoặc OR kèm KTC. Khi biến kết cục phổ biến, OR cách xa 1 hơn RR.
- Tương quan (`cor.test()`, Pearson hoặc Spearman) đo mối liên quan, không phải quan hệ nhân quả hay sự phù hợp; luôn vẽ đồ thị trước.
- Các kiểm định đơn biến không thể xử lý nhiều; tỷ số chênh từ hồi quy logistic với một biến dự báo bằng tỷ số chênh của bảng 2×2, và việc thêm biến dự báo cho các ước lượng hiệu chỉnh (Chương 5).

4.12 Đọc thêm

- Kirkwood and Sterne (2003), *Essential Medical Statistics*, các chương về khoảng tin cậy, kiểm định giả thuyết, so sánh trung bình và tỷ lệ: trình bày rõ ràng và chặt chẽ mọi nội dung của chương này, được viết cho các nhà nghiên cứu y học.
- Altman (1991), *Practical Statistics for Medical Research*: cuốn sách ứng dụng kinh điển, với những hướng dẫn đặc biệt tốt về chọn kiểm định, kiểm tra giả định và trình bày kết quả.
- Greenland et al. (2016), "Statistical tests, P values, confidence intervals, and power: a guide to misinterpretations": danh sách 25 cách hiểu sai phổ biến, cần đọc trước khi viết bất kỳ phần kết quả nào.
- Wasserstein and Lazar (2016), tuyên bố của ASA về giá trị p: một tuyên bố ngắn gọn, có thẩm quyền về những gì giá trị p có thể và không thể cho bạn biết.
- Agresti (2013), *Categorical Data Analysis*: tài liệu tham khảo về bảng tiếp liên, kiểm định chính xác và các thước đo mối liên quan, dành cho người đọc muốn tìm hiểu sâu về lý thuyết.

4.13 Bài tập

Tất cả các bài tập đều dùng nhóm bệnh nhân đã được chẩn đoán, `dx <- filter(analysis_data, htn_diagnosed == "Yes")`, trừ khi có ghi chú khác. Lời giải chi tiết được trình bày trong phụ lục.

Bài tập 4.1

Nạp `Data/analysis_data.rds` và tạo quần thể phân tích `dx`.

1. Có bao nhiêu bệnh nhân trong `dx`, và bao nhiêu phần trăm trong số họ đang điều trị?
2. Tính tỷ lệ phần trăm đang điều trị trong *toàn bộ* 1.500 bệnh nhân. Giải thích trong hai câu vì sao không nên báo cáo con số này như tỷ lệ tiếp nhận điều trị.
3. Dùng `dx`, tính trung bình, độ lệch chuẩn và sai số chuẩn của điểm kiến thức. Giải thích sự khác biệt giữa độ lệch chuẩn và sai số chuẩn.

Bài tập 4.2

Đánh giá xem chỉ số khối cơ thể (`bmi`) có phân phối xấp xỉ chuẩn trong `dx` hay không.

1. Vẽ biểu đồ tần suất và biểu đồ Q–Q chuẩn của `bmi`.
2. Chạy `shapiro.test()` cho `bmi`. Giá trị `p` cho biết điều gì, và bạn nên coi trọng nó đến mức nào với cỡ mẫu này?
3. Dựa trên đánh giá của bạn, hãy chọn một kiểm định để so sánh BMI giữa bệnh nhân có và không tiếp nhận điều trị, thực hiện kiểm định và diễn giải kết quả.

Bài tập 4.3

So sánh huyết áp tâm thu (`sbp_mmhg`) giữa bệnh nhân đang điều trị và bệnh nhân không điều trị.

1. Cho biết trung bình và SD của từng nhóm.
2. Chạy kiểm định `t Welch` và báo cáo trong một câu hiệu số trung bình kèm khoảng tin cậy 95% và giá trị `p`.
3. Độ lớn của khác biệt có quan trọng về mặt lâm sàng không? Bệnh nhân được điều trị có huyết áp *cao hơn*: hãy đưa ra một lý do vì sao điều này hợp lý trong một nghiên cứu cắt ngang.

Bài tập 4.4

Huyết áp tâm thu có khác nhau giữa các nhóm BMI (`bmi_cat`: `Underweight` — thiếu cân, `Normal` — bình thường, `Overweight` — thừa cân, `Obese` — béo phì) không?

1. Vẽ biểu đồ hộp của `sbp_mmhg` theo `bmi_cat` và lập bảng trung bình và SD của từng nhóm.
2. Thực hiện ANOVA một yếu tố và đọc bảng ANOVA: số bậc tự do, thống kê `F` và giá trị `p`. Bao nhiêu bệnh nhân bị loại do giá trị khuyết?
3. Chạy kiểm định `Kruskal–Wallis` để kiểm tra lại.
4. Dùng các kiểm định `t` từng cặp có hiệu chỉnh `Bonferroni` để xác định những nhóm nào khác nhau.

Bài tập 4.5

Việc tiếp nhận điều trị có liên quan đến nơi cư trú (*residence*) không?

1. Lập bảng 2x2 và tỷ lệ phần trăm tiếp nhận điều trị theo dòng trong từng nhóm nơi cư trú.
2. Chạy kiểm định khi bình phương và kiểm tra các số đếm kỳ vọng.
3. Lấy việc cư trú ở thành thị làm "phơi nhiễm", tính hiệu số nguy cơ, nguy cơ tương đối và tỷ số chênh kèm khoảng tin cậy 95%.
4. Giải thích vì sao tỷ số chênh cách xa 1 hơn nguy cơ tương đối.

Bài tập 4.6

Quay lại với đái tháo đường và việc tiếp nhận điều trị.

1. Tính tỷ số chênh của việc tiếp nhận điều trị (có so với không có đái tháo đường) từ bảng 2x2 theo công thức ad/bc , và bằng hồi quy logistic `glm(treatment_uptake ~ diabetes, family = binomial)`. Hai kết quả có trùng nhau không?
2. So sánh chúng với tỷ số chênh do `fisher.test()` báo cáo. Vì sao nó hơi khác?
3. Vì sao khoảng tin cậy của tỷ số chênh này rộng hơn nhiều so với khoảng tin cậy của biến bảo hiểm y tế?

Bài tập 4.7

Điểm kiến thức về tăng huyết áp có liên quan đến tuổi hoặc đến khoảng cách tới cơ sở y tế không?

1. Vẽ biểu đồ phân tán của `knowledge_score` theo `age`.
2. Tính hệ số tương quan Pearson và Spearman bằng `cor.test()` và diễn giải chúng, bao gồm cả khoảng tin cậy của r Pearson.
3. Lập lại với `knowledge_score` và `distance_to_facility_km`. Hệ số nào phù hợp hơn cho biến khoảng cách, và vì sao?
4. Một đồng nghiệp viết "kiến thức không liên quan đến tuổi ($p = 0,73$), nên giáo dục sức khỏe nhắm theo nhóm tuổi là không cần thiết". Hãy nhận xét về nhận định này.

Bài tập 4.8

Kiểm định bội trong thực tế. Xét tám biến phân loại `sex`, `residence`, `education`, `occupation`, `marital_status`, `smoking`, `alcohol` và `facility`.

1. Với mỗi biến, chạy kiểm định khi bình phương về mối liên quan với `treatment_uptake` và tập hợp tám giá trị p vào một data frame (gợi ý: dùng `lapply()` hoặc `purrr::map()` và `chisq.test(table(...))$p.value`).
2. Hiệu chỉnh các giá trị p bằng `p.adjust()` theo phương pháp Bonferroni và Holm. Những mối liên quan nào vẫn nhỏ hơn 0,05?

- 3.** Giả sử cả tám giả thuyết không đều đúng và các kiểm định độc lập với nhau, xác suất có ít nhất một giá trị p nhỏ hơn 0,05 là bao nhiêu? Điều này hàm ý gì đối với một bài báo chỉ báo cáo những kết quả có ý nghĩa từ một cuộc sàng lọc như vậy?

CHƯƠNG 5

Mô hình hồi quy và báo cáo kết quả

Ở Chương 4, chúng ta đặt ra từng câu hỏi một. Việc sử dụng điều trị có phổ biến hơn ở những bệnh nhân có bảo hiểm y tế không? Bệnh nhân thành thị và nông thôn có khác nhau không? Mỗi kiểm định so sánh các nhóm được xác định bởi một biến duy nhất. Thực tế lâm sàng hiếm khi gọn gàng như vậy. Những bệnh nhân có bảo hiểm y tế có thể đồng thời trẻ hơn, có trình độ học vấn cao hơn hoặc sống gần cơ sở y tế hơn, và chính mỗi đặc điểm này lại có thể ảnh hưởng đến việc một người bị tăng huyết áp có bắt đầu điều trị hay không. Nếu muốn biết bảo hiểm có liên quan đến việc sử dụng điều trị *ngoài và vượt lên trên* các yếu tố khác này hay không, chúng ta cần một phương pháp xem xét nhiều biến cùng lúc. Phương pháp đó là hồi quy.

Hồi quy là công cụ chủ lực của nghiên cứu lâm sàng và dịch tễ học. Nó xuất hiện trong hầu hết các nghiên cứu quan sát được công bố trên các tạp chí y khoa, và là điểm đến tự nhiên của quá trình phân tích mà chúng ta đã xây dựng từ Chương 1: chúng ta đã nhập và làm sạch dữ liệu tăng huyết áp, mô tả mẫu nghiên cứu, kiểm định các giả thuyết đơn giản, và giờ đây chúng ta tập hợp các yếu tố quyết định việc sử dụng điều trị vào một mô hình duy nhất. Chương này giải thích cách các mô hình hồi quy hoạt động, cách xây dựng (fit) và đọc chúng trong R, cách kiểm tra rằng chúng hợp lý, và cách chuyển kết quả thành các bảng, hình và câu văn xuất hiện trong một bài báo khoa học. Chương kết thúc với các thực hành giúp toàn bộ phân tích có thể tái lập, để một người khác (hoặc chính bạn, một năm sau) có thể thu được chính xác những kết quả như nhau.

Mục tiêu học tập

- Giải thích ba mục đích của mô hình hồi quy (mô tả, dự báo và giải thích) và lý do mục đích định hình mô hình.
- Xây dựng và diễn giải mô hình hồi quy tuyến tính đa biến cho biến kết cục liên tục, bao gồm các hệ số, R^2 và kiểm tra phần dư.
- Chuyển đổi giữa xác suất, odds và log-odds, và giải thích vì sao hồi quy logistic mô hình hóa log-odds của một biến kết cục nhị phân.
- Xây dựng mô hình hồi quy logistic đa biến bằng `glm()`, đọc từng dòng kết quả của `summary()`, và báo cáo tỷ số chênh (odds ratio, OR) kèm khoảng tin cậy (confidence interval, CI) 95%.
- Phân biệt ước lượng thô với ước lượng hiệu chỉnh, nhận biết nhiều, và tránh "ngụy biện Bảng 2" (Table 2 fallacy).

- Xây dựng mô hình dựa trên lập luận lâm sàng thay vì chọn biến tự động, và kiểm tra số biến cố trên mỗi biến, đa cộng tuyến, tính tuyến tính, khả năng phân biệt, hiệu chuẩn và các quan sát có ảnh hưởng.
- Tạo bảng hồi quy sẵn sàng cho công bố và biểu đồ rừng (forest plot), và viết một đoạn Kết quả theo khuyến nghị STROBE.
- Tổ chức phân tích sao cho có thể tái lập từ dữ liệu thô đến báo cáo.

5.1 Vì sao cần hồi quy?

5.1.1 Từ từng biến một đến nhiều biến

Các kiểm định ở Chương 4 trả lời những câu hỏi dạng "biến kết cục có liên quan đến *biến này* không?". Một mô hình hồi quy trả lời một câu hỏi phong phú hơn: "biến kết cục liên quan đến biến này như thế nào, *khi đã biết* giá trị của các biến khác?" Mô hình làm điều này bằng cách biểu diễn giá trị kỳ vọng của biến kết cục (hoặc một phép biến đổi của nó) như một hàm của nhiều biến dự báo đồng thời. Khi đó, mỗi hệ số trong mô hình mô tả mối liên quan giữa một biến dự báo và biến kết cục trong khi các biến dự báo khác được giữ cố định. Việc "giữ cố định" này là điều mà các nhà dịch tễ học gọi là *hiệu chỉnh* (adjustment), và đó là lý do chính khiến hồi quy được sử dụng trong nghiên cứu quan sát (Vittinghoff et al. 2012; Kirkwood and Sterne 2003).

Hồi quy cũng cung cấp nhiều hơn một giá trị p. Nó cho một *ước lượng* về độ lớn của mỗi mối liên quan, kèm khoảng tin cậy mô tả độ chính xác của ước lượng đó, và có thể đưa ra dự báo cho từng bệnh nhân. Như Chương 4 đã nhấn mạnh, một ước lượng kèm khoảng tin cậy cung cấp nhiều thông tin hơn hẳn so với một tuyên bố rằng kiểm định "có ý nghĩa" (Altman 1991; Wasserstein and Lazar 2016).

5.1.2 Mô tả, dự báo và giải thích

Trước khi xây dựng bất kỳ mô hình nào, bạn cần biết rõ mô hình đó *dùng để làm gì*, vì mục đích quyết định những biến nào cần đưa vào và cách đánh giá kết quả (Vittinghoff et al. 2012; Harrell 2015).

- **Mô tả.** Mục tiêu là tóm tắt cách một biến kết cục thay đổi theo nhiều đặc điểm trong một quần thể, ví dụ tỷ lệ sử dụng điều trị khác nhau như thế nào theo tuổi, giới và nơi cư trú. Mô hình là một bản tóm tắt đa biến gọn gàng; không đưa ra kết luận nhân quả.
- **Dự báo.** Mục tiêu là ước lượng biến kết cục cho một cá nhân mới chính xác nhất có thể, chẳng hạn xác suất một bệnh nhân mới được chẩn đoán sẽ bắt đầu điều trị. Bất kỳ biến nào cải thiện độ chính xác dự báo đều được chào đón, dù nó có phải là nguyên nhân hay không. Mô hình được đánh giá bằng khả năng phân biệt và hiệu chuẩn trên dữ liệu *mới*, và cần hết sức cẩn thận để tránh quá khớp (overfitting) (Harrell 2015).
- **Giải thích (căn nguyên).** Mục tiêu là ước lượng tác động của một phơi nhiễm cụ thể lên biến kết cục, ví dụ tác động của bảo hiểm y tế lên việc sử dụng điều trị. Các biến được đưa vào vì chúng là *yếu tố gây nhiễu* của mối quan hệ phơi nhiễm–kết cục đó, và việc lựa chọn được định hướng bởi kiến thức chuyên môn, thường được tóm tắt trong một sơ đồ nhân quả (Rothman et al. 2008; Greenland et al. 1999).

Nghiên cứu tình huống của chúng ta, *Các yếu tố quyết định việc sử dụng điều trị tăng huyết áp ở người trưởng thành đến khám tại các cơ sở chăm sóc sức khỏe ban đầu*, nằm giữa mô tả và giải thích. Chúng ta muốn biết những đặc điểm nào của bệnh nhân và của khả năng tiếp cận có liên quan độc lập với việc sử dụng điều trị, để có thể nhắm mục tiêu các dịch vụ. Vì vậy, chương này xây dựng một mô hình đa biến duy nhất, được xác định trước, và diễn giải các hệ số của nó như những *mối liên quan đã hiệu chỉnh*. Chúng ta sẽ nhiều lần quay lại mối nguy hiểm của việc đọc chúng như những tác động nhân quả.

Thực hành tốt

Hãy ghi lại mục đích của mô hình và danh sách các biến bạn sẽ đưa vào trong kế hoạch phân tích *trước khi* xem dữ liệu biến kết cục. Một mô hình dự báo, một mô hình mô tả và một mô hình căn nguyên được xây dựng từ cùng một bộ dữ liệu hoàn toàn có thể trông khá khác nhau một cách chính đáng.

5.1.3 Một họ các mô hình hồi quy

Tất cả các mô hình trong chương này có chung một cấu trúc: một *bộ dự báo tuyến tính* (linear predictor), tức là tổng có trọng số của các biến giải thích,

$$\eta = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_k x_k,$$

được liên kết với giá trị kỳ vọng của biến kết cục thông qua một hàm được chọn cho phù hợp với loại biến kết cục. Đây là các *mô hình tuyến tính tổng quát* (generalised linear models, GLM) (Agresti 2013). Loại biến kết cục quyết định mô hình, như được tóm tắt dưới đây.

Bảng 5.1: Chọn mô hình hồi quy theo loại biến kết cục.

Loại biến kết cục	Ví dụ trong nghiên cứu	Mô hình	Thước đo tác động	Hàm R
Liên tục	Huyết áp tâm thu	Tuyến tính	Hiệu số trung bình	lm()
Nhị phân	Sử dụng điều trị (Yes/No)	Logistic	Tỷ số chênh	glm(family = binomial)
Đếm	Số bệnh đồng mắc	Poisson	Tỷ số tỷ suất	glm(family = poisson)
Thời gian đến biến cố	Thời gian đến khi bắt đầu điều trị	Cox	Tỷ số nguy hại	survival::coxph()

Chương này trình bày chi tiết hai dòng đầu tiên. Một khi bạn đã hiểu hồi quy tuyến tính và hồi quy logistic, các mô hình khác đều theo cùng một logic.

5.2 Chuẩn bị phân tích

Như ở mọi chương, chúng ta bắt đầu một phiên R mới bằng cách nạp các gói và bộ dữ liệu phân tích đã làm sạch được tạo ở Chương 2.

```
library(tidyverse) # dplyr, ggplot2, tidyr, ...
library(broom)    # tidy() và augment() cho các đối tượng mô hình
```

R

```
library(gtsummary) # bảng hồi quy sẵn sàng cho công bố
library(car)       # vif() để đánh giá đa cộng tuyến
library(pROC)      # đường cong ROC và AUC
library(patchwork) # ghép các khung đồ thị ggplot2
library(scales)    # định dạng trục
library(knitr)     # bảng kable()
```

```
analysis_data <- readRDS("Data/analysis_data.rds")
```

Biến kết cục chính, `treatment_uptake`, chỉ có ý nghĩa đối với những người đã biết mình bị tăng huyết áp: một người chưa bao giờ được chẩn đoán thì không thể "tiếp nhận" điều trị. Vì vậy, quần thể phân tích là những bệnh nhân có `htn_diagnosed == "Yes"`.

```
dx <- analysis_data |>
  filter(htn_diagnosed == "Yes") |>
  # education được lưu dưới dạng factor CÓ THỨ TỰ (None < Primary < ...).
  # Khi hồi quy, ta chuyển thành factor thông thường để mỗi mức được
  # so sánh với nhóm tham chiếu "None" (giải thích bên dưới).
  mutate(education = factor(education, ordered = FALSE))

nrow(dx) # cỡ quần thể phân tích
```

```
#> [1] 1089
```

```
table(dx$treatment_uptake) # phân bố của biến kết cục
```

```
#>
#> No Yes
#> 581 508
```

```
levels(dx$treatment_uptake) # mức đầu tiên = tham chiếu ("No")
```

```
#> [1] "No" "Yes"
```

Trong số 1.089 bệnh nhân đã được chẩn đoán, 508 người (46,6%) đang điều trị thuốc hạ huyết áp. Mức đầu tiên của factor biến kết cục là "No" (không), nên các mô hình dưới đây ước lượng odds của việc *sử dụng điều trị* ("Yes", có), là biến cố quan tâm. Nếu thứ tự các mức bị đảo ngược, mọi tỷ số chênh trong chương này sẽ bị nghịch đảo.

Lỗi thường gặp

Factor có thứ tự (ordered factor) thuận tiện cho bảng và đồ thị, nhưng trong hồi quy R mã hóa chúng bằng *tương phản đa thức trực giao* (orthogonal polynomial contrasts). Khi đó kết quả chứa các số hạng tên là `education.L`, `education.Q` và `education.C` (xu hướng tuyến tính, bậc hai và bậc ba) thay vì một phép so sánh cho mỗi mức. Tỷ số chênh của chúng không phải là "Primary so với None" hay "cho mỗi mức học vấn", và rất dễ bị báo cáo sai. Trừ khi bạn thực sự muốn kiểm định xu hướng, hãy chuyển factor có thứ tự bằng `factor(x, ordered = FALSE)` trước khi xây dựng mô hình, như chúng ta đã làm ở trên.

5.3 Hồi quy tuyến tính cho biến kết cục liên tục

Hồi quy tuyến tính là mô hình hồi quy đơn giản nhất và là nền tảng cho mọi mô hình khác, vì vậy chúng ta bắt đầu với nó, sử dụng huyết áp tâm thu (systolic blood pressure, SBP) làm biến kết cục. Vì SBP được đo ở tất cả mọi người, chúng ta dùng toàn bộ mẫu 1.500 người trưởng thành cho mục này.

5.3.1 Mô hình hồi quy tuyến tính đơn

Với một biến dự báo x (chẳng hạn chỉ số khối cơ thể, BMI), mô hình hồi quy tuyến tính đơn cho bệnh nhân i là

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, \sigma^2).$$

Ở đây β_0 là *hệ số chặn* (intercept; trung bình của y khi $x = 0$), β_1 là *hệ số góc* (slope; mức thay đổi của trung bình y khi x tăng một đơn vị), và ε_i là sai số ngẫu nhiên: phần huyết áp của bệnh nhân i không được giải thích bởi BMI. Các sai số được giả định là độc lập và có phân phối chuẩn với phương sai không đổi σ^2 .

Các hệ số được ước lượng bằng phương pháp *bình phương tối thiểu thông thường* (ordinary least squares, OLS): chúng ta chọn $\hat{\beta}_0$ và $\hat{\beta}_1$ sao cho tổng bình phương các khoảng cách theo chiều dọc giữa các điểm quan sát và đường thẳng ước lượng là nhỏ nhất,

$$\text{minimise } \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2,$$

từ đó cho nghiệm dạng tường minh

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}.$$

Do đó hệ số góc có liên hệ chặt chẽ với hệ số tương quan Pearson ở Chương 4: $\hat{\beta}_1 = r s_y / s_x$ (Altman 1991; Bland 2015).

```
# Hồi quy tuyến tính đơn: SBP (mmHg) theo BMI (kg/m^2)
lm_simple <- lm(sbp_mmhg ~ bmi, data = analysis_data)
coef(lm_simple)
```

```
#> (Intercept)      bmi
#>    101.467    1.435
```

Đường thẳng ước lượng là $\widehat{SBP} = 101.5 + 1.44 \times BMI$. Mỗi kg/m^2 BMI tăng thêm có liên quan đến SBP trung bình cao hơn khoảng 1.44 mmHg. Hệ số chặn là SBP dự báo tại BMI bằng không, một giá trị bất khả về mặt sinh học; nó cần thiết để định vị đường thẳng nhưng không có ý nghĩa lâm sàng. Điều này rất phổ biến, và đó là một lý do khiến một số nhà phân tích *định tâm* (centre) các biến dự báo liên tục (trừ đi một giá trị điển hình như trung bình) trước khi xây dựng mô hình.

5.3.2 Hồi quy tuyến tính đa biến

Huyết áp tăng theo tuổi, và BMI cũng có thể khác nhau theo tuổi, vì vậy chúng ta thêm tuổi vào mô hình. Với k biến dự báo, mô hình trở thành

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki} + \varepsilon_i,$$

hoặc, dưới dạng ma trận, $\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$, với nghiệm bình phương tối thiểu $\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$. Bạn sẽ không bao giờ phải tính tay công thức này, nhưng nó làm rõ một điểm: mỗi hệ số được ước lượng bằng cách sử dụng tất cả các biến dự báo cùng nhau, nên giá trị của nó phụ thuộc vào những biến nào khác có trong mô hình. Mỗi β_j là hiệu số kỳ vọng của y giữa hai người khác nhau một đơn vị về x_j nhưng có *cùng giá trị* ở tất cả các biến dự báo khác (Vittinghoff et al. 2012).

```
lm_sbp <- lm(sbp_mmhg ~ age + bmi, data = analysis_data)
summary(lm_sbp)
```

```
#>
#> Call:
#> lm(formula = sbp_mmhg ~ age + bmi, data = analysis_data)
#>
#> Residuals:
#>      Min       1Q   Median       3Q      Max
#> -53.66 -12.69  -0.51   12.50   55.50
#>
#> Coefficients:
#>              Estimate Std. Error t value Pr(>|t|)
#> (Intercept)  87.4657      3.1789   27.51 < 2e-16 ***
#> age           0.2593      0.0336    7.71 2.3e-14 ***
#> bmi           1.4510      0.0975   14.87 < 2e-16 ***
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> Residual standard error: 18.1 on 1446 degrees of freedom
#> (51 observations deleted due to missingness)
#> Multiple R-squared:  0.161,    Adjusted R-squared:  0.159
#> F-statistic: 138 on 2 and 1446 DF,  p-value: <2e-16
```

Chúng ta hãy đọc kết quả này từ trên xuống dưới.

- **Call** nhắc lại công thức mô hình và dữ liệu, điều này hữu ích khi bạn đã xây dựng nhiều mô hình.
- **Residuals** tóm tắt các hiệu số giữa SBP quan sát và SBP ước lượng. Trung vị gần bằng không và các tứ phân vị gần như đối xứng (khoảng ± 12.6 mmHg), đúng như kỳ vọng nếu các sai số đối xứng quanh không.
- **Coefficients** là phần cốt lõi của kết quả. Với mỗi số hạng có ước lượng, sai số chuẩn (standard error, SE), thống kê t (ước lượng chia cho SE) và giá trị p hai phía cho giả thuyết không rằng hệ số thực bằng không.
 - (Intercept) 87,5 mmHg là SBP dự báo cho một người 0 tuổi có BMI bằng 0, một lần nữa không có ý nghĩa lâm sàng.

- age 0,26: khi giữ BMI cố định, mỗi năm tuổi tăng thêm có liên quan đến SBP trung bình cao hơn 0,26 mmHg; qua mười năm là khoảng 2,6 mmHg.
- bmi 1,45: ở những người cùng tuổi, mỗi kg/m² tăng thêm có liên quan đến SBP trung bình cao hơn 1,45 mmHg; chênh lệch 5 kg/m² tương ứng với khoảng 7,3 mmHg.
- **Residual standard error** (sai số chuẩn của phần dư, 18,1 mmHg) ước lượng σ , khoảng cách điển hình từ một quan sát đến giá trị ước lượng của nó. Giá trị này lớn so với các hệ số: tuổi và BMI chỉ giải thích một phần sự biến thiên của huyết áp.
- (51 observations deleted due to missingness) (51 quan sát bị loại do dữ liệu khuyết) nhắc chúng ta rằng `lm()` âm thầm loại bỏ mọi dòng có giá trị khuyết ở bất kỳ biến nào trong mô hình. Mô hình được xây dựng trên 1.449 người, không phải 1.500.
- **Multiple R-squared** (0,16) là tỷ lệ phương sai của SBP được mô hình giải thích, $R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2}$. R^2 **hiệu chỉnh** (adjusted) áp dụng một mức phạt nhỏ cho số lượng biến dự báo.
- **F-statistic** kiểm định giả thuyết không rằng *tất cả* các hệ số góc đều bằng không. Với $p < 2.2 \times 10^{-16}$, chúng ta kết luận rằng tuổi và BMI cùng nhau giải thích được một phần biến thiên của SBP.

Diễn giải lâm sàng

R^2 bằng 0,16 không có nghĩa là mô hình vô dụng. Trong một phân tích giải thích, chúng ta quan tâm đến các *hệ số*: chênh lệch khoảng 7 mmHg về SBP trung bình cho mỗi 5 kg/m² BMI, độc lập với tuổi, là quan trọng về mặt lâm sàng ở cấp độ quần thể. R^2 thấp chỉ cho biết huyết áp của từng cá nhân phụ thuộc vào nhiều yếu tố khác (di truyền, lượng muối ăn vào, thuốc, sai số đo lường) không có trong mô hình.

Để dễ trích dẫn các hệ số hơn, chúng ta có thể yêu cầu khoảng tin cậy (KTC) và đổi thang đo của tuổi sang một đơn vị có ý nghĩa hơn.

```
tidy(lm_sbp, conf.int = TRUE) |>
  select(term, estimate, conf.low, conf.high, p.value) |>
  mutate(across(estimate:conf.high, \(x) round(x, 3)),
         p.value = signif(p.value, 2))
```

```
#> # A tibble: 3 × 5
#>   term      estimate conf.low conf.high  p.value
#>   <chr>      <dbl>    <dbl>    <dbl>    <dbl>
#> 1 (Intercept)  87.5      81.2     93.7  2.20e-134
#> 2 age          0.259     0.193     0.325  2.3 e- 14
#> 3 bmi          1.45      1.26     1.64  1.10e- 46
```

```
# Cho mỗi 10 năm tuổi: nhân hệ số của tuổi và KTC của nó với 10
age10 <- 10 * c(coef(lm_sbp)["age"], confint(lm_sbp)["age", ])
round(age10, 2)
```

```
#>   age  2.5 % 97.5 %
#> 2.59  1.93  3.25
```

Chúng ta sẽ báo cáo: "Mỗi 10 năm tuổi tăng thêm có liên quan đến SBP trung bình cao hơn 2.6 mmHg (KTC 95% 1.9 đến 3.3), sau khi hiệu chỉnh theo BMI."

5.3.3 Các giả định và kiểm tra phần dư

Các suy luận từ một mô hình tuyến tính (sai số chuẩn, khoảng tin cậy, giá trị p) dựa trên bốn giả định, dễ nhớ theo chữ viết tắt tiếng Anh **LINE** (Vittinghoff et al. 2012; Kirkwood and Sterne 2003):

1. **Linearity** (tính tuyến tính): trung bình của y thay đổi tuyến tính theo mỗi biến dự báo liên tục (khi đã biết các biến khác).
2. **Independence** (tính độc lập): sai số của các bệnh nhân khác nhau độc lập với nhau. Đây là một đặc tính của thiết kế nghiên cứu; các phép đo lặp lại trên cùng một bệnh nhân, hoặc bệnh nhân được nhóm theo cơ sở y tế, có thể vi phạm giả định này.
3. **Normality** (tính chuẩn): các sai số có phân phối xấp xỉ chuẩn. Với mẫu lớn, định lý giới hạn trung tâm khiến các hệ số có phân phối xấp xỉ chuẩn ngay cả khi sai số không chuẩn, nên giả định này quan trọng nhất với mẫu nhỏ và với khoảng dự báo.
4. **Equal variance** (phương sai bằng nhau, homoscedasticity): độ phân tán của các sai số không thay đổi theo giá trị ước lượng.

Chúng ta kiểm tra các giả định này bằng *phần dư* (residuals), $e_i = y_i - \hat{y}_i$. Có hai đồ thị tiêu chuẩn: phần dư theo giá trị ước lượng (để kiểm tra tính tuyến tính và phương sai bằng nhau) và đồ thị Q-Q chuẩn của phần dư (để kiểm tra tính chuẩn). `broom::augment()` trả về các giá trị ước lượng và phần dư trong một khung dữ liệu thuận tiện cho `ggplot2`.


```
lm_aug <- augment(lm_sbp) # mỗi dòng = một bệnh nhân trong mô hình

p_resfit <- ggplot(lm_aug, aes(x = .fitted, y = .resid)) +
  geom_point(alpha = 0.25, colour = "#0D7377") +
  geom_hline(yintercept = 0, linetype = "dashed") +
  geom_smooth(method = "loess", se = FALSE, colour = "#E07A1F") +
  labs(title = "Phần dư theo giá trị ước lượng",
       x = "SBP ước lượng (mmHg)", y = "Phần dư (mmHg)")

p_qq <- ggplot(lm_aug, aes(sample = .std.resid)) +
  stat_qq(alpha = 0.25, colour = "#0D7377") +
  stat_qq_line(linetype = "dashed") +
  labs(title = "Đồ thị Q-Q chuẩn",
       x = "Phân vị lý thuyết", y = "Phần dư chuẩn hóa")

p_resfit + p_qq
```

Ở khung bên trái, các điểm tạo thành một dải nằm ngang có độ rộng gần như không đổi, tập trung quanh không, và đường cong làm trơn gần như phẳng, ngoại trừ một chút đi lên ở các giá trị ước lượng cao nhất, nơi có ít bệnh nhân và đường làm trơn không ổn định. Không có dấu hiệu thuyết phục nào về độ cong (điều sẽ gợi ý thiếu một số hạng phi tuyến) hay hình phễu (điều sẽ gợi ý phương sai không bằng nhau). Ở khung bên phải, các điểm bám sát đường tham chiếu, chỉ lệch nhẹ ở hai đuôi. Các giả định có vẻ hợp lý.



Hình 5.1: Chẩn đoán phần dư cho mô hình hồi quy tuyến tính của huyết áp tâm thu theo tuổi và BMI. Trái: phần dư theo giá trị ước lượng, kèm đường cong làm trơn; phải: đồ thị Q-Q chuẩn của phần dư.

Thực hành tốt

Hãy nhìn đồ thị phần dư, đừng kiểm định chúng. Các kiểm định chính thức về tính chuẩn bác bỏ những sai lệch không đáng kể ở mẫu lớn và bỏ sót những sai lệch quan trọng ở mẫu nhỏ (Altman and Bland 1995b). Nếu đồ thị cho thấy một dạng cong, hãy cân nhắc thêm một số hạng phi tuyến (ví dụ bậc hai hoặc spline của tuổi); nếu nó cho thấy hình phễu, hãy cân nhắc biến đổi biến kết cục hoặc dùng sai số chuẩn vững (robust standard errors).

5.4 Biến kết cục nhị phân: xác suất, odds và log-odds

Biến kết cục chính của chúng ta, việc sử dụng điều trị, là biến nhị phân: mỗi bệnh nhân hoặc đang điều trị ($y = 1$) hoặc không ($y = 0$). Hồi quy tuyến tính không phù hợp ở đây. Một đường thẳng theo x có thể dự báo "xác suất" nhỏ hơn 0 hoặc lớn hơn 1, phương sai của một biến nhị phân phụ thuộc vào trung bình của nó (nên giả định phương sai bằng nhau không thỏa mãn), và các sai số không thể có phân phối chuẩn. Chúng ta cần một thang đo mà trên đó mô hình tuyến tính có ý nghĩa. Thang đo đó là log-odds.

5.4.1 Ba cách biểu diễn cùng một nguy cơ

Gọi p là xác suất một bệnh nhân sử dụng điều trị. Odds của việc sử dụng điều trị là xác suất sử dụng chia cho xác suất không sử dụng,

$$\text{odds} = \frac{p}{1-p}, \quad \text{and conversely} \quad p = \frac{\text{odds}}{1 + \text{odds}}.$$

Odds quen thuộc trong cá cược: odds bằng 3 ("3 ăn 1") nghĩa là khả năng biến cố xảy ra gấp ba lần khả năng không xảy ra, tương ứng với xác suất $3/4 = 0.75$. Trong khi xác suất bị giới hạn trong $[0, 1]$, odds nằm trong khoảng từ 0 đến vô cùng. Lấy logarit tự nhiên ta được *log-odds* hay *logit*,

$$\text{logit}(p) = \log\left(\frac{p}{1-p}\right),$$

có giá trị trải trên toàn bộ trục số thực, từ $-\infty$ đến $+\infty$, và đối xứng quanh không: xác suất 0,5 có odds bằng 1 và log-odds bằng 0.

Bảng 5.2: Cùng một nguy cơ được biểu diễn dưới dạng xác suất, odds và log-odds.

Xác suất p	Odds $p/(1-p)$	Log-odds	Diễn giải
0.10	0.11	-2.20	1 lần thành công trên 9 lần thất bại
0.25	0.33	-1.10	1 trên 3
0.50	1.00	0.00	Khả năng ngang nhau
0.75	3.00	1.10	3 trên 1
0.90	9.00	2.20	9 trên 1

5.4.2 Tỷ số chênh

Để so sánh hai nhóm, chúng ta lấy tỷ số odds của chúng. Nếu p_1 là xác suất sử dụng điều trị ở bệnh nhân có bảo hiểm và p_0 ở bệnh nhân không có bảo hiểm, thì *tỷ số chênh* (odds ratio, OR) là

$$\text{OR} = \frac{p_1/(1-p_1)}{p_0/(1-p_0)}.$$

OR bằng 1 nghĩa là không có mối liên quan; lớn hơn 1 nghĩa là odds của biến kết cục cao hơn ở nhóm thứ nhất; nhỏ hơn 1 nghĩa là odds thấp hơn (Bland and Altman 2000). Chúng ta hãy tính tay OR cho bảo hiểm y tế.

```
tab_ins <- table(Insurance = dx$health_insurance,
                 Uptake    = dx$treatment_uptake)
tab_ins
```

```
#>      Uptake
#> Insurance No Yes
#>      No  419 306
#>      Yes  162 202
```

```
# Xác suất, odds và log-odds của việc sử dụng điều trị ở mỗi nhóm bảo hiểm
ins_summary <- dx |>
  group_by(health_insurance) |>
  summarise(n = n(),
            p_uptake = mean(treatment_uptake == "Yes")) |>
  mutate(odds = p_uptake / (1 - p_uptake),
         log_odds = log(odds))
kable(ins_summary, digits = 3,
      caption = paste("Sử dụng điều trị theo tình trạng bảo hiểm y tế",
                      "(bệnh nhân đã được chẩn đoán)."))
```

Bảng 5.3: Sử dụng điều trị theo tình trạng bảo hiểm y tế (bệnh nhân đã được chẩn đoán).

health_insurance	n	p_uptake	odds	log_odds
No	725	0.422	0.730	-0.314
Yes	364	0.555	1.247	0.221

```
# Tỷ số chênh thô: odds ở nhóm có bảo hiểm / odds ở nhóm không có bảo hiểm
or_ins <- ins_summary$odds[2] / ins_summary$odds[1]
round(or_ins, 2)
```

```
#> [1] 1.71
```

Trong số bệnh nhân không có bảo hiểm, 42.2% đang điều trị (odds 0.73); trong số bệnh nhân có bảo hiểm, tỷ lệ này là 55.5% (odds 1.25). Odds sử dụng điều trị ở nhóm có bảo hiểm cao gấp 1.71 lần. Hãy chú ý cột cuối cùng của bảng: *hiệu số log-odds*, $0.221 - (-0.314) = 0.535$, chính là logarit của tỷ số chênh. Đây là chìa khóa của hồi quy logistic: một hiệu số trên thang log-odds là một log tỷ số chênh, và lấy hàm mũ của nó cho ta tỷ số chênh.

5.4.3 Tỷ số chênh so với nguy cơ tương đối

Các bác sĩ lâm sàng thường suy nghĩ theo nguy cơ, và *nguy cơ tương đối* (relative risk, hay tỷ số nguy cơ, risk ratio, RR) p_1/p_0 là thước đo trực quan hơn. Ở đây RR là $0.555 / 0.422 = 1.31$, nhỏ hơn đáng kể so với OR là 1.71. Hai thước đo này chỉ gần nhau khi biến kết cục hiếm gặp (chẳng hạn dưới 10%) ở cả hai nhóm, vì khi đó $1 - p \approx 1$ và odds xấp xỉ nguy cơ (Bland and Altman 2000; Rothman et al. 2008). Khi biến kết cục phổ biến, như ở đây (gần một nửa số bệnh nhân đang điều trị), OR luôn cách xa 1 hơn RR.

Zhang and Yu (1998) đã đề xuất một cách chuyển đổi đơn giản từ OR sang RR xấp xỉ, khi biết nguy cơ p_0 ở nhóm tham chiếu:

$$RR \approx \frac{OR}{(1 - p_0) + p_0 \times OR}$$

Với $p_0 = 0.422$ và $OR = 1.71$, công thức cho kết quả 1.31, tái tạo chính xác RR thô. Với các tỷ số chênh hiệu chỉnh, phép chuyển đổi này chỉ mang tính xấp xỉ, và các phương pháp khác (như hồi quy log-binomial hoặc hồi quy Poisson với sai số chuẩn vững) được ưu tiên nếu mục tiêu là RR hiệu chỉnh.

Lỗi thường gặp

Đừng mô tả tỷ số chênh bằng 2,0 là "nguy cơ gấp đôi" hay "khả năng gấp đôi" khi biến kết cục phổ biến. Với tỷ lệ sử dụng điều trị khoảng 40% ở nhóm tham chiếu, OR bằng 2,0 chỉ tương ứng với tỷ số nguy cơ khoảng 1,4. Hãy nói "odds gấp đôi", và nếu người đọc cần nguy cơ, hãy báo cáo thêm xác suất dự báo hoặc tỷ số nguy cơ.

Vậy thì tại sao chúng ta lại dùng tỷ số chênh? Có ba lý do chính đáng. Thứ nhất, mô hình logistic làm cơ sở cho chúng ta luôn cho ra các xác suất hợp lệ nằm giữa 0 và 1. Thứ hai, OR có tính đối xứng: OR của việc sử dụng điều trị là nghịch đảo của OR của việc không sử dụng điều trị, điều không đúng với RR. Thứ ba, OR có thể được ước lượng từ các nghiên cứu bệnh-chứng, nơi

không thể ước lượng nguy cơ (Rothman et al. 2008; Hosmer et al. 2013).

5.5 Mô hình hồi quy logistic

5.5.1 Phương trình của mô hình

Hồi quy logistic mô hình hóa log-odds của biến kết cục như một hàm tuyến tính của các biến dự báo (Hosmer et al. 2013; Agresti 2013):

$$\text{logit}(p_i) = \log\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_k x_{ki},$$

trong đó $p_i = \Pr(y_i = 1 \mid x_{1i}, \dots, x_{ki})$ là xác suất sử dụng điều trị của bệnh nhân i . Giải phương trình theo p_i ta được hàm logistic,

$$p_i = \frac{\exp(\beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki})}{1 + \exp(\beta_0 + \beta_1 x_{1i} + \dots + \beta_k x_{ki})},$$

một đường cong hình chữ S luôn nằm giữa 0 và 1. Phương trình không có số hạng sai số: tính ngẫu nhiên nằm ở chính biến kết cục, được giả định tuân theo phân phối Bernoulli với xác suất p_i .

Hình dưới đây cho thấy hai bộ mặt của mô hình với một biến dự báo duy nhất là tuổi. Trên thang log-odds (bên trái), mối quan hệ là một đường thẳng; trên thang xác suất (bên phải), cùng mô hình đó là một đường cong hình chữ S thoải thoải.

```


glm_age <- glm(treatment_uptake ~ age, data = dx, family = binomial)

# Dự báo trên một khoảng tuổi rộng, theo cả hai thang đo
age_grid <- tibble(age = seq(15, 100, by = 1))
age_grid <- age_grid |>
  mutate(log_odds = predict(glm_age, newdata = age_grid, type = "link"),
         prob = predict(glm_age, newdata = age_grid, type = "response"))

p_link <- ggplot(age_grid, aes(age, log_odds)) +
  geom_line(linewidth = 1, colour = "#0D7377") +
  geom_hline(yintercept = 0, linetype = "dashed", colour = "grey50") +
  labs(title = "Thang log-odds", x = "Tuổi (năm)",
       y = "Log-odds sử dụng điều trị")

p_prob <- ggplot(age_grid, aes(age, prob)) +
  geom_line(linewidth = 1, colour = "#0D7377") +
  geom_hline(yintercept = 0.5, linetype = "dashed", colour = "grey50") +
  scale_y_continuous(labels = percent, limits = c(0, 1)) +
  labs(title = "Thang xác suất", x = "Tuổi (năm)",
       y = "Xác suất sử dụng điều trị")

p_link + p_prob
  
```



Hình 5.2: Mô hình hồi quy logistic của việc sử dụng điều trị theo tuổi, biểu diễn trên thang log-odds (trái), nơi mô hình là tuyến tính, và trên thang xác suất (phải), nơi mô hình có hình chữ S.

5.5.2 Ước lượng bằng hợp lý cực đại

Phương pháp bình phương tối thiểu không phù hợp với biến kết cục nhị phân. Thay vào đó, các hệ số được ước lượng bằng phương pháp *hợp lý cực đại* (maximum likelihood): chúng ta chọn các giá trị của β làm cho dữ liệu quan sát được có khả năng xảy ra cao nhất. Với bệnh nhân i , xác suất của kết cục quan sát được là p_i nếu $y_i = 1$ và $1 - p_i$ nếu $y_i = 0$, có thể viết gọn là $p_i^{y_i} (1 - p_i)^{1-y_i}$. Giả sử các bệnh nhân độc lập, hàm hợp lý (likelihood) là tích trên tất cả bệnh nhân, và làm việc với logarit của nó sẽ dễ dàng hơn:

$$\ell(\beta) = \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)],$$

trong đó mỗi p_i phụ thuộc vào β thông qua hàm logistic. Không có nghiệm dạng tường minh; R cực đại hóa ℓ bằng phương pháp số với một thuật toán gọi là *bình phương tối thiểu có trọng số lặp lại* (iteratively reweighted least squares, còn gọi là Fisher scoring), thường hội tụ sau một vài vòng lặp (Agresti 2013; Hosmer et al. 2013).

Hai đại lượng được suy ra từ hàm hợp lý xuất hiện trong kết quả của R và được dùng để kiểm định.

- **Độ lệch** (deviance) của một mô hình là $D = -2\ell(\hat{\beta})$ (so với một mô hình bão hòa khớp hoàn hảo mọi quan sát). Độ lệch càng nhỏ nghĩa là mô hình càng khớp tốt. **Độ lệch rỗng** (null deviance) là độ lệch của mô hình chỉ có hệ số chặn; **độ lệch phần dư** (residual deviance) là độ lệch của mô hình đã xây dựng.
- **Kiểm định tỷ số hợp lý** (likelihood-ratio test, LR) so sánh hai mô hình *lồng nhau* (nested), trong đó mô hình nhỏ hơn là một trường hợp đặc biệt của mô hình lớn hơn. Hiệu số độ lệch, $D_{\text{small}} - D_{\text{large}}$, tuân theo xấp xỉ phân phối χ^2 với số bậc tự do bằng số tham số bổ sung trong mô hình lớn hơn.

Mỗi hệ số riêng lẻ cũng đi kèm với một **kiểm định Wald**, $z = \hat{\beta}_j / \text{SE}(\hat{\beta}_j)$, được so sánh với phân phối chuẩn tắc. Kiểm định Wald và kiểm định LR thường cho kết quả thống nhất ở mẫu

lớn; khi chúng khác nhau (mẫu nhỏ, các nhóm thưa, tác động rất lớn), kiểm định LR đáng tin cậy hơn (Hosmer et al. 2013; Agresti 2013).

5.5.3 Diễn giải các hệ số dưới dạng tỷ số chênh

Xét hai bệnh nhân giống hệt nhau ở mọi biến dự báo ngoại trừ x_1 , mà ở người thứ hai cao hơn một đơn vị. Trừ hai bộ dự báo tuyến tính của họ cho nhau, mọi số hạng đều triệt tiêu trừ một:

$$\text{logit}(p_{\text{second}}) - \text{logit}(p_{\text{first}}) = \beta_1.$$

Một hiệu số log-odds là logarit của một tỷ số chênh, do đó

$$\text{OR}_{x_1} = \exp(\beta_1).$$

Đây là kết quả trung tâm cho việc diễn giải (Hosmer et al. 2013): $\exp(\beta_j)$ là **tỷ số chênh ứng với mức tăng một đơn vị của x_j , khi giữ cố định các biến dự báo khác**. Vì mô hình tuyến tính trên thang log-odds, OR này là như nhau bất kể giá trị xuất phát của x_j và bất kể giá trị của các biến dự báo khác (trừ khi có số hạng tương tác; xem Mục 5.7).

Cách định nghĩa "một đơn vị" phụ thuộc vào loại biến dự báo.

- **Biến dự báo nhị phân** (ví dụ đái tháo đường, mã hóa No = 0, Yes = 1). $\exp(\beta)$ là OR so sánh bệnh nhân có đái tháo đường với bệnh nhân không có, là nhóm tham chiếu.
- **Biến dự báo phân loại có nhiều mức** (ví dụ học vấn: None, Primary, Secondary, Tertiary — không đi học, tiểu học, trung học, sau trung học). R tạo một biến chỉ thị ("biến giả", dummy) cho mỗi mức không phải tham chiếu. Mỗi $\exp(\beta)$ so sánh mức đó với mức tham chiếu (None), chứ không phải với mức ngay bên dưới.
- **Biến dự báo liên tục** (ví dụ tuổi tính bằng năm). $\exp(\beta)$ là OR cho mỗi đơn vị tăng (mỗi năm). Chênh lệch một năm hiếm khi đáng quan tâm về mặt lâm sàng, nên chúng ta thường báo cáo OR cho một mức tăng c có ý nghĩa, chẳng hạn 10 năm:

$$\text{OR}_{c \text{ units}} = \exp(c \beta) = [\exp(\beta)]^c,$$

với khoảng tin cậy $\exp(c \hat{\beta} \pm 1.96 c \text{SE}(\hat{\beta}))$. Lưu ý rằng OR cho 10 năm là OR mỗi năm lũy thừa 10, chứ không phải nhân với 10.

5.5.4 Các giả định của hồi quy logistic

Hồi quy logistic đòi hỏi ít giả định hơn hồi quy tuyến tính, nhưng các giả định đó không hề tầm thường (Hosmer et al. 2013; Vittinghoff et al. 2012):

1. **Hàm liên kết đúng và tính tuyến tính trên thang logit.** Mỗi biến dự báo liên tục có quan hệ tuyến tính với *log-odds* của biến kết cục (không phải với xác suất). Có thể kiểm tra điều này bằng cách thêm các số hạng phi tuyến.

2. **Tính độc lập.** Kết cục của các bệnh nhân khác nhau là độc lập với nhau khi đã biết các biến dự báo. Việc bệnh nhân tập trung theo cơ sở y tế là một khả năng vi phạm mà chúng ta sẽ thảo luận ở Mục 5.8.
3. **Không có tách biệt hoàn toàn** (perfect separation). Không có biến dự báo nào (hoặc tổ hợp biến nào) dự báo hoàn hảo biến kết cục. Chẳng hạn, nếu mọi bệnh nhân đái tháo đường đều đang điều trị, ước lượng hợp lý cực đại của hệ số đái tháo đường sẽ là vô hạn; R cảnh báo "fitted probabilities numerically 0 or 1 occurred" (xuất hiện xác suất ước lượng bằng 0 hoặc 1 về mặt số học) và báo cáo một hệ số cùng sai số chuẩn rất lớn.
4. **Cỡ mẫu đủ lớn.** Các ước lượng hợp lý cực đại chỉ xấp xỉ không chệch và có phân phối chuẩn ở mẫu lớn; số *biến cố* so với số tham số là điều quan trọng (Mục 5.8).

Không có giả định rằng các biến dự báo có phân phối chuẩn, và cũng không có giả định phương sai bằng nhau.

5.6 Xây dựng mô hình logistic trong R

5.6.1 Mô hình đầu tiên với một biến dự báo

Hồi quy logistic được xây dựng trong R bằng `glm()`, hàm dành cho các mô hình tuyến tính tổng quát, bằng cách chỉ định `family = binomial` (hàm liên kết logit là mặc định). Biến kết cục có thể là một factor, khi đó mức đầu tiên được coi là 0 (thất bại) và mọi mức khác là 1 (thành công). Chúng ta bắt đầu với mô hình thô cho bảo hiểm y tế và kiểm tra rằng nó tái tạo đúng tỷ số chênh đã tính tay.

```
glm_ins <- glm(treatment_uptake ~ health_insurance,
              data = dx, family = binomial(link = "logit"))
coef(glm_ins) # thang log-odds
```

```
#> (Intercept) health_insuranceYes
#> -0.3143      0.5350
```

```
exp(coef(glm_ins)) # thang odds
```

```
#> (Intercept) health_insuranceYes
#> 0.7303      1.7074
```

Hệ số chặn, -0.314, là log-odds sử dụng điều trị ở nhóm tham chiếu (không có bảo hiểm); lấy hàm mũ, nó là odds 0.73 mà chúng ta đã thấy trong bảng. Hệ số của `health_insuranceYes`, 0.535, là hiệu số log-odds giữa bệnh nhân có và không có bảo hiểm, và hàm mũ của nó, 1.71, chính xác là OR thô đã tính tay. Một mô hình hồi quy logistic với một biến dự báo đơn giản chỉ là cách biểu diễn lại một bảng 2×2 .

5.6.2 Mô hình đa biến

Bây giờ chúng ta xây dựng mô hình chính của nghiên cứu. Các biến dự báo đã được chọn *trước khi* phân tích dựa trên cơ sở lâm sàng và y tế công cộng (Mục 5.8 giải thích vì sao điều này quan trọng):

- các đặc điểm nhân khẩu học thường gây nhiều việc sử dụng dịch vụ y tế: tuổi, giới, học vấn và nơi cư trú;
- các yếu tố lâm sàng làm tăng tiếp xúc với dịch vụ y tế: đái tháo đường và tiền sử gia đình bị tăng huyết áp;
- các yếu tố quyết định đã nêu của nghiên cứu: bảo hiểm y tế (tiếp cận tài chính), điểm kiến thức về tăng huyết áp (nhận thức) và khoảng cách đến cơ sở y tế (tiếp cận địa lý).

```

model_full <- glm(
  treatment_uptake ~ age + sex + education + residence + diabetes +
    family_history_htn + health_insurance + knowledge_score +
    distance_to_facility_km,
  data = dx,
  family = binomial(link = "logit")
)

summary(model_full)

```

```

#>
#> Call:
#> glm(formula = treatment_uptake ~ age + sex + education + residence +
#>       diabetes + family_history_htn + health_insurance + knowledge_score +
#>       distance_to_facility_km, family = binomial(link = "logit"),
#>       data = dx)
#>
#> Coefficients:
#>
#>               Estimate Std. Error z value Pr(>|z|)
#> (Intercept)      -3.75688    0.44473   -8.45 < 2e-16 ***
#> age                0.03019    0.00507    5.96 2.6e-09 ***
#> sexMale           -0.30160    0.13956   -2.16 0.03069 *
#> educationPrimary   0.33065    0.19540    1.69 0.09061 .
#> educationSecondary 0.65087    0.20939    3.11 0.00188 **
#> educationTertiary  0.89294    0.25704    3.47 0.00051 ***
#> residenceUrban     0.62486    0.14595    4.28 1.9e-05 ***
#> diabetesYes        1.26938    0.47394    2.68 0.00740 **
#> family_history_htnYes 0.64480    0.14472    4.46 8.4e-06 ***
#> health_insuranceYes 0.71753    0.14779    4.85 1.2e-06 ***
#> knowledge_score     0.09348    0.02053    4.55 5.3e-06 ***
#> distance_to_facility_km -0.01859    0.01222   -1.52 0.12798
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#>
#> (Dispersion parameter for binomial family taken to be 1)
#>
#>      Null deviance: 1369.1  on 991  degrees of freedom
#> Residual deviance: 1221.9  on 980  degrees of freedom
#> (97 observations deleted due to missingness)
#> AIC: 1246
#>
#> Number of Fisher Scoring iterations: 4

```

5.6.3 Đọc từng dòng kết quả summary

Kết quả này chứa rất nhiều thông tin, và đáng để đọc chậm rãi.

- **Call.** Công thức mô hình, họ phân phối (family) và bộ dữ liệu. Luôn kiểm tra rằng công thức đúng như bạn dự định.
- **Coefficients.** Mỗi dòng ứng với một tham số được ước lượng, trên **thang log-odds**.
 - Estimate là $\hat{\beta}_j$. Giá trị dương nghĩa là odds sử dụng điều trị cao hơn khi biến dự báo tăng (hoặc ở nhóm đó so với nhóm tham chiếu); giá trị âm nghĩa là odds thấp hơn.
 - Std. Error là sai số chuẩn của $\hat{\beta}_j$, một thước đo độ chính xác của nó. Hãy chú ý nó lớn như thế nào đối với *diabetesYes* (0,474) so với các biến dự báo nhị phân khác (khoảng 0,14–0,15). Chỉ có 28 bệnh nhân đã được chẩn đoán có đái tháo đường, nên hệ số này được ước lượng kém chính xác.
 - z value là thống kê Wald, Estimate / Std. Error.
 - $Pr(>|z|)$ là giá trị p Wald hai phía cho giả thuyết không $\beta_j = 0$ (OR = 1), đã hiệu chỉnh theo các biến khác.
- **Đọc từng dòng hệ số.**
 - (Intercept) –3.77 là log-odds sử dụng điều trị của một bệnh nhân giả định có mọi biến dự báo bằng không hoặc ở mức tham chiếu: 0 tuổi, nữ, không đi học, nông thôn, không đái tháo đường, không có tiền sử gia đình, không có bảo hiểm, điểm kiến thức 0, sống cách cơ sở y tế 0 km. Nó neo giữ mô hình nhưng không có ý nghĩa lâm sàng.
 - age 0,030: mỗi năm tuổi tăng thêm làm tăng log-odds sử dụng điều trị thêm 0,030, khi giữ cố định các biến khác.
 - sexMale –0.302: nam giới có log-odds sử dụng điều trị thấp hơn nữ giới cùng tuổi, học vấn, nơi cư trú, v.v. Hậu tố Male (nam) cho bạn biết Female (nữ) là nhóm tham chiếu.
 - educationPrimary, educationSecondary, educationTertiary: mỗi hệ số so sánh mức đó với nhóm không được giáo dục chính quy. Các hệ số tăng đều đặn (0,33, 0,65, 0,89), gợi ý một gradient (xu hướng tăng dần).
 - distance_to_facility_km –0.019: odds thấp hơn khi khoảng cách xa hơn, nhưng giá trị p (0,128) cho thấy dữ liệu tương thích với việc không có mối liên quan khi đã tính đến các biến khác.
- **Signif. codes.** Các dấu sao là chú giải cho các ngưỡng giá trị p. Chúng khuyến khích lối tư duy nhị phân (có/không ý nghĩa) và không bao giờ nên được báo cáo trong bài báo (Wasserstein and Lazar 2016; Greenland et al. 2016).
- **Dispersion parameter** (tham số phân tán). Với mô hình nhị thức, nó được cố định bằng 1; dòng này chỉ quan trọng với các họ phân phối khác.
- **Null deviance** (1369,1 với 991 bậc tự do) là độ lệch của mô hình chỉ có hệ số chặn; **residual deviance** (1221,9 với 980 bậc tự do) là độ lệch sau khi thêm 11 số hạng dự báo. Mức giảm 147,2 với 11 bậc tự do là thống kê LR cho giả thuyết không rằng *không* biến dự báo nào có liên quan đến việc sử dụng điều trị, và giả thuyết này bị bác bỏ một cách áp đảo.
- (97 observations deleted due to missingness) (97 quan sát bị loại do dữ liệu khuyết). Dòng này rất dễ bị bỏ qua nhưng lại rất quan trọng. `glm()` chỉ sử dụng các trường hợp đầy đủ (complete cases): mọi bệnh nhân có giá trị khuyết ở *bất kỳ* biến nào trong mô hình đều bị loại. Mô hình được xây dựng trên 992 trong số 1.089 bệnh nhân đã được chẩn đoán (bậc tự do 991 + 1). Con số này phải xuất hiện trong bài báo của bạn.

- **AIC** (tiêu chuẩn thông tin Akaike, Akaike information criterion), $AIC = D + 2q$ trong đó q là số tham số, cân bằng giữa độ khớp và độ phức tạp. Nó hữu ích để so sánh các mô hình được xây dựng trên *cùng* các quan sát; tự thân nó không có cách diễn giải nào.
- **Number of Fisher Scoring iterations** (số vòng lặp Fisher scoring, 4) cho thấy thuật toán hội tụ nhanh. Một con số lớn (chẳng hạn trên 20) là dấu hiệu cảnh báo, thường là do tách biệt hoàn toàn.

```
nobs(model_full) # số quan sát được sử dụng
```

```
#> [1] 992
```

```
table(model_full$y) # kết cục ở những quan sát đó (0/1)
```

```
#>
#>  0  1
#> 535 457
```

Lỗi thường gặp

Báo cáo cỡ mẫu của bộ dữ liệu thay vì của mô hình. Ở đây 97 bệnh nhân đã được chẩn đoán (8,9%) bị loại khỏi mô hình do khuyết điểm kiến thức, khoảng cách, học vấn hoặc tuổi. Luôn báo cáo số đối tượng được phân tích, mô tả dữ liệu khuyết, và cân nhắc liệu phân tích trường hợp đầy đủ có thể bị sai lệch hay không. Khi tỷ lệ dữ liệu khuyết đáng kể, phương pháp gán giá trị đa bội (multiple imputation) thường được ưu tiên hơn (Sterne et al. 2009; Little and Rubin 2019).

5.6.4 Tỷ số chênh kèm khoảng tin cậy

Các hệ số log-odds cần thiết cho phân toán học, nhưng người đọc cần tỷ số chênh. `broom::tidy()` với `exponentiate = TRUE` và `conf.int = TRUE` lấy hàm mũ của các ước lượng và các giới hạn tin cậy của chúng chỉ trong một bước.

```
or_table <- tidy(model_full, exponentiate = TRUE, conf.int = TRUE)
```

```
or_table |>
  select(term, OR = estimate, lower = conf.low, upper = conf.high,
         p = p.value) |>
  mutate(across(c(OR, lower, upper), \(x) round(x, 2)),
         p = format.pval(p, digits = 2, eps = 0.001))
```

```
#> # A tibble: 12 × 5
#>   term                OR lower upper p
#>   <chr>              <dbl> <dbl> <dbl> <chr>
#> 1 (Intercept)        0.02  0.01  0.06 <0.001
#> 2 age                1.03  1.02  1.04 <0.001
#> 3 sexMale            0.74  0.56  0.97 0.0307
#> 4 educationPrimary   1.39  0.95  2.05 0.0906
#> 5 educationSecondary 1.92  1.27  2.9  0.0019
#> 6 educationTertiary  2.44  1.48  4.06 <0.001
```

```
#> 7 residenceUrban          1.87  1.4   2.49 <0.001
#> 8 diabetesYes            3.56  1.46  9.61 0.0074
#> 9 family_history_htnYes  1.91  1.44  2.53 <0.001
#> 10 health_insuranceYes   2.05  1.54  2.74 <0.001
#> 11 knowledge_score       1.1   1.06  1.14 <0.001
#> 12 distance_to_facility_km 0.98  0.96  1.01 0.1280
```

Các giới hạn tin cậy do `tidy()` trả về đến từ `confint()`, mà với một đối tượng `glm` sử dụng phương pháp *hợp lý hồ sơ* (profile likelihood). Các khoảng này hơi bất đối xứng trên thang log và chính xác hơn các khoảng Wald $\exp(\hat{\beta} \pm 1.96 \text{ SE})$, đặc biệt với các ước lượng kém chính xác như OR của đái tháo đường (Hosmer et al. 2013). Cũng lưu ý rằng không thể đơn giản lấy hàm mũ của sai số chuẩn: cột `std.error` của `tidy()` vẫn nằm trên thang log-odds ngay cả khi `exponentiate = TRUE`.

Mỗi tỷ số chênh được diễn giải như một mối liên quan *đã hiệu chỉnh*, khi giữ cố định các biến khác trong mô hình.

- **Tuổi**, OR 1,03 cho mỗi năm (KTC 95% 1,02 đến 1,04): mỗi năm tuổi tăng thêm có liên quan đến odds sử dụng điều trị cao hơn 3%.
- **Giới**, OR 0,74 (0,56 đến 0,97): nam giới có odds sử dụng điều trị thấp hơn nữ giới khoảng 26%.
- **Học vấn**: so với không được giáo dục chính quy, OR là 1,39 (0,95 đến 2,05) với tiểu học, 1,92 (1,27 đến 2,90) với trung học và 2,44 (1,48 đến 4,06) với giáo dục sau trung học, một gradient rõ ràng.
- **Cư trú thành thị**, OR 1,87 (1,40 đến 2,49) so với nông thôn.
- **Đái tháo đường**, OR 3,56 (1,46 đến 9,61): OR lớn nhất, nhưng cũng có khoảng tin cậy rộng nhất, phản ánh số lượng ít bệnh nhân có đái tháo đường.
- **Tiền sử gia đình bị tăng huyết áp**, OR 1,91 (1,44 đến 2,53).
- **Bảo hiểm y tế**, OR 2,05 (1,54 đến 2,74).
- **Điểm kiến thức**, OR 1,10 cho mỗi điểm (1,06 đến 1,14).
- **Khoảng cách đến cơ sở y tế**, OR 0,98 cho mỗi km (0,96 đến 1,01), $p = 0,13$.

Diễn giải lâm sàng

Độ rộng của khoảng tin cậy cho bạn biết dữ liệu ràng buộc ước lượng chặt chẽ đến mức nào. Khoảng tin cậy của đái tháo đường trải từ mức tăng odds khiêm tốn 1,5 lần đến gần 10 lần: chúng ta có thể khá tin rằng mối liên quan là dương, nhưng biết rất ít về độ lớn của nó. Ngược lại, khoảng tin cậy của bảo hiểm y tế (1,5 đến 2,7) đủ hẹp để hữu ích cho việc lập kế hoạch. Một ước lượng điểm lớn với khoảng tin cậy rộng là bằng chứng yếu hơn một ước lượng vừa phải với khoảng tin cậy hẹp. (Dữ liệu được mô phỏng cho mục đích giảng dạy; các kết quả này minh họa phương pháp, không phải phát hiện lâm sàng thực tế.)

5.6.5 Tỷ số chênh cho các mức tăng có ý nghĩa lâm sàng

Các OR cho mỗi đơn vị của tuổi, kiến thức và khoảng cách gần bằng 1 đơn giản vì một năm, một điểm hay một kilômét là một thay đổi nhỏ. Chúng ta đổi thang đo của chúng bằng $\exp(c \hat{\beta})$,

áp dụng cùng phép nhân cho các giới hạn tin cậy trên thang log.

```
# Các mức tăng có ý nghĩa cho từng biến dự báo liên tục
increments <- tibble(
  term = c("age", "knowledge_score", "distance_to_facility_km"),
  unit = c("10 năm", "5 điểm", "5 km"),
  c     = c(10, 5, 5)
)

# KTC hợp lý hồ sơ trên thang log-odds, sau đó nhân với c
ci_log <- confint(model_full)

rescaled <- increments |>
  mutate(beta = coef(model_full)[term],
         OR   = exp(c * beta),
         lower = exp(c * ci_log[term, 1]),
         upper = exp(c * ci_log[term, 2])) |>
  select(term, unit, OR, lower, upper)

kable(rescaled, digits = 2,
      caption = "Tỷ số chênh hiệu chỉnh cho mức tăng có ý nghĩa lâm sàng.")
```

Bảng 5.4: Tỷ số chênh hiệu chỉnh cho mức tăng có ý nghĩa lâm sàng.

term	unit	OR	lower	upper
age	10 năm	1.35	1.23	1.50
knowledge_score	5 điểm	1.60	1.31	1.96
distance_to_facility_km	5 km	0.91	0.81	1.03

Biểu diễn theo cách này, kết quả trở nên dễ truyền đạt hơn nhiều: chênh lệch 10 năm tuổi có liên quan đến odds sử dụng điều trị gấp 1.35 lần, điểm kiến thức cao hơn 5 điểm có liên quan đến odds gấp 1.6 lần, và sống xa hơn 5 km có liên quan đến odds gấp 0.91 lần (KTC 95% 0.81 đến 1.03). Mức tăng nên được chọn dựa trên sự phù hợp lâm sàng (thường là khoảng tứ phân vị hoặc một đơn vị quen thuộc như một thập kỷ), được nêu rõ, và được quyết định trước khi xem kết quả.

5.6.6 Xác suất dự báo

Tỷ số chênh là các thước đo tương đối. Để cho thấy mô hình hàm ý điều gì theo nghĩa tuyệt đối, chúng ta có thể tính xác suất dự báo cho các bệnh nhân đại diện bằng `predict(type = "response")`. Ở đây chúng ta so sánh hai phụ nữ 55 tuổi sống ở nông thôn, học vấn tiểu học, không đái tháo đường, không có tiền sử gia đình, điểm kiến thức trung bình là 10 và sống cách cơ sở y tế 6 km, chỉ khác nhau về bảo hiểm y tế.

```
profiles <- tibble(
  age = 55, sex = "Female", education = "Primary", residence = "Rural",
  diabetes = "No", family_history_htn = "No",
  health_insurance = c("No", "Yes"),
  knowledge_score = 10, distance_to_facility_km = 6
)

profiles |>
```

```
mutate(p_uptake = predict(model_full, newdata = profiles,
                           type = "response")) |>
select(health_insurance, p_uptake)
```

```
#> # A tibble: 2 × 2
#>   health_insurance p_uptake
#>   <chr>           <dbl>
#> 1 No             0.280
#> 2 Yes            0.444
```

Xác suất dự báo của việc sử dụng điều trị tăng từ 28% lên 44%, một hiệu số tuyệt đối 16 điểm phần trăm. Tỷ số chênh là như nhau với mọi hồ sơ bệnh nhân, nhưng hiệu số tuyệt đối phụ thuộc vào xác suất nền, đó là lý do xác suất dự báo (hoặc hiệu số nguy cơ) là phần bổ sung quý giá cho OR khi trao đổi với các bác sĩ lâm sàng và nhà hoạch định chính sách.

5.6.7 Kiểm định một biến dự báo phân loại có nhiều mức

Học vắn đi vào mô hình dưới dạng ba biến chỉ thị, mỗi biến có giá trị p Wald riêng. Chúng trả lời ba câu hỏi riêng biệt (Primary có khác None không? Secondary có khác None không? Tertiary có khác None không?) nhưng không trả lời câu hỏi tổng thể "học vắn có liên quan đến việc sử dụng điều trị không?". Để trả lời câu hỏi đó, chúng ta cần một kiểm định duy nhất cho giả thuyết không rằng cả ba hệ số đều bằng không, và kiểm định tỷ số hợp lý là lựa chọn tự nhiên (Hosmer et al. 2013).

`drop1()` lần lượt loại bỏ từng số hạng (tất cả các mức của một factor cùng lúc) và so sánh độ lệch với độ lệch của mô hình đầy đủ.

```
drop1(model_full, test = "LRT")
```

```
#> Single term deletions
#>
#> Model:
#> treatment_uptake ~ age + sex + education + residence + diabetes +
#>   family_history_htn + health_insurance + knowledge_score +
#>   distance_to_facility_km
#>
#>           Df Deviance   AIC   LRT Pr(>Chi)
#> <none>                1222 1246
#> age              1      1259 1281 37.4  9.8e-10 ***
#> sex              1      1227 1249  4.7  0.0303 *
#> education        3      1238 1256 16.3  0.0010 **
#> residence         1      1240 1262 18.6  1.6e-05 ***
#> diabetes         1      1230 1252  8.0  0.0047 **
#> family_history_htn 1      1242 1264 20.2  7.0e-06 ***
#> health_insurance  1      1246 1268 24.1  9.3e-07 ***
#> knowledge_score   1      1243 1265 21.4  3.7e-06 ***
#> distance_to_facility_km 1      1224 1246  2.3  0.1261
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Dòng của học vắn cho thấy việc loại bỏ biến này làm độ lệch tăng 16,3 với 3 bậc tự do, $p = 0.001$: học vắn nói chung có liên quan đến việc sử dụng điều trị. Các dòng khác cho kiểm định LR của từng số hạng một tham số; giá trị p của chúng rất gần với giá trị p Wald trong `summary()`, đúng như kỳ vọng với cỡ mẫu này.

Cũng có thể thu được cùng kiểm định này bằng cách xây dựng mô hình không có học vấn và so sánh trực tiếp hai mô hình lồng nhau bằng `anova()`. Ở đây có một cái bẫy. Học vấn có 24 giá trị khuyết trong số các bệnh nhân đã được chẩn đoán, nên một mô hình *không có học vấn*, xây dựng trên `dx`, sẽ bao gồm những bệnh nhân đã bị loại khỏi `model_full`. Khi đó hai độ lệch sẽ ứng với những nhóm bệnh nhân khác nhau và không thể so sánh được (R dừng lại với thông báo lỗi "models were not all fitted to the same size of dataset" – các mô hình không được xây dựng trên bộ dữ liệu cùng cỡ). Vì vậy chúng ta trích xuất dữ liệu trường hợp đầy đủ mà mô hình đầy đủ đã sử dụng bằng `model.frame()` và xây dựng mô hình nhỏ hơn trên chính xác những bệnh nhân đó.

```
cc <- model.frame(model_full)      # 992 bệnh nhân được model_full sử dụng
nrow(cc)
```

```
#> [1] 992
```

```
model_no_edu <- update(model_full, . ~ . - education, data = cc)
lrt_edu <- anova(model_no_edu, model_full, test = "LRT")
attr(lrt_edu, "heading") <- NULL   # bỏ phần công thức mô hình dài dòng
lrt_edu
```

```
#>   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
#> 1      983      1238
#> 2      980      1222  3      16.3    0.001 **
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Thống kê LR (hiệu số độ lệch, 16,3 với 3 bậc tự do) và giá trị p của nó giống hệt kết quả của `drop1()`, vốn thực hiện cùng phép so sánh này ở bên trong.

Thực hành tốt

Khi so sánh các mô hình lồng nhau, hãy đảm bảo cả hai được xây dựng trên chính xác cùng các quan sát. Cách đơn giản nhất là tạo bộ dữ liệu trường hợp đầy đủ một lần, bằng `model.frame()` của mô hình lớn nhất hoặc bằng `drop_na()` trên tất cả các biến ứng viên, rồi xây dựng mọi mô hình trên bộ dữ liệu đó.

5.7 Nhiều: ước lượng thô so với ước lượng hiệu chỉnh

5.7.1 Nhiều là gì?

Một *yếu tố gây nhiễu* (confounder) là một biến làm sai lệch mối liên quan quan sát được giữa một phơi nhiễm và một biến kết cục vì nó có liên quan đến cả hai. Các tiêu chí kinh điển là một yếu tố gây nhiễu (1) là một nguyên nhân, hoặc đại diện cho một nguyên nhân, của biến kết cục; (2) có liên quan đến phơi nhiễm trong quần thể nguồn; và (3) không phải là hệ quả của phơi nhiễm, tức là không nằm trên con đường nhân quả từ phơi nhiễm đến biến kết cục (Rothman et al. 2008). Ước lượng *thô* (chưa hiệu chỉnh) trộn lẫn tác động của phơi nhiễm với tác động của yếu tố gây nhiễu; ước lượng *hiệu chỉnh*, từ một mô hình có đưa yếu tố gây nhiễu vào, cố gắng tách biệt chúng.

5.7.2 Sơ đồ nhân quả bằng lời

Sơ đồ nhân quả, hay đồ thị có hướng không chu trình (directed acyclic graphs, DAG), giúp diễn đạt chính xác những ý tưởng này (Greenland et al. 1999). Một DAG vẽ mỗi biến thành một nút và mỗi tác động nhân quả trực tiếp được giả định thành một mũi tên. Xét câu hỏi "khoảng cách đến cơ sở y tế có liên quan đến việc sử dụng điều trị không?". Các giả định hợp lý là:

- *Khoảng cách* → *Sử dụng điều trị*: bệnh nhân sống xa phòng khám phải chịu chi phí và thời gian đi lại, điều có thể làm giảm việc sử dụng điều trị.
- *Nơi cư trú* → *Khoảng cách*: bệnh nhân nông thôn có xu hướng sống xa cơ sở y tế hơn.
- *Nơi cư trú* → *Sử dụng điều trị*: độc lập với khoảng cách, khu vực thành thị có thể có nhiều nhà thuốc hơn, nhiều thông tin y tế hơn và các mô hình chăm sóc khác.

Do đó, nơi cư trú mở ra một "đường cửa sau" (back-door path) từ khoảng cách đến việc sử dụng điều trị (*Khoảng cách* ← *Nơi cư trú* → *Sử dụng điều trị*) mà không thuộc về tác động của khoảng cách. Để ước lượng mối liên quan giữa khoảng cách và việc sử dụng điều trị không do nơi cư trú gây ra, đường cửa sau phải được chặn bằng cách hiệu chỉnh theo nơi cư trú. Ngược lại, một biến do phơi nhiễm gây ra và nằm trên con đường đến biến kết cục (một *biến trung gian*, mediator) không nên được hiệu chỉnh nếu chúng ta muốn ước lượng tác động toàn phần, và việc hiệu chỉnh theo một *hệ quả* chung của phơi nhiễm và biến kết cục (một *biến va chạm*, collider) có thể tạo ra sai lệch ở nơi vốn không có (Greenland et al. 1999; VanderWeele 2019).

VanderWeele (2019) đưa ra một quy tắc thực hành cho những tình huống mà cấu trúc nhân quả đầy đủ chưa chắc chắn, gọi là *tiêu chí nguyên nhân tuyển được điều chỉnh* (modified disjunctive cause criterion): hiệu chỉnh theo bất kỳ biến nào có trước phơi nhiễm mà là nguyên nhân của phơi nhiễm, của biến kết cục hoặc của cả hai; loại trừ các biến công cụ đã biết (chỉ là nguyên nhân của phơi nhiễm); và đưa vào các biến đại diện tốt cho các nguyên nhân chung không đo lường được.

5.7.3 Ví dụ minh họa: khoảng cách và nơi cư trú

Dữ liệu phù hợp với hai mũi tên đầu tiên: bệnh nhân nông thôn trong mẫu của mô hình sống cách cơ sở y tế trung bình 9,6 km, bệnh nhân thành thị 6,0 km. Bây giờ chúng ta so sánh tỷ số chênh thô của khoảng cách với tỷ số chênh đã hiệu chỉnh chỉ theo nơi cư trú và theo tất cả các biến trong mô hình đầy đủ. Để so sánh công bằng, cả ba mô hình được xây dựng trên cùng 992 trường hợp đầy đủ.

```
# cc: dữ liệu trường hợp đầy đủ mà mô hình đầy đủ sử dụng (đã tạo ở trên)
with(cc, tapply(distance_to_facility_km, residence, mean))
```

```
#> Rural Urban
#> 9.591 6.022
```

```
m_crude <- glm(treatment_uptake ~ distance_to_facility_km,
               data = cc, family = binomial)
m_res <- glm(treatment_uptake ~ distance_to_facility_km + residence,
             data = cc, family = binomial)
```

```
# Trích OR của khoảng cách (mỗi 5 km) và KTC 95% từ mỗi mô hình
```

```
dist_or <- function(model, label) {
  b <- coef(model)["distance_to_facility_km"]
  ci <- confint(model)["distance_to_facility_km", ]
  p <- summary(model)$coefficients["distance_to_facility_km", 4]
  tibble(model = label, OR_5km = exp(5 * b),
    lower = exp(5 * ci[1]), upper = exp(5 * ci[2]), p = p)
}

conf_tab <- bind_rows(
  dist_or(m_crude, "Thô"),
  dist_or(m_res, "Hiệu chỉnh theo nơi cư trú"),
  dist_or(model_full, "Hiệu chỉnh đầy đủ")
)
kable(conf_tab, digits = 3,
  caption = "OR mỗi 5 km khoảng cách: thô và hiệu chỉnh.")
```

Bảng 5.5: OR mỗi 5 km khoảng cách: thô và hiệu chỉnh.

model	OR_5km	lower	upper	p
Thô	0.850	0.762	0.947	0.003
Hiệu chỉnh theo nơi cư trú	0.913	0.815	1.021	0.111
Hiệu chỉnh đầy đủ	0.911	0.807	1.026	0.128

Phân tích thô gợi ý rằng mỗi 5 km tăng thêm có liên quan đến odds sử dụng điều trị thấp hơn 15%, với khoảng tin cậy không chứa 1 ($p = 0.0034$). Sau khi chỉ hiệu chỉnh theo nơi cư trú, OR dịch chuyển về phía 1 (0.91), khoảng tin cậy chứa 1, và giá trị p tăng lên 0.11. Biểu diễn trên thang log-odds, hệ số đã co lại khoảng 44%. Phần lớn mối liên quan thô giữa khoảng cách và việc sử dụng điều trị là do nơi cư trú: bệnh nhân nông thôn sống xa hơn và, vì những lý do khác ngoài khoảng cách, ít có khả năng đang điều trị hơn. Hiệu chỉnh thêm các biến còn lại hầu như không làm thay đổi OR của khoảng cách nữa.

Một quy tắc kinh nghiệm phổ biến coi một biến là yếu tố gây nhiễu nếu việc hiệu chỉnh theo nó làm hệ số của phơi nhiễm thay đổi hơn 10% (tiêu chí *thay đổi ước lượng*, change-in-estimate). Đây là một công cụ sàng lọc hữu ích, nhưng không nên thay thế lập luận nhân quả: một biến trung gian hoặc một biến va chạm cũng có thể làm thay đổi ước lượng, và việc hiệu chỉnh theo nó sẽ tạo ra sai lệch (Rothman et al. 2008; VanderWeele 2019).

Diễn giải lâm sàng

Phân tích thô có thể khiến một nhà hoạch định y tế kết luận rằng bản thân khoảng cách là một rào cản lớn đối với điều trị. Phân tích hiệu chỉnh gợi ý một bức tranh tinh tế hơn: cư trú ở nông thôn có liên quan đến tỷ lệ sử dụng điều trị thấp hơn, và khoảng cách mang rất ít thông tin bổ sung khi đã biết nơi cư trú. Do đó, các can thiệp nhắm vào bệnh nhân nông thôn (ví dụ các hoạt động tiếp cận cộng đồng hoặc cấp phát thuốc tại cộng đồng) có thể quan trọng hơn việc chỉ đơn thuần giảm khoảng cách đi lại. Trong thực tế, điều này cần được xác nhận bằng các nghiên cứu được thiết kế tốt hơn; dữ liệu này là dữ liệu mô phỏng.

5.7.4 Không phải mọi thay đổi đều là nhiễu: tính không thể gộp

Hãy so sánh OR thô và OR hiệu chỉnh của hai biến khác trên cùng 992 bệnh nhân.

```
crude_or <- function(var) {
  f <- reformulate(var, response = "treatment_uptake")
  exp(coef(glm(f, data = cc, family = binomial)))[2]
}
tibble(variable = c("family_history_htn", "health_insurance"),
  crude_OR = c(crude_or("family_history_htn"),
    crude_or("health_insurance")),
  adjusted_OR = exp(coef(model_full)[c("family_history_htnYes",
    "health_insuranceYes")])) |>
  kable(digits = 2, caption = "OR thô và OR hiệu chỉnh của hai biến dự báo.")
```

Bảng 5.6: OR thô và OR hiệu chỉnh của hai biến dự báo.

variable	crude_OR	adjusted_OR
family_history_htn	1.65	1.91
health_insurance	1.67	2.05

Cả hai tỷ số chênh đều dịch chuyển *ra xa* 1 sau khi hiệu chỉnh, từ khoảng 1,65 lên khoảng 2,0, mặc dù tiền sử gia đình và bảo hiểm chỉ liên quan yếu với các biến dự báo khác trong dữ liệu này. Chỉ một phần của sự thay đổi này là do nhiễu. Phần còn lại là một tính chất toán học của tỷ số chênh gọi là *tính không thể gộp* (non-collapsibility): khi các biến dự báo mạnh biến kết cục được thêm vào mô hình logistic, OR của một phơi nhiễm nhất định thường dịch chuyển *ra xa* giá trị không có tác động *ngay cả khi hoàn toàn không có nhiễu* (Rothman et al. 2008; Vittinghoff et al. 2012). OR hiệu chỉnh (*có điều kiện*, conditional) so sánh những bệnh nhân có giá trị giống hệt nhau ở tất cả các biến dự báo khác, trong khi OR thô (*biên*, marginal) lấy trung bình trên toàn quần thể, và với tỷ số chênh thì hai đại lượng này khác nhau. Hiệu số nguy cơ và tỷ số nguy cơ không có tính chất này. Bài tập 5.4 cho thấy cách tách hai thành phần này bằng phương pháp chuẩn hóa (standardisation). Bài học thực tế là sự thay đổi giữa OR thô và OR hiệu chỉnh tự nó không phải là bằng chứng của nhiễu; lập luận nhân quả của bạn phải đi trước.

5.7.5 Nguy biến Bảng 2

Thật hấp dẫn khi diễn giải *mọi* OR hiệu chỉnh trong một mô hình đa biến như tác động của biến đó, như chúng ta đã làm, kèm những lưu ý, trong danh sách ở trên. Westreich and Greenland (2013) gọi đây là *nguy biến Bảng 2* (Table 2 fallacy) (vì kết quả đa biến chính thường nằm ở bảng thứ hai của bài báo). Vấn đề là một mô hình được xây dựng để ước lượng tác động của một phơi nhiễm được hiệu chỉnh theo các yếu tố gây nhiễu của phơi nhiễm đó, mà thường không phải là tập hợp biến hiệu chỉnh đúng cho từng biến dự báo khác.

Lấy ví dụ học vấn và điểm kiến thức. Học vấn có lẽ *gây ra* kiến thức tốt hơn về tăng huyết áp, và kiến thức đến lượt nó lại làm tăng việc sử dụng điều trị. Trong mô hình của chúng ta, vốn bao gồm kiến thức, OR của học vấn ước lượng mối liên quan giữa học vấn và việc sử dụng điều trị ở *những bệnh nhân có cùng điểm kiến thức*: phần tác động của học vấn không thông qua kiến thức (*tác động trực tiếp*). Tác động toàn phần của học vấn sẽ được ước lượng bằng một mô hình bỏ qua các biến trung gian của nó. Tương tự, OR của tuổi được hiệu chỉnh theo lối sống, mà bản thân lối sống một phần là hệ quả của tuổi.

Lỗi thường gặp

Diễn giải mỗi hệ số trong một mô hình "các yếu tố quyết định" như một tác động nhân quả có vị thế ngang nhau. Trong một mô hình đa biến mô tả, các OR là *những mối liên quan được hiệu chỉnh lẫn nhau*. Nếu một phơi nhiễm cụ thể là mối quan tâm nhân quả, hãy xây dựng mô hình cho phơi nhiễm đó (dùng sơ đồ nhân quả) và chỉ báo cáo OR của nó như kết quả chính (Westreich and Greenland 2013).

5.7.6 Tương tác (thay đổi tác động)

Cho đến nay, chúng ta đã giả định rằng OR của mỗi biến dự báo là như nhau ở mọi giá trị của các biến dự báo khác. *Tương tác* (interaction), hay *thay đổi tác động* (effect modification), xảy ra khi mối liên quan của một biến với biến kết cục khác nhau tùy theo mức của một biến khác (Rothman et al. 2008; Kirkwood and Sterne 2003). Ví dụ, mối liên quan giữa đái tháo đường và việc sử dụng điều trị có thể mạnh hơn ở bệnh nhân trẻ tuổi, những người mà chẩn đoán đái tháo đường mang lại sự tiếp xúc thường xuyên với phòng khám. Tương tác được mô hình hóa bằng cách thêm tích của hai biến:

$$\text{logit}(p) = \beta_0 + \beta_1 \text{age} + \beta_2 \text{diabetes} + \beta_3 (\text{age} \times \text{diabetes}) + \dots$$

Khi đó OR của đái tháo đường là $\exp(\beta_2 + \beta_3 \times \text{age})$, thay đổi theo tuổi. Chúng ta kiểm định $\beta_3 = 0$ bằng một kiểm định LR so sánh các mô hình có và không có số hạng tích.

```
model_int <- update(model_full, . ~ . + diabetes:age)
anova(model_full, model_int, test = "LRT")
```

R

```
#> Analysis of Deviance Table
#>
#> Model 1: treatment_uptake ~ age + sex + education + residence + diabetes +
#>   family_history_htn + health_insurance + knowledge_score +
#>   distance_to_facility_km
#> Model 2: treatment_uptake ~ age + sex + education + residence + diabetes +
#>   family_history_htn + health_insurance + knowledge_score +
#>   distance_to_facility_km + age:diabetes
#>   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
#> 1      980      1222
#> 2      979      1221  1      1.32      0.25
```

Số hạng tương tác chỉ làm giảm độ lệch 1,3 với 1 bậc tự do ($p = 0.25$). Không có bằng chứng rằng OR của đái tháo đường thay đổi theo tuổi, nên chúng ta giữ mô hình đơn giản hơn không có tương tác. Các tương tác nên được xác định trước dựa trên cơ sở lâm sàng và được kiểm định một cách dè dặt: các kiểm định tương tác có lực thống kê thấp, và việc tìm kiếm nhiều tương tác có thể có sẽ tạo ra những phát hiện giả.

Lỗi thường gặp

Khi một số hạng tương tác *được* giữ lại trong mô hình, các hệ số "tác động chính" (main effect) thay đổi ý nghĩa. Trong mô hình ở trên, *diabetesYes* sẽ là log OR của đái tháo đường ở tuổi 0, một giá trị vô nghĩa. Hãy báo cáo OR của một biến tại những giá trị được chọn của biến kia (ví dụ ở tuổi 40, 55 và 70), hoặc định tâm biến liên tục trước khi tạo tích.

5.8 Xây dựng mô hình

5.8.1 Xác định trước so với chọn biến tự động

Các biến dự báo trong một mô hình đa biến nên được chọn như thế nào? Trong một phân tích giải thích hoặc mô tả, câu trả lời là: dựa trên kiến thức chuyên môn, được quyết định trước khi xem mối liên quan của từng biến ứng viên với biến kết cục, và được ghi lại trong kế hoạch phân tích thống kê (Vittinghoff et al. 2012; Harrell 2015; Heinze et al. 2018). Đây là cách `model_full` đã được xây dựng.

Cách làm thay thế, vẫn phổ biến trong các bài báo lâm sàng, là để một thuật toán lựa chọn: *chọn tiến* (forward selection) thêm từng biến một, *loại lùi* (backward elimination) bắt đầu với tất cả các biến ứng viên và loại bỏ biến kém ý nghĩa nhất, và các phương pháp *từng bước* (stepwise) xen kẽ giữa hai cách trên. Một biến thể là cách tiếp cận hai bước phổ biến: sàng lọc các biến bằng kiểm định đơn biến (ví dụ giữ những biến có $p < 0.2$) rồi thực hiện loại lùi. Các quy trình này có những vấn đề đã được ghi nhận rõ ràng (Harrell 2015; Heinze et al. 2018):

- **Ước lượng bị chệch.** Các biến được chọn *bởi vì* tác động ước lượng của chúng tình cờ lớn trong mẫu này, nên các hệ số được chọn bị chệch ra xa không.
- **Suy luận không hợp lệ.** Sai số chuẩn, khoảng tin cậy và giá trị p của mô hình cuối cùng bỏ qua quá trình chọn biến; các khoảng tin cậy quá hẹp và giá trị p quá nhỏ.
- **Thiếu ổn định.** Những thay đổi nhỏ trong dữ liệu (một mẫu khác, thêm vài bệnh nhân) thường tạo ra một tập hợp biến "được chọn" khác.
- **Bỏ sót yếu tố gây nhiễu.** Một yếu tố gây nhiễu quan trọng có thể bị loại bỏ vì giá trị p của chính nó lớn hơn 0,05, đưa trở lại chính sai lệch mà việc hiệu chỉnh nhằm loại bỏ.
- **Sàng lọc đơn biến gây hiểu lầm.** Một biến có thể không liên quan đến biến kết cục khi đứng một mình nhưng lại quan trọng sau khi hiệu chỉnh (và ngược lại), nên giá trị p thô là một chỉ dẫn kém về những gì nên có trong mô hình đa biến.

Hàm `step()` của R thực hiện chọn biến từng bước theo AIC. Để đầy đủ, đây là những gì nó làm với mô hình của chúng ta.

```
model_step <- step(model_full, direction = "both", trace = 0)
attr(terms(model_step), "term.labels")      # các biến được giữ lại
```

```
#> [1] "age"                "sex"
#> [3] "education"          "residence"
#> [5] "diabetes"            "family_history_htn"
#> [7] "health_insurance"    "knowledge_score"
#> [9] "distance_to_facility_km"
```

```
AIC(model_full, model_step)
```

```
#>           df  AIC
#> model_full 12 1246
#> model_step 12 1246
```

Với bộ dữ liệu này, `step()` giữ lại mọi biến, kể cả khoảng cách với giá trị $p = 0,13$, vì loại bỏ khoảng cách sẽ làm AIC tăng nhẹ. Với một bộ dữ liệu khác, nó có thể loại bỏ vài biến. Quyết định của chúng ta không phụ thuộc vào kết quả của `step()`: mô hình được xác định trước là phân tích chính.

Thực hành tốt

Nếu bạn sử dụng phương pháp chọn biến dựa trên dữ liệu (ví dụ trong một mô hình dự báo), hãy dùng các phương pháp được thiết kế cho mục đích đó, như hồi quy có phạt (penalised regression), báo cáo đầy đủ quy trình, và đánh giá độ ổn định của việc chọn biến bằng phương pháp lấy mẫu lại bootstrap (Heinze et al. 2018; Harrell 2015). Không bao giờ trình bày một mô hình được chọn bằng phương pháp từng bước như thể nó đã được xác định trước.

5.8.2 Dữ liệu có thể hỗ trợ bao nhiêu biến dự báo?

Mỗi tham số trong mô hình logistic đều "tiêu tốn" thông tin. Lượng thông tin liên quan không phải là tổng cỡ mẫu mà là số bệnh nhân trong nhóm kết cục *ít gặp hơn*, thường được gọi là số biến cố. Peduzzi et al. (1996) đã chỉ ra bằng mô phỏng rằng khi có ít hơn khoảng 10 biến cố trên mỗi biến (events per variable, EPV; chính xác là trên mỗi tham số được ước lượng), các hệ số của mô hình logistic có thể bị chệch, phương sai của chúng được ước lượng kém, và khoảng tin cậy không đáng tin cậy. Quy tắc "10 EPV" là một hướng dẫn sơ bộ chứ không phải một định luật, và đặc biệt các mô hình dự báo có thể cần nhiều hơn đáng kể (Harrell 2015), nhưng nó là một phép kiểm tra hợp lý hữu ích.

```
n_events <- min(table(model_full$y)) # nhóm ít gặp hơn
n_parameters <- length(coef(model_full)) - 1 # không tính hệ số chặn
c(events = n_events, parameters = n_parameters,
  EPV = round(n_events / n_parameters, 1))
```

```
#>      events parameters      EPV
#>      457.0         11.0      41.5
```

Với 457 biến cố (bệnh nhân đang điều trị) và 11 tham số, EPV khoảng 42, cao hơn hẳn 10. Mô hình không bị quá khớp. Sự thiếu chính xác của ước lượng đại tháo đường đến từ một vấn đề khác: chỉ có 28 bệnh nhân đã được chẩn đoán có đại tháo đường, và độ chính xác của OR của một biến dự báo nhị phân phụ thuộc vào số bệnh nhân trong ô nhỏ nhất của nó, chứ không phụ thuộc vào EPV của toàn bộ mô hình.

5.8.3 Đa cộng tuyến

Cộng tuyến (collinearity, hay đa cộng tuyến, multicollinearity) xảy ra khi các biến dự báo tương quan mạnh với nhau. Khi đó mô hình khó tách biệt đóng góp riêng của từng biến, sai số chuẩn bị phóng đại, và các ước lượng có thể thay đổi mạnh khi thêm hoặc bớt một biến. Hệ số phóng đại phương sai (variance inflation factor, VIF) của biến dự báo j là

$$VIF_j = \frac{1}{1 - R_j^2},$$

trong đó R_j^2 là R^2 khi hồi quy x_j theo tất cả các biến dự báo khác. VIF bằng 1 nghĩa là không có cộng tuyến; giá trị trên 5, và đặc biệt trên 10, cho thấy có vấn đề (Vittinghoff et al. 2012). Với các factor có nhiều mức, `car::vif()` báo cáo VIF *tổng quát* (generalised VIF, GVIF) và $GVIF^{1/(2\text{ df})}$, mà bình phương của nó có thể so sánh với các ngưỡng VIF thông thường.

```
car::vif(model_full)
```

R

```
#>               GVIF Df GVIF^(1/(2*Df))
#> age               1.022  1           1.011
#> sex               1.006  1           1.003
#> education         1.048  3           1.008
#> residence         1.116  1           1.056
#> diabetes          1.019  1           1.009
#> family_history_htn 1.029  1           1.015
#> health_insurance  1.038  1           1.019
#> knowledge_score   1.034  1           1.017
#> distance_to_facility_km 1.097  1           1.047
```

Tất cả các giá trị đều gần 1 (GVIF lớn nhất, của nơi cư trú, khoảng 1,12). Các biến dự báo mang thông tin phần lớn tách biệt nhau, và đa cộng tuyến không phải là mối lo ngại. Trong dữ liệu lâm sàng, đa cộng tuyến thường phát sinh khi đưa vào hai thước đo của cùng một thứ (cân nặng và BMI, huyết áp tâm thu và huyết áp động mạch trung bình) hoặc một biến cùng với một phép biến đổi của chính nó.

5.8.4 Dữ liệu khuyết và tính cụm

Hai vấn đề thiết kế khác cũng ảnh hưởng đến mô hình này. Thứ nhất, như đã lưu ý, 97 bệnh nhân bị loại do dữ liệu khuyết. Phân tích trường hợp đầy đủ không bị chệch nếu tình trạng khuyết không phụ thuộc vào biến kết cục khi đã biết các biến dự báo, nhưng có thể bị chệch trong trường hợp ngược lại; với khoảng 9% bệnh nhân bị loại, việc báo cáo phân tích trường hợp đầy đủ làm phân tích chính là hợp lý, và trong một nghiên cứu đầy đủ, cần kiểm tra lại bằng phương pháp gán giá trị đa bội (Sterne et al. 2009; Little and Rubin 2019).

Thứ hai, bệnh nhân được tuyển chọn từ sáu cơ sở y tế. Bệnh nhân đến khám tại cùng một cơ sở có chung nhân viên, nguồn cung thuốc và chính sách địa phương, nên kết cục của họ có thể tương quan với nhau, vi phạm giả định độc lập. Bỏ qua tính cụm (clustering) như vậy thường làm sai số chuẩn quá nhỏ. Các lựa chọn bao gồm thêm cơ sở y tế như một tác động cố định (khả thi khi chỉ có sáu cơ sở; xem Bài tập 5.6), sử dụng sai số chuẩn vững theo cụm (cluster-robust standard errors), hoặc xây dựng mô hình hỗn hợp với tác động ngẫu nhiên của cơ sở y tế; hai cách sau nằm ngoài phạm vi của cuốn sách này (Vittinghoff et al. 2012).

5.9 Kiểm tra mô hình

Một mô hình đã xây dựng cần được kiểm tra trước khi báo cáo kết quả. Với hồi quy logistic, các kiểm tra chính liên quan đến dạng hàm của các biến dự báo liên tục, mức độ mô hình tách biệt được bệnh nhân có và không có biến kết cục (*khả năng phân biệt*, discrimination), mức độ xác suất dự báo khớp với tỷ lệ quan sát (*hiệu chuẩn*, calibration), và liệu một vài quan sát có ảnh hưởng quá mức đến kết quả hay không (Hosmer et al. 2013; Harrell 2015).

5.9.1 Tính tuyến tính của các biến dự báo liên tục trên thang logit

Mô hình giả định rằng tuổi, điểm kiến thức và khoảng cách, mỗi biến đều có quan hệ tuyến tính với log-odds sử dụng điều trị. Một cách kiểm tra đơn giản là thêm một số hạng bậc hai cho mỗi biến và kiểm định nó bằng kiểm định LR. Nếu số hạng bậc hai không cần thiết, dạng tuyến tính là thỏa đáng.

```

model_quad <- update(model_full, . ~ . + I(age^2) + I(knowledge_score^2) +
                      I(distance_to_facility_km^2))
anova(model_full, model_quad, test = "LRT")

```

R

```

#> Analysis of Deviance Table
#>
#> Model 1: treatment_uptake ~ age + sex + education + residence + diabetes +
#>   family_history_htn + health_insurance + knowledge_score +
#>   distance_to_facility_km
#> Model 2: treatment_uptake ~ age + sex + education + residence + diabetes +
#>   family_history_htn + health_insurance + knowledge_score +
#>   distance_to_facility_km + I(age^2) + I(knowledge_score^2) +
#>   I(distance_to_facility_km^2)
#>   Resid. Df Resid. Dev Df Deviance Pr(>Chi)
#> 1         980         1222
#> 2         977         1219  3      2.71    0.44

```

Ba số hạng bậc hai cùng nhau chỉ làm giảm độ lệch một lượng nhỏ ($p = 0.44$), nên không có bằng chứng về độ cong và các số hạng tuyến tính được giữ lại. Các phép kiểm tra linh hoạt hơn sử dụng spline bậc ba có giới hạn (restricted cubic splines) (Harrell 2015).

5.9.2 Khả năng phân biệt: đường cong ROC và AUC

Với mỗi bệnh nhân, mô hình đưa ra một xác suất dự báo sử dụng điều trị. Nếu chúng ta phân loại một bệnh nhân là "dự báo có điều trị" bất cứ khi nào xác suất này vượt quá một ngưỡng t , chúng ta có thể tính *độ nhạy* (sensitivity; tỷ lệ những người thực sự điều trị được phân loại đúng) và *độ đặc hiệu* (specificity; tỷ lệ những người không điều trị được phân loại đúng). *Đường cong ROC* (receiver operating characteristic) vẽ độ nhạy theo $1 -$ độ đặc hiệu cho mọi ngưỡng có thể.

Diện tích dưới đường cong ROC (area under the curve, AUC, còn gọi là thống kê c) tóm tắt khả năng phân biệt bằng một con số duy nhất. Hanley and McNeil (1982) đã chỉ ra rằng nó có một cách diễn giải đơn giản: AUC là xác suất để một bệnh nhân được chọn ngẫu nhiên có biến kết cục có xác suất dự báo cao hơn một bệnh nhân được chọn ngẫu nhiên *không* có biến kết cục. AUC bằng 0,5 nghĩa là mô hình phân biệt không tốt hơn tung đồng xu, và 1,0 nghĩa là tách biệt hoàn hảo. Các nhãn mô tả thường dùng là 0,7–0,8 "chấp nhận được", 0,8–0,9 "rất tốt" và trên 0,9 "xuất sắc" (Hosmer et al. 2013).

```

roc_obj <- roc(response = model_full$y,      # kết cục quan sát 0/1
               predictor = fitted(model_full), # xác suất dự báo
               quiet    = TRUE)
auc(roc_obj)

```

R

```

#> Area under the curve: 0.715

```

```
ci.auc(roc_obj) # khoảng tin cậy 95% theo DeLong
```

R


```
#> 95% CI: 0.683-0.747 (DeLong)
```

```
roc_df <- tibble(fpr = 1 - roc_obj$specificities,
                 tpr = roc_obj$sensitivities) |>
  arrange(fpr, tpr)

ggplot(roc_df, aes(x = fpr, y = tpr)) +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed",
             colour = "grey50") +
  geom_step(linewidth = 0.9, colour = "#0D7377") +
  annotate("text", x = 0.65, y = 0.25,
         label = paste0("AUC = ", round(auc(roc_obj), 3))) +
  coord_equal() +
  labs(title = "Đường cong ROC: mô hình sử dụng điều trị",
       x = "1 - độ đặc hiệu (tỷ lệ dương tính giả)",
       y = "Độ nhạy (tỷ lệ dương tính thật)")
```

R

Đường cong ROC: mô hình sử dụng điều trị



Hình 5.3: Đường cong ROC của mô hình hồi quy logistic đa biến về việc sử dụng điều trị. Đường chéo nét đứt biểu thị một mô hình không có khả năng phân biệt (AUC = 0,5).

AUC bằng 0.71 (KTC 95% 0.68 đến 0.75): nếu chúng ta chọn ngẫu nhiên một bệnh nhân đang điều trị và một bệnh nhân không điều trị, mô hình gán xác suất cao hơn cho bệnh nhân đang điều trị trong khoảng 71% số lần. Đây là khả năng phân biệt chấp nhận được đối với một mô

hình có mục đích giải thích chứ không phải dự báo cho từng cá nhân.

Diễn giải lâm sàng

AUC khoảng 0,71 nghĩa là các yếu tố quyết định được đo lường giải thích một phần, nhưng còn xa mới là toàn bộ, lý do vì sao một số bệnh nhân sử dụng điều trị còn những người khác thì không. Mô hình hữu ích để hiểu quần thể; nó sẽ không đủ tốt để quyết định những bệnh nhân cụ thể nào cần hỗ trợ thêm. Cũng lưu ý rằng AUC được tính trên chính dữ liệu dùng để xây dựng mô hình, nên nó hơi lạc quan; một mô hình dự báo sẽ cần thẩm định nội bộ (internal validation), ví dụ bằng bootstrap (Harrell 2015).

5.9.3 Hiệu chuẩn và kiểm định Hosmer–Lemeshow

Khả năng phân biệt liên quan đến việc xếp hạng; *hiệu chuẩn* liên quan đến sự phù hợp. Một mô hình được hiệu chuẩn tốt dự báo xác suất sử dụng điều trị 30% cho một nhóm bệnh nhân thì sẽ thấy khoảng 30% trong số họ đang điều trị. Cách kiểm tra kinh điển là nhóm bệnh nhân theo xác suất dự báo, thường thành mười nhóm ("thập phân vị nguy cơ", deciles of risk), và so sánh số biến cố quan sát được O_g trong mỗi nhóm với số kỳ vọng $E_g = \sum_{i \in g} \hat{p}_i$.

Hosmer and Lemeshow (1980) đã kết hợp các phép so sánh này thành một thống kê đánh giá độ phù hợp (goodness-of-fit),

$$\hat{C} = \sum_{g=1}^G \frac{(O_g - E_g)^2}{E_g (1 - E_g / n_g)},$$

trong đó n_g là số bệnh nhân trong nhóm g . Nếu mô hình phù hợp, $\hat{C}$ tuân theo xấp xỉ phân phối χ^2 với $G - 2$ bậc tự do. Một giá trị p nhỏ cho thấy mô hình phù hợp kém. Kiểm định này có sẵn trong các gói bổ sung, nhưng tính trực tiếp cũng đơn giản, và điều đó cũng làm rõ nó thực sự làm gì.

```
calib <- tibble(y = model_full$y, p_hat = fitted(model_full)) |>
  mutate(decile = ntile(p_hat, 10)) |> # 10 nhóm cỡ bằng nhau
  group_by(decile) |>
  summarise(n = n(),
            mean_pred = mean(p_hat), # xác suất dự báo trung bình
            obs_prop = mean(y), # tỷ lệ quan sát
            expected = sum(p_hat), # E_g
            observed = sum(y)) # O_g

kable(calib, digits = 3,
      caption = paste("Số sử dụng điều trị quan sát và kỳ vọng theo",
                      "thập phân vị nguy cơ dự báo."))
```

```
hl_stat <- with(calib, sum((observed - expected)^2 /
                        (expected * (1 - expected / n))))
hl_df <- nrow(calib) - 2
hl_p <- pchisq(hl_stat, df = hl_df, lower.tail = FALSE)
c(statistic = round(hl_stat, 2), df = hl_df, p = round(hl_p, 3))
```

Bảng 5.7: Số sử dụng điều trị quan sát và kỳ vọng theo thập phân vị nguy cơ dự báo.

decile	n	mean_pred	obs_prop	expected	observed
1	100	0.159	0.200	15.90	20
2	100	0.257	0.280	25.67	28
3	99	0.319	0.253	31.57	25
4	99	0.371	0.354	36.69	35
5	99	0.426	0.485	42.16	48
6	99	0.476	0.424	47.11	42
7	99	0.538	0.535	53.22	53
8	99	0.610	0.566	60.38	56
9	99	0.676	0.727	66.97	72
10	99	0.781	0.788	77.33	78

```
#> statistic      df      p
#>      8.150    8.000  0.419
```

Trên cả mười nhóm, số quan sát và số kỳ vọng khớp nhau chặt chẽ, và thống kê Hosmer–Lemeshow bằng 8.15 với 8 bậc tự do ($p = 0.42$): không có bằng chứng về hiệu chuẩn kém. Thông tin tương tự dễ thấy hơn trong một đồ thị hiệu chuẩn.

```
ggplot(calib, aes(x = mean_pred, y = obs_prop)) +
  geom_abline(intercept = 0, slope = 1, linetype = "dashed",
             colour = "grey50") +
  geom_line(colour = "#0D7377") +
  geom_point(size = 2.5, colour = "#0D7377") +
  scale_x_continuous(labels = percent, limits = c(0, 1)) +
  scale_y_continuous(labels = percent, limits = c(0, 1)) +
  coord_equal() +
  labs(title = "Hiệu chuẩn theo thập phân vị nguy cơ dự báo",
       x = "Xác suất dự báo trung bình",
       y = "Tỷ lệ quan sát đang điều trị")
```


Lỗi thường gặp

Coi một kiểm định Hosmer–Lemeshow không có ý nghĩa thống kê là bằng chứng của một mô hình tốt. Kiểm định này có lực thống kê thấp ở mẫu nhỏ và, ở mẫu rất lớn, lại đánh dấu cả những sai lệch hiệu chuẩn không đáng kể; kết quả của nó cũng phụ thuộc vào số nhóm được chọn (Hosmer et al. 2013). Hãy sử dụng nó cùng với đồ thị hiệu chuẩn, và nhớ rằng hiệu chuẩn trên dữ liệu dùng để xây dựng mô hình nói lên rất ít về hiệu chuẩn trong một quần thể mới.

5.9.4 Các quan sát có ảnh hưởng

Một bệnh nhân bất thường, hoặc một vài bệnh nhân, có thể làm thay đổi đáng kể một ước lượng hồi quy. *Khoảng cách Cook* (Cook's distance) đo lường mức độ thay đổi của tất cả các giá trị ước lượng khi loại bỏ quan sát i ; `broom::augment()` tính nó cho mọi quan sát. Một ngưỡng sàng lọc thường dùng là $4/n$.

Hiệu chuẩn theo thập phân vị nguy cơ dự báo



Hình 5.4: Đồ thị hiệu chuẩn: tỷ lệ quan sát đang điều trị theo xác suất dự báo trung bình trong mười nhóm nguy cơ dự báo. Các điểm nằm trên đường nét đứt cho thấy hiệu chuẩn hoàn hảo.

```
aug_glm <- augment(model_full) # mỗi dòng = một bệnh nhân
cut_off <- 4 / nrow(aug_glm)
sum(aug_glm$.cooks > cut_off) # số vượt quá ngưỡng
```

```
#> [1] 17
```

```
max(aug_glm$.cooks) # khoảng cách Cook lớn nhất
```

```
#> [1] 0.01534
```

```
# 10 bệnh nhân có ảnh hưởng nhất là ai?
top10 <- order(aug_glm$.cooks, decreasing = TRUE)[1:10]
count(cc[top10, ], diabetes, treatment_uptake)
```

```
#>   diabetes treatment_uptake n
#> 1      No                Yes 2
#> 2      Yes                No  7
#> 3      Yes                Yes 1
```

17 trong số 992 bệnh nhân vượt quá ngưỡng, nhưng khoảng cách Cook lớn nhất chỉ là 0.015, thấp hơn nhiều so với giá trị 1 đôi khi được dùng để chỉ ra một quan sát thực sự chi phối. Những bệnh nhân có ảnh hưởng nhất là ai? Phần lớn trong mười giá trị lớn nhất thuộc về những bệnh nhân đái tháo đường *không* đang điều trị. Điều này hợp lý: chỉ 7 trong số 28 bệnh nhân đái tháo đường đã được chẩn đoán tăng huyết áp là không điều trị, nên mỗi người trong số họ mang rất nhiều thông tin về hệ số của đái tháo đường.

Điều gì xảy ra nếu chúng ta loại bỏ mười bệnh nhân này, như một nhà phân tích quá nhiệt tình có thể làm để "làm sạch" mô hình?

```
model_sens <- update(model_full, data = cc[-top10, ])
tibble(term = names(coef(model_full))[-1],
       full = exp(coef(model_full))[-1],
       without_top10 = exp(coef(model_sens))[-1]) |>
  mutate(full = round(full, 2), without_top10 = signif(without_top10, 3))
```

```
#> # A tibble: 11 × 3
#>   term                full without_top10
#>   <chr>              <dbl>         <dbl>
#> 1 age                1.03          1.03
#> 2 sexMale            0.74          0.754
#> 3 educationPrimary  1.39          1.36
#> 4 educationSecondary 1.92          1.98
#> 5 educationTertiary 2.44          2.46
#> 6 residenceUrban    1.87          1.94
#> 7 diabetesYes       3.56      15300000
#> 8 family_history_htn 1.91          1.88
#> 9 health_insuranceYes 2.05          2.1
#> 10 knowledge_score   1.1          1.1
#> 11 distance_to_facility_km 0.98        0.982
```

Phần lớn các OR hầu như không thay đổi, nhưng OR của đái tháo đường bùng nổ thành một

giá trị phi lý khoảng 15 triệu. Khi những bệnh nhân đái tháo đường không điều trị trong dữ liệu bị loại bỏ, *mọi* bệnh nhân đái tháo đường còn lại đều đang điều trị: khi đó đái tháo đường dự báo hoàn hảo biến kết cục. Đây là *tách biệt hoàn toàn* (complete separation; Mục 5.5), và ước lượng hợp lý cực đại của hệ số đái tháo đường không còn tồn tại. Ví dụ này mang lại hai bài học. Thứ nhất, các quan sát có ảnh hưởng thường là những bệnh nhân thật và giàu thông tin, không phải lỗi; xóa chúng có thể phá hủy chính thông tin mà một hệ số phụ thuộc vào. Thứ hai, các quan sát bị đánh dấu cần được *xem xét kỹ* (chúng là lỗi nhập liệu, hay là những bệnh nhân thật nhưng bất thường?), và mọi phân tích độ nhạy (sensitivity analysis) cần được báo cáo song song với phân tích chính chứ không thay thế nó.

5.10 Trình bày kết quả

5.10.1 Bảng hồi quy sẵn sàng cho công bố

Cách tiêu chuẩn để trình bày một mô hình hồi quy logistic đa biến trong bài báo là một bảng có, với mỗi biến dự báo, OR thô (đơn biến) và OR hiệu chỉnh (đa biến), mỗi OR kèm KTC 95% và giá trị p. Trình bày cả hai giúp người đọc thấy việc hiệu chỉnh làm thay đổi mỗi ước lượng đến mức nào. Sao chép các con số từ console sang trình soạn thảo văn bản vừa chậm vừa dễ sai sót; gtsummary xây dựng bảng trực tiếp từ các đối tượng mô hình (Sjoberg et al. 2021).

tbl_uvregression() xây dựng một mô hình đơn biến cho mỗi biến dự báo, tbl_regression() định dạng mô hình đa biến, và tbl_merge() đặt chúng cạnh nhau. Chúng ta xây dựng các mô hình đơn biến trên cùng 992 trường hợp đầy đủ (cc) để ước lượng thô và ước lượng hiệu chỉnh có thể so sánh trực tiếp với nhau.

```
# Nhãn dễ đọc cho các biến dự báo
labels_list <- list(
  age ~ "Tuổi (năm)",
  sex ~ "Giới",
  education ~ "Học vấn",
  residence ~ "Nơi cư trú",
  diabetes ~ "Đái tháo đường",
  family_history_htn ~ "Tiền sử gia đình bị tăng huyết áp",
  health_insurance ~ "Bảo hiểm y tế",
  knowledge_score ~ "Điểm kiến thức (mỗi điểm)",
  distance_to_facility_km ~ "Khoảng cách đến cơ sở (mỗi km)"
)

# OR đơn biến (thô), một mô hình cho mỗi biến dự báo
tbl_uni <- tbl_uvregression(
  data      = cc,
  method    = glm,
  y         = treatment_uptake,
  method.args = list(family = binomial),
  exponentiate = TRUE,
  label     = labels_list,
  hide_n    = TRUE
) |>
  modify_header(label ~ "***Đặc điểm***", estimate ~ "***cOR**",
                conf.low ~ "***KTC 95%***", p.value ~ "***Giá trị p**")

# OR đa biến (hiệu chỉnh) từ mô hình được xác định trước
```

```
tbl_multi <- tbl_regression(model_full, exponentiate = TRUE,
                           label = labels_list) |>
  modify_header(label ~ "***Đặc điểm***", estimate ~ "***aOR***",
                conf.low ~ "***KTC 95%***", p.value ~ "***Giá trị p***")

tbl_both <- tbl_merge(list(tbl_uni, tbl_multi),
                      tab_spanner = c("***Thô***", "***Hiệu chỉnh***"))

tbl_both |>
  as_kable(caption = paste("Tỷ số chênh thô và hiệu chỉnh cho việc sử dụng",
                           "điều trị tăng huyết áp (n = 992)."))
```

Bảng 5.8: Tỷ số chênh thô và hiệu chỉnh cho việc sử dụng điều trị tăng huyết áp (n = 992).

Đặc điểm	cOR	KTC 95%	Giá trị p	aOR	KTC 95%	Giá trị p
Tuổi (năm)	1.03	1.02, 1.04	<0.001	1.03	1.02, 1.04	<0.001
Giới						
Female	—	—		—	—	
Male	0.75	0.58, 0.97	0.029	0.74	0.56, 0.97	0.031
Học vấn						
None	—	—		—	—	
Primary	1.38	0.97, 1.98	0.078	1.39	0.95, 2.05	0.091
Secondary	1.88	1.28, 2.76	0.001	1.92	1.27, 2.90	0.002
Tertiary	2.11	1.32, 3.39	0.002	2.44	1.48, 4.06	<0.001
Nơi cư trú						
Rural	—	—		—	—	
Urban	1.87	1.46, 2.42	<0.001	1.87	1.40, 2.49	<0.001
Đái tháo đường						
No	—	—		—	—	
Yes	3.27	1.42, 8.44	0.008	3.56	1.46, 9.61	0.007
Tiền sử gia đình bị tăng huyết áp						
No	—	—		—	—	
Yes	1.65	1.27, 2.15	<0.001	1.91	1.44, 2.53	<0.001
Bảo hiểm y tế						
No	—	—		—	—	
Yes	1.67	1.28, 2.18	<0.001	2.05	1.54, 2.74	<0.001
Điểm kiến thức (mỗi điểm)	1.09	1.05, 1.13	<0.001	1.10	1.06, 1.14	<0.001
Khoảng cách đến cơ sở (mỗi km)	0.97	0.95, 0.99	0.003	0.98	0.96, 1.01	0.13

Bảng có bảy cột: đặc điểm, sau đó là OR, KTC 95% và giá trị p cho phân tích thô và phân tích hiệu chỉnh. Các nhóm tham chiếu được hiển thị bằng một dấu gạch ngang, nhắc người đọc rằng mỗi OR được so sánh với nhóm nào. Trong một bản thảo, bạn sẽ thêm chú thích: "cOR = tỷ số chênh thô; aOR = tỷ số chênh đã hiệu chỉnh theo tất cả các biến khác trong bảng; KTC = khoảng tin cậy. Phân tích trường hợp đầy đủ trên 992 trong số 1.089 bệnh nhân đã được chẩn đoán tăng huyết áp."

Thực hành tốt

Trong một bản thảo, hãy xuất cùng bảng đó sang Word hoặc HTML bằng `gtsummary::as_flex_table()` hoặc `as_gt()`, để các con số trong bài báo đến trực tiếp từ mã lệnh. Nếu

dữ liệu thay đổi, chạy lại script và bảng sẽ tự cập nhật. Báo cáo giá trị p với hai chữ số có nghĩa (và "<0,001" với các giá trị rất nhỏ), không bao giờ dùng dấu sao hay "NS" (không có ý nghĩa).

5.10.2 Biểu đồ rừng của các tỷ số chênh lệch chính

Một *biểu đồ rừng* (forest plot) hiển thị mỗi OR dưới dạng một điểm kèm một đoạn thẳng nằm ngang biểu thị khoảng tin cậy, và một đường tham chiếu thẳng đứng tại OR = 1. Vì OR là các tỷ số, trục hoành nên dùng thang **logarit**: trên thang tuyến tính, OR bằng 0,5 (giảm odds một nửa) sẽ trông gần 1 hơn nhiều so với OR bằng 2 (tăng gấp đôi odds), mặc dù hai tác động có cùng độ lớn, và các khoảng tin cậy sẽ trông bất đối xứng một cách giả tạo.

```
# Nhãn dễ đọc cho từng số hạng của mô hình
term_labels <- c(
  age = "Tuổi (mỗi năm)",
  sexMale = "Nam (so với nữ)",
  educationPrimary = "Tiểu học (so với không đi học)",
  educationSecondary = "Trung học (so với không đi học)",
  educationTertiary = "Sau trung học (so với không đi học)",
  residenceUrban = "Thành thị (so với nông thôn)",
  diabetesYes = "Đái tháo đường",
  family_history_htnYes = "Tiền sử gia đình THA",
  health_insuranceYes = "Bảo hiểm y tế",
  knowledge_score = "Điểm kiến thức (mỗi điểm)",
  distance_to_facility_km = "Khoảng cách (mỗi km)"
)


forest_df <- or_table |>
  filter(term != "(Intercept)") |>
  mutate(label = factor(term_labels[term],
    levels = rev(term_labels))) # giữ thứ tự mô hình

ggplot(forest_df, aes(x = estimate, y = label)) +
  geom_vline(xintercept = 1, linetype = "dashed", colour = "grey50") +
  geom_errorbar(aes(xmin = conf.low, xmax = conf.high),
    width = 0.25, colour = "#0D7377", orientation = "y") +
  geom_point(size = 2.6, colour = "#0D7377") +
  scale_x_log10(breaks = c(0.5, 0.75, 1, 1.5, 2, 3, 5, 10)) +
  labs(title = "Tỷ số chênh lệch chính cho việc sử dụng điều trị",
    x = "Tỷ số chênh lệch chính (thang log)", y = NULL)
```

Biểu đồ truyền tải các thông điệp chính chỉ trong một cái nhìn: tất cả các OR ngoại trừ của giới và khoảng cách đều nằm bên phải giá trị 1; phần lớn các khoảng tin cậy không chứa 1; khoảng tin cậy của đái tháo đường rộng hơn hẳn; và OR của khoảng cách nằm ngay bên trái 1 với khoảng tin cậy cắt qua giá trị này. Lưu ý rằng OR cho mỗi đơn vị của các biến liên tục trông nhỏ chỉ vì các đơn vị nhỏ; một biểu đồ rừng trộn lẫn OR theo đơn vị và OR theo nhóm cần ghi rõ điều đó trong nhãn, hoặc dùng các OR đã đổi thang đo.

5.11 Viết phần kết quả

Tỷ số chênh hiệu chỉnh cho việc sử dụng điều trị



Hình 5.5: Biểu đồ rừng của các tỷ số chênh hiệu chỉnh (khoảng tin cậy 95%) cho việc sử dụng điều trị từ mô hình hồi quy logistic đa biến ($n = 992$). Trục hoành dùng thang logarit; đường nét đứt đánh dấu $OR = 1$.

5.11.1 Cần báo cáo những gì

Tuyên bố STROBE (*Strengthening the Reporting of Observational Studies in Epidemiology* – Tăng cường báo cáo các nghiên cứu quan sát trong dịch tễ học) liệt kê các mục mà báo cáo của các nghiên cứu thuần tập, bệnh–chứng và cắt ngang cần có (Elm et al. 2007). Với một phân tích hồi quy, những mục phù hợp nhất là:

- **Đối tượng tham gia:** số người ở mỗi giai đoạn, bao gồm số người đủ tiêu chuẩn, số người được phân tích và lý do loại trừ (ở đây là 1.089 bệnh nhân đã được chẩn đoán, trong đó 992 người có dữ liệu đầy đủ).
- **Phương pháp thống kê:** mô hình, cách chọn biến, cách xử lý các biến liên tục, cách xử lý dữ liệu khuyết, và mọi phân tích độ nhạy.
- **Kết quả chính:** các ước lượng thô và hiệu chỉnh kèm độ chính xác (KTC 95%), nêu rõ đã hiệu chỉnh theo những yếu tố gây nhiễu nào và vì sao.
- **Ranh giới phân nhóm và đơn vị:** với các biến dự báo liên tục, đơn vị mà mỗi OR đề cập đến.
- **Các phân tích khác:** các tương tác đã được xem xét và các phân tích độ nhạy.

5.11.2 Một đoạn Phương pháp

> Chúng tôi sử dụng hồi quy logistic đa biến để ước lượng mối liên quan > giữa các đặc điểm của bệnh nhân và khả năng tiếp cận với việc sử dụng > điều trị ở người trưởng thành đã được chẩn đoán tăng huyết áp. Các biến > dự báo được xác định trước khi phân tích dựa trên y văn

và lập luận lâm sàng: tuổi, giới, học vấn, nơi cư trú, đài tháo đường, tiền sử gia đình > bị tăng huyết áp, bảo hiểm y tế, điểm kiến thức về tăng huyết áp và > khoảng cách đến cơ sở y tế. Các biến dự báo liên tục được mô hình hóa > dưới dạng số hạng tuyến tính sau khi kiểm tra tính phi tuyến bằng các số > hạng bậc hai. Kết quả được báo cáo dưới dạng tỷ số chênh (OR) kèm khoảng > tin cậy 95% theo hợp lý hồ sơ; mối liên quan tổng thể của các biến phân > loại được đánh giá bằng kiểm định tỷ số hợp lý. Khả năng phân biệt được > đánh giá bằng diện tích dưới đường cong ROC và hiệu chuẩn bằng kiểm định > Hosmer–Lemeshow. Các phân tích sử dụng các trường hợp đầy đủ và được thực > hiện bằng R phiên bản 4.6.

5.11.3 Một đoạn Kết quả

Đoạn văn dưới đây được viết bằng mã R nội dòng (inline R code), nên mọi con số đều lấy trực tiếp từ các đối tượng mô hình đã tạo ở trên.

> Trong số 1.089 người trưởng thành đã được chẩn > đoán tăng huyết áp, 508 người (46.6%) > đang được điều trị thuốc hạ huyết áp; 992 người có dữ liệu đầy > đủ và được đưa vào mô hình đa biến. Sau khi hiệu chỉnh lẫn nhau, việc sử > dụng điều trị có liên quan đến đài tháo đường (OR > 3.56, KTC 95% 1.46 đến 9.61), bảo hiểm y tế (OR > 2.05, KTC 95% 1.54 đến 2.74), tiền sử gia đình bị tăng huyết áp (OR > 1.91, KTC 95% 1.44 đến 2.53) và cư trú ở thành thị thay vì nông > thôn (OR 1.87, KTC 95% 1.40 đến 2.49). Odds sử dụng điều trị tăng theo > trình độ học vấn (kiểm định tỷ số hợp lý $p \Rightarrow 0.001$; OR của giáo dục sau trung học so với không đi học > 2.44, KTC 95% 1.48 đến 4.06), theo tuổi (OR cho mỗi 10 năm > 1.35, KTC 95% 1.23 đến 1.50) > và theo kiến thức về tăng huyết áp (OR cho mỗi 5 điểm > 1.60, KTC 95% 1.31 đến 1.96). > Nam giới có odds sử dụng điều trị thấp hơn nữ giới (OR 0.74, KTC 95% 0.56 đến 0.97). > Khoảng cách đến cơ sở y tế có liên quan đến tỷ lệ sử dụng điều trị thấp > hơn trong phân tích thô, nhưng sau khi hiệu chỉnh (chủ yếu theo nơi cư > trú), mối liên quan yếu hơn và tương thích với việc không có liên quan (OR > cho mỗi 5 km > 0.91, KTC 95% 0.81 đến 1.03). > Mô hình có khả năng phân biệt chấp nhận được (AUC > 0.71, KTC 95% 0.68 đến 0.75) > và không có bằng chứng về hiệu chuẩn kém (Hosmer–Lemeshow $p \Rightarrow 0.42$).

Hãy chú ý các đặc điểm của đoạn văn này. Nó bắt đầu với đối tượng tham gia và số người được phân tích. Mọi OR đều có KTC 95%, và nhóm tham chiếu được nêu rõ ("thành thị thay vì nông thôn", "nam giới ... so với nữ giới"). Các biến dự báo liên tục được báo cáo theo mức tăng có ý nghĩa. Một biến nhiều mức được tóm tắt bằng kiểm định LR tổng thể cùng với phép so sánh giàu thông tin nhất. Một kết quả không có ý nghĩa thống kê (khoảng cách) được báo cáo với ước lượng và khoảng tin cậy của nó, chứ không chỉ ghi "không có ý nghĩa". Và cách diễn đạt mô tả *mối liên quan*, không phải tác động.

Lỗi thường gặp

Khẳng định quá mức về quan hệ nhân quả. Đây là một nghiên cứu cắt ngang: phơi nhiễm và biến kết cục được đo cùng một thời điểm, nên chúng ta không thể biết, chẳng hạn, kiến thức dẫn đến điều trị hay điều trị (cùng với việc tư vấn đi kèm) dẫn đến kiến thức. Những từ như "tác động", "ảnh hưởng", "dẫn đến", "làm giảm" và "quyết định" hàm ý quan hệ nhân quả. Hãy ưu tiên "có liên quan đến", "có odds cao hơn" và "phổ biến hơn ở", và thảo luận về quan hệ nhân quả ngược và nhiễu tồn dư trong phần Bàn luận (Elm et al. 2007).

Diễn giải lâm sàng

Nếu các phát hiện này là thật, chúng sẽ chỉ ra một số nhóm có nguy cơ không được điều trị sau khi chẩn đoán: nam giới, người sống ở nông thôn, người không có bảo hiểm y tế, người ít được giáo dục chính quy và người có kiến thức kém về tăng huyết áp. Một số yếu tố này (độ bao phủ bảo hiểm, kiến thức) có khả năng thay đổi được thông qua chính sách và giáo dục sức khỏe. Tuy nhiên, hãy nhớ rằng dữ liệu trong cuốn sách này được mô phỏng cho mục đích giảng dạy: các kết quả minh họa phương pháp, không phải phát hiện lâm sàng thực tế.

5.11.4 Kết quả, diễn giải và bàn luận

Phần Kết quả báo cáo những gì đã tìm thấy: các con số, các khoảng tin cậy, và cách diễn đạt trung lập. Việc diễn giải các con số đó (ý nghĩa của chúng đối với bệnh nhân và dịch vụ), việc so sánh với các nghiên cứu trước, và các hạn chế thuộc về phần Bàn luận. Với phân tích này, phần hạn chế sẽ đề cập đến thiết kế cắt ngang (không có trình tự thời gian), việc sử dụng điều trị do bệnh nhân tự báo cáo, phân tích trường hợp đầy đủ, khả năng nhiễu tồn dư do các yếu tố không được đo lường như thu nhập hay mức độ nặng của tăng huyết áp, và tính cụm của bệnh nhân trong sáu cơ sở y tế. Cuối cùng, phần Bàn luận cần tránh nguy biện Bảng 2: các OR hiệu chỉnh là những mối liên quan được hiệu chỉnh lẫn nhau, không phải một bảng xếp hạng các tác động nhân quả (Westreich and Greenland 2013).

5.12 Báo cáo có thể tái lập

5.12.1 Vì sao khả năng tái lập lại quan trọng

Một phân tích là *có thể tái lập* (reproducible) nếu một người khác, với cùng dữ liệu và mã lệnh, thu được cùng kết quả (Peng 2011). Đây là một yêu cầu thấp hơn *khả năng lặp lại* (replicability; thu được kết quả nhất quán trên dữ liệu mới), nhưng đáng ngạc nhiên là nó thường không được đáp ứng. Những con số sao chép thủ công từ console vào bản thảo trở nên lỗi thời khi phân tích thay đổi; các hình được tạo bằng cách nhấp chuột qua các menu không thể tạo lại được; và một script chỉ chạy được trên máy tính của tác giả, với các tệp nằm ở `C:/Users/...`, thì không ai khác có thể kiểm tra. Trong nghiên cứu lâm sàng, nơi kết quả có thể thay đổi thực hành, khả năng lặp lại mọi bước từ dữ liệu thô đến con số được công bố là một phần của tính liêm chính khoa học.

5.12.2 Các nguyên tắc cho một phân tích có thể tái lập

Wilson et al. (2017) mô tả những thực hành "đủ tốt" mà bất kỳ nhà nghiên cứu nào cũng có thể áp dụng, và Peng (2011) mô tả một phổ từ chỉ có bài báo công bố đến mã lệnh và dữ liệu được liên kết đầy đủ và có thể thực thi. Với một phân tích như trong cuốn sách này, các thực hành thiết yếu như sau.

- **Giữ dữ liệu thô ở chế độ chỉ đọc.** Không bao giờ sửa tệp thô bằng tay. Mọi thao tác làm sạch được thực hiện bằng một script (Chương 2) ghi ra một tệp sạch riêng biệt, như cách `analysis_data.rds` đã được tạo.
- **Tổ chức dự án.** Dùng một thư mục cho mỗi dự án, mở dưới dạng một RStudio Project, với

các thư mục con như `Data/` (dữ liệu thô và sạch), `Scripts/` (các script phân tích được đánh số), `Resources/` hoặc `Output/` (các bảng và hình được tạo ra), và `Reports/` (các tài liệu R Markdown hoặc Quarto).

- **Dùng đường dẫn tương đối.** Tham chiếu đến các tệp tương đối với thư mục dự án ("`Data/analysis_data.rds`"), không bao giờ dùng đường dẫn tuyệt đối; gói `here` hữu ích khi các script nằm trong thư mục con.
- **Viết script cho mọi thứ.** Mọi bảng và hình nên được tạo ra bằng mã lệnh đã được lưu lại, không phải bằng các lệnh tương tác được gõ rồi bị lãng quên.
- **Đặt hạt giống ngẫu nhiên** (random seed). Mọi phân tích có sử dụng số ngẫu nhiên (bootstrap, gán giá trị đa bội, chia dữ liệu ngẫu nhiên, mô phỏng) phải gọi `set.seed()` để cho kết quả giống hệt nhau mỗi lần chạy.
- **Ghi lại môi trường phân mềm.** Báo cáo phiên bản của R và của các gói chính, vì kết quả và các thiết lập mặc định có thể thay đổi giữa các phiên bản.
- **Dùng hệ thống quản lý phiên bản** (version control, như Git) để lưu lịch sử thay đổi của mã lệnh và văn bản.

5.12.3 Đặt hạt giống: một ví dụ

Ước lượng hợp lý cực đại là tất định, nên `model_full` cho cùng các hệ số mỗi lần chạy. Các phương pháp lấy mẫu lại thì không. Ví dụ, một khoảng tin cậy bootstrap cho AUC rút các mẫu lại ngẫu nhiên từ các bệnh nhân.

```
set.seed(2026)
ci.auc(roc_obj, method = "bootstrap", boot.n = 500, progress = "none")
```

```
#> 95% CI: 0.682-0.747 (500 stratified bootstrap replicates)
```

```
set.seed(2026) # cùng hạt giống, nên cho chính xác cùng khoảng
ci.auc(roc_obj, method = "bootstrap", boot.n = 500, progress = "none")
```

```
#> 95% CI: 0.682-0.747 (500 stratified bootstrap replicates)
```

Khi chạy với cùng hạt giống, hai khoảng tin cậy bootstrap giống hệt nhau; với một hạt giống khác (hoặc không có hạt giống), chúng sẽ hơi khác nhau giữa các lần chạy. Cả hai đều gần với khoảng tin cậy DeLong giải tích đã tính trước đó.

5.12.4 Từ script đến báo cáo: R Markdown và Quarto

Công cụ mạnh mẽ nhất cho báo cáo có thể tái lập là *tài liệu động* (dynamic document), xen kẽ văn bản và mã lệnh trong một tệp duy nhất (Xie 2015). Trong một tài liệu R Markdown (`.Rmd`) hoặc Quarto (`.qmd`), văn bản được viết bằng Markdown và mã phân tích được đặt trong các *khối mã* (chunks). Khi tài liệu được kết xuất ("`knit`"), R chạy mọi khối mã trong một phiên mới và chèn kết quả (bảng, hình và con số) vào một báo cáo Word, PDF hoặc HTML. Chính cuốn sách này đã được tạo ra theo cách đó.

Một báo cáo phân tích tối thiểu có ba phần:

1. Một *phần đầu* (header, viết bằng YAML) với tiêu đề, tác giả, ngày và định dạng đầu ra, ví dụ output: word_document trong R Markdown hoặc format: docx trong Quarto.
2. Các *khối mã* nạp các gói và dữ liệu, xây dựng các mô hình và tạo ra các bảng và hình đúng như trong chương này.
3. *Văn bản* có mã R nội dòng, để các con số trong câu được tính toán chứ không phải gõ tay. Đoạn Kết quả ở Mục 5.11 đã được viết theo cách này: một biểu thức nội dòng như `nrow(dx)`, đặt giữa các dấu backtick sau chữ `r`, được thay bằng giá trị của nó (1089) khi tài liệu được kết xuất.

Vì báo cáo được tạo lại từ dữ liệu mỗi lần, một chỉnh sửa trong script làm sạch, hoặc một bộ dữ liệu được cập nhật, sẽ tự động lan tỏa đến mọi con số, bảng và hình. Không có bước nào mà một con số có thể bị sao chép sai.

Mã lệnh dưới đây cho thấy cách lưu các kết quả từ một script. Trong một dự án thực tế, chúng sẽ được lưu vào một thư mục đầu ra; ở đây chúng được ghi vào một thư mục tạm thời để không có gì trong dự án bị thay đổi.

```

out_dir <- tempdir()      # trong một dự án: "Resources" hoặc "Output"

# Bảng hồi quy và dữ liệu biểu đồ rừng dưới dạng CSV
write_csv(or_table, file.path(out_dir, "regression_table.csv"))

# Biểu đồ rừng dưới dạng ảnh PNG độ phân giải cao
forest_plot <- ggplot(forest_df, aes(x = estimate, y = label)) +
  geom_vline(xintercept = 1, linetype = "dashed") +
  geom_errorbar(aes(xmin = conf.low, xmax = conf.high), width = 0.25,
                orientation = "y") +
  geom_point() +
  scale_x_log10()
ggsave(file.path(out_dir, "forest_plot.png"), forest_plot,
        width = 7, height = 5, dpi = 300)

list.files(out_dir, pattern = "regression_table|forest_plot")

#> [1] "forest_plot.png"      "regression_table.csv"

```

5.12.5 Ghi lại môi trường phần mềm

`sessionInfo()` in ra phiên bản R, hệ điều hành và mọi gói đã nạp kèm phiên bản của chúng. Trong một báo cáo, bạn sẽ đưa nó vào phụ lục hoặc tệp bổ sung, ví dụ bằng `writeLines(capture.output(sessionInfo()), "session_info.txt")`. Kết quả đầy đủ khá dài; thông tin thiết yếu được trình bày dưới đây.

```

R.version.string

#> [1] "R version 4.6.1 (2026-06-24 ucrt)"

pkgs <- c("tidyverse", "broom", "gtsummary", "car", "pROC", "ggplot2")
tibble(package = pkgs,

```

```
version = map_chr(pkgs, \(p) as.character(packageVersion(p)))
```

```
#> # A tibble: 6 × 2
#>   package version
#>   <chr>    <chr>
#> 1 tidyverse 2.0.0
#> 2 broom     1.0.13
#> 3 gtsummary 2.5.1
#> 4 car       3.1.5
#> 5 pROC      1.19.0.1
#> 6 ggplot2   4.0.3
```

Thực hành tốt

Trước khi nộp bài báo, hãy khởi động lại R, xóa sạch không gian làm việc (workspace), và chạy (hoặc kết xuất) toàn bộ phân tích từ dữ liệu thô đến báo cáo cuối cùng trong một lần. Nếu nó chạy không lỗi và tái tạo được mọi con số trong bản thảo, phân tích của bạn có thể tái lập. Nếu không, tốt hơn là bạn phát hiện ra ngay bây giờ thay vì để người phản biện phát hiện sau này.

5.13 Tóm tắt

Chương này đã kết hợp các kỹ năng của các chương trước để trả lời câu hỏi chính của nghiên cứu bằng các mô hình hồi quy. Hồi quy tuyến tính mô hình hóa trung bình của một biến kết cục liên tục như một hàm tuyến tính của nhiều biến dự báo, được ước lượng bằng phương pháp bình phương tối thiểu; các hệ số của nó là hiệu số trung bình khi giữ cố định các biến dự báo khác, và các giả định của nó được kiểm tra bằng đồ thị phần dư. Với biến kết cục nhị phân, hồi quy logistic mô hình hóa log-odds như một hàm tuyến tính của các biến dự báo, được ước lượng bằng hợp lý cực đại; hàm mũ của các hệ số là tỷ số chênh, chỉ xấp xỉ tỷ số nguy cơ khi biến kết cục hiếm gặp.

Chúng ta đã xây dựng một mô hình hồi quy logistic đa biến được xác định trước cho việc sử dụng điều trị ở 992 bệnh nhân đã được chẩn đoán tăng huyết áp và có dữ liệu đầy đủ, đọc từng dòng kết quả `summary()`, chuyển các hệ số thành tỷ số chênh kèm khoảng tin cậy hợp lý hồ sơ, đổi thang đo của các biến dự báo liên tục sang các mức tăng có ý nghĩa, và kiểm định học vấn như một tổng thể bằng kiểm định tỷ số hợp lý. So sánh ước lượng thô và hiệu chỉnh cho thấy mối liên quan bề ngoài giữa khoảng cách và việc sử dụng điều trị phần lớn được giải thích bởi nơi cư trú, một ví dụ rõ ràng về nhiễu, trong khi những thay đổi của OR đối với tiền sử gia đình và bảo hiểm một phần phản ánh tính không thể gộp. Mô hình có đủ số biến cố trên mỗi biến, không có đa cộng tuyến, không có bằng chứng về tính phi tuyến hay hiệu chuẩn kém, và có khả năng phân biệt chấp nhận được. Cuối cùng, chúng ta đã trình bày kết quả dưới dạng một bảng gộp ước lượng thô và hiệu chỉnh và một biểu đồ rừng, viết các đoạn Phương pháp và Kết quả theo STROBE, và thấy cách tài liệu động, hạt giống ngẫu nhiên và việc ghi lại môi trường phần mềm giúp toàn bộ phân tích có thể tái lập.

Điểm chính

- Quyết định mục đích của mô hình (mô tả, dự báo hay giải thích) và các biến dự báo của nó trước khi xem dữ liệu biến kết cục.

- Trong hồi quy logistic, $\exp(\beta)$ là tỷ số chênh ứng với mức tăng một đơn vị, khi giữ cố định các biến dự báo khác; hãy báo cáo các biến dự báo liên tục theo mức tăng có ý nghĩa lâm sàng, $\exp(c\beta)$.
- Tỷ số chênh phóng đại tỷ số nguy cơ khi biến kết cục phổ biến; hãy nói "odds", và bổ sung xác suất dự báo hoặc tỷ số nguy cơ khi người đọc cần thông tin về nguy cơ.
- Báo cáo số bệnh nhân được phân tích: `glm()` âm thầm loại bỏ bất kỳ ai có giá trị khuyết ở bất kỳ biến nào trong mô hình.
- Dùng kiểm định tỷ số hợp lý (`drop1()`, `anova(test = "LRT")`) cho các factor nhiều mức và để so sánh các mô hình lồng nhau được xây dựng trên cùng các bệnh nhân.
- Sự thay đổi từ OR thô sang OR hiệu chỉnh có thể phản ánh nhiều, nhưng OR có tính không thể gộp; hãy lập luận theo quan hệ nhân quả, và không diễn giải mọi OR hiệu chỉnh như một tác động nhân quả (ngụy biện Bảng 2).
- Tránh chọn biến từng bước trong các mô hình giải thích; kiểm tra số biến cố trên mỗi biến, đa cộng tuyến (VIF), tính tuyến tính, khả năng phân biệt (AUC), hiệu chuẩn và các quan sát có ảnh hưởng.
- Trình bày OR thô và hiệu chỉnh kèm KTC 95% trong một bảng `gtsummary` và một biểu đồ rừng với thang log; viết kết quả dưới dạng mối liên quan, theo STROBE.
- Làm cho phân tích có thể tái lập: script, đường dẫn tương đối, `set.seed()`, tài liệu động và việc ghi lại phiên bản phần mềm.

5.14 Đọc thêm

- Hosmer et al. (2013), *Applied Logistic Regression*: tài liệu tham khảo chuẩn về hồi quy logistic, trình bày sâu về xây dựng mô hình, diễn giải tỷ số chênh, độ phù hợp và chẩn đoán mô hình.
- Vittinghoff et al. (2012), *Regression Methods in Biostatistics*: trình bày rõ ràng, dựa trên ví dụ, về hồi quy tuyến tính, logistic, Poisson và Cox, với một chương xuất sắc về việc chọn biến dự báo cho các mục đích khác nhau.
- Harrell (2015), *Regression Modeling Strategies*: hướng dẫn kinh điển về xây dựng mô hình dự báo một cách có trách nhiệm, bao gồm các lập luận phản đối chọn biến từng bước, spline, thẩm định và hiệu chuẩn.
- Westreich and Greenland (2013) và VanderWeele (2019): hai bài báo ngắn, dễ đọc về cách chọn các biến hiệu chỉnh và cách diễn giải (và không nên diễn giải) các hệ số của một mô hình đa biến.
- Elm et al. (2007), tuyên bố STROBE: bảng kiểm cần tuân theo khi viết báo cáo bất kỳ nghiên cứu quan sát nào.

5.15 Bài tập

Bài tập 5.1

Sử dụng toàn bộ `analysis_data` (cả 1.500 người trưởng thành), xây dựng mô hình hồi quy tuyến tính của huyết áp tâm thu (`sbp_mmhg`) theo `age`, `bmi` và `sex`.

1. Báo cáo hệ số của tuổi cho mỗi 10 năm, kèm KTC 95%.
2. Diễn giải hệ số của `sexMale` trong một câu.
3. Mô hình giải thích được bao nhiêu phần biến thiên của SBP?
4. Vẽ đồ thị phần dư theo giá trị ước lượng. Các giả định có hợp lý không?

Bài tập 5.2

Trong số các bệnh nhân đã được chẩn đoán (`dx`), lập bảng chéo `family_history_htn` theo `treatment_uptake`.

1. Tính tỷ lệ và odds sử dụng điều trị ở mỗi nhóm, và tỷ số chênh thô.
2. Xây dựng `glm(treatment_uptake ~ family_history_htn, family = binomial)` và xác nhận rằng `exp(coef())` cho cùng OR.
3. Tính tỷ số nguy cơ thô và so sánh với OR. Vì sao chúng khác nhau? Kiểm tra câu trả lời của bạn bằng công thức của Zhang và Yu.

Bài tập 5.3

Từ `model_full`, tính tỷ số chênh hiệu chỉnh và KTC 95% cho:

1. mức tăng 10 năm tuổi;
2. mức tăng 5 điểm kiến thức;
3. mức tăng 10 km khoảng cách đến cơ sở y tế.

Bạn cho rằng mức tăng nào trong số này có ý nghĩa lâm sàng nhất, và vì sao mức tăng cần được chọn trước khi phân tích?

Bài tập 5.4

Hãy tìm hiểu xem mối liên quan giữa bảo hiểm y tế và việc sử dụng điều trị có bị nhiễu hay không.

1. Sử dụng dữ liệu trường hợp đầy đủ `cc`, xây dựng mô hình thô cho `health_insurance` và so sánh OR của nó với OR hiệu chỉnh từ `model_full`. Tính phần trăm thay đổi của log OR.
2. Mô tả bằng lời một sơ đồ nhân quả cho bảo hiểm và việc sử dụng điều trị. Những biến nào khác trong mô hình có thể là yếu tố gây nhiễu, và có biến nào có thể là biến trung gian không?
3. Sự thay đổi bạn quan sát được giải thích tốt nhất bởi nhiễu hay bởi tính không thể

gộp? Hãy giải thích câu trả lời của bạn.

Bài tập 5.5

Học vấn là một biến có thứ tự.

1. Dùng `drop1()` để thu được kiểm định tỷ số hợp lý cho học vấn trong `model_full`, và nêu giả thuyết không mà nó kiểm định.
2. Tạo một phiên bản dạng số của học vấn (0 = None, 1 = Primary, 2 = Secondary, 3 = Tertiary) và xây dựng lại mô hình với biến này thay cho factor. Diễn giải OR "cho mỗi mức học vấn".
3. So sánh hai mô hình bằng AIC. Bạn sẽ báo cáo mô hình nào, và vì sao?

Bài tập 5.6

Bệnh nhân được tuyển chọn từ sáu cơ sở y tế.

1. Thêm `facility` vào `model_full` và kiểm định nó bằng kiểm định tỷ số hợp lý.
2. Việc thêm cơ sở y tế có làm thay đổi OR hiệu chỉnh nào khác hơn 10% không?
3. So sánh AUC của hai mô hình. Bạn kết luận gì về vai trò của cơ sở y tế trong phân tích này?

Bài tập 5.7

Một nhà kinh tế y tế cho rằng bảo hiểm y tế có thể quan trọng hơn đối với bệnh nhân nông thôn, những người phải chịu chi phí đi lại cao hơn.

1. Thêm tương tác `health_insurance:residence` vào `model_full` và kiểm định nó bằng kiểm định tỷ số hợp lý.
2. Từ mô hình tương tác, tính OR của bảo hiểm riêng cho bệnh nhân nông thôn và bệnh nhân thành thị.
3. Viết hai câu báo cáo kết quả, như bạn sẽ viết trong một bài báo.

Bài tập 5.8

Một biến kết cục phụ là kiểm soát huyết áp (`bp_controlled`), chỉ được xác định ở những bệnh nhân đang điều trị.

1. Giới hạn dữ liệu ở các bệnh nhân đã được chẩn đoán có `treatment_uptake == "Yes"` và lập bảng `bp_controlled`. Có bao nhiêu biến cố?
2. Theo hướng dẫn 10 biến cố trên mỗi biến, một mô hình logistic cho kiểm soát huyết áp có thể hỗ trợ bao nhiêu tham số?
3. Xác định trước và xây dựng một mô hình với không quá số tham số đó (ví dụ tuổi, giới, BMI và tuân thủ điều trị). Báo cáo các OR hiệu chỉnh kèm KTC 95% và AUC.

4. Viết một đoạn Kết quả ngắn (khoảng 100 từ) báo cáo các phát hiện một cách phù hợp, bao gồm cả những hạn chế do số biến cố ít.

Lời giải bài tập

Phụ lục này trình bày lời giải chi tiết cho các bài tập ở cuối mỗi chương. Hãy tự làm từng bài trước khi đọc lời giải: thường có nhiều cách viết mã đúng, và việc so sánh cách làm của bạn với cách làm của chúng tôi là một phần của quá trình học.

A.1 Chương 1: Bắt đầu với R và RStudio

Bài tập 1.1

Chúng ta lưu mỗi số đo vào một đối tượng có tên chứa đơn vị đo, rồi viết các công thức dựa trên những đối tượng đó. Chiều cao phải được đổi từ centimét sang mét trước khi bình phương.

```
weight_kg <- 82
height_cm <- 168
sbp <- 148
dbp <- 96

bmi <- weight_kg / (height_cm / 100)^2
round(bmi, 1)
```

```
#> [1] 29.1
```

```
map <- dbp + (sbp - dbp) / 3
round(map, 1)
```

```
#> [1] 113.3
```

```
# Không có ngoặc đơn: ^ được tính trước, vì vậy biểu thức này là
# weight / (height / 100^2) = 82 / (168 / 10000)
weight_kg / height_cm / 100^2
```

```
#> [1] 4.881e-05
```

BMI của bệnh nhân là 29,1 kg/m², ngay dưới ngưỡng quy ước của béo phì (30 kg/m²), và MAP là 113,3 mmHg. Nếu không có ngoặc đơn, R tính 100² trước (vì lũy thừa có mức ưu tiên cao nhất), rồi chia từ trái sang phải, nên biểu thức trở thành 82 / 168 / 10.000, một con số vô nghĩa gần bằng không. Không có thông báo lỗi nào cảnh báo bạn: đặt sai ngoặc sẽ âm thầm tạo ra

những con số sai.

Bài tập 1.2

```
dbp <- c(88, 92, 79, 101, 95, NA, 84, 90)
length(dbp)
```

R

```
#> [1] 8
```

```
mean(dbp) # NA: có một giá trị chưa biết
```

R

```
#> [1] NA
```

```
mean(dbp, na.rm = TRUE) # trung bình của 7 giá trị quan sát được
```

R

```
#> [1] 89.86
```

```
sum(dbp >= 90, na.rm = TRUE) # số lần đo >= 90
```

R

```
#> [1] 4
```

```
mean(dbp >= 90, na.rm = TRUE) # tỷ lệ trong số các lần đo quan sát được
```

R

```
#> [1] 0.5714
```

```
dbp[3:5]
```

R

```
#> [1] 79 101 95
```

```
dbp[!is.na(dbp)]
```

R

```
#> [1] 88 92 79 101 95 84 90
```

Vectơ có tám phần tử, trong đó một phần tử bị khuyết. Không có `na.rm = TRUE`, `mean()` trả về `NA`, vì trung bình của một tập hợp có chứa một giá trị chưa biết thì bản thân nó cũng chưa biết; có `na.rm = TRUE`, R tính trung bình của bảy giá trị quan sát được (89,9 mmHg). Bốn lần đo đạt ít nhất 90 mmHg, tức là 4 trong 7 lần đo quan sát được, hay 57%. Lưu ý rằng phép so sánh `dbp >= 90` cho ra `NA` ở lần đo bị khuyết, vì vậy cũng cần `na.rm = TRUE` trong `sum()` và `mean()`. Chỉ số logic `!is.na(dbp)` ("không bị khuyết") giữ lại bảy lần đo quan sát được.

Bài tập 1.3

```
glucose <- c("5.4", "6.1", "<2.0", "7.3", "999", "4.8")
class(glucose)
```

R

```
#> [1] "character"
```

```
glucose_num <- as.numeric(glucose)
glucose_num
```

R

```
#> [1] 5.4 6.1 NA 7.3 999.0 4.8
```

```
mean(glucose_num, na.rm = TRUE)
```

R

```
#> [1] 204.5
```

```
mean(glucose_num[glucose_num != 999], na.rm = TRUE)
```

R

```
#> [1] 5.9
```

Vectơ có kiểu ký tự vì các giá trị của nó được viết trong dấu nháy; và ngay cả khi không có dấu nháy, giá trị "<2.0" không thể là một con số, vì vậy một cột chứa nó sẽ được đọc thành văn bản. `as.numeric()` chuyển đổi thành công các chữ số nhưng biến "<2.0" thành NA (kèm cảnh báo "NAs introduced by coercion"), vì "nhỏ hơn 2,0" không phải là một con số. Đó là một sự mất mát thông tin: kết quả được biết là thấp, chứ không phải là chưa biết. Giá trị 999 gần như chắc chắn là một mã giá trị khuyết, vì glucose lúc đói 999 mmol/L là không thể có. Nếu để nguyên, nó đẩy trung bình của năm giá trị số lên 204,5 mmol/L; nếu bỏ nó đi, trung bình của bốn giá trị thật là 5,9 mmol/L.

Bài tập 1.4

```
htn <- read_csv("Data/hypertension_phc_raw.csv")
htn_xl <- read_excel("Data/hypertension_phc_raw.xlsx", sheet = "data")
```

R

```
dim(htn)
```

```
#> [1] 1503 36
```

```
dim(htn_xl)
```

R

```
#> [1] 1503 36
```

```
identical(names(htn), names(htn_xl))
```

R

```
#> [1] TRUE
```

```
n_distinct(htn$patient_id)
```

```
#> [1] 1500
```

Cả hai đối tượng đều có 1.503 dòng và 36 cột, với tên cột giống hệt nhau. Nghiên cứu đã tuyển chọn 1.500 bệnh nhân, và có đúng 1.500 mã bệnh nhân khác nhau, vì vậy có ba mã xuất hiện hai lần: tệp chứa ba bản ghi trùng lặp, cần được loại bỏ trước khi phân tích (Chương 2).

Bài tập 1.5

```
glimpse(select(htn, age, sbp_mmhg, bmi, sex, facility, education,
               diabetes, treatment_uptake, enroll_date))
```

```
#> Rows: 1,503
#> Columns: 9
#> $ age          <dbl> 74, 56, 54, 33, 86, 70, 45, 59, 46, 61, 70, 56, 45...
#> $ sbp_mmhg     <dbl> 140, 185, 147, 124, 131, 153, 162, 108, 152, 127, ...
#> $ bmi          <dbl> 22.6, 26.7, 21.4, 28.4, 21.6, 31.6, NA, 25.2, 33.0...
#> $ sex          <chr> "Female", "Female", "Female", "Female", "Male", "M...
#> $ facility     <chr> "Igoma HC", "Kisesa HC", "Bugando PHC", "Ilemela H...
#> $ education    <chr> "Primary", "Primary", "None", "Primary", "Primary"...
#> $ diabetes     <chr> "No", "No", "No", "No", "0", "No", "0", "No", "0"...
#> $ treatment_uptake <chr> "Yes", "No", "N", "Yes", "No", "No", "1", "No", "0...
#> $ enroll_date  <chr> "01/02/2024", "2024-09-03", "2024-11-26", "2024-10...
```

Các biến số (<dbl>) gồm age, sbp_mmhg và bmi (cùng với height_cm, weight_kg và các giá trị xét nghiệm). Các biến ký tự (<chr>) gồm sex, facility và education. Các biến diabetes và treatment_uptake (cũng như health_insurance, family_history_htn và htn_diagnosed) đáng lẽ phải là factor Yes/No, nhưng chúng trộn lẫn các mã "Yes"/"No", "Y"/"N" và "1"/"0"; vì "Yes" không thể là một con số, readr lưu toàn bộ cột dưới dạng văn bản. enroll_date có kiểu ký tự vì các giá trị của nó dùng những định dạng khác nhau ("01/02/2024", "2024-09-03"), nên readr không thể nhận ra một định dạng ngày duy nhất và giữ nguyên văn bản.

Bài tập 1.6

```
summary(select(htn, sbp_mmhg, dbp_mmhg, height_cm))
```

```
#>      sbp_mmhg      dbp_mmhg      height_cm
#> Min.   : 0      Min.   : 5.0      Min.   : 17
#> 1st Qu.:126      1st Qu.: 79.0      1st Qu.:158
#> Median :139      Median : 86.0      Median :164
#> Mean   :140      Mean   : 85.9      Mean   :164
#> 3rd Qu.:153      3rd Qu.: 93.0      3rd Qu.:169
#> Max.   :700      Max.   :121.0      Max.   :193
```

```
table(htn$diabetes)
```

R

```
#>
#>      0      1      N      No      Y      Yes
#> 230     7    143   1095     4     24
```

```
table(htn$htn_diagnosed)
```

R

```
#>
#>      0      1      N      No      Y      Yes
#>  73   158    44   296   110   822
```

```
sum(is.na(htn$weight_kg))
```

R

```
#> [1] 45
```

Huyết áp tâm thu dao động từ 0 đến 700 mmHg: cả hai giá trị cực trị đều không thể có. Huyết áp tâm trương dao động từ 5 đến 121 mmHg; giá trị nhỏ nhất 5 mmHg là không hợp lý. Chiều cao dao động từ 17 đến khoảng 193 cm; 17 cm là không thể có ở người trưởng thành và có lẽ là 170 cm bị đặt sai dấu thập phân. Cả `diabetes` và `htn_diagnosed` đều dùng sáu mã khác nhau (0, 1, N, No, Y, Yes) cho điều đáng lẽ chỉ là hai nhóm. Cuối cùng, có 45 giá trị của `weight_kg` bị khuyết.

Bài tập 1.7

```
htn |>
  filter(facility == "Nyamagana PHC") |>
  mutate(map_mmhg = round((sbp_mmhg + (sbp_mmhg - dbp_mmhg) / 3, 1)) |>
  select(patient_id, age, sbp_mmhg, dbp_mmhg, map_mmhg) |>
  arrange(desc(map_mmhg)) |>
  head(5)
```

R

```
#> # A tibble: 5 × 5
#>   patient_id age sbp_mmhg dbp_mmhg map_mmhg
#>   <chr>      <dbl>   <dbl>   <dbl>   <dbl>
#> 1 PHC-0741    63     171     116    134.3
#> 2 PHC-1014    59     149     119    129
#> 3 PHC-0810    65     183     102    129
#> 4 PHC-0701    62     163     110    127.7
#> 5 PHC-1106    53     159     109    125.7
```

```
htn |>
  filter(diabetes == "Yes") |>
  count(facility)
```

R


```
#> # A tibble: 6 × 2
#>   facility      n
#>   <chr>      <int>
```

```
#> 1 Bugando PHC      6
#> 2 Buzuruga PHC     3
#> 3 Igoma HC         3
#> 4 Ilemela HC       6
#> 5 Kisesa HC        2
#> 6 Nyamagana PHC    4
```

Các giá trị MAP cao nhất tại Nyamagana PHC nằm trong khoảng từ 126 đến 134 mmHg, thuộc về những bệnh nhân có huyết áp tâm thu từ 149 đến 183 mmHg và huyết áp tâm trương trên 100 mmHg. Đây là những giá trị cao nhưng có thể xảy ra trên lâm sàng (tăng huyết áp nặng), vì vậy, khác với SBP 700 mmHg, chúng không nên bị coi là lỗi. Chuỗi pipe thứ hai đếm các bản ghi có giá trị `diabetes` chính xác là "Yes". Tổng cộng chỉ có 24 bản ghi được mã hóa là "Yes", trong khi Bài tập 1.6 cho thấy còn 11 bản ghi khác được mã hóa là "1" hoặc "Y", vì vậy một phép đếm dựa trên một cách viết duy nhất sẽ ước tính thấp số bệnh nhân đái tháo đường gần một phần ba (24 thay vì 35). Đây thêm một lý do nữa để chuẩn hóa các mã trước khi tiến hành bất kỳ phân tích nào.

Bài tập 1.8

```
ggplot(htn, aes(x = sbp_mmhg)) +  
  geom_histogram(binwidth = 10, fill = "#1F6F8B", colour = "white") +  
  labs(x = "Huyết áp tâm thu (mmHg)", y = "Số bệnh nhân")
```



Hình A.1: Biểu đồ tần suất của huyết áp tâm thu trong dữ liệu thô ($n = 1.503$). Hai giá trị không thể có (0 và 700 mmHg) kéo giãn trục hoành và nén phân phối thực vào một dải hẹp.


```
htn_plausible <- htn |>  
  filter(sbp_mmhg >= 60, sbp_mmhg <= 260)  
nrow(htn) - nrow(htn_plausible) # số bản ghi bị loại bỏ
```

```
#> [1] 2
```

```
summary(htn_plausible$sbp_mmhg)
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#>       90    126    139     139    153    201
```

```
ggplot(htn_plausible, aes(x = sbp_mmhg)) +
  geom_histogram(binwidth = 5, fill = "#1F6F8B", colour = "white") +
  labs(x = "Huyết áp tâm thu (mmHg)", y = "Số bệnh nhân")
```



Hình A.2: Biểu đồ tần suất của huyết áp tâm thu sau khi chỉ giữ lại các giá trị hợp lý từ 60 đến 260 mmHg. Phân phối có một đỉnh và hơi lệch phải, tập trung quanh 140 mmHg.

Trong biểu đồ tần suất thứ nhất, hai giá trị cực trị buộc trục hoành trải từ 0 đến 700 mmHg, nên dữ liệu thực chỉ chiếm một dải hẹp và khó thấy được hình dạng của chúng. Việc lọc đã loại bỏ hai bản ghi (các giá trị 0 và 700 mmHg; không có giá trị SBP nào bị khuyết, nên không mất thêm dòng nào). Các giá trị hợp lý tạo thành một phân phối có một đỉnh, tập trung quanh 139 mmHg (trung vị), với phần lớn các lần đo nằm trong khoảng từ 100 đến 190 mmHg và một đuôi hơi dài hơn về phía huyết áp cao. Giá trị hợp lý nhỏ nhất là 90 mmHg và lớn nhất là 201 mmHg. Chưa đến một nửa số bệnh nhân có huyết áp tâm thu từ 140 mmHg trở lên (trung vị là 139 mmHg), đúng như mong đợi ở một quần thể có nhiều bệnh nhân tăng huyết áp. Trong thực tế, các giá trị không hợp lý nên được đặt thành giá trị khuyết trong một bước làm sạch có ghi chép rõ ràng thay vì bị lặng lẽ lọc bỏ, như sẽ trình bày trong Chương 2.

A.2 Chương 2: Tìm hiểu và làm sạch dữ liệu lâm sàng

Các lời giải dưới đây bắt đầu từ tệp thô hoặc từ tệp phân tích đã làm sạch, tùy theo yêu cầu của từng bài tập. Chúng ta nạp các gói và cả hai bộ dữ liệu một lần.

```

library(tidyverse)
library(lubridate)

na_codes <- c("", "NA", "999", "-99")
raw_default <- read_csv("Data/hypertension_phc_raw.csv")
raw <- read_csv("Data/hypertension_phc_raw.csv", na = na_codes)
analysis_data <- readRDS("Data/analysis_data.rds")

# Hàm trợ giúp Yes/No từ Mục 2.6
to_yesno <- function(x) {
  x <- str_to_lower(str_trim(as.character(x)))
  case_when(
    x %in% c("yes", "y", "1", "true") ~ "Yes",
    x %in% c("no", "n", "0", "false") ~ "No",
    TRUE ~ NA_character_
  )
}

```

Bài tập 2.1

Chúng ta viết một hàm tóm tắt nhỏ và áp dụng nó cho cả hai lần nhập, để hai dòng của kết quả có thể so sánh trực tiếp với nhau.

```

# 1-2. Glucose lúc đói theo hai cách nhập
glucose_summary <- function(d) {
  summarise(d,
    mean = mean(fasting_glucose_mmol_l, na.rm = TRUE),
    median = median(fasting_glucose_mmol_l, na.rm = TRUE),
    max = max(fasting_glucose_mmol_l, na.rm = TRUE),
    n_missing = sum(is.na(fasting_glucose_mmol_l)))
}

bind_rows(default = glucose_summary(raw_default),
  declared = glucose_summary(raw), .id = "import")

```

```

#> # A tibble: 2 × 5
#>   import    mean median    max n_missing
#>   <chr>    <dbl> <dbl> <dbl>    <int>
#> 1 default  32.521    5.4  999      35
#> 2 declared  5.4489    5.4  10.1     75

```

Với cách nhập mặc định, 40 giá trị được mã hóa 999 bị coi là nồng độ glucose thật. **Trung bình** là thống kê tóm tắt bị ảnh hưởng nhiều nhất: nó tăng từ 5,4 lên 32,5 mmol/L, vì trung bình sử dụng độ lớn của mọi giá trị và một vài giá trị cực lớn chi phối nó. **Giá trị lớn nhất** cũng sai (999 thay vì 10,1). **Trung vị** không thay đổi, vẫn là 5,4, vì 40 giá trị canh gác, dù cực trị, chỉ chiếm 2,7 phần trăm số giá trị và không làm dịch chuyển phần giữa của phân phối; tính vững này là một lý do khiến trung vị được ưu tiên với dữ liệu lệch. Cách nhập mặc định báo cáo 35 giá trị khuyết và cách nhập có khai báo mã báo cáo 75, chênh lệch chính là 40 giá trị canh gác.

Với câu hỏi 3, chúng ta nhập dữ liệu chỉ với các mã khuyết tiêu chuẩn và chuyển 999 thành NA riêng trong cột glucose, bằng `na_if()`.

```
# 3. Chỉ coi 999 là khuyết trong cột mà nó là giá trị cạnh gác
raw_selective <- read_csv("Data/hypertension_phc_raw.csv",
                          na = c("", "NA")) |>
  mutate(fasting_glucose_mmol_l = na_if(fasting_glucose_mmol_l, 999))

sum(is.na(raw_selective$fasting_glucose_mmol_l))
```

```
#> [1] 75
```

```
max(raw_selective$creatinine_umol_l) # creatinine không bị động đến
```

```
#> [1] 141
```

Glucose giờ có cùng 75 giá trị khuyết như trước, trong khi creatinine không bị động đến (giá trị lớn nhất của nó, 141 $\mu\text{mol/L}$, cho thấy không có cột nào bị thay đổi do nhầm lẫn; trong một bộ dữ liệu mà creatinine thực sự đạt 999, giá trị đó sẽ được giữ lại). Cách tiếp cận có chọn lọc này là lựa chọn mặc định an toàn bất cứ khi nào một mã có thể là giá trị thật ở một số cột.

Bài tập 2.2

Chúng ta liệt kê các mã bị lặp lại, hiển thị các bản ghi của chúng bằng `janitor::get_dupes()`, và so sánh số dòng trùng lặp hoàn toàn với số mã thừa.

```
# 1. Các mã xuất hiện nhiều hơn một lần, và các bản ghi của chúng
raw |> count(patient_id) |> filter(n > 1)
```

```
#> # A tibble: 3 × 2
#>   patient_id      n
#>   <chr>      <int>
#> 1 PHC-0011         2
#> 2 PHC-0251         2
#> 3 PHC-0881         2
```

```
janitor::get_dupes(raw, patient_id) |>
  select(patient_id, dupe_count, facility, age, sex, sbp_mmhg)
```

```
#> # A tibble: 6 × 6
#>   patient_id dupe_count facility      age sex      sbp_mmhg
#>   <chr>      <int> <chr>      <dbl> <chr>    <dbl>
#> 1 PHC-0011         2 Ilemela HC    51 Male     128
#> 2 PHC-0011         2 Ilemela HC    51 Male     128
#> 3 PHC-0251         2 Bugando PHC    51 Female   131
#> 4 PHC-0251         2 Bugando PHC    51 Female   131
#> 5 PHC-0881         2 Kisesa HC     45 Female   140
#> 6 PHC-0881         2 Kisesa HC     45 Female   140
```

```
# 2. Số dòng trùng lặp hoàn toàn so với số mã thừa
sum(duplicated(raw))
```

```
#> [1] 3
```

```
nrow(raw) - n_distinct(raw$patient_id)
```

```
#> [1] 3
```

Ba mã (PHC-0011, PHC-0251 và PHC-0881) xuất hiện hai lần, và `get_dupes()` hiển thị hai bản ghi của mỗi mã cạnh nhau, kèm theo cột `dupe_count`. Có 3 dòng trùng lặp hoàn toàn và 3 mã thừa (1.503 dòng trừ 1.500 mã khác nhau). Vì hai con số này khớp nhau, mọi mã bị lặp lại đều là bản sao chính xác, và không có bản ghi mâu thuẫn nào cần được đối chiếu với tài liệu gốc.

Một câu phù hợp cho phần phương pháp: *"Bộ dữ liệu thô gồm 1.503 bản ghi; ba bản ghi là bản sao hoàn toàn của các bản ghi khác (giống nhau ở mọi biến) và đã được loại bỏ, còn lại 1.500 người tham gia với mã định danh duy nhất."*

Bài tập 2.3

Chúng ta lập bảng tần số các mã thô, sau đó áp dụng hàm trợ giúp sau khi đã loại bỏ bản ghi trùng lặp, và kiểm tra phép ánh xạ bằng bảng chéo giữa giá trị cũ và giá trị mới.

```
# 1. Các mã được dùng trước khi làm sạch
table(raw$health_insurance, useNA = "ifany")
```

```
#>
#>   0    1    N  No    Y  Yes
#> 150   70   97 743   49 394
```

```
table(raw$htn_diagnosed, useNA = "ifany")
```

```
#>
#>   0    1    N  No    Y  Yes
#>  73 158   44 296 110 822
```

```
# 2. Áp dụng hàm trợ giúp và kiểm tra phép ánh xạ
clean_bin <- distinct(raw) |>
  mutate(health_insurance_new = to_yesno(health_insurance),
         htn_diagnosed_new = to_yesno(htn_diagnosed))

table(before = clean_bin$health_insurance,
      after = clean_bin$health_insurance_new)
```

```
#>      after
#> before No Yes
#>    0   150   0
#>    1    70  70
#>    N   96   0
#>   No  742   0
#>    Y    0  49
#>   Yes    0 393
```

```
table(before = clean_bin$htn_diagnosed,
      after = clean_bin$htn_diagnosed_new)
```

```
#>      after
#> before No Yes
#>    0    73  0
#>    1     0 158
#>    N    43  0
#>   No   295  0
#>    Y     0 110
#>   Yes    0 821
```

Cả hai biến đều dùng sáu mã: 0/1, N/Y và No/Yes. Các bảng chéo cho thấy mỗi mã được ánh xạ đến đúng một giá trị sạch (mọi mã 0, N và No thành "No", mọi mã 1, Y và Yes thành "Yes") và không có giá trị nào trở thành khuyết. Các con số hơi nhỏ hơn so với hai bảng đầu tiên vì ba bản ghi trùng lặp đã bị loại bỏ.

```
# 3. Tỷ lệ trong dữ liệu sạch
analysis_data |>
  summarise(insured_pct = round(100 * mean(health_insurance == "Yes"), 1),
            diagnosed_pct = round(100 * mean(htn_diagnosed == "Yes"), 1))
```

```
#> # A tibble: 1 × 2
#>   insured_pct diagnosed_pct
#>       <dbl>         <dbl>
#> 1      34.1          72.6
```

Trong dữ liệu sạch, 34,1 phần trăm bệnh nhân có bảo hiểm y tế và 72,6 phần trăm (1.089 trong số 1.500) đã được chẩn đoán tăng huyết áp. Vì `health_insurance` và `htn_diagnosed` không có giá trị khuyết, `mean(x == "Yes")` cho ra tỷ lệ một cách trực tiếp; nếu có giá trị khuyết, bạn sẽ cần `na.rm = TRUE` và nên báo cáo mẫu số.

Bài tập 2.4

Các phép kiểm tra giữa các biến so sánh những biến phải có một mối quan hệ cố định với nhau.

```
# 1. Huyết áp tâm trương cao bằng hoặc hơn huyết áp tâm thu
analysis_data |>
  summarise(dbp_ge_sbp = sum(dbp_mmhg >= sbp_mmhg, na.rm = TRUE))
```

```
#> # A tibble: 1 × 1
#>   dbp_ge_sbp
#>       <int>
#> 1         11
```

```
# 2. Hiệu áp
analysis_data <- analysis_data |>
  mutate(pulse_pressure = sbp_mmhg - dbp_mmhg)
summary(analysis_data$pulse_pressure)
```

```
#>      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.     NAs
#>   -18.0   39.0    53.0   53.3   68.0   129.0      3
```

```
sum(analysis_data$pulse_pressure < 20, na.rm = TRUE)
```

```
#> [1] 92
```

Mười một bệnh nhân có huyết áp tâm trương bằng hoặc cao hơn huyết áp tâm thu. Điều này không thể xảy ra về mặt sinh lý với một số đo huyết áp cánh tay được đo đúng cách: theo định nghĩa, huyết áp tâm thu là áp lực đỉnh của chu chuyển tim. Mỗi bản ghi này đều đã vượt qua các phép kiểm tra khoảng giá trị của từng biến riêng lẻ, và đó chính là lý do cần có các phép kiểm tra giữa các biến. Bản tóm tắt hiệu áp xác nhận vấn đề từ một góc độ khác: giá trị nhỏ nhất là -18 mmHg. Thêm 92 bệnh nhân có hiệu áp dưới 20 mmHg, điều bất thường (hiệu áp bình thường vào khoảng 40 mmHg) và có thể phản ánh các số đo bị đảo chỗ hoặc gõ nhầm. Trong một nghiên cứu thực tế, những bản ghi này sẽ được gửi lại cho các cơ sở để xác minh. Dữ liệu trong cuốn sách này là dữ liệu mô phỏng và các số đo được giữ nguyên trong `analysis_data`, nhưng nếu bạn làm sạch dữ liệu này để công bố, bạn sẽ thêm một quy tắc (ví dụ, chuyển cả hai số đo huyết áp thành `NA` khi huyết áp tâm trương lớn hơn hoặc bằng tâm thu) vào script làm sạch và báo cáo quy tắc đó.

```
# 3. Các quy tắc nhất quán từ từ điển dữ liệu
analysis_data |>
  group_by(htn_diagnosed) |>
  summarise(n = n(),
            min_months = min(months_since_diagnosis),
            max_months = max(months_since_diagnosis))
```

```
#> # A tibble: 2 × 4
#>   htn_diagnosed      n min_months max_months
#>   <fct>         <int>     <dbl>     <dbl>
#> 1 No             411         0         0
#> 2 Yes           1089         1       119
```

```
analysis_data |>
  count(treatment_uptake, adherence_recorded = !is.na(adherence))
```

```
#> # A tibble: 2 × 3
#>   treatment_uptake adherence_recorded      n
#>   <fct>           <lgl>             <int>
#> 1 No             FALSE             992
#> 2 Yes            TRUE              508
```

Cả hai quy tắc đều được thỏa mãn. Tất cả 411 bệnh nhân chưa được chẩn đoán đều có `months_since_diagnosis` bằng 0, và 1.089 bệnh nhân đã được chẩn đoán có giá trị từ 1 đến 119 tháng. Tuân thủ điều trị được ghi nhận cho cả 508 bệnh nhân đang điều trị và không cho bệnh nhân nào trong số 992 bệnh nhân không điều trị.

Bài tập 2.5

Thêm `right = FALSE` làm cho mỗi khoảng bao gồm giới hạn dưới của nó, ví dụ `[18.5, 25)`, khớp với định nghĩa của WHO.

```
# 1. Phân loại theo đúng WHO: các khoảng đóng bên trái
analysis_data <- analysis_data |>
  mutate(bmi_cat_who = cut(bmi,
                           breaks = c(-Inf, 18.5, 25, 30, Inf),
                           labels = c("Underweight", "Normal",
                                       "Overweight", "Obese"),
                           right = FALSE))

# 2. So sánh hai phiên bản
table(default = analysis_data$bmi_cat, who = analysis_data$bmi_cat_who)
```

```
#>           who
#> default    Underweight Normal Overweight Obese
#> Underweight      82      2         0      0
#> Normal           0     466        10      0
#> Overweight       0      0        568      9
#> Obese            0      0         0     316
```

```
analysis_data |>
  filter(bmi_cat != bmi_cat_who) |>
  count(bmi, bmi_cat, bmi_cat_who)
```

```
#> # A tibble: 3 × 4
#>   bmi bmi_cat   bmi_cat_who     n
#>   <dbl> <fct>     <fct>     <int>
#> 1  18.5 Underweight Normal         2
#> 2   25   Normal   Overweight    10
#> 3  30   Overweight Obese          9
```

Bảng chéo gần như nằm hoàn toàn trên đường chéo: 21 bệnh nhân thay đổi nhóm, tất cả đều chuyển lên một nhóm. Bảng thứ hai cho thấy lý do: họ chính là những bệnh nhân có BMI, khi làm tròn đến một chữ số thập phân, nằm đúng trên một điểm cắt. Hai bệnh nhân có BMI 18,5 chuyển từ "Underweight" (thiếu cân) sang "Normal" (bình thường), mười bệnh nhân có BMI 25,0 chuyển từ "Normal" sang "Overweight" (thừa cân) và chín bệnh nhân có BMI 30,0 chuyển từ "Overweight" sang "Obese" (béo phì). Ở đây sự khác biệt là nhỏ, nhưng trong một nghiên cứu báo cáo tỷ lệ hiện mắc béo phì, nó sẽ làm thay đổi ước lượng, và làm cho kết quả không khớp với các nghiên cứu đã áp dụng đúng định nghĩa của WHO.

```
# 3. Nhóm tuổi, được đối chiếu với tuổi
analysis_data <- analysis_data |>
  mutate(age_group = cut(age, breaks = c(18, 40, 60, Inf),
                          labels = c("18-39", "40-59", "60+"),
                          right = FALSE))

analysis_data |>
  group_by(age_group) |>
  summarise(n = n(), min_age = min(age), max_age = max(age))
```

```
#> # A tibble: 4 × 4
#>   age_group      n min_age max_age
#>   <fct>      <int>   <dbl>   <dbl>
#> 1 18-39        274     18     39
#> 2 40-59        772     40     59
#> 3 60+         452     60     95
#> 4 <NA>         2      NA      NA
```

Cùng ý tưởng `right = FALSE` đó giúp định nghĩa các nhóm tuổi có nhãn đúng với ý nghĩa của chúng: [18, 40) là từ 18 đến 39 tuổi. Tuổi nhỏ nhất và lớn nhất trong mỗi nhóm xác nhận định nghĩa (18-39, 40-59 và 60-95), và hai bệnh nhân có tuổi bị chuyển thành khuyết trong quá trình kiểm định được gán đúng một nhóm tuổi khuyết.

Bài tập 2.6

Biểu thức chính quy (regular expression) mô tả từng định dạng: `\\d{4}` (với dấu gạch chéo ngược được viết hai lần bên trong một chuỗi R) là bốn chữ số và `[A-Za-z]{3}` là ba chữ cái; `^` và `$` neo mẫu vào đầu và cuối của giá trị.

```
# 1. Đếm từng định dạng ngày
dates <- distinct(raw)$enroll_date
c(iso = sum(str_detect(dates, "^\\d{4}-\\d{2}-\\d{2}$")),
  slash = sum(str_detect(dates, "^\\d{2}/\\d{2}/\\d{4}$")),
  month_name = sum(str_detect(dates, "^\\d{2}-[A-Za-z]{3}-\\d{4}$")))
```

```
#>      iso      slash month_name
#>    1050        347        103
```

```
# 2. Hiểu định dạng gạch chéo theo kiểu tháng trước
wrong <- parse_date_time(dates, orders = c("ymd", "mdy", "d-b-Y")) |>
  as_date()
sum(is.na(wrong)) # số lỗi phân tích
```

```
#> [1] 221
```

```
sum(wrong != analysis_data$enroll_date, na.rm = TRUE) # khác biệt âm thầm
```

```
#> [1] 137
```

Ba định dạng bao gồm toàn bộ 1.500 ngày (1.050 + 347 + 103). Khi phân tích định dạng gạch chéo theo kiểu tháng trước, 221 ngày không phân tích được: chúng có số đầu tiên lớn hơn 12 (chẳng hạn 18/02/2024), không thể là một tháng. Ít ra thì lỗi này còn nhìn thấy được. Nguy hiểm hơn là 137 ngày được phân tích thành công nhưng khác với ngày đúng. Phần lớn trong số đó (115) là các ngày dạng gạch chéo có cả hai số đều nhỏ hơn hoặc bằng 12, khiến 01/02/2024 trở thành ngày 2 tháng 1 thay vì ngày 1 tháng 2; 22 ngày còn lại là các ngày có tên tháng mà `parse_date_time()` đã khớp với một thứ tự khác khi danh sách thứ tự thay đổi. Nếu không so sánh với các ngày được phân tích đúng, không lỗi nào trong số 137 lỗi này được phát hiện. Đó là lý do thứ tự phải được chọn dựa trên hiểu biết về dữ liệu, và kết quả phải được kiểm tra.

```
# 3. Số lượt tuyển chọn mỗi quý
analysis_data |>
  mutate(enroll_quarter = quarter(enroll_date)) |>
  count(enroll_quarter)
```

```
#> # A tibble: 4 × 2
#>   enroll_quarter     n
#>   <int> <int>
#> 1         1    392
#> 2         2    412
#> 3         3    421
#> 4         4    275
```

Việc tuyển chọn được phân bố đều trong ba quý đầu (từ 392 đến 421 bệnh nhân) và thấp hơn trong quý thứ tư (275), vì việc tuyển chọn kết thúc vào ngày 2 tháng 12.

Bài tập 2.7

Chúng ta tạo một biến chỉ thị việc bị khuyết và so sánh nó giữa các nhóm của các biến quan sát được.

```
analysis_data <- analysis_data |>
  mutate(chol_missing = is.na(total_chol_mmol_l))

# 1. Tỷ lệ phần trăm bị khuyết theo chẩn đoán và theo nơi cư trú
analysis_data |>
  group_by(htn_diagnosed) |>
  summarise(n = n(), pct_missing = round(100 * mean(chol_missing), 1))
```

```
#> # A tibble: 2 × 3
#>   htn_diagnosed     n pct_missing
#>   <fct>         <int>     <dbl>
#> 1 No             411         3.9
#> 2 Yes           1089         6.8
```

```
analysis_data |>
  group_by(residence) |>
  summarise(n = n(), pct_missing = round(100 * mean(chol_missing), 1))
```

```
#> # A tibble: 2 × 3
#>   residence     n pct_missing
#>   <fct>    <int>     <dbl>
#> 1 Rural    703         5.4
#> 2 Urban    797         6.5
```

```
# 2. Tuổi trung bình theo tình trạng bị khuyết
analysis_data |>
  group_by(chol_missing) |>
  summarise(n = n(), mean_age = round(mean(age, na.rm = TRUE), 1))
```

```
#> # A tibble: 2 × 3
#>   chol_missing    n mean_age
#>   <lggl>      <int>   <dbl>
#> 1 FALSE      1410     52
#> 2 TRUE        90    55.9
```

Cholesterol bị khuyết ở 6,8 phần trăm bệnh nhân đã được chẩn đoán và 3,9 phần trăm bệnh nhân chưa được chẩn đoán, và ở 6,5 phần trăm người sống ở thành thị so với 5,4 phần trăm người sống ở nông thôn. Những bệnh nhân bị khuyết cholesterol trung bình lớn tuổi hơn khoảng bốn năm (55,9 so với 52,0 tuổi). Các chênh lệch này không lớn, và Chương 4 sẽ trình bày cách kiểm định xem những chênh lệch cỡ này có thể do ngẫu nhiên hay không, nhưng chúng chỉ về một hướng nhất quán: việc bị khuyết dường như liên quan đến các đặc điểm quan sát được (chẩn đoán, tuổi). Nếu vậy, dữ liệu không phải là MCAR, và một phân tích giới hạn ở những bệnh nhân có kết quả cholesterol sẽ có hơi nhiều bệnh nhân trẻ tuổi, chưa được chẩn đoán hơn so với thực tế. MAR, với việc bị khuyết phụ thuộc vào tuổi và chẩn đoán, là một giả định làm việc hợp lý hơn, và mọi phân tích có sử dụng cholesterol ít nhất nên đưa các biến này vào mô hình hoặc vào mô hình quy nạp.

Dữ liệu không thể cho chúng ta biết cholesterol có phải là MNAR hay không. Điều đó đòi hỏi phải biết liệu những bệnh nhân có giá trị khuyết có xu hướng có cholesterol cao hơn hay thấp hơn những bệnh nhân được quan sát cùng tuổi và cùng tình trạng chẩn đoán hay không, mà cholesterol của họ lại chính là thứ chúng ta không quan sát được. Các nhận định về MNAR dựa trên hiểu biết về cách dữ liệu được thu thập (ví dụ, liệu máu chỉ được lấy từ những bệnh nhân trông có vẻ không khỏe hay không) và được tìm hiểu bằng các phân tích độ nhạy. Vì dữ liệu này là dữ liệu mô phỏng, quy luật ở đây minh họa cho cách lập luận chứ không phải là một phát hiện lâm sàng thực tế.

Bài tập 2.8

Hàm này tập hợp các bước của chương theo đúng thứ tự. Nó sử dụng hàm trợ giúp `to_yesno()` được định nghĩa ở đầu phụ lục này; trong một dự án thực tế, bạn sẽ đặt cả hai hàm trong cùng một tệp script.

```
clean_htn <- function(path) {
  # Nhập với các mã giá trị khuyết; bỏ trùng lặp hoàn toàn; cắt khoảng trắng
  dat <- read_csv(path, na = c("", "NA", "999", "-99"),
    show_col_types = FALSE) |>
    distinct() |>
    mutate(across(where(is.character), str_trim))

  # Danh mục: giới tính và các biến Yes/No
  dat <- dat |>
    mutate(
      sex = case_when(
        str_to_lower(sex) %in% c("female", "f") ~ "Female",
        str_to_lower(sex) %in% c("male", "m") ~ "Male",
        TRUE ~ NA_character_),
      across(c(diabetes, family_history_htn, health_insurance,
        htn_diagnosed, treatment_uptake), to_yesno)
    )
}
```

```

# Kiểm định: các giá trị không thể xảy ra trở thành NA
dat <- dat |>
  mutate(
    age      = if_else(between(age, 18, 110), age, NA_real_),
    sbp_mmhg = if_else(between(sbp_mmhg, 70, 260), sbp_mmhg, NA_real_),
    dbp_mmhg = if_else(between(dbp_mmhg, 40, 150), dbp_mmhg, NA_real_),
    height_cm = if_else(between(height_cm, 120, 210), height_cm, NA_real_),
    weight_kg = if_else(between(weight_kg, 30, 200), weight_kg, NA_real_)
  )

# Biến dẫn xuất và ngày tháng
dat <- dat |>
  mutate(
    bmi = round(weight_kg / (height_cm / 100)^2, 1),
    bmi_cat = cut(bmi, breaks = c(-Inf, 18.5, 25, 30, Inf),
                  labels = c("Underweight", "Normal",
                             "Overweight", "Obese")),
    bp_category = case_when(
      is.na(sbp_mmhg) | is.na(dbp_mmhg) ~ NA_character_,
      sbp_mmhg >= 140 | dbp_mmhg >= 90 ~ "Hypertension",
      sbp_mmhg >= 130 | dbp_mmhg >= 80 ~ "Elevated",
      TRUE ~ "Normal"),
    enroll_date = as_date(parse_date_time(
      enroll_date, orders = c("ymd", "dmy", "d-b-Y")))
  )

# Factor với các mức được chọn có chủ đích
yn <- c("No", "Yes")
dat <- dat |>
  mutate(
    facility = factor(facility),
    sex = factor(sex, levels = c("Female", "Male")),
    residence = factor(residence, levels = c("Rural", "Urban")),
    education = factor(education, ordered = TRUE,
                      levels = c("None", "Primary", "Secondary",
                                 "Tertiary")),
    occupation = factor(occupation),
    marital_status = factor(marital_status),
    physical_activity = factor(physical_activity, ordered = TRUE,
                              levels = c("Low", "Moderate", "High")),
    smoking = factor(smoking, levels = c("Never", "Former", "Current")),
    alcohol = factor(alcohol, levels = c("None", "Moderate", "Heavy")),
    bp_category = factor(bp_category,
                        levels = c("Normal", "Elevated", "Hypertension")),
    health_insurance = factor(health_insurance, levels = yn),
    family_history_htn = factor(family_history_htn, levels = yn),
    diabetes = factor(diabetes, levels = yn),
    htn_diagnosed = factor(htn_diagnosed, levels = yn),
    treatment_uptake = factor(treatment_uptake, levels = yn),
    adherence = factor(na_if(adherence, ""), levels = c("Poor", "Good")),
    bp_controlled = factor(na_if(bp_controlled, ""), levels = yn)
  )

# Khẳng định: dừng lại rõ ràng nếu xuất hiện một vấn đề mới
stopifnot(

```

```

    n_distinct(dat$patient_id) == nrow(dat),
    !anyNA(dat$sex),
    !anyNA(dat$enroll_date),
    !anyNA(dat$treatment_uptake),
    all(between(dat$sbp_mmhg, 70, 260), na.rm = TRUE)
  )
  dat
}

my_clean <- clean_htn("Data/hypertension_phc_raw.csv")
all.equal(my_clean, readRDS("Data/analysis_data.rds"))

#> [1] TRUE

```

`all.equal()` trả về `TRUE`: hàm tái tạo chính xác bộ dữ liệu phân tích. Các khẳng định ở cuối hàm kiểm tra rằng mã bệnh nhân là duy nhất, rằng giới tính, ngày tuyển chọn và biến kết cục không có giá trị khuyết, và rằng huyết áp tâm thu nằm trong khoảng hợp lý; nếu một phiên bản tương lai của tệp thô chứa, chẳng hạn, một cách viết giới tính mới hoặc một định dạng ngày mới, hàm sẽ dừng lại với một thông báo lỗi nêu rõ điều kiện không thỏa mãn thay vì âm thầm trả về dữ liệu có sai sót.

Một hàm hữu ích hơn một script dài khi nhận được một tệp thô đã được sửa vì ba lý do. Nó có thể được chạy lại trên tệp mới chỉ bằng một dòng lệnh, không cần chỉnh sửa gì. Nó có thể được áp dụng cho nhiều tệp (ví dụ, một lần xuất dữ liệu giữa kỳ và một lần xuất cuối cùng) và so sánh các kết quả. Và vì mọi thứ diễn ra bên trong hàm, không có đối tượng trung gian nào bị để lại trong không gian làm việc để có thể bị nhầm lẫn với dữ liệu sạch. Đóng gói một quy trình làm sạch thành một hàm là một bước nhỏ hướng tới các quy trình làm việc có thể tái lập mà Wilson et al. (2017) khuyến nghị.

A.3 Chương 3: Thống kê mô tả, bảng và hình

Tất cả lời giải đều bắt đầu từ tệp phân tích đã làm sạch và, khi có liên quan đến biến kết cục, từ quần thể bệnh nhân đã được chẩn đoán.

```

analysis_data <- readRDS("Data/analysis_data.rds")
diagnosed <- analysis_data |> filter(htn_diagnosed == "Yes")
teal <- "#0D7377"

```

R

Bài tập 3.1

Chúng ta tính bốn thống kê cho mỗi biến, cùng với số giá trị khuyết.

```

analysis_data |>
  select(age, distance_to_facility_km) |>
  pivot_longer(everything(), names_to = "variable", values_to = "value") |>
  group_by(variable) |>
  summarise(
    missing = sum(is.na(value)),
    mean     = mean(value, na.rm = TRUE),
    sd       = sd(value, na.rm = TRUE),

```

R

```

median = median(value, na.rm = TRUE),
iqr     = IQR(value, na.rm = TRUE)
) |>
kable(digits = 2,
caption = "Tóm tắt tuổi và khoảng cách đến cơ sở y tế.")

```

Bảng A.1: Tóm tắt tuổi và khoảng cách đến cơ sở y tế.

variable	missing	mean	sd	median	iqr
age	2	52.28	14.10	52.00	19.0
distance_to_facility_km	60	7.82	6.09	6.45	6.3

Tuổi có 2 giá trị khuyết và khoảng cách có 60. Với **tuổi**, trung bình (52,3 tuổi) và trung vị (52 tuổi) gần như trùng nhau và SD (14,1) nhỏ so với trung bình, nên phân phối gần như đối xứng: báo cáo **trung bình (SD)**, 52,3 (14,1) tuổi. Với **khoảng cách**, trung bình (7,8 km) cao hơn hẳn trung vị (6,45 km) và SD (6,1 km) gần bằng trung bình của một biến không thể nhận giá trị âm, dấu hiệu đặc trưng của phân phối lệch phải (xem histogram ở Mục 3.5): báo cáo **trung vị (IQR)**: 6,45 km (IQR 4,0 đến 10,3 km, tức khoảng tứ phân vị là 6,3 km).

Bài tập 3.2

```
ldl <- analysis_data$ldl_mmol_l
```

```
mean(ldl) # cái bẫy na.rm: NA
```

```
#> [1] NA
```

```

c(n_valid = sum(!is.na(ldl)),
  n_missing = sum(is.na(ldl)),
  pct_miss = 100 * mean(is.na(ldl)),
  mean     = mean(ldl, na.rm = TRUE),
  sd       = sd(ldl, na.rm = TRUE),
  cv_pct   = 100 * sd(ldl, na.rm = TRUE) / mean(ldl, na.rm = TRUE)) |>
round(2)

```

```

#>   n_valid n_missing pct_miss   mean    sd  cv_pct
#>   1395.00   105.00     7.00    2.70   1.03   38.26

```

Không có `na.rm = TRUE`, `mean()` trả về NA vì 105 giá trị LDL (7,0%) bị khuyết. Trong 1.395 bệnh nhân có kết quả, cholesterol LDL trung bình là 2,70 mmol/L với SD 1,03 mmol/L, hệ số biến thiên khoảng 38%, nên LDL biến thiên tương đối nhiều hơn cholesterol toàn phần (CV khoảng 19%). Một câu cho bài báo: *"Cholesterol LDL có sẵn ở 1.395 trong số 1.500 người tham gia (93,0%); trung bình 2,70 mmol/L (SD 1,03)."*

Bài tập 3.3

```
table(analysis_data$smoking, useNA = "ifany")
```

R

```
#>
#>   Never   Former Current   <NA>
#>     899     295     261     45
```

```
table(analysis_data$bp_category, useNA = "ifany")
```

R

```
#>
#>   Normal   Elevated Hypertension   <NA>
#>     144     357     996         3
```

```
analysis_data |>
  tabyl(smoking) |>
  adorn_pct_formatting(digits = 1)
```

R

```
#> smoking   n percent valid_percent
#>   Never 899   59.9%         61.8%
#>  Former 295   19.7%         20.3%
#> Current 261   17.4%         17.9%
#>   <NA>  45    3.0%          -
```

```
analysis_data |>
  tabyl(bp_category) |>
  adorn_pct_formatting(digits = 1)
```

R

```
#> bp_category   n percent valid_percent
#>   Normal  144    9.6%         9.6%
#> Elevated  357   23.8%        23.8%
#> Hypertension 996   66.4%        66.5%
#>   <NA>    3    0.2%          -
```

Tình trạng hút thuốc bị khuyết ở 45 bệnh nhân và phân loại huyết áp bị khuyết ở 3 bệnh nhân. Có 261 người hiện đang hút thuốc (Current): (a) 17,4% trong tổng số 1.500 bệnh nhân (percent), và (b) 17,9% trong số 1.455 người biết tình trạng hút thuốc (valid_percent). Ở đây khác biệt nhỏ vì chỉ 3% bị khuyết, nhưng luôn phải nêu rõ mẫu số.

Bài tập 3.4

```
ins_tab <- table(Insurance = diagnosed$health_insurance,
                 Treated   = diagnosed$treatment_uptake)
addmargins(ins_tab)
```

R

```
#>           Treated
#> Insurance   No  Yes  Sum
#>       No   419 306  725
#>       Yes   162 202  364
```

```
#>      Sum  581  508 1089
```

```
round(100 * prop.table(ins_tab, margin = 1), 1) # % hàng (trong nhóm bảo hiểm) R
```

```
#>      Treated
#> Insurance  No  Yes
#>      No  57.8 42.2
#>      Yes 44.5 55.5
```

```
round(100 * prop.table(ins_tab, margin = 2), 1) # % cột (trong nhóm điều trị) R
```

```
#>      Treated
#> Insurance  No  Yes
#>      No  72.1 60.2
#>      Yes 27.9 39.8
```

Trong 364 bệnh nhân đã được chẩn đoán có bảo hiểm, 55,5% đang điều trị, so với 42,2% trong 725 người không có bảo hiểm. Đây là các **tỷ lệ phần trăm theo hàng**, được tính trong các nhóm của biến giải thích (bảo hiểm). Chúng trả lời trực tiếp câu hỏi "bảo hiểm có liên quan đến việc sử dụng điều trị không?", vì chúng so sánh biến kết cục giữa các nhóm phơi nhiễm. Các tỷ lệ phần trăm theo cột (39,8% bệnh nhân được điều trị và 27,9% bệnh nhân không được điều trị có bảo hiểm) mô tả thành phần của các nhóm biến kết cục, đúng là những gì một Bảng 1 theo việc sử dụng điều trị trình bày, nhưng chúng không cho biết tỷ lệ sử dụng điều trị trong mỗi nhóm bảo hiểm.

Bài tập 3.5

```
diagnosed |>
  group_by(treatment_uptake) |>
  summarise(
    n      = sum(!is.na(sbp_mmhg)),
    mean   = mean(sbp_mmhg, na.rm = TRUE),
    sd     = sd(sbp_mmhg, na.rm = TRUE),
    se     = sd / sqrt(n),
    lower  = mean - qt(0.975, n - 1) * se,
    upper  = mean + qt(0.975, n - 1) * se
  ) |>
  kable(digits = 2,
    caption = "SBP trung bình (mmHg) kèm CI 95% theo việc điều trị.") R
```

Bảng A.2: SBP trung bình (mmHg) kèm CI 95% theo việc điều trị.

treatment_uptake	n	mean	sd	se	lower	upper
No	581	142.2	19.81	0.82	140.6	143.8
Yes	507	148.1	18.34	0.81	146.5	149.7

```

diagnosed |>
  group_by(residence) |>
  summarise(n = n(), treated = sum(treatment_uptake == "Yes")) |>
  mutate(pct = 100 * treated / n,
         se = sqrt((pct / 100) * (1 - pct / 100) / n),
         lower = pct - 100 * 1.96 * se,
         upper = pct + 100 * 1.96 * se) |>
  select(-se) |>
  kable(digits = 1,
        caption = "Tỷ lệ sử dụng điều trị (%) kèm CI 95% theo nơi cư trú.")

```

Bảng A.3: Tỷ lệ sử dụng điều trị (%) kèm CI 95% theo nơi cư trú.

residence	n	treated	pct	lower	upper
Rural	501	195	38.9	34.7	43.2
Urban	588	313	53.2	49.2	57.3

Bệnh nhân đã được chẩn đoán không điều trị có SBP trung bình 142,2 mmHg (CI 95% khoảng 140,6 đến 143,8) và bệnh nhân được điều trị có SBP trung bình 148,1 mmHg (khoảng 146,5 đến 149,7). Tỷ lệ sử dụng điều trị là 38,9% (CI 95% khoảng 34,7% đến 43,2%) ở bệnh nhân nông thôn (Rural) và 53,2% (khoảng 49,2% đến 57,3%) ở bệnh nhân thành thị (Urban) đã được chẩn đoán; các khoảng không chồng lên nhau, gợi ý một khác biệt thực sự mà Chương 4 sẽ kiểm định chính thức.

SD (khoảng 18 đến 20 mmHg) đo mức độ SBP của từng bệnh nhân dao động quanh trung bình của nhóm; nó sẽ giữ gần như nguyên nếu chúng ta tuyển thêm bệnh nhân. **SE** (khoảng 0,8 mmHg) đo mức độ chính xác của việc ước lượng *trung bình* của mỗi nhóm; nó bằng SD chia cho $\sqrt{n}$ và sẽ giảm đi với một mẫu lớn hơn. SD mô tả bệnh nhân, SE mô tả sự bất định của một ước lượng.

Bài tập 3.6

```

diagnosed |>
  select(age, sex, residence, education, health_insurance,
         family_history_htn, knowledge_score, comorbidity_count,
         treatment_uptake) |>
  tbl_summary(
    by = treatment_uptake,
    type = comorbidity_count ~ "continuous", # coi số đếm là biến số
    statistic = list(
      c(age, knowledge_score) ~ "{mean} ({sd})",
      comorbidity_count ~ "{median} ({p25}, {p75})",
      all_categorical() ~ "{n} ({p}%"
    ),
    digits = list(c(age, knowledge_score) ~ 1, comorbidity_count ~ 0),
    label = list(
      age ~ "Tuổi, năm",
      sex ~ "Giới tính",
      residence ~ "Nơi cư trú",
      education ~ "Học vấn",
      health_insurance ~ "Bảo hiểm y tế",
      family_history_htn ~ "Tiền sử gia đình tăng huyết áp",

```

```

knowledge_score ~ "Điểm kiến thức (0-20)",
comorbidity_count ~ "Số bệnh đồng mắc"
),
missing = "ifany",
missing_text = "Khuyết"
) |>
add_overall(last = FALSE, col_label = "**Chung** \nN = {N}") |>
modify_header(label = "**Đặc điểm**") |>
as_kable(caption = "Bệnh nhân đã được chẩn đoán theo việc sử dụng điều trị.")

```

Bảng A.4: Bệnh nhân đã được chẩn đoán theo việc sử dụng điều trị.


Đặc điểm	Chung N = 1089	No N = 581	Yes N = 508
Tuổi, năm	53.5 (14.0)	51.1 (13.4)	56.3 (14.1)
Khuyết	1	1	0
Giới tính			
Female	629 (58%)	315 (54%)	314 (62%)
Male	460 (42%)	266 (46%)	194 (38%)
Nơi cư trú			
Rural	501 (46%)	306 (53%)	195 (38%)
Urban	588 (54%)	275 (47%)	313 (62%)
Học vấn			
None	201 (19%)	126 (22%)	75 (15%)
Primary	444 (42%)	252 (44%)	192 (39%)
Secondary	292 (27%)	137 (24%)	155 (31%)
Tertiary	128 (12%)	55 (9.6%)	73 (15%)
Khuyết	24	11	13
Bảo hiểm y tế	364 (33%)	162 (28%)	202 (40%)
Tiền sử gia đình tăng huyết áp	394 (36%)	183 (31%)	211 (42%)
Điểm kiến thức (0-20)	10.4 (3.5)	9.9 (3.4)	10.9 (3.4)
Khuyết	29	16	13
Số bệnh đồng mắc	0 (0, 1)	0 (0, 1)	0 (0, 1)

Nếu không có `type = comorbidity_count ~ "continuous"`, `gtsummary` sẽ coi một biến đếm chỉ có bốn giá trị khác nhau là biến phân loại và hiển thị n (%) cho mỗi giá trị, mà thực ra đó lại là một phương án thay thế hoàn toàn tốt ở đây: trung vị (IQR) bằng 0 (0, 1) giống hệt nhau ở cả hai nhóm và che giấu mọi khác biệt.

Hai đặc điểm khác nhau: bệnh nhân được điều trị **lớn tuổi hơn** (trung bình khoảng 56 so với 51 tuổi) và thường có **tiền sử gia đình tăng huyết áp** hơn (khoảng 42% so với 31%); họ cũng thường có bảo hiểm, sống ở thành thị và có học vấn cao hơn, và có điểm kiến thức cao hơn một chút. Những khác biệt này hợp lý về mặt lâm sàng: bệnh nhân lớn tuổi và những người có tiền sử gia đình dễ được nhận diện là nguy cơ cao và được bắt đầu điều trị hơn, và bảo hiểm, học vấn và kiến thức có thể làm giảm các rào cản tài chính và thông tin trong việc tiếp cận chăm sóc. Đây là những khác biệt mô tả, chưa hiệu chỉnh, trên dữ liệu mô phỏng, cần được xem xét bằng các kiểm định (Chương 4) và các mô hình đa biến (Chương 5).

Bài tập 3.7

```
ggplot(diagnosed, aes(x = treatment_uptake, y = knowledge_score)) +
  geom_jitter(width = 0.2, height = 0.2, alpha = 0.25, size = 0.8,
    na.rm = TRUE) +
  geom_boxplot(width = 0.4, outlier.shape = NA, fill = teal, alpha = 0.3,
    na.rm = TRUE) +
  labs(title = "Bệnh nhân được điều trị có điểm kiến thức cao hơn một chút",
    x = "Đang dùng thuốc điều trị tăng huyết áp",
    y = "Điểm kiến thức (0-20)")
```




Hình A.3: Điểm kiến thức về tăng huyết áp (0-20) ở bệnh nhân đã được chẩn đoán không điều trị và có điều trị; hộp thể hiện trung vị và các tứ phân vị, các điểm thể hiện từng bệnh nhân.

Điểm kiến thức là số nguyên, nên một độ rải dọc nhỏ (`height = 0.2`) giúp các bệnh nhân có cùng điểm không bị vẽ chồng lên nhau. Điểm trung vị là 11 ở bệnh nhân được điều trị và 10 ở bệnh nhân không được điều trị, nhưng hai phân phối gần như chồng lên nhau hoàn toàn.

```
diagnosed |>
  filter(!is.na(education)) |>
  group_by(education) |>
  summarise(pct = mean(treatment_uptake == "Yes")) |>
  ggplot(aes(x = education, y = pct)) +
  geom_col(fill = teal, width = 0.65) +
  geom_text(aes(label = percent(pct, accuracy = 0.1)), vjust = -0.4) +
  scale_y_continuous(labels = label_percent(), limits = c(0, 0.7)) +
  labs(title = "Tỷ lệ sử dụng điều trị tăng theo học vấn",
    x = "Trình độ học vấn cao nhất",
    y = "Bệnh nhân đã chẩn đoán đang điều trị")
```

Vì `education` là một factor có thứ tự, các cột xuất hiện từ không đi học (None) đến sau trung học (Tertiary) mà không cần thêm mã. Tỷ lệ sử dụng điều trị tăng từ khoảng 37% ở bệnh nhân không đi học lên khoảng 57% ở những người có trình độ sau trung học, một gradient phù hợp với việc học vấn giúp dễ tiếp cận và sử dụng dịch vụ chăm sóc hơn. Biểu đồ cột phù hợp ở đây vì mỗi cột là một *tỷ lệ phần trăm*, mà chiều dài của nó tính từ số không có ý nghĩa.

Tỷ lệ sử dụng điều trị tăng theo học vấn



Hình A.4: Tỷ lệ phần trăm bệnh nhân tăng huyết áp đã được chẩn đoán đang điều trị theo trình độ học vấn cao nhất (loại 24 bệnh nhân bị khuyết thông tin học vấn); tỷ lệ sử dụng điều trị tăng dần theo học vấn.

Bài tập 3.8

```

facility_summary <- diagnosed |>
  group_by(facility) |>
  summarise(
    n          = n(),
    treated     = sum(treatment_uptake == "Yes"),
    median_dist = median(distance_to_facility_km, na.rm = TRUE),
    pct_insured = 100 * mean(health_insurance == "Yes")
  ) |>
  rowwise() |>                                # mỗi cơ sở một prop.test()
  mutate(
    ci = list(prop.test(treated, n, correct = FALSE)$conf.int),
    pct = 100 * treated / n,
    lower = 100 * ci[1],
    upper = 100 * ci[2]
  ) |>
  ungroup() |>
  select(facility, n, pct, lower, upper, median_dist, pct_insured) |>
  arrange(desc(pct))

facility_summary |>
  kable(digits = 1,
        caption = paste("Tỷ lệ sử dụng điều trị (% , CI 95% Wilson) và khả",
                        "năng tiếp cận theo cơ sở y tế."))

```

```


ggplot(facility_summary, aes(x = median_dist, y = pct / 100)) +
  geom_point(size = 3, colour = teal) +
  geom_text(aes(label = facility), vjust = -1, size = 3.2) +
  scale_y_continuous(labels = label_percent(), limits = c(0.35, 0.58)) +

```

Bảng A.5: Tỷ lệ sử dụng điều trị (%; CI 95% Wilson) và khả năng tiếp cận theo cơ sở y tế.

facility	n	pct	lower	upper	median_dist	pct_insured
Nyamagana PHC	220	53.6	47.0	60.1	6.4	36.8
Bugando PHC	259	47.5	41.5	53.6	6.5	34.0
Kisesa HC	154	46.1	38.4	54.0	6.2	33.1
Ilemela HC	192	45.3	38.4	52.4	7.2	35.9
Buzuruga PHC	134	44.0	35.9	52.5	5.5	26.1
Igoma HC	130	38.5	30.5	47.0	5.8	30.8

```
scale_x_continuous(limits = c(5.2, 7.5)) +
labs(title = "Tỷ lệ sử dụng điều trị của cơ sở và khoảng cách trung vị",
      x = "Khoảng cách trung vị đến cơ sở y tế (km)",
      y = "Bệnh nhân đã chẩn đoán đang điều trị")
```

Tỷ lệ sử dụng điều trị của cơ sở và khoảng cách trung vị**Hình A.5:** Tỷ lệ sử dụng điều trị ở bệnh nhân đã được chẩn đoán theo khoảng cách trung vị đến cơ sở y tế, mỗi cơ sở một điểm; với chỉ sáu cơ sở, không thấy mối quan hệ rõ ràng nào.

`rowwise()` làm cho `mutate()` xử lý từng cơ sở một, nên `prop.test()` nhận số đếm của cơ sở đó; khoảng Wilson được lưu dưới dạng một cột danh sách (list column) rồi được tách thành giới hạn dưới và giới hạn trên. Tỷ lệ sử dụng điều trị dao động từ 38,5% (Igoma HC) đến 53,6% (Nyamagana PHC), với các khoảng Wilson tương tự các khoảng Wald ở Mục 3.8 vì mỗi cơ sở có hơn 100 bệnh nhân đã được chẩn đoán. Trên biểu đồ không có xu hướng rõ ràng: các cơ sở có khoảng cách trung vị ngắn nhất (Buzuruga PHC và Igoma HC) không có tỷ lệ sử dụng điều trị cao nhất.

Cần hết sức thận trọng vì ba lý do. Thứ nhất, chỉ có **sáu** điểm dữ liệu, nên bất kỳ mối quan hệ nào nhìn thấy cũng có thể dễ dàng xuất hiện do ngẫu nhiên. Thứ hai, đây là một phép so sánh **sinh thái** (ecological) giữa các giá trị trung bình của cơ sở: một mối quan hệ giữa các cơ sở không nhất thiết đúng với từng bệnh nhân (*ngụy biện sinh thái*, ecological fallacy), và thực tế ở cấp bệnh nhân, Bảng 1 ở Mục 3.10 đã cho thấy bệnh nhân được điều trị sống gần cơ sở y tế

hơn một chút. Thứ ba, các cơ sở khác nhau về nhiều mặt cùng lúc (độ bao phủ bảo hiểm, nhân lực, quần thể trong vùng phục vụ), nên không thể tách riêng khoảng cách khỏi các đặc điểm khác của cơ sở nếu không có một phân tích đa biến ở cấp bệnh nhân có tính đến sự phân cụm (Chương 5).

A.4 Chương 4: Các kiểm định thống kê thường dùng trong nghiên cứu y học

Mọi lời giải đều bắt đầu từ bộ dữ liệu sạch và quần thể phân tích gồm các bệnh nhân đã được chẩn đoán tăng huyết áp.

```
library(tidyverse)
library(broom)
library(patchwork)

course_teal <- "#0D7377"

analysis_data <- readRDS("Data/analysis_data.rds")
dx <- filter(analysis_data, htn_diagnosed == "Yes")
```

Bài tập 4.1

1. Cỡ của quần thể phân tích và tỷ lệ tiếp nhận điều trị.

```
nrow(dx)
```

```
#> [1] 1089
```

```
dx |> count(treatment_uptake) |> mutate(percent = round(100 * n / sum(n), 1))
```

```
#> # A tibble: 2 × 3
#>   treatment_uptake     n percent
#>   <fct>           <int>   <dbl>
#> 1 No              581    53.4
#> 2 Yes             508    46.6
```

Có 1.089 bệnh nhân đã được chẩn đoán, trong đó 508 người (46,6%) đang điều trị.

2. Tỷ lệ tiếp nhận điều trị trong toàn bộ 1.500 bệnh nhân.

```
analysis_data |>
  count(htn_diagnosed, treatment_uptake) |>
  mutate(percent_of_all = round(100 * n / sum(n), 1))
```

```
#> # A tibble: 3 × 4
#>   htn_diagnosed treatment_uptake     n percent_of_all
#>   <fct>         <fct>           <int>   <dbl>
#> 1 No          No              411    27.4
#> 2 Yes          No              581    38.7
#> 3 Yes          Yes              508    33.9
```

```
round(100 * mean(analysis_data$treatment_uptake == "Yes"), 1)
```

```
#> [1] 33.9
```

Trên toàn bộ 1.500 bệnh nhân, chỉ 33,9% "đang điều trị", vì 411 bệnh nhân chưa được chẩn đoán đều được ghi nhận là không điều trị. Việc tiếp nhận điều trị chỉ được định nghĩa cho những người biết mình bị tăng huyết áp, nên việc đưa cả bệnh nhân chưa được chẩn đoán vào sẽ trộn lẫn hai quá trình khác nhau (được chẩn đoán, và được điều trị sau khi đã chẩn đoán) và cho ra một con số thấp gây hiểu lầm; mẫu số đúng là 1.089 bệnh nhân đã được chẩn đoán.

3. Độ lệch chuẩn và sai số chuẩn của điểm kiến thức.

```
dx |> summarise(n = sum(!is.na(knowledge_score)),
               mean = mean(knowledge_score, na.rm = TRUE),
               sd = sd(knowledge_score, na.rm = TRUE),
               se = sd / sqrt(n))
```

```
#> # A tibble: 1 × 4
#>       n mean sd se
#>   <int> <dbl> <dbl> <dbl>
#> 1  1060  10.4  3.46 0.106
```

Điểm kiến thức trung bình là 10,4 điểm với độ lệch chuẩn 3,5 điểm: từng bệnh nhân thường khác trung bình khoảng 3,5 điểm. Sai số chuẩn, 0,11 điểm, mô tả độ chính xác của *trung bình*: nếu nghiên cứu được lặp lại, các trung bình mẫu thường dao động khoảng 0,1 điểm. SD mô tả bệnh nhân; SE mô tả ước lượng và giảm theo $1/\sqrt{n}$.

Bài tập 4.2

1. Biểu đồ tần suất và biểu đồ Q–Q của BMI.


```
p_hist <- ggplot(dx, aes(x = bmi)) +
  geom_histogram(binwidth = 1, fill = course_teal, colour = "white") +
  labs(x = "BMI (kg/m²)", y = "Số bệnh nhân")
p_qq <- ggplot(dx, aes(sample = bmi)) +
  stat_qq(size = 0.6, alpha = 0.5, colour = course_teal) +
  stat_qq_line() +
  labs(x = "Phân vị lý thuyết", y = "Phân vị mẫu")
p_hist + p_qq
```

Biểu đồ tần suất đối xứng và có hình chuông, và biểu đồ Q–Q gần với một đường thẳng, chỉ có những sai lệch rất nhỏ ở hai đầu.

2. Kiểm định Shapiro–Wilk.

```
shapiro.test(dx$bmi)
```

```
#>
#>      Shapiro-Wilk normality test
#>
#> data:  dx$bmi
```



Hình A.6: Biểu đồ tần suất và biểu đồ Q-Q chuẩn của chỉ số khối cơ thể ở bệnh nhân đã được chẩn đoán.

```
#> W = 0.997, p-value = 0.052
```

$W = 0.997$ và $p = 0.052$: không có bằng chứng mạnh chống lại tính chuẩn. Tuy nhiên, với hơn 1.000 bệnh nhân, kiểm định sẽ đánh dấu cả những sai lệch không đáng kể, và các biểu đồ (cùng với định lý giới hạn trung tâm) là chỉ dẫn hữu ích hơn. Dù theo cách nào, BMI cũng có thể được coi là có phân phối xấp xỉ chuẩn.

3. So sánh BMI theo việc tiếp nhận điều trị. Kiểm định t Welch là phù hợp.

```
t.test(bmi ~ treatment_uptake, data = dx)
```

R

```
#>
#>      Welch Two Sample t-test
#>
#> data:  bmi by treatment_uptake
#> t = -0.504, df = 1045, p-value = 0.61
#> alternative hypothesis: true difference in means between group No and group
#>   Yes is not equal to 0
#> 95 percent confidence interval:
#>  -0.72587  0.42912
#> sample estimates:
#> mean in group No mean in group Yes
#>      26.763      26.912
```

```
wilcox.test(bmi ~ treatment_uptake, data = dx) # để kiểm tra lại
```

R

```
#>
#>      Wilcoxon rank sum test with continuity correction
#>
#> data:  bmi by treatment_uptake
#> W = 135646, p-value = 0.52
#> alternative hypothesis: true location shift is not equal to 0
```

BMI trung bình là 26,8 kg/m² ở bệnh nhân không điều trị và 26,9 kg/m² ở bệnh nhân được điều trị; hiệu số (No trừ Yes) là -0.15 kg/m² (KTC 95% từ -0.73 đến 0,43; $p = 0.61$). Kiểm định Wilcoxon cho kết quả thống nhất ($p = 0.52$). Khoảng tin cậy hẹp và chỉ chứa những hiệu số quá nhỏ để có ý nghĩa lâm sàng, nên trong trường hợp này chúng ta có thể kết luận một cách hợp lý rằng BMI không khác biệt đáng kể giữa hai nhóm, chứ không chỉ đơn thuần là "kiểm định không có ý nghĩa".

Bài tập 4.3

1. Tóm tắt theo nhóm.

```
dx |>
  group_by(treatment_uptake) |>
  summarise(n = sum(!is.na(sbp_mmhg)),
            mean = mean(sbp_mmhg, na.rm = TRUE),
            sd = sd(sbp_mmhg, na.rm = TRUE))
```

```
#> # A tibble: 2 × 4
#>   treatment_uptake      n mean   sd
#>   <fct>           <int> <dbl> <dbl>
#> 1 No              581  142.  19.8
#> 2 Yes             507  148.  18.3
```

2. Kiểm định t Welch.

```
t.test(sbp_mmhg ~ treatment_uptake, data = dx)
```

```
#>
#>      Welch Two Sample t-test
#>
#> data:  sbp_mmhg by treatment_uptake
#> t = -5.14, df = 1082, p-value = 3.3e-07
#> alternative hypothesis: true difference in means between group No and group
#>   Yes is not equal to 0
#> 95 percent confidence interval:
#>  -8.2128 -3.6727
#> sample estimates:
#> mean in group No mean in group Yes
#>      142.16      148.10
```

Bệnh nhân đang điều trị có huyết áp tâm thu trung bình cao hơn những người không điều trị (148,1 so với 142,2 mmHg; hiệu số 5,9 mmHg, KTC 95% từ 3,7 đến 8,2 mmHg; kiểm định t Welch $p < 0.001$).


3. Diễn giải. Hiệu số khoảng 6 mmHg về huyết áp tâm thu trung bình có ý nghĩa lâm sàng ở cấp độ quần thể (mức giảm cỡ này đi kèm với sự giảm đáng kể nguy cơ tim mạch). Thoạt nhìn, hướng của khác biệt gây ngạc nhiên, vì điều trị phải làm *giảm* huyết áp. Tuy nhiên, trong một nghiên cứu cắt ngang, chúng ta không thể biết điều gì xảy ra trước: bệnh nhân có huyết áp cao hơn có nhiều khả năng được đề nghị và chấp nhận điều trị hơn (quan hệ nhân quả ngược, hay "nhiều do chỉ định" — confounding by indication), và bệnh nhân được điều trị có thể chưa được kiểm soát huyết áp. Một phép so sánh cắt ngang đơn lẻ không thể đánh giá tác động của điều trị lên huyết áp. (Dữ liệu là mô phỏng, nên khuôn mẫu này minh họa cách lập luận chứ không

phải một phát hiện thực tế.)

Bài tập 4.4

1. Biểu đồ hộp và bảng tóm tắt.

```
dx |>
  filter(!is.na(bmi_cat), !is.na(sbp_mmhg)) |>
  ggplot(aes(x = bmi_cat, y = sbp_mmhg)) +
  geom_jitter(width = 0.2, alpha = 0.15, size = 0.8, colour = course_teal) +
  geom_boxplot(fill = NA, outlier.shape = NA, width = 0.5) +
  labs(x = "Nhóm BMI", y = "HA tâm thu (mmHg)")
```



Hình A.7: Huyết áp tâm thu theo nhóm BMI ở bệnh nhân đã được chẩn đoán.

```
dx |>
  filter(!is.na(bmi_cat), !is.na(sbp_mmhg)) |>
  group_by(bmi_cat) |>
  summarise(n = n(), mean = mean(sbp_mmhg), sd = sd(sbp_mmhg))
```

```
#> # A tibble: 4 × 4
#>   bmi_cat      n mean  sd
#>   <fct>    <int> <dbl> <dbl>
#> 1 Underweight    51  127.  22.1
#> 2 Normal       308  140.  18.2
#> 3 Overweight   440  146.  18.9
#> 4 Obese        256  152.  16.9
```

Huyết áp tâm thu trung bình tăng đều từ khoảng 127 mmHg ở nhóm thiếu cân (Underweight) lên 152 mmHg ở nhóm béo phì (Obese).

2. ANOVA một yếu tố.

```
aov_sbp <- aov(sbp_mmhg ~ bmi_cat, data = dx)
summary(aov_sbp)
```

```
#>               Df Sum Sq Mean Sq F value Pr(>F)
#> bmi_cat         3  39096   13032    38.5 <2e-16 ***
#> Residuals    1051 355674     338
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
#> 34 observations deleted due to missingness
```

Dòng giữa các nhóm có $4 - 1 = 3$ bậc tự do và dòng phần dư có 1.051 bậc tự do ($N - k$ với $N = 1,055$). $F = 38.5$ với $p < 2 \times 10^{-16}$: bằng chứng rất mạnh cho thấy huyết áp tâm thu trung bình khác nhau giữa các nhóm BMI. Có 34 bệnh nhân bị loại vì thiếu thông tin nhóm BMI hoặc huyết áp tâm thu.

3. Kiểm định Kruskal–Wallis.

```
kruskal.test(sbp_mmhg ~ bmi_cat, data = dx)
```

R

```
#>
#>      Kruskal-Wallis rank sum test
#>
#> data:  sbp_mmhg by bmi_cat
#> Kruskal-Wallis chi-squared = 89.6, df = 3, p-value <2e-16
```

Kiểm định dựa trên thứ hạng cho kết quả thống nhất ($\chi^2 = 89.6$, 3 bậc tự do, $p < 0.001$).

4. So sánh từng cặp có hiệu chỉnh Bonferroni.

```
pairwise.t.test(dx$sbp_mmhg, dx$bmi_cat, p.adjust.method = "bonferroni")
```

R

```
#>
#>      Pairwise comparisons using t tests with pooled SD
#>
#> data:  dx$sbp_mmhg and dx$bmi_cat
#>
#>      Underweight Normal Overweight
#> Normal      3e-05      -          -
#> Overweight  2e-11      2e-05      -
#> Obese       <2e-16     1e-14     1e-04
#>
#> P value adjustment method: bonferroni
```

Cả sáu giá trị p đã hiệu chỉnh đều nhỏ hơn 0,001: mọi nhóm BMI đều khác với mọi nhóm còn lại, theo một gradient nhất quán (BMI càng cao, huyết áp tâm thu càng cao). Phương pháp Tukey (TukeyHSD(aov_sbp)) sẽ cho cùng kết luận và cung cấp thêm khoảng tin cậy cho từng hiệu số từng cặp.

Bài tập 4.5

1. Bảng và tỷ lệ phần trăm theo dòng.

```
tab_res <- table(Residence = dx$residence, Uptake = dx$treatment_uptake)
addmargins(tab_res)
```

R

```
#>           Uptake
#> Residence    No  Yes  Sum
#>      Rural  306  195  501
#>      Urban  275  313  588
#>       Sum   581  508 1089
```

```
round(100 * prop.table(tab_res, margin = 1), 1)
```

```
#>           Uptake
#> Residence    No  Yes
#>      Rural  61.1 38.9
#>      Urban  46.8 53.2
```

Tỷ lệ tiếp nhận điều trị là 53,2% ở bệnh nhân thành thị (Urban) và 38,9% ở bệnh nhân nông thôn (Rural).

2. Kiểm định khi bình phương và số đếm kỳ vọng.

```
chisq.test(tab_res)
```

```
#>
#>      Pearson's Chi-squared test with Yates' continuity correction
#>
#> data:  tab_res
#> X-squared = 21.7, df = 1, p-value = 3.2e-06
```

```
chisq.test(tab_res)$expected
```

```
#>           Uptake
#> Residence    No  Yes
#>      Rural 267.29 233.71
#>      Urban 313.71 274.29
```

$\chi^2 = 21.7$ với 1 bậc tự do, $p < 0.001$. Mọi số đếm kỳ vọng đều lớn hơn 230, nên xấp xỉ khi bình phương hoàn toàn phù hợp.

3. Hiệu số nguy cơ, nguy cơ tương đối và tỷ số chênh (thành thị so với nông thôn).

```
a <- tab_res["Urban", "Yes"]; b <- tab_res["Urban", "No"] # có phơi nhiễm
cc <- tab_res["Rural", "Yes"]; dd <- tab_res["Rural", "No"] # không phơi nhiễm
n1 <- a + b; n0 <- cc + dd
p1 <- a / n1; p0 <- cc / n0
```

```
rd <- p1 - p0
se_rd <- sqrt(p1 * (1 - p1) / n1 + p0 * (1 - p0) / n0)
rr <- p1 / p0
se_log_rr <- sqrt(1 / a - 1 / n1 + 1 / cc - 1 / n0)
or <- (a * dd) / (b * cc)
se_log_or <- sqrt(1 / a + 1 / b + 1 / cc + 1 / dd)
```

```
tibble(
```

```

measure = c("Hiệu số nguy cơ", "Nguy cơ tương đối", "Tỷ số chênh"),
estimate = c(rd, rr, or),
lower = c(rd - 1.96 * se_rd, exp(log(rr) - 1.96 * se_log_rr),
          exp(log(or) - 1.96 * se_log_or)),
upper = c(rd + 1.96 * se_rd, exp(log(rr) + 1.96 * se_log_rr),
          exp(log(or) + 1.96 * se_log_or))
) |>
knitr::kable(digits = 3,
              col.names = c("Thuốc đo", "Ước lượng", "Cận dưới", "Cận trên"),
              caption = "Nơi cư trú thành thị so với nông thôn và việc tiếp nhận
điều trị.")

```

Bảng A.6: Nơi cư trú thành thị so với nông thôn và việc tiếp nhận điều trị.

Thuốc đo	Ước lượng	Cận dưới	Cận trên
Hiệu số nguy cơ	0.143	0.084	0.202
Nguy cơ tương đối	1.368	1.197	1.563
Tỷ số chênh	1.786	1.402	2.275

Bệnh nhân thành thị có khả năng đang điều trị cao hơn bệnh nhân nông thôn 14,3 điểm phần trăm (KTC 95% từ 8,4 đến 20,2); nguy cơ (xác suất) tiếp nhận điều trị của họ cao gấp khoảng 1,37 lần (KTC 95% từ 1,20 đến 1,56), và odds cao gấp khoảng 1,79 lần (KTC 95% từ 1,40 đến 2,28). Cả ba khoảng tin cậy đều không chứa giá trị "không tác động".

4. Vì sao OR cách xa 1 hơn RR. Tỷ số chênh chỉ xấp xỉ nguy cơ tương đối khi biến kết cục hiếm gặp. Việc tiếp nhận điều trị là phổ biến (khoảng 40–55%), và khi nguy cơ cao, odds $p/(1-p)$ thay đổi nhanh hơn nhiều so với chính nguy cơ, nên OR (1,79) cách xa 1 hơn rõ rệt so với RR (1,37). Báo cáo OR như thế nó có nghĩa là "khả năng cao gấp 1,8 lần" sẽ phóng đại mối liên quan.

Bài tập 4.6

1. OR tích chéo và hồi quy logistic.

```

tab_diab <- table(Diabetes = dx$diabetes, Uptake = dx$treatment_uptake)
tab_diab

```

```

#>      Uptake
#> Diabetes No Yes
#>      No  574 487
#>      Yes   7  21

```

```

or_table <- (tab_diab["Yes", "Yes"] * tab_diab["No", "No"]) /
             (tab_diab["Yes", "No"] * tab_diab["No", "Yes"])
or_table

```

```

#> [1] 3.5359

```

```
m_diab <- glm(treatment_uptake ~ diabetes, data = dx, family = binomial)
tidy(m_diab, exponentiate = TRUE, conf.int = TRUE) |>
  select(term, estimate, p.value, conf.low, conf.high)
```

```
#> # A tibble: 2 × 5
#>   term          estimate p.value conf.low conf.high
#>   <chr>          <dbl>   <dbl>   <dbl>   <dbl>
#> 1 (Intercept)    0.848 0.00763    0.752    0.957
#> 2 diabetesYes    3.54 0.00416    1.56    9.04
```

Hai kết quả trùng khớp hoàn toàn: $(21 \times 574)/(7 \times 487) = 3.54$, và hệ số đã lấy mũ của diabetesYes cũng bằng 3,54. Hồi quy logistic với một biến dự báo nhị phân duy nhất tái tạo đúng bằng 2×2 .

2. Kiểm định chính xác Fisher.

```
fisher.test(tab_diab)
```

```
#>
#>      Fisher's Exact Test for Count Data
#>
#> data:  tab_diab
#> p-value = 0.0033
#> alternative hypothesis: true odds ratio is not equal to 1
#> 95 percent confidence interval:
#>  1.4313 9.9226
#> sample estimates:
#> odds ratio
#>      3.5321
```

Kiểm định Fisher báo cáo tỷ số chênh là 3,53. Đây là một ước lượng *hợp lý cực đại có điều kiện* (được tính với điều kiện các tổng biên của bảng cố định), không phải tỷ số tích chéo đơn giản, nên nó hơi khác, đặc biệt khi một số ô nhỏ. Khoảng tin cậy chính xác của nó (1,43 đến 9,92) cũng rộng hơn một chút so với khoảng tin cậy hợp lý hồ sơ (profile-likelihood) từ mô hình hồi quy (1,56 đến 9,04). Các giá trị p (0,003 và 0,004) dẫn đến cùng một kết luận.


3. Vì sao khoảng tin cậy rộng. Sai số chuẩn của logarit tỷ số chênh là $\sqrt{1/a + 1/b + 1/c + 1/d}$, đại lượng này bị chi phối bởi các ô nhỏ nhất. Chỉ có 28 bệnh nhân mắc đái tháo đường, và chỉ 7 người trong số họ không được điều trị, nên số hạng $1/7$ làm sai số chuẩn lớn (khoảng 0,44, so với 0,13 của biến bảo hiểm y tế, vốn có ô nhỏ nhất là 162). Dữ liệu tương thích với mọi mức từ một mối liên quan khiêm tốn đến một mối liên quan rất lớn.

Bài tập 4.7

1. Biểu đồ phân tán.

```
ggplot(dx, aes(x = age, y = knowledge_score)) +
  geom_jitter(width = 0, height = 0.2, alpha = 0.3, size = 1,
    colour = course_teal) +
  geom_smooth(method = "lm", formula = y ~ x, colour = "black") +
  labs(x = "Tuổi (năm)", y = "Điểm kiến thức (0-20)")
```

Đám mây điểm không có hình dạng rõ ràng và đường hồi quy nằm ngang.



Hình A.8: Điểm kiến thức về tăng huyết áp theo tuổi ở bệnh nhân đã được chẩn đoán, với đường bình phương tối thiểu.

2. Tương quan với tuổi.

```
cor.test(dx$age, dx$knowledge_score)
```

R

```
#>
#>      Pearson's product-moment correlation
#>
#> data:  dx$age and dx$knowledge_score
#> t = 0.343, df = 1057, p-value = 0.73
#> alternative hypothesis: true correlation is not equal to 0
#> 95 percent confidence interval:
#>  -0.049719  0.070749
#> sample estimates:
#>      cor
#> 0.010553
```

```
cor.test(dx$age, dx$knowledge_score, method = "spearman", exact = FALSE)
```

R

```
#>
#>      Spearman's rank correlation rho
#>
#> data:  dx$age and dx$knowledge_score
#> S = 1.95e+08, p-value = 0.66
#> alternative hypothesis: true rho is not equal to 0
#> sample estimates:
#>      rho
#> 0.013459
```

Hệ số Pearson $r = 0.011$ (KTC 95% từ -0.050 đến 0.071 ; $p = 0.73$) và hệ số Spearman $r_s = 0.013$ ($p = 0.66$). Không có bằng chứng về mối liên quan tuyến tính hay đơn điệu, và khoảng tin cậy cho thấy mọi tương quan tuyến tính nếu có cũng rất yếu (giá trị hợp lý lớn nhất, 0,07, tương ứng với việc tuổi giải thích chưa đến 1% biến thiên).

3. Tương quan với khoảng cách.

```
cor.test(dx$distance_to_facility_km, dx$knowledge_score)
```

R

```
#>
#>      Pearson's product-moment correlation
#>
#> data:  dx$distance_to_facility_km and dx$knowledge_score
#> t = -0.318, df = 1014, p-value = 0.75
#> alternative hypothesis: true correlation is not equal to 0
#> 95 percent confidence interval:
#>  -0.071439  0.051555
#> sample estimates:
#>      cor
#> -0.0099799
```

```
cor.test(dx$distance_to_facility_km, dx$knowledge_score,
         method = "spearman", exact = FALSE)
```

R

```
#>
#>      Spearman's rank correlation rho
#>
#> data:  dx$distance_to_facility_km and dx$knowledge_score
#> S = 1.78e+08, p-value = 0.52
#> alternative hypothesis: true rho is not equal to 0
#> sample estimates:
#>      rho
#> -0.020245
```

Cả hai hệ số đều gần bằng 0 ($r = -0.010$, $r_s = -0.020$). Hệ số Spearman phù hợp hơn ở đây, vì khoảng cách lệch phải mạnh và một vài khoảng cách rất lớn có thể ảnh hưởng quá mức đến r Pearson; hệ số dựa trên thứ hạng không bị ảnh hưởng bởi chúng.

4. Nhận xét. Nhận định này mắc hai lỗi. Thứ nhất, một giá trị p không có ý nghĩa không phải là bằng chứng cho thấy không có mối quan hệ (không có bằng chứng không phải là bằng chứng của sự không có); tuy nhiên, ở đây khoảng tin cậy hẹp thực sự ủng hộ kết luận rằng mọi mối liên quan *tuyến tính* đều rất yếu. Thứ hai, và quan trọng hơn, việc không có tương quan giữa tuổi và kiến thức không nói lên điều gì về việc bệnh nhân lớn tuổi (hay trẻ tuổi) có *được lợi* từ giáo dục sức khỏe nhằm mục tiêu hay không: điều đó phụ thuộc vào nhu cầu của họ và vào việc tiếp nhận điều trị, vốn có liên quan đến tuổi (Mục 4.4). Tương quan cũng chỉ nắm bắt các khuôn mẫu tuyến tính (Pearson) hoặc đơn điệu (Spearman); một mối quan hệ hình chữ U có thể bị bỏ sót, và đó là lý do chúng ta vẽ đồ thị trước.

Bài tập 4.8

1. Tám kiểm định khi bình phương.

```
vars <- c("sex", "residence", "education", "occupation",
         "marital_status", "smoking", "alcohol", "facility")

screen <- tibble(
  variable = vars,
  p_raw = map_dbl(vars, function(v) {
```

R

```
chisq.test(table(dx[[v]], dx$treatment_uptake))$p.value
})
)
```

2. Hiệu chỉnh Bonferroni và Holm.

```
screen |>
  mutate(p_bonferroni = p.adjust(p_raw, method = "bonferroni"),
         p_holm      = p.adjust(p_raw, method = "holm")) |>
  arrange(p_raw) |>
  # hiển thị giá trị p rất nhỏ là "<0.001" thay vì làm tròn thành 0
  mutate(across(starts_with("p_"),
                 \ (x) scales::pvalue(x, accuracy = 0.001))) |>
  knitr::kable(
    col.names = c("Biến", "p chưa hiệu chỉnh", "p Bonferroni",
                  "p Holm"),
    caption = "Giá trị p chưa hiệu chỉnh và đã hiệu chỉnh của tám kiểm
              định khi bình phương về mối liên quan với việc tiếp nhận điều trị.")
```

Bảng A.7: Giá trị p chưa hiệu chỉnh và đã hiệu chỉnh của tám kiểm định khi bình phương về mối liên quan với việc tiếp nhận điều trị.

Biến	p chưa hiệu chỉnh	p Bonferroni	p Holm
residence	<0.001	<0.001	<0.001
education	<0.001	0.002	0.002
sex	0.014	0.108	0.081
alcohol	0.123	0.984	0.615
facility	0.135	>0.999	0.615
smoking	0.230	>0.999	0.691
occupation	0.353	>0.999	0.706
marital_status	0.885	>0.999	0.885

Trước khi hiệu chỉnh, có ba biến có $p < 0.05$: nơi cư trú (*residence*), học vấn (*education*) và giới tính (*sex*). Sau khi hiệu chỉnh Bonferroni hoặc Holm, chỉ còn nơi cư trú và học vấn nhỏ hơn 0,05; mối liên quan với giới tính ($p = 0.014$ chưa hiệu chỉnh) không còn giữ được. Phương pháp Holm là một cải tiến theo từng bước giảm dần (step-down) của Bonferroni, luôn có lực thống kê cao hơn trong khi vẫn kiểm soát tỷ lệ sai lầm chung (family-wise error rate): nó so sánh giá trị p nhỏ nhất với α/m , giá trị p tiếp theo với $\alpha/(m-1)$, và cứ thế tiếp tục.

3. Khả năng có ít nhất một kết quả dương tính giả.

```
1 - 0.95^8
```

```
#> [1] 0.33658
```

Nếu cả tám giả thuyết không đều đúng và các kiểm định độc lập với nhau, xác suất có ít nhất một giá trị p nhỏ hơn 0,05 là khoảng 34%. Vì vậy, một bài báo sàng lọc nhiều biến và chỉ báo cáo những biến "có ý nghĩa" nhiều khả năng sẽ báo cáo một số mối liên quan dương tính giả; bài báo nên báo cáo mọi kiểm định đã thực hiện, mô tả phân tích là mang tính thăm dò, và hoặc hiệu chỉnh cho vấn đề so sánh bội, hoặc diễn giải thận trọng những giá trị p nhỏ đơn lẻ.

A.5 Chương 5: Mô hình hồi quy và báo cáo kết quả

Các lời giải này sử dụng cùng các gói, dữ liệu và mô hình chính như ở Chương 5. Mã thiết lập dưới đây tạo lại quần thể phân tích (dx), mô hình đa biến được xác định trước (model_full) và dữ liệu trường hợp đầy đủ của nó (cc). Hãy nhớ rằng dữ liệu được mô phỏng cho mục đích giảng dạy: các kết quả minh họa phương pháp, không phải phát hiện lâm sàng thực tế.

```
analysis_data <- readRDS("Data/analysis_data.rds")

# Bệnh nhân đã chẩn đoán; education là factor không thứ tự (tham chiếu "None")
dx <- analysis_data |>
  filter(htn_diagnosed == "Yes") |>
  mutate(education = factor(education, ordered = FALSE))

model_full <- glm(
  treatment_uptake ~ age + sex + education + residence + diabetes +
    family_history_htn + health_insurance + knowledge_score +
    distance_to_facility_km,
  data = dx, family = binomial
)
cc <- model.frame(model_full) # 992 trường hợp đầy đủ
```

Bài tập 5.1

Chúng ta xây dựng mô hình tuyến tính trên tất cả người trưởng thành có dữ liệu đầy đủ ở bốn biến và trích xuất các hệ số kèm khoảng tin cậy.

```
lm_sex <- lm(sbp_mmhg ~ age + bmi + sex, data = analysis_data)
summary(lm_sex)$coefficients |> round(3)
```

```
#>               Estimate Std. Error t value Pr(>|t|)
#> (Intercept)    87.309      3.214   27.168   0.000
#> age             0.260      0.034    7.714   0.000
#> bmi             1.451      0.098   14.870   0.000
#> sexMale         0.325      0.966    0.336   0.737
```

```
# Tuổi cho mỗi 10 năm, kèm KTC 95%
age10 <- 10 * c(coef(lm_sex)["age"], confint(lm_sex)["age", ])
round(age10, 2)
```

```
#>   age  2.5 % 97.5 %
#>  2.60   1.94   3.26
```


```
c(n = nobs(lm_sex), R2 = round(summary(lm_sex)$r.squared, 3),
  adj_R2 = round(summary(lm_sex)$adj.r.squared, 3))
```

```
#>      n      R2   adj_R2
#> 1449.000 0.161  0.159
```

1. Mỗi 10 năm tuổi tăng thêm có liên quan đến SBP trung bình cao hơn 2.6 mmHg (KTC 95%)

- 1.9 đến 3.3), khi giữ cố định BMI và giới.
2. Nam giới có SBP trung bình cao hơn 0.3 mmHg so với nữ giới cùng tuổi và cùng BMI (KTC 95% -1.6 đến 2.2). Khoảng tin cậy chứa giá trị không, nên dữ liệu tương thích với việc không có khác biệt về SBP trung bình theo giới.
3. Mô hình giải thích được 16.1% phương sai của SBP, về cơ bản giống với mô hình không có biến giới trong chương. Việc thêm biến giới đóng góp rất ít.
4. Đồ thị phân dư được trình bày dưới đây.

```
augment(lm_sex) |>
  ggplot(aes(.fitted, .resid)) +
  geom_point(alpha = 0.25, colour = "#0D7377") +
  geom_hline(yintercept = 0, linetype = "dashed") +
  geom_smooth(method = "loess", se = FALSE, colour = "#E07A1F") +
  labs(x = "SBP ước lượng (mmHg)", y = "Phần dư (mmHg)")
```



Hình A.9: Phần dư theo giá trị ước lượng của mô hình hồi quy tuyến tính SBP theo tuổi, BMI và giới.

Các phần dư tạo thành một dải có độ rộng gần như không đổi quanh giá trị không, không có độ cong hay hình phễu rõ rệt, nên các giả định về tính tuyến tính và phương sai bằng nhau có vẻ hợp lý. (Một đồ thị Q-Q, như trong chương, sẽ được dùng để kiểm tra tính chuẩn.)

Bài tập 5.2

```
tab_fh <- table(FamilyHistory = dx$family_history_htn,
  Uptake = dx$treatment_uptake)
tab_fh
```

```
#>           Uptake
#> FamilyHistory No Yes
#>           No  398 297
#>           Yes  183 211
```

```
fh <- dx |>
  group_by(family_history_htn) |>
  summarise(n = n(), p = mean(treatment_uptake == "Yes")) |>
  mutate(odds = p / (1 - p))
kable(fh, digits = 3,
      caption = "Sử dụng điều trị theo tiền sử gia đình bị tăng huyết áp.")
```

Bảng A.8: Sử dụng điều trị theo tiền sử gia đình bị tăng huyết áp.

family_history_htn	n	p	odds
No	695	0.427	0.746
Yes	394	0.536	1.153

```
or_fh <- fh$odds[2] / fh$odds[1]      # tỷ số chênh thô
rr_fh <- fh$p[2] / fh$p[1]            # tỷ số nguy cơ thô
c(OR = round(or_fh, 3), RR = round(rr_fh, 3))
```

```
#>      OR      RR
#> 1.545 1.253
```

```
glm_fh <- glm(treatment_uptake ~ family_history_htn, data = dx,
              family = binomial)
exp(coef(glm_fh))
```

```
#>      (Intercept) family_history_htnYes
#>      0.7462      1.5451
```

```
# Chuyển đổi OR sang RR theo Zhang và Yu, dùng nguy cơ ở nhóm tham chiếu
p0 <- fh$p[1]
round(or_fh / ((1 - p0) + p0 * or_fh), 3)
```

```
#> [1] 1.253
```

1. Khi không có tiền sử gia đình, 42.7% bệnh nhân đang điều trị (odds 0.75); khi có tiền sử gia đình, tỷ lệ này là 53.6% (odds 1.15). OR thô bằng 1.55.
2. Hàm mũ của hệ số từ `glm()` cho kết quả giống hệt: một mô hình hồi quy logistic với một biến dự báo tái tạo đúng bằng 2×2 .
3. RR thô bằng 1.25, nhỏ hơn OR. Việc sử dụng điều trị phổ biến (khoảng 40–55%), nên odds lớn hơn nhiều so với nguy cơ và OR nằm xa 1 hơn RR. Công thức của Zhang và Yu, với $p_0 = 0.427$, khôi phục chính xác RR khi áp dụng cho một OR thô.

Bài tập 5.3

Chúng ta nhân mỗi hệ số và các giới hạn tin cậy hợp lý hồ sơ của nó với mức tăng đã chọn trước khi lấy hàm mũ.

```
ci_log <- confint(model_full)
tibble(term = c("age", "knowledge_score", "distance_to_facility_km"),
  increment = c(10, 5, 10)) |>
  mutate(OR = exp(increment * coef(model_full)[term]),
    lower = exp(increment * ci_log[term, 1]),
    upper = exp(increment * ci_log[term, 2])) |>
  kable(digits = 2, caption = "OR hiệu chỉnh cho các mức tăng đã chọn.")
```

Bảng A.9: OR hiệu chỉnh cho các mức tăng đã chọn.

term	increment	OR	lower	upper
age	10	1.35	1.23	1.50
knowledge_score	5	1.60	1.31	1.96
distance_to_facility_km	10	0.83	0.65	1.05

Một thập kỷ tuổi là một đơn vị lâm sàng tự nhiên, và chênh lệch 5 điểm kiến thức (một phần tư thang điểm 0–20, gần bằng khoảng tứ phân vị) dễ diễn giải. Với khoảng cách, 10 km gần bằng chênh lệch giữa việc sống ngay cạnh phòng khám và sống ở mức tứ phân vị trên của khoảng cách trong mẫu này. Các mức tăng phải được chọn trước khi phân tích (và được nêu trong phần Phương pháp), vì nếu không, nhà phân tích có thể chọn bất kỳ đơn vị nào làm cho một mối liên quan trông ấn tượng nhất; lựa chọn này làm thay đổi độ lớn của OR nhưng không làm thay đổi giá trị p của nó.

Bài tập 5.4

```
glm_ins_cc <- glm(treatment_uptake ~ health_insurance, data = cc,
  family = binomial)
b_crude <- coef(glm_ins_cc)["health_insuranceYes"]
b_adj <- coef(model_full)["health_insuranceYes"]

c(crude_OR = exp(b_crude), adjusted_OR = exp(b_adj),
  pct_change_logOR = 100 * (b_adj - b_crude) / b_crude) |>
  unname() |> setNames(c("crude_OR", "adjusted_OR", "pct_change_logOR")) |>
  round(2)
```

```
#>      crude_OR      adjusted_OR pct_change_logOR
#>          1.67          2.05          40.24
```

1. OR dịch chuyển từ 1.67 (thô) lên 2.05 (hiệu chỉnh), một mức thay đổi khoảng 40% của log OR, vượt xa ngưỡng thay đổi ước lượng 10%.
2. Một sơ đồ nhân quả hợp lý: bảo hiểm làm tăng việc sử dụng điều trị (bằng cách giảm chi phí thuốc và khám bệnh). Học vấn, nơi cư trú và tuổi có thể ảnh hưởng đến cả việc một người có bảo hiểm hay không lẫn việc họ có sử dụng điều trị hay không, nên chúng là các yếu tố gây nhiễu tiềm tàng. Điểm kiến thức có thể là biến trung gian nếu các chương trình bảo hiểm cung cấp giáo dục sức khỏe, hoặc là yếu tố gây nhiễu nếu những người hiểu biết hơn chủ động tìm kiếm bảo hiểm; chiều hướng chưa chắc chắn. Đái tháo đường và tiền sử gia đình khó có thể do bảo hiểm gây ra và chủ yếu ảnh hưởng đến biến kết cục.
3. Để phân định giữa nhiễu và tính không thể gộp, chúng ta có thể kiểm tra mức độ liên quan

giữa bảo hiểm và các biến dự báo khác, và tính một OR *biên* (marginal, lấy trung bình trên quần thể) từ mô hình hiệu chỉnh bằng phương pháp chuẩn hóa: dự báo xác suất sử dụng điều trị của mọi bệnh nhân khi bảo hiểm được đặt là "Yes" và là "No", lấy trung bình mỗi trường hợp, rồi tính OR của hai giá trị trung bình đó. Chuẩn hóa loại bỏ nhiễu do các hiệp biến trong mô hình nhưng, khác với OR có điều kiện, nó có tính gộp được (collapsible).

```
# Bảo hiểm có liên quan đến các biến dự báo khác không? (OR gần 1 = yếu)
glm(health_insurance ~ age + sex + education + residence + diabetes +
    family_history_htn + knowledge_score + distance_to_facility_km,
    data = cc, family = binomial) |>
tidy(exponentiate = TRUE) |>
filter(term != "(Intercept)") |>
select(term, OR = estimate, p = p.value) |>
mutate(OR = round(OR, 2), p = round(p, 3))
```

```
#> # A tibble: 10 × 3
#>   term                OR      p
#>   <chr>              <dbl> <dbl>
#> 1 age                0.99 0.237
#> 2 sexMale            1.01 0.939
#> 3 educationPrimary   1.2  0.341
#> 4 educationSecondary 1.21 0.362
#> 5 educationTertiary  1.09 0.736
#> 6 residenceUrban     0.8  0.128
#> 7 diabetesYes        0.4  0.101
#> 8 family_history_htn 0.82 0.178
#> 9 knowledge_score    0.97 0.161
#> 10 distance_to_facility_km 0.99 0.243
```

```
# OR biên bằng chuẩn hóa trên các hiệp biến quan sát được
all_yes <- mutate(cc, health_insurance = "Yes") # mọi người đều có bảo hiểm
all_no  <- mutate(cc, health_insurance = "No")  # không ai có bảo hiểm
p_yes <- mean(predict(model_full, newdata = all_yes, type = "response"))
p_no  <- mean(predict(model_full, newdata = all_no, type = "response"))
c(p_insured = p_yes, p_uninsured = p_no,
  marginal_OR = (p_yes / (1 - p_yes)) / (p_no / (1 - p_no))) |> round(3)
```

```
#>   p_insured p_uninsured marginal_OR
#>      0.564      0.409      1.869
```

Bảo hiểm chỉ liên quan yếu với phần lớn các biến dự báo khác, nhưng bệnh nhân có bảo hiểm có phần ít khả năng sống ở thành thị, có đái tháo đường hoặc có tiền sử gia đình hơn, mà tất cả các yếu tố này đều thuận lợi cho việc sử dụng điều trị. Điều này tạo ra một mức nhiễu âm (negative confounding) đối với OR thô. OR chuẩn hóa (biên), 1.87, loại bỏ nhiễu đó trong khi vẫn ở trên thang trung bình quần thể giống như OR thô. Do đó, chúng ta có thể chia sự thay đổi trên thang log-odds thành hai phần:

- từ thô đến biên, từ 1.67 lên 1.87: sự thay đổi do **nhiều** từ các hiệp biến đã đo lường;
- từ biên đến có điều kiện, từ 1.87 lên 2.05: sự thay đổi do **tính không thể gộp**.

```
logs <- c(crude = b_crude, marginal = log(marg_or), conditional = b_adj)
c(confounding_part = unname(logs[2] - logs[1]),
  noncollapsibility_part = unname(logs[3] - logs[2])) |> round(3)
```

```
#>      confounding_part noncollapsibility_part
#>                0.114                0.092
```

Hai thành phần có độ lớn tương đương nhau. Vậy câu trả lời là "cả hai": khoảng một nửa sự thay đổi từ OR thô sang OR hiệu chỉnh phản ánh nhiều (bệnh nhân có bảo hiểm có ít các đặc điểm khác thuận lợi cho việc sử dụng điều trị hơn), và khoảng một nửa phản ánh tính không thể gộp. Cả hai OR đều hợp lệ, nhưng chúng trả lời những câu hỏi khác nhau: OR có điều kiện so sánh những bệnh nhân có cùng giá trị hiệp biến; OR biên so sánh toàn bộ quần thể khi có và không có bảo hiểm.

Bài tập 5.5

```
drop1(model_full, test = "LRT")["education", ]
```

```
#> Single term deletions
#>
#> Model:
#> treatment_uptake ~ age + sex + education + residence + diabetes +
#>   family_history_htn + health_insurance + knowledge_score +
#>   distance_to_facility_km
#>      Df Deviance   AIC   LRT Pr(>Chi)
#> education  3      1238 1256 16.3    0.001 **
#> ---
#> Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

1. Kiểm định LR so sánh `model_full` với cùng mô hình đó nhưng không có ba biến chỉ thị học vấn. Giả thuyết không là cả ba hệ số của học vấn đều bằng không, nghĩa là odds sử dụng điều trị như nhau ở mọi mức học vấn khi đã tính đến các biến khác. Giả thuyết này bị bác bỏ ($p \approx 0.001$).

```
cc_num <- cc |> mutate(edu_num = as.integer(education) - 1) # 0, 1, 2, 3
```

```
model_trend <- glm(
  treatment_uptake ~ age + sex + edu_num + residence + diabetes +
  family_history_htn + health_insurance + knowledge_score +
  distance_to_facility_km,
  data = cc_num, family = binomial
)
tidy(model_trend, exponentiate = TRUE, conf.int = TRUE) |>
  filter(term == "edu_num") |>
  select(term, OR = estimate, conf.low, conf.high, p.value)
```

```
#> # A tibble: 1 × 5
#>   term      OR conf.low conf.high  p.value
#>   <chr>   <dbl>   <dbl>   <dbl>   <dbl>
#> 1 edu_num 1.36     1.17     1.58 0.0000673
```

```
AIC(model_full, model_trend)
```

R

```
#>           df  AIC
#> model_full 12 1246
#> model_trend 10 1242
```

1. Với học vấn được mã hóa 0–3, mỗi bậc tăng trên thang học vấn (None lên Primary, Primary lên Secondary, Secondary lên Tertiary) có liên quan đến odds sử dụng điều trị gấp 1.36 lần. Điều này giả định OR như nhau cho mọi bậc, nên OR của Tertiary so với None là $1.36^3 = 2.49$.
2. Mô hình xu hướng có AIC 1242.0 so với 1245.9 của mô hình factor: nó khớp tốt ngang bằng với ít hơn hai tham số, và do đó được ưu tiên theo AIC (chênh lệch khoảng 4 điểm). Các OR theo nhóm trong chương (1,39, 1,92, 2,44) quả thực tăng gần theo cấp số nhân. Cả hai lựa chọn đều có thể biện minh được; điều quan trọng là lựa chọn phải được đưa ra *trước khi* xem kết quả. Phiên bản factor dễ diễn giải hơn cho người đọc và không giả định các bậc bằng nhau; phiên bản xu hướng tiết kiệm tham số hơn và cho một ước lượng duy nhất, chính xác hơn. Một cách tiếp cận hợp lý là báo cáo các nhóm trong bảng và đề cập đến kiểm định xu hướng trong phần văn bản.

Bài tập 5.6

```
model_fac <- update(model_full, . ~ . + facility)
anova(model_full, model_fac, test = "LRT")[, 3:5]
```

R

```
#>   Df Deviance Pr(>Chi)
#> 1
#> 2 5         7.6      0.18
```

```
# Phần trăm thay đổi của mỗi OR chung khi thêm cơ sở y tế
shared <- names(coef(model_full))[-1]
tibble(term = shared,
        OR_without = exp(coef(model_full)[shared]),
        OR_with = exp(coef(model_fac)[shared])) |>
  mutate(pct_change = 100 * (OR_with - OR_without) / OR_without) |>
  kable(digits = 2, caption = "OR hiệu chỉnh khi có và không có cơ sở y tế.")
```

R

```
auc_without <- auc(roc(model_full$y, fitted(model_full), quiet = TRUE))
auc_with <- auc(roc(model_fac$y, fitted(model_fac), quiet = TRUE))
round(c(without = auc_without, with = auc_with), 3)
```

R

```
#> without  with
#>   0.715   0.721
```

1. Thêm năm biến chỉ thị cơ sở y tế làm giảm độ lệch 7.6 với 5 bậc tự do ($p = 0.18$): không có bằng chứng rõ ràng rằng việc sử dụng điều trị khác nhau giữa các cơ sở sau khi hiệu chỉnh.

Bảng A.10: OR hiệu chỉnh khi có và không có cơ sở y tế.

term	OR_without	OR_with	pct_change
age	1.03	1.03	0.03
sexMale	0.74	0.74	0.33
educationPrimary	1.39	1.40	0.68
educationSecondary	1.92	1.96	2.37
educationTertiary	2.44	2.48	1.65
residenceUrban	1.87	1.87	-0.05
diabetesYes	3.56	3.74	5.21
family_history_htnYes	1.91	1.92	0.75
health_insuranceYes	2.05	2.04	-0.57
knowledge_score	1.10	1.10	0.20
distance_to_facility_km	0.98	0.98	-0.16

- Mức thay đổi lớn nhất của bất kỳ OR nào khác là 5.2% (đối với diabetesYes); không có OR nào thay đổi quá 10%. Cơ sở y tế không gây nhiều các mối liên quan khác.
- AUC chỉ tăng nhẹ, từ 0.715 lên 0.721, như kỳ vọng mỗi khi thêm số hạng vào một mô hình được đánh giá trên chính dữ liệu của nó. Cơ sở y tế bổ sung rất ít. Tuy nhiên, nó vẫn là một biến thiết kế: bệnh nhân trong cùng một cơ sở có thể tương quan với nhau, và một phân tích độ nhạy với cơ sở y tế là tác động cố định (hoặc với sai số chuẩn vững theo cụm) đáng được báo cáo để cho thấy các kết luận không phụ thuộc vào việc bỏ qua tính cụm.

Bài tập 5.7

```
model_ir <- update(model_full, . ~ . + health_insurance:residence)
anova(model_full, model_ir, test = "LRT")[, 3:5]
```

R

```
#>   Df Deviance Pr(>Chi)
#> 1
#> 2   1     0.303     0.58
```

Để thu được OR của bảo hiểm trong mỗi nhóm nơi cư trú, lưu ý rằng trong mô hình tương tác, log OR của bảo hiểm là β_{ins} ở bệnh nhân nông thôn (nhóm tham chiếu) và $\beta_{ins} + \beta_{int}$ ở bệnh nhân thành thị. Phương sai của tổng là $Var(\beta_{ins}) + Var(\beta_{int}) + 2 Cov(\beta_{ins}, \beta_{int})$, lấy từ ma trận phương sai–hiệp phương sai `vcov()`.

```
b <- coef(model_ir)
V <- vcov(model_ir)
ins <- "health_insuranceYes"
int <- "residenceUrban:health_insuranceYes"

log_or <- c(rural = unname(b[ins]),
            urban = unname(b[ins] + b[int]))
se <- c(rural = sqrt(V[ins, ins]),
        urban = sqrt(V[ins, ins] + V[int, int] + 2 * V[ins, int]))
```

R

```
tibble(residence = names(log_or),
       OR      = exp(log_or),
       lower   = exp(log_or - 1.96 * se),
       upper   = exp(log_or + 1.96 * se)) |>
kable(digits = 2,
      caption = "OR của bảo hiểm y tế theo nơi cư trú (KTC Wald).")
```

Bảng A.11: OR của bảo hiểm y tế theo nơi cư trú (KTC Wald).

residence	OR	lower	upper
rural	1.88	1.24	2.86
urban	2.21	1.48	3.30

- Một cách viết có thể: "Mối liên quan giữa bảo hiểm y tế và việc sử dụng điều trị không khác biệt đáng kể theo nơi cư trú (kiểm định tỷ số hợp lý cho tương tác $p = 0.58$); OR hiệu chỉnh của bảo hiểm là 1.88 (KTC 95% 1.24 đến 2.86) ở bệnh nhân nông thôn và 2.21 (1.48 đến 3.30) ở bệnh nhân thành thị. Do đó, chúng tôi báo cáo mô hình không có số hạng tương tác." Lưu ý rằng hai khoảng tin cậy theo từng tầng chồng lấn nhau rất nhiều; giả thuyết của nhà kinh tế không được dữ liệu này ủng hộ, mặc dù nghiên cứu không được thiết kế với đủ lực thống kê để phát hiện một tương tác ở mức vừa phải.

Bài tập 5.8

```
treated <- dx |> filter(treatment_uptake == "Yes")
table(treated$bp_controlled, useNA = "ifany")
```

```
#>
#>   No Yes
#> 470  38
```

```
table(Diabetes = treated$diabetes, Controlled = treated$bp_controlled)
```

```
#>           Controlled
#> Diabetes   No Yes
#>       No  449  38
#>       Yes   21   0
```

- Chỉ 38 trong số 508 bệnh nhân đang điều trị có huyết áp được kiểm soát. Ở đây *biến cố* là nhóm ít gặp hơn, huyết áp được kiểm soát, nên cỡ mẫu hiệu dụng là 38, không phải 508.
- Với 10 biến cố cho mỗi tham số, mô hình có thể hỗ trợ khoảng 3 tham số. Ngay cả con số này cũng là lạc quan, và các ước lượng sẽ kém chính xác.
- Chúng ta xác định trước ba tham số: tuổi, BMI và tuân thủ điều trị (tốt so với kém), tất cả đều là những yếu tố quyết định hợp lý về mặt lâm sàng đối với việc kiểm soát huyết áp. Giới được bỏ ra để tôn trọng giới hạn EPV. Không thể dùng đại tháo đường: không bệnh nhân đại tháo đường nào đang điều trị có huyết áp được kiểm soát, nên mô hình sẽ gặp hiện tượng tách biệt.

```
model_bp <- glm(bp_controlled ~ age + bmi + adherence,
  data = treated, family = binomial)
nobs(model_bp)
```

```
#> [1] 494
```

```
tidy(model_bp, exponentiate = TRUE, conf.int = TRUE) |>
  filter(term != "(Intercept)") |>
  select(term, OR = estimate, conf.low, conf.high, p.value) |>
  mutate(across(OR:conf.high, \(x) round(x, 2)), p.value = round(p.value, 3))
```

```
#> # A tibble: 3 × 5
#>   term          OR conf.low conf.high p.value
#>   <chr>        <dbl>   <dbl>   <dbl>   <dbl>
#> 1 age          0.97     0.95     0.99   0.013
#> 2 bmi          0.88     0.81     0.95   0.001
#> 3 adherenceGood 0.36     0.16     0.76   0.011
```

```
auc_bp <- auc(roc(model_bp$y, fitted(model_bp), quiet = TRUE))
round(auc_bp, 3)
```

```
#> [1] 0.739
```

1. Một đoạn Kết quả có thể viết: "Trong số 508 bệnh nhân đang điều trị thuốc hạ huyết áp, 38 người (7.5%) có huyết áp được kiểm soát. Do số bệnh nhân có huyết áp được kiểm soát ít, mô hình được giới hạn ở ba biến dự báo đã xác định trước. BMI cao hơn có liên quan đến odds kiểm soát thấp hơn (OR cho mỗi 5 kg/m² 0.52, KTC 95% 0.36 đến 0.76), tuổi cao hơn cũng vậy (OR cho mỗi 10 năm 0.73, KTC 95% 0.57 đến 0.93). Tuân thủ điều trị tốt có liên quan đến odds kiểm soát thấp hơn so với tuân thủ kém (OR 0.36, KTC 95% 0.16 đến 0.76), một phát hiện không như kỳ vọng. Khả năng phân biệt của mô hình ở mức chấp nhận được (AUC 0.74). Với chỉ 38 biến cố, các ước lượng kém chính xác và cần được diễn giải thận trọng."

Kết quả về tuân thủ điều trị đi ngược với kỳ vọng lâm sàng. Trong một nghiên cứu thực tế, nó sẽ thúc đẩy việc kiểm tra cách đo lường tuân thủ điều trị và kiểm soát huyết áp (ví dụ, bệnh nhân kiểm soát kém có thể được tư vấn nhiều hơn và sau đó báo cáo tuân thủ tốt hơn: quan hệ nhân quả ngược trong một thiết kế cắt ngang). Ở đây, đó đơn giản là một đặc điểm của dữ liệu mô phỏng, và là lời nhắc nhở rằng những kết quả khó tin cần được xem xét kỹ lưỡng thay vì được giải thích một cách sáng tạo. Cũng lưu ý rằng các KTC hợp lý hồ sơ cho các OR đã đổi thang đo được thu được bằng cách nhân các giới hạn trên thang log với mức tăng, như trong chương.

Tài liệu tham khảo

- Agresti, A. (2013). *Categorical Data Analysis*. 3rd ed. Hoboken, NJ: Wiley.
- Altman, D. G. (1991). *Practical Statistics for Medical Research*. London: Chapman and Hall.
- Altman, D. G. and J. M. Bland (1994). “Quartiles, Quintiles, Centiles, and Other Quantiles”. In: *BMJ* 309.6960, p. 996. doi: [10.1136/bmj.309.6960.996](https://doi.org/10.1136/bmj.309.6960.996).
- Altman, D. G. and J. M. Bland (1995a). “Absence of Evidence Is Not Evidence of Absence”. In: *BMJ* 311.7003, p. 485. doi: [10.1136/bmj.311.7003.485](https://doi.org/10.1136/bmj.311.7003.485).
- Altman, D. G. and J. M. Bland (1995b). “Statistics Notes: The Normal Distribution”. In: *BMJ* 310.6975, p. 298. doi: [10.1136/bmj.310.6975.298](https://doi.org/10.1136/bmj.310.6975.298).
- Bland, J. M. and D. G. Altman (1995). “Multiple Significance Tests: The Bonferroni Method”. In: *BMJ* 310.6973, p. 170. doi: [10.1136/bmj.310.6973.170](https://doi.org/10.1136/bmj.310.6973.170).
- Bland, J. M. and D. G. Altman (2000). “The Odds Ratio”. In: *BMJ* 320.7247, p. 1468. doi: [10.1136/bmj.320.7247.1468](https://doi.org/10.1136/bmj.320.7247.1468).
- Bland, M. (2015). *An Introduction to Medical Statistics*. 4th ed. Oxford: Oxford University Press.
- Broman, K. W. and K. H. Woo (2018). “Data Organization in Spreadsheets”. In: *The American Statistician* 72.1, pp. 2–10. doi: [10.1080/00031305.2017.1375989](https://doi.org/10.1080/00031305.2017.1375989).
- Buuren, S. van and K. Groothuis-Oudshoorn (2011). “mice: Multivariate Imputation by Chained Equations in R”. In: *Journal of Statistical Software* 45.3, pp. 1–67. doi: [10.18637/jss.v045.i03](https://doi.org/10.18637/jss.v045.i03).
- Elm, E. von, D. G. Altman, M. Egger, S. J. Pocock, P. C. Gøtzsche, and J. P. Vandenbroucke (2007). “The Strengthening the Reporting of Observational Studies in Epidemiology (STROBE) Statement: Guidelines for Reporting Observational Studies”. In: *The Lancet* 370.9596, pp. 1453–1457. doi: [10.1016/S0140-6736\(07\)61602-X](https://doi.org/10.1016/S0140-6736(07)61602-X).
- Greenland, S., J. Pearl, and J. M. Robins (1999). “Causal Diagrams for Epidemiologic Research”. In: *Epidemiology* 10.1, pp. 37–48. doi: [10.1097/00001648-199901000-00008](https://doi.org/10.1097/00001648-199901000-00008).
- Greenland, S., S. J. Senn, K. J. Rothman, J. B. Carlin, C. Poole, S. N. Goodman, and D. G. Altman (2016). “Statistical Tests, P Values, Confidence Intervals, and Power: A Guide to Misinterpretations”. In: *European Journal of Epidemiology* 31.4, pp. 337–350. doi: [10.1007/s10654-016-0149-3](https://doi.org/10.1007/s10654-016-0149-3).
- Grolemund, G. and H. Wickham (2011). “Dates and Times Made Easy with lubridate”. In: *Journal of Statistical Software* 40.3, pp. 1–25. doi: [10.18637/jss.v040.i03](https://doi.org/10.18637/jss.v040.i03).
- Hanley, J. A. and B. J. McNeil (1982). “The Meaning and Use of the Area under a Receiver Operating Characteristic (ROC) Curve”. In: *Radiology* 143.1, pp. 29–36. doi: [10.1148/radiology.143.1.7063747](https://doi.org/10.1148/radiology.143.1.7063747).
- Harrell, F. E. (2015). *Regression Modeling Strategies: With Applications to Linear Models, Logistic and Ordinal Regression, and Survival Analysis*. 2nd ed. Cham: Springer.
- Heinze, G., C. Wallisch, and D. Dunkler (2018). “Variable Selection – A Review and Recommendations for the Practicing Statistician”. In: *Biometrical Journal* 60.3, pp. 431–449. doi: [10.1002/bimj.201700067](https://doi.org/10.1002/bimj.201700067).
- Hosmer, D. W. and S. Lemeshow (1980). “Goodness of Fit Tests for the Multiple Logistic Regression Model”. In: *Communications in Statistics – Theory and Methods* 9.10, pp. 1035–1046. doi: [10.1080/03610928008827941](https://doi.org/10.1080/03610928008827941).

- Hosmer, D. W., S. Lemeshow, and R. X. Sturdivant (2013). *Applied Logistic Regression*. 3rd ed. Hoboken, NJ: Wiley.
- Kirkwood, B. R. and J. A. C. Sterne (2003). *Essential Medical Statistics*. 2nd ed. Oxford: Blackwell Science.
- Kruskal, W. H. and W. A. Wallis (1952). "Use of Ranks in One-Criterion Variance Analysis". In: *Journal of the American Statistical Association* 47.260, pp. 583–621. doi: [10.1080/01621459.1952.10483441](https://doi.org/10.1080/01621459.1952.10483441).
- Little, R. J. A. and D. B. Rubin (2019). *Statistical Analysis with Missing Data*. 3rd ed. Hoboken, NJ: Wiley.
- Lumley, T., P. Diehr, S. Emerson, and L. Chen (2002). "The Importance of the Normality Assumption in Large Public Health Data Sets". In: *Annual Review of Public Health* 23, pp. 151–169. doi: [10.1146/annurev.publhealth.23.100901.140546](https://doi.org/10.1146/annurev.publhealth.23.100901.140546).
- Mann, H. B. and D. R. Whitney (1947). "On a Test of Whether One of Two Random Variables is Stochastically Larger than the Other". In: *The Annals of Mathematical Statistics* 18.1, pp. 50–60. DOI: [10.1214/aoms/1177730491](https://doi.org/10.1214/aoms/1177730491).
- Mills, K. T., A. Stefanescu, and J. He (2020). "The Global Epidemiology of Hypertension". In: *Nature Reviews Nephrology* 16.4, pp. 223–237. doi: [10.1038/s41581-019-0244-2](https://doi.org/10.1038/s41581-019-0244-2).
- NCD Risk Factor Collaboration (NCD-RisC) (2021). "Worldwide Trends in Hypertension Prevalence and Progress in Treatment and Control from 1990 to 2019: A Pooled Analysis of 1201 Population-Representative Studies with 104 Million Participants". In: *The Lancet* 398.10304, pp. 957–980. doi: [10.1016/S0140-6736\(21\)01330-1](https://doi.org/10.1016/S0140-6736(21)01330-1).
- Pearson, K. (1900). "On the Criterion that a Given System of Deviations from the Probable in the Case of a Correlated System of Variables is Such that it Can be Reasonably Supposed to have Arisen from Random Sampling". In: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 50.302, pp. 157–175. doi: [10.1080/14786440009463897](https://doi.org/10.1080/14786440009463897).
- Peduzzi, P., J. Concato, E. Kemper, T. R. Holford, and A. R. Feinstein (1996). "A Simulation Study of the Number of Events per Variable in Logistic Regression Analysis". In: *Journal of Clinical Epidemiology* 49.12, pp. 1373–1379. doi: [10.1016/S0895-4356\(96\)00236-3](https://doi.org/10.1016/S0895-4356(96)00236-3).
- Peng, R. D. (2011). "Reproducible Research in Computational Science". In: *Science* 334.6060, pp. 1226–1227. doi: [10.1126/science.1213847](https://doi.org/10.1126/science.1213847).
- R Core Team (2026). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing. Vienna, Austria.
- Rothman, K. J., S. Greenland, and T. L. Lash (2008). *Modern Epidemiology*. 3rd ed. Philadelphia: Lippincott Williams & Wilkins.
- Rubin, D. B. (1976). "Inference and Missing Data". In: *Biometrika* 63.3, pp. 581–592. doi: [10.1093/biomet/63.3.581](https://doi.org/10.1093/biomet/63.3.581).
- Shapiro, S. S. and M. B. Wilk (1965). "An Analysis of Variance Test for Normality (Complete Samples)". In: *Biometrika* 52.3/4, pp. 591–611. doi: [10.2307/2333709](https://doi.org/10.2307/2333709).
- Sjoberg, D. D., K. Whiting, M. Curry, J. A. Lavery, and J. Larmarange (2021). "Reproducible Summary Tables with the gtsummary Package". In: *The R Journal* 13.1, pp. 570–580. doi: [10.32614/RJ-2021-053](https://doi.org/10.32614/RJ-2021-053).
- Spearman, C. (1904). "The Proof and Measurement of Association between Two Things". In: *The American Journal of Psychology* 15.1, pp. 72–101. doi: [10.2307/1412159](https://doi.org/10.2307/1412159).
- Sterne, J. A. C., I. R. White, J. B. Carlin, M. Spratt, P. Royston, M. G. Kenward, A. M. Wood, and J. R. Carpenter (2009). "Multiple Imputation for Missing Data in Epidemiological and Clinical Research: Potential and Pitfalls". In: *BMJ* 338, b2393. doi: [10.1136/bmj.b2393](https://doi.org/10.1136/bmj.b2393).
- Student (1908). "The Probable Error of a Mean". In: *Biometrika* 6.1, pp. 1–25. doi: [10.2307/2331554](https://doi.org/10.2307/2331554).

- VanderWeele, T. J. (2019). “Principles of Confounder Selection”. In: *European Journal of Epidemiology* 34.3, pp. 211–219. doi: [10.1007/s10654-019-00494-6](https://doi.org/10.1007/s10654-019-00494-6).
- Vittinghoff, E., D. V. Glidden, S. C. Shiboski, and C. E. McCulloch (2012). *Regression Methods in Biostatistics: Linear, Logistic, Survival, and Repeated Measures Models*. 2nd ed. New York: Springer.
- Wasserstein, R. L. and N. A. Lazar (2016). “The ASA Statement on p-Values: Context, Process, and Purpose”. In: *The American Statistician* 70.2, pp. 129–133. doi: [10.1080/00031305.2016.1154108](https://doi.org/10.1080/00031305.2016.1154108).
- Weissgerber, T. L., N. M. Milic, S. J. Winham, and V. D. Garovic (2015). “Beyond Bar and Line Graphs: Time for a New Data Presentation Paradigm”. In: *PLOS Biology* 13.4, e1002128. doi: [10.1371/journal.pbio.1002128](https://doi.org/10.1371/journal.pbio.1002128).
- Welch, B. L. (1947). “The Generalization of ‘Student’s’ Problem when Several Different Population Variances are Involved”. In: *Biometrika* 34.1/2, pp. 28–35. doi: [10.2307/2332510](https://doi.org/10.2307/2332510).
- Westreich, D. and S. Greenland (2013). “The Table 2 Fallacy: Presenting and Interpreting Confounder and Modifier Coefficients”. In: *American Journal of Epidemiology* 177.4, pp. 292–298. doi: [10.1093/aje/kws412](https://doi.org/10.1093/aje/kws412).
- Wickham, H. (2014). “Tidy Data”. In: *Journal of Statistical Software* 59.10, pp. 1–23. doi: [10.18637/jss.v059.i10](https://doi.org/10.18637/jss.v059.i10).
- Wickham, H. (2016). *ggplot2: Elegant Graphics for Data Analysis*. 2nd ed. New York: Springer.
- Wickham, H., M. Çetinkaya-Rundel, and G. Grolemund (2023). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. 2nd ed. Sebastopol, CA: O’Reilly Media.
- Wickham, H. et al. (2019). “Welcome to the tidyverse”. In: *Journal of Open Source Software* 4.43, p. 1686. doi: [10.21105/joss.01686](https://doi.org/10.21105/joss.01686).
- Wilson, G., J. Bryan, K. Cranston, J. Kitzes, L. Nederbragt, and T. K. Teal (2017). “Good Enough Practices in Scientific Computing”. In: *PLOS Computational Biology* 13.6, e1005510. doi: [10.1371/journal.pcbi.1005510](https://doi.org/10.1371/journal.pcbi.1005510).
- World Health Organization (2021). *Guideline for the Pharmacological Treatment of Hypertension in Adults*. Geneva: World Health Organization.
- Xie, Y. (2015). *Dynamic Documents with R and knitr*. 2nd ed. Boca Raton, FL: Chapman and Hall/CRC.
- Zhang, J. and K. F. Yu (1998). “What’s the Relative Risk? A Method of Correcting the Odds Ratio in Cohort Studies of Common Outcomes”. In: *JAMA* 280.19, pp. 1690–1691. doi: [10.1001/jama.280.19.1690](https://doi.org/10.1001/jama.280.19.1690).